

Tài liệu Hướng dẫn Quản lý Dữ liệu với DVC

Môi trường Machine Learning (Data Version Control)

Team ML & Data Engineering-NgoTanDat

21/06/2026

1 Mục tiêu và Chiến lược Quản lý

DVC (Data Version Control) sẽ được sử dụng để quản lý các tập dữ liệu dung lượng lớn không thể lưu trực tiếp trên Git. Quy trình tổ chức thư mục Machine Learning được chuẩn hóa cực kỳ đơn giản:

- Quản lý thư mục theo tiền tố (ví dụ: 01_train_val_test, 02_baseline_model, 03_model_output).
- Mỗi thư mục chứa tập dữ liệu hoặc mô hình riêng biệt, được track riêng biệt bằng file .dvc tương ứng.

2 Cấu hình CLI Remote Storage (S3 / Supabase)

Dưới đây là tập hợp các lệnh CLI chuẩn để cấu hình kết nối DVC tới kho lưu trữ từ xa (Remote Storage). Nếu bạn bị quên, chỉ cần chạy các lệnh sau:

```
1 dvc init
2 dvc remote add -d myremote s3://my-bucket/dvc-storage
3 dvc remote modify myremote endpointurl https://<project-id>.supabase.co/
  storage/v1/s3
4 dvc remote modify myremote access_key_id YOUR_ACCESS_KEY
5 dvc remote modify myremote secret_access_key YOUR_SECRET_KEY
```

3 Quy trình Push/Pull Dữ liệu Hàng ngày

Sau khi cấu hình Remote xong, quy trình làm việc với các file dữ liệu (ví dụ: chia tập Train/Val/Test) cực kỳ đơn giản:

```
1 dvc add data/01_train_val_test/
2 dvc push
3 git add data/01_train_val_test.dvc .gitignore
```

```
4 git commit -m "Thanh lap tap du lieu Train/Val/Test v1.0"  
5 git pull origin main  
6 dvc pull data/01_train_val_test.dvc
```

Nhờ quy trình này, toàn bộ dữ liệu lịch sử của mô hình ML đều được lưu vết một cách ngăn nắp và tiết kiệm tài nguyên!