

Báo cáo xử lý vấn đề Staging và Load dữ liệu vào Bảng đệm Supabase

Ngô Tấn Đạt

09/06/2026

Tổng quan

Báo cáo này ghi lại quá trình kiểm tra, xử lý và nạp dữ liệu từ các bảng raw staging `staging.stg_*` vào các bảng đệm trong schema `staging` trên Supabase.

Mục tiêu chính:

- Kiểm tra dữ liệu trước khi load để tránh mất dòng, dư dòng, duplicate hoặc lỗi ép kiểu.
- Xử lý vấn đề bảng `stg_solar_energy_generation` bị thiếu dữ liệu do file object storage sai.
- Enrich `dim_weather_type` từ `weather_code` theo WMO codes.
- Load dữ liệu vào bảng đệm sau khi dry-run validation pass.
- Kiểm tra toàn vẹn dữ liệu sau load.

1 Vấn đề phát hiện ban đầu

1.1 Bảng `stg_solar_energy_generation` thiếu dòng

Khi validate lần đầu, bảng `staging.stg_solar_energy_generation` trên Supabase không khớp với file raw gốc.

Nguồn dữ liệu	Số dòng	Số SiteKey
CSV raw local	2,731,946	42
Supabase staging ban đầu	1,048,575	17

Ngoài ra, cột `solargeneration` trên Supabase staging ban đầu có 177,059 giá trị bị sai format số, ví dụ:

1	16.015.625
2	1.203.125
3	119.140.625

Trong khi đó, file raw local `data/raw/Solar_Energy_Generation.csv` có:

```

1 rows = 2,731,946
2 unique SiteKey = 42
3 timestamp min/max = 2020-01-01 00:15:00 -> 2022-04-23
  23:45:00
4 SolarGeneration blank = 1,536,301
5 SolarGeneration valid numeric= 1,195,645
6 SolarGeneration invalid = 0

```

Nguyên nhân nghi ngờ là file trên Supabase Object Storage từng bị upload từ bản đã mở/lưu qua Excel. Con số 1,048,575 dòng gần đúng với giới hạn Excel 1,048,576 dòng trừ header.

1.2 Xử lý

File object storage được upload lại đúng từ CSV raw:

```

1 bucket: raw_solar_data
2 object: Solar_Energy_Generation.csv

```

Sau khi upload lại, object storage được kiểm tra và đã đúng:

```

1 rows = 2,731,946
2 unique SiteKey = 42
3 timestamp min/max = 2020-01-01 00:15:00 -> 2022-04-23
  23:45:00
4 SolarGeneration invalid = 0

```

Sau đó bảng `staging.stg_solar_energy_generation` được reload lại từ object storage mới.

2 Vấn đề `dim_weather_type`

File weather raw chỉ có các cột liên quan thời tiết sau:

```

1 weather_code
2 is_day

```

Trong khi bảng đệm `staging.dim_weather_type` có bốn cột:

```

1 weather_code
2 is_day
3 weather_condition
4 description

```

Theo tài liệu nội bộ:

```

1 weather | weather_code + is_day -> dim_weather_type.
  weather_type_id | generate combo
2 weather | weather_condition, description -> dim_weather_type.*
  | generate tu WMO codes

```

Vì vậy `weather_condition` và `description` không để NULL, mà được generate từ WMO Weather Interpretation Codes.

3 Mapping WMO dùng cho dim_weather_type

Mapping nghiệp vụ được áp dụng dựa trên `weather_code` và `is_day`.

Điều kiện	WeatherTypeLabel	Ý nghĩa
<code>code = 0, is_day = 1</code>	Sunny / Clear Sky	Trời quang đãng ban ngày
<code>code in (0,1,2,3), is_day = 0</code>	Clear / Cloudy Night	Đêm quang hoặc có mây
<code>code in (1,2), is_day = 1</code>	Partly Cloudy	Có mây rải rác ban ngày
<code>code = 3, is_day = 1</code>	Overcast	Âm u, mây che phủ
<code>code in (45,48)</code>	Fog / Mist	Sương mù
<code>code in (51,53,61,80)</code>	Light Rain / Drizzle	Mưa nhẹ hoặc mưa phùn
<code>code in (55,63,65,81,82)</code>	Moderate to Heavy Rain	Mưa vừa đến mưa to
<code>code in (56,57,66,67)</code>	Freezing Rain	Mưa đóng băng
<code>code in (71,73,75,77,85,86)</code>	Snowfall	Tuyết rơi
<code>code in (95,96,99)</code>	Thunderstorm / Hail	Giông bão hoặc mưa đá

4 Script load dữ liệu

Script load chính được đặt tại:

```
1 src/etl/pipeline/load_staging_to_buffers.py
```

Script có hai chế độ:

```
1 python src/etl/pipeline/load_staging_to_buffers.py
2 python src/etl/pipeline/load_staging_to_buffers.py --execute
```

- Không truyền `-execute`: chỉ dry-run, đếm số dòng dự kiến, không ghi dữ liệu.
- Có `-execute`: truncate bảng đệm và insert dữ liệu từ `staging.stg_*`.

5 Giải thích từng block code chính

5.1 Cấu hình môi trường

```
1 REPO = Path(__file__).resolve().parents[3]
2 ENV_FILE = REPO / ".env"
3 SCHEMA = "staging"
```

Block này xác định thư mục gốc project để đọc file `.env`. Vì script nằm trong `src/etl/pipeline/`, cần dùng `parents[3]` để trở về root project.

5.2 Parse timestamp của solar generation

```
1 CASE
2     WHEN timestamp ~ '^\d{4}-\d{2}-\d{2}_\d{2}'
3     THEN timestamp::timestamp
```

```

4      ELSE to_timestamp(timestamp, 'DD/MM/YYYY_HH24:MI')::timestamp
5 END

```

Block này xử lý hai format timestamp có thể gặp:

- Format mới sau khi reload object storage: YYYY-MM-DD HH:MI:SS
- Format cũ từng có trong staging lỗi: DD/MM/YYYY HH24:MI

Mục tiêu là giúp script không bị lỗi nếu staging thay đổi format timestamp giữa các lần upload.

5.3 Mapping WMO weather type

```

1 WITH weather_type_map(weather_code, is_day, weather_condition,
2   description) AS (
3     SELECT
4       w.weather_code,
5       w.is_day,
6       CASE
7         WHEN w.weather_code = 0 AND w.is_day = 1 THEN 'Sunny_/_
8           _Clear_Sky'
9         WHEN w.weather_code IN (0, 1, 2, 3) AND w.is_day = 0
10          THEN 'Clear_/_Cloudy_Night'
11         WHEN w.weather_code IN (1, 2) AND w.is_day = 1 THEN '
12           Partly_Cloudy'
13         WHEN w.weather_code = 3 AND w.is_day = 1 THEN '
14           Overcast'
15         WHEN w.weather_code IN (45, 48) THEN 'Fog_/_Mist'
16         WHEN w.weather_code IN (51, 53, 61, 80) THEN 'Light_
17           Rain_/_Drizzle'
18         WHEN w.weather_code IN (55, 63, 65, 81, 82) THEN '
19           Moderate_to_Heavy_Rain'
20         WHEN w.weather_code IN (56, 57, 66, 67) THEN 'Freezing
21           _Rain'
22         WHEN w.weather_code IN (71, 73, 75, 77, 85, 86) THEN '
23           Snowfall'
24         WHEN w.weather_code IN (95, 96, 99) THEN 'Thunderstorm
25           _/_Hail'
26       END AS weather_condition
27     FROM (
28       SELECT DISTINCT weather_code::int AS weather_code, is_day
29         ::int AS is_day
30       FROM staging.stg_open_meteo_weather_raw
31     ) w
32 )

```

Block này tạo bảng mapping tạm thời bằng SQL CTE. Mapping được generate từ các combo `weather_code` và `is_day` có thật trong dữ liệu. Nhờ đó, `dim_weather_type` không cần mapping CSV riêng và không dễ trống `weather_condition/description`.

5.4 Khai báo LoadSpec

```
1 @dataclass(frozen=True)
2 class LoadSpec:
3     table: str
4     columns: tuple[str, ...]
5     select_sql: str
6
7     @property
8     def insert_sql(self) -> str:
9         column_list = ", ".join(self.columns)
10        return f"INSERT INTO {SCHEMA}.{self.table} ({column_list})
        \n{self.select_sql}"
```

LoadSpec gom ba thông tin của mỗi bảng đệm:

- Tên bảng đích.
- Danh sách cột đích.
- Câu SELECT lấy dữ liệu từ bảng raw staging.

Từ đó script tự tạo câu INSERT INTO ... SELECT ... cho từng bảng.

5.5 Load dim_geography

```
1 SELECT DISTINCT
2     w.sitekey,
3     w.latitude::numeric AS latitude,
4     w.longitude::numeric AS longitude,
5     c.name AS location_name
6 FROM staging.stg_open_meteo_weather_raw w
7 LEFT JOIN staging.stg_solar_site_details s
8     ON w.sitekey = s.sitekey
9 LEFT JOIN staging.stg_campus_meta c
10    ON s.campuskey = c.id
```

Block này lấy:

- sitekey, latitude, longitude từ weather raw.
- location_name từ stg_campus_meta.name.

Không dùng trực tiếp lat/lon trong stg_solar_site_details vì dữ liệu ban đầu từng có format không ổn định.

5.6 Load dim_time

```
1 WITH all_times AS (
2     SELECT <solar_timestamp_expr> AS ts
3     FROM staging.stg_solar_energy_generation
4     UNION
```

```

5      SELECT timestamp::timestamp AS ts
6      FROM staging.stg_open_meteo_weather_raw
7  )
8  SELECT DISTINCT
9      to_char(ts, 'HH24:MI') AS time_string,
10     EXTRACT(hour FROM ts)::int AS hour,
11     EXTRACT(minute FROM ts)::int AS minute
12 FROM all_times

```

Block này gom tất cả mốc thời gian từ solar generation và weather raw. Kết quả có 96 time slots, tương ứng dữ liệu 15 phút/ngày.

5.7 Load fact_solar_energy_gen

```

1  SELECT
2      sitekey,
3      <solar_timestamp_expr> AS timestamp,
4      CASE
5          WHEN NULLIF(solargeneration, '') IS NULL THEN NULL
6          WHEN solargeneration ~ '^-[0-9]+(\.[0-9]+)?$'
7              THEN solargeneration::numeric
8          ELSE NULL
9      END AS energy_generated_kwh
10 FROM staging.stg_solar_energy_generation

```

Block này giữ nguyên số dòng từ source. solargeneration rỗng được chuyển thành NULL. Nếu có giá trị không đúng định dạng numeric, dry-run validation sẽ báo lỗi trước khi load.

5.8 Load fact_weather

```

1  SELECT
2      sitekey,
3      timestamp::timestamp AS timestamp,
4      weather_code::int AS weather_code,
5      is_day::int AS is_day,
6      shortwave_radiation::numeric AS shortwave_radiation,
7      temperature_2m::numeric AS temperature_c,
8      cloud_cover::numeric AS cloud_cover_total,
9      diffuse_radiation::numeric AS diffuse_solar_radiation,
10     direct_radiation::numeric AS direct_normal_irradiance
11 FROM staging.stg_open_meteo_weather_raw

```

Block này rename các cột weather raw về tên cột trong bảng đệm. Ví dụ:

- temperature_2m thành temperature_c
- cloud_cover thành cloud_cover_total
- diffuse_radiation thành diffuse_solar_radiation
- direct_radiation thành direct_normal_irradiance

5.9 Truncate và load

```
1 TRUNCATE_ORDER = (  
2     "fact_weather",  
3     "fact_solar_energy_gen",  
4     "dim_weather_type",  
5     "dim_time",  
6     "dim_solar_site",  
7     "dim_geography",  
8     "dim_date",  
9 )
```

Fact tables được truncate trước dimension tables để tránh rủi ro quan hệ phụ thuộc. Script dùng `TRUNCATE ... RESTART IDENTITY` để reset identity/sequence nếu bảng có cột tự tăng.

```
1 if not args.execute:  
2     print("Dry-run only. Re-run with --execute to truncate and  
3         load buffer tables.")  
4     return 0
```

Block này giúp script mặc định chạy an toàn. Nếu không truyền `-execute`, script chỉ in row count dự kiến và không ghi dữ liệu.

6 Kết quả validate trước load

Trước khi load, script validate dry-run đã pass toàn bộ:

Bảng đệm	Kết quả
dim_date	PASS
dim_geography	PASS
dim_solar_site	PASS
dim_time	PASS
dim_weather_type	PASS
fact_solar_energy_gen	PASS
fact_weather	PASS

7 Kết quả sau load

Sau khi load vào bảng đệm, kết quả kiểm tra an toàn dữ liệu như sau:

Bảng	Số dòng
dim_date	2,312
dim_geography	42
dim_solar_site	42
dim_time	96
dim_weather_type	22
fact_solar_energy_gen	2,731,946
fact_weather	850,752

Các kiểm tra toàn vẹn sau load:

```
1 PASS row_count all buffer tables
2 PASS duplicate rows = 0 for all buffer tables
3 PASS weather mapping missing = 0
4 PASS source solar invalid numeric = 0
5 PASS solar null preservation:
6     fact energy_generated_kwh NULL = 1,536,301
7     source solargeneration blank   = 1,536,301
```

8 Kết luận

Dữ liệu bảng đệm hiện tại đã an toàn để sử dụng cho các bước tiếp theo.

- Dữ liệu staging solar đã được reload đúng từ object storage.
- Không còn lỗi numeric ở solargeneration.
- dim_weather_type đã được enrich theo WMO codes và không còn NULL ở label/description.
- Tất cả bảng đệm đủ số dòng, không duplicate.
- NULL của energy_generated_kwh được giữ nguyên đúng theo source.