

Báo cáo xử lý outlier generation

Rolling-IQR audit và bảng flag trên Supabase

Ngo Tan Dat

14/06/2026

1 Mục tiêu

Báo cáo này ghi lại kết quả kiểm tra outlier cho cột `energy_generated_kwh` trong bảng `staging.fact_solar_energy_gen`. Mục tiêu không phải là xóa dữ liệu gốc hay thay đổi giá trị `energy_generated_kwh`, mà là bổ sung cột `rolling_outlier_flag` để team có thể review và dùng cho các thí nghiệm *training-clean*.

2 Nguồn dữ liệu đã dùng

Dữ liệu outlier được tính từ bản export trực tiếp từ Supabase, không dùng CSV raw bên ngoài:

```
staging.fact_solar_energy_gen →  
data/processed/temp_staging_buffers/temp_fact_solar_energy_gen.parquet →  
rolling outlier flag
```

Trước khi upload flag lại Supabase, file local đã được đối chiếu với bảng fact trên Supabase bằng fingerprint theo khóa và tổng energy.

Kiểm tra	Supabase	Local flag CSV
Tổng dòng	2,731,946	2,731,946
Số site	42	42
Timestamp nhỏ nhất	2020-01-01 00:15:00	2020-01-01 00:15:00
Timestamp lớn nhất	2022-04-23 23:45:00	2022-04-23 23:45:00
Checksum khóa <code>sitekey + timestamp</code>	PASS	PASS
Sai khác tổng <code>energy_generated_kwh</code>	2.0956e-21, xem như bằng 0	

Ghi chú: checksum theo raw text của `double precision` có cảnh báo do PostgreSQL và CSV có thể serialize số thực khác nhau ở vài chữ số cuối. Kiểm tra cũng dùng cho quyết định upload là checksum khóa, số dòng, số site, min/max timestamp và tổng energy.

3 Phương pháp outlier chính

Phương pháp chính hiện tại là **Rolling 1h IQR theo từng site và từng giờ**. Cách này chỉ dùng chuỗi generation 15 phút, không join weather, nên không tạo giả định rằng 4 dòng 15 phút trong cùng một giờ có cùng bức xạ.

Quy trình tính:

1. Sắp xếp dữ liệu theo `sitekey`, `timestamp`.
2. Với từng site, tính rolling mean 1 giờ của `energy_generated_kwh`.
3. Tính độ lệch tuyệt đối:

$$\text{rolling_1h_abs_deviation} = |\text{energy_generated_kwh} - \text{rolling_1h_mean}|$$

4. Gom nhóm theo `sitekey + hour`.
5. Trong mỗi nhóm, tính:

$$\text{upper_iqr} = Q3 + 1.5 \times (Q3 - Q1)$$

6. Gắn flag nếu:

$$\text{rolling_1h_abs_deviation} > \text{upper_iqr}$$

Điểm quan trọng: IQR không tính trên toàn bộ distribution. IQR được tính riêng theo từng `sitekey + hour`, để tránh so sánh trực tiếp các site có đặc tính khác nhau và tránh trộn các khung giờ vận hành khác nhau.

4 Kết quả rolling outlier

Nhóm dòng	Số dòng	Tỷ lệ
Tổng số dòng fact generation	2,731,946	100.000000%
Rolling outlier candidate	100,822	3.690482901199%
Giữ nguyên raw	2,631,124	96.309517098801%

File evidence chính:

- `reports/final_rolling_compare/05_full_rolling_iqr_candidates.csv`
- `reports/outlier_flag_pipeline_rolling_only/02_rolling_iqr_candidates.csv`
- `reports/outlier_flag_pipeline_rolling_only/03_rolling_flag_summary.csv`

5 So sánh với cách radiation-context cũ

Trước đó có kiểm tra theo bối cảnh `sitekey + hour + radiation band`. Cách này có giá trị để quan sát quan hệ với bức xạ, nhưng cần join hourly weather vào generation 15 phút. Vì weather theo giờ còn generation theo 15 phút, một giá trị weather có thể được gán cho nhiều dòng generation trong cùng giờ.

Kết quả so sánh:

Phương pháp	Candidate	Tỷ lệ	Ghi chú
Radiation-context IQR	58,073	2.125701%	Có join weather theo giờ
Rolling 1h IQR	100,822	3.690483%	Không join weather, giữ grain 15 phút
EWM span=4 IQR	170,676	6.247415%	Dùng làm sensitivity check

Rolling 1h IQR bắt lại 24,175 dòng trong nhóm radiation-context, tương đương 41.628640% candidate của radiation-context. Điều này cho thấy hai cách không hoàn toàn trùng nhau: radiation-context nhìn theo bức xạ, rolling nhìn theo độ lệch chuỗi thời gian của chính site.

6 Kết quả cập nhật trên Supabase

Đã bổ sung cột flag vào bảng fact gốc:

```
staging.fact_solar_energy_gen.rolling_outlier_flag
```

Việc cập nhật không dựa vào thứ tự dòng. Các dòng được đánh dấu `true` bằng đúng khóa:

`sitekey + timestamp`

Bảng flag phụ đã được dùng làm nguồn đối chiếu khóa. Bảng này có thể xóa thủ công sau khi team xác nhận, vì cột flag đã nằm trong bảng fact gốc.

Kiểm tra trong transaction cập nhật	Kết quả
Bảng flag phụ: số dòng	100,822
Bảng flag phụ: distinct <code>sitekey + timestamp</code>	100,822
Bảng flag phụ: duplicate key	0
Bảng flag phụ không match fact	0
Fact gốc: số dòng	2,731,946
Fact gốc: distinct <code>sitekey + timestamp</code>	2,731,946
Fact gốc: duplicate key	0
Số dòng reset <code>false</code>	2,731,946

Số dòng update <code>true</code> theo khóa	100,822
Fact sau update: <code>true</code>	100,822
Fact sau update: <code>false</code>	2,631,124
Fact sau update: <code>NULL</code>	0
Mapping check: <code>true_without_flag</code>	0
Mapping check: <code>flag_not_true</code>	0

Không truncate bảng fact gốc. Không insert thêm dòng vào fact. Không cập nhật theo thứ tự dòng. Chỉ thêm một cột boolean và update giá trị theo khóa `sitekey + timestamp`.

7 Cách sử dụng cột flag

Từ thời điểm cập nhật, có thể đọc trực tiếp từ bảng fact:

Listing 1: Đọc các dòng rolling outlier trong bảng fact gốc

```

1 SELECT
2   *
3 FROM staging.fact_solar_energy_gen
4 WHERE rolling_outlier_flag = true;
```

Kiểm tra tổng số flag trong bảng fact:

Listing 2: Kiểm tra số dòng true/false/null sau update

```

1 SELECT
2   COUNT(*) AS rows,
3   COUNT(*) FILTER (WHERE rolling_outlier_flag = true) AS true_flags,
4   COUNT(*) FILTER (WHERE rolling_outlier_flag = false) AS false_flags,
5   COUNT(*) FILTER (WHERE rolling_outlier_flag IS NULL) AS null_flags
6 FROM staging.fact_solar_energy_gen;
```

Kỳ vọng:

`rows = 2731946, true_flags = 100822, false_flags = 2631124, null_flags = 0`

Kiểm tra duplicate key của fact:

Listing 3: Kiểm tra duplicate key của fact

```

1 SELECT
2   COUNT(*) AS rows,
3   COUNT(DISTINCT (sitekey, timestamp)) AS distinct_keys,
4   COUNT(*) - COUNT(DISTINCT (sitekey, timestamp)) AS duplicate_keys
5 FROM staging.fact_solar_energy_gen;
```

Kỳ vọng:

`rows = 2731946, distinct_keys = 2731946, duplicate_keys = 0`

8 Khuyến nghị xử lý

Khuyến nghị hiện tại:

1. **Data Warehouse:** không xóa dữ liệu gốc. Giữ nguyên giá trị `energy_generated_kwh`; dùng cột `rolling_outlier_flag` để review và audit.
2. **Phân tích EDA:** khi cần quan sát dữ liệu sạch hơn, có thể lọc bỏ các dòng có `rolling_outlier_flag = true`, nhưng phải ghi rõ đây là bản phân tích đã lọc.
3. **Machine Learning:** tạo ít nhất hai dataset để so sánh: `raw` và `training_clean_rolling`. Chỉ dùng bản clean nếu metric validation theo thời gian tốt hơn và không làm mất pattern vận hành quan trọng.
4. **Không normalize/cap trực tiếp vào bảng gốc.** Nếu cần cap hoặc transform, thực hiện trong pipeline tạo feature/training dataset riêng.

9 Kết luận

Kết quả hiện tại đã có cột `rolling_outlier_flag` trong `staging.fact_solar_energy_gen`. Có 100,822 dòng candidate, chiếm 3.690482901199% tổng số dòng generation. Việc cập nhật đã được kiểm tra bằng khóa `sitekey + timestamp`: không có duplicate key, không có dòng flag nào không match fact, số dòng `true/false/NULL` đúng kỳ vọng. Phương pháp chính là Rolling 1h IQR theo `sitekey + hour`, phù hợp cho audit chuỗi generation 15 phút vì không phụ thuộc vào join weather theo giờ. Cột flag nên được dùng để review, lọc EDA hoặc tạo bản `training-clean`, không dùng để xóa raw data trong Data Warehouse.