

Báo cáo chi tiết phát hiện Outlier Generation

Rolling Window 1 giờ, IQR theo Site và Giờ

Ngo Tan Dat

18/06/2026

1 Tóm tắt kết quả

Báo cáo kiểm tra cột `energy_generated_kwh` trong bảng `staging.fact_solar_energy_gen`.
Phương pháp chính đã được triển khai là:

Rolling Window 1 giờ → độ lệch tuyệt đối → IQR riêng theo `sitekey` + `hour`

Kết quả trên toàn bộ dữ liệu:

Chỉ số	Kết quả
Tổng số dòng được kiểm tra	2,731,946
Số site	42
Khoảng thời gian	01/01/2020 00:15 – 23/04/2022 23:45
Giá trị generation null	0
Giá trị generation âm	0
Rolling-IQR candidate	100,822
Tỷ lệ candidate	3.690482901199%
Dòng không bị gấn cờ	2,631,124
Tỷ lệ không bị gấn cờ	96.309517098801%

Kết luận sử dụng: 100,822 dòng trên là *outlier candidate*, nghĩa là các điểm biến động bất thường so với chuỗi 1 giờ gần nhất của cùng site và so với phân phối lịch sử của cùng site, cùng giờ. Cờ này phục vụ review, EDA và so sánh dataset huấn luyện; không đồng nghĩa toàn bộ 100,822 dòng đều là lỗi cảm biến và không được dùng để xóa dữ liệu gốc tự động.

2 Nguồn dữ liệu, notebook và hình ảnh

2.1 Nguồn dữ liệu

Dữ liệu được export trực tiếp từ Supabase:

```
staging.fact_solar_energy_gen → data/processed/temp_staging_buffers/  
temp_fact_solar_energy_gen.parquet
```

File parquet có đủ 2,731,946 dòng, 42 site, không có generation null hoặc âm. Trước khi upload cò, dữ liệu local đã được đối chiếu với Supabase theo số dòng, số site, timestamp nhỏ nhất/lớn nhất, checksum khóa `sitekey + timestamp` và tổng energy.

2.2 Notebook tạo kết quả

Toàn bộ Rolling Window, IQR, CSV candidate và 8 hình trong báo cáo được tạo bởi:

```
notebooks/final_iqr_rolling_compare.ipynb
```

- Cell 5: tính Rolling Mean 1 giờ, Rolling Deviation và EWM span 4.
- Cell 7: tính IQR theo `sitekey + hour`, xuất danh sách candidate.
- Cell 11: xuất 8 hình boxplot vào `pictures/final_rolling_compare`.

2.3 Danh sách hình cần đưa lên Overleaf

Upload toàn bộ các file sau vào thư mục photo trên Overleaf:

1. 01_boxplot_rolling_abs_deviation_by_hour_with_fliers.png
2. 02_boxplot_rolling_abs_deviation_by_hour_no_fliers.png
3. 03_boxplot_ewm_abs_deviation_by_hour_with_fliers.png
4. 04_boxplot_ewm_abs_deviation_by_hour_no_fliers.png
5. 05_boxplot_rolling_abs_deviation_by_site_with_fliers.png
6. 06_boxplot_rolling_abs_deviation_by_site_no_fliers.png
7. 07_boxplot_ewm_abs_deviation_by_site_with_fliers.png
8. 08_boxplot_ewm_abs_deviation_by_site_no_fliers.png

Bốn hình Rolling là kết quả chính. Bốn hình EWM chỉ dùng làm kiểm chứng độ nhạy, không phải rule đã ghi vào Supabase.

2.4 Nguyên tắc đối chiếu hình và số liệu

Các kết luận trong báo cáo được tách thành hai loại bằng chứng:

- **Bằng chứng trực quan:** hình dạng box, median, whisker, vùng giờ hoặc site có dải fliers cao. Những nhận xét này được quan sát trực tiếp từ 8 file PNG.
- **Bằng chứng định lượng:** số dòng, tỷ lệ candidate, cực trị, Q_1 , Q_3 , IQR và upper bound. Các con số này lấy từ CSV do chính notebook xuất ra, không ước lượng bằng mắt từ hình.

Do boxplot không hiển thị số lượng từng điểm, không được nhìn mật độ chấm trên hình rồi suy ra số candidate. Số candidate phải đọc từ file summary hoặc đếm từ CSV evidence.

3 Phương pháp Rolling Window 1 giờ

3.1 Bước 1: Rolling Mean

Với từng site, dữ liệu được sắp theo timestamp. Tại thời điểm t , Rolling Mean 1 giờ được tính trên các quan sát nằm trong cửa sổ một giờ gần nhất:

$$\overline{E}_{t,1h} = \text{mean}(E_\tau : t - 1h < \tau \leq t)$$

Do dữ liệu có tần suất 15 phút, một cửa sổ đầy đủ thường gồm bốn điểm:

$$t - 45, \quad t - 30, \quad t - 15, \quad t$$

Nói cách khác, code hiện tại dùng cửa sổ **có chứa giá trị tại thời điểm t** . Ví dụ tại 15:45, cửa sổ gồm 15:00, 15:15, 15:30 và 15:45. Đây là phép phát hiện bất thường tại chính thời điểm quan sát, không phải feature dùng để dự báo tương lai.

Code thực tế trong notebook:

Listing 1: Rolling Mean 1 giờ theo từng site

```
1 rolling_mean = (  
2     group.set_index('timestamp')['energy_generated_kwh']  
3     .rolling('1h', min_periods=1)  
4     .mean()  
5 )
```

3.2 Bước 2: Độ lệch so với cửa sổ

$$D_t = E_t - \overline{E}_{t,1h}$$

$$A_t = |D_t|$$

Trong đó:

- E_t : generation tại thời điểm đang kiểm tra.
- $\overline{E}_{t,1h}$: generation trung bình trong cửa sổ một giờ gần nhất của cùng site.
- $D_t < 0$: generation hiện tại giảm so với mức trung bình một giờ.
- $D_t > 0$: generation hiện tại tăng so với mức trung bình một giờ.
- A_t : độ lớn của biến động, không phụ thuộc chiều tăng hay giảm.

3.3 Vì sao tính “giá trị hiện tại trừ trung bình”?

Phép trừ:

$$D_t = E_t - \overline{E}_{t,1h}$$

trả lời trực tiếp câu hỏi:

Giá trị hiện tại đang cao hơn hay thấp hơn mức hoạt động gần nhất của chính site bao nhiêu kWh?

Ví dụ:

- Nếu $E_t = 30$ và Rolling Mean bằng 20 thì $D_t = 30 - 20 = +10$: hiện tại cao hơn mức gần nhất 10 kWh.
- Nếu $E_t = 10$ và Rolling Mean bằng 20 thì $D_t = 10 - 20 = -10$: hiện tại thấp hơn mức gần nhất 10 kWh.

Về mặt độ lớn, viết theo chiều ngược lại $\overline{E}_{t,1h} - E_t$ cũng cho cùng kết quả sau khi lấy trị tuyệt đối:

$$|E_t - \overline{E}_{t,1h}| = |\overline{E}_{t,1h} - E_t|$$

Chiều **current - baseline** được chọn vì dấu dương biểu thị tăng và dấu âm biểu thị giảm, phù hợp cách diễn giải residual thông thường.

3.4 Vì sao phải lấy trị tuyệt đối?

Nếu áp dụng IQR trực tiếp lên D_t , các cú giảm mạnh có giá trị âm và các cú tăng mạnh có giá trị dương. Khi đó cần xây dựng đồng thời lower bound và upper bound.

Mục tiêu hiện tại là đo **mức độ thay đổi**, bất kể chiều tăng hay giảm, nên dùng:

$$A_t = |D_t|$$

Ví dụ hai trường hợp:

$$D_1 = +10, \quad D_2 = -10$$

sau khi lấy trị tuyệt đối:

$$A_1 = A_2 = 10$$

Hai trường hợp đều lệch khỏi baseline 10 kWh và đều cần được kiểm tra. Nếu không lấy trị tuyệt đối mà chỉ kiểm tra upper bound dương, trường hợp $D_2 = -10$ có thể bị bỏ sót dù đây là một cú sụt giảm lớn.

Việc giữ cả hai cột có hai mục đích khác nhau:

- `rolling_1h_deviation`: giữ dấu để biết candidate tăng hay giảm.
- `rolling_1h_abs_deviation`: dùng để so sánh độ lớn biến động với ngưỡng IQR.

3.5 Vì sao chọn cửa sổ một giờ?

Dữ liệu generation có tần suất 15 phút. Cửa sổ một giờ thường chứa bốn quan sát, đủ để tạo baseline ngắn hạn nhưng vẫn phản ứng với thay đổi trong ngày:

- cửa sổ 15 phút chỉ có một điểm, không tạo được baseline;
- cửa sổ 30 phút chỉ có khoảng hai điểm, dễ dao động;
- cửa sổ một giờ có khoảng bốn điểm và vẫn giữ được biến động ngắn hạn;
- cửa sổ quá dài có thể trộn nhiều trạng thái bức xạ khác nhau và làm chậm phản ứng với sự kiện đột ngột.

Một giờ là lựa chọn thực nghiệm, có thể giải thích và tính tay, không phải hằng số vật lý bắt buộc. EWM span 4 được dùng làm đối chứng để kiểm tra mức nhạy của lựa chọn này.

3.6 Lưu ý về việc cửa sổ chứa điểm hiện tại

Do Rolling Mean hiện tại chứa cả E_t , một điểm cực đoan cũng tham gia vào trung bình và kéo baseline về phía chính nó. Vì vậy độ lệch thu được nhỏ hơn so với trường hợp chỉ lấy ba hoặc bốn điểm trước thời điểm t .

Ví dụ Site 27 lúc 15:45:

$$\text{mean}(97.84375, 97.03125, 93.65625, 0) = 72.1328125$$

Nếu chỉ dùng ba điểm trước đó, baseline sẽ là:

$$\frac{97.84375 + 97.03125 + 93.65625}{3} = 96.1770833$$

Khi đó độ lệch của giá trị 0 sẽ là 96.1770833 kWh thay vì 72.1328125 kWh.

Thiết kế hiện tại vẫn hợp lệ cho **audit đồng thời** vì toàn bộ ngưỡng IQR được xây dựng nhất quán bằng cùng một công thức. Tuy nhiên, nếu tạo feature cho mô hình dự báo tại thời điểm t , baseline phải chỉ dùng dữ liệu trước t , ví dụ dùng `shift(1)` trước khi rolling, để tránh đưa thông tin của điểm đang dự báo vào feature.

3.7 Bước 3: IQR theo đúng ngữ cảnh site và giờ

Không tính một ngưỡng chung cho toàn bộ 42 site. Các giá trị A_t được nhóm theo:

$$\text{sitekey} + \text{hour}$$

Ví dụ, dòng Site 27 lúc 15:45 chỉ được đối chiếu với phân phối độ lệch của **Site 27 trong giờ 15** qua toàn bộ các ngày. Nó không bị so sánh với Site 7, Site 11 hoặc các giờ ban đêm.

Trong mỗi nhóm:

$$IQR = Q_3 - Q_1$$

$$U = Q_3 + 1.5 \times IQR$$

Dòng được gắn cờ khi:

$$\boxed{A_t > U}$$

4 Ví dụ tính tay bằng dữ liệu thật

4.1 Ngưỡng của Site 27, giờ 15

Nhóm `sitekey` = 27, `hour` = 15 có 3,320 quan sát. Phân phối `rolling_1h_abs_deviation` cho kết quả:

Thống kê	Giá trị
Q_1	2.062500
Median	4.510278469260427
Q_3	8.359375
$IQR = Q_3 - Q_1$	6.296875
$U = Q_3 + 1.5 \times IQR$	17.8046875

4.2 Ngày 30/10/2020: điểm bị gấn cờ

Bốn quan sát trong cửa sổ kết thúc lúc 15:45:

Timestamp	Generation (kWh)
30/10/2020 15:00	97.843750
30/10/2020 15:15	97.031250
30/10/2020 15:30	93.656250
30/10/2020 15:45	0.000000

Tính Rolling Mean:

$$\bar{E}_{15:45} = \frac{97.84375 + 97.03125 + 93.65625 + 0}{4} = 72.1328125$$

Độ lệch:

$$D_{15:45} = 0 - 72.1328125 = -72.1328125$$

$$A_{15:45} = |-72.1328125| = 72.1328125$$

So sánh với ngưỡng của Site 27, giờ 15:

$$72.1328125 > 17.8046875$$

Vì vậy dòng 27, 2020-10-30 15:45:00 được gán `rolling_outlier_flag=true`. Dòng này thể hiện generation giảm đột ngột từ mức trên 93 kWh về 0 trong 15 phút.

4.3 Ngày 29/10/2020: cùng site, cùng giờ nhưng không bị gấn cở

Bốn quan sát trong cửa sổ kết thúc lúc 15:45:

Timestamp	Generation (kWh)
29/10/2020 15:00	13.437500
29/10/2020 15:15	28.187500
29/10/2020 15:30	24.937500
29/10/2020 15:45	11.781250

$$\bar{E}_{15:45} = \frac{13.4375 + 28.1875 + 24.9375 + 11.78125}{4} = 19.5859375$$

$$D_{15:45} = 11.78125 - 19.5859375 = -7.8046875$$

$$A_{15:45} = 7.8046875$$

$$7.8046875 < 17.8046875$$

Dòng này không bị gấn cở. Hai ngày được đánh giá bằng cùng một ngưỡng vì cùng Site 27 và cùng giờ 15, nhưng chỉ ngày 30/10 có độ lệch vượt ngưỡng.

4.4 Cách trình bày khi so sánh hai ngày

Khi review thủ công một candidate, cần trình bày đủ:

1. Chọn cùng một site và cùng giờ để bảo đảm so sánh công bằng.
2. Liệt kê bốn dòng 15 phút trong Rolling Window.
3. Tính Rolling Mean.
4. Tính độ lệch có dấu và độ lệch tuyệt đối.
5. Lấy Q_1 , Q_3 , IQR và upper bound của đúng nhóm `sitekey + hour`.
6. Kết luận candidate bằng phép so sánh $A_t > U$.

5 Kết quả chi tiết

5.1 Candidate theo chiều biến động

Loại candidate	Số dòng	Tỷ lệ trong candidate
Giảm so với Rolling Mean ($D_t < 0$)	52,223	51.797%
Tăng so với Rolling Mean ($D_t > 0$)	48,599	48.203%
Generation bằng 0	16,012	15.882%
Generation dương	84,810	84.118%

Candidate không chỉ là generation cao. Phương pháp phát hiện cả:

- tăng đột ngột so với cửa sổ;
- giảm đột ngột;
- rơi về 0 trong khi các điểm ngay trước đó đang cao;
- chuyển trạng thái nhanh ở đầu hoặc cuối chu kỳ phát điện.

5.2 Các site có tỷ lệ candidate cao

Site	Tổng dòng	Candidate	Tỷ lệ site
27	79,805	4,646	5.821690%
7	79,319	4,521	5.699769%
11	42,041	1,742	4.143574%
1	79,319	3,183	4.012910%
41	79,319	3,138	3.956177%
2	79,319	3,134	3.951134%
15	65,020	2,562	3.940326%
40	64,252	2,475	3.852020%

Site 27 và Site 7 có tỷ lệ cao nhất. Đây là lý do hình theo site cần được giữ trong báo cáo. Tuy nhiên, tỷ lệ cao chỉ cho biết chuỗi biến động nhiều hơn, chưa đủ để kết luận metadata site hoặc cảm biến bị sai.

5.3 Các giờ có tỷ lệ candidate cao

Giờ	Tổng dòng	Candidate	Tỷ lệ theo giờ
-----	-----------	-----------	----------------

20	113,472	14,162	12.480612%
6	114,272	11,639	10.185347%
11	113,825	7,250	6.369427%
7	114,236	7,224	6.323751%
15	113,624	6,942	6.109625%
16	113,671	6,895	6.065751%
21	113,181	6,425	5.676748%
14	113,624	6,429	5.658136%
12	113,699	6,359	5.592837%
13	113,639	5,813	5.115321%

Giờ 6 và 20–21 có nhiều candidate và phù hợp với giả thuyết đây là vùng chuyển trạng thái phát điện. Các giờ 11–16 có độ lệch lớn hơn, phù hợp với giai đoạn generation hoạt động ở biên độ cao. Đây là diễn giải từ timestamp và hình dạng chuỗi, chưa phải kết luận nguyên nhân. Muốn xác nhận cần đối chiếu thêm bức xạ, `is_day` hoặc nhật ký vận hành. Do đó, báo cáo không chỉ đọc số lượng candidate mà còn phải đọc độ lớn trên trục y của boxplot.

6 Giải thích từng hình Rolling chính


6.1 Cách đọc boxplot trong báo cáo

Mỗi boxplot có các thành phần:

- cạnh dưới box: Q_1 ;
- đường màu cam: median;
- cạnh trên box: Q_3 ;
- chiều cao box: $IQR = Q_3 - Q_1$;
- whisker: vùng dữ liệu không bị xem là flier theo quy tắc boxplot;
- các chấm đen: fliers của phân phối đang được vẽ.

Lưu ý quan trọng: Hình theo giờ gộp dữ liệu của 42 site để mô tả tổng quan. Trong khi đó, rule tạo `rolling_outlier_flag` tính IQR riêng trong từng nhóm `sitekey + hour`. Vì vậy hình tổng quan hỗ trợ quan sát, còn CSV `03_rolling_iqr_site_hour_stats.csv` mới chứa ngưỡng quyết định cho từng nhóm.

6.2 Hình 1: Rolling deviation theo giờ, có hiển thị fliers



Hình 1: Rolling 1h absolute deviation theo 24 giờ, hiển thị các điểm ngoài râu boxplot.

Cách đọc: trục x là giờ 0–23; trục y là `rolling_1h_abs_deviation`. Mỗi box tổng hợp toàn bộ site tại giờ đó để trực quan hóa. Các điểm đen phía trên râu là các độ lệch lớn.


Quan sát:

- Giờ 0–4 và 22–23 tập trung gần 0.
- Từ 8–18 xuất hiện dải fliers cao; đây là vùng generation thường có biên độ lớn trong dữ liệu quan sát.
- Các cực trị lớn nhất tập trung khoảng 11–17.
- Cực trị toàn tập của Rolling Absolute Deviation là 72.1328125 kWh.

Hình này dùng để thấy toàn bộ biên độ outlier nhưng phần box bị nén do cực trị, vì vậy cần Hình 2 để đọc phần phân phối trung tâm.

Đối chiếu định lượng: theo CSV candidate, giờ 20 có 14,162 candidate, giờ 6 có 11,639 candidate. Tuy nhiên Hình 1 không trực tiếp thể hiện hai số này; hình chỉ cho thấy biên độ và mật độ trực quan của độ lệch.

6.3 Hình 2: Rolling deviation theo giờ, ẩn fliers



Hình 2: Rolling 1h absolute deviation theo 24 giờ, ẩn fliers để quan sát phần phân phối trung tâm.


Quan sát:

- Median ban đêm gần 0 vì generation ổn định ở mức 0 hoặc rất thấp.
- Box bắt đầu mở rộng từ giờ 7–8.
- Phân phối trung tâm rộng nhất trong khoảng 9–17.
- Sau giờ 18, median và IQR giảm dần.

Hình này không xóa fliers khỏi dữ liệu; tham số `showfliers=False` chỉ ẩn điểm trên biểu đồ để nhìn rõ box, median và whisker.

Ý nghĩa đối với quy trình: khoảng 9–17 có box rộng vì generation đang hoạt động và thay đổi theo thời gian. Do đó một giá trị cao trong giờ này không tự động là lỗi; nó chỉ trở thành candidate khi độ lệch của đúng site, đúng giờ vượt upper IQR của nhóm đó.

6.4 Hình 3: Rolling deviation theo site, có hiển thị fliers




Hình 3: Rolling 1h absolute deviation của 42 site, hiển thị fliers.

Quan sát:

- Site 11, 25 và 27 có dải độ lệch lớn nổi bật.
- Site 27 chứa cực trị 72.1328125 kWh.
- Các site có quy mô generation khác nhau nên độ cao box khác nhau.
- Đây là lý do ngưỡng cuối cùng được tính riêng theo site và giờ, không dùng một upper bound chung cho 42 site.

Đối chiếu định lượng: Site 27 có 4,646 candidate trên 79,805 dòng (5.821690%); Site 7 có 4,521 candidate trên 79,319 dòng (5.699769%). Các tỷ lệ này lấy từ phép đếm trên dữ liệu đầy đủ, không đọc bằng mắt từ chiều cao box.

6.5 Hình 4: Rolling deviation theo site, ẩn fliers



Hình 4: Rolling 1h absolute deviation của 42 site, ẩn fliers.

Quan sát:

- Site 11, 25 và 27 vẫn có box/whisker rộng hơn nhiều site khác.
- Một số site như 4, 5, 9, 16, 28, 29 có phân phối hẹp.
- Sự khác biệt giữa site xác nhận rằng so sánh toàn hệ thống bằng một IQR chung sẽ không công bằng.

Hình 4 cho phép so sánh độ rộng phân phối thông thường giữa các site mà không bị các cực trị kéo giãn trục y . Nó không phải hình “sau khi xóa outlier”; toàn bộ dữ liệu vẫn được sử dụng, chỉ không vẽ các dấu chấm flier.


7 Kiểm chứng độ nhạy bằng EWM span 4

EWM span 4 được chạy như phương pháp đối chứng. Với `span=4`, hệ số cập nhật là:

$$\alpha = \frac{2}{4 + 1} = 0.4$$

EWM đặt trọng số lớn hơn cho các quan sát gần hiện tại, vì vậy phản ứng nhanh hơn Rolling Mean đơn giản. Kết quả EWM gần 170,676 candidate, tương đương 6.247414846414%, cao hơn Rolling-IQR.

7.1 Hình 5: EWM theo giờ, có hiển thị fliers




Hình 5: EWM span 4 absolute deviation theo giờ, có fliers.

Quan sát trực tiếp:

- box ở giờ 0–4 và 22–23 gần sát 0;
- box mở rộng rõ từ giờ 7 và thu hẹp sau giờ 19–20;
- các fliers có biên độ lớn tập trung chủ yếu từ giờ 8–19;
- cực trị EWM Absolute Deviation trong CSV là 57.470810, thấp hơn cực trị Rolling là 72.1328125.

Hình cho thấy EWM vẫn phản ánh chu kỳ hoạt động ban ngày. Tuy nhiên số candidate không thể đọc trực tiếp từ số chấm vì các điểm chồng lên nhau; con số 170,676 lấy từ `09_method_candidate_summary.csv`.

7.2 Hình 6: EWM theo giờ, ẩn fliers




Hình 6: EWM span 4 absolute deviation theo giờ, ẩn fliers.

Quan sát trực tiếp:

- median tăng từ giờ 7, cao nhất tương đối trong các giờ 9–10 và 15–16;
- phần box trung tâm trong khoảng giờ 9–17 nằm chủ yếu dưới khoảng 1.4 kWh;
- sau giờ 18, median và độ rộng box giảm;
- so với Hình 2, phân phối trung tâm EWM thường hẹp hơn vì EWM điều chỉnh nhanh theo các quan sát mới.

Việc ẩn fliers chỉ thay đổi cách hiển thị, không thay đổi dữ liệu hoặc kết quả candidate.

7.3 Hình 7: EWM theo site, có hiển thị fliers




Hình 7: EWM span 4 absolute deviation theo 42 site, có fliers.

Quan sát trực tiếp:

- Site 11, 25 và 27 tiếp tục có dải biến động nổi bật;
- Site 27 có fliers cao nhất, gần 57.47 kWh;
- Site 11 có dải fliers lên khoảng giữa 40 kWh;
- nhiều site khác vẫn có median gần 0 nhưng xuất hiện đuôi phải dài.

Điều này cho thấy kết luận “các site có quy mô và mức biến động khác nhau” không chỉ xuất hiện ở Rolling Mean mà còn xuất hiện trong phương pháp EWM.

7.4 Hình 8: EWM theo site, ẩn fliers



Hình 8: EWM span 4 absolute deviation theo 42 site, ẩn fliers.

Quan sát trực tiếp:

- Site 11 có box và whisker trung tâm rộng nhất;
- Site 25 và 27 tiếp tục nổi bật với whisker gần 9–9.5 kWh;
- Site 18, 19, 40 và 41 có phân phối rộng hơn nhiều site lân cận;
- các site 4, 5, 9, 16, 28 và 29 có box hẹp gần 0.

EWM được giữ trong báo cáo để chứng minh nhóm đã kiểm tra sensitivity. Tuy nhiên, không dùng EWM làm cờ chính vì:

- gần nhiều candidate hơn: 170,676 so với 100,822;
- khó giải thích bằng tính tay hơn Rolling Mean bốn điểm;
- phụ thuộc trọng số EWM và lịch sử trước đó;
- Rolling Window 1 giờ phù hợp hơn với yêu cầu báo cáo có thể audit.

8 So sánh các phương pháp đã thử

Phương pháp	Candidate	Tỷ lệ	Vai trò
Radiation-context IQR	58,073	2.125701%	Thử nghiệm cũ, cần join hourly weather với generation 15 phút.
Rolling 1h IQR	100,822	3.690483%	Phương pháp chính, không join weather, dùng để tạo flag.
EWM span 4 IQR	170,676	6.247415%	Đối chứng độ nhạy, không upload làm flag chính.

Rolling-IQR giao với Radiation-context tại 24,175 dòng:

- 23.977902% candidate Rolling nằm trong tập Radiation-context.
- Rolling bắt lại 41.628640% candidate của Radiation-context.

Hai phương pháp không đo cùng một khái niệm. Radiation-context đánh giá generation trong nhóm bức xạ; Rolling đánh giá tốc độ thay đổi của chính chuỗi generation. Do weather chỉ có grain một giờ trong dữ liệu hiện tại, Rolling được chọn để không nhân cùng một weather value cho bốn dòng generation 15 phút.

9 Giới hạn cần ghi rõ

1. Rolling-IQR là rule thống kê, không có nhãn lỗi cảm biến làm ground truth.
2. Cờ phát hiện biến động, không tự xác định nguyên nhân. Nguyên nhân có thể là lỗi đo, mất kết nối, shutdown, curtailment, mây thay đổi nhanh hoặc vận hành.
3. Ở các nhóm có nhiều giá trị bằng 0, IQR có thể rất nhỏ hoặc bằng 0. Có 9,561 candidate thuộc nhóm có upper IQR bằng 0; các điểm này vẫn đúng theo rule nhưng cần review thận trọng.
4. Boxplot theo giờ trong hình gộp 42 site để trực quan; quyết định flag thật vẫn dùng ngưỡng riêng theo `sitekey + hour`.
5. Không sử dụng cờ này để sửa hoặc nội suy `energy_generated_kwh` trong Data Warehouse.

10 Phạm vi giải quyết theo các tình huống vận hành thực tế

10.1 Câu hỏi mà thuật toán hiện tại giải quyết

Rolling-IQR hiện tại trả lời câu hỏi:

Tại một thời điểm, sản lượng điện của một site có biến động bất thường so với cửa sổ một giờ gần nhất và so với phân phối lịch sử của chính site trong cùng khung giờ hay không?

Thuật toán phát hiện **thời điểm biến động bất thường**, nhưng không tự xác định nguyên nhân vật lý gây ra biến động.

Tình huống	Khả năng hiện tại	Giải thích
Generation tăng hoặc giảm đột ngột	Giải quyết trực tiếp	Rolling deviation đo mức chênh lệch so với một giờ gần nhất; IQR theo <code>sitekey + hour</code> xác định candidate.
Generation rơi về 0 đột ngột	Có thể phát hiện	Ví dụ Site 27 ngày 30/10/2020 lúc 15:45 được flag khi generation từ trên 93 kWh rơi về 0. Thuật toán chưa biết nguyên nhân là lỗi thiết bị, mất kết nối hay vận hành.
Shading hoặc mây làm giảm sản lượng	Chỉ phát hiện một phần	Có thể flag cú giảm, nhưng không phân biệt shading với mây nếu chưa có weather cùng grain và dữ liệu vận hành.
Mưa rửa bụi làm sản lượng tăng	Chỉ phát hiện một phần	Có thể flag cú tăng đột ngột, nhưng không chứng minh nguyên nhân do mưa hoặc cleaning.
Hỏng inverter làm giảm khoảng 1/3 sản lượng	Chỉ phát hiện thời điểm chuyển trạng thái	Khi sản lượng vừa giảm, rolling deviation có thể lớn. Nếu hệ thống tiếp tục ổn định ở mức thấp, rolling mean thích nghi và độ lệch giảm, nên sự cố kéo dài có thể không tiếp tục bị flag.

Inverter clipping	Chưa giải quyết tốt	Clipping thường tạo vùng công suất phẳng kéo dài. Khi các điểm liên tiếp gần nhau, rolling deviation có thể nhỏ dù trạng thái bị giới hạn công suất.
Performance Ratio vượt 100%	Không giải quyết	Dữ liệu hiện tại chưa có PR, công suất DC/AC theo inverter và irradiation chuẩn hóa ở cùng thời điểm.
Generation âm hoặc NaN	Không cần Rolling-IQR	Đây là lỗi domain trực tiếp. Dữ liệu hiện tại có 0 dòng generation âm và 0 dòng generation null.
Suy hao tấm pin dài hạn	Không phù hợp	Rolling Window 1 giờ tập trung vào biến động ngắn hạn, không mô hình hóa xu hướng degradation theo tháng hoặc năm.

10.2 Vì sao chưa thể kết luận shading hoặc inverter failure

Các phân tích như scatter cloud giữa công suất và bức xạ, Performance Ratio và nhiệt độ module, hoặc điện áp DC và nhiệt độ module cần thêm các trường:

- điện áp DC và công suất DC/AC theo inverter;
- nhiệt độ module;
- mã inverter gắn với từng observation;
- irradiation cùng grain 15 phút;
- rated capacity chính thức và Performance Ratio;
- nhật ký shutdown, maintenance, clipping hoặc shading.

Data Warehouse hiện có generation theo site và weather theo geography/thời gian, nhưng chưa có telemetry cấp inverter và module. Vì vậy báo cáo chỉ được kết luận:

Rolling-IQR phát hiện candidate có biến động generation bất thường. Nguyên nhân cần được xác minh bằng weather, metadata thiết bị và nhật ký vận hành.

Không nên ghi rằng thuật toán hiện tại đã phát hiện chính xác shading, inverter failure, soiling hoặc clipping.

10.3 Các câu hỏi thực tế phù hợp với project hiện tại

1. Làm thế nào phát hiện các thời điểm sản lượng tăng hoặc giảm đột ngột so với hành vi gần nhất của chính site, đồng thời tránh sử dụng một ngưỡng chung cho các site có quy mô khác nhau?

Trả lời: sử dụng Rolling Window 1 giờ và IQR riêng theo `sitekey + hour`.

2. Các candidate có nên bị xóa trước khi huấn luyện mô hình dự báo hay chỉ nên được lưu thành cở để so sánh dataset raw và clean?

Trả lời: giữ nguyên trong Data Warehouse, tạo hai version dataset ML và quyết định dựa trên temporal validation.

3. Khi generation giảm đột ngột, thuật toán có thể kết luận nguyên nhân là lỗi thiết bị hay thời tiết không?

Trả lời: chưa thể. Thuật toán chỉ phát hiện sự kiện biến động, chưa phân loại nguyên nhân.

10.4 Hướng phát triển

Các tình huống shading, inverter failure, clipping và soiling nên được xem là hướng phát triển:

1. Bổ sung telemetry cấp inverter và module.
2. Đồng bộ generation và irradiation ở cùng grain 15 phút.
3. Tạo scatter plot giữa generation và irradiation theo từng site/inverter.
4. Xây dựng normalized power hoặc Performance Ratio khi có đủ metadata.
5. Phát hiện các cụm điểm tách khỏi quan hệ vận hành bình thường.
6. Kết hợp candidate với weather và maintenance log để gán nguyên nhân.
7. Đánh giá riêng sự cố ngắn hạn và suy giảm kéo dài; không dùng một Rolling Window cho cả hai bài toán.

11 Cập nhật và validation trên Supabase

Cột đã được cập nhật:

```
staging.fact_solar_energy_gen.rolling_outlier_flag
```

Việc cập nhật dùng chính xác khóa `sitekey + timestamp`, không dựa vào thứ tự dòng.

Kiểm tra	Kết quả
Fact staging rows	2,731,946
Distinct <code>sitekey + timestamp</code>	2,731,946
Duplicate key	0
Candidate table rows	100,822
Candidate distinct key	100,822
Candidate không match fact	0
Fact flag true	100,822
Fact flag false	2,631,124
Fact flag null	0
True nhưng không có trong candidate	0
Candidate nhưng fact không true	0

Khi load sang `datawarehouse.fact_solar_energy_gen`, kết quả vẫn giữ:

- 2,731,946 dòng;
- 0 duplicate `site_id + date_id + time_id`;
- 100,822 flag true;
- 2,631,124 flag false;
- 0 flag null.

12 Cách sử dụng cho Data Warehouse và Machine Learning

12.1 Data Warehouse

- Giữ nguyên tất cả 2,731,946 dòng.
- Giữ nguyên giá trị `energy_generated_kwh`.
- Dùng `rolling_outlier_flag` làm thuộc tính audit.
- Không cap, normalize, interpolation hoặc xóa trực tiếp trong fact.

12.2 EDA

Khi phân tích, phải trình bày song song:

1. Kết quả trên toàn bộ dữ liệu.
2. Kết quả sensitivity khi loại các candidate.

Không được chỉ trình bày bản đã lọc vì có thể che mất sự kiện vận hành thật.

12.3 Machine Learning

Tạo hai version dataset:

- **raw**: giữ toàn bộ dòng, có cột flag làm feature/audit.
- **training_clean_rolling**: loại candidate chỉ trong dataset train.

Hai dataset phải dùng cùng temporal split và cùng model. Chỉ chọn bản clean nếu:

- MAE/RMSE/WAPE trên validation và test tốt hơn;
- không làm sai pattern bình minh, hoàng hôn và ngày nhiều mây;
- kết quả ổn định theo site, không chỉ tốt ở metric tổng;
- không dùng dữ liệu tương lai để tạo feature.

13 Lệnh và file evidence

Listing 2: Kiểm tra và áp dụng Rolling flag

```
1 python src/etl/pipeline/upload_rolling_outlier_flags.py verify-source
2 python src/etl/pipeline/upload_rolling_outlier_flags.py upload --replace
  --execute
3 python src/etl/pipeline/upload_rolling_outlier_flags.py apply-to-fact
```

Listing 3: Load fact từ staging sang Data Warehouse

```
1 python src/etl/pipeline/load_fact_solar_energy_gen_dw.py --execute --
  replace
```

Các file evidence chính:

- reports/final_rolling_compare/03_rolling_iqr_site_hour_stats.csv
- reports/final_rolling_compare/05_full_rolling_iqr_candidates.csv

- `reports/final_rolling_compare/09_method_candidate_summary.csv`
- `reports/final_rolling_compare/10_overlap_with_old_radiation_iqr.csv`
- `reports/final_rolling_compare/11_validation_checks.csv`
- `reports/outlier_flag_pipeline_rolling_only/99_sha256_checksums.csv`

14 Kết luận

Rolling Window 1 giờ kết hợp IQR theo `sitekey + hour` đã kiểm tra toàn bộ 2,731,946 dòng generation và tạo 100,822 candidate, chiếm 3.690482901199%. Phương pháp giữ đúng grain 15 phút, không join weather theo giờ và có thể giải thích bằng tính tay.

Cờ đã được ghi vào staging và Data Warehouse bằng khóa chính xác, không mất dòng, không duplicate và không thay đổi giá trị generation. Cách xử lý cuối cùng là giữ raw data, dùng flag để audit và so sánh dataset ML; không xóa tự động toàn bộ candidate.