

Kế hoạch thực hiện EDA cho Nhóm

Phục vụ Business Intelligence và Machine Learning

Nhóm dự án- Ngô Tấn Đạt - Tài liệu tham khảo

19/06/2026

1 Mục tiêu

Kế hoạch này phân chia công việc EDA cho nhóm nhằm tạo một bộ kết quả thống nhất phục vụ hai mục tiêu:

1. **BI**: mô tả sản lượng, điều kiện thời tiết, khác biệt giữa site và chất lượng dữ liệu.
2. **ML**: xác định target, feature tiềm năng, lag, seasonality, outlier policy và temporal split trước khi huấn luyện.

EDA phải tạo ra quyết định cụ thể, không chỉ tạo biểu đồ. Mỗi hình phải ghi:

- dữ liệu và cột được sử dụng;
- grain và phép tổng hợp;
- câu hỏi hình cần trả lời;
- kết quả quan sát;
- ảnh hưởng tới BI hoặc ML;
- giới hạn của kết luận.

2 Quy ước giải thích thuật ngữ

Tài liệu không giả định mọi thành viên đã quen với thuật ngữ Data, BI và ML. Khi một thuật ngữ chuyên môn xuất hiện, phần giải thích ngắn gọn được đặt trong ngoặc ngay sau thuật ngữ. Các thuật ngữ dùng xuyên suốt tài liệu gồm:

Thuật ngữ	Giải thích ngắn
EDA (Exploratory Data Analysis)	Phân tích khám phá dữ liệu trước khi báo cáo hoặc xây dựng mô hình.
BI (Business Intelligence)	Hệ thống báo cáo và dashboard hỗ trợ theo dõi, so sánh và ra quyết định.
ML (Machine Learning)	Phương pháp cho mô hình học quy luật từ dữ liệu để dự báo.
Dashboard	Màn hình tổng hợp nhiều KPI, biểu đồ và bộ lọc phục vụ một nhóm câu hỏi.
KPI (Key Performance Indicator)	Chỉ số chính dùng để theo dõi kết quả hoặc chất lượng hệ thống.
Grain	Mức chi tiết của một dòng dữ liệu, ví dụ một site tại một timestamp 15 phút.
Target	Biến kết quả mà mô hình cần dự báo.
Feature	Biến đầu vào được cung cấp cho mô hình để tạo dự báo.
Endogenous variable	Biến nội sinh cần được giải thích hoặc dự báo; trong dự án là generation.
Exogenous variable	Biến ngoại sinh cung cấp ngữ cảnh bên ngoài như weather, calendar hoặc site.
Coverage	Tỷ lệ số mốc dữ liệu thực tế so với số mốc đáng lẽ phải có.
Local visualization	Biểu đồ ở mức chi tiết như một timestamp, một ngày, một site hoặc một sự kiện.
Global visualization	Biểu đồ tổng quan được tổng hợp từ nhiều bản ghi, thời kỳ hoặc site.
Cross-site comparison	So sánh các site bằng cùng một chỉ số và cùng phạm vi thời gian.
Outlier candidate	Điểm khác biệt cần review, chưa đồng nghĩa với dữ liệu sai cần xóa.
Lag	Giá trị quá khứ của một biến, ví dụ generation cách hiện tại 15 phút.
Rolling window	Cửa sổ trượt dùng nhiều mốc quá khứ gần nhau để tính mean, median hoặc độ lệch.
Temporal split	Chia train, validation và test theo thứ tự thời gian, không trộn ngẫu nhiên.
Leakage	Rò rỉ thông tin tương lai hoặc thông tin không tồn tại tại thời điểm dự báo.
Baseline	Mô hình tham chiếu đơn giản mà mô hình ML phải cải thiện được.

Distribution	Phân bố giá trị của một biến, thể hiện mức phổ biến và độ biến động.
Distribution shift	Phân bố dữ liệu thay đổi giữa các giai đoạn hoặc giữa train và test.
Stationary series	Chuỗi dừng: đặc tính thống kê như mean, variance và quan hệ theo lag tương đối ổn định theo thời gian.
Non-stationary series	Chuỗi không dừng: mean, variance, trend, seasonality hoặc quan hệ giữa các biến thay đổi theo thời gian.
Correlation	Mức độ hai biến thay đổi cùng nhau; không tự động chứng minh quan hệ nhân quả.
Multicollinearity	Nhiều feature mang thông tin gần giống nhau, làm mô hình tuyến tính thiếu ổn định.
VIF (Variance Inflation Factor)	Chỉ số đo mức độ một feature bị giải thích bởi các feature còn lại.
ACF/PACF	Biểu đồ đo mức liên hệ của chuỗi hiện tại với các giá trị quá khứ theo từng lag.
Macro metric	Trung bình metric của các site, mỗi site có trọng số bằng nhau.
Micro/global metric	Metric tính trên toàn bộ dòng, nên site nhiều dữ liệu có ảnh hưởng lớn hơn.
XAI (Explainable Artificial Intelligence)	Các phương pháp giải thích vì sao mô hình tạo ra dự báo.
SHAP	Phương pháp ước lượng mức mỗi feature kéo một dự báo tăng hoặc giảm.

3 Khung phân tích Endogenous và Exogenous

Thuật ngữ đúng được sử dụng trong tài liệu forecasting là **exogenous variables** (các **biến ngoại sinh**), không phải “exposure”. Việc phân biệt hai nhóm biến này giúp nhóm biết biến nào là kết quả cần dự báo và biến nào cung cấp ngữ cảnh bên ngoài cho dự báo.

- **Endogenous variable (biến nội sinh)**: biến được mô hình giải thích hoặc dự báo. Trong dự án này, đó là `energy_generated_kwh` hoặc `target_energy_next_1h_kwh`.
- **Exogenous variables (các biến ngoại sinh)**: các đầu vào bên ngoài có thể ảnh hưởng đến target (biến cần dự báo) nhưng không phải target, gồm radiation, temperature, cloud, wind, rain, weather condition, calendar, vị trí và metadata site.

Quan hệ tổng quát của bài toán:

$\text{Solar generation}_{t+1:t+4} = f(\text{generation history}_{\leq t}, \text{weather/context available at } t, \text{calendar, site})$.

3.1 Vì sao phải đặt khung này trước khi visualization

Nếu chỉ vẽ từng cột riêng lẻ, nhóm biết dữ liệu phân bố thế nào nhưng chưa biết nó có giúp giải thích target hay không. EDA phải thực hiện theo hai hướng:

1. **Phân tích endogenous:** target có chu kỳ, zero, peak, lag, seasonality, outlier và distribution shift như thế nào?
2. **Phân tích exogenous:** khi radiation, cloud, temperature hoặc calendar thay đổi, phân phối target thay đổi thế nào; tín hiệu đó có ổn định theo site và thời gian không?

Vì vậy, visualization không chỉ dùng để “nhìn dữ liệu”. Nó phải giúp trả lời:

- exogenous variable nào thực sự có tín hiệu với target;
- quan hệ là tuyến tính, phi tuyến hay phụ thuộc interaction;
- feature nào trùng thông tin và có thể gây multicollinearity;
- feature nào có nguy cơ leakage hoặc không tồn tại khi dự báo thật;
- model cần lịch sử target, exogenous input hay cả hai.

3.2 Quy tắc availability (khả năng có sẵn) để tránh leakage (rò rỉ dữ liệu tương lai)

Một cột chỉ được dùng làm feature nếu giá trị của nó có sẵn tại thời điểm phát dự báo. Quy tắc cho dự báo một giờ tới:

Nhóm biến	Có thể dùng?	Điều kiện
Generation quá khứ	Có	Chỉ dùng giá trị tại hoặc trước thời điểm t .
Calendar tương lai	Có	Hour, day, month và holiday đã biết trước.
Metadata site	Có điều kiện	Phải có nguồn chính thức; không tự fill capacity/panel.

Observed weather đến t	Có	Dùng current/lag weather đã quan sát.
Observed weather từ $t + 15$ đến $t + 60$	Không	Đây là thông tin tương lai và gây leakage.
Weather forecast cho $t + 15$ đến $t + 60$	Có	Chỉ dùng khi hệ thống thực tế có forecast này tại thời điểm t .

Do đó, EDA có thể dùng observed weather để hiểu quan hệ vật lý và đánh giá tiềm năng feature. Tuy nhiên, trước khi train phải tách rõ `observed_weather` và `forecast_weather`; không được dùng weather tương lai thực đo như thể model đã biết trước.

4 Nguyên tắc visualization: từ chi tiết đến tổng quan

Trong tài liệu này, **local** không đồng nghĩa với “từng site”. Local là mức quan sát chi tiết nhất phù hợp với câu hỏi. Global là kết quả tổng hợp ở mức tổng quan. Site chỉ là một trong các chiều có thể dùng để phân nhóm.

Thứ tự phân tích:

Local: timestamp/sự kiện/bản ghi $\rightarrow$ Segment: giờ/ngày/tháng/site/mùa $\rightarrow$
Global: toàn bộ phạm vi phân tích

Cấp độ	Ví dụ visualization	Câu hỏi trả lời
Local (chi tiết)	Một timestamp, đường cong một ngày, một sự kiện mưa, một gap hoặc một dự báo cụ thể	Điều gì đã xảy ra tại quan sát/sự kiện cụ thể và dữ liệu liên quan có hợp lý không?
Segment (nhóm trung gian)	Phân phối theo giờ, ngày, tháng, mùa, site, weather condition hoặc radiation bin	Pattern có lặp lại trong nhóm nào và nhóm nào khác biệt?
Global (tổng quan)	KPI, trend toàn kỳ, phân phối toàn bộ dữ liệu và metric toàn hệ thống	Xu hướng chung là gì và kết luận chi tiết nào vẫn còn đúng sau khi tổng hợp?

4.1 Vì sao phải đi từ chi tiết đến tổng quan

1. Tổng hợp quá sớm có thể che mất gap, lỗi join, sự kiện thời tiết hoặc outlier chỉ tồn tại trong một khoảng ngắn.

2. Một điểm khác biệt ở mức local có thể là sự kiện hợp lệ; cần xem nó có lặp lại ở segment trước khi kết luận.
3. Kết quả segment giúp giải thích global thay vì chỉ đưa một con số tổng.
4. Site lớn hoặc giai đoạn có nhiều dòng có thể chi phối global; vì vậy phải giữ khả năng drill-down về mức chi tiết.

4.2 Quy tắc tổng hợp

- Mọi KPI global phải truy ngược được về segment và bản ghi local.
- Không lấy trung bình các median segment để gọi là median global. Median global phải tính trực tiếp trên phạm vi global.
- Ghi rõ phép tổng hợp là sum, mean, median, weighted mean hay count.
- Ghi rõ global đang weighted theo số dòng, generation hay mỗi site có trọng số bằng nhau.
- Khi local, segment và global cho kết luận khác nhau, phải báo sự khác biệt và giải thích nguyên nhân, không bỏ cấp độ chi tiết.

5 Phạm vi dữ liệu

Bảng	Grain (mức chi tiết một dòng)	Vai trò
fact_solar_energy_gen	Site-15 phút	Target sản lượng và cờ outlier.
fact_weather	Site/Geo-một giờ	Các biến thời tiết ngoại sinh.
dim_solar_site	Một site	Capacity, panel, inverter và metadata trạm.
dim_geography	Một site/vị trí	Tọa độ và tên địa điểm.
dim_date	Một ngày	Ngày, tháng và năm.
dim_time	Một mốc trong ngày	Giờ và phút.
dim_weather_type	Weather code-day/night	Nhãn và mô tả điều kiện thời tiết.

Quy tắc chung: generation có grain (mức chi tiết) 15 phút, weather có grain một giờ. Không được join hai bảng mà không ghi rõ cách aggregate hoặc resampling.

6 Bài toán ML thống nhất

Mục tiêu đầu tiên của nhóm:

Dự báo tổng sản lượng của từng site trong một giờ kế tiếp

Target tại thời điểm t :

$$y_{t,1h} = E_{t+15} + E_{t+30} + E_{t+45} + E_{t+60}$$

Chỉ tạo target (biến cần dự báo) khi có đủ bốn mốc kế tiếp liên tục của cùng site. Feature (biến đầu vào mô hình) tại thời điểm t chỉ được dùng dữ liệu có sẵn không muộn hơn t .

7 Phân loại cột và câu hỏi cần trả lời

7.1 Nhóm 1: Endogenous target

Cột	Câu hỏi	EDA cần thực hiện
energy_generated_kwh	Phân phối target có zero, peak, skew hoặc long tail không?	Describe, skewness, kurtosis, histogram, ECDF và boxplot.
target_energy_next_1h_kwh	Target một giờ có ổn định và đủ mẫu để train không?	Phân phối theo site, hour, month và tập train/validation/test.

7.2 Nhóm 2: Temporal context và known exogenous

Cột/feature	Câu hỏi	Visualization
timestamp	Dữ liệu có thiếu interval hoặc duplicate không?	Coverage heatmap, gap-length histogram và duplicate table.
hour, minute	Chu kỳ phát điện trong ngày như thế nào?	Median và IQR generation theo giờ; line plot ngày đại diện.
day_of_week	Có khác biệt theo ngày trong tuần không?	Boxplot/line theo day of week và site.
month, season	Mùa nào có sản lượng cao hoặc biến động lớn?	Monthly profile, seasonal profile và year-month heatmap.

year	Pattern có thay đổi giữa các năm không?	Overlay theo month/day-of-year và distribution comparison.
Target theo thời gian	Chuỗi stationary (dừng) hay non-stationary (không dừng)?	Rolling mean/variance, decomposition, ADF/KPSS và so sánh theo giai đoạn.

7.3 Nhóm 3: Radiation exogenous

Cột	Câu hỏi	Visualization
shortwave_radiation	Generation tăng như thế nào khi tổng bức xạ tăng?	Hexbin/scatter density, binned median và IQR theo site/hour.
direct_normal_irradiance	Bức xạ trực tiếp có giải thích peak generation không?	Binned response và correlation theo site.
diffuse_solar_radiation	Bức xạ tán xạ có duy trì generation khi nhiều mây không?	Scatter/hexbin và facet theo cloud/weather condition.

7.4 Nhóm 4: Weather exogenous

Cột	Câu hỏi	Visualization
temperature_c	Sau khi xét radiation, nhiệt độ còn liên quan tới generation không?	Radiation-conditioned scatter/bins; không xem là module temperature.
cloud_cover_*	Mây làm giảm mức hay làm tăng biến động generation?	Binned median/IQR, facet theo radiation band.
wind_speed	Gió có tín hiệu độc lập sau temperature/radiation không?	Binned response và partial comparison.
precipitation_mm	Mưa liên quan đến giảm tức thời hoặc thay đổi sau mưa không?	Rain/no-rain boxplot và event window trước/sau mưa.

sunshine_duration	Có bổ sung thông tin ngoài radiation không?	Correlation, VIF và target response plot.
-------------------	---	---

7.5 Nhóm 5: Categorical exogenous

Cột	Câu hỏi	Visualization
weather_code	Mỗi code có đủ mẫu và generation khác biệt không?	Count plot và box/violin kèm sample count.
weather_condition	Nhóm thời tiết nào đi cùng generation cao/thấp?	Median/IQR theo condition, tách daytime.
is_day	Có generation dương vào ban đêm không?	Day/night counts và distribution audit.
panel, inverter, optimizers	Thiết bị nào có pattern hoặc outlier rate khác nhau?	Count plot và site-level summary; không kết luận nếu nhóm quá ít mẫu.

7.6 Nhóm 6: Static exogenous và metadata site

Cột	Câu hỏi	Visualization
capacity_kw	Khác biệt generation có phải do quy mô site không?	Missingness, distribution và generation-capacity scatter.
number_of_panels	Có nhất quán với capacity và generation không?	Scatter và metadata audit.
latitude, longitude	Khác biệt khí hậu/vị trí có tạo pattern khác không?	Map và profile theo location/site.
site_id	Site nào có pattern và chất lượng dữ liệu khác biệt?	Small multiples, site-hour heatmap và site ranking.

7.7 Nhóm 7: Data Quality và Outlier

Cột/metric	Câu hỏi	Visualization
rolling_outlier_flag	Candidate tập trung ở site, giờ và mùa nào?	Outlier rate theo site/hour/month và event windows.
Null/duplicate/gap	Dữ liệu có đủ để tính feature và target không?	Missing heatmap, duplicate table và gap histogram.
Coverage ratio	Site nào thiếu nhiều timestamp?	Site-month coverage heatmap.

8 Workstream EDA của nhóm

8.1 Workstream 1: Data Quality

Công việc:

- kiểm tra schema, kiểu dữ liệu và row count;
- kiểm tra business key và duplicate;
- kiểm tra missing interval theo site;
- kiểm tra null, zero và domain invalid;
- lập danh sách site/period đủ điều kiện train.

Đầu ra:

- data quality summary CSV;
- missing heatmap;
- temporal coverage heatmap;
- gap-length histogram;
- bảng PASS/WARN/FAIL.

8.2 Workstream 2: Target và Time Series

Công việc:

- thống kê target: mean, standard deviation, quantile, skewness, kurtosis, zero rate;

- phân tích theo 15 phút, giờ, ngày, tuần, tháng, mùa và năm;
- so sánh toàn hệ thống với từng site;
- kiểm tra ACF/PACF, lag và persistence;
- tạo target một giờ và kiểm tra continuity.

Đầu ra:

- target distribution raw/daytime/positive;
- hourly profile có median và IQR;
- site-hour và site-month heatmap;
- yearly/seasonal comparison;
- lag relevance table.

8.3 Workstream 3: Weather và Domain

Công việc:

- phân phối từng weather feature;
- quan hệ generation với radiation, cloud, temperature, wind và rain;
- kiểm tra weather code/condition và sample count;
- tách daytime và segment theo site/hour/season;
- kiểm tra các trường hợp generation-weather bất thường.

Đầu ra:

- target-weather hexbin/binning plots;
- weather condition summary;
- daytime/weather regime comparison;
- danh sách candidate cần domain review.

8.4 Workstream 4: Correlation và Feature Readiness

Công việc:

- Pearson và Spearman $X-y$;
- correlation $X-X$;
- correlation theo site/hour/season/year;
- VIF cho nhóm feature tuyến tính;
- thử PCA/PLS chỉ khi multicollinearity cao;
- đề xuất lag, rolling, delta và cyclical features.

Đầu ra:

- Pearson/Spearman heatmap;
- VIF table;
- feature decision table: giữ, bỏ, transform hoặc thử nghiệm;
- leakage checklist.

8.5 Workstream 5: BI và ML Integration

Công việc:

- tổng hợp KPI và dashboard-ready tables;
- chuẩn hóa caption, đơn vị, filter và sample count;
- tạo temporal train/validation/test split;
- tạo baseline;
- so sánh raw và training-clean;
- đóng gói dataset và kết quả bằng DVC.

Đầu ra:

- BI summary dataset;
- ML-ready dataset version;
- split manifest;
- baseline metrics;
- EDA report tổng hợp.

9 Phân công đề xuất cho 5 người

Người	Phụ trách	Deliverable chính	Phối hợp
1	Data Quality và nguồn dữ liệu	Schema audit, missing, duplicate, coverage, grain validation	Cung cấp tập dữ liệu hợp lệ cho cả nhóm.
2	Target và temporal EDA	Distribution, hourly/weekly/monthly/seasonal profiles, lag analysis	Thống nhất target và split với người 5.
3	Weather và domain EDA	Target-weather plots, weather regimes, candidate review	Phối hợp với người 4 về feature selection.
4	Correlation và feature readiness	Pearson/Spearman, VIF, PCA/PLS diagnostic, feature table	Chuyển quyết định feature cho ML pipeline.
5	BI/ML integration và nghiệm thu	Dashboard tables, temporal split, baseline, raw-vs-clean, report	Kiểm tra thống nhất số liệu của toàn nhóm.

10 Lịch thực hiện đề xuất

Ngày	Công việc	Kết quả cần chốt
Ngày 1	Kickoff và data contract	Target, horizon, grain, timezone, units và nguồn dữ liệu.
Ngày 2–3	Data Quality	Danh sách lỗi, coverage và tập dữ liệu đủ điều kiện EDA.
Ngày 3–5	Target/time/weather EDA	Các hình chính và bảng số liệu kiểm chứng.
Ngày 5–6	Correlation/feature readiness	Feature decision table và leakage checklist.
Ngày 7	Review chéo	Sửa sai khác số liệu, caption và kết luận.
Ngày 8–9	BI/ML integration	Dashboard aggregates, ML-ready target và temporal split.
Ngày 10	Nghiệm thu	EDA report, notebook, CSV, PNG và dataset version.

11 Kế hoạch 5 dashboard và các visualization thành phần

Giáo viên yêu cầu nhóm xây dựng **4 dashboard**. Nhóm dự kiến bổ sung thêm **1 dashboard XAI** để giải thích kết quả mô hình. Vì vậy, đầu ra cuối cùng gồm tổng cộng **5 dashboard**:

Số	Dashboard	Câu hỏi chính cần trả lời
1	Tổng quan sản lượng	Hệ thống phát được bao nhiêu điện, xu hướng thay đổi ra sao và dữ liệu có đủ coverage để tin cậy hay không?
2	Phân tích site và thời gian	Site nào đóng góp nhiều, hồ sơ phát điện theo giờ/mùa khác nhau thế nào và site nào có hành vi khác biệt?
3	Exogenous weather và yếu tố ảnh hưởng	Radiation, mây, nhiệt độ, gió, mưa và weather condition liên quan thế nào đến generation?
4	Chất lượng dữ liệu và ML readiness	Dữ liệu có null, duplicate, gap, outlier candidate, distribution shift hoặc nguy cơ leakage nào cản trở training?
5	XAI – Giải thích mô hình	Model dự báo dựa vào feature nào, tác động theo chiều nào, vì sao một dự báo cụ thể cao/thấp và model thất bại tại site/thời điểm nào?

Dashboard 1–4 là phạm vi bắt buộc. Dashboard 5 là phần mở rộng của nhóm, chỉ hoàn thiện sau khi đã có model được đánh giá trên tập test theo thời gian.

11.1 Logic liên kết giữa 5 dashboard

Năm dashboard không phải năm màn hình rời rạc. Chúng đi theo chuỗi câu hỏi của một bài toán forecasting:

1. **Dashboard 1 quan sát endogenous target**: generation hiện có quy mô và xu hướng như thế nào?
2. **Dashboard 2 đặt target vào temporal/site context**: target thay đổi theo giờ, mùa và site ra sao?
3. **Dashboard 3 kiểm tra exogenous drivers**: weather có giải thích được sự thay đổi của target không và feature nào đáng đưa vào model?

4. **Dashboard 4 kiểm tra ML readiness:** dữ liệu, join, continuity, outlier policy và temporal split có đủ an toàn để train không?
5. **Dashboard 5 kiểm tra model bằng XAI:** sau khi train, model có thực sự sử dụng target history và exogenous variables theo hướng hợp lý hay đang học leakage hoặc pattern giả?

Lý do cần đủ chuỗi này là một correlation hoặc feature importance đơn lẻ không đủ chứng minh feature hữu ích. Nhóm phải quan sát phân phối target, kiểm soát site/time, kiểm tra exogenous relationship, đánh giá out-of-time và cuối cùng đối chiếu hành vi model bằng XAI.

11.2 Phân bổ visualization vào từng dashboard

Dashboard	Visualization chính	Quyết định hỗ trợ
Dashboard 1	KPI tổng quan; trend ngày/tháng; seasonality tổng hệ thống	Xác nhận quy mô, xu hướng và kỳ dữ liệu cần drill-down.
Dashboard 2	Hourly profile; site ranking; site-hour heatmap; year-month/site heatmap	Xác định site/khung giờ khác biệt và cách phân đoạn phân tích.
Dashboard 3	Target-radiation; weather condition; cloud/temperature/wind/rain response	Kiểm tra exogenous signal; chọn weather feature, interaction và các trường hợp cần domain review.
Dashboard 4	Null/gap/duplicate; target distribution; outlier sensitivity; split comparison; baseline error theo site	Chốt tập dữ liệu train, rule làm sạch, temporal split và ML readiness.
Dashboard 5	Global/local feature importance; SHAP summary/dependence/waterfall; error analysis theo site/hour	Giải thích model, kiểm tra model học đúng domain và hỗ trợ phản biện kết quả.

11.3 Ma trận chi tiết–tổng quan cho 5 dashboard

Dashboard	Mức chi tiết và nhóm trung gian	Mức tổng quan
-----------	---------------------------------	---------------

Dashboard 1	Quan sát timestamp/ngày bất thường; trend ngày/tháng theo site hoặc location; đánh dấu coverage từng kỳ	KPI toàn hệ thống và tổng generation theo ngày/tháng, kèm số site đóng góp.
Dashboard 2	Đường cong một ngày; profile theo giờ, tháng, mùa và site	Site-hour heatmap, site ranking và pattern chung toàn hệ thống; vẫn giữ khả năng drill-down về ngày/site cụ thể.
Dashboard 3	Quan sát sự kiện weather cụ thể; target-weather theo hour, season, site và sample count từng bin	Quan hệ target-weather toàn hệ thống và bảng so sánh response giữa các nhóm.
Dashboard 4	Chi tiết dòng/gap/outlier; thống kê null, duplicate, distribution và baseline error theo site/giai đoạn	Tổng lỗi toàn hệ thống, macro/micro rate, split comparison và danh sách nhóm có rủi ro cao.
Dashboard 5	Giải thích từng dự báo cụ thể; SHAP/error theo site, hour hoặc regime	Feature importance và SHAP summary toàn tập test, kèm đối chiếu giữa các nhóm.

Thứ tự trình bày trong mỗi dashboard phải là:

1. xem bản ghi, timestamp, ngày hoặc sự kiện cụ thể;
2. tổng hợp theo nhóm phù hợp như hour, month, season, site hoặc weather;
3. cuối cùng mới hiển thị kết quả tổng quan;
4. nếu tổng quan che khuất trường hợp chi tiết, dashboard phải cảnh báo và giữ khả năng drill-down.

11.4 Cách sử dụng phản hướng dẫn

Mỗi visualization phải bắt đầu từ một câu hỏi cần ra quyết định. Nhóm không vẽ hình chỉ để mô tả dữ liệu. Sau mỗi hình phải ghi đúng bốn dòng:

1. **Câu hỏi:** vấn đề nghiệp vụ hoặc chất lượng dữ liệu cần trả lời;
2. **Quan sát:** con số, xu hướng hoặc nhóm khác biệt nhìn thấy;
3. **Kết luận:** câu trả lời có giới hạn, không suy diễn quá dữ liệu;
4. **Hành động:** giữ nguyên, điều tra, sửa pipeline, tạo feature hoặc chuyển sang bước mô hình.

11.5 Chuẩn bị dữ liệu chung

Trước khi vẽ, người phụ trách phải tạo một bảng BI summary (bảng tổng hợp phục vụ dashboard) có grain (mức chi tiết của một dòng) được ghi rõ. Không nối trực tiếp hai bảng khác grain rồi dùng ngay để tính tổng. Tối thiểu cần các bảng trung gian sau:

- `site_15min`: một dòng cho mỗi `sitekey` + `timestamp`, chứa `generation`;
- `site_day`: một dòng cho mỗi `sitekey` + `date`, chứa tổng `generation` ngày;
- `site_month`: một dòng cho mỗi `sitekey` + `year` + `month`, chứa tổng `generation` tháng;
- `quality_summary`: một dòng cho mỗi site và kỳ báo cáo, chứa `row count`, `expected row count`, `null`, `duplicate`, `gap` và `outlier candidate`.

Mọi phép tổng hợp phải xuất kèm CSV. Tổng số dòng trong CSV phải khớp với số liệu ghi trên hình và trong báo cáo.

11.6 Visual BI-01: KPI tổng quan – Dashboard 1

Câu hỏi cần trả lời: trong kỳ báo cáo, hệ thống ghi nhận bao nhiêu năng lượng, bao nhiêu site thực sự có dữ liệu, coverage (tỷ lệ số mốc thực tế so với số mốc kỳ vọng) đạt bao nhiêu và bao nhiêu quan sát đang cần review?

Vì sao cần: tổng `generation` không có ý nghĩa nếu dữ liệu bị thiếu một phần thời gian hoặc thiếu site. KPI coverage (chỉ số mức đầy đủ dữ liệu) đặt sản lượng trong đúng bối cảnh, tránh báo cáo sản lượng giảm trong khi nguyên nhân thật là pipeline thiếu dòng.

Cách làm: tính tổng `energy_generated_kwh`, số site phân biệt, số timestamp thực tế, số timestamp kỳ vọng và số `rolling_outlier_flag = true`. Coverage được tính:

$$\text{coverage} = \frac{\text{observed site-timestamps}}{\text{expected site-timestamps}} \times 100\%.$$

Hiển thị: bốn KPI cards (ô hiển thị chỉ số chính) gồm `total generation`, `active sites`, `coverage` (tỷ lệ dữ liệu đầy đủ) và `outlier candidate rate` (tỷ lệ điểm cần review). Mỗi card phải ghi đơn vị và phạm vi ngày.

Kiểm chứng: cộng lại từ CSV theo từng site phải bằng KPI toàn hệ thống. Không lấy `COUNT(*)` sau một phép join làm số dòng nguồn nếu join có thể nhân bản bản ghi.

Câu trả lời và quyết định: xác nhận kỳ dữ liệu có đủ tin cậy để tiếp tục phân tích hay không. Nếu coverage (tỷ lệ dữ liệu đầy đủ) thấp, phải xử lý nguồn/gap (khoảng timestamp bị thiếu) trước khi giải thích biến động sản lượng. Outlier candidate (điểm khác biệt cần review) không phải dòng chắc chắn phải xóa.

11.7 Visual BI-02: Trend sản lượng theo ngày và tháng – Dashboard 1

Câu hỏi cần trả lời: sản lượng thay đổi theo thời gian như thế nào; các đợt tăng/giảm là mùa vụ, sự kiện vận hành hay chỉ do thiếu dữ liệu?

Vì sao cần: điện mặt trời phụ thuộc chu kỳ ngày, mùa và thời tiết. Một KPI tổng không cho biết thời điểm hệ thống thay đổi chế độ, mất dữ liệu hoặc xuất hiện một giai đoạn suy giảm kéo dài.

Cách làm: từ `site_15min`, cộng generation theo `sitekey + date`; sau đó mới cộng các site nếu cần đường toàn hệ thống. Tạo thêm tổng theo tháng từ bảng ngày.

Hiển thị: line chart theo ngày và line/bar chart theo tháng. Trục X là thời gian liên tục, trục Y là tổng kWh. Cho phép lọc site/location.

Cách đọc: tìm xu hướng mùa vụ, ngày giảm bất thường, khoảng trống dữ liệu và thay đổi mức nền. Một điểm thấp chỉ được gọi là bất thường sau khi kiểm tra coverage (tỷ lệ dữ liệu đầy đủ) của ngày đó; không được nhầm ngày thiếu dữ liệu với ngày sản lượng thấp thật.

Câu trả lời và quyết định: xác định kỳ nào cần drill-down theo site, weather hoặc chất lượng dữ liệu; đồng thời quyết định feature mùa vụ nào cần đưa vào mô hình.

11.8 Visual BI-03: Hồ sơ phát điện theo giờ – Dashboard 2

Câu hỏi cần trả lời: trong một ngày điển hình, hệ thống bắt đầu phát, đạt đỉnh và giảm sản lượng vào giờ nào; độ biến động ở mỗi giờ lớn đến đâu?

Vì sao cần: phân phối generation thay đổi mạnh theo vị trí mặt trời. So sánh trực tiếp 6 giờ với 12 giờ mà không có hồ sơ theo giờ sẽ gần nhầm peak buổi trưa hoặc zero ban đêm thành outlier.

Cách làm: lấy generation 15 phút, tạo `hour` từ timestamp rồi tính median, Q1, Q3 và sample count theo `sitekey + hour`. Nếu cần biểu đồ toàn hệ thống, phải tính thống kê trực tiếp từ toàn bộ quan sát, không lấy trung bình các median của site.

Hiển thị: đường median theo 24 giờ; vùng tô từ Q1 đến Q3. Có thể thêm small multiples theo site.

Cách đọc: xác định giờ bắt đầu phát điện, giờ peak và độ biến động. Zero ban đêm là trạng thái vận hành thông thường, không tự động là outlier.

Câu trả lời và quyết định: chốt các feature thời gian, nhóm giờ cần so sánh riêng và baseline theo giờ. Nếu profile khác mạnh giữa site, không dùng một ngưỡng generation chung cho toàn hệ thống.

11.9 Visual BI-04: Site ranking và site-hour heatmap – Dashboard 2

Câu hỏi cần trả lời: site nào đóng góp sản lượng lớn; site nào có hồ sơ phát điện theo giờ khác rõ rệt so với phần còn lại?

Vì sao cần: các site có thể khác vị trí, quy mô, thiết bị và chất lượng dữ liệu. Gộp all-site có thể che mất một site hoạt động bất thường hoặc làm site lớn chi phối toàn bộ kết quả.

Cách làm: site ranking dùng tổng generation theo site trong cùng một khoảng thời gian có coverage tương đương. Heatmap dùng median generation theo `sitekey + hour`.

Hiển thị: bar chart xếp hạng site và heatmap có hàng là site, cột là 0–23 giờ, màu là median generation. Ghi thêm coverage hoặc sample count.

Cách đọc: heatmap dùng để tìm site có khung giờ vận hành khác biệt. Ranking chỉ phản ánh sản lượng tuyệt đối; không được diễn giải thành hiệu suất nếu chưa có metadata công suất đáng tin cậy.

Câu trả lời và quyết định: quyết định site nào cần phân tích riêng, site nào đủ dữ liệu train và nên dùng mô hình global có site feature hay mô hình riêng. Không xếp hạng hiệu suất chỉ từ tổng kWh.

11.10 Visual BI-05: Seasonality và year-month heatmap – Dashboard 2

Câu hỏi cần trả lời: tháng/mùa nào có mức sản lượng đặc trưng; cùng một tháng có ổn định giữa các năm hay xuất hiện regime shift?

Vì sao cần: bức xạ, độ dài ban ngày, mây và mưa thay đổi theo mùa. Không nhận diện seasonality sẽ làm mô hình học một mức nền chung và tăng sai số ở các mùa cực trị.

Cách làm: tổng hợp generation theo tháng và năm; đồng thời tính coverage theo cùng grain. Với dữ liệu nhiều site, tạo cả tổng hệ thống và phiên bản theo site.

Hiển thị: heatmap có hàng là năm, cột là tháng, màu là tổng generation hoặc generation trung vị theo ngày. Đặt coverage trong annotation hoặc hình phụ.

Cách đọc: so sánh cùng tháng giữa các năm và nhận diện mùa cao/thấp. Không so sánh tổng tháng khi số ngày hoặc coverage khác nhau mà không chuẩn hóa.

Câu trả lời và quyết định: chốt feature month/season/day-of-year, cách chia backtest qua nhiều mùa và kỳ nào cần điều tra distribution shift.

11.11 Visual BI-06: Weather condition và generation – Dashboard 3

Câu hỏi cần trả lời: trong dữ liệu hiện có, generation phân bố khác nhau thế nào giữa các trạng thái thời tiết; sự khác biệt còn tồn tại khi xét site và thời điểm tương đương hay không?

Vì sao cần: radiation là động lực chính của phát điện, còn mây/mưa tác động đến radiation và độ biến động. Nếu chỉ nhìn weather label toàn cục, khác biệt giờ trong ngày hoặc mùa có thể bị hiểu nhầm là tác động của weather.

Cách làm: chỉ dùng phép join đã audit grain. Nếu weather một giờ và generation 15 phút, phải ghi rõ quy tắc ghép; ưu tiên tổng hợp generation lên site-hour trước khi join site-hour weather để tránh nhân bản. Sau đó tính count, median, Q1 và Q3 generation theo weather condition.

Hiển thị: boxplot hoặc point-range plot theo condition; bên cạnh phải có sample count. Có filter site, month và hour.

Cách đọc: dùng để mô tả khác biệt phân phối, không kết luận weather condition gây ra thay đổi nếu chưa kiểm soát radiation, site và thời gian.

Câu trả lời và quyết định: xác định weather feature nào có tín hiệu, feature nào chỉ lặp thông tin radiation và interaction nào cần thử trong mô hình. Nhóm ít mẫu chỉ ghi nhận, không kết luận.

11.12 Visual BI-07: Data Quality – Dashboard 4

Câu hỏi cần trả lời: lỗi dữ liệu nằm ở bảng, site, cột và giai đoạn nào; ảnh hưởng bao nhiêu dòng và có chặn được EDA/training không?

Vì sao cần: null, duplicate và gap có hậu quả khác nhau. Duplicate có thể làm tăng giả tổng generation; gap làm hỏng lag/rolling; metadata null làm giới hạn phân tích theo capacity nhưng không nhất thiết làm mất fact generation.

Cách làm: từ `quality_summary`, tính null rate, duplicate count, missing interval count, coverage và outlier candidate rate theo site và tháng.

Hiển thị: heatmap site-month cho coverage, bar chart lỗi theo loại và bảng chi tiết các site/period WARN hoặc FAIL.

Cách đọc: dashboard phải giúp trả lời lỗi nằm ở site nào, giai đoạn nào và ảnh hưởng bao nhiêu dòng. Outlier candidate phải tách khỏi lỗi domain; không cộng chung hai loại thành một số “dữ liệu lỗi”.

Câu trả lời và quyết định: tạo danh sách PASS/WARN/FAIL, owner và hành động xử lý. Chỉ FAIL mới chặn pipeline; WARN phải được chuyển thành giới hạn phân tích hoặc cờ chất lượng cụ thể.

Mỗi hình BI phải cho phép lọc theo site, location và thời gian. Sản lượng tuyệt đối không được dùng để đánh giá hiệu quả site nếu chưa xét quy mô/capacity.

12 Visualization ML phục vụ Dashboard 3 và Dashboard 4

12.1 Visual ML-01: Phân phối target – Dashboard 4

Câu hỏi cần trả lời: target có nhiều zero, lệch phải, nhiều đỉnh hoặc đuôi dài không; các tính chất này có thay đổi theo site và thời gian không?

Vì sao cần: hình dạng target quyết định metric, loss, transform và chiến lược mô hình. Với solar, trộn zero ban đêm và generation ban ngày có thể làm thống kê toàn cục che mất phân phối vận hành thực.

Cách làm: vẽ riêng ba tập: toàn bộ target, target ở thời điểm có phát điện và target dương. Báo cáo count, zero rate, mean, median, standard deviation, Q1, Q3, p95, p99, skewness và kurtosis.

Hiển thị: histogram có cùng bin, ECDF và boxplot cho ba tập. Nếu long tail lớn, thêm phiên bản trục $\log_{1p}$, nhưng phải giữ hình theo đơn vị gốc.

Mục đích: quyết định có cần transform target, loss robust hoặc metric ít nhạy với zero. Không xóa tail chỉ vì histogram lệch phải.

Câu trả lời và quyết định: chốt target representation, metric chính và liệu có cần mô hình hai giai đoạn zero/non-zero. Kết luận phải nêu tỷ lệ mẫu của cả ba phân phối.

12.2 Visual ML-02: Temporal coverage và missing gap – Dashboard 4

Câu hỏi cần trả lời: chuỗi của mỗi site có liên tục đủ để tạo target một giờ, lag và rolling hay không; gap thường dài bao nhiêu?

Vì sao cần: một target một giờ cần đủ bốn mốc 15 phút tương lai. Một rolling window cũng mất ý nghĩa nếu cửa sổ chứa gap nhưng code vẫn coi các dòng kề nhau là các interval liên tục.

Cách làm: với từng site, tạo dãy timestamp kỳ vọng 15 phút trong phạm vi hoạt động; anti-join với timestamp thực tế để tìm gap. Gộp các timestamp thiếu liên tiếp thành một gap event và tính độ dài gap.

Hiển thị: coverage heatmap site-month và histogram số interval của mỗi gap.

Mục đích: quyết định cửa sổ nào đủ điều kiện tạo lag/rolling và target một giờ.

Không nội suy qua gap dài nếu chưa có rule được duyệt.

Câu trả lời và quyết định: chốt maximum gap được phép, số mẫu bị loại khi tạo target và danh sách site/period đủ điều kiện train.

12.3 Visual ML-03: Độ ổn định theo thời gian – Dashboard 4

Câu hỏi cần trả lời: quan hệ phân phối của target có ổn định qua giờ, mùa và năm không; chuỗi stationary (dừng) hay non-stationary (không dừng); mô hình train ở giai đoạn trước có đại diện cho tương lai?

Vì sao cần: dữ liệu solar thường có trend, chu kỳ ngày/mùa và thay đổi giữa các giai đoạn. Đây là các dấu hiệu có thể làm chuỗi non-stationary. Nếu mean, variance hoặc quan hệ theo lag thay đổi, mô hình train ở quá khứ có thể không đại diện cho tương lai. Random split còn trộn các giai đoạn với nhau và cho kết quả quá lạc quan.

Cách làm theo mức chi tiết đến tổng quan:

1. **Chi tiết:** chọn các chuỗi liên tục đại diện; vẽ generation theo timestamp và rolling mean/rolling variance (trung bình/phương sai cửa sổ trượt).
2. **Nhóm:** tính median, IQR, p95 và sample count theo hour, day, month, season, year và site.
3. **Tổng quan:** so sánh phân phối giữa các giai đoạn và giữa train/validation/test.
4. Thực hiện seasonal decomposition (tách trend, seasonality và residual) trên chuỗi có tần suất liên tục.
5. Chạy ADF và KPSS như hai kiểm định bổ sung, không dùng một kiểm định đơn lẻ để kết luận.

Giải thích kiểm định:

- **ADF (Augmented Dickey–Fuller):** giả thuyết gốc là chuỗi có unit root, tức có dấu hiệu không dừng. P-value nhỏ cung cấp bằng chứng chống lại giả thuyết này.
- **KPSS:** giả thuyết gốc là chuỗi dừng quanh một mức hoặc trend. P-value nhỏ cho thấy có bằng chứng chuỗi không dừng.
- Hai kiểm định có thể mâu thuẫn khi chuỗi có seasonality mạnh, structural break hoặc chưa đủ mẫu. Khi đó phải ưu tiên biểu đồ, decomposition và kiểm tra theo từng giai đoạn.

Hiển thị: time-series plot kèm rolling mean/variance, decomposition, profile theo giờ, boxplot theo tháng/mùa, overlay giữa các năm và bảng kết quả ADF/KPSS theo site/giai đoạn.

Mục đích: tìm distribution shift (sự thay đổi phân bố theo thời gian), seasonality (chu kỳ lặp lại theo giờ/mùa) và site heterogeneity (sự khác biệt giữa các site); từ đó quyết định feature thời gian, mô hình global hay per-site và chiến lược temporal split (chia dữ liệu theo thời gian).

Câu trả lời và quyết định:

- Nếu chuỗi tương đối stationary sau khi tách seasonality, có thể dùng level/lag trực tiếp với temporal validation.
- Nếu non-stationary do trend hoặc level shift, cân nhắc delta, differencing, rolling normalization hoặc retraining theo cửa sổ gần.
- Nếu non-stationary chủ yếu do seasonality, giữ feature hour, day-of-year, month hoặc Fourier encoding thay vì xóa pattern mùa vụ.
- Dù kết quả kiểm định thế nào, vẫn phải split/backtest theo thời gian và báo metric theo từng giai đoạn.

12.4 Visual ML-04: Quan hệ target–weather – Dashboard 3

Câu hỏi cần trả lời: target phản ứng tuyến tính hay phi tuyến với từng biến weather; có vùng saturation, vùng ít mẫu hoặc interaction theo site/hour không?

Vì sao cần: generation không chỉ phụ thuộc radiation mà còn chịu ngữ cảnh thời gian và site. Visualization có điều kiện giúp tránh coi peak hợp lệ là outlier và giúp chọn mô hình có khả năng học phi tuyến.

Cách làm: audit grain trước join. Sau join, chia từng weather feature liên tục thành quantile bins từ dữ liệu train; trong mỗi bin tính count, median, Q1 và Q3 của target. Với dữ liệu lớn, dùng hexbin thay scatter toàn bộ.

Hiển thị: hexbin target–radiation; point-range median/IQR theo bin radiation, temperature, cloud, wind và rain; facet theo site/hour khi cần.

Mục đích: kiểm tra phi tuyến, saturation, interaction và vùng ít mẫu. Quantile bins chỉ phục vụ mô tả, không tự động trở thành rule cắt dữ liệu.

Câu trả lời và quyết định: xác định feature weather cần giữ, transform cần thử và interaction cần tạo. Nếu quan hệ thay đổi mạnh theo site/hour, phải giữ biến ngữ cảnh hoặc dùng mô hình phân đoạn.

12.5 Visual ML-05: Correlation và multicollinearity – Dashboard

4

Câu hỏi cần trả lời: feature nào liên quan với target; feature nào gần như mang cùng một thông tin và có nguy cơ gây bất ổn cho mô hình tuyến tính?

Vì sao cần: các biến radiation thường tương quan mạnh với nhau. Giữ toàn bộ không nhất thiết gây hại mô hình cây nhưng có thể làm hệ số tuyến tính, VIF và giải thích feature thiếu ổn định.

Cách làm: tính Pearson cho quan hệ gần tuyến tính và Spearman cho quan hệ đơn điệu. Thực hiện trên train set, toàn hệ thống và theo các site chính. Tính VIF chỉ trên nhóm feature số đã xử lý null và không chứa target tương lai.

Hiển thị: hai heatmap Pearson/Spearman, bảng chênh lệch hai hệ số và VIF table.

Mục đích: phát hiện feature trùng thông tin và quan hệ phi tuyến tiềm năng. Correlation (mức độ hai biến thay đổi cùng nhau) thấp không đồng nghĩa feature vô dụng đối với mô hình cây.

Câu trả lời và quyết định: tạo bảng feature gồm giữ, bỏ, transform, chỉ dùng cho tree model hoặc cần kiểm tra thêm. Không chọn feature chỉ theo một ngưỡng correlation.

12.6 Visual ML-06: ACF/PACF và lag relevance – Dashboard 4

Câu hỏi cần trả lời: quá khứ gần, cùng giờ hôm trước hay cùng giờ tuần trước còn mang thông tin cho target một giờ tới đến mức nào?

Vì sao cần: generation có tính liên tục ngắn hạn và chu kỳ ngày. Lag không phù hợp vừa tăng số cột vừa làm mất mẫu đầu chuỗi; lag tạo sai thứ tự sẽ gây leakage hoặc nối nhầm giữa các site.

Cách làm: chọn chuỗi liên tục theo từng site; không nối cuối ngày/site này với đầu ngày/site khác. Tính ACF/PACF cho target hoặc generation với các lag 15 phút, 30 phút, 1 giờ, 24 giờ và 7 ngày. Đồng thời tính correlation của từng lag với target một giờ.

Hiển thị: ACF/PACF plot (biểu đồ liên hệ với các mốc quá khứ) và bảng lag (độ trễ thời gian) gồm hệ số, số mẫu hợp lệ và tỷ lệ mất mẫu do shift.

Mục đích: chọn lag có tín hiệu và xác định chiều dài history. Mọi lag phải được tạo sau khi sort theo `sitekey + timestamp`.

Câu trả lời và quyết định: chốt lag/rolling windows cho baseline và model, cùng số dòng mất đi vì từng feature.

12.7 Visual ML-07: Raw-vs-clean sensitivity – Dashboard 4

Câu hỏi cần trả lời: xử lý outlier có thực sự cải thiện dự báo tương lai hay chỉ làm dữ liệu trông đẹp hơn?

Vì sao cần: peak generation, ramp nhanh hoặc thời tiết cực đoan có thể là tín hiệu thật. Xóa theo thống kê đơn biến có thể làm mô hình không học được các trường hợp khó nhưng quan trọng về vận hành.

Cách làm: giữ nguyên một temporal split (cách chia dữ liệu theo thời gian) và

một baseline (mô hình tham chiếu đơn giản); chạy ít nhất hai phiên bản dữ liệu: raw và bản xử lý candidate. Chỉ thay đổi rule outlier, không thay đồng thời feature hoặc model.

Hiển thị: bảng số dòng bị ảnh hưởng, distribution overlay và bảng MAE, RMSE, WAPE/MASE theo toàn hệ thống và site.

Mục đích: chỉ chấp nhận cắt/cap khi validation metric và độ ổn định theo site tốt hơn. Nếu metric xấu đi hoặc chỉ tốt ở train, giữ dữ liệu raw.

Câu trả lời và quyết định: chọn giữ, cap, remove hoặc chỉ gắn cờ cho từng rule. Quyết định phải dựa trên số dòng ảnh hưởng và metric out-of-time.

12.8 Visual ML-08: So sánh train, validation và test – Dashboard 4

Câu hỏi cần trả lời: ba tập có cùng miền giá trị và chế độ vận hành không; test có chứa mùa/site/regime chưa xuất hiện trong train không?

Vì sao cần: chênh lệch phân phối giải thích vì sao metric test xấu và cho biết mô hình đang nội suy hay ngoại suy. Đây cũng là kiểm tra trực tiếp cho temporal leakage và split không đại diện.

Cách làm: split theo thời gian trước; sau đó tính cùng một bộ thống kê target và feature cho ba tập. Không dùng quantile của toàn bộ dữ liệu để tạo bin trước split.

Hiển thị: ECDF/boxplot target, feature summary table và PSI hoặc distribution distance cho các feature quan trọng.

Mục đích: xác định distribution shift và bảo đảm test đại diện cho giai đoạn tương lai. Ghi rõ ngày bắt đầu/kết thúc và row count của từng tập.

Câu trả lời và quyết định: chốt split cuối cùng, backtest bổ sung và những feature cần drift monitoring sau triển khai.

12.9 Visual ML-09: Phân phối theo site và rủi ro baseline – Dashboard 4

Câu hỏi cần trả lời: mô hình/baseline thất bại ở site nào, vào thời điểm nào và có bị metric tổng thể che khuất không?

Vì sao cần: site lớn có thể chi phối metric toàn hệ thống, trong khi site nhỏ hoặc site thiếu coverage có sai số rất cao. Dự báo năng lượng cần đánh giá theo segment để phục vụ vận hành thực tế.

Cách làm: với từng site, tính target count, zero rate, median, IQR, p95, coverage và metric của persistence baseline. Sắp xếp site theo WAPE/MASE hoặc MAE có kèm quy mô target.

Hiển thị: site summary heatmap, baseline error bar chart và small multiples cho các site tốt/xấu đại diện.

Mục đích: xác định site khó dự báo, site thiếu dữ liệu và liệu một mô hình global có đang che giấu lỗi lớn tại một số site hay không.

Câu trả lời và quyết định: xác định site cần model riêng, sample weight, feature bổ sung hoặc trạng thái “insufficient data”. Báo cáo phải nêu worst sites, không chỉ metric trung bình.

13 Dashboard 5: XAI – Giải thích mô hình

13.1 Mục tiêu

Dashboard XAI (dashboard giải thích mô hình) không chỉ hiển thị “feature importance” (mức độ quan trọng của feature). Dashboard phải trả lời được ba cấp độ:

1. **Global:** nhìn chung model dựa vào feature nào?
2. **Segment:** model có sử dụng feature khác nhau theo site, hour, season hoặc mức radiation không?
3. **Local:** vì sao model đưa ra một dự báo cụ thể và vì sao dự báo đó sai?

13.2 XAI-01: Global feature importance

Câu hỏi cần trả lời: feature nào đóng góp nhiều nhất vào dự báo trên toàn bộ tập test?

Vì sao cần: importance mặc định của mô hình cây có thể thiên về feature có nhiều điểm chia. Nhóm cần một cách giải thích nhất quán trên dữ liệu chưa dùng để train.

Visualization: bar chart mean absolute SHAP (mức tác động tuyệt đối trung bình của từng feature) trên tập test, kèm permutation importance (đo mức metric giảm khi xáo trộn một feature). Hai kết quả phải được đặt cạnh nhau để kiểm tra độ ổn định của thứ hạng.

Quyết định: feature đứng đầu phải hợp lý với domain solar. Nếu một ID, row order hoặc feature có nguy cơ leakage đứng đầu, phải dùng nghiệm thu model và kiểm tra pipeline.

13.3 XAI-02: SHAP summary và hướng tác động

Câu hỏi cần trả lời: giá trị cao/thấp của từng feature làm dự báo tăng hay giảm, và tác động có ổn định không?

Visualization: SHAP beeswarm (biểu đồ phân bố tác động của feature) cho các feature quan trọng nhất. Mỗi điểm là một dòng test; trục X là SHAP value (mức feature kéo dự báo tăng hoặc giảm); màu thể hiện giá trị feature.

Cách đọc domain: radiation cao nhìn chung phải có xu hướng đẩy dự báo generation lên trong điều kiện phù hợp. Nếu model học chiều ngược lại trên phần lớn dữ liệu, phải kiểm tra join, timestamp, unit, missing value và leakage.

13.4 XAI-03: SHAP dependence và interaction

Câu hỏi cần trả lời: tác động của radiation, cloud hoặc temperature có phi tuyến và thay đổi theo hour/site không?

Visualization: dependence plot cho radiation–SHAP, tô màu theo hour, cloud cover hoặc site. Chỉ chọn interaction có cơ sở từ EDA.

Quyết định: dùng để xác nhận saturation, interaction và vùng model ngoại suy. Không suy diễn SHAP thành quan hệ nhân quả.

13.5 XAI-04: Giải thích từng dự báo

Câu hỏi cần trả lời: với một timestamp/site cụ thể, feature nào kéo dự báo lên hoặc xuống so với giá trị nền?

Visualization: SHAP waterfall (biểu đồ giải thích từng dự báo bằng các đóng góp cộng/trừ của feature) cho ít nhất bốn nhóm:

- dự báo đúng điển hình;
- dự báo sai lớn dương;
- dự báo sai lớn âm;
- trường hợp outlier/weather cực trị cần review.

Mỗi case phải ghi site, timestamp, actual, predicted, residual và các feature weather/time tương ứng để có thể truy vết.

13.6 XAI-05: Error analysis theo segment

Câu hỏi cần trả lời: model sai tập trung ở site, hour, month, weather condition hoặc mức target nào?

Visualization: heatmap MAE/WAPE theo site–hour, residual distribution, actual–predicted scatter và bảng worst cases.

Quyết định: xác định model cần feature bổ sung, retrain theo regime, model riêng cho site hoặc fallback baseline. Dashboard phải tách lỗi model khỏi lỗi dữ liệu.

13.7 Điều kiện nghiệm thu Dashboard XAI

- Chỉ tính XAI trên validation/test hoặc sample đại diện từ tập test.
- Không dùng `gen_id`, surrogate key hoặc row order làm feature.
- Mọi local explanation phải truy vết được về `site_id` và `timestamp`.
- SHAP giải thích hành vi model, không chứng minh quan hệ nhân quả.
- Insight XAI phải được đối chiếu với EDA và kiến thức domain solar.

14 Quy tắc thực hiện

1. Không random split dữ liệu time series.
2. Không dùng feature có thông tin tương lai.
3. Lag/rolling phải `shift` trước khi tính feature dự báo.
4. Không fit scaler/PCA/PLS trên toàn bộ dữ liệu trước split.
5. Không trộn generation 15 phút với weather một giờ mà không ghi rule.
6. Không dùng ID số nguyên như biến liên tục.
7. Không tự fill metadata capacity/panel.
8. Không coi IQR candidate là dữ liệu lỗi chắc chắn.
9. Không kết luận correlation là quan hệ nhân quả.
10. Không chỉ báo cáo all-site; phải có kiểm tra theo site và thời gian.
11. Không dùng MAPE làm metric chính khi target có nhiều zero.
12. Mọi hình phải có bảng số liệu hoặc CSV kiểm chứng.

15 Baseline và metric cho bước ML

15.1 Baseline

- persistence gần nhất;
- cùng giờ ngày trước;
- cùng giờ tuần trước;
- zero/night baseline nếu phạm vi có ban đêm.

15.2 Metric

- MAE: sai số tuyệt đối trung bình, đơn vị kWh;
- RMSE: nhạy với sai số lớn;
- WAPE hoặc MASE: metric chính khi có zero;
- sMAPE: metric bổ sung;
- R^2 : chỉ dùng bổ sung, không kết luận một mình.

Metric phải được báo cáo tổng thể và theo site, hour/season, không chỉ có một con số toàn hệ thống.

Với metric theo nhiều site, phải báo đồng thời:

- **Segment metric (metric theo nhóm):** MAE/RMSE/WAPE/MASE của từng site, hour, season hoặc nhóm cần giám sát;
- **Macro metric:** trung bình metric của các site, mỗi site có trọng số bằng nhau;
- **Micro/global metric:** tính trên toàn bộ dòng test, nên site có nhiều dòng hoặc target lớn có thể đóng góp nhiều hơn;
- **Worst-site metric:** nhóm site có sai số cao nhất để tránh metric global che khuất lỗi local.

16 Cấu trúc đầu ra chung

Mỗi workstream phải nộp:

- notebook chạy lại được;
- CSV summary đứng sau các hình;
- ảnh PNG có tên duy nhất;
- phần kết luận gồm câu hỏi, quan sát, quyết định và giới hạn;
- validation cell kiểm tra row count/grain;
- danh sách cột đã sử dụng;
- phiên bản dataset hoặc DVC reference.

17 Tiêu chí nghiệm thu

Kế hoạch EDA hoàn thành khi:

- data quality được kiểm tra trước phân tích;
- mọi nhóm cột đã có thống kê và câu hỏi rõ;
- target được phân tích theo nhiều mức thời gian;
- weather được phân tích theo đúng grain và domain;
- mọi visualization phù hợp đi từ bản ghi/sự kiện chi tiết, qua nhóm trung gian, đến kết quả tổng quan;
- kết luận tổng quan truy ngược được về các nhóm và trường hợp chi tiết;
- macro metric, micro/global metric và worst-site metric được báo riêng;
- stationarity/non-stationarity được kiểm tra bằng visualization, rolling statistics, decomposition và ADF/KPSS khi chuỗi đủ điều kiện;
- correlation và multicollinearity được kiểm tra;
- lag/rolling được đánh giá không leakage;
- raw-vs-clean được so sánh thay vì tự động xóa outlier;
- BI và ML có kết luận riêng;
- số liệu giữa notebook, CSV, hình và báo cáo thống nhất;
- nhóm chốt được feature decision table và ML-ready dataset.

18 Kết luận

Nhóm thực hiện EDA theo thứ tự:

Data Quality → Target/Time → Weather/Domain → Correlation/Lag → BI/ML
Integration

Kết quả cuối cùng không chỉ là bộ hình trực quan mà phải là một bộ quyết định có thể chuyển thẳng sang dashboard và pipeline ML: target nào được dùng, feature nào được giữ, feature nào cần transform, outlier được xử lý ra sao, split như thế nào và metric nào dùng để nghiệm thu.