

Báo cáo EDA — Dự báo Sản lượng Điện Mặt trời UNISOLAR

Ngô Tấn Đạt

Ngày 27 tháng 6 năm 2026

Tóm tắt nội dung

Báo cáo trình bày chi tiết quá trình phân tích khám phá dữ liệu (EDA) trên bộ dữ liệu UNISOLAR gồm 42 trạm pin mặt trời tại 5 khuôn viên của Đại học La Trobe (Victoria, Úc), tần suất 15 phút, giai đoạn 2020–2022. Mỗi kỹ thuật được trình bày theo cấu trúc: công thức/đoạn mã, lý do áp dụng, và **ví dụ thực tế trên chính bộ dữ liệu**. Nội dung trọng tâm: phân rã chuỗi thời gian, trực quan hóa đa tầng, báo cáo dữ liệu thiếu (gap), lệch múi giờ khi join, xử lý DST, và phát hiện ngoại lai.

Mục lục

1	Phân rã chuỗi thời gian (Decomposition)	3
1.1	Dữ liệu dùng để minh họa	3
1.2	Bước 1 — Tính Trend (trung bình trượt cân giữa 24 giờ)	3
1.3	Bước 2 — Khử xu hướng	3
1.4	Bước 3 — Tính Seasonal từ bảng trên	4
1.5	Bước 4 — Tính Residual và kiểm tra	5
1.6	Insight rút ra từ phân rã	5
2	Trực quan hóa chuỗi thời gian đa tầng (Line Charts)	7
2.1	Phương pháp	7
2.2	Phát hiện quan trọng: giờ đạt đỉnh dịch theo mùa	7
3	Báo cáo dữ liệu thiếu (Gap)	8
3.1	Phương pháp	8
3.2	Lý do	9
3.3	Ví dụ trên bộ dữ liệu	9

4	Kiểm tra lệch múi giờ khi join	10
4.1	Vấn đề	10
4.2	Bảng chứng: giờ đạt đỉnh (Trạm 2)	11
4.3	Giải thích nguyên nhân	11
5	Xử lý Daylight Saving Time (DST)	11
5.1	Lùi đồng hồ: giờ 2h sáng lặp hai lần	11
5.2	Tiến đồng hồ: giờ ảo không tồn tại	12
5.3	Điểm chú ý khi năng lượng đạt đỉnh	12
6	Phát hiện ngoại lai (Outlier)	13
6.1	Loại 1 — Phát điện ban đêm (nhiều cảm biến)	13
6.2	Loại 2 — Ngoại lai ngũ cảnh	13
6.3	Loại 3 — Nắng mạnh nhưng không phát điện	14
6.4	Loại 4 — Bất thường công suất (capacity)	14
7	Tổng kết EDA	14

1 Phân rã chuỗi thời gian (Decomposition)

Công thức phân rã tách chuỗi gốc thành ba phần: xu hướng, mùa vụ và phần dư.

$$Y_t = T_t + S_t + R_t$$

Y_t : Giá trị quan sát tại thời điểm t

T_t : Trend: xu hướng dài hạn

S_t : Seasonality: mùa vụ chu kỳ

R_t : Residual: phần dư

1.1 Dữ liệu dùng để minh họa

Ví dụ tính tay trên dữ liệu **thật**: Trạm 23, gộp theo giờ, từ 06/11/2021 đến 10/11/2021, gồm **120 điểm** (5 ngày $\times$ 24 giờ). Chu kỳ $m = 24$ (một ngày).

```
from statsmodels.tsa.seasonal import seasonal_decompose
s = df[df.site_id==23].set_index('timestamp')['energy_generated_kwh']
s = s.resample('1h').mean()['2021-11-06':'2021-11-10']
res = seasonal_decompose(s, model='additive', period=24)
```

1.2 Bước 1 — Tính Trend (trung bình trượt cân giữa 24 giờ)

$$T_t = \frac{1}{24} \left(\frac{1}{2}Y_{t-12} + Y_{t-11} + \dots + Y_{t+11} + \frac{1}{2}Y_{t+12} \right)$$

Tính tay tại $t = 08/11/2021$ 12:00, lấy đúng các giá trị thật trong cửa sổ trung bình trượt:

$$\text{Tử số} = 76,262.$$

$$T_{12h} = \frac{76,262}{24} = 3,1776$$

Trend tại trưa chính là *mức sản lượng trung bình của cả ngày hôm đó*.

1.3 Bước 2 — Khử xu hướng

$$d_t = Y_t - T_t, \quad d_{12h} = 9,7266 - 3,1776 = 6,5490$$

Nhóm giờ	Giá trị Y (kWh)	Tổng
08/11 00:00–05:00	0,000 mỗi giờ	0,000
08/11 06:00	0,064	0,064
08/11 07:00	1,006	1,006
08/11 08:00	2,047	2,047
08/11 09:00	2,234	2,234
08/11 10:00	3,031	3,031
08/11 11:00	7,953	7,953
08/11 12:00	9,727	9,727
08/11 13:00	8,055	8,055
08/11 14:00	10,219	10,219
08/11 15:00	11,434	11,434
08/11 16:00	10,186	10,186
08/11 17:00	7,410	7,410
08/11 18:00	2,541	2,541
08/11 19:00	0,355	0,355
08/11 20:00–23:00	0,000 mỗi giờ	0,000
Tổng		76,262

Bảng 1: Các giá trị sản lượng dùng để tính trend tại 08/11/2021 12:00.

1.4 Bước 3 — Tính Seasonal từ bảng trên

Sau Bước 2, mỗi dòng đã có phần khử xu hướng:

$$d_t = Y_t - T_t.$$

Trong ví dụ tính tay này, ta dùng chính bảng 24 giờ ở Bước 1. Vì trend của ngày là $T = 3,1776$, seasonal minh họa tại mỗi giờ được tính trực tiếp:

$$S_h = Y_h - 3,1776.$$

Do 3,1776 là trung bình của 24 giờ trong ngày, tổng các giá trị S_h trong ngày bằng 0. Vì vậy bảng seasonal bên dưới được tính ngay từ bảng số liệu ở Bước 1, không cần thêm dữ liệu ngoài.

Ví dụ tại 12h:

$$S_{12h} = Y_{12h} - T = 9,7266 - 3,1776 = 6,5490.$$

Ý nghĩa: lúc 12h, sản lượng cao hơn mức nền ngày khoảng 6,5490 kWh.

Tính tương tự cho các giờ tiêu biểu:

Vậy $S_{12h} = +6,549$: trưa cao hơn nền ngày khoảng 6,55 kWh trong ví dụ tính tay này.

Giờ	S_h	Giờ	S_h	Giờ	S_h
0h	-3,178	9h	-0,944	15h	+8,256
6h	-3,114	11h	+4,775	16h	+7,008
7h	-2,172	12h	+6,549	18h	-0,637
8h	-1,131	13h	+4,877	21h	-3,178

Bảng 2: Seasonal minh họa tính trực tiếp từ bảng 24 giờ: $S_h = Y_h - 3,1776$.

1.5 Bước 4 — Tính Residual và kiểm tra

$$R_t = Y_t - T_t - S_t, \quad R_{12h} = 9,7266 - 3,1776 - 6,5490 = 0$$

Kiểm tra lại tại 08/11 12:00:

$$T + S + R = 3,1776 + 6,5490 + 0 = 9,7266 = Y_{12h}.$$


Đây là ví dụ tính tay tối giản từ bảng một ngày: mỗi quan sát được tách thành mức nền ngày (Trend), nhịp ngày–đêm minh họa (Seasonal), và phần còn lại (Residual). Khi chạy decomposition đầy đủ trên nhiều ngày, seasonal được lấy trung bình theo cùng giờ qua nhiều ngày nên residual sẽ không nhất thiết bằng 0.

1.6 Insight rút ra từ phân rã


Từ bảng tính tay một ngày, có thể rút ra các nhận xét sau:

- Chuỗi có **mùa vụ ngày–đêm rất mạnh**: ban đêm seasonal âm vì sản lượng gần 0, còn buổi trưa/chiều seasonal dương vì sản lượng cao hơn mức nền ngày.
- Riêng ngày 08/11/2021, giá trị cao nhất trong bảng là lúc 15h (11,434 kWh), nên ngày này đỉnh bị lệch về chiều. Điều này có thể do mây, nhiệt độ, hoặc điều kiện vận hành trong ngày, nên không nên kết luận toàn bộ dữ liệu luôn đỉnh 15h.
- Vì trung bình thay đổi rõ theo giờ trong ngày (đêm gần 0, ban ngày tăng mạnh), chuỗi gốc có thể xem là **non-stationary theo mùa vụ ngày–đêm**. Nói cách khác, phân phối của Y_t phụ thuộc vào thời điểm trong ngày.


Với dữ liệu điện mặt trời, kết luận EDA hợp lý là: chuỗi gốc **non-stationary do seasonal pattern ngày–đêm**. Sau khi loại bỏ seasonal/trend, phần residual có thể gần stationary hơn, nhưng báo cáo này không dùng kiểm định thống kê riêng nên không khẳng định residual stationary.



Hình 1: Kết quả phân rã chuỗi thời gian từ notebook cho Site 11.



Hình 2: Kết quả phân rã chuỗi thời gian từ notebook cho Site 27.



Hình 3: Kết quả phân rã chuỗi thời gian từ notebook cho Site 25.

2 Trực quan hóa chuỗi thời gian đa tầng (Line Charts)

2.1 Phương pháp


Vẽ đường sản lượng theo nhiều tầng thời gian: (i) toàn cục theo năm; (ii) theo mùa; (iii) theo ngày điển hình, lọc theo từng trạm và khung giờ. Mục đích: phát hiện chu kỳ, so sánh giữa các trạm, quan sát biến động trong ngày.

```
g = df[(df.site_id==23) &
      (df.timestamp.dt.date==pd.Timestamp('2021-11-08').date())]
plt.plot(g.timestamp, g.energy_generated_kwh)
```

Heatmap 42 trạm $\times$ 24 giờ dùng để kiểm tra nhanh theo giờ: vùng ban đêm lý tưởng phải gần 0; nếu ban đêm vẫn xuất hiện màu khác 0 thì đó là dấu hiệu **đêm có điện**, tức ngoại lai/nhiều cảm biến.

2.2 Phát hiện quan trọng: giờ đạt đỉnh dịch theo mùa

Không phải cứ ở Úc là sản lượng luôn đạt đỉnh 13h. Với dữ liệu ở bang Victoria (múi giờ Australia/Melbourne), giờ đạt đỉnh phụ thuộc mùa, DST và điều kiện thời tiết. Một quan sát then chốt là sản lượng **không** luôn đạt đỉnh lúc 12h:



Hình 4: Công cụ trực quan hóa chuỗi thời gian để chọn trạm, khoảng ngày và khung giờ.

Mùa	Giờ đỉnh sản lượng	Giờ đỉnh bức xạ
Hè (DST bật, T12–T2)	13h	14h
Thu (T3–T5)	12h	13h
Đông (DST tắt, T6–T8)	12h	13h
Xuân (T9–T11)	12h	13h

Bảng 3: Giờ đạt đỉnh dịch theo mùa do DST và độ dài ngày.

Chi tiết theo tháng: tháng 1 đỉnh sản lượng lúc **14h**, tháng 2–3 và 11 lúc 13h, các tháng 4–10 lúc 12h, tháng 12 lúc 14h. Vì vậy nên diễn giải là: **mùa hè/DST có thể đỉnh 13h–14h, còn các mùa khác thường gần 12h**. Đây là minh chứng cần phân tích *theo mùa* thay vì chỉ lấy trung bình toàn năm.


3 Báo cáo dữ liệu thiếu (Gap)

3.1 Phương pháp

Tạo lưới thời gian đầy đủ 15 phút rồi so với số mốc thực có. Độ phủ:

$$\text{Coverage}_s = \frac{N_s^{\text{thực}}}{N_s^{\text{đầy đủ}}} \times 100\%, \quad N_s^{\text{đầy đủ}} = \frac{t_s^{\text{max}} - t_s^{\text{min}}}{15 \text{ phút}} + 1$$

```
full = pd.date_range(g.timestamp.min(), g.timestamp.max(), freq='15 min')
missing = len(full) - len(g)
coverage = 100 * len(g) / len(full)
```


Hình 5: Heatmap tương quan ban ngày giữa sản lượng và các biến thời tiết từ notebook.

3.2 Lý do

Mô hình chuỗi thời gian giả định lưới đều. Nếu không phát hiện gap, đặc trưng trễ (lag) sẽ nổi nhảm hai thời điểm cách nhau bởi khoảng trống dài. Do đó cần reindex và đánh dấu vùng thiếu.

3.3 Ví dụ trên bộ dữ liệu

Ngoài các khoảng thiếu rải rác, tồn tại **gap đồng bộ** (nhiều trạm cùng mất), điển hình khoảng 01--05/10/2020 — sự cố pipeline thu thập. Xử lý: chỉ nội suy gap ngắn (nhỏ hơn 6 giờ) cho biến thời tiết; **biến mục tiêu giữ NaN**, không bịa nhãn.



Hình 6: Heatmap 42 trạm theo 24 giờ; vùng đêm khác 0 giúp phát hiện nhiều “đêm có điện”.

Chỉ số	Giá trị
Độ phủ trung bình (42 trạm)	98,13%
Độ phủ thấp nhất	97,84%
Tổng số mốc 15 phút bị thiếu	52 492

Bảng 4: Thống kê dữ liệu thiếu.

4 Kiểm tra lệch múi giờ khi join

4.1 Vấn đề

Sản lượng tần suất 15 phút, thời tiết theo giờ. Khi join theo giờ, cần kiểm tra khớp pha bằng tương quan chéo:

$$\rho(k) = \text{corr}(E_t, R_{t+k}),$$

$$k^* = \arg \max_k \rho(k)$$


```
shifts = range(-8, 9)
corrs = [E.corr(R.shift(k)) for k in shifts]
best_k = shifts[int(np.argmax(corrs))]
```

Giờ	Sản lượng TB (kWh)	Bức xạ TB (W/m ²)
11	11,59	512,67
12	11,95 (đỉnh energy)	590,05
13	11,48	622,53 (đỉnh radiation)
14	10,97	609,55

Bảng 5: Sản lượng đỉnh sớm hơn bức xạ một giờ (Trạm 2, trung bình cả năm).

4.2 Bằng chứng: giờ đạt đỉnh (Trạm 2)

Toàn bộ 42 trạm: **19/42 trạm** có sản lượng đạt đỉnh *trước* bức xạ.



Hình 7: Tương quan giữa sản lượng và bức xạ theo độ dịch 15 phút cho Site 22.

4.3 Giải thích nguyên nhân

Phân tích theo phút: `weather_timestamp` luôn ở phút :00, `energy` có 4 mốc :00, :15, :30, :45. Join theo giờ **đúng về khóa**, nhưng bức xạ *phẳng trong cả giờ* còn sản lượng *biến động liên tục*, nên tương quan chéo phát hiện lệch pha biểu kiến -30 đến -45 phút. Đây là **hệ quả chênh lệch độ phân giải** (15 phút vs 1 giờ), không phải lỗi ETL. Bù bằng dịch pha động theo từng trạm (tính trên tập huấn luyện) ở bước mô hình.

5 Xử lý Daylight Saving Time (DST)

Victoria áp dụng giờ mùa hè: lùi đồng hồ (fall-back) tháng 4, tiến đồng hồ (spring-forward) tháng 10.

5.1 Lùi đồng hồ: giờ 2h sáng lặp hai lần

```

WITH ranked AS (
  SELECT
    sitekey,
    timestamp,
    solargeneration,
    ROW_NUMBER() OVER (
      PARTITION BY sitekey, timestamp
      ORDER BY timestamp
    ) AS rn
  FROM energy_raw
)
SELECT *
FROM ranked
WHERE rn = 1;

```

Ví dụ thực tế. Vào ngày lùi đồng hồ, mốc 2h có thể xuất hiện hai lần theo giờ địa phương. Vì vậy dữ liệu được đánh số bằng ROW_NUMBER() theo từng khóa (sitekey, timestamp) và chỉ giữ dòng rn = 1. Kiểm tra 3 ngày lùi đồng hồ (05/04/2020, 04/04/2021, 03/04/2022) cho đúng **388 dòng** sau khi giữ rn = 1 (không phải 504, vì 2020 chỉ có 13 trạm). Toàn bộ có solargeneration **NULL**:

sitekey	timestamp	solargeneration
1	2021-04-04 02:00:00	(NULL)
1	2021-04-04 02:15:00	(NULL)
1	2021-04-04 02:30:00	(NULL)
1	2021-04-04 02:45:00	(NULL)

Bảng 6: Dữ liệu điện tại giờ lùi đồng hồ sau khi giữ dòng rn = 1.

5.2 Tiến đồng hồ: giờ ảo không tồn tại

```

df = df.dropna(subset=['temperature_c', 'wind_speed']) # loại 218
dong gio ao

```

Có **218 dòng** bị loại do thời tiết NULL tại các mốc giờ ảo.

5.3 Điểm chú ý khi năng lượng đạt đỉnh

Múi giờ chuẩn là Australia/Melbourne. Khi DST bật (mùa hè), solar noon thường lệch sang khoảng 13h theo đồng hồ; đỉnh sản lượng thực tế có thể rơi 13h–

14h tùy tháng và thời tiết (Bảng 3). Nếu hiểu nhầm timestamp là UTC, đỉnh bức xạ sẽ rơi khoảng 2h sáng — vô lý. Lưu ý:

- Đặc trưng hình học mặt trời (zenith, clearsky_ghi) phải tính theo đúng múi giờ Australia/Melbourne bằng pvlib.
- Giờ đỉnh dịch theo mùa (Bảng 3): mùa hè/DST thường muộn hơn, các mùa khác gần 12h — cần xử lý theo mùa.
- Sản lượng đạt đỉnh *sớm hơn* bức xạ một phần do nhiệt độ tấm pin tăng cao buổi chiều làm giảm hiệu suất.

6 Phát hiện ngoại lai (Outlier)

Ngoại lai xử lý theo **từng trạm** (per-site) vì 42 trạm chênh lệch lớn. Bốn loại:

6.1 Loại 1 — Phát điện ban đêm (nhiều cảm biến)

$$E_t \leftarrow 0 \quad \text{nếu} \quad R_t = 0.$$

```
night = df[(df.shortwave_radiation==0) & (df.energy_generated_kwh
>0)]
df.loc[df.shortwave_radiation==0, 'energy_generated_kwh'] = 0.0
```

Ví dụ: notebook phát hiện **26 138 dòng** phát điện ban đêm, ví dụ Trạm 6 lúc 2021-02-13 07:45 có energy = 2,205 trong khi bức xạ = 0.

Heatmap ở Hình 6 cũng hỗ trợ phát hiện lỗi này: các ô ban đêm đáng ra phải gần 0, nên ô nào còn màu đỏ/vàng ở giờ đêm là tín hiệu cần kiểm tra.

6.2 Loại 2 — Ngoại lai ngữ cảnh

Ngưỡng IQR được tính riêng theo từng trạm và từng bin bức xạ.

$$\begin{aligned} \text{IQR} &= Q_3 - Q_1, \\ \text{ngưỡng} &= [Q_1 - 1,5 \text{ IQR}, Q_3 + 1,5 \text{ IQR}] \end{aligned}$$

```
g['radbin'] = pd.cut(g.shortwave_radiation,
[0,200,400,600,800,2000])
Q1, Q3 = sub.quantile(.25), sub.quantile(.75)
IQR = Q3 - Q1
lo, hi = Q1 - 1.5*IQR, Q3 + 1.5*IQR
```

Lý do: sản lượng phụ thuộc mạnh vào bức xạ nên phải chuẩn hóa theo ngữ cảnh (cùng trạm, cùng mức nắng).

Ví dụ (Trạm 23, bin 400–600 W/m²):


$$Q_1 = 4,03, \quad Q_3 = 7,99, \quad \text{IQR} = 3,96, \\ \text{ngưỡng} = [-1,91; 13,93]$$

Điểm ngoài khoảng này tại mức bức xạ đó bị gấn cờ (không xóa).

6.3 Loại 3 — Năng mạnh nhưng không phát điện

$$R_t > 500 \text{ W/m}^2 \wedge E_t < 0,5 \text{ kWh.}$$

Ví dụ: 2 062 dòng, tập trung ở Trạm 9 (290 điểm), Trạm 29 (269), Trạm 5 (238).



Hình 8: Phân bố lỗi “năng mạnh nhưng không phát điện” theo giờ từ notebook.

6.4 Loại 4 — Bất thường công suất (capacity)

$$\text{ratio}_s = \frac{\max_t E_t}{\text{capacity}_s/4}$$

Ví dụ: 17/42 trạm thiếu capacity_kw. Trạm 19 có ratio = 5,20: energy max = 44,61, trong khi capacity/4 = 8,58. Điều này cho thấy dữ liệu capacity sai. Kết luận: **không** dùng capacity để cắt cứng sản lượng.

7 Tổng kết EDA

Vấn đề	Phát hiện	Hướng xử lý
Giờ đỉnh	Dịch theo mùa (hè 13h)	Phân tích theo mùa
Dữ liệu thiếu	Phủ 98,13%	Reindex, giữ NaN target
Lệch pha join	Energy đỉnh sớm hơn radiation	Dịch pha động per-site
DST fall-back	Giữ 388 dòng sau lọc rn = 1	Loại bản lặp bằng ROW_NUMBER
DST spring-forward	218 dòng giờ ảo	Loại bỏ
Nhiều ban đêm	26 138 dòng	Kẹp về 0
Sự cố inverter	2 062 dòng	Gắn cờ
Capacity sai	Trạm 19 vượt 5,2 lần	Không hard-clip

Bảng 7: Tóm tắt phát hiện EDA và hướng xử lý.