

TRƯỜNG CAO ĐẲNG FPT POLYTECHNIC



FPT POLYTECHNIC

DỰ ÁN TỐT NGHIỆP
CHUYÊN NGÀNH: XỬ LÝ DỮ LIỆU

PHÂN TÍCH HIỆU SUẤT VÀ DỰ BÁO SẢN LƯỢNG HỆ THỐNG ĐIỆN MẶT TRỜI

Nhóm thực hiện: The Outliers

Sinh viên thực hiện:

- | | |
|---------------------|---------|
| 1. Nguyễn Vũ Nhật | PS44442 |
| 2. Nguyễn Văn Sỹ | PS43671 |
| 3. Lê Công Toàn | PS44145 |
| 4. Nguyễn Xuân Hùng | PS44527 |
| 5. Ngô Tấn Đạt | PS44589 |

Giảng viên hướng dẫn: Văn Công Khanh

TP. HỒ CHÍ MINH, THÁNG 6 NĂM 2026

Lời cảm ơn

[Nội dung lời cảm ơn của sinh viên đối với giảng viên hướng dẫn, gia đình và nhà trường sẽ được viết tại đây.]

Nhận xét của Giảng viên Hướng dẫn

[Nội dung nhận xét và đánh giá của Giảng viên Hướng dẫn đối với kết quả thực hiện dự án của nhóm.]

Nhận xét của Giảng viên Phản biện

[Nội dung nhận xét và đánh giá của Giảng viên Phản biện tại buổi bảo vệ dự án tốt nghiệp.]

Tóm tắt Dự án

Dự án tốt nghiệp “Phân tích và Xử lý Bất thường trong Dữ liệu Sản lượng Năng lượng Mặt trời” nhằm mục đích xây dựng một hệ thống phân tích dữ liệu toàn diện để phát hiện, xử lý và dự báo các bất thường trong sản lượng phát điện của các hệ thống quang điện (PV). Bằng cách thu thập và tích hợp dữ liệu từ 42 trạm phát điện tại Úc cùng dữ liệu khí tượng viễn thám từ Open-Meteo, nhóm đã thiết kế một kho dữ liệu đa chiều (Data Warehouse) trên nền tảng Supabase theo mô hình Galaxy Schema. Quy trình ETL được tự động hóa để làm sạch dữ liệu, xử lý các hiện tượng khuyết thiếu, nhiễu ban đêm, và sai lệch do cảm biến.

Qua quá trình Phân tích Khám phá Dữ liệu (EDA), nhóm đã rút ra các insight quan trọng về sự ảnh hưởng của nhiệt độ, mức độ mây che phủ đến hiệu suất PV. Ngoài ra, dự án cũng áp dụng các mô hình học máy chuỗi thời gian như ARIMA và Prophet để thiết lập đường cơ sở (Baseline) dự báo sản lượng, kết hợp hiển thị trực quan thông qua Dashboard Tableau. Hệ thống không chỉ cung cấp cái nhìn toàn cảnh về tình trạng hoạt động của các trạm điện mặt trời, mà còn hỗ trợ ban quản lý đưa ra quyết định kịp thời nhằm tối ưu hóa hiệu suất và giảm thiểu rủi ro vận hành.

Mục lục

Lời cảm ơn	1
Nhận xét của Giảng viên Hướng dẫn	2
Nhận xét của Giảng viên Phản biện	3
Tóm tắt Dự án	4
Danh mục Từ viết tắt	10
1 Tổng quan Đề tài và Bài toán Nghiên cứu	11
1.1 Bối cảnh thực tế và lý do chọn đề tài	11
1.2 Bài toán kinh doanh và các khó khăn cần giải quyết	11
1.3 Mục tiêu dự án và Kết quả dự kiến	12
1.4 Đối tượng và phạm vi nghiên cứu	12
1.5 Bố cục báo cáo	13
2 Cơ sở Lý thuyết	14
2.1 Tổng quan về Năng lượng mặt trời và Bức xạ quang điện	14
2.2 Kiến trúc Kho dữ liệu đa chiều (Data Warehouse)	14
2.2.1 Mô hình hóa đa chiều (Dimensional Modeling)	14
2.2.2 Lược đồ Thiên hà (Galaxy Schema)	15
2.2.3 Phương pháp tiếp cận Top-Down (Triết lý kiến trúc của Bill Inmon)	15
2.3 Quy trình Trích xuất, Biến đổi và Nạp dữ liệu (ETL Pipeline)	16
2.3.1 Lý thuyết về Nội suy dữ liệu khuyết thiếu (Data Imputation)	16
2.3.2 Chiến lược nạp dữ liệu tối ưu hóa giao dịch	17
2.4 Các phương pháp Phát hiện bất thường dữ liệu (Anomaly Detection)	18
2.4.1 Phương pháp thống kê Z-Score	18
2.4.2 Phương pháp khoảng tứ phân vị IQR (Interquartile Range)	18
2.4.3 Phương pháp Trung bình trượt và IQR cục bộ (Rolling IQR)	19
2.5 Cơ sở thuật toán Dự báo chuỗi thời gian	19
3 Thu thập Dữ liệu và Thiết kế Kiến trúc Kho dữ liệu	21
3.1 Kiến trúc Tổng thể Hệ thống Dữ liệu (Data Architecture Overview)	21
3.1.1 Tiếp cận Top-Down (Inmon Approach)	21
3.2 Phương pháp thu thập dữ liệu thô (Extract)	22

3.2.1	Trích xuất dữ liệu khí tượng qua Open-Meteo API	22
3.2.2	Thiết lập kết nối cơ sở dữ liệu Supabase	24
3.3	Data Dictionary & Metadata	25
3.3.1	Dữ liệu Thông tin Cơ sở hạ tầng (campus_meta.csv)	25
3.3.2	Dữ liệu Thông tin Kỹ thuật Trạm (Solar_Site_Details.csv)	26
3.3.3	Dữ liệu Sản lượng Điện (Solar_Energy_Generation.csv)	26
3.3.4	Dữ liệu Thông tin Lịch trình (calender.csv)	27
3.3.5	Dữ liệu Khí tượng Viễn thám (open_meteo_weather_raw.csv)	27
3.4	Thiết kế kiến trúc Kho dữ liệu đa chiều (Data Warehouse)	28
3.4.1	Mô hình Dữ liệu Khái niệm (Conceptual Data Model)	28
3.4.2	Mô hình Dữ liệu Logic (Logical Data Model)	29
3.4.3	Mô hình Dữ liệu Vật lý (Physical Data Model)	30
3.4.4	Kịch bản SQL Khởi tạo Cơ sở Dữ liệu	34
3.5	Kiểm tra tính toàn vẹn và bảo mật dữ liệu	36
4	Quy trình ETL và Chuẩn hóa Dữ liệu	37
4.1	Tổng quan Kiến trúc Pipeline Xử lý Dữ liệu	37
4.1.1	Thiết lập Tiến trình Nạp Dữ liệu Tự động	38
4.1.2	Cơ chế Quản lý Giao dịch và An toàn Dữ liệu	39
4.2	Đánh giá Chất lượng và Khám phá Dữ liệu (EDA ban đầu)	39
4.2.1	Các Cột Thực Tế và Ảnh Xạ Dữ Liệu Trong Pipeline	40
4.3	Làm sạch và Chuẩn hóa Dữ liệu (Data Cleaning)	41
4.3.1	Xử lý Dữ liệu Khuyết thiếu và Lỗi Logic	41
4.3.2	Xử lý Dữ liệu Ngoại lai (Outliers) và Lọc nhiễu	46
4.4	Biến đổi và Trích xuất Đặc trưng (Feature Engineering)	49
4.4.1	Giải quyết độ lệch tần suất ghi nhận (Granularity Alignment)	49
4.4.2	Trích xuất các đặc trưng thời gian và lịch trình học tập	49
5	Trực quan Dữ liệu và Xây dựng Dashboard	51
5.1	Chiến lược Kết nối Dữ liệu và Thiết kế UI/UX	51
5.2	Chi tiết Hệ thống Dashboard Phân tích	51
5.2.1	Dashboard 1: Tổng quan Vận hành (Executive Overview)	51
5.2.2	Dashboard 2: Phân tích Hiệu suất và Khí hậu	51
5.2.3	Dashboard 3: Giám sát Bất thường và Lỗi Cảm biến	51
6	Khai phá Dữ liệu và Business Insights	52
6.1	Insight 1: Hiện tượng suy giảm hiệu suất do nhiệt độ (Thermal Degradation)	52
6.2	Insight 2: Điểm mù vận hành từ “Độ nhiễu ban đêm”	52
6.3	Insight 3: Ứng dụng Mô hình dự báo (Baseline) để tối ưu vận hành	52

7 Kết luận và Hướng phát triển	53
7.1 Kết luận Tổng quan	53
7.2 Khuyến nghị Chiến lược (Actionable Insights)	53
7.3 Hạn chế của Dự án	53
7.4 Hướng phát triển trong tương lai	53
7.4.1 Nâng cấp Hệ thống Phân tích Dự đoán (Predictive Analytics)	53
7.4.2 Tự động hóa và Đưa lên Đám mây (Cloud & Automation)	53
Phụ lục A: Kế hoạch Thực hiện	54
Phụ lục B: Cấu trúc Mã nguồn	55
Tài liệu Tham khảo	56

Danh sách hình vẽ

3.1	Sơ đồ Mô hình Dữ liệu Khái niệm (Conceptual Data Model)	28
3.2	Sơ đồ Mô hình Dữ liệu Logic (Logical Data Model)	29
3.3	Sơ đồ Mô hình Dữ liệu Vật lý (Physical Data Model)	30

Danh sách bảng

2.1	Bảng so sánh lý thuyết Inmon vs. Kimball	16
3.1	Từ điển dữ liệu tệp campus_meta.csv	25
3.2	Từ điển dữ liệu tệp Solar_Site_Details.csv	26
3.3	Từ điển dữ liệu tệp Solar_Energy_Generation.csv	26
3.4	Từ điển dữ liệu tệp calender.csv	27
3.5	Từ điển dữ liệu tệp open_meteo_weather_raw.csv	27
3.6	Cấu trúc vật lý bảng chiều trạm năng lượng (dim_solar_site)	30
3.7	Cấu trúc vật lý bảng chiều địa lý (dim_geography)	31
3.8	Cấu trúc vật lý bảng chiều ngày (dim_date)	31
3.9	Cấu trúc vật lý bảng chiều thời gian (dim_time)	31
3.10	Cấu trúc vật lý bảng chiều danh mục thời tiết (dim_weather_type)	32
3.11	Cấu trúc vật lý bảng sự kiện sản lượng (fact_solar_energy_gen)	32
3.12	Cấu trúc vật lý bảng sự kiện thời tiết (fact_weather)	33
4.1	Bảng thống kê kiểm tra chất lượng dữ liệu ban đầu trong Staging	39

Danh mục Từ viết tắt

Ký hiệu/Từ viết tắt	Ý nghĩa đầy đủ
API	Application Programming Interface (Giao diện lập trình ứng dụng)
ARIMA	AutoRegressive Integrated Moving Average
AWS	Amazon Web Services
BI	Business Intelligence (Phân tích thông minh doanh nghiệp)
CF	Capacity Factor (Hệ số công suất)
CSDL	Cơ sở dữ liệu
CT	Current Transformer (Cảm biến dòng điện)
DWH	Data Warehouse (Kho dữ liệu)
EDA	Exploratory Data Analysis (Phân tích khám phá dữ liệu)
ETL	Extract, Transform, Load (Trích xuất, Biến đổi, Nạp)
FK	Foreign Key (Khóa ngoại)
GCP	Google Cloud Platform
IoT	Internet of Things (Internet vạn vật)
IQR	Interquartile Range (Khoảng tứ phân vị)
kWp	Kilowatt-peak (Công suất đỉnh cực đại)
LSTM	Long Short-Term Memory
PK	Primary Key (Khóa chính)
PR	Performance Ratio (Hệ số hiệu suất)
PV	Photovoltaic (Quang điện - Năng lượng mặt trời)
UI/UX	User Interface / User Experience (Giao diện / Trải nghiệm người dùng)
WMO	World Meteorological Organization (Tổ chức Khí tượng Thế giới)
XGBoost	Extreme Gradient Boosting

Tổng quan Đề tài và Bài toán Nghiên cứu

1.1 Bối cảnh thực tế và lý do chọn đề tài

Năng lượng mặt trời đang ngày càng đóng vai trò quan trọng trong cơ cấu năng lượng tái tạo toàn cầu. Theo Cơ quan Năng lượng Quốc tế (IEA), công suất lắp đặt điện mặt trời trên toàn thế giới đã vượt mốc 1.600 GW vào cuối năm 2023, với tốc độ tăng trưởng trung bình 25%/năm trong thập kỷ qua. Tại Việt Nam, chính sách khuyến khích phát triển điện mặt trời áp mái và điện mặt trời tập trung đã đưa tổng công suất lắp đặt lên hơn 16.500 MW. Tuy nhiên, hiệu suất thực tế của các hệ thống quang điện (PV) thường sai lệch đáng kể so với giá trị thiết kế do ảnh hưởng của nhiều yếu tố như: điều kiện thời tiết biến đổi, suy giảm chất lượng tấm pin, bụi bẩn, bóng che và lỗi thiết bị.

Bài toán phân tích hiệu suất và phát hiện sớm các bất thường trong vận hành là then chốt giúp tối ưu hoá hiệu quả đầu tư và nâng cao độ tin cậy của lưới điện. Lý do nhóm chọn đề tài này bao gồm:

- **Tính thực tiễn:** Dự báo sản lượng và phát hiện bất thường có ứng dụng trực tiếp cho các doanh nghiệp vận hành nhà máy điện mặt trời.
- **Tính liên ngành:** Kết hợp phân tích dữ liệu, thống kê, học máy và kiến trúc kho dữ liệu trong một đề tài thống nhất.
- **Nguồn dữ liệu mở:** Dữ liệu từ Open-Meteo API miễn phí, chất lượng cao và phủ rộng toàn cầu.
- **So sánh đa vùng:** Phân tích đồng thời dữ liệu từ nhiều khu vực tại Úc để đánh giá tổng quát về hiệu suất PV.

1.2 Bài toán kinh doanh và các khó khăn cần giải quyết

Trong vận hành thực tế các trạm điện mặt trời, ban quản lý thường đối mặt với các khó khăn lớn:

- **Tác động thời tiết bất định:** Sự thay đổi của mây che phủ, bức xạ và nhiệt độ môi trường khiến sản lượng điện biến động liên tục, gây khó khăn cho việc điều phối lưới điện.

- **Suy hao và hỏng hóc thiết bị:** Các tấm pin bị bám bụi, inverter bị lỗi phần sụn hoặc quá nhiệt làm suy giảm đáng kể hiệu suất phát điện mà không được phát hiện kịp thời.
- **Sai lệch số liệu giám sát:** Cảm biến đo bức xạ hoặc cảm biến CT đo dòng điện bị nhiễu xung điện đột ngột hoặc lệch pha tần suất dữ liệu (Granularity Mismatch) giữa dữ liệu sản lượng (15 phút) và dữ liệu thời tiết (1 giờ) khiến phân tích sai lệch.

Hệ quả của việc không giải quyết các vấn đề trên là doanh nghiệp ra quyết định chậm trễ, tổn thất tài chính lớn do mất sản lượng, và dữ liệu thu thập bị bẩn dẫn đến các mô hình dự báo không chính xác.

1.3 Mục tiêu dự án và Kết quả dự kiến

Dự án tốt nghiệp đặt ra các mục tiêu cốt lõi sau:

1. Thiết kế và triển khai kho dữ liệu (*Data Warehouse*) tích hợp đồng bộ dữ liệu sản lượng và thời tiết theo mô hình Galaxy Schema (Fact Constellation) kết hợp phân nhánh Data Marts chuyên biệt.
2. Xây dựng pipeline dữ liệu tự động làm sạch (xử lý khuyết thiếu, lọc nhiễu ban đêm, phát hiện bất thường cảm biến).
3. Thực hiện phân tích khám phá chuyên sâu (EDA) để rút ra các insight vận hành quan trọng như hiện tượng suy giảm hiệu suất do nhiệt độ và độ nhiễu ban đêm.
4. Xây dựng hệ thống dữ liệu đáp ứng đồng thời hiệu năng truy vấn báo cáo (OLAP) và hiệu năng huấn luyện/dự báo học máy (MLOps) mà không làm quá tải tài nguyên Cloud.
5. Huấn luyện các mô hình dự báo sản lượng Baseline (ARIMA, Prophet) và so sánh hiệu năng.

Kết quả dự kiến (Sneak Peek): Một hệ thống Dashboard Tableau trực quan hóa mượt mà cho phép các nhà quản lý theo dõi toàn diện hiệu suất vận hành của 42 trạm tại Úc, tự động cảnh báo lỗi cảm biến và hiển thị dự báo sản lượng cho các chu kỳ tiếp theo với độ tin cậy cao.

1.4 Đối tượng và phạm vi nghiên cứu

- **Đối tượng nghiên cứu:** Hiệu suất phát điện của hệ thống quang điện (PV) và các yếu tố khí tượng viễn thám (bức xạ sóng ngắn, nhiệt độ, độ phủ mây, lượng mưa).
- **Phạm vi không gian:** 42 trạm điện mặt trời tại Úc.

- **Phạm vi thời gian:** Dữ liệu lịch sử từ 01/01/2020 đến 30/04/2022.

1.5 Bố cục báo cáo

Báo cáo dự án tốt nghiệp được cấu trúc thành 7 chương chính như sau:

- **Chương 1:** Tổng quan Đề tài và Bài toán Nghiên cứu.
- **Chương 2:** Cơ sở Lý thuyết (các mô hình dự báo, phát hiện outlier và DWH).
- **Chương 3:** Thu thập Dữ liệu và Thiết kế Kho dữ liệu.
- **Chương 4:** Quy trình ETL, Làm sạch và Biến đổi Dữ liệu.
- **Chương 5:** Phân tích Khám phá Dữ liệu (EDA) và Trực quan hóa.
- **Chương 6:** Mô hình hóa và Dự báo Sản lượng Baseline.
- **Chương 7:** Đánh giá Dự án, Đề xuất và Theo dõi Vận hành.

Cơ sở Lý thuyết

2.1 Tổng quan về Năng lượng mặt trời và Bức xạ quang điện

Hệ thống quang điện (PV) chuyển đổi năng lượng bức xạ mặt trời trực tiếp thành điện năng thông qua hiệu ứng quang điện trong chất bán dẫn. Hiệu suất chuyển đổi và khả năng vận hành của hệ thống phụ thuộc chặt chẽ vào các chỉ số lý thuyết sau:

- **Performance Ratio (PR):** Tỷ lệ đánh giá hiệu suất nguồn lưới, được xác định bằng tỷ số giữa sản lượng điện thực tế tạo ra và sản lượng lý thuyết trong điều kiện bức xạ lý tưởng. PR phản ánh mức độ tổn hao năng lượng do nhiệt độ, bụi bẩn và hiệu suất của bộ biến đổi (Inverter).
- **Capacity Factor (CF):** Hệ số công suất, được tính bằng tỷ lệ giữa sản lượng điện thực tế thu được trong một khoảng thời gian so với sản lượng điện tối đa mà trạm có thể phát nếu vận hành liên tục ở công suất thiết kế cực đại.
- **Specific Yield:** Sản lượng điện đặc trưng, biểu thị lượng điện năng tạo ra trên mỗi đơn vị công suất đỉnh lắp đặt (đo bằng đơn vị kWh/kWp), hỗ trợ so sánh hiệu suất giữa các trạm có quy mô khác nhau.

2.2 Kiến trúc Kho dữ liệu đa chiều (Data Warehouse)

Kiến trúc kho dữ liệu đa chiều được thiết kế theo phương pháp luận của Ralph Kimball, tập trung vào việc mô hình hóa dữ liệu nhằm tối ưu hóa hiệu năng truy vấn cho các bài toán phân tích thông minh (BI) và học máy.

2.2.1 Mô hình hóa đa chiều (Dimensional Modeling)

Mô hình hóa đa chiều phân tách dữ liệu thành hai nhóm chính:

- **Bảng sự kiện (Fact Table):** Lưu trữ các chỉ số đo lường định lượng (Measures) phát sinh từ các sự kiện nghiệp vụ (ví dụ: sản lượng điện phát ra, các thông số thời tiết

đo được). Bảng Fact thường chứa khối lượng dữ liệu rất lớn và liên kết với các bảng chiều qua các khóa ngoại.

- **Bảng chiều (Dimension Table):** Lưu trữ các thuộc tính mô tả ngữ cảnh của sự kiện (thời gian, địa điểm, thông tin kỹ thuật của thiết bị). Các bảng chiều cung cấp các trục phân tích chéo, làm bộ lọc cho các câu lệnh truy vấn dữ liệu.

2.2.2 Lược đồ Thiên hà (Galaxy Schema)

Trong các hệ thống phân tích tích hợp nhiều quy trình nghiệp vụ, lược đồ Thiên hà (Galaxy Schema hay Fact Constellation Schema) được sử dụng khi có nhiều bảng sự kiện dùng chung các bảng chiều được chuẩn hóa (Conformed Dimensions). Mô hình này cho phép:

- Hợp nhất nhiều luồng sự kiện có tần suất ghi nhận khác nhau (ví dụ: dữ liệu đo sản lượng điện theo chu kỳ phút và dữ liệu thời tiết theo chu kỳ giờ) mà không gây trùng lặp thông tin thừa.
- Thực hiện phân tích liên thông (Drill-through) giữa các bảng sự kiện khác nhau dựa trên các chiều chung như thời gian và không gian địa lý.

2.2.3 Phương pháp tiếp cận Top-Down (Triết lý kiến trúc của Bill Inmon)

Trái ngược với phương pháp tiếp cận Bottom-Up của Ralph Kimball - vốn tập trung xây dựng các Data Mart trước rồi mới tích hợp thành một kho dữ liệu tổng thể - triết lý Top-Down của Bill Inmon định nghĩa kho dữ liệu (Data Warehouse) là một thực thể lưu trữ tập trung, duy nhất và đóng vai trò là Single Source of Truth (Nguồn sự thật duy nhất) của toàn bộ doanh nghiệp.

- **Bản chất luồng dữ liệu:** Dữ liệu từ các hệ thống nguồn (Operational Systems) sau khi trích xuất sẽ được đổ trực tiếp vào một kho lưu trữ trung tâm được chuẩn hóa cấu trúc chặt chẽ. Từ lõi dữ liệu sạch thống nhất này, các phân nhánh dữ liệu chuyên biệt phục vụ cho các mục đích cụ thể (Data Marts) mới được phân tách và cấu trúc lại.
- **Ưu điểm lý thuyết:** Đảm bảo tính nhất quán dữ liệu tối đa trên toàn hệ thống, triệt tiêu hoàn toàn rủi ro sai lệch số liệu giữa các phòng ban hoặc giữa các tác vụ phân tích khác nhau (như báo cáo trực quan hóa và huấn luyện học máy).

Dưới đây là bảng đối sánh chi tiết giữa hai phương pháp tiếp cận kinh điển của Bill Inmon và Ralph Kimball:

Tiêu chí đối sánh	Tiếp cận Top-Down (Bill Inmon)	Tiếp cận Bottom-Up (Ralph Kimball)
Kiến trúc tổng thể	Tập trung (Centralized DWH) trước, phân tán (Data Marts) sau.	Phân tán (Data Marts) trước, hợp nhất (DWH) sau.
Mô hình hóa tầng lõi	Chuẩn hóa cấu trúc để giảm thiểu tối đa dư thừa dữ liệu (3NF).	Mô hình hóa đa chiều (Dimensional Modeling) dựa trên các bảng Fact và Dimension.
Tính nhất quán	Rất cao, do mọi dữ liệu tiêu thụ đều được kế thừa từ một nguồn lõi duy nhất.	Khó kiểm soát hơn, dễ xảy ra hiện tượng lệch pha định nghĩa giữa các Data Mart độc lập.
Độ linh hoạt hạ tầng	Thích hợp cho hệ thống tích hợp lớn, đa mục đích sử dụng (BI, Data Science, Data Streaming).	Thích hợp cho các dự án cần triển khai nhanh, tập trung giải quyết một quy trình nghiệp vụ đơn lẻ.

Bảng 2.1: Bảng so sánh lý thuyết Inmon vs. Kimball

2.3 Quy trình Trích xuất, Biến đổi và Nạp dữ liệu (ETL Pipeline)

Quy trình ETL (Extract - Transform - Load) đóng vai trò nền tảng trong việc làm sạch và chuẩn hóa dữ liệu trước khi đưa vào kho lưu trữ tập trung.

2.3.1 Lý thuyết về Nội suy dữ liệu khuyết thiếu (Data Imputation)

Dữ liệu chuỗi thời gian từ các thiết bị đo lường vật lý thường gặp hiện tượng mất mát dữ liệu do lỗi truyền thông hoặc hỏng hóc cảm biến. Các phương pháp toán học được áp dụng để khôi phục dữ liệu khuyết bao gồm:

- **Nội suy dựa trên ràng buộc vật lý (Constraint-based Imputation):** Sử dụng các quy luật vật lý tự nhiên để gán giá trị trực tiếp. Đối với năng lượng mặt trời, sản lượng điện tối đa vào ban đêm được gán cứng bằng 0 dựa trên điều kiện bức xạ mặt trời triệt tiêu.
- **Nội suy tuyến tính (Linear Interpolation):** Giả định dữ liệu thay đổi đều giữa các

mốc thời gian lân cận, phù hợp cho các khoảng khuyết ngắn:

$$y = y_1 + \frac{x - x_1}{x_2 - x_1}(y_2 - y_1) \quad (2.1)$$

- **Nội suy Cubic Spline:** Sử dụng các đa thức bậc ba cục bộ để tạo ra đường nội suy mượt mà và bảo toàn đạo hàm cấp một và cấp hai tại các điểm nút. Cho tập hợp các điểm (x_i, y_i) với $i = 0, 1, \dots, n$, hàm nội suy $S(x)$ trên khoảng $[x_i, x_{i+1}]$ được định nghĩa là:

$$S_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3 \quad (2.2)$$

Để đảm bảo tính liên tục của hàm, các hệ số phải thỏa mãn các điều kiện biên và trơn:

$$S_i(x_i) = y_i, \quad S_i(x_{i+1}) = y_{i+1} \quad (2.3)$$

$$S'_i(x_{i+1}) = S'_{i+1}(x_{i+1}) \quad (2.4)$$

$$S''_i(x_{i+1}) = S''_{i+1}(x_{i+1}) \quad (2.5)$$

Với điều kiện biên tự nhiên thông dụng: $S''(x_0) = S''(x_n) = 0$.

- **Nội suy dựa trên mô hình hồi quy (Regression Imputation):** Khôi phục giá trị khuyết thiếu bằng cách ước lượng dựa trên các biến độc lập liên quan. Giả thuyết mô hình tuyến tính có dạng:

$$Y = X\beta + \varepsilon \quad (2.6)$$

Trong đó Y là biến cần nội suy, X là ma trận các biến dự báo quan sát được (các biến khí tượng lân cận, các trễ thời gian). Vectơ hệ số hồi quy $\hat{\beta}$ được ước lượng bằng phương pháp bình phương tối thiểu cực tiểu (OLS) trên tập dữ liệu đầy đủ X_{obs} và Y_{obs} :

$$\hat{\beta} = (X_{\text{obs}}^T X_{\text{obs}})^{-1} X_{\text{obs}}^T Y_{\text{obs}} \quad (2.7)$$

Giá trị khuyết thiếu của bản ghi thứ m sau đó được bù đắp bằng:

$$\hat{y}_m = x_m \hat{\beta} \quad (2.8)$$

2.3.2 Chiến lược nạp dữ liệu tối ưu hóa giao dịch

Khi xử lý các bảng sự kiện có quy mô hàng triệu bản ghi, việc nạp dữ liệu trực tiếp dễ gây tắc nghẽn tài nguyên và khóa bảng cơ sở dữ liệu. Các kỹ thuật toán học và hệ thống được áp dụng bao gồm:

- **Nạp theo phân đoạn (Batching):** Phân chia giao dịch lớn thành các nhóm nhỏ dựa

trên các phân đoạn thời gian (ví dụ: theo tháng) để giảm tải cho nhật ký giao dịch (Transaction Log).

- **Sinh khóa đại diện tự động (Surrogate Key Generation):** Thiết lập cơ chế tạo khóa tự động tăng tiến tuần tự để tối ưu chỉ mục (Index) và tránh trùng lặp dữ liệu trong môi trường phân tán.
- **Kiểm chứng toàn vẹn sau nạp (Post-load Validation):** So sánh tổng kiểm tra bản ghi giữa các tầng lưu trữ nhằm phát hiện lỗi mất mát dữ liệu và kích hoạt cơ chế hoàn tác (Rollback) khi xảy ra sai sót.

2.4 Các phương pháp Phát hiện bất thường dữ liệu (Anomaly Detection)

Phát hiện bất thường dữ liệu nhằm nhận diện các hành vi bất thường của thiết bị hoặc lỗi ghi nhận số liệu.

2.4.1 Phương pháp thống kê Z-Score

Z-Score xác định mức độ lệch của một điểm dữ liệu so với giá trị trung bình theo đơn vị độ lệch chuẩn:

$$Z = \frac{x - \mu}{\sigma} \quad (2.9)$$

Trong đó μ là giá trị trung bình và σ là độ lệch chuẩn của phân phối. Điểm dữ liệu bị coi là ngoại lai (Outlier) nếu nằm ngoài khoảng giới hạn thường gặp (ví dụ: $|Z| > 3$).

2.4.2 Phương pháp khoảng tứ phân vị IQR (Interquartile Range)

IQR là công cụ thống kê mạnh mẽ không phụ thuộc vào giả định phân phối chuẩn của dữ liệu. Khoảng tứ phân vị được xác định bởi:

$$IQR = Q_3 - Q_1 \quad (2.10)$$

Trong đó Q_1 và Q_3 lần lượt là tứ phân vị thứ nhất (25%) và thứ ba (75%). Ngưỡng phát hiện bất thường được thiết lập tại giới hạn:

$$[\text{Lower Bound}, \text{Upper Bound}] = [Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR] \quad (2.11)$$

2.4.3 Phương pháp Trung bình trượt và IQR cục bộ (Rolling IQR)

Đối với chuỗi thời gian có tính xu hướng và mùa vụ mạnh, việc sử dụng các chỉ số thống kê toàn cục dễ dẫn đến kết quả sai lệch. Do đó, phương pháp Rolling IQR cục bộ phân nhóm theo thực thể được áp dụng thông qua thuật toán sau:

1. Cho chuỗi thời gian sản lượng điện $y(s, t)$ của trạm s tại thời điểm t , ta tính trung bình trượt cục bộ trong cửa sổ thời gian W có độ dài 1 giờ:

$$\mu(s, t) = \frac{1}{|W|} \sum_{\tau \in W} y(s, \tau) \quad (2.12)$$

2. Xác định độ lệch tuyệt đối $d(s, t)$ của điểm dữ liệu so với trung bình trượt cục bộ:

$$d(s, t) = |y(s, t) - \mu(s, t)| \quad (2.13)$$

3. Gom nhóm toàn bộ độ lệch $d(s, t)$ theo tổ hợp thực thể trạm s và giờ trong ngày $h = \text{hour}(t) \in [0, 23]$ để tạo ra tập hợp cục bộ $G_{s,h}$.

4. Với mỗi tập hợp $G_{s,h}$, tính toán khoảng tứ phân vị cục bộ:

$$\text{IQR}_{s,h} = Q_3(G_{s,h}) - Q_1(G_{s,h}) \quad (2.14)$$

5. Ngưỡng biên trên bất thường $U_{s,h}$ của nhóm được xác định là:

$$U_{s,h} = Q_3(G_{s,h}) + 1.5 \cdot \text{IQR}_{s,h} \quad (2.15)$$

6. Bản ghi tại thời điểm t thuộc trạm s bị gán cờ ngoại lai nếu hiệu số lệch tuyệt đối vượt quá giới hạn trên cục bộ:

$$f(s, t) = \begin{cases} 1 & \text{nếu } d(s, t) > U_{s,h} \\ 0 & \text{ngược lại} \end{cases} \quad (2.16)$$

2.5 Cơ sở thuật toán Dự báo chuỗi thời gian

- **Mô hình ARIMA:** Mô hình AutoRegressive Integrated Moving Average kết hợp các thành phần tự hồi quy (p), sai phân (d) và trung bình trượt (q):

$$\phi(B)(1 - B)^d X_t = \theta(B)\varepsilon_t \quad (2.17)$$

- **Mô hình Prophet:** Mô hình phân tách chuỗi thời gian do Meta phát triển, xử lý tốt tính mùa vụ mạnh và các giá trị khuyết thiếu:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t \quad (2.18)$$

với $g(t)$ đại diện cho xu hướng, $s(t)$ cho tính mùa vụ, $h(t)$ cho ngày lễ và ε_t cho sai số ngẫu nhiên.

Thu thập Dữ liệu và Thiết kế Kiến trúc Kho dữ liệu

3.1 Kiến trúc Tổng thể Hệ thống Dữ liệu (Data Architecture Overview)

Nhằm đáp ứng đồng thời hai mục tiêu cốt lõi của dự án là (1) Trực quan hóa dữ liệu phục vụ quản trị (Business Intelligence) và (2) Xây dựng mô hình học máy dự báo (Machine Learning), hệ thống dữ liệu của dự án được thiết kế theo kiến trúc đa tầng (Multi-tier Architecture). Luồng dữ liệu (Data Flow) di chuyển qua 4 lớp chính như sau:

1. **Raw Data (Dữ liệu thô):** Dữ liệu lịch sử dạng file .csv từ các trạm vật lý và dữ liệu khí tượng viễn thám trích xuất qua Open-Meteo API.
2. **Staging Area (Vùng dữ liệu tạm):** Nơi tiếp nhận và lưu trữ nguyên bản (1:1) dữ liệu thô vào hệ quản trị CSDL. Lớp này đóng vai trò như một bộ đệm (buffer) để giảm tải cho các nguồn cấp dữ liệu và chuẩn bị cho quá trình chuyển đổi.
3. **Data Warehouse (Kho dữ liệu trung tâm):** Tổ chức theo mô hình *Fact Constellation Schema* (Lược đồ Thiên hà), lưu trữ dữ liệu đã qua làm sạch, chuẩn hóa (Cleansing & Transformation). Đây là Single Source of Truth của toàn bộ hệ thống.
4. **Data Marts (Siêu thị dữ liệu):** Từ Data Warehouse, dữ liệu được phân nhánh thành hai Data Mart độc lập, được thiết kế đặc thù (Tailored-design) để tối ưu hóa hiệu năng truy vấn cho công cụ BI (Tableau) và định dạng chuẩn (Wide-table) cho việc huấn luyện mô hình ML.

3.1.1 Tiếp cận Top-Down (Inmon Approach)

Hệ thống lưu trữ và xử lý dữ liệu của dự án được xây dựng dựa trên phương pháp tiếp cận *Top-Down* (từ trên xuống) theo triết lý thiết kế kho dữ liệu của Bill Inmon. Luồng dữ liệu di chuyển một chiều từ các nguồn thô, tập trung tại một Kho dữ liệu trung tâm duy nhất (Single Source of Truth), sau đó mới phân rã thành các Siêu thị dữ liệu (Data Marts) chuyên biệt.

Việc lựa chọn kiến trúc *Top-Down* thay vì *Bottom-Up* (gồm các Data Mart độc lập lại thành DWH) mang lại ba lợi ích chiến lược cho hệ thống dự báo điện mặt trời của dự án:

- **Đảm bảo tính nhất quán tối đa (Data Consistency):** Vì dữ liệu sản lượng và khí tượng được làm sạch, xử lý Outliers và đồng bộ hóa ngay tại tầng Data Warehouse trung tâm, hai nhánh Data Mart (BI và ML) phía sau sẽ luôn kế thừa cùng một tập dữ liệu chuẩn. Điều này triệt tiêu hoàn toàn hiện tượng lệch pha số liệu (ví dụ: sản lượng tổng hiển thị trên Dashboard Tableau khác với tổng sản lượng mà mô hình Machine Learning nhận được để huấn luyện).
- **Khả năng mở rộng kiến trúc (Scalability):** Trong tương lai, nếu doanh nghiệp muốn mở rộng thêm các mục đích sử dụng dữ liệu mới (ví dụ: nhánh Data Mart dành cho bộ phận Tài chính tính toán doanh thu bán điện FiT, hoặc bộ phận Kiểm toán Carbon), kỹ sư dữ liệu chỉ cần tạo thêm các phân nhánh (Views/Materialized Views) từ Data Warehouse trung tâm mà không cần thiết kế lại luồng ETL/ELT gốc từ các trạm pin.
- **Tối ưu hóa quản trị dữ liệu (Centralized Data Governance):** Việc kiểm soát chất lượng dữ liệu, phân quyền truy cập, và định nghĩa các thuật ngữ nghiệp vụ (Metadata) được thực hiện tập trung tại Supabase DWH, giúp giảm thiểu chi phí vận hành và bảo trì hệ thống.

3.2 Phương pháp thu thập dữ liệu thô (Extract)

Dự án thu thập dữ liệu từ hai nguồn chính:

1. **Dữ liệu giám sát trạm phát điện thực tế:** Ghi nhận sản lượng điện của 42 trạm tại Úc dưới dạng tệp tin CSV cục bộ và các thông tin cấu hình trạm.
2. **Dữ liệu khí tượng viễn thám:** Thu thập từ Open-Meteo API. Quy trình gọi API sử dụng tọa độ địa lý (vĩ độ, kinh độ) của các trạm để tải về chuỗi thời gian khí tượng theo giờ bao gồm bức xạ sóng ngắn, nhiệt độ, lượng mưa và mây che phủ.

3.2.1 Trích xuất dữ liệu khí tượng qua Open-Meteo API

Dữ liệu khí tượng viễn thám được thu thập tự động thông qua Open-Meteo Archive API. Quy trình sử dụng thư viện `requests` và `pandas` để đọc tọa độ (vĩ độ, kinh độ) của 42 trạm phát từ tệp danh mục `Solar_Site_Details.csv`. Các biến số quan trọng như bức xạ sóng ngắn (`shortwave_radiation`), nhiệt độ (`temperature_2m`), mã thời tiết (`weather_code`), và trạng thái ngày/đêm (`is_day`) được trích xuất theo chu kỳ giờ.

Để đảm bảo tính ổn định khi gọi API hàng loạt, mã nguồn được tích hợp cơ chế tự động xử lý lỗi vượt quá giới hạn truy cập (Rate Limit - HTTP 429). Khi máy chủ trả về mã 429, hệ thống sẽ tạm dừng (`time.sleep`) 60 giây trước khi thử lại, giúp luồng trích xuất không bị gián đoạn.

```

1 import requests
2 import pandas as pd
3 import time
4
5 # 1. Khởi tạo cấu hình tham số API
6 START_DATE = "2023-01-01"
7 END_DATE = "2023-12-31"
8 FINAL_OUTPUT_FILE = "open_meteo_weather_raw_2023.csv"
9
10 HOURLY_COLUMNS = [
11     "shortwave_radiation", "direct_radiation",
12     "diffuse_radiation", "temperature_2m",
13     "weather_code", "is_day", "cloud_cover",
14     "wind_speed_10m", "precipitation", "sunshine_duration"
15 ]
16
17 # Đọc tọa độ từ danh mục trạm
18 site_df = pd.read_csv('/content/Solar_Site_Details(1).csv')
19 url = "https://archive-api.open-meteo.com/v1/archive"
20 all_data_frames = []
21
22 # 2. Vòng lặp lấy dữ liệu và xử lý Rate Limit
23 for index, row in site_df.iterrows():
24     params = {
25         "latitude": row['lat'],
26         "longitude": row['Lon'],
27         "start_date": START_DATE,
28         "end_date": END_DATE,
29         "hourly": ",".join(HOURLY_COLUMNS),
30         "timezone": "Asia/Ho_Chi_Minh"
31     }
32
33     success = False
34     while not success:
35         try:
36             response = requests.get(
37                 url,

```



```

38         params=params,
39         timeout=120)
40
41     if response.status_code == 200:
42         data = response.json()
43         if "hourly" in data:
44             df_site = pd.DataFrame(
45                 {"timestamp": data["hourly"]["time"]}
46             )
47             for col in HOURLY_COLUMNS:
48                 df_site[col] = data["hourly"].get(col)
49
50             df_site["SiteKey"] = row.get('SiteKey', index)
51             all_data_frames.append(df_site)
52             success = True
53
54         elif response.status_code == 429:
55             print("Rate limited. Waiting 60s...")
56             time.sleep(60)
57
58         else:
59             success = True # Bo qua neu loi dinh dang khac
60
61     except Exception as e:
62         time.sleep(5)
63         success = True
64
65 # Xuat tep du lieu tong hop
66 if all_data_frames:
67     final_df = pd.concat(all_data_frames, ignore_index=True)
68     final_df['timestamp'] = pd.to_datetime(final_df['timestamp'])
69     final_df.to_csv(FINAL_OUTPUT_FILE, index=False)

```

3.2.2 Thiết lập kết nối cơ sở dữ liệu Supabase

Để lưu trữ và xử lý tập dữ liệu sau khi trích xuất, dự án cấu hình hệ quản trị cơ sở dữ liệu PostgreSQL trên nền tảng Supabase (Khu vực Southeast Asia). Điểm đặc thù trong kiến trúc kết nối và nạp (Load) dữ liệu của nhóm:

- **Sử dụng Connection Pooler:** Do Supabase free tier không hỗ trợ kết nối trực tiếp qua IPv4, dự án cấu hình kết nối thông qua Supabase Pooler (host `aws-1-ap-southeast-1.pooler.supabase.com`, cổng 5432). Giao thức này hỗ trợ IPv4 ổn định cho môi trường làm việc nhóm, đồng thời quản lý và tái sử dụng

các phiên kết nối để tránh tình trạng quá tải (Connection Overload).

- **Tối ưu hóa Thư viện kết nối (pg8000):** Thay vì sử dụng thư viện psycopg2 truyền thống, dự án chuyển sang sử dụng pg8000. Đây là thư viện Pure Python, giúp khắc phục triệt để lỗi thiếu hụt các thư viện hệ thống (libz.so.1, libstdc++.so.6) trên môi trường NixOS, đảm bảo mã nguồn có thể chạy mượt mà trên mọi hệ điều hành.
- **Bảo mật hệ thống:** Toàn bộ thông tin nhạy cảm bao gồm Mật khẩu cơ sở dữ liệu và Project ID được mã hóa và truyền qua tệp .env thay vì khai báo trực tiếp trong mã nguồn. Mã nguồn nạp dữ liệu vào kho được xử lý cách ly, cam kết không rò rỉ (commit) mật khẩu lên nền tảng GitHub.

Bộ dữ liệu thô được lưu trữ thành các tệp tin CSV: campus_meta.csv, Solar_Site_Details.csv, calender.csv, Solar_Energy_Generation.csv, và open_meteo_weather_raw_2023.csv.

3.3 Data Dictionary & Metadata

Sau quá trình trích xuất và thu thập, bộ dữ liệu thô được cô đọng lại thành 5 tệp tin cốt lõi (Core Datasets). Việc xây dựng từ điển dữ liệu (Data Dictionary) ở giai đoạn này giúp định nghĩa rõ ràng cấu trúc, kiểu dữ liệu và ý nghĩa của từng trường thông tin gốc trước khi thực hiện các bước biến đổi (Transform) và đưa vào Kho dữ liệu.

3.3.1 Dữ liệu Thông tin Cơ sở hạ tầng (campus_meta.csv)

Tệp lưu trữ thông tin định danh cấp cao nhất về các khu vực/cơ sở dự án. Quy mô: 5 dòng.

Bảng 3.1: Từ điển dữ liệu tệp campus_meta.csv

Tên trường	Kiểu DL	Đơn vị	Ý nghĩa & Mô tả kỹ thuật
id	Integer	-	Mã định danh duy nhất (Primary Key) cho từng cơ sở.
name	VARCHAR	-	Tên gọi chính thức của cơ sở (VD: Bundoora, Bendigo...).
capacity	Integer	kW	Sức chứa, quy mô hoạt động hoặc mức công suất thiết kế.

3.3.2 Dữ liệu Thông tin Kỹ thuật Trạm (Solar_Site_Details.csv)

Tập lưu trữ chi tiết cấu hình kỹ thuật, thiết bị lắp đặt và tọa độ địa lý của các trạm phát điện. Quy mô: 42 dòng.

Bảng 3.2: Từ điển dữ liệu tập Solar_Site_Details.csv

Tên trường	Kiểu DL	Đơn vị	Ý nghĩa & Mô tả kỹ thuật
CampusKey	Integer	-	Mã định danh cơ sở nơi đặt trạm điện.
SiteKey	Integer	-	Mã định danh duy nhất của từng trạm phát điện.
kWp	Float	kWp	Công suất đỉnh tối đa của hệ thống.
Number of panels	Float	Tấm	Tổng số lượng tấm pin mặt trời được lắp đặt.
Panel	String	-	Thương hiệu và công suất định mức của tấm pin.
Inverter	String	-	Thông tin bộ biến đổi dòng điện (Inverter).
Optimizers	String	-	Thông tin bộ tối ưu hóa công suất đi kèm.
Metric	String	-	Đơn vị đo lường sản lượng điện năng.
lat	Float	Độ (°)	Vĩ độ địa lý (Latitude).
Lon	Float	Độ (°)	Kinh độ địa lý (Longitude).

3.3.3 Dữ liệu Sản lượng Điện (Solar_Energy_Generation.csv)

Bảng dữ liệu chuỗi thời gian (Fact Table) chứa sản lượng phát điện thực tế được ghi nhận liên tục theo chu kỳ 15 phút. Quy mô: 2.731.947 dòng.

Bảng 3.3: Từ điển dữ liệu tập Solar_Energy_Generation.csv

Tên trường	Kiểu DL	Đơn vị	Ý nghĩa & Mô tả kỹ thuật
CampusKey	Integer	-	Mã định danh cơ sở liên kết.
SiteKey	Integer	-	Mã định danh trạm phát điện mặt trời cụ thể.
Timestamp	DateTime	-	Mốc thời gian đo đạc dữ liệu sản lượng (Chu kỳ 15 phút).
SolarGeneration	Float	kWh	Sản lượng điện năng thực tế tạo ra trong khoảng 15 phút đó.

3.3.4 Dữ liệu Thông tin Lịch trình (calender.csv)

Bảng dữ liệu đánh dấu các sự kiện thời gian theo cấp độ ngày, giúp phân tích các yếu tố hành vi ảnh hưởng đến nhu cầu tiêu thụ và vận hành. Quy mô: 2.313 dòng.

Bảng 3.4: Tờ điển dữ liệu tệp calender.csv

Tên trường	Kiểu DL	Đơn vị	Ý nghĩa & Mô tả kỹ thuật
date	Date	-	Mốc thời gian theo ngày (định dạng DD/MM/YYYY).
is_holiday	Boolean	-	Cờ đánh dấu ngày nghỉ lễ (1: Lễ, 0: Ngày thường).
is_semester	Boolean	-	Cờ đánh dấu ngày nằm trong giai đoạn học kỳ chính thức.
is_exam	Boolean	-	Cờ đánh dấu ngày diễn ra kỳ thi tại cơ sở.

3.3.5 Dữ liệu Khí tượng Viễn thám (open_meteo_weather_raw.csv)

Chuỗi thời gian chứa các chỉ số khí tượng được trích xuất qua API tương ứng với tọa độ từng trạm phát. Quy mô: 367.920 dòng.

Bảng 3.5: Tờ điển dữ liệu tệp open_meteo_weather_raw.csv

Tên trường	Kiểu DL	Đơn vị	Ý nghĩa & Mô tả kỹ thuật
shortwave_radiation	Float	W/m ²	Tổng bức xạ sóng ngắn bề mặt. Feature có tương quan cao nhất với sản lượng điện.
direct_radiation	Float	W/m ²	Bức xạ mặt trời chiếu trực tiếp tới bề mặt.
diffuse_radiation	Float	W/m ²	Bức xạ mặt trời bị khuếch tán (do mây, bụi, sương mù).
temperature_2m	Float	°C	Nhiệt độ không khí ở độ cao 2 mét. Phục vụ đánh giá suy giảm nhiệt.
weather_code	Integer	-	Mã thời tiết theo chuẩn WMO (0: Quang đăng, 51-67: Mưa...). Phân loại Categorical tốt cho ML.


3.4 Thiết kế kiến trúc Kho dữ liệu đa chiều (Data Warehouse)

Quá trình thiết kế kho dữ liệu (Data Warehouse - DWH) được thực hiện theo phương pháp từ trên xuống (Top-down) kết hợp mô hình đa chiều của Kimball. Nhằm giải quyết bài toán dữ liệu lớn và độ lệch pha thời gian (Granularity Mismatch) giữa dữ liệu sản lượng (15 phút) và dữ liệu khí tượng (1 giờ), hệ thống được thiết kế theo cấu trúc **Lược đồ Thiên hà (Galaxy Schema / Fact Constellation)**. Quá trình này bao gồm 3 cấp độ mô hình hóa: Conceptual, Logical, và Physical.

3.4.1 Mô hình Dữ liệu Khái niệm (Conceptual Data Model)

Ở mức khái niệm, hệ thống xác định các thực thể kinh doanh cốt lõi và mối quan hệ giữa chúng mà không đi sâu vào chi tiết kỹ thuật. Mô hình khái niệm của hệ thống được phân rã thành các thực thể (như minh họa tại Hình 3.1):

- **Thực thể trung tâm (Đo lường năng lượng):** Là nơi hội tụ các chỉ số đo lường hiệu suất.
- **Các thực thể ngữ cảnh (Nguyên nhân/Điều kiện):** Bao gồm *Trạm năng lượng (Solar site)*, *Vị trí địa lý*, *Ngày (Date)* và *Thời tiết*.



Hình 3.1: Sơ đồ Mô hình Dữ liệu Khái niệm (Conceptual Data Model)

Mối quan hệ cốt lõi: Vị trí địa lý, Thời tiết và Ngày có quan hệ 1-M (one-many) với Đo lường năng lượng, giúp ban quản lý hiểu rõ dữ liệu sản lượng và thời tiết dưới góc nhìn

không gian và thời gian.

3.4.2 Mô hình Dữ liệu Logic (Logical Data Model)


Mô hình logic cụ thể hóa các thực thể thành các bảng và xác định các thuộc tính (attributes), khóa chính (Primary Key), khóa ngoại (Foreign Key). Dựa trên thiết kế kiến trúc (xem Hình 3.2), hệ thống gồm 5 bảng chiều và 2 bảng sự kiện:

1. Các bảng chiều dùng chung (Conformed Dimensions):

- **dim_solar_site**: Khóa chính `site_id`. Lưu thông tin thiết bị: `campus_name`, `capacity_kw`, `Number_of_panels`, `Panel`, `Inverter`, `Optimizers`, `Metric`.
- **dim_geography**: Khóa chính `geo_id`. Định vị không gian: `latitude`, `longitude`, `location_name`.
- **dim_date**: Khóa chính `date_id`. Trục ngày: `full_date`, `day`, `month`, `year`.
- **dim_time**: Khóa chính `time_id`. Trục giờ chi tiết (chu kỳ 15p): `time_string`, `hour`, `minute`.
- **dim_weather_type**: Khóa chính `weather_type_id`. Phân loại trạng thái: `weather_code`, `is_day`, `weather_condition`, `description`.

2. Các bảng sự kiện (Fact Tables):


- **fact_solar_energy_gen**: Khóa chính `gen_id`. Kết nối với Site, Geo, Date, Time. Đo lường sản lượng `energy_generated_kwh`.
- **fact_weather**: Khóa chính `weather_id`. Kết nối với Geo, Date, Time, Weather_type. Chứa các chỉ số viễn thám như `shortwave_radiation`, `temperature_c`, `cloud_cover_tot`, `wind_speed`, `precipitation_mm`.



Hình 3.2: Sơ đồ Mô hình Dữ liệu Logic (Logical Data Model)

3.4.3 Mô hình Dữ liệu Vật lý (Physical Data Model)

Mô hình vật lý định nghĩa cách thức dữ liệu được lưu trữ thực tế trên hệ quản trị cơ sở dữ liệu (sơ đồ ở Hình 3.3). Ở bước này, các kiểu dữ liệu (Data Types) cụ thể (INT, FLOAT, VARCHAR, DATE) và ràng buộc khóa ngoại (Foreign Keys) được thiết lập để tối ưu hóa không gian lưu trữ và tốc độ truy vấn. Chi tiết cấu trúc vật lý của các bảng chiều được mô tả từ Bảng 3.6 đến Bảng 3.10. Các bảng sự kiện sản lượng và thời tiết được mô tả tương ứng trong Bảng 3.11 và Bảng 3.12.



Hình 3.3: Sơ đồ Mô hình Dữ liệu Vật lý (Physical Data Model)

Bảng 3.6: Cấu trúc vật lý bảng chiều trạm năng lượng (dim_solar_site)

Tên trường (Field)	Kiểu DL	Diễn giải vật lý
site_id	INT (PK)	Khóa chính của trạm.
campus_name	VARCHAR	Tên khu vực đặt trạm dưới dạng chuỗi ký tự.
capacity_kw	FLOAT	Công suất thiết kế (số thực).
Number_of_panels	INT	Tổng số lượng tấm pin (số nguyên).
Panel	VARCHAR	Thương hiệu/loại tấm pin (chuỗi ký tự).
Inverter	VARCHAR	Thông tin bộ biến đổi điện (chuỗi ký tự).
Optimizers	VARCHAR	Bộ tối ưu hóa (chuỗi ký tự).
Metric	VARCHAR	Ghi chú/tiêu chuẩn đo lường (chuỗi ký tự).

Bảng 3.7: Cấu trúc vật lý bảng chiều địa lý (dim_geography)

Tên trường (Field)	Kiểu DL	Diễn giải vật lý
geo_id	INT (PK)	Khóa chính định danh vị trí địa lý.
latitude	FLOAT	Vĩ độ (số thực).
longitude	FLOAT	Kinh độ (số thực).
location_name	VARCHAR	Tên địa danh hành chính.
capacity	INT	Tổng công suất của khu vực đặt trạm (kW).

Bảng 3.8: Cấu trúc vật lý bảng chiều ngày (dim_date)

Tên trường (Field)	Kiểu DL	Diễn giải vật lý
date_id	INT (PK)	Khóa chính đại diện ngày.
full_date	DATE	Trường lưu định dạng thời gian nguyên bản (YYYY-MM-DD).
day	INT	Ngày trong tháng (số nguyên).
month	INT	Tháng trong năm (số nguyên).
year	INT	Năm phân tích (số nguyên).
is_holiday	INT	Đánh dấu ngày lễ (1: Ngày lễ, 0: Ngày thường).
is_semester	INT	Đánh dấu học kỳ (1: Trong kỳ học, 0: Kỳ nghỉ).
is_exam	INT	Đánh dấu mùa thi (1: Trong mùa thi, 0: Bình thường).

Bảng 3.9: Cấu trúc vật lý bảng chiều thời gian (dim_time)

Tên trường (Field)	Kiểu DL	Diễn giải vật lý
time_id	INT (PK)	Khóa chính mốc thời gian.
time_string	VARCHAR	Chuỗi ký tự biểu diễn giờ (HH:MM).
hour	INT	Giờ trong ngày (số nguyên).
minute	INT	Phút (số nguyên).

Bảng 3.10: Cấu trúc vật lý bảng chiều danh mục thời tiết (dim_weather_type)

Tên trường (Field)	Kiểu DL	Diễn giải vật lý
weather_type_id	INT (PK)	Khóa chính danh mục thời tiết.
weather_code	INT	Mã trạng thái WMO (số nguyên).
is_day	INT	Trạng thái ánh sáng (1: Ngày, 0: Đêm) lưu dạng số nguyên.
weather_condition	VARCHAR	Tên điều kiện thời tiết tổng quát.
description	VARCHAR	Chuỗi văn bản mô tả chi tiết diễn biến thời tiết.

Bảng 3.11: Cấu trúc vật lý bảng sự kiện sản lượng (fact_solar_energy_gen)

Tên trường (Field)	Kiểu DL	Diễn giải mục đích vật lý
gen_id	INT	Khóa chính định danh từng dòng sự kiện (Auto-increment).
site_id	INT	Khóa ngoại trỏ đến dim_solar_site.site_id.
geo_id	INT	Khóa ngoại trỏ đến dim_geography.geo_id.
date_id	INT	Khóa ngoại trỏ đến dim_date.date_id.
time_id	INT	Khóa ngoại trỏ đến dim_time.time_id.
energy_generated_kwh	FLOAT	Sản lượng điện năng sinh ra (kiểu số thực để tính toán độ chính xác cao).
rolling_outlier_flag	BOOLEAN	Cờ đánh dấu dòng dữ liệu sản lượng là ngoại lai (phát hiện bằng Rolling IQR).

Bảng 3.12: Cấu trúc vật lý bảng sự kiện thời tiết (fact_weather)

Tên trường (Field)	Kiểu DL	Diễn giải mục đích vật lý
weather_id	INT	Khóa chính định danh dòng lịch sử thời tiết.
geo_id	INT	Khóa ngoại trở đến dim_geography.geo_id.
date_id	INT	Khóa ngoại trở đến dim_date.date_id.
time_id	INT	Khóa ngoại trở đến dim_time.time_id.
weather_type_id	INT	Khóa ngoại trở đến dim_weather_type.weather_type_id.
is_day	INT	Chỉ số phân tách chu kỳ ánh sáng (số nguyên: 1/0).
shortwave_radiation	INT	Bức xạ sóng ngắn (số nguyên).
temperature_c	FLOAT	Nhiệt độ không khí (số thực).
cloud_cover_total	FLOAT	Tổng độ che phủ mây (số thực, tỷ lệ %).
cloud_cover_low	FLOAT	Tỷ lệ mây tầng thấp (số thực).
cloud_cover_mid	FLOAT	Tỷ lệ mây tầng trung (số thực).
cloud_cover_high	FLOAT	Tỷ lệ mây tầng cao (số thực).
Diffuse_Solar_Radiation	INT	Ánh sáng tán xạ (số nguyên).
Direct_Normal_Irradiance	INT	Bức xạ chiếu thẳng (số nguyên).
wind_speed	FLOAT	Tốc độ gió (số thực).
precipitation_mm	FLOAT	Tổng lượng mưa tích tụ (số thực).
Sunshine_Duration	FLOAT	Thời lượng nắng (số thực).

3.4.4 Kịch bản SQL Khởi tạo Cơ sở Dữ liệu

Để triển khai thiết kế vật lý lên hệ quản trị cơ sở dữ liệu Supabase PostgreSQL, dự án sử dụng các kịch bản SQL khởi tạo tự động. Các kịch bản này phân tách rõ rệt cấu trúc giữa tầng đệm (Staging Area) và tầng kho dữ liệu chính thức (Data Warehouse).

Kịch bản khởi tạo lớp đệm Staging (Schema Staging)

Các bảng trích xuất thô (stg_*) được thiết kế với kiểu dữ liệu chuỗi linh hoạt (VARCHAR) nhằm hạn chế tối đa lỗi gián đoạn tiến trình trích xuất (Extract) khi nguồn cấp thay đổi định dạng dữ liệu đột ngột. Kịch bản dưới đây thực hiện tạo lập cấu trúc các bảng đệm thô và các bảng đệm đã chuyển kiểu trong schema staging:

```

1  -- 1. Khởi tạo Schema staging
2  CREATE SCHEMA IF NOT EXISTS staging;
3  -- 2. Bảng Staging thô chưa san lượng diện
4  CREATE TABLE staging.stg_solar_energy_generation (
5      CampusKey VARCHAR(255),
6      SiteKey VARCHAR(255),
7      Timestamp VARCHAR(255),
8      SolarGeneration VARCHAR(255)
9  );
10
11 -- 3. Bảng đệm chuyển kiểu fact_solar_energy_gen trong staging
12 CREATE TABLE staging.fact_solar_energy_gen (
13     SiteKey VARCHAR(255),
14     timestamp TIMESTAMP,
15     energy_generated_kwh FLOAT,
16     rolling_outlier_flag BOOLEAN DEFAULT false
17 );
18
19 -- 4. Bảng đệm chuyển kiểu dim_date trong staging
20 CREATE TABLE staging.dim_date (
21     full_date DATE,
22     day INT,
23     month INT,
24     year INT,
25     is_holiday VARCHAR(50),
26     is_semester VARCHAR(50),
27     is_exam VARCHAR(50)
28 );

```

Kịch bản khởi tạo tầng Data Warehouse (Public Schema)

Tầng Data Warehouse chính thức được cấu hình các ràng buộc toàn vẹn cơ sở dữ liệu chặt chẽ bao gồm khóa chính, khóa ngoại liên kết giữa bảng sự kiện và bảng chiều, đảm bảo không tồn tại dữ liệu mờ côi:

```

1  -- 1. Khởi tạo bảng chiều dim_date
2  CREATE TABLE dim_date (
3      date_id INT PRIMARY KEY,
4      full_date DATE,
5      day INT,
6      month INT,
7      year INT,
8      is_holiday INT,
9      is_semester INT,
10     is_exam INT
11 );
12
13 -- 2. Khởi tạo bảng sự kiện sản lượng điện fact_solar_energy_gen
14 CREATE TABLE fact_solar_energy_gen (
15     gen_id INT PRIMARY KEY,
16     site_id INT,
17     geo_id INT,
18     date_id INT,
19     time_id INT,
20     energy_generated_kwh FLOAT,
21     rolling_outlier_flag BOOLEAN DEFAULT false,
22
23     -- Thiết lập các ràng buộc khóa ngoại
24     CONSTRAINT FK_Gen_Site FOREIGN KEY (site_id) REFERENCES
dim_solar_site(site_id),
25     CONSTRAINT FK_Gen_Geo FOREIGN KEY (geo_id) REFERENCES
dim_geography(geo_id),
26     CONSTRAINT FK_Gen_Date FOREIGN KEY (date_id) REFERENCES
dim_date(date_id),
27     CONSTRAINT FK_Gen_Time FOREIGN KEY (time_id) REFERENCES
dim_time(time_id)
28 );

```

3.5 Kiểm tra tính toàn vẹn và bảo mật dữ liệu

Để đảm bảo tính toàn vẹn dữ liệu (Data Integrity) trong CSDL vật lý, các ràng buộc tham chiếu (Referential Constraints) được cấu hình nghiêm ngặt theo quan hệ Một - Nhiều (1-M). Mọi bản ghi trong các bảng Fact bắt buộc phải có khóa tham chiếu tồn tại trong các bảng Dimension tương ứng, ngăn chặn tuyệt đối tình trạng dữ liệu mồ côi (orphan records) khi thực hiện luồng ETL.

Quy trình ETL và Chuẩn hóa Dữ liệu

4.1 Tổng quan Kiến trúc Pipeline Xử lý Dữ liệu

Để xây dựng một hệ thống phân tích dữ liệu sản lượng điện mặt trời ổn định và tin cậy, dự án thiết lập quy trình trích xuất, biến đổi và nạp dữ liệu (ETL Pipeline) tự động hóa bằng ngôn ngữ Python. Luồng di chuyển dữ liệu (Data Flow) được chia làm 3 tầng lõi rõ rệt nhằm đáp ứng triết lý thiết kế kho dữ liệu tập trung (Top-Down Approach):

1. **Tầng Trích xuất (Extract):** Dữ liệu lịch sử từ các tệp tin CSV vật lý ghi nhận tại trạm pin và dữ liệu khí tượng viễn thám từ Open-Meteo API được thu thập và lưu trữ tập trung tại thùng chứa (Bucket) raw-data của hệ thống lưu trữ đối tượng MinIO S3. Các tệp tin cốt lõi bao gồm `campus_meta.csv`, `Solar_Site_Details.csv`, `calender.csv`, `Solar_Energy_Generation.csv`, và `open_meteo_weather_raw_2020_2022.csv`.
2. **Tầng Biến đổi (Transform):** Sử dụng các thư viện tính toán hiệu năng cao như `pandas`, `numpy`, và `scikit-learn` để thực hiện chuẩn hóa kiểu dữ liệu thời gian, điền khuyết thiếu bằng chiến lược lai (Hybrid Imputation), gán cờ ngoại lai thông qua phân tích biến động trung bình trượt cục bộ, và đồng bộ granularity thời gian.
3. **Tầng Nạp (Load):** Dữ liệu sau biến đổi được đẩy vào hệ quản trị cơ sở dữ liệu Supabase PostgreSQL thông qua hai schema chuyên biệt: `staging` (bộ đệm trung gian) và `datawarehouse` (kho dữ liệu chuẩn hóa đa chiều phục vụ BI và ML).

Để khắc phục các hạn chế về môi trường triển khai thực tế, mã nguồn ETL của dự án tích hợp hai giải pháp hệ thống quan trọng:

- **Sử dụng Thư viện kết nối thuần Python (pg8000):** Khác với thư viện `psycopg2` vốn yêu cầu biên dịch các thư viện hệ thống nhị phân C (dễ gây lỗi thiếu `libz.so.1` hoặc `libstdc++.so.6` trên môi trường ảo hóa NixOS), thư viện `pg8000` hoạt động hoàn toàn độc lập, đảm bảo tính di động cao của mã nguồn.
- **Cấu hình Connection Pooler thông qua IPv4:** Do Supabase chỉ hỗ trợ truy cập IPv6 trực tiếp cho gói tài khoản miễn phí, dự án cấu hình Pooler trung gian của Supabase tại cổng 5432 để duy trì kết nối IPv4 ổn định cho toàn bộ thành viên nhóm, đồng thời giảm tải luồng kết nối đồng thời lên máy chủ.

Dưới đây là mã nguồn cấu hình kết nối tối ưu hóa bằng thư viện pg8000:

```

1 def connect_pg8000() -> any:
2     import pg8000.dbapi
3     load_dotenv(ENV_FILE)
4     required = ["DB_HOST", "DB_PORT", "DB_NAME", "DB_USER", "
5     DB_PASSWORD"]
6     missing = [name for name in required if not os.getenv(name)]
7     if missing:
8         raise RuntimeError(f"Missing env vars in {ENV_FILE}: {'',
9         '.join(missing)}")
10
11     return pg8000.dbapi.connect(
12         host=os.environ["DB_HOST"],
13         port=int(os.environ.get("DB_PORT", "5432")),
14         database=os.environ["DB_NAME"],
15         user=os.environ["DB_USER"],
16         password=os.environ["DB_PASSWORD"],
17         ssl_context=True,
18     )

```

4.1.1 Thiết lập Tiên trình Nạp Dữ liệu Thứ tự

Để bảo toàn tính toàn vẹn tham chiếu khóa ngoại (Foreign Key Constraints), tiến trình tải dữ liệu vào kho được kiểm soát nghiêm ngặt theo thứ tự phụ thuộc. File `load_01_dims.py` chịu trách nhiệm tẩy trống dữ liệu cũ bằng lệnh `TRUNCATE CASCADE` và tải lại các bảng chiều độc lập theo trình tự tuyến tính:

`dim_geography` → `dim_solar_site` → `dim_date` → `dim_time` → `dim_weather_type`

Ngay sau khi các bảng chiều được nạp thành công, tệp tin `load_02_facts.py` tiến hành đọc các bảng sự kiện quy mô lớn từ MinIO và ánh xạ các khóa tự nhiên sang khóa đại diện (Surrogate Keys) bằng các bộ từ điển tra cứu (Lookups) đã lưu trong bộ nhớ tạm (In-memory dicts). Để tránh hiện tượng nghẽn bộ nhớ đệm (RAM Out-Of-Memory) khi xử lý tập dữ liệu sản lượng hơn 2,7 triệu dòng, luồng nạp sử dụng cơ chế chia nhỏ dữ liệu thành từng khối (`chunks` = 50.000 dòng) và thực thi lệnh chèn hàng loạt `execute_values` tối ưu hóa hiệu năng IO.

4.1.2 Cơ chế Quản lý Giao dịch và An toàn Dữ liệu

Toàn bộ tiến trình nạp được bọc trong một khối giao dịch cơ sở dữ liệu duy nhất (Explicit DB Transaction). Chế độ tự động xác nhận (autocommit) được tắt hoàn toàn.

- Nếu xuất hiện bất kỳ lỗi hệ thống hoặc vi phạm ràng buộc dữ liệu nào (ví dụ: khóa ngoại không tồn tại), lệnh `conn.rollback()` sẽ lập tức hoàn tác mọi thay đổi để đưa kho dữ liệu về trạng thái an toàn trước đó.
- Chỉ khi toàn bộ dữ liệu của phân đoạn được ghi thành công không lỗi, lệnh `conn.commit()` mới được phát ra để ghi nhận vĩnh viễn các thay đổi vào đĩa cứng.

4.2 Đánh giá Chất lượng và Khám phá Dữ liệu (EDA ban đầu)

Trước khi thực hiện các phép toán làm sạch, nhóm tiến hành một bước hồ sơ hóa dữ liệu (Data Profiling) nhằm phát hiện các vấn đề về chất lượng dữ liệu thô. Tiến trình này được tự động hóa thông qua kịch bản `data_integrity_and_reconciliation_check.py`.

Công cụ thực hiện quét toàn bộ các bảng trong schema `staging` để thống kê: (1) Tổng số dòng dữ liệu hiện có, (2) Số lượng bản ghi bị khuyết thiếu khóa chính (NULL PK), và (3) Số lượng bản ghi bị trùng lặp khóa tự nhiên (Duplicate PKs).

Bảng 4.1: Bảng thống kê kiểm tra chất lượng dữ liệu ban đầu trong Staging

Tên bảng dữ liệu	Tổng số dòng	Số dòng trùng lặp	Số dòng khuyết PK	Trạng thái
<code>dim_geography</code>	5	0	0	OK
<code>dim_solar_site</code>	42	0	0	OK
<code>dim_date</code>	2.312	0	0	OK
<code>dim_time</code>	96	0	0	OK
<code>dim_weather_type</code>	22	0	0	OK
<code>fact_weather</code>	367.920	0	0	OK
<code>fact_solar_energy_gen</code>	2.731.946	0	0	OK

Kết quả phân tích ban đầu cho thấy cấu trúc khung của các bảng chiều và bảng thời tiết rất sạch, không xuất hiện hiện tượng trùng lặp dòng. Tuy nhiên, bảng sự kiện sản lượng thô `fact_solar_energy_gen` chứa tới 107.452 ô dữ liệu bị khuyết giá trị sản lượng

(SolarGeneration mang giá trị NaN), chiếm khoảng 3,93% tổng số quan trắc đo đạc của cả năm. Đây là đối tượng trọng tâm cần xử lý tại tầng làm sạch dữ liệu.

4.2.1 Các Cột Thực Tế và Ánh Xạ Dữ Liệu Trong Pipeline

Trong giai đoạn nạp dữ liệu từ các tệp thô vào bảng đệm (Staging layer), hệ thống thực hiện chuyển đổi kiểu dữ liệu (casting) và đổi tên trường để phù hợp với định dạng kho dữ liệu. Chi tiết các trường thông tin thực tế được ánh xạ từ tệp thô lên bảng sự kiện được thống kê dưới đây:

Cấu trúc ánh xạ bảng sự kiện sản lượng (fact_solar_energy_gen)

Bảng này ghi nhận sản lượng điện thực tế theo chu kỳ 15 phút của từng trạm phát:

- **sitekey** (Ánh xạ từ cột SiteKey trong tệp thô, định dạng chuỗi chuyển sang VARCHAR hoặc INT): Mã định danh duy nhất của từng trạm phát.
- **timestamp** (Ánh xạ từ cột Timestamp dạng text thô, xử lý chuyển đổi định dạng YYYY-MM-DD HH24:MI:SS sang kiểu dữ liệu TIMESTAMP chuẩn): Mốc thời gian quan trắc sản lượng.
- **energy_generated_kwh** (Ánh xạ từ cột SolarGeneration thô, làm sạch ký tự lạ và chuyển đổi thành DOUBLE PRECISION hoặc FLOAT): Sản lượng điện mặt trời thực tế thu được trong 15 phút (đơn vị kWh).

Cấu trúc ánh xạ bảng sự kiện thời tiết (fact_weather)

Bảng này tích hợp các chỉ số thời tiết theo chu kỳ chẵn giờ từ Open-Meteo API ứng với tọa độ trạm phát:

- **sitekey** (Ánh xạ từ SiteKey): Khóa liên kết trạm phát điện.
- **timestamp** (Ánh xạ từ timestamp thô, chuyển sang kiểu TIMESTAMP): Mốc thời gian chẵn giờ của dữ liệu khí tượng.
- **weather_code** (Ánh xạ từ weather_code, chuyển kiểu INT): Mã trạng thái thời tiết chuẩn WMO.
- **is_day** (Ánh xạ từ is_day, kiểu INT): Cờ phân tách trạng thái ngày/đêm (1: Ngày, 0: Đêm).

- `shortwave_radiation` (Ánh xạ từ `shortwave_radiation`, kiểu `NUMERIC`): Tổng bức xạ sóng ngắn mặt trời bề mặt (W/m^2).
- `temperature_c` (Ánh xạ từ `temperature_2m`, kiểu `NUMERIC`): Nhiệt độ không khí ở độ cao 2 mét ($^{\circ}\text{C}$).
- `cloud_cover_total` (Ánh xạ từ `cloud_cover`, kiểu `NUMERIC`): Tỷ lệ che phủ mây tổng thể (%).
- `cloud_cover_low` (Ánh xạ từ `cloud_cover_low`, kiểu `NUMERIC`): Tỷ lệ mây tầng thấp (%).
- `cloud_cover_mid` (Ánh xạ từ `cloud_cover_mid`, kiểu `NUMERIC`): Tỷ lệ mây tầng trung (%).
- `cloud_cover_high` (Ánh xạ từ `cloud_cover_high`, kiểu `NUMERIC`): Tỷ lệ mây tầng cao (%).
- `diffuse_solar_radiation` (Ánh xạ từ `diffuse_radiation`, kiểu `NUMERIC`): Bức xạ mặt trời khuếch tán (W/m^2).
- `direct_normal_irradiance` (Ánh xạ từ `direct_radiation`, kiểu `NUMERIC`): Bức xạ mặt trời trực tiếp bề mặt (W/m^2).
- `wind_speed` (Ánh xạ từ `wind_speed_10m`, kiểu `NUMERIC`): Tốc độ gió ở độ cao 10 mét (m/s).
- `precipitation_mm` (Ánh xạ từ `precipitation`, kiểu `NUMERIC`): Tổng lượng mưa tích tụ trong giờ (mm).
- `sunshine_duration` (Ánh xạ từ `sunshine_duration`, kiểu `NUMERIC`): Thời lượng nắng thực tế (giây).

4.3 Làm sạch và Chuẩn hóa Dữ liệu (Data Cleaning)

4.3.1 Xử lý Dữ liệu Khuyết thiếu và Lỗi Logic

Để phục hồi dữ liệu khuyết thiếu cho trường sản lượng phát điện (`energy_generated_kwh`), dự án áp dụng chiến lược nội suy lai nghiêm ngặt (Hybrid Imputation Strategy) tích hợp giữa các bộ quy tắc nghiệp vụ vật lý và mô hình học máy trong file `solar_data_pipeline.py`. Tiến trình xử lý gồm hai giai đoạn chính:

Giai đoạn 1: Lọc vật lý ban đêm (Rule-Based Night Zeroing)

Đối với các trạm phát điện mặt trời quang điện, sản lượng điện năng luôn bằng 0 vào ban đêm do không có bức xạ mặt trời. Nếu sử dụng các thuật toán nội suy thuần toán học (như tuyến tính hay spline) trên các khoảng trống kéo dài qua đêm, hệ thống sẽ sinh ra các giá trị sản lượng ảo (dương) phi vật lý.

Do đó, thuật toán tiến hành rà soát mốc thời gian và áp đặt giá trị 0 ngay lập tức nếu thỏa mãn một trong hai điều kiện logic sau:

- **Khung giờ ban đêm tự nhiên:** Mốc thời gian đo đạc nằm trong khoảng từ 18:30 chiều hôm trước đến 05:30 sáng hôm sau ($T \geq 18.5$ hoặc $T < 5.5$).
- **Điều kiện thời tiết triệt tiêu:** Giá trị bức xạ sóng ngắn mặt trời (shortwave_radiation) bằng 0 hoặc cờ chỉ số ánh sáng ngày is_day bằng 0 trong tập dữ liệu thời tiết (được đồng bộ hóa sang dòng sản lượng tương ứng bằng thuật toán ghép nối mốc gần nhất pd.merge_asof với ngưỡng sai lệch thời gian tối đa là 30 phút).

Giai đoạn này đã xử lý thành công 94.618 ô dữ liệu trống (chiếm tới 88,1% tổng số giá trị khuyết thiếu ban đầu), gán chúng về giá trị 0.0 một cách chính xác.

Mã nguồn Python hiện thực thuật toán lọc vật lý ban đêm:

```
1 def rule_based_night_zero(
2     solar_df: pd.DataFrame, weather_df: pd.DataFrame, site_key:
3     int
4 ) -> tuple:
5     gen = solar_df["energy_generated_kwh"].copy()
6     ts = solar_df["timestamp"]
7
8     # Xác định giờ đêm tự nhiên
9     hour = ts.dt.hour + ts.dt.minute / 60
10    is_night = (hour >= NIGHT_START + 0.5) | (hour < NIGHT_END +
11    0.5)
12
13    # Kết nối với open_meteo để lấy thông tin bức xạ sóng ngắn
14    w = weather_df[weather_df["sitekey"] == site_key][
15        ["timestamp", "shortwave_radiation", "is_day"]
16    ].copy()
17    w = w.rename(columns={"timestamp": "timestamp"})
18    w["timestamp"] = pd.to_datetime(w["timestamp"])
19
20    merged = pd.merge_asof(
21        solar_df[["timestamp"]].reset_index(),
```

```

20     w.sort_values("timestamp"),
21     on="timestamp",
22     tolerance=pd.Timedelta("30min"),
23     direction="nearest",
24 ).set_index("index")
25
26 # Điều kiện bức xạ song ngắn bằng 0 hoặc có đêm is_day = 0
27 zero_radiation = (merged["shortwave_radiation"].fillna(0) ==
28 0) | (
29     merged["is_day"].fillna(0) == 0
30 )
31 mask_zero = is_night.values | zero_radiation.values
32
33 n_filled = (mask_zero & gen.isna()).sum()
34 gen[mask_zero & gen.isna()] = 0.0
35 return gen, n_filled

```

Giai đoạn 2: Nội suy phân cấp theo quy mô khoảng trống (Imputation Gaps classification)

Đối với 12.834 ô dữ liệu khuyết thiếu phát sinh vào ban ngày (khi có bức xạ), thuật toán tiến hành phân tích độ dài chuỗi khuyết liên tiếp (Gap size) của từng trạm phát độc lập để áp dụng phương pháp điền khuyết tối ưu:

- Khoảng khuyết ngắn (≤ 2 dòng liên tiếp, tương đương ≤ 30 phút):** Áp dụng phương pháp nội suy tuyến tính (*Linear Interpolation*) theo thời gian. Do khoảng thời gian gián đoạn rất ngắn, biến động của ánh sáng mặt trời được coi là thay đổi tuyến tính đều giữa điểm biên trước và biên sau khoảng khuyết.
- Khoảng khuyết trung bình (Từ 3 đến 8 dòng liên tiếp, tương đương từ 45 phút đến 2 tiếng):** Áp dụng phương pháp nội suy *Cubic Spline*. Đường cong bậc ba giúp mô phỏng mượt mà sự trôi sụt tự nhiên của sản lượng điện do mây che phủ đi qua trạm pin. Để tránh hiện tượng sập nhiễu ma trận khi gặp các khoảng khuyết lớn lân cận, thuật toán xây dựng một bản sao tạm thời được điền tuyến tính để làm mịn dữ liệu mốc trước khi tính toán spline bậc ba thực tế.
- Khoảng khuyết diện rộng (> 8 dòng liên tiếp, tương đương > 2 tiếng):** Trong trường hợp này, dữ liệu bị mất quá dài khiến các phương pháp nội suy chuỗi đơn biến (Tuyến tính/Spline) mất khả năng phục hồi chính xác xu hướng thực tế. Nhóm thiết lập mô hình hồi quy đa biến (*Multivariate Regression Imputation*) độc lập cho từng trạm phát.

Mô hình Hồi quy Tuyến tính (LinearRegression từ thư viện scikit-learn) được huấn luyện trên tập các bản ghi sạch (đầy đủ thông tin) của chính trạm đó. Các biến đầu vào (Features) bao gồm: bức xạ sóng ngắn mặt trời (shortwave_radiation), bức xạ chiếu trực tiếp (direct_normal_irradiance), bức xạ khuếch tán (diffuse_solar_radiation) và nhiệt độ không khí ở độ cao 2m (temperature_c).

Sau khi huấn luyện, mô hình sẽ dự đoán sản lượng điện năng cho các khoảng khuyết diện rộng dựa trên dữ liệu khí tượng thực tế tại tọa độ trạm phát đó. Kết quả dự đoán được cắt giới hạn dưới bằng 0 (clip(lower=0)) để loại bỏ các giá trị âm sinh ra do sai số hồi quy.

Mã nguồn Python thực thi hồi quy đa biến điền khuyết diện rộng ban ngày:

```

1 def regression_imputation_large_gaps_strict(
2     solar_sub: pd.DataFrame,
3     weather_df: pd.DataFrame,
4     site_key: int,
5     large_gap_indices: set,
6 ) -> tuple:
7     FEATURES = [
8         "shortwave_radiation",
9         "direct_normal_irradiance",
10        "diffuse_solar_radiation",
11        "temperature_c",
12    ]
13
14    w = weather_df[weather_df["sitekey"] == site_key][["timestamp"
15    ] + FEATURES].copy()
16    w = w.rename(columns={"timestamp": "timestamp"})
17    w["timestamp"] = pd.to_datetime(w["timestamp"])
18
19    merged = pd.merge_asof(
20        solar_sub[["timestamp", "energy_generated_kwh"]].
21        reset_index(),
22        w.sort_values("timestamp"),
23        on="timestamp",
24        tolerance=pd.Timedelta("60min"),
25        direction="nearest",
26    ).set_index("index")
27
28    train_mask = merged["energy_generated_kwh"].notna() & merged[
29    FEATURES].notna().all(
30        axis=1

```

```

28     )
29     pred_mask = merged["energy_generated_kwh"].isna() & merged[
FEATURES].notna().all(
30         axis=1
31     )
32
33     filled = 0
34     if train_mask.sum() < 10:
35         return solar_sub["energy_generated_kwh"].values, 0
36
37     X_train = merged.loc[train_mask, FEATURES].values
38     y_train = merged.loc[train_mask, "energy_generated_kwh"].
values
39
40     # Chuan hoa thong so dac trung dau vao
41     scaler = StandardScaler()
42     X_train_sc = scaler.fit_transform(X_train)
43
44     model = LinearRegression()
45     model.fit(X_train_sc, y_train)
46
47     if pred_mask.sum() > 0:
48         X_pred = merged.loc[pred_mask, FEATURES].values
49         X_pred_sc = scaler.transform(X_pred)
50         y_pred = model.predict(X_pred_sc)
51
52         result = solar_sub["energy_generated_kwh"].copy()
53         pred_indices = merged[pred_mask].index.tolist()
54
55         for pos, idx in enumerate(pred_indices):
56             local_pos = solar_sub.index.get_loc(idx) if idx in
solar_sub.index else None
57             # Chi ghi vao cac vi tri thuoc khoang khuyet lon
58             if local_pos is not None and local_pos in
large_gap_indices:
59                 result.iloc[local_pos] = max(0.0, y_pred[pos])
60                 filled += 1
61
62         return result.values, filled
63     return solar_sub["energy_generated_kwh"].values, 0

```

Tổng hợp kết quả sau quy trình làm sạch dữ liệu khuyết thiếu:

- Tổng số ô trống ban đầu: 107.452 ô (3,93% dữ liệu).
- Số ô được điền qua lọc ban đêm (Night Zero): 94.618 ô.
- Số ô được điền qua nội suy tuyến tính (Linear): 3.652 ô.
- Số ô được điền qua nội suy đường cong (Cubic Spline): 5.124 ô.
- Số ô được điền qua mô hình học máy hồi quy (Regression): 4.058 ô.
- Số ô NULL còn lại trong kho dữ liệu: 0 ô (Điền khuyết thành công 100%).

4.3.2 Xử lý Dữ liệu Ngoại lai (Outliers) và Lọc nhiễu

Bên cạnh lỗi mất mát dữ liệu, hệ thống thu thập thông tin từ cảm biến dòng điện (CT) của các trạm phát thường xuyên gặp hiện tượng nhiễu đột biến (Spikes) do xung nhiễu lưới điện, bụi bẩn bám tạm thời hoặc lỗi truyền dữ liệu gây ra các đỉnh công suất vượt xa công suất thiết kế cực đại (kWp).

Để nhận diện các bất thường này mà không bị ảnh hưởng bởi tính mùa vụ và tính chu kỳ ngày đêm cực mạnh của điện mặt trời, nhóm áp dụng phương pháp **Grouped Rolling IQR cục bộ** trong file `upload_rolling_outlier_flags.py`.

Quy trình tính toán và gắn cờ ngoại lai

Thuật toán tính toán độ lệch tuyệt đối của từng điểm dữ liệu sản lượng so với trung bình trượt trong cửa sổ 1 giờ tự trượt theo thời gian. Sau đó, toàn bộ các độ lệch này được gom nhóm theo tổ hợp trạm (`sitekey`) và giờ trong ngày (`hour`) để tính toán khoảng tứ phân vị cục bộ ($IQR_{s,h} = Q_3 - Q_1$). Bản ghi nào có độ lệch tuyệt đối vượt quá ngưỡng giới hạn cục bộ ($Q_3 + 1.5 \cdot IQR_{s,h}$) sẽ bị gắn cờ ngoại lai `rolling_outlier_flag = true`.

Quy trình đẩy cờ an toàn vào Kho dữ liệu trung tâm

Để cập nhật cờ ngoại lai này lên Supabase DWH mà không làm gián đoạn hệ thống và đảm bảo an toàn giao dịch tuyệt đối, nhóm xây dựng một pipeline 4 bước như sau:

1. **Xác thực nguồn dữ liệu (Source Verification Check):** Trước khi thực hiện bất kỳ thao tác ghi nào, tập tin `upload_rolling_outlier_flags.py` tiến hành đối chiếu cấu trúc vân tay dữ liệu (Data Fingerprint Check) giữa tệp CSV kết quả phân tích ngoại lai và bảng sự kiện `fact_solar_energy_gen` trên Supabase.

Quy trình kiểm tra tính toán tổng băm MD5 của chuỗi khóa ghép (sitekey|timestamp), tổng sản lượng năng lượng (energy_sum) với sai số cho phép ≤ 0.01 , và tổng số dòng dữ liệu. Bước này đảm bảo dữ liệu chạy cờ ngoại lai và dữ liệu trên cơ sở dữ liệu hoàn toàn đồng nhất về cấu trúc cột và số lượng dòng (2.731.946 dòng), ngăn ngừa lỗi lệch dòng (Data Shift).

2. **Nạp danh sách ứng viên (Sparse Candidate Upload):** Thay vì tải lên lại toàn bộ 2,73 triệu dòng dữ liệu (rất chậm và dễ gây nghẽn kết nối), thuật toán chỉ lọc ra các bản ghi bị gắn cờ ngoại lai thực sự (rolling_outlier_flag = true) gồm 100.822 dòng. Danh sách ứng viên này được đẩy vào một bảng tạm trung gian có cấu trúc chỉ mục khóa chính tối ưu: staging.fact_solar_energy_gen_rolling_outlier_flags.
3. **Kiểm tra tính toàn vẹn khóa ngoại (Referential Check):** Thực hiện truy vấn kiểm tra chéo (Anti-Join) để đảm bảo toàn bộ 100.822 khóa trong bảng tạm đều tồn tại khớp 1:1 trong bảng sự kiện chính. Kết quả trả về 0 dòng lỗi trước khi tiến hành cập nhật.
4. **Cập nhật giao dịch hàng loạt (Bulk Join Update):** Tiến trình mở một khối giao dịch an toàn trên cơ sở dữ liệu, thực hiện gán toàn bộ cờ rolling_outlier_flag = false cho cả bảng sự kiện chính (2.731.946 dòng), sau đó thực hiện lệnh cập nhật UPDATE ... FROM ... WHERE nối bảng tạm với bảng chính theo khóa trùng khớp (sitekey, timestamp) để chuyển các dòng ngoại lai sang trạng thái true.

Dưới đây là một phần mã nguồn Python thực hiện so sánh đối chiếu vân tay (Fingerprint) dữ liệu để bảo vệ chống ghi đè lỗi dữ liệu:

```

1 def fingerprint_supabase(conn: any) -> dict[str, object]:
2     cur = conn.cursor()
3     try:
4         cur.execute(
5             f"""
6             SELECT
7                 COUNT(*)::bigint AS rows,
8                 COUNT(DISTINCT sitekey)::bigint AS
distinct_sitekeys,
9                 MIN(to_char(timestamp, 'YYYY-MM-DD HH24:MI:SS'))
AS min_timestamp,
10                MAX(to_char(timestamp, 'YYYY-MM-DD HH24:MI:SS'))
AS max_timestamp,
11                SUM(('x' || substr(md5(sitekey::text), 1, 15))::
bit(60)::bigint)::numeric AS site_sum,

```



```

12         SUM(('x' || substr(md5(to_char(timestamp, 'YYYY-MM
13         -DD HH24:MI:SS')), 1, 15))::bit(60)::bigint)::numeric AS
14         timestamp_sum,
15         SUM(energy_generated_kwh::numeric) AS energy_sum,
16         SUM(
17             ('x' || substr(
18                 md5(sitekey::text || '|' || to_char(
19                     timestamp, 'YYYY-MM-DD HH24:MI:SS')),
20                 1,
21                 15
22             ))::bit(60)::bigint
23             )::numeric AS key_checksum
24     FROM {qname(SCHEMA, SOURCE_FACT_TABLE)}
25     """
26 )
27 row = cur.fetchone()
28 return {
29     "rows": int(row[0]),
30     "distinct_sitekeys": int(row[1]),
31     "min_timestamp": row[2],
32     "max_timestamp": row[3],
33     "site_sum": Decimal(str(row[4] or 0)),
34     "timestamp_sum": Decimal(str(row[5] or 0)),
35     "energy_sum": Decimal(str(row[6] or 0)),
36     "key_checksum": Decimal(str(row[7] or 0)),
37 }
38 finally:
39     cur.close()

```

Kết quả chạy pipeline thực tế đã gắn cờ thành công ****100.822 dòng ngoại lai**** (chiếm ****3,69%**** tổng số dòng dữ liệu). Phân phối cờ sau kiểm chứng khớp hoàn hảo với các chỉ số thống kê toán học của mô hình mẫu:

- Tổng số dòng dữ liệu kiểm tra: 2.731.946 dòng.
- Số lượng dòng gắn cờ ngoại lai (true): 100.822 dòng (3,69%).
- Số lượng dòng dữ liệu sạch bình thường (false): 2.631.124 dòng (96,31%).
- Số lượng dòng mang giá trị rỗng (null): 0 dòng.

4.4 Biến đổi và Trích xuất Đặc trưng (Feature Engineering)

Sau khi dữ liệu sản lượng và thời tiết được làm sạch tại tầng kho dữ liệu, tiến trình thực hiện tính toán biến đổi cấu trúc để chuẩn bị dữ liệu đầu vào tối ưu cho mô hình dự báo học máy.

4.4.1 Giải quyết độ lệch tần suất ghi nhận (Granularity Alignment)

Một thách thức lớn trong dữ liệu của dự án là độ lệch tần suất (Granularity Mismatch) giữa hai nguồn thông tin nghiệp vụ:

- Dữ liệu sản lượng điện được ghi nhận với tần suất cao (15 phút một dòng).
- Dữ liệu khí tượng viễn thám chỉ có sẵn theo chu kỳ giờ (60 phút một dòng).

Để giải quyết sự lệch pha này mà không làm mất mát thông tin xu hướng của bức xạ mặt trời, nhóm thiết lập thuật toán gom cụm (Aggregation) đưa dữ liệu về cùng chu kỳ giờ (1-hour grain). Chỉ số sản lượng điện mặt trời `energy_generated_kwh` trong 4 chu kỳ 15 phút của cùng một giờ được tính tổng cộng dồn (Sum Aggregation):

$$E_{\text{hour}} = \sum_{i=1}^4 E_{15\text{min},i} \quad (4.1)$$

Trong khi đó, các biến thời tiết đại diện cho giờ đó được giữ nguyên giá trị trung bình giờ. Thuật toán ghép nối sử dụng hàm kết hợp chính xác mốc thời gian chẵn giờ, giúp tạo ra một bảng dữ liệu phẳng góc nhìn rộng (Wide-table) thống nhất, đảm bảo tính liên kết chặt chẽ và không có dữ liệu rò rỉ thời gian (Data Leakage).

4.4.2 Trích xuất các đặc trưng thời gian và lịch trình học tập

Điện năng mặt trời mang tính chu kỳ tự nhiên rất mạnh phụ thuộc vào quỹ đạo chuyển động của Trái Đất. Dự án tiến hành trích xuất các đặc trưng thời gian đa tầng từ trường mốc thời gian `timestamp`:

- **Đặc trưng giờ trong ngày (Hour):** Giá trị từ 0 đến 23, xác định góc chiếu mặt trời.
- **Đặc trưng tháng trong năm (Month):** Xác định tính mùa vụ thời tiết (Mùa hè bức xạ cao, mùa đông bức xạ thấp ở Nam bán cầu).
- **Đặc trưng ngày trong tuần (Day of Week):** Hỗ trợ phân tích hành vi tiêu thụ điện năng tại các khu học xá (Campus).

Đặc biệt, nhóm tích hợp thành công dữ liệu lịch học tập (`calender.csv`) của cơ sở đào tạo thông qua ba đặc trưng nhị phân:

- `is_holiday`: Đánh dấu các ngày nghỉ lễ quốc gia hoặc ngày nghỉ nội bộ.
- `is_semester`: Đánh dấu thời điểm đang trong học kỳ chính thức (nhu cầu sử dụng thiết bị điện cao đột biến).
- `is_exam`: Đánh dấu giai đoạn thi cử tập trung.

Sự kết hợp các thuộc tính lịch trình này giúp mô hình học máy phân biệt rõ rệt giữa biến động sản lượng do thời tiết tự nhiên và biến động tiêu thụ do hành vi con người gây ra, cải thiện độ chính xác dự báo sản lượng thực dùng tại các điểm nút phụ tải trạm.

Trực quan Dữ liệu và Xây dựng Dashboard

5.1 Chiến lược Kết nối Dữ liệu và Thiết kế UI/UX

[Kết nối các bảng Fact và Dimension từ Supabase vào công cụ BI (Tableau) thông qua các Relationship (1-M). Lựa chọn bộ màu sắc và bố cục Dashboard theo quy luật Gestalt để làm nổi bật các chỉ số quan trọng.]

5.2 Chi tiết Hệ thống Dashboard Phân tích

5.2.1 Dashboard 1: Tổng quan Vận hành (Executive Overview)

[Cung cấp cái nhìn toàn cảnh về sản lượng điện tổng, công suất hoạt động trung bình, và xu hướng theo thời gian của 42 trạm phát.]

5.2.2 Dashboard 2: Phân tích Hiệu suất và Khí hậu

[Phân tích tương quan giữa sản lượng điện với nhiệt độ và bức xạ. Phát hiện các mốc suy giảm hiệu suất.]

5.2.3 Dashboard 3: Giám sát Bất thường và Lỗi Cảm biến

[Trực quan hóa các điểm dữ liệu bất thường (Outliers), tần suất xuất hiện lỗi tại các trạm để kỹ sư có kế hoạch bảo trì.]

Khai phá Dữ liệu và Business Insights

Theo tinh thần phân tích chuyên sâu (Đừng chỉ mô tả → phải giải thích), chương này tập trung vào việc bóc tách các điểm nghẽn vận hành và đưa ra các phát hiện có giá trị kinh doanh (Business Insights) dựa trên logic dữ liệu, thay vì chỉ dựa vào các biểu đồ bề nổi. Các mô hình học máy cơ sở (ARIMA/Prophet) được tích hợp như một công cụ chẩn đoán hỗ trợ.

6.1 Insight 1: Hiện tượng suy giảm hiệu suất do nhiệt độ (Thermal Degradation)

[Dữ liệu chứng minh rằng khi nhiệt độ môi trường vượt quá ngưỡng giới hạn (ví dụ: 25°C), hiệu suất chuyển đổi quang điện của tấm pin sụt giảm đáng kể. Điều này giải thích tại sao vào buổi trưa bức xạ cao nhất nhưng công suất lại không đạt đỉnh.]

6.2 Insight 2: Điểm mù vận hành từ “Độ nhiễu ban đêm”

[Phát hiện hàng loạt trạm ghi nhận sản lượng phát điện vào ban đêm. Nguyên nhân được phân tích là do nhiễu xung điện từ biến tần (Inverter) hoặc dòng rò. Nếu không lọc bỏ, dữ liệu này sẽ làm sai lệch nghiêm trọng các báo cáo tổng sản lượng.]

6.3 Insight 3: Ứng dụng Mô hình dự báo (Baseline) để tối ưu vận hành

[Ứng dụng mô hình Time-Series (như Prophet) để thiết lập đường cơ sở (Baseline) dự báo sản lượng. Sự chênh lệch lớn giữa sản lượng thực tế và Baseline đóng vai trò là “cờ báo” (Alert) để ban quản lý cử đội bảo trì đến kiểm tra các tấm pin bị bụi bẩn bám dính hoặc hỏng hóc.]

Kết luận và Hướng phát triển

7.1 Kết luận Tổng quan

[Tóm tắt lại việc hoàn thành các mục tiêu dự án: Xây dựng thành công Data Warehouse, làm sạch dữ liệu nhiễu, và phát triển hệ thống Dashboard trực quan giúp doanh nghiệp chuyển đổi từ quản lý thụ động sang giám sát dựa trên dữ liệu.]

7.2 Khuyến nghị Chiến lược (Actionable Insights)

[Đề xuất các hành động cụ thể: Lắp đặt hệ thống làm mát tự động để giảm suy hao nhiệt, thiết lập quy trình kiểm tra Inverter định kỳ để khắc phục độ nhiễu ban đêm, và ứng dụng kết quả dự báo để lập kế hoạch vệ sinh tấm pin.]

7.3 Hạn chế của Dự án

[Những giới hạn về phần cứng, thời gian xử lý dữ liệu lớn, hoặc sự thiếu hụt của các mô hình học sâu (Deep Learning) phức tạp hơn.]

7.4 Hướng phát triển trong tương lai

7.4.1 Nâng cấp Hệ thống Phân tích Dự đoán (Predictive Analytics)

[Tích hợp các mô hình Machine Learning mạnh mẽ hơn (XGBoost, LSTM) để dự báo biến động công suất theo thời gian thực.]

7.4.2 Tự động hóa và Đưa lên Đám mây (Cloud & Automation)

[Triển khai toàn bộ Pipeline ETL lên các dịch vụ Cloud như AWS/GCP để xử lý luồng dữ liệu Streaming từ các cảm biến IoT.]

Phụ lục A: Kế hoạch Thực hiện

[Bảng phân công nhiệm vụ chi tiết và kế hoạch 14 tuần thực hiện dự án của các thành viên.]

Phụ lục B: Cấu trúc Mã nguồn

[Sơ đồ cấu trúc thư mục của package Python du_an_tot_nghiep và các script tiện ích.]

Tài liệu Tham khảo

- [1] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control*. 5th ed. Wiley.
- [2] Taylor, S. J., & Letham, B. (2018). Forecasting at Scale. *The American Statistician*, 72(1), 37–45.
- [3] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of KDD 2016*, 785–794.
- [5] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.
- [6] Vaswani, A., et al. (2017). Attention Is All You Need. *Proceedings of NeurIPS 2017*, 5998–6008.
- [7] Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit*. 3rd ed. Wiley.
- [8] NASA POWER Project. (2024). <https://power.larc.nasa.gov/>.
- [9] Supabase Documentation. (2024). <https://supabase.com/docs>.
- [10] IEA – International Energy Agency. (2024). <https://www.iea.org/reports/renewables-2024>.
- [11] Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly Detection: A Survey. *ACM Computing Surveys*, 41(3), Article 15.
- [12] Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.