

TRƯỜNG CAO ĐẲNG FPT POLYTECHNIC



FPT POLYTECHNIC

DỰ ÁN TỐT NGHIỆP
CHUYÊN NGÀNH: XỬ LÝ DỮ LIỆU

PHÂN TÍCH HIỆU SUẤT VÀ DỰ BÁO SẢN LƯỢNG HỆ THỐNG ĐIỆN MẶT TRỜI

Nhóm thực hiện: The Outliers

Sinh viên thực hiện:

- | | |
|---------------------|---------|
| 1. Nguyễn Vũ Nhật | PS44442 |
| 2. Nguyễn Văn Sỹ | PS43671 |
| 3. Lê Công Toàn | PS44145 |
| 4. Nguyễn Xuân Hùng | PS44527 |
| 5. Ngô Tấn Đạt | PS44589 |

Giảng viên hướng dẫn: Văn Công Khanh

TP. HỒ CHÍ MINH, THÁNG 6 NĂM 2026

Lời cảm ơn

[Nội dung lời cảm ơn của sinh viên đối với giảng viên hướng dẫn, gia đình và nhà trường sẽ được viết tại đây.]

Nhận xét của Giảng viên Hướng dẫn

[Nội dung nhận xét và đánh giá của Giảng viên Hướng dẫn đối với kết quả thực hiện dự án của nhóm.]

Nhận xét của Giảng viên Phản biện

[Nội dung nhận xét và đánh giá của Giảng viên Phản biện tại buổi bảo vệ dự án tốt nghiệp.]

Tóm tắt Dự án

Dự án tốt nghiệp “Phân tích và Xử lý Bất thường trong Dữ liệu Sản lượng Năng lượng Mặt trời” nhằm mục đích xây dựng một hệ thống phân tích dữ liệu toàn diện để phát hiện, xử lý và dự báo các bất thường trong sản lượng phát điện của các hệ thống quang điện (PV). Bằng cách thu thập và tích hợp dữ liệu từ 42 trạm phát điện tại Úc cùng dữ liệu khí tượng viễn thám từ Open-Meteo, nhóm đã thiết kế một kho dữ liệu đa chiều (Data Warehouse) trên nền tảng Supabase theo mô hình Galaxy Schema. Quy trình ETL được tự động hóa để làm sạch dữ liệu, xử lý các hiện tượng khuyết thiếu, nhiễu ban đêm, và sai lệch do cảm biến.

Qua quá trình Phân tích Khám phá Dữ liệu (EDA), nhóm đã rút ra các insight quan trọng về sự ảnh hưởng của nhiệt độ, mức độ mây che phủ đến hiệu suất PV. Ngoài ra, dự án cũng áp dụng các mô hình học máy chuỗi thời gian như ARIMA và Prophet để thiết lập đường cơ sở (Baseline) dự báo sản lượng, kết hợp hiển thị trực quan thông qua Dashboard Tableau. Hệ thống không chỉ cung cấp cái nhìn toàn cảnh về tình trạng hoạt động của các trạm điện mặt trời, mà còn hỗ trợ ban quản lý đưa ra quyết định kịp thời nhằm tối ưu hóa hiệu suất và giảm thiểu rủi ro vận hành.

Mục lục

Lời cảm ơn	1
Nhận xét của Giảng viên Hướng dẫn	2
Nhận xét của Giảng viên Phản biện	3
Tóm tắt Dự án	4
Danh mục Từ viết tắt	15
1 Tổng quan Đề tài và Bài toán Nghiên cứu	16
1.1 Bối cảnh thực tế và lý do chọn đề tài	16
1.2 Bài toán kinh doanh và các khó khăn cần giải quyết	16
1.3 Mục tiêu dự án và Kết quả dự kiến	17
1.4 Đối tượng và phạm vi nghiên cứu	17
1.5 Bố cục báo cáo	18
2 Cơ sở Lý thuyết	19
2.1 Tổng quan về Năng lượng mặt trời và Bức xạ quang điện	19
2.2 Kiến trúc Kho dữ liệu đa chiều (Data Warehouse)	19
2.2.1 Mô hình hóa đa chiều (Dimensional Modeling)	19
2.2.2 Lược đồ Thiên hà (Galaxy Schema)	20
2.2.3 Phương pháp tiếp cận Top-Down (Triết lý kiến trúc của Bill Inmon)	20
2.3 Quy trình Trích xuất, Biến đổi và Nạp dữ liệu (ETL Pipeline)	21
2.3.1 Lý thuyết về Nội suy dữ liệu khuyết thiếu (Data Imputation)	21
2.3.2 Chiến lược nạp dữ liệu tối ưu hóa giao dịch	22
2.4 Các phương pháp Phát hiện bất thường dữ liệu (Anomaly Detection)	23
2.4.1 Phương pháp thống kê Z-Score	23
2.4.2 Phương pháp khoảng tứ phân vị IQR (Interquartile Range)	23
2.4.3 Phương pháp Trung bình trượt và IQR cục bộ (Rolling IQR)	23
2.5 Cơ sở thuật toán Dự báo chuỗi thời gian	24
3 Thu thập Dữ liệu và Thiết kế Kiến trúc Kho dữ liệu	25
3.1 Kiến trúc Tổng thể Hệ thống Dữ liệu (Data Architecture Overview)	25
3.1.1 Tiếp cận Top-Down (Inmon Approach)	25
3.2 Phương pháp thu thập dữ liệu thô (Extract)	26

3.2.1	Trích xuất dữ liệu khí tượng qua Open-Meteo API	26
3.2.2	Thiết lập kết nối cơ sở dữ liệu Supabase	28
3.3	Data Dictionary & Metadata	29
3.3.1	Dữ liệu Thông tin Cơ sở hạ tầng (campus_meta.csv)	29
3.3.2	Dữ liệu Thông tin Kỹ thuật Trạm (Solar_Site_Details.csv)	30
3.3.3	Dữ liệu Sản lượng Điện (Solar_Energy_Generation.csv)	30
3.3.4	Dữ liệu Thông tin Lịch trình (calender.csv)	31
3.3.5	Dữ liệu Khí tượng Viễn thám (open_meteo_weather_raw.csv)	31
3.4	Thiết kế kiến trúc Kho dữ liệu đa chiều (Data Warehouse)	32
3.4.1	Mô hình Dữ liệu Khái niệm (Conceptual Data Model)	32
3.4.2	Mô hình Dữ liệu Logic (Logical Data Model)	33
3.4.3	Mô hình Dữ liệu Vật lý (Physical Data Model)	34
3.4.4	Kịch bản SQL Khởi tạo Cơ sở Dữ liệu	38
3.5	Kiểm tra tính toàn vẹn và bảo mật dữ liệu	40
4	Quy trình ETL và Chuẩn hóa Dữ liệu	41
4.1	Tổng quan Kiến trúc Pipeline Xử lý Dữ liệu	41
4.1.1	Thiết lập Tiến trình Nạp Dữ liệu Tự động	42
4.1.2	Cơ chế Quản lý Giao dịch và An toàn Dữ liệu	43
4.2	Đánh giá Chất lượng và Khám phá Dữ liệu (EDA ban đầu)	43
4.2.1	Các Cột Thực Tế và Ảnh Xạ Dữ Liệu Trong Pipeline	44
4.3	Làm sạch và Chuẩn hóa Dữ liệu (Data Cleaning)	45
4.3.1	Xử lý Dữ liệu Khuyết thiếu và Lỗi Logic	45
4.3.2	Xử lý Dữ liệu Ngoại lai (Outliers) và Lọc nhiễu	50
4.4	Biến đổi và Trích xuất Đặc trưng (Feature Engineering)	52
4.4.1	Giải quyết độ lệch tần suất ghi nhận (Granularity Alignment)	53
4.4.2	Trích xuất các đặc trưng thời gian và lịch trình học tập	53
5	Trực quan Dữ liệu và Xây dựng Dashboard	55
5.1	Chiến lược Kết nối Dữ liệu và Thiết kế UI/UX	55
5.2	Chi tiết Hệ thống Dashboard Phân tích	55
5.2.1	Dashboard 1: Tổng quan Vận hành (Executive Overview)	55
5.2.2	Dashboard 2: Phân tích Hiệu suất và Khí hậu	55
5.2.3	Dashboard 3: Giám sát Bất thường và Lỗi Cảm biến	55
6	Khai phá Dữ liệu và Business Insights	56
6.1	Insight 1: Hiện tượng suy giảm hiệu suất do nhiệt độ (Thermal Degradation)	56
6.2	Insight 2: Điểm mù vận hành từ “Độ nhiễu ban đêm”	56
6.3	Insight 3: Ứng dụng Mô hình dự báo (Baseline) để tối ưu vận hành	56

7	Thiết kế, Huấn luyện và Đánh giá Mô hình Dự báo Sản lượng Quang điện	57
7.1	Tổng quan quy trình học máy	57
7.1.1	Phạm vi và dữ liệu đầu vào	57
7.1.2	Bài toán và tầm dự báo	58
7.1.3	Nhãn ngoại lai kế thừa từ tầng ETL	59
7.1.4	Sơ đồ toàn cảnh	65
7.1.5	Năm rào chắn chống rò rỉ dữ liệu	66
7.2	Chuẩn bị dữ liệu và chia tập	68
7.2.1	Dựng lại lưới thời gian liên tục	68
7.2.2	Phân tích khám phá dữ liệu và các quyết định sinh đặc trưng . . .	70
7.2.3	Chia dữ liệu theo trục thời gian	74
7.2.4	Ba fold theo cửa sổ mở rộng	76
7.2.5	Thực nghiệm: đo phần chồng lấn nhãn ở ranh giới fold	77
7.3	Sinh đặc trưng	78
7.3.1	Đặc trưng thời gian, trễ và cửa sổ trượt	78
7.3.2	Hình học Mặt Trời, bức xạ trời quang và chuẩn hoá theo trạm . . .	83
7.3.3	Định nghĩa các đặc trưng dẫn xuất	89
7.3.4	Thực nghiệm: khử độ trễ cài sẵn bằng đặc trưng tại thời điểm mục tiêu	90
7.3.5	Chuẩn hoá mục tiêu theo vật lý	91
7.3.6	Kiểm chứng các tham số cố định	94
7.3.7	Chẩn đoán và chọn đặc trưng	97
7.3.8	Tổng hợp bộ đặc trưng đưa vào mô hình	103
7.4	Huấn luyện và chọn hàm mất mát	103
7.4.1	Chính sách trọng số cho dòng ngoại lai	103
7.4.2	Tinh chỉnh siêu tham số	104
7.4.3	Sáu cấu hình Optuna chọn được	105
7.4.4	Chọn hàm mất mát	106
7.4.5	Cấu hình tắt định	107
7.5	Đánh giá trên tập test niêm phong	107
7.5.1	Thước đo	107
7.5.2	Phạm vi chấm điểm	108
7.5.3	Kết quả	109
7.5.4	Chênh lệch giữa sai số trên test và trên kiểm định	109
7.5.5	Đối chứng với Prophet	110
7.5.6	Kiểm chứng độ trễ pha trên mô hình cuối	112
7.6	Giải thích mô hình bằng SHAP	112
7.6.1	Cơ sở phương pháp	113

7.6.2	Tầm quan trọng tổng thể	113
7.6.3	Giải thích ba dự báo cụ thể	115
7.6.4	Giới hạn diễn giải	116
7.7	Ứng dụng trực quan hoá kết quả	116
7.7.1	Trang giám sát chuỗi thời gian	116
7.7.2	Trang giải thích dự báo	116
7.7.3	Trang dự báo và phân tích giả định	118
7.8	Kết luận và hướng phát triển	121
7.8.1	Kết quả đạt được	121
7.8.2	Giới hạn	121
7.8.3	Hướng phát triển	121
8	Kết luận và Hướng phát triển	125
8.1	Kết luận Tổng quan	125
8.2	Khuyến nghị Chiến lược (Actionable Insights)	125
8.3	Hạn chế của Dự án	125
8.4	Hướng phát triển trong tương lai	125
8.4.1	Nâng cấp Hệ thống Phân tích Dự đoán (Predictive Analytics) . . .	125
8.4.2	Tự động hóa và Đưa lên Đám mây (Cloud & Automation)	125
	Phụ lục A: Kế hoạch Thực hiện	126
	Phụ lục B: Cấu trúc Mã nguồn	127
	Tài liệu Tham khảo	128

Danh sách hình vẽ

3.1	Sơ đồ Mô hình Dữ liệu Khái niệm (Conceptual Data Model)	32
3.2	Sơ đồ Mô hình Dữ liệu Logic (Logical Data Model)	34
3.3	Sơ đồ Mô hình Dữ liệu Vật lý (Physical Data Model)	34
7.1	Trang đầu bài báo công bố bộ dữ liệu UNISOLAR [1], IEEE <i>International Conference on Human-System Interaction</i> 2022. Phần tóm tắt xác nhận quy mô 42 dàn quang điện trên năm khuôn viên và bước đo 15 phút. . . .	58
7.2	Bảng 4 của Roy, Pyltsov và Hu [2], so sánh 12 mô hình trên cùng bộ dữ liệu. Khung đồ đánh dấu ba dòng RMSE — chỉ số càng nhỏ càng tốt. Ở kịch bản $Year\ 1 \rightarrow Year\ 2$, mô hình cây XGBoost đạt 159,6 trong khi Transformer (cột TF) là 239,5, LSTM là 220,9 và TimeGPT là 369,03. . .	59
7.3	Trang 1 bản toàn văn của Li và cộng sự [4], <i>IEEE Access</i> tập 13, trang 108823–108837. Khung đồ đánh dấu đúng hai ý mà dự án lấy làm ngữ cảnh: dùng <i>chiến lược phân đoạn bằng cây quyết định</i> để tạo các vùng gần Gauss, và <i>tích hợp Isolation Forest làm cơ chế quyết định</i> ở bước chi tiết. Hai con số 3,8% và 9,1% dẫn ở đoạn trên nằm ở cuối phần tóm tắt, do trên dữ liệu của bài báo — nơi nhóm tác giả có nhãn đối chiếu. . . .	61
7.4	(Trích xuất từ Notebook 05d_thuc_nghiem_rao_chan_vat_ly.ipynb) Hai nguyên lý chạy trên dữ liệu thật của dự án: trạm 27, dải bức xạ 201–350 W/m ² , 8.176 quan sát. Trái: GMM hai thành phần, điểm đỏ là các quan sát có mật độ tương đối $P_{GMM} < 0,02$. Phải: phân bố điểm cô lập của Isolation Forest (100 cây), phần cam là vùng bị cắt theo <code>contamination = 0,03</code>	62
7.5	(Trích xuất từ Notebook 05d_thuc_nghiem_rao_chan_vat_ly.ipynb) Quét hệ số nhân m của <code>safe_IQR</code> qua sáu mức. Trái: số dòng bị gán cờ. Phải: phần sản lượng bị ảnh hưởng, trục tung dừng ở 0,05%.	65
7.6	Chín bước của quy trình học máy. Đọc theo mũi tên: bước 1 ở ô trên cùng bên trái, sang phải là bước 2, xuống hàng dưới là bước 3 rồi 4, tiếp tục tới bước 9. Dòng cuối mỗi ô ghi tập kết quả mà bước đó sinh ra.	66
7.7	Trích đoạn abstract của Kim, Ko và Kim [3]. Khung đồ đánh dấu câu khẳng định dữ liệu <i>khuyết làm suy giảm hiệu năng dự báo sản lượng quang điện</i> và cần được xử lý bằng cách điền giá trị thay thế. Đây là cơ sở để dự án tách bạch hai việc ở bước chuẩn bị dữ liệu.	70

7.8	(Trích xuất từ Notebook 02_EDA.ipynb) Trái: histogram toàn bộ tập huấn luyện, trục tung thang loga. Giữa: chỉ ban ngày. Phải: boxplot đối chiếu hai phạm vi.	72
7.9	(Trích xuất từ Notebook 02_EDA.ipynb) Sản lượng theo bước 15 phút tại trạm 27, hai ngày dùng chung thang trục tung. Trái: ngày trời quang 02/10/2020, độ gấp 0,0031. Phải: ngày nhiều mây 23/12/2020, độ gấp 0,0926. Trục hoành là giờ trong ngày, cắt trong khoảng 5–21 giờ vì ngoài khoảng đó sản lượng bằng 0. Số đo của hai ngày kiểm chứng được bằng <code>srcs/05_machine_learning/kiem_chung_bao_cao_v4.py</code> , mục 11.	73
7.10	(Trích xuất từ Notebook 02_EDA.ipynb) Trái: ACF quét 288 bước = 72 giờ. Phải: PACF quét 96 bước = 24 giờ. Vạch đỏ chấm là mốc 96 bước. . .	73
7.11	(Trích xuất từ Notebook 02_EDA.ipynb) Ma trận tương quan Spearman trên 606.112 dòng đo thật ban ngày.	75
7.12	(Trích xuất từ Notebook 02_split_time_series.ipynb) Cách chia dữ liệu theo trục thời gian: tập test niêm phong tách ra từ phần cuối, phần Phát triển còn lại chia thành ba fold theo cửa sổ mở rộng.	76
7.13	Trích mục <i>Benchmarking</i> của Dev và cộng sự [8]. Khung đỏ đánh dấu hai mệnh đề: <i>persistence</i> giả định điều kiện không đổi — <i>đặc biệt ở các tầm dự báo ngắn</i> — và <i>phương pháp này chạy tốt</i> khi điều kiện thời tiết biến thiên chậm.	79
7.14	NOAA Solar Calculator của Global Monitoring Laboratory — công cụ chính thức tính vị trí Mặt Trời mà hàm <code>tingh_goc_mat_troi</code> của dự án dựa theo.	83
7.15	Đoạn tóm tắt bài báo Haurwitz [5], <i>Journal of Meteorology</i> tập 2, tr. 154–166. Khung đỏ đánh dấu dạng công thức $T = (a/m)e^{-bm}$ với m là khối không khí — nguồn gốc của mô hình trời quang mà dự án dùng. . . .	84
7.16	Trích trang 5 bài tổng quan Bailey và cộng sự [6]. Khung đỏ mô tả thuật toán Graham và Hollands (1990): tách chỉ số trời quang theo giờ k_t thành mô hình cộng $k_t = k_{tm} + \alpha$	86
7.17	(Trích xuất từ Notebook 03_2_features_spatial.ipynb) Bức xạ tại trạm 1, ngày 19/12/2020, từ 11 giờ đến 17 giờ. Trên: dữ liệu gốc theo giờ, mỗi giá trị lặp bốn lần nên đường đi thành bậc thang. Dưới: sau khi hạ độ phân giải, đường biến thiên theo từng bước 15 phút.	87
7.18	Trích trang 21 của Engerer và Mills [7]. Hai đoạn được đánh dấu cho thấy hai công trình tiền lệ dùng hai mức phân vị khác nhau để dựng mẫu số: Golnas lấy phân vị 93, còn Lonij và cộng sự [12] lấy phân vị 80.	92
7.19	Đoạn khai báo danh sách cấm trong quy trình chọn đặc trưng. Mỗi nhóm cột bị cấm đi kèm lý do ngay tại chỗ khai báo.	101

7.20	Mục <i>deterministic</i> trong tài liệu tham số của LightGBM. Dòng đầu ghi tham số này chỉ dùng được với thiết bị CPU.	107
7.21	Dòng <i>Weighted Absolute Percentage Error</i> trong Bảng 1 của Temporal-Neto và cộng sự [9], cắt từ bảng chỉ số đánh giá mô hình dự báo. Công thức trùng với dạng dự án dùng. Cách chia tập và cách lọc phạm vi là thiết kế riêng của dự án.	108
7.22	Đoạn được đánh dấu trong Zhang và cộng sự [11], NREL/CP-5500-60142: các thước đo thông dụng của dự báo quang điện gồm RMSE, MBE và MAE. Dự án lấy tinh thần đánh giá bằng nhiều chỉ số đặt cạnh một mô hình đối chứng, thay vì đọc một giá trị sai số đơn lẻ.	110
7.23	Trang đầu bài báo Lundberg và Lee [10], <i>A Unified Approach to Interpreting Model Predictions</i> , NeurIPS 2017 — nguồn của phương pháp quy đóng góp mà bước này sử dụng.	114
7.24	(Trích xuất từ Notebook <code>08_explainable_ai.ipynb</code>) Biểu đồ beeswarm. Mỗi điểm là một dòng dữ liệu; vị trí ngang là giá trị SHAP, màu là độ lớn của chính đặc trưng đó.	115
7.25	(Trích xuất từ Notebook <code>08_explainable_ai.ipynb</code>) Biểu đồ thác cho hai dự báo tương phản. Trên: trường hợp các đặc trưng cùng đẩy dự báo lên. Dưới: trường hợp cùng kéo xuống.	117
7.26	Trang 1 của ứng dụng — giám sát chuỗi thời gian theo trạm.	118
7.27	Trang 2 của ứng dụng — giải thích dự báo bằng SHAP.	119
7.28	Trang 3 của ứng dụng — dự báo và phân tích giả định.	120

Danh sách bảng

2.1	Bảng so sánh lý thuyết Inmon vs. Kimball	21
3.1	Từ điển dữ liệu tệp campus_meta.csv	29
3.2	Từ điển dữ liệu tệp Solar_Site_Details.csv	30
3.3	Từ điển dữ liệu tệp Solar_Energy_Generation.csv	30
3.4	Từ điển dữ liệu tệp calender.csv	31
3.5	Từ điển dữ liệu tệp open_meteo_weather_raw.csv	31
3.6	Cấu trúc vật lý bảng chiều trạm năng lượng (dim_solar_site)	35
3.7	Cấu trúc vật lý bảng chiều địa lý (dim_geography)	35
3.8	Cấu trúc vật lý bảng chiều ngày (dim_date)	35
3.9	Cấu trúc vật lý bảng chiều thời gian (dim_time)	36
3.10	Cấu trúc vật lý bảng chiều danh mục thời tiết (dim_weather_type) . .	36
3.11	Cấu trúc vật lý bảng sự kiện sản lượng (fact_solar_energy_gen) . .	36
3.12	Cấu trúc vật lý bảng sự kiện thời tiết (fact_weather)	37
4.1	Bảng thống kê kiểm tra chất lượng dữ liệu ban đầu trong Staging	43
7.1	Số ứng viên của từng cơ chế và phần còn lại sau khi bắt cả hai cùng đồng ý. Ngưỡng dùng cho GMM là $P_{GMM} < 0,02$; Isolation Forest chạy với contamination = 0,03. Dừng lại trên máy bằng 07_local_gmm_if_audit.py; số liệu ghi ở 07_local_gmm_if_summary.json.	63
7.2	Đối chiếu số cờ do notebook dựng lại với số cờ tầng ETL đã ghi. Đọc từ ô kết quả của notebook 05d_thuc_nghiem_rao_chan_vat_ly.ipynb.	64
7.3	Số dòng và sản lượng bị loại khi đổi hệ số nhân của safe_IQR. Tỷ lệ tính trên tổng 9,31 triệu kWh. Đọc từ tệp kết quả 05d_rao_chan_vat_ly/quet_he_so_safe_iqr.csv.	65
7.4	Ánh xạ giữa bước trong quy trình và notebook thực hiện.	67
7.5	Thống kê mô tả sản lượng theo ba phạm vi. Đọc từ ô kết quả của notebook 02_EDA.ipynb.	71
7.6	Tự tương quan của chuỗi sản lượng tại các mốc trễ đáng chú ý, trạm 27, 51.652 bước liên tục. Đọc từ ô kết quả của notebook 02_EDA.ipynb. . .	73
7.7	Tương quan với sản lượng, tính trên phạm vi đo thật ban ngày, kèm cột đối chiếu khi gộp cả ban đêm. Đọc từ ô kết quả của notebook 02_EDA.ipynb. .	74

7.8	Ranh giới thời gian, kích thước và số trạm của ba fold, đọc từ các tệp <code>fold*_train_selected.parquet</code> và <code>fold*_val_selected.parquet</code>	76
7.9	Số dòng huấn luyện có nhãn rơi sang vùng kiểm định, tính trên từng fold và từng tầm dự báo. Đọc từ ô kết quả của notebook <code>05b_thuc_nghiem_tham_so_hardcode.ipynb</code> , Thí nghiệm 9. . . .	77
7.10	Ba nhóm đặc trưng sinh tại notebook <code>03_1_features_time.ipynb</code> . Cột cuối ghi tham số thực tế khai báo trong notebook.	78
7.11	Ba mốc trễ đã được thử và quyết định tương ứng, ghi tại ô khai báo LAGS của notebook <code>03_1_features_time.ipynb</code>	80
7.12	Mô hình nháp dùng ở cổng lệch pha so với mô hình cuối. Đọc từ ô cấu hình cổng lệch pha trong notebook <code>06_1_train_mae.ipynb</code>	81
7.13	Ba chi tiết cài đặt của bước hình học Mặt Trời.	84
7.14	Hệ số hiệu chỉnh trời quang <code>cs_factor</code> theo từng fold. Đọc từ ô kết quả của notebook <code>03_2_features_spatial.ipynb</code>	85
7.15	Quy mô trạm tính trên tập huấn luyện, tám trạm lớn nhất. Đọc từ ô kết quả của notebook <code>03_2_features_spatial.ipynb</code>	87
7.16	Năm đặc trưng tương tác, tỷ lệ khuyết trên tập huấn luyện và tương quan Pearson với mục tiêu tính trên 763.740 dòng ban ngày. Đọc từ ô kết quả của notebook <code>03_3_features_aggregate.ipynb</code>	88
7.17	Công thức các đặc trưng dẫn xuất. Đọc từ mã nguồn notebook <code>03_2_features_spatial.ipynb</code> và <code>03_3_features_aggregate.ipynb</code>	89
7.18	So sánh dùng đặc trưng tất định tại T với tại $T+h$, đo bằng MAE của đường bao $\text{site_scale} \times \max(\sin h, \epsilon)$ so với sản lượng thật tại $T+15$ phút, trên 999.010 dòng ban ngày của tập Phát triển. Kiểm chứng bằng <code>srcs/05_machine_learning/kiem_chung_bao_cao_v4.py</code> , mục 10.	91
7.19	Quét mức phân vị dùng làm cận cắt, chạy trên tập kiểm định . Đọc từ tệp kết quả <code>05_selected/quet_muc_phan_vi_nguong_cat.csv</code>	93
7.20	Tỷ lệ nhãn bị ngưỡng 1,3764 cắt, tách theo giờ trong ngày, tính trên tập huấn luyện. Kiểm chứng bằng <code>srcs/05_machine_learning/kiem_chung_bao_cao_v4.py</code> , mục 1.	94
7.21	Quét bốn tham số cố định, chấm trên 779.099 dòng của tập kiểm định. Đọc từ tệp kết quả <code>05b_thuc_nghiem_tham_so/thuc_nghiem_tham_so_hardcode.csv</code>	95
7.22	Số điểm bị ngưỡng CLIP_CSI cắt. Đọc từ tệp kết quả <code>05b_thuc_nghiem_tham_so/thuc_nghiem_clip_csi.csv</code>	96

7.23	Phân bố nhãn chẩn đoán trên 86 đặc trưng số. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.	97
7.24	Tám cột trùng lặp gần hoàn hảo và cột đại diện được giữ lại. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.	98
7.25	Tám đặc trưng có hệ số phóng đại phương sai cao nhất. Giá trị 9999 là mức chặn trên mà notebook đặt cho trường hợp cộng tuyến gần hoàn hảo. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.	98
7.26	Bảy đặc trưng dẫn đầu theo điểm quan trọng biến của hồi quy bình phương tối thiểu riêng phần, đặt cạnh hệ số phóng đại phương sai của chính chúng. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.	99
7.27	Mười đặc trưng có điểm thông tin tương hỗ cao nhất. Đọc từ ô kết quả của notebook 05_select_features.ipynb.	100
7.28	Bốn mươi đặc trưng được chọn, xếp theo nhóm. Đọc từ 05_selected/selected_features.json.	104
7.29	Miền tìm kiếm siêu tham số khai báo cho Optuna. Đọc từ hàm tham_so_co_ban trong notebook 06_1_train_mae.ipynb.	105
7.30	Siêu tham số tốt nhất do Optuna chọn, theo từng hàm mất mát và tầm dự báo. Cả sáu cấu hình dùng chung random_state = 42, deterministic = true và max_bin = 127 trên CPU. Đọc từ khóa best_params trong tệp kết quả của mỗi notebook huấn luyện.	105
7.31	Sai số trên tập kiểm định, phạm vi đo thật ban ngày. Trong mỗi tầm, cả ba hàm được chấm trên đúng cùng số quan sát. Đọc từ metrics_val.json của sáu cấu hình dưới 06_train/.	106
7.32	Sai số WAPE trên tập test niêm phong theo ba phạm vi. Đọc từ ô kết quả của notebook 07_final_test.ipynb và tệp metrics_overall.json của từng tầm.	109
7.33	Cùng mô hình, ba phạm vi đánh giá. Đọc từ 08_baseline_prophet_test/optuna_vs_current_wape.csv. . .	110
7.34	Đối chứng với Prophet trên cùng tập dòng. Đọc từ 08_baseline_prophet_test/prophet_bang_bao_cao.csv và prophet_test_summary.json.	111
7.35	Độ lệch đỉnh theo vị trí của đỉnh thực tế trong khối giờ. Đọc từ tệp kết quả 09_kiem_chung_tre_pha/lech_theo_vi_tri_trong_gio_h1.csv.	113
7.36	Mười đặc trưng có tầm quan trọng tổng thể lớn nhất, đo bằng trung bình trị tuyệt đối giá trị SHAP. Đọc từ 08_explain/shap_importance.csv.	114
7.37	Ba dự báo được mổ xẻ. Đọc từ 08_explain/local_shap_cases.csv.	116

Danh mục Từ viết tắt

Ký hiệu/Từ viết tắt	Ý nghĩa đầy đủ
API	Application Programming Interface (Giao diện lập trình ứng dụng)
ARIMA	AutoRegressive Integrated Moving Average
AWS	Amazon Web Services
BI	Business Intelligence (Phân tích thông minh doanh nghiệp)
CF	Capacity Factor (Hệ số công suất)
CSDL	Cơ sở dữ liệu
CT	Current Transformer (Cảm biến dòng điện)
DWH	Data Warehouse (Kho dữ liệu)
EDA	Exploratory Data Analysis (Phân tích khám phá dữ liệu)
ETL	Extract, Transform, Load (Trích xuất, Biến đổi, Nạp)
FK	Foreign Key (Khóa ngoại)
GCP	Google Cloud Platform
IoT	Internet of Things (Internet vạn vật)
IQR	Interquartile Range (Khoảng tứ phân vị)
kWp	Kilowatt-peak (Công suất đỉnh cực đại)
LSTM	Long Short-Term Memory
PK	Primary Key (Khóa chính)
PR	Performance Ratio (Hệ số hiệu suất)
PV	Photovoltaic (Quang điện - Năng lượng mặt trời)
UI/UX	User Interface / User Experience (Giao diện / Trải nghiệm người dùng)
WMO	World Meteorological Organization (Tổ chức Khí tượng Thế giới)
XGBoost	Extreme Gradient Boosting

Tổng quan Đề tài và Bài toán Nghiên cứu

1.1 Bối cảnh thực tế và lý do chọn đề tài

Năng lượng mặt trời đang ngày càng đóng vai trò quan trọng trong cơ cấu năng lượng tái tạo toàn cầu. Theo Cơ quan Năng lượng Quốc tế (IEA), công suất lắp đặt điện mặt trời trên toàn thế giới đã vượt mốc 1.600 GW vào cuối năm 2023, với tốc độ tăng trưởng trung bình 25%/năm trong thập kỷ qua. Tại Việt Nam, chính sách khuyến khích phát triển điện mặt trời áp mái và điện mặt trời tập trung đã đưa tổng công suất lắp đặt lên hơn 16.500 MW. Tuy nhiên, hiệu suất thực tế của các hệ thống quang điện (PV) thường sai lệch đáng kể so với giá trị thiết kế do ảnh hưởng của nhiều yếu tố như: điều kiện thời tiết biến đổi, suy giảm chất lượng tấm pin, bụi bẩn, bóng che và lỗi thiết bị.

Bài toán phân tích hiệu suất và phát hiện sớm các bất thường trong vận hành là then chốt giúp tối ưu hoá hiệu quả đầu tư và nâng cao độ tin cậy của lưới điện. Lý do nhóm chọn đề tài này bao gồm:

- **Tính thực tiễn:** Dự báo sản lượng và phát hiện bất thường có ứng dụng trực tiếp cho các doanh nghiệp vận hành nhà máy điện mặt trời.
- **Tính liên ngành:** Kết hợp phân tích dữ liệu, thống kê, học máy và kiến trúc kho dữ liệu trong một đề tài thống nhất.
- **Nguồn dữ liệu mở:** Dữ liệu từ Open-Meteo API miễn phí, chất lượng cao và phủ rộng toàn cầu.
- **So sánh đa vùng:** Phân tích đồng thời dữ liệu từ nhiều khu vực tại Úc để đánh giá tổng quát về hiệu suất PV.

1.2 Bài toán kinh doanh và các khó khăn cần giải quyết

Trong vận hành thực tế các trạm điện mặt trời, ban quản lý thường đối mặt với các khó khăn lớn:

- **Tác động thời tiết bất định:** Sự thay đổi của mây che phủ, bức xạ và nhiệt độ môi trường khiến sản lượng điện biến động liên tục, gây khó khăn cho việc điều

phối lưới điện.

- **Suy hao và hỏng hóc thiết bị:** Các tấm pin bị bám bụi, inverter bị lỗi phần sụn hoặc quá nhiệt làm suy giảm đáng kể hiệu suất phát điện mà không được phát hiện kịp thời.
- **Sai lệch số liệu giám sát:** Cảm biến đo bức xạ hoặc cảm biến CT đo dòng điện bị nhiễu xung điện đột ngột hoặc lệch pha tần suất dữ liệu (Granularity Mismatch) giữa dữ liệu sản lượng (15 phút) và dữ liệu thời tiết (1 giờ) khiến phân tích sai lệch.

Hệ quả của việc không giải quyết các vấn đề trên là doanh nghiệp ra quyết định chậm trễ, tổn thất tài chính lớn do mất sản lượng, và dữ liệu thu thập bị bẩn dẫn đến các mô hình dự báo không chính xác.

1.3 Mục tiêu dự án và Kết quả dự kiến

Dự án tốt nghiệp đặt ra các mục tiêu cốt lõi sau:

1. Thiết kế và triển khai kho dữ liệu (*Data Warehouse*) tích hợp đồng bộ dữ liệu sản lượng và thời tiết theo mô hình Galaxy Schema (Fact Constellation) kết hợp phân nhánh Data Marts chuyên biệt.
2. Xây dựng pipeline dữ liệu tự động làm sạch (xử lý khuyết thiếu, lọc nhiễu ban đêm, phát hiện bất thường cảm biến).
3. Thực hiện phân tích khám phá chuyên sâu (EDA) để rút ra các insight vận hành quan trọng như hiện tượng suy giảm hiệu suất do nhiệt độ và độ nhiễu ban đêm.
4. Xây dựng hệ thống dữ liệu đáp ứng đồng thời hiệu năng truy vấn báo cáo (OLAP) và hiệu năng huấn luyện/dự báo học máy (MLOps) mà không làm quá tải tài nguyên Cloud.
5. Huấn luyện các mô hình dự báo sản lượng Baseline (ARIMA, Prophet) và so sánh hiệu năng.

Kết quả dự kiến (Sneak Peek): Một hệ thống Dashboard Tableau trực quan hóa mượt mà cho phép các nhà quản lý theo dõi toàn diện hiệu suất vận hành của 42 trạm tại Úc, tự động cảnh báo lỗi cảm biến và hiển thị dự báo sản lượng cho các chu kỳ tiếp theo với độ tin cậy cao.

1.4 Đối tượng và phạm vi nghiên cứu

- **Đối tượng nghiên cứu:** Hiệu suất phát điện của hệ thống quang điện (PV) và các yếu tố khí tượng viễn thám (bức xạ sóng ngắn, nhiệt độ, độ phủ mây, lượng mưa).
- **Phạm vi không gian:** 42 trạm điện mặt trời tại Úc.
- **Phạm vi thời gian:** Dữ liệu lịch sử từ 01/01/2020 đến 30/04/2022.

1.5 Bố cục báo cáo

Báo cáo dự án tốt nghiệp được cấu trúc thành 7 chương chính như sau:

- **Chương 1:** Tổng quan Đề tài và Bài toán Nghiên cứu.
- **Chương 2:** Cơ sở Lý thuyết (các mô hình dự báo, phát hiện outlier và DWH).
- **Chương 3:** Thu thập Dữ liệu và Thiết kế Kho dữ liệu.
- **Chương 4:** Quy trình ETL, Làm sạch và Biến đổi Dữ liệu.
- **Chương 5:** Phân tích Khám phá Dữ liệu (EDA) và Trực quan hóa.
- **Chương 6:** Mô hình hóa và Dự báo Sản lượng Baseline.
- **Chương 7:** Đánh giá Dự án, Đề xuất và Theo dõi Vận hành.

Cơ sở Lý thuyết

2.1 Tổng quan về Năng lượng mặt trời và Bức xạ quang điện

Hệ thống quang điện (PV) chuyển đổi năng lượng bức xạ mặt trời trực tiếp thành điện năng thông qua hiệu ứng quang điện trong chất bán dẫn. Hiệu suất chuyển đổi và khả năng vận hành của hệ thống phụ thuộc chặt chẽ vào các chỉ số lý thuyết sau:

- **Performance Ratio (PR):** Tỷ lệ đánh giá hiệu suất nguồn lưới, được xác định bằng tỷ số giữa sản lượng điện thực tế tạo ra và sản lượng lý thuyết trong điều kiện bức xạ lý tưởng. PR phản ánh mức độ tổn hao năng lượng do nhiệt độ, bụi bẩn và hiệu suất của bộ biến đổi (Inverter).
- **Capacity Factor (CF):** Hệ số công suất, được tính bằng tỷ lệ giữa sản lượng điện thực tế thu được trong một khoảng thời gian so với sản lượng điện tối đa mà trạm có thể phát nếu vận hành liên tục ở công suất thiết kế cực đại.
- **Specific Yield:** Sản lượng điện đặc trưng, biểu thị lượng điện năng tạo ra trên mỗi đơn vị công suất đỉnh lắp đặt (đo bằng đơn vị kWh/kWp), hỗ trợ so sánh hiệu suất giữa các trạm có quy mô khác nhau.

2.2 Kiến trúc Kho dữ liệu đa chiều (Data Warehouse)

Kiến trúc kho dữ liệu đa chiều được thiết kế theo phương pháp luận của Ralph Kimball, tập trung vào việc mô hình hóa dữ liệu nhằm tối ưu hóa hiệu năng truy vấn cho các bài toán phân tích thông minh (BI) và học máy.

2.2.1 Mô hình hóa đa chiều (Dimensional Modeling)

Mô hình hóa đa chiều phân tách dữ liệu thành hai nhóm chính:

- **Bảng sự kiện (Fact Table):** Lưu trữ các chỉ số đo lường định lượng (Measures) phát sinh từ các sự kiện nghiệp vụ (ví dụ: sản lượng điện phát ra, các thông số thời tiết đo được). Bảng Fact thường chứa khối lượng dữ liệu rất lớn và liên kết với các bảng chiều qua các khóa ngoại.

- **Bảng chiều (Dimension Table):** Lưu trữ các thuộc tính mô tả ngữ cảnh của sự kiện (thời gian, địa điểm, thông tin kỹ thuật của thiết bị). Các bảng chiều cung cấp các trục phân tích chéo, làm bộ lọc cho các câu lệnh truy vấn dữ liệu.

2.2.2 Lược đồ Thiên hà (Galaxy Schema)

Trong các hệ thống phân tích tích hợp nhiều quy trình nghiệp vụ, lược đồ Thiên hà (Galaxy Schema hay Fact Constellation Schema) được sử dụng khi có nhiều bảng sự kiện dùng chung các bảng chiều được chuẩn hóa (Conformed Dimensions). Mô hình này cho phép:

- Hợp nhất nhiều luồng sự kiện có tần suất ghi nhận khác nhau (ví dụ: dữ liệu đo sản lượng điện theo chu kỳ phút và dữ liệu thời tiết theo chu kỳ giờ) mà không gây trùng lặp thông tin thừa.
- Thực hiện phân tích liên thông (Drill-through) giữa các bảng sự kiện khác nhau dựa trên các chiều chung như thời gian và không gian địa lý.

2.2.3 Phương pháp tiếp cận Top-Down (Triết lý kiến trúc của Bill Inmon)

Trái ngược với phương pháp tiếp cận Bottom-Up của Ralph Kimball - vốn tập trung xây dựng các Data Mart trước rồi mới tích hợp thành một kho dữ liệu tổng thể - triết lý Top-Down của Bill Inmon định nghĩa kho dữ liệu (Data Warehouse) là một thực thể lưu trữ tập trung, duy nhất và đóng vai trò là Single Source of Truth (Nguồn sự thật duy nhất) của toàn bộ doanh nghiệp.

- **Bản chất luồng dữ liệu:** Dữ liệu từ các hệ thống nguồn (Operational Systems) sau khi trích xuất sẽ được đổ trực tiếp vào một kho lưu trữ trung tâm được chuẩn hóa cấu trúc chặt chẽ. Từ lõi dữ liệu sạch thống nhất này, các phân nhánh dữ liệu chuyên biệt phục vụ cho các mục đích cụ thể (Data Marts) mới được phân tách và cấu trúc lại.
- **Ưu điểm lý thuyết:** Đảm bảo tính nhất quán dữ liệu tối đa trên toàn hệ thống, triệt tiêu hoàn toàn rủi ro sai lệch số liệu giữa các phòng ban hoặc giữa các tác vụ phân tích khác nhau (như báo cáo trực quan hóa và huấn luyện học máy).

Dưới đây là bảng đối sánh chi tiết giữa hai phương pháp tiếp cận kinh điển của Bill Inmon và Ralph Kimball:

Tiêu chí đối sánh	Tiếp cận Top-Down (Bill Inmon)	Tiếp cận Bottom-Up (Ralph Kimball)
Kiến trúc tổng thể	Tập trung (Centralized DWH) trước, phân tán (Data Marts) sau.	Phân tán (Data Marts) trước, hợp nhất (DWH) sau.
Mô hình hóa tầng lõi	Chuẩn hóa cấu trúc để giảm thiểu tối đa dư thừa dữ liệu (3NF).	Mô hình hóa đa chiều (Dimensional Modeling) dựa trên các bảng Fact và Dimension.
Tính nhất quán	Rất cao, do mọi dữ liệu tiêu thụ đều được kế thừa từ một nguồn lõi duy nhất.	Khó kiểm soát hơn, dễ xảy ra hiện tượng lệch pha định nghĩa giữa các Data Mart độc lập.
Độ linh hoạt hạ tầng	Thích hợp cho hệ thống tích hợp lớn, đa mục đích sử dụng (BI, Data Science, Data Streaming).	Thích hợp cho các dự án cần triển khai nhanh, tập trung giải quyết một quy trình nghiệp vụ đơn lẻ.

Bảng 2.1: Bảng so sánh lý thuyết Inmon vs. Kimball

2.3 Quy trình Trích xuất, Biến đổi và Nạp dữ liệu (ETL Pipeline)

Quy trình ETL (Extract - Transform - Load) đóng vai trò nền tảng trong việc làm sạch và chuẩn hóa dữ liệu trước khi đưa vào kho lưu trữ tập trung.

2.3.1 Lý thuyết về Nội suy dữ liệu khuyết thiếu (Data Imputation)

Dữ liệu chuỗi thời gian từ các thiết bị đo lường vật lý thường gặp hiện tượng mất mát dữ liệu do lỗi truyền thông hoặc hỏng hóc cảm biến. Các phương pháp toán học được áp dụng để khôi phục dữ liệu khuyết bao gồm:

- **Nội suy dựa trên ràng buộc vật lý (Constraint-based Imputation):** Sử dụng các quy luật vật lý tự nhiên để gán giá trị trực tiếp. Đối với năng lượng mặt trời, sản lượng điện tối đa vào ban đêm được gán cứng bằng 0 dựa trên điều kiện bức xạ mặt trời triệt tiêu.
- **Nội suy tuyến tính (Linear Interpolation):** Giả định dữ liệu thay đổi đều giữa các mốc thời gian lân cận, phù hợp cho các khoảng khuyết ngắn:

$$y = y_1 + \frac{x - x_1}{x_2 - x_1}(y_2 - y_1) \quad (2.1)$$

- **Nội suy Cubic Spline:** Sử dụng các đa thức bậc ba cục bộ để tạo ra đường nội

suy mượt mà và bảo toàn đạo hàm cấp một và cấp hai tại các điểm nút. Cho tập hợp các điểm (x_i, y_i) với $i = 0, 1, \dots, n$, hàm nội suy $S(x)$ trên khoảng $[x_i, x_{i+1}]$ được định nghĩa là:

$$S_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3 \quad (2.2)$$

Để đảm bảo tính liên tục của hàm, các hệ số phải thỏa mãn các điều kiện biên và trơn:

$$S_i(x_i) = y_i, \quad S_i(x_{i+1}) = y_{i+1} \quad (2.3)$$

$$S'_i(x_{i+1}) = S'_{i+1}(x_{i+1}) \quad (2.4)$$

$$S''_i(x_{i+1}) = S''_{i+1}(x_{i+1}) \quad (2.5)$$

Với điều kiện biên tự nhiên thông dụng: $S'''(x_0) = S'''(x_n) = 0$.

- **Nội suy dựa trên mô hình hồi quy (Regression Imputation):** Khôi phục giá trị khuyết thiếu bằng cách ước lượng dựa trên các biến độc lập liên quan. Giả thuyết mô hình tuyến tính có dạng:

$$Y = X\beta + \varepsilon \quad (2.6)$$

Trong đó Y là biến cần nội suy, X là ma trận các biến dự báo quan sát được (các biến khí tượng lân cận, các trẻ thời gian). Vectơ hệ số hồi quy $\hat{\beta}$ được ước lượng bằng phương pháp bình phương tối thiểu cực tiểu (OLS) trên tập dữ liệu đầy đủ X_{obs} và Y_{obs} :

$$\hat{\beta} = (X_{\text{obs}}^T X_{\text{obs}})^{-1} X_{\text{obs}}^T Y_{\text{obs}} \quad (2.7)$$

Giá trị khuyết thiếu của bản ghi thứ m sau đó được bù đắp bằng:

$$\hat{y}_m = x_m \hat{\beta} \quad (2.8)$$

2.3.2 Chiến lược nạp dữ liệu tối ưu hóa giao dịch

Khi xử lý các bảng sự kiện có quy mô hàng triệu bản ghi, việc nạp dữ liệu trực tiếp dễ gây tắc nghẽn tài nguyên và khóa bảng cơ sở dữ liệu. Các kỹ thuật toán học và hệ thống được áp dụng bao gồm:

- **Nạp theo phân đoạn (Batching):** Phân chia giao dịch lớn thành các nhóm nhỏ dựa trên các phân đoạn thời gian (ví dụ: theo tháng) để giảm tải cho nhật ký giao dịch (Transaction Log).
- **Sinh khóa đại diện tự động (Surrogate Key Generation):** Thiết lập cơ chế

tạo khóa tự động tăng tiến tuần tự để tối ưu chỉ mục (Index) và tránh trùng lặp dữ liệu trong môi trường phân tán.

- **Kiểm chứng toàn vẹn sau nạp (Post-load Validation):** So sánh tổng kiểm tra bản ghi giữa các tầng lưu trữ nhằm phát hiện lỗi mất mát dữ liệu và kích hoạt cơ chế hoàn tác (Rollback) khi xảy ra sai sót.

2.4 Các phương pháp Phát hiện bất thường dữ liệu (Anomaly Detection)

Phát hiện bất thường dữ liệu nhằm nhận diện các hành vi bất thường của thiết bị hoặc lỗi ghi nhận số liệu.

2.4.1 Phương pháp thống kê Z-Score

Z-Score xác định mức độ lệch của một điểm dữ liệu so với giá trị trung bình theo đơn vị độ lệch chuẩn:

$$Z = \frac{x - \mu}{\sigma} \quad (2.9)$$

Trong đó μ là giá trị trung bình và σ là độ lệch chuẩn của phân phối. Điểm dữ liệu bị coi là ngoại lai (Outlier) nếu nằm ngoài khoảng giới hạn thường gặp (ví dụ: $|Z| > 3$).

2.4.2 Phương pháp khoảng tứ phân vị IQR (Interquartile Range)

IQR là công cụ thống kê mạnh mẽ không phụ thuộc vào giả định phân phối chuẩn của dữ liệu. Khoảng tứ phân vị được xác định bởi:

$$\text{IQR} = Q_3 - Q_1 \quad (2.10)$$

Trong đó Q_1 và Q_3 lần lượt là tứ phân vị thứ nhất (25%) và thứ ba (75%). Ngưỡng phát hiện bất thường được thiết lập tại giới hạn:

$$[\text{Lower Bound}, \text{Upper Bound}] = [Q_1 - 1.5 \cdot \text{IQR}, Q_3 + 1.5 \cdot \text{IQR}] \quad (2.11)$$

2.4.3 Phương pháp Trung bình trượt và IQR cục bộ (Rolling IQR)

Đối với chuỗi thời gian có tính xu hướng và mùa vụ mạnh, việc sử dụng các chỉ số thống kê toàn cục dễ dẫn đến kết quả sai lệch. Do đó, phương pháp Rolling IQR cục bộ phân nhóm theo thực thể được áp dụng thông qua thuật toán sau:

1. Cho chuỗi thời gian sản lượng điện $y(s, t)$ của trạm s tại thời điểm t , ta tính trung bình trượt cục bộ trong cửa sổ thời gian W có độ dài 1 giờ:

$$\mu(s, t) = \frac{1}{|W|} \sum_{\tau \in W} y(s, \tau) \quad (2.12)$$

2. Xác định độ lệch tuyệt đối $d(s, t)$ của điểm dữ liệu so với trung bình trượt cục bộ:

$$d(s, t) = |y(s, t) - \mu(s, t)| \quad (2.13)$$

3. Gom nhóm toàn bộ độ lệch $d(s, t)$ theo tổ hợp thực thể trạm s và giờ trong ngày $h = \text{hour}(t) \in [0, 23]$ để tạo ra tập hợp cục bộ $G_{s,h}$.
4. Với mỗi tập hợp $G_{s,h}$, tính toán khoảng tứ phân vị cục bộ:

$$\text{IQR}_{s,h} = Q_3(G_{s,h}) - Q_1(G_{s,h}) \quad (2.14)$$

5. Ngưỡng biên trên bất thường $U_{s,h}$ của nhóm được xác định là:

$$U_{s,h} = Q_3(G_{s,h}) + 1.5 \cdot \text{IQR}_{s,h} \quad (2.15)$$

6. Bản ghi tại thời điểm t thuộc trạm s bị gán cờ ngoại lai nếu hiệu số lệch tuyệt đối vượt quá giới hạn trên cục bộ:

$$f(s, t) = \begin{cases} 1 & \text{nếu } d(s, t) > U_{s,h} \\ 0 & \text{ngược lại} \end{cases} \quad (2.16)$$

2.5 Cơ sở thuật toán Dự báo chuỗi thời gian

- **Mô hình ARIMA:** Mô hình AutoRegressive Integrated Moving Average kết hợp các thành phần tự hồi quy (p), sai phân (d) và trung bình trượt (q):

$$\phi(B)(1 - B)^d X_t = \theta(B)\varepsilon_t \quad (2.17)$$

- **Mô hình Prophet:** Mô hình phân tách chuỗi thời gian do Meta phát triển, xử lý tốt tính mùa vụ mạnh và các giá trị khuyết thiếu:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t \quad (2.18)$$

với $g(t)$ đại diện cho xu hướng, $s(t)$ cho tính mùa vụ, $h(t)$ cho ngày lễ và ε_t cho sai số ngẫu nhiên.

Thu thập Dữ liệu và Thiết kế Kiến trúc Kho dữ liệu

3.1 Kiến trúc Tổng thể Hệ thống Dữ liệu (Data Architecture Overview)

Nhằm đáp ứng đồng thời hai mục tiêu cốt lõi của dự án là (1) Trực quan hóa dữ liệu phục vụ quản trị (Business Intelligence) và (2) Xây dựng mô hình học máy dự báo (Machine Learning), hệ thống dữ liệu của dự án được thiết kế theo kiến trúc đa tầng (Multi-tier Architecture). Luồng dữ liệu (Data Flow) di chuyển qua 4 lớp chính như sau:

1. **Raw Data (Dữ liệu thô):** Dữ liệu lịch sử dạng file `.csv` từ các trạm vật lý và dữ liệu khí tượng viễn thám trích xuất qua Open-Meteo API.
2. **Staging Area (Vùng dữ liệu tạm):** Nơi tiếp nhận và lưu trữ nguyên bản (1:1) dữ liệu thô vào hệ quản trị CSDL. Lớp này đóng vai trò như một bộ đệm (buffer) để giảm tải cho các nguồn cấp dữ liệu và chuẩn bị cho quá trình chuyển đổi.
3. **Data Warehouse (Kho dữ liệu trung tâm):** Tổ chức theo mô hình *Fact Constellation Schema* (Lược đồ Thiên hà), lưu trữ dữ liệu đã qua làm sạch, chuẩn hóa (Cleansing & Transformation). Đây là Single Source of Truth của toàn bộ hệ thống.
4. **Data Marts (Siêu thị dữ liệu):** Từ Data Warehouse, dữ liệu được phân nhánh thành hai Data Mart độc lập, được thiết kế đặc thù (Tailored-design) để tối ưu hóa hiệu năng truy vấn cho công cụ BI (Tableau) và định dạng chuẩn (Wide-table) cho việc huấn luyện mô hình ML.

3.1.1 Tiếp cận Top-Down (Inmon Approach)

Hệ thống lưu trữ và xử lý dữ liệu của dự án được xây dựng dựa trên phương pháp tiếp cận *Top-Down* (từ trên xuống) theo triết lý thiết kế kho dữ liệu của Bill Inmon. Luồng dữ liệu di chuyển một chiều từ các nguồn thô, tập trung tại một Kho dữ liệu trung tâm duy nhất (Single Source of Truth), sau đó mới phân rã thành các Siêu thị dữ liệu (Data Marts) chuyên biệt.

Việc lựa chọn kiến trúc *Top-Down* thay vì *Bottom-Up* (gồm các Data Mart độc lập lại thành DWH) mang lại ba lợi ích chiến lược cho hệ thống dự báo điện mặt trời của dự

án:

- **Đảm bảo tính nhất quán tối đa (Data Consistency):** Vì dữ liệu sản lượng và khí tượng được làm sạch, xử lý Outliers và đồng bộ hóa ngay tại tầng Data Warehouse trung tâm, hai nhánh Data Mart (BI và ML) phía sau sẽ luôn kế thừa cùng một tập dữ liệu chuẩn. Điều này triệt tiêu hoàn toàn hiện tượng lệch pha số liệu (ví dụ: sản lượng tổng hiển thị trên Dashboard Tableau khác với tổng sản lượng mà mô hình Machine Learning nhận được để huấn luyện).
- **Khả năng mở rộng kiến trúc (Scalability):** Trong tương lai, nếu doanh nghiệp muốn mở rộng thêm các mục đích sử dụng dữ liệu mới (ví dụ: nhánh Data Mart dành cho bộ phận Tài chính tính toán doanh thu bán điện FiT, hoặc bộ phận Kiểm toán Carbon), kỹ sư dữ liệu chỉ cần tạo thêm các phân nhánh (Views/Materialized Views) từ Data Warehouse trung tâm mà không cần thiết kế lại luồng ETL/ELT gốc từ các trạm pin.
- **Tối ưu hóa quản trị dữ liệu (Centralized Data Governance):** Việc kiểm soát chất lượng dữ liệu, phân quyền truy cập, và định nghĩa các thuật ngữ nghiệp vụ (Metadata) được thực hiện tập trung tại Supabase DWH, giúp giảm thiểu chi phí vận hành và bảo trì hệ thống.

3.2 Phương pháp thu thập dữ liệu thô (Extract)

Dự án thu thập dữ liệu từ hai nguồn chính:

1. **Dữ liệu giám sát trạm phát điện thực tế:** Ghi nhận sản lượng điện của 42 trạm tại Úc dưới dạng tệp tin CSV cục bộ và các thông tin cấu hình trạm.
2. **Dữ liệu khí tượng viễn thám:** Thu thập từ Open-Meteo API. Quy trình gọi API sử dụng tọa độ địa lý (vĩ độ, kinh độ) của các trạm để tải về chuỗi thời gian khí tượng theo giờ bao gồm bức xạ sóng ngắn, nhiệt độ, lượng mưa và mây che phủ.

3.2.1 Trích xuất dữ liệu khí tượng qua Open-Meteo API

Dữ liệu khí tượng viễn thám được thu thập tự động thông qua Open-Meteo Archive API. Quy trình sử dụng thư viện `requests` và `pandas` để đọc tọa độ (vĩ độ, kinh độ) của 42 trạm phát từ tệp danh mục `Solar_Site_Details.csv`. Các biến số quan trọng như bức xạ sóng ngắn (`shortwave_radiation`), nhiệt độ (`temperature_2m`), mã thời tiết (`weather_code`), và trạng thái ngày/đêm (`is_day`) được trích xuất theo chu kỳ giờ.

Để đảm bảo tính ổn định khi gọi API hàng loạt, mã nguồn được tích hợp cơ chế tự động xử lý lỗi vượt quá giới hạn truy cập (Rate Limit - HTTP 429). Khi máy chủ trả về mã 429, hệ thống sẽ tạm dừng (`time.sleep`) 60 giây trước khi thử lại, giúp luồng trích xuất không bị gián đoạn.

```

1 import requests
2 import pandas as pd
3 import time
4
5 # 1. Khởi tạo cấu hình tham số API
6 START_DATE = "2023-01-01"
7 END_DATE = "2023-12-31"
8 FINAL_OUTPUT_FILE = "open_meteo_weather_raw_2023.csv"
9
10 HOURLY_COLUMNS = [
11     "shortwave_radiation", "direct_radiation",
12     "diffuse_radiation", "temperature_2m",
13     "weather_code", "is_day", "cloud_cover",
14     "wind_speed_10m", "precipitation", "sunshine_duration"
15 ]
16
17 # Đọc tọa độ từ danh mục trạm
18 site_df = pd.read_csv('/content/Solar_Site_Details(1).csv')
19 url = "https://archive-api.open-meteo.com/v1/archive"
20 all_data_frames = []
21
22 # 2. Vòng lặp lấy dữ liệu và xử lý Rate Limit
23 for index, row in site_df.iterrows():
24     params = {
25         "latitude": row['lat'],
26         "longitude": row['Lon'],
27         "start_date": START_DATE,
28         "end_date": END_DATE,
29         "hourly": ", ".join(HOURLY_COLUMNS),
30         "timezone": "Asia/Ho_Chi_Minh"
31     }
32
33     success = False
34     while not success:
35         try:
36             response = requests.get(
37                 url,

```

```

38         params=params,
39         timeout=120)
40
41     if response.status_code == 200:
42         data = response.json()
43         if "hourly" in data:
44             df_site = pd.DataFrame(
45                 {"timestamp": data["hourly"]["time"]}
46             )
47             for col in HOURLY_COLUMNS:
48                 df_site[col] = data["hourly"].get(col)
49
50             df_site["SiteKey"] = row.get('SiteKey', index)
51             all_data_frames.append(df_site)
52             success = True
53         elif response.status_code == 429:
54             print("Rate limited. Waiting 60s...")
55             time.sleep(60)
56         else:
57             success = True # Bo qua neu loi dinh dang khac
58     except Exception as e:
59         time.sleep(5)
60         success = True
61
62 # Xuat tep du lieu tong hop
63 if all_data_frames:
64     final_df = pd.concat(all_data_frames, ignore_index=True)
65     final_df['timestamp'] = pd.to_datetime(final_df['timestamp'])
66     final_df.to_csv(FINAL_OUTPUT_FILE, index=False)

```

3.2.2 Thiết lập kết nối cơ sở dữ liệu Supabase

Để lưu trữ và xử lý tập dữ liệu sau khi trích xuất, dự án cấu hình hệ quản trị cơ sở dữ liệu PostgreSQL trên nền tảng Supabase (Khu vực Southeast Asia). Điểm đặc thù trong kiến trúc kết nối và nạp (Load) dữ liệu của nhóm:

- **Sử dụng Connection Pooler:** Do Supabase free tier không hỗ trợ kết nối trực tiếp qua IPv4, dự án cấu hình kết nối thông qua Supabase Pooler (host `aws-1-ap-southeast-1.pooler.supabase.com`, cổng 5432). Giao thức này hỗ trợ IPv4 ổn định cho môi trường làm việc nhóm, đồng thời quản lý và tái sử dụng các phiên kết nối để tránh tình trạng quá tải (Connection Overload).

- **Tối ưu hóa Thư viện kết nối (pg8000):** Thay vì sử dụng thư viện psycopg2 truyền thống, dự án chuyển sang sử dụng pg8000. Đây là thư viện Pure Python, giúp khắc phục triệt để lỗi thiếu hụt các thư viện hệ thống (libz.so.1, libstdc++.so.6) trên môi trường NixOS, đảm bảo mã nguồn có thể chạy mượt mà trên mọi hệ điều hành.
- **Bảo mật hệ thống:** Toàn bộ thông tin nhạy cảm bao gồm Mật khẩu cơ sở dữ liệu và Project ID được mã hóa và truyền qua tệp .env thay vì khai báo trực tiếp trong mã nguồn. Mã nguồn nạp dữ liệu vào kho được xử lý cách ly, cam kết không rò rỉ (commit) mật khẩu lên nền tảng GitHub.

Bộ dữ liệu thô được lưu trữ thành các tệp tin CSV: campus_meta.csv, Solar_Site_Details.csv, calender.csv, Solar_Energy_Generation.csv, và open_meteo_weather_raw_2023.csv.

3.3 Data Dictionary & Metadata

Sau quá trình trích xuất và thu thập, bộ dữ liệu thô được cô đọng lại thành 5 tệp tin cốt lõi (Core Datasets). Việc xây dựng từ điển dữ liệu (Data Dictionary) ở giai đoạn này giúp định nghĩa rõ ràng cấu trúc, kiểu dữ liệu và ý nghĩa của từng trường thông tin gốc trước khi thực hiện các bước biến đổi (Transform) và đưa vào Kho dữ liệu.

3.3.1 Dữ liệu Thông tin Cơ sở hạ tầng (campus_meta.csv)

Tệp lưu trữ thông tin định danh cấp cao nhất về các khu vực/cơ sở dự án. Quy mô: 5 dòng.

Bảng 3.1: Từ điển dữ liệu tệp campus_meta.csv

Tên trường	Kiểu DL	Đơn vị	Ý nghĩa & Mô tả kỹ thuật
id	Integer	-	Mã định danh duy nhất (Primary Key) cho từng cơ sở.
name	VARCHAR	-	Tên gọi chính thức của cơ sở (VD: Bundoora, Bendigo...).
capacity	Integer	kW	Sức chứa, quy mô hoạt động hoặc mức công suất thiết kế.

3.3.2 Dữ liệu Thông tin Kỹ thuật Trạm (**Solar_Site_Details.csv**)

Tập lưu trữ chi tiết cấu hình kỹ thuật, thiết bị lắp đặt và tọa độ địa lý của các trạm phát điện. Quy mô: 42 dòng.

Bảng 3.2: Từ điển dữ liệu tệp **Solar_Site_Details.csv**

Tên trường	Kiểu DL	Đơn vị	Ý nghĩa & Mô tả kỹ thuật
CampusKey	Integer	-	Mã định danh cơ sở nơi đặt trạm điện.
SiteKey	Integer	-	Mã định danh duy nhất của từng trạm phát điện.
kWp	Float	kWp	Công suất đỉnh tối đa của hệ thống.
Number of panels	Float	Tấm	Tổng số lượng tấm pin mặt trời được lắp đặt.
Panel	String	-	Thương hiệu và công suất định mức của tấm pin.
Inverter	String	-	Thông tin bộ biến đổi dòng điện (Inverter).
Optimizers	String	-	Thông tin bộ tối ưu hóa công suất đi kèm.
Metric	String	-	Đơn vị đo lường sản lượng điện năng.
lat	Float	Độ (°)	Vĩ độ địa lý (Latitude).
Lon	Float	Độ (°)	Kinh độ địa lý (Longitude).

3.3.3 Dữ liệu Sản lượng Điện (**Solar_Energy_Generation.csv**)

Bảng dữ liệu chuỗi thời gian (Fact Table) chứa sản lượng phát điện thực tế được ghi nhận liên tục theo chu kỳ 15 phút. Quy mô: 2.731.947 dòng.

Bảng 3.3: Từ điển dữ liệu tệp **Solar_Energy_Generation.csv**

Tên trường	Kiểu DL	Đơn vị	Ý nghĩa & Mô tả kỹ thuật
CampusKey	Integer	-	Mã định danh cơ sở liên kết.
SiteKey	Integer	-	Mã định danh trạm phát điện mặt trời cụ thể.
Timestamp	DateTime	-	Mốc thời gian đo đạc dữ liệu sản lượng (Chu kỳ 15 phút).
SolarGeneration	Float	kWh	Sản lượng điện năng thực tế tạo ra trong khoảng 15 phút đó.

3.3.4 Dữ liệu Thông tin Lịch trình (**calender.csv**)

Bảng dữ liệu đánh dấu các sự kiện thời gian theo cấp độ ngày, giúp phân tích các yếu tố hành vi ảnh hưởng đến nhu cầu tiêu thụ và vận hành. Quy mô: 2.313 dòng.

Bảng 3.4: Từ điển dữ liệu tệp `calender.csv`

Tên trường	Kiểu DL	Đơn vị	Ý nghĩa & Mô tả kỹ thuật
date	Date	-	Mốc thời gian theo ngày (định dạng DD/MM/YYYY).
is_holiday	Boolean	-	Cờ đánh dấu ngày nghỉ lễ (1: Lễ, 0: Ngày thường).
is_semester	Boolean	-	Cờ đánh dấu ngày nằm trong giai đoạn học kỳ chính thức.
is_exam	Boolean	-	Cờ đánh dấu ngày diễn ra kỳ thi tại cơ sở.

3.3.5 Dữ liệu Khí tượng Viễn thám (**open_meteo_weather_raw.csv**)

Chuỗi thời gian chứa các chỉ số khí tượng được trích xuất qua API tương ứng với tọa độ từng trạm phát. Quy mô: 367.920 dòng.

Bảng 3.5: Từ điển dữ liệu tệp `open_meteo_weather_raw.csv`

Tên trường	Kiểu DL	Đơn vị	Ý nghĩa & Mô tả kỹ thuật
shortwave_radiation	Float	W/m ²	Tổng bức xạ sóng ngắn bề mặt. Feature có tương quan cao nhất với sản lượng điện.
direct_radiation	Float	W/m ²	Bức xạ mặt trời chiếu trực tiếp tới bề mặt.
diffuse_radiation	Float	W/m ²	Bức xạ mặt trời bị khuếch tán (do mây, bụi, sương mù).
temperature_2m	Float	°C	Nhiệt độ không khí ở độ cao 2 mét. Phục vụ đánh giá suy giảm nhiệt.
weather_code	Integer	-	Mã thời tiết theo chuẩn WMO (0: Quang đăng, 51-67: Mưa...). Phân loại Categorical tốt cho ML.


3.4 Thiết kế kiến trúc Kho dữ liệu đa chiều (Data Warehouse)

Quá trình thiết kế kho dữ liệu (Data Warehouse - DWH) được thực hiện theo phương pháp từ trên xuống (Top-down) kết hợp mô hình đa chiều của Kimball. Nhằm giải quyết bài toán dữ liệu lớn và độ lệch pha thời gian (Granularity Mismatch) giữa dữ liệu sản lượng (15 phút) và dữ liệu khí tượng (1 giờ), hệ thống được thiết kế theo cấu trúc **Lược đồ Thiên hà (Galaxy Schema / Fact Constellation)**. Quá trình này bao gồm 3 cấp độ mô hình hóa: Conceptual, Logical, và Physical.

3.4.1 Mô hình Dữ liệu Khái niệm (Conceptual Data Model)

Ở mức khái niệm, hệ thống xác định các thực thể kinh doanh cốt lõi và mối quan hệ giữa chúng mà không đi sâu vào chi tiết kỹ thuật. Mô hình khái niệm của hệ thống được phân rã thành các thực thể (như minh họa tại Hình 3.1):

- **Thực thể trung tâm (Đo lường năng lượng):** Là nơi hội tụ các chỉ số đo lường hiệu suất.
- **Các thực thể ngữ cảnh (Nguyên nhân/Điều kiện):** Bao gồm *Trạm năng lượng* (Solar site), *Vị trí địa lý*, *Ngày* (Date) và *Thời tiết*.



Hình 3.1: Sơ đồ Mô hình Dữ liệu Khái niệm (Conceptual Data Model)

Mối quan hệ cốt lõi: Vị trí địa lý, Thời tiết và Ngày có quan hệ 1-M (one-many) với Đo lường năng lượng, giúp ban quản lý hiểu rõ dữ liệu sản lượng và thời tiết dưới góc nhìn không gian và thời gian.

3.4.2 Mô hình Dữ liệu Logic (Logical Data Model)


Mô hình logic cụ thể hóa các thực thể thành các bảng và xác định các thuộc tính (attributes), khóa chính (Primary Key), khóa ngoại (Foreign Key). Dựa trên thiết kế kiến trúc (xem Hình 3.2), hệ thống gồm 5 bảng chiều và 2 bảng sự kiện:

1. Các bảng chiều dùng chung (Conformed Dimensions):

- `dim_solar_site`: Khóa chính `site_id`. Lưu thông tin thiết bị: `campus_name`, `capacity_kw`, `Number_of_panels`, `Panel`, `Inverter`, `Optimizers`, `Metric`.
- `dim_geography`: Khóa chính `geo_id`. Định vị không gian: `latitude`, `longitude`, `location_name`.
- `dim_date`: Khóa chính `date_id`. Trục ngày: `full_date`, `day`, `month`, `year`.
- `dim_time`: Khóa chính `time_id`. Trục giờ chi tiết (chu kỳ 15p): `time_string`, `hour`, `minute`.
- `dim_weather_type`: Khóa chính `weather_type_id`. Phân loại trạng thái: `weather_code`, `is_day`, `weather_condition`, `description`.

2. Các bảng sự kiện (Fact Tables):


- `fact_solar_energy_gen`: Khóa chính `gen_id`. Kết nối với Site, Geo, Date, Time. Đo lường sản lượng `energy_generated_kwh`.
- `fact_weather`: Khóa chính `weather_id`. Kết nối với Geo, Date, Time, Weather_type. Chứa các chỉ số viễn thám như `shortwave_radiation`, `temperature_c`, `cloud_cover_total`, `wind_speed`, `precipitation_mm`.



Hình 3.2: Sơ đồ Mô hình Dữ liệu Logic (Logical Data Model)

3.4.3 Mô hình Dữ liệu Vật lý (Physical Data Model)

Mô hình vật lý định nghĩa cách thức dữ liệu được lưu trữ thực tế trên hệ quản trị cơ sở dữ liệu (sơ đồ ở Hình 3.3). Ở bước này, các kiểu dữ liệu (Data Types) cụ thể (INT, FLOAT, VARCHAR, DATE) và ràng buộc khóa ngoại (Foreign Keys) được thiết lập để tối ưu hóa không gian lưu trữ và tốc độ truy vấn. Chi tiết cấu trúc vật lý của các bảng chiều được mô tả từ Bảng 3.6 đến Bảng 3.10. Các bảng sự kiện sản lượng và thời tiết được mô tả tương ứng trong Bảng 3.11 và Bảng 3.12.



Hình 3.3: Sơ đồ Mô hình Dữ liệu Vật lý (Physical Data Model)

Bảng 3.6: Cấu trúc vật lý bảng chiều trạm năng lượng (dim_solar_site)

Tên trường (Field)	Kiểu DL	Diễn giải vật lý
site_id	INT (PK)	Khóa chính của trạm.
campus_name	VARCHAR	Tên khu vực đặt trạm dưới dạng chuỗi ký tự.
capacity_kw	FLOAT	Công suất thiết kế (số thực).
Number_of_panels	INT	Tổng số lượng tấm pin (số nguyên).
Panel	VARCHAR	Thương hiệu/loại tấm pin (chuỗi ký tự).
Inverter	VARCHAR	Thông tin bộ biến đổi điện (chuỗi ký tự).
Optimizers	VARCHAR	Bộ tối ưu hóa (chuỗi ký tự).
Metric	VARCHAR	Ghi chú/tiêu chuẩn đo lường (chuỗi ký tự).

Bảng 3.7: Cấu trúc vật lý bảng chiều địa lý (dim_geography)

Tên trường (Field)	Kiểu DL	Diễn giải vật lý
geo_id	INT (PK)	Khóa chính định danh vị trí địa lý.
latitude	FLOAT	Vĩ độ (số thực).
longitude	FLOAT	Kinh độ (số thực).
location_name	VARCHAR	Tên địa danh hành chính.
capacity	INT	Tổng công suất của khu vực đặt trạm (kW).

Bảng 3.8: Cấu trúc vật lý bảng chiều ngày (dim_date)

Tên trường (Field)	Kiểu DL	Diễn giải vật lý
date_id	INT (PK)	Khóa chính đại diện ngày.
full_date	DATE	Trường lưu định dạng thời gian nguyên bản (YYYY-MM-DD).
day	INT	Ngày trong tháng (số nguyên).
month	INT	Tháng trong năm (số nguyên).
year	INT	Năm phân tích (số nguyên).
is_holiday	INT	Đánh dấu ngày lễ (1: Ngày lễ, 0: Ngày thường).
is_semester	INT	Đánh dấu học kỳ (1: Trong kỳ học, 0: Kỳ nghỉ).
is_exam	INT	Đánh dấu mùa thi (1: Trong mùa thi, 0: Bình thường).

Bảng 3.9: Cấu trúc vật lý bảng chiều thời gian (dim_time)

Tên trường (Field)	Kiểu DL	Diễn giải vật lý
time_id	INT (PK)	Khóa chính mốc thời gian.
time_string	VARCHAR	Chuỗi ký tự biểu diễn giờ (HH:MM).
hour	INT	Giờ trong ngày (số nguyên).
minute	INT	Phút (số nguyên).

Bảng 3.10: Cấu trúc vật lý bảng chiều danh mục thời tiết (dim_weather_type)

Tên trường (Field)	Kiểu DL	Diễn giải vật lý
weather_type_id	INT (PK)	Khóa chính danh mục thời tiết.
weather_code	INT	Mã trạng thái WMO (số nguyên).
is_day	INT	Trạng thái ánh sáng (1: Ngày, 0: Đêm) lưu dạng số nguyên.
weather_condition	VARCHAR	Tên điều kiện thời tiết tổng quát.
description	VARCHAR	Chuỗi văn bản mô tả chi tiết diễn biến thời tiết.

Bảng 3.11: Cấu trúc vật lý bảng sự kiện sản lượng (fact_solar_energy_gen)

Tên trường (Field)	Kiểu DL	Diễn giải mục đích vật lý
gen_id	INT	Khóa chính định danh từng dòng sự kiện (Auto-increment).
site_id	INT	Khóa ngoại trở đến dim_solar_site.site_id.
geo_id	INT	Khóa ngoại trở đến dim_geography.geo_id.
date_id	INT	Khóa ngoại trở đến dim_date.date_id.
time_id	INT	Khóa ngoại trở đến dim_time.time_id.
energy_generated_kwh	FLOAT	Sản lượng điện năng sinh ra (kiểu số thực để tính toán độ chính xác cao).
rolling_outlier_flag	BOOLEAN	Cờ đánh dấu dòng dữ liệu sản lượng là ngoại lai (phát hiện bằng Rolling IQR).

Bảng 3.12: Cấu trúc vật lý bảng sự kiện thời tiết (fact_weather)

Tên trường (Field)	Kiểu DL	Diễn giải mục đích vật lý
weather_id	INT	Khóa chính định danh dòng lịch sử thời tiết.
geo_id	INT	Khóa ngoại trở đến dim_geography.geo_id.
date_id	INT	Khóa ngoại trở đến dim_date.date_id.
time_id	INT	Khóa ngoại trở đến dim_time.time_id.
weather_type_id	INT	Khóa ngoại trở đến dim_weather_type.weather_type_id.
is_day	INT	Chỉ số phân tách chu kỳ ánh sáng (số nguyên: 1/0).
shortwave_radiation	INT	Bức xạ sóng ngắn (số nguyên).
temperature_c	FLOAT	Nhiệt độ không khí (số thực).
cloud_cover_total	FLOAT	Tổng độ che phủ mây (số thực, tỷ lệ %).
cloud_cover_low	FLOAT	Tỷ lệ mây tầng thấp (số thực).
cloud_cover_mid	FLOAT	Tỷ lệ mây tầng trung (số thực).
cloud_cover_high	FLOAT	Tỷ lệ mây tầng cao (số thực).
Diffuse_Solar_Radiation	INT	Ánh sáng tán xạ (số nguyên).
Direct_Normal_Irradiance	INT	Bức xạ chiếu thẳng (số nguyên).
wind_speed	FLOAT	Tốc độ gió (số thực).
precipitation_mm	FLOAT	Tổng lượng mưa tích tụ (số thực).
Sunshine_Duration	FLOAT	Thời lượng nắng (số thực).

3.4.4 Kịch bản SQL Khởi tạo Cơ sở Dữ liệu

Để triển khai thiết kế vật lý lên hệ quản trị cơ sở dữ liệu Supabase PostgreSQL, dự án sử dụng các kịch bản SQL khởi tạo tự động. Các kịch bản này phân tách rõ rệt cấu trúc giữa tầng đệm (Staging Area) và tầng kho dữ liệu chính thức (Data Warehouse).

Kịch bản khởi tạo lớp đệm Staging (Schema Staging)

Các bảng trích xuất thô (stg_*) được thiết kế với kiểu dữ liệu chuỗi linh hoạt (VARCHAR) nhằm hạn chế tối đa lỗi gián đoạn tiến trình trích xuất (Extract) khi nguồn cấp thay đổi định dạng dữ liệu đột ngột. Kịch bản dưới đây thực hiện tạo lập cấu trúc các bảng đệm thô và các bảng đệm đã chuyển kiểu trong schema staging:

```

1 -- 1. Khoi tạo Schema staging
2 CREATE SCHEMA IF NOT EXISTS staging;
3 -- 2. Bang Staging tho chua san luong dien
4 CREATE TABLE staging.stg_solar_energy_generation (
5     CampusKey VARCHAR(255),
6     SiteKey VARCHAR(255),
7     Timestamp VARCHAR(255),
8     SolarGeneration VARCHAR(255)
9 );
10
11 -- 3. Bang dem chuyen kieu fact_solar_energy_gen trong staging
12 CREATE TABLE staging.fact_solar_energy_gen (
13     SiteKey VARCHAR(255),
14     timestamp TIMESTAMP,
15     energy_generated_kwh FLOAT,
16     rolling_outlier_flag BOOLEAN DEFAULT false
17 );
18
19 -- 4. Bang dem chuyen kieu dim_date trong staging
20 CREATE TABLE staging.dim_date (
21     full_date DATE,
22     day INT,
23     month INT,
24     year INT,
25     is_holiday VARCHAR(50),
26     is_semester VARCHAR(50),
27     is_exam VARCHAR(50)
28 );

```

Kịch bản khởi tạo tầng Data Warehouse (Public Schema)

Tầng Data Warehouse chính thức được cấu hình các ràng buộc toàn vẹn cơ sở dữ liệu chặt chẽ bao gồm khóa chính, khóa ngoại liên kết giữa bảng sự kiện và bảng chiều, đảm bảo không tồn tại dữ liệu mờ côi:

```

1  -- 1. Khởi tạo bảng chiều dim_date
2  CREATE TABLE dim_date (
3      date_id INT PRIMARY KEY,
4      full_date DATE,
5      day INT,
6      month INT,
7      year INT,
8      is_holiday INT,
9      is_semester INT,
10     is_exam INT
11 );
12
13 -- 2. Khởi tạo bảng sự kiện sản lượng điện fact_solar_energy_gen
14 CREATE TABLE fact_solar_energy_gen (
15     gen_id INT PRIMARY KEY,
16     site_id INT,
17     geo_id INT,
18     date_id INT,
19     time_id INT,
20     energy_generated_kwh FLOAT,
21     rolling_outlier_flag BOOLEAN DEFAULT false,
22
23     -- Thiết lập các ràng buộc khóa ngoại
24     CONSTRAINT FK_Gen_Site FOREIGN KEY (site_id)
25         REFERENCES dim_solar_site(site_id),
26     CONSTRAINT FK_Gen_Geo FOREIGN KEY (geo_id)
27         REFERENCES dim_geography(geo_id),
28     CONSTRAINT FK_Gen_Date FOREIGN KEY (date_id)
29         REFERENCES dim_date(date_id),
30     CONSTRAINT FK_Gen_Time FOREIGN KEY (time_id)
31         REFERENCES dim_time(time_id)
32 );

```


3.5 Kiểm tra tính toàn vẹn và bảo mật dữ liệu

Để đảm bảo tính toàn vẹn dữ liệu (Data Integrity) trong CSDL vật lý, các ràng buộc tham chiếu (Referential Constraints) được cấu hình nghiêm ngặt theo quan hệ Một - Nhiều (1-M). Mọi bản ghi trong các bảng Fact bắt buộc phải có khóa tham chiếu tồn tại trong các bảng Dimension tương ứng, ngăn chặn tuyệt đối tình trạng dữ liệu mồ côi (orphan records) khi thực hiện luồng ETL.

Quy trình ETL và Chuẩn hóa Dữ liệu

4.1 Tổng quan Kiến trúc Pipeline Xử lý Dữ liệu

Để xây dựng một hệ thống phân tích dữ liệu sản lượng điện mặt trời ổn định và tin cậy, dự án thiết lập quy trình trích xuất, biến đổi và nạp dữ liệu (ETL Pipeline) tự động hóa bằng ngôn ngữ Python. Luồng di chuyển dữ liệu (Data Flow) được chia làm 3 tầng lõi rõ rệt nhằm đáp ứng triết lý thiết kế kho dữ liệu tập trung (Top-Down Approach):

1. **Tầng Trích xuất (Extract):** Dữ liệu lịch sử từ các tệp tin CSV vật lý ghi nhận tại trạm pin và dữ liệu khí tượng viễn thám từ Open-Meteo API được thu thập và lưu trữ tập trung tại thùng chứa (Bucket) raw-data của hệ thống lưu trữ đối tượng MinIO S3. Các tệp tin cốt lõi bao gồm `campus_meta.csv`, `Solar_Site_Details.csv`, `calender.csv`, `Solar_Energy_Generation.csv`, và `open_meteo_weather_raw_2020_2022.csv`.
2. **Tầng Biến đổi (Transform):** Sử dụng các thư viện tính toán hiệu năng cao như `pandas`, `numpy`, và `scikit-learn` để thực hiện chuẩn hóa kiểu dữ liệu thời gian, điền khuyết thiếu bằng chiến lược lai (Hybrid Imputation), gán cờ ngoại lai thông qua phân tích biến động trung bình trượt cục bộ, và đồng bộ granularity thời gian.
3. **Tầng Nạp (Load):** Dữ liệu sau biến đổi được đẩy vào hệ quản trị cơ sở dữ liệu Supabase PostgreSQL thông qua hai schema chuyên biệt: `staging` (bộ đệm trung gian) và `datawarehouse` (kho dữ liệu chuẩn hóa đa chiều phục vụ BI và ML).

Để khắc phục các hạn chế về môi trường triển khai thực tế, mã nguồn ETL của dự án tích hợp hai giải pháp hệ thống quan trọng:

- **Sử dụng Thư viện kết nối thuần Python (pg8000):** Khác với thư viện `psycopg2` vốn yêu cầu biên dịch các thư viện hệ thống nhị phân C (dễ gây lỗi thiếu `libz.so.1` hoặc `libstdc++.so.6` trên môi trường ảo hóa NixOS), thư viện `pg8000` hoạt động hoàn toàn độc lập, đảm bảo tính di động cao của mã nguồn.
- **Cấu hình Connection Pooler thông qua IPv4:** Do Supabase chỉ hỗ trợ truy cập IPv6 trực tiếp cho gói tài khoản miễn phí, dự án cấu hình Pooler trung gian

của Supabase tại cổng 5432 để duy trì kết nối IPv4 ổn định cho toàn bộ thành viên nhóm, đồng thời giảm tải luồng kết nối đồng thời lên máy chủ.

Dưới đây là mã nguồn cấu hình kết nối tối ưu hóa bằng thư viện pg8000:

```

1 def connect_pg8000() -> any:
2     import pg8000.dbapi
3     load_dotenv(ENV_FILE)
4     required = [
5         "DB_HOST", "DB_PORT", "DB_NAME",
6         "DB_USER", "DB_PASSWORD"
7     ]
8     missing = [name for name in required if not os.getenv(name)]
9     if missing:
10         missing_str = ', '.join(missing)
11         err_msg = f"Missing vars in {ENV_FILE}: {missing_str}"
12         raise RuntimeError(err_msg)
13
14     return pg8000.dbapi.connect(
15         host=os.environ["DB_HOST"],
16         port=int(os.environ.get("DB_PORT", "5432")),
17         database=os.environ["DB_NAME"],
18         user=os.environ["DB_USER"],
19         password=os.environ["DB_PASSWORD"],
20         ssl_context=True,
21     )

```

4.1.1 Thiết lập Tiến trình Nạp Dữ liệu Thứ tự

Để bảo toàn tính toàn vẹn tham chiếu khóa ngoại (Foreign Key Constraints), tiến trình tải dữ liệu vào kho được kiểm soát nghiêm ngặt theo thứ tự phụ thuộc. File `load_01_dims.py` chịu trách nhiệm tẩy trống dữ liệu cũ bằng lệnh `TRUNCATE CASCADE` và tải lại các bảng chiều độc lập theo trình tự tuyến tính:

`dim_geography` → `dim_solar_site` → `dim_date` → `dim_time` → `dim_weather_type`

Ngay sau khi các bảng chiều được nạp thành công, tệp tin `load_02_facts.py` tiến hành đọc các bảng sự kiện quy mô lớn từ MinIO và ánh xạ các khóa tự nhiên sang khóa đại diện (Surrogate Keys) bằng các bộ từ điển tra cứu (Lookups) đã lưu trong bộ nhớ tạm (In-memory dicts). Để tránh hiện tượng nghẽn bộ nhớ đệm (RAM Out-Of-Memory) khi xử lý tập dữ liệu sản lượng hơn 2,7 triệu dòng, luồng nạp sử dụng cơ chế chia nhỏ

dữ liệu thành từng khối (chunksize = 50.000 dòng) và thực thi lệnh chèn hàng loạt `execute_values` tối ưu hóa hiệu năng IO.

4.1.2 Cơ chế Quản lý Giao dịch và An toàn Dữ liệu

Toàn bộ tiến trình nạp được bọc trong một khối giao dịch cơ sở dữ liệu duy nhất (Explicit DB Transaction). Chế độ tự động xác nhận (autocommit) được tắt hoàn toàn.

- Nếu xuất hiện bất kỳ lỗi hệ thống hoặc vi phạm ràng buộc dữ liệu nào (ví dụ: khóa ngoại không tồn tại), lệnh `conn.rollback()` sẽ lập tức hoàn tác mọi thay đổi để đưa kho dữ liệu về trạng thái an toàn trước đó.
- Chỉ khi toàn bộ dữ liệu của phân đoạn được ghi thành công không lỗi, lệnh `conn.commit()` mới được phát ra để ghi nhận vĩnh viễn các thay đổi vào đĩa cứng.

4.2 Đánh giá Chất lượng và Khám phá Dữ liệu (EDA ban đầu)

Trước khi thực hiện các phép toán làm sạch, nhóm tiến hành một bước hồ sơ hóa dữ liệu (Data Profiling) nhằm phát hiện các vấn đề về chất lượng dữ liệu thô. Tiến trình này được tự động hóa thông qua kịch bản `data_integrity_and_reconciliation_check.py`.

Công cụ thực hiện quét toàn bộ các bảng trong schema staging để thống kê: (1) Tổng số dòng dữ liệu hiện có, (2) Số lượng bản ghi bị khuyết thiếu khóa chính (NULL PK), và (3) Số lượng bản ghi bị trùng lặp khóa tự nhiên (Duplicate PKs).

Bảng 4.1: Bảng thống kê kiểm tra chất lượng dữ liệu ban đầu trong Staging

Tên bảng dữ liệu	Tổng số dòng	Số dòng trùng lặp	Số dòng khuyết PK	Trạng thái
<code>dim_geography</code>	5	0	0	OK
<code>dim_solar_site</code>	42	0	0	OK
<code>dim_date</code>	2.312	0	0	OK
<code>dim_time</code>	96	0	0	OK
<code>dim_weather_type</code>	22	0	0	OK
<code>fact_weather</code>	367.920	0	0	OK
<code>fact_solar_energy_gen</code>	2.731.946	0	0	OK

Kết quả phân tích ban đầu cho thấy cấu trúc khung của các bảng chiều và bảng thời tiết rất sạch, không xuất hiện hiện tượng trùng lặp dòng. Tuy nhiên, bảng sự kiện sản lượng thô `fact_solar_energy_gen` chứa tới 107.452 ô dữ liệu bị khuyết giá trị sản lượng (`SolarGeneration` mang giá trị NaN), chiếm khoảng 3,93% tổng số quan trắc đo đạc của cả năm. Đây là đối tượng trọng tâm cần xử lý tại tầng làm sạch dữ liệu.

4.2.1 Các Cột Thực Tế và Ánh Xạ Dữ Liệu Trong Pipeline

Trong giai đoạn nạp dữ liệu từ các tệp thô vào bảng đệm (Staging layer), hệ thống thực hiện chuyển đổi kiểu dữ liệu (casting) và đổi tên trường để phù hợp với định dạng kho dữ liệu. Chi tiết các trường thông tin thực tế được ánh xạ từ tệp thô lên bảng sự kiện được thống kê dưới đây:

Cấu trúc ánh xạ bảng sự kiện sản lượng (**fact_solar_energy_gen**)

Bảng này ghi nhận sản lượng điện thực tế theo chu kỳ 15 phút của từng trạm phát:

- `sitekey` (Ánh xạ từ cột `SiteKey` trong tệp thô, định dạng chuỗi chuyển sang `VARCHAR` hoặc `INT`): Mã định danh duy nhất của từng trạm phát.
- `timestamp` (Ánh xạ từ cột `Timestamp` dạng text thô, xử lý chuyển đổi định dạng `YYYY-MM-DD HH24:MI:SS` sang kiểu dữ liệu `TIMESTAMP` chuẩn): Mốc thời gian quan trắc sản lượng.
- `energy_generated_kwh` (Ánh xạ từ cột `SolarGeneration` thô, làm sạch ký tự lạ và chuyển đổi thành `DOUBLE PRECISION` hoặc `FLOAT`): Sản lượng điện mặt trời thực tế thu được trong 15 phút (đơn vị kWh).

Cấu trúc ánh xạ bảng sự kiện thời tiết (**fact_weather**)

Bảng này tích hợp các chỉ số thời tiết theo chu kỳ chẵn giờ từ Open-Meteo API ứng với tọa độ trạm phát:

- `sitekey` (Ánh xạ từ `SiteKey`): Khóa liên kết trạm phát điện.
- `timestamp` (Ánh xạ từ `timestamp` thô, chuyển sang kiểu `TIMESTAMP`): Mốc thời gian chẵn giờ của dữ liệu khí tượng.
- `weather_code` (Ánh xạ từ `weather_code`, chuyển kiểu `INT`): Mã trạng thái thời tiết chuẩn WMO.

- `is_day` (Ảnh xạ từ `is_day`, kiểu INT): Cờ phân tách trạng thái ngày/đêm (1: Ngày, 0: Đêm).
- `shortwave_radiation` (Ảnh xạ từ `shortwave_radiation`, kiểu NUMERIC): Tổng bức xạ sóng ngắn mặt trời bề mặt (W/m^2).
- `temperature_c` (Ảnh xạ từ `temperature_2m`, kiểu NUMERIC): Nhiệt độ không khí ở độ cao 2 mét ($^{\circ}\text{C}$).
- `cloud_cover_total` (Ảnh xạ từ `cloud_cover`, kiểu NUMERIC): Tỷ lệ che phủ mây tổng thể (%).
- `cloud_cover_low` (Ảnh xạ từ `cloud_cover_low`, kiểu NUMERIC): Tỷ lệ mây tầng thấp (%).
- `cloud_cover_mid` (Ảnh xạ từ `cloud_cover_mid`, kiểu NUMERIC): Tỷ lệ mây tầng trung (%).
- `cloud_cover_high` (Ảnh xạ từ `cloud_cover_high`, kiểu NUMERIC): Tỷ lệ mây tầng cao (%).
- `diffuse_solar_radiation` (Ảnh xạ từ `diffuse_radiation`, kiểu NUMERIC): Bức xạ mặt trời khuếch tán (W/m^2).
- `direct_normal_irradiance` (Ảnh xạ từ `direct_radiation`, kiểu NUMERIC): Bức xạ mặt trời trực tiếp bề mặt (W/m^2).
- `wind_speed` (Ảnh xạ từ `wind_speed_10m`, kiểu NUMERIC): Tốc độ gió ở độ cao 10 mét (m/s).
- `precipitation_mm` (Ảnh xạ từ `precipitation`, kiểu NUMERIC): Tổng lượng mưa tích tụ trong giờ (mm).
- `sunshine_duration` (Ảnh xạ từ `sunshine_duration`, kiểu NUMERIC): Thời lượng nắng thực tế (giây).

4.3 Làm sạch và Chuẩn hóa Dữ liệu (Data Cleaning)

4.3.1 Xử lý Dữ liệu Khuyết thiếu và Lỗi Logic

Để phục hồi dữ liệu khuyết thiếu cho trường sản lượng phát điện (`energy_generated_kwh`), dự án áp dụng chiến lược nội suy lai nghiêm ngặt (Hybrid Imputation Strategy) tích hợp giữa các bộ quy tắc nghiệp vụ vật lý và mô hình học máy trong file `solar_data_pipeline.py`. Tiến trình xử lý gồm hai giai đoạn chính:

Giai đoạn 1: Lọc vật lý ban đêm (Rule-Based Night Zeroing)

Đối với các trạm phát điện mặt trời quang điện, sản lượng điện năng luôn bằng 0 vào ban đêm do không có bức xạ mặt trời. Nếu sử dụng các thuật toán nội suy thuần toán học (như tuyến tính hay spline) trên các khoảng trống kéo dài qua đêm, hệ thống sẽ sinh ra các giá trị sản lượng ảo (dương) phi vật lý.

Do đó, thuật toán tiến hành rà soát mốc thời gian và áp đặt giá trị 0 ngay lập tức nếu thỏa mãn một trong hai điều kiện logic sau:

- **Khung giờ ban đêm tự nhiên:** Mốc thời gian đo đạc nằm trong khoảng từ 18:30 chiều hôm trước đến 05:30 sáng hôm sau ($T \geq 18.5$ hoặc $T < 5.5$).
- **Điều kiện thời tiết triệt tiêu:** Giá trị bức xạ sóng ngắn mặt trời (shortwave_radiation) bằng 0 hoặc cờ chỉ số ánh sáng ngày is_day bằng 0 trong tập dữ liệu thời tiết (được đồng bộ hóa sang dòng sản lượng tương ứng bằng thuật toán ghép nối mốc gần nhất pd.merge_asof với ngưỡng sai lệch thời gian tối đa là 30 phút).

Giai đoạn này đã xử lý thành công 94.618 ô dữ liệu trống (chiếm tới 88,1% tổng số giá trị khuyết thiếu ban đầu), gán chúng về giá trị 0.0 một cách chính xác.

Mã nguồn Python hiện thực thuật toán lọc vật lý ban đêm:

```

1 def rule_based_night_zero(
2     solar_df: pd.DataFrame, weather_df: pd.DataFrame, site_key: int
3 ) -> tuple:
4     gen = solar_df["energy_generated_kwh"].copy()
5     ts = solar_df["timestamp"]
6
7     # Xác định giờ đêm tự nhiên
8     hour = ts.dt.hour + ts.dt.minute / 60
9     is_night = (hour >= NIGHT_START + 0.5) | (hour < NIGHT_END + 0.5)
10
11     # Kết nối với open_meteo để lấy thông tin bức xạ sóng ngắn
12     w = weather_df[weather_df["sitekey"] == site_key][
13         ["timestamp", "shortwave_radiation", "is_day"]
14     ].copy()
15     w = w.rename(columns={"timestamp": "timestamp"})
16     w["timestamp"] = pd.to_datetime(w["timestamp"])
17
18     merged = pd.merge_asof(
19         solar_df[["timestamp"]].reset_index(),

```

```

20     w.sort_values("timestamp"),
21     on="timestamp",
22     tolerance=pd.Timedelta("30min"),
23     direction="nearest",
24 ).set_index("index")
25
26 # Điều kiện bức xạ song ngắn bằng 0 hoặc có dem is_day = 0
27 zero_radiation = (merged["shortwave_radiation"].fillna(0) == 0) | (
28     merged["is_day"].fillna(0) == 0
29 )
30 mask_zero = is_night.values | zero_radiation.values
31
32 n_filled = (mask_zero & gen.isna()).sum()
33 gen[mask_zero & gen.isna()] = 0.0
34 return gen, n_filled

```

Giai đoạn 2: Nội suy phân cấp theo quy mô khoảng trống (Imputation Gaps classification)

Đối với 12.834 ô dữ liệu khuyết thiếu phát sinh vào ban ngày (khi có bức xạ), thuật toán tiến hành phân tích độ dài chuỗi khuyết liên tiếp (Gap size) của từng trạm phát độc lập để áp dụng phương pháp điền khuyết tối ưu:

- a. **Khoảng khuyết ngắn (≤ 2 dòng liên tiếp, tương đương ≤ 30 phút):** Áp dụng phương pháp nội suy tuyến tính (*Linear Interpolation*) theo thời gian. Do khoảng thời gian gián đoạn rất ngắn, biến động của ánh sáng mặt trời được coi là thay đổi tuyến tính đều giữa điểm biên trước và biên sau khoảng khuyết.
- b. **Khoảng khuyết trung bình (Từ 3 đến 8 dòng liên tiếp, tương đương từ 45 phút đến 2 tiếng):** Áp dụng phương pháp nội suy *Cubic Spline*. Đường cong bậc ba giúp mô phỏng mượt mà sự trôi sụt tự nhiên của sản lượng điện do mây che phủ đi qua trạm pin. Để tránh hiện tượng sập nhiễu ma trận khi gặp các khoảng khuyết lớn lân cận, thuật toán xây dựng một bản sao tạm thời được điền tuyến tính để làm mịn dữ liệu mốc trước khi tính toán spline bậc ba thực tế.
- c. **Khoảng khuyết diện rộng (> 8 dòng liên tiếp, tương đương > 2 tiếng):** Trong trường hợp này, dữ liệu bị mất quá dài khiến các phương pháp nội suy chuỗi đơn biến (Tuyến tính/Spline) mất khả năng phục hồi chính xác xu hướng thực tế. Nhóm thiết lập mô hình hồi quy đa biến (*Multivariate Regression Imputation*) độc lập cho từng trạm phát.

Mô hình Hồi quy Tuyến tính (LinearRegression từ thư viện `scikit-learn`) được huấn luyện trên tập các bản ghi sạch (đầy đủ thông tin) của chính trạm đó. Các biến đầu vào (Features) bao gồm: bức xạ sóng ngắn mặt trời (`shortwave_radiation`), bức xạ chiếu trực tiếp (`direct_normal_irradiance`), bức xạ khuếch tán (`diffuse_solar_radiation`) và nhiệt độ không khí ở độ cao 2m (`temperature_c`).

Sau khi huấn luyện, mô hình sẽ dự đoán sản lượng điện năng cho các khoảng khuyết diện rộng dựa trên dữ liệu khí tượng thực tế tại tọa độ trạm phát đó. Kết quả dự đoán được cắt giới hạn dưới bằng 0 (`clip(lower=0)`) để loại bỏ các giá trị âm sinh ra do sai số hồi quy.

Mã nguồn Python thực thi hồi quy đa biến điền khuyết diện rộng ban ngày:

```

1 def regression_imputation_large_gaps_strict(
2     solar_sub: pd.DataFrame,
3     weather_df: pd.DataFrame,
4     site_key: int,
5     large_gap_indices: set,
6 ) -> tuple:
7     FEATURES = [
8         "shortwave_radiation",
9         "direct_normal_irradiance",
10        "diffuse_solar_radiation",
11        "temperature_c",
12    ]
13
14    w = weather_df[weather_df["sitekey"] == site_key][["timestamp"] + FEATURES
15    w = w.rename(columns={"timestamp": "timestamp"})
16    w["timestamp"] = pd.to_datetime(w["timestamp"])
17
18    merged = pd.merge_asof(
19        solar_sub[["timestamp", "energy_generated_kwh"]].reset_index(),
20        w.sort_values("timestamp"),
21        on="timestamp",
22        tolerance=pd.Timedelta("60min"),
23        direction="nearest",
24    ).set_index("index")
25
26    train_mask = merged["energy_generated_kwh"].notna() & \
27        merged[FEATURES].notna().all(axis=1)

```

```

28     pred_mask = merged["energy_generated_kwh"].isna() & \
29         merged[FEATURES].notna().all(axis=1)
30
31     filled = 0
32     if train_mask.sum() < 10:
33         return solar_sub["energy_generated_kwh"].values, 0
34
35     X_train = merged.loc[train_mask, FEATURES].values
36     y_train = merged.loc[train_mask, "energy_generated_kwh"].values
37
38     # Chuan hoa thong so dac trung dau vao
39     scaler = StandardScaler()
40     X_train_sc = scaler.fit_transform(X_train)
41
42     model = LinearRegression()
43     model.fit(X_train_sc, y_train)
44
45     if pred_mask.sum() > 0:
46         X_pred = merged.loc[pred_mask, FEATURES].values
47         X_pred_sc = scaler.transform(X_pred)
48         y_pred = model.predict(X_pred_sc)
49
50         result = solar_sub["energy_generated_kwh"].copy()
51         pred_indices = merged[pred_mask].index.tolist()
52
53         for pos, idx in enumerate(pred_indices):
54             local_pos = solar_sub.index.get_loc(idx) if idx in solar_sub.index
55             # Chi ghi vao cac vi tri thuoc khoang khuyet lon
56             if local_pos is not None and local_pos in large_gap_indices:
57                 result.iloc[local_pos] = max(0.0, y_pred[pos])
58                 filled += 1
59
60         return result.values, filled
61     return solar_sub["energy_generated_kwh"].values, 0

```

Tổng hợp kết quả sau quy trình làm sạch dữ liệu khuyết thiếu:

- Tổng số ô trống ban đầu: 107.452 ô (3,93% dữ liệu).
- Số ô được điền qua lọc ban đêm (Night Zero): 94.618 ô.
- Số ô được điền qua nội suy tuyến tính (Linear): 3.652 ô.

- Số ô được điền qua nội suy đường cong (Cubic Spline): 5.124 ô.
- Số ô được điền qua mô hình học máy hồi quy (Regression): 4.058 ô.
- Số ô NULL còn lại trong kho dữ liệu: 0 ô (Điền khuyết thành công 100%).

4.3.2 Xử lý Dữ liệu Ngoại lai (Outliers) và Lọc nhiễu

Bên cạnh lỗi mất mát dữ liệu, hệ thống thu thập thông tin từ cảm biến dòng điện (CT) của các trạm phát thường xuyên gặp hiện tượng nhiễu đột biến (Spikes) do xung nhiễu lưới điện, bụi bẩn bám tạm thời hoặc lỗi truyền dữ liệu gây ra các đỉnh công suất vượt xa công suất thiết kế cực đại (kWp).

Để nhận diện các bất thường này mà không bị ảnh hưởng bởi tính mùa vụ và tính chu kỳ ngày đêm cực mạnh của điện mặt trời, nhóm áp dụng phương pháp **Grouped Rolling IQR cục bộ** trong file `upload_rolling_outlier_flags.py`.

Quy trình tính toán và gắn cờ ngoại lai

Thuật toán tính toán độ lệch tuyệt đối của từng điểm dữ liệu sản lượng so với trung bình trượt trong cửa sổ 1 giờ tự trượt theo thời gian. Sau đó, toàn bộ các độ lệch này được gom nhóm theo tổ hợp trạm (`sitekey`) và giờ trong ngày (`hour`) để tính toán khoảng tứ phân vị cục bộ ($IQR_{s,h} = Q_3 - Q_1$). Bản ghi nào có độ lệch tuyệt đối vượt quá ngưỡng giới hạn cục bộ ($Q_3 + 1.5 \cdot IQR_{s,h}$) sẽ bị gắn cờ ngoại lai `rolling_outlier_flag = true`.

Quy trình đẩy cờ an toàn vào Kho dữ liệu trung tâm

Để cập nhật cờ ngoại lai này lên Supabase DWH mà không làm gián đoạn hệ thống và đảm bảo an toàn giao dịch tuyệt đối, nhóm xây dựng một pipeline 4 bước như sau:

1. **Xác thực nguồn dữ liệu (Source Verification Check):** Trước khi thực hiện bất kỳ thao tác ghi nào, tập tin `upload_rolling_outlier_flags.py` tiến hành đối chiếu cấu trúc vân tay dữ liệu (Data Fingerprint Check) giữa tệp CSV kết quả phân tích ngoại lai và bảng sự kiện `fact_solar_energy_gen` trên Supabase.

Quy trình kiểm tra tính toán tổng băm MD5 của chuỗi khóa ghép (`sitekey|timestamp`), tổng sản lượng năng lượng (`energy_sum`) với sai số cho phép ≤ 0.01 , và tổng số dòng dữ liệu. Bước này đảm bảo dữ liệu chạy cờ ngoại lai và dữ liệu trên cơ sở dữ liệu hoàn toàn đồng nhất về cấu trúc cột và số lượng dòng (2.731.946 dòng), ngăn ngừa lỗi lệch dòng (Data Shift).

2. **Nạp danh sách ứng viên (Sparse Candidate Upload):** Thay vì tải lên lại toàn bộ 2,73 triệu dòng dữ liệu (rất chậm và dễ gây nghẽn kết nối), thuật toán chỉ lọc ra các bản ghi bị gán cờ ngoại lai thực sự (`rolling_outlier_flag = true`) gồm 100.822 dòng. Danh sách ứng viên này được đẩy vào một bảng tạm trung gian có cấu trúc chỉ mục khóa chính tối ưu: `staging.fact_solar_energy_gen_rolling_outlier_flags`.
3. **Kiểm tra tính toàn vẹn khóa ngoại (Referential Check):** Thực hiện truy vấn kiểm tra chéo (Anti-Join) để đảm bảo toàn bộ 100.822 khóa trong bảng tạm đều tồn tại khớp 1:1 trong bảng sự kiện chính. Kết quả trả về 0 dòng lỗi trước khi tiến hành cập nhật.
4. **Cập nhật giao dịch hàng loạt (Bulk Join Update):** Tiến trình mở một khối giao dịch an toàn trên cơ sở dữ liệu, thực hiện gán toàn bộ cờ `rolling_outlier_flag = false` cho cả bảng sự kiện chính (2.731.946 dòng), sau đó thực hiện lệnh cập nhật `UPDATE ... FROM ... WHERE` nối bảng tạm với bảng chính theo khóa trùng khớp (`sitekey, timestamp`) để chuyển các dòng ngoại lai sang trạng thái `true`.

Dưới đây là một phần mã nguồn Python thực hiện so sánh đối chiếu vân tay (Fingerprint) dữ liệu để bảo vệ chống ghi đè lỗi dữ liệu:

```

1 def fingerprint_supabase(conn: any) -> dict[str, object]:
2     cur = conn.cursor()
3     try:
4         cur.execute(
5             f"""
6             SELECT
7                 COUNT(*)::bigint AS rows,
8                 COUNT(DISTINCT sitekey)::bigint AS distinct_sitekeys,
9                 MIN(to_char(timestamp, 'YYYY-MM-DD HH24:MI:SS')) AS min_timestamp,
10                MAX(to_char(timestamp, 'YYYY-MM-DD HH24:MI:SS')) AS max_timestamp,
11                SUM(
12                    ('x' || substr(md5(sitekey::text), 1, 15))::bit(60)::bigint
13                )::numeric AS site_sum,
14                SUM(
15                    ('x' || substr(md5(to_char(timestamp,
16                    'YYYY-MM-DD HH24:MI:SS')), 1, 15))::bit(60)::bigint
17                )::numeric AS timestamp_sum,
18                SUM(energy_generated_kwh::numeric) AS energy_sum,
19                SUM(
20                    ('x' || substr(

```

```

21         md5(sitekey::text || '|' ||
22             to_char(timestamp, 'YYYY-MM-DD HH24:MI:SS')),
23             1,
24             15
25         )::bit(60)::bigint
26         )::numeric AS key_checksum
27     FROM {qname(SCHEMA, SOURCE_FACT_TABLE)}
28     """
29 )
30 row = cur.fetchone()
31 return {
32     "rows": int(row[0]),
33     "distinct_sitekeys": int(row[1]),
34     "min_timestamp": row[2],
35     "max_timestamp": row[3],
36     "site_sum": Decimal(str(row[4] or 0)),
37     "timestamp_sum": Decimal(str(row[5] or 0)),
38     "energy_sum": Decimal(str(row[6] or 0)),
39     "key_checksum": Decimal(str(row[7] or 0)),
40 }
41 finally:
42     cur.close()

```

Kết quả chạy pipeline thực tế đã gán cờ thành công ****100.822 dòng ngoại lai**** (chiếm ****3,69%**** tổng số dòng dữ liệu). Phân phối cờ sau kiểm chứng khớp hoàn hảo với các chỉ số thống kê toán học của mô hình mẫu:

- Tổng số dòng dữ liệu kiểm tra: 2.731.946 dòng.
- Số lượng dòng gán cờ ngoại lai (`true`): 100.822 dòng (3,69%).
- Số lượng dòng dữ liệu sạch bình thường (`false`): 2.631.124 dòng (96,31%).
- Số lượng dòng mang giá trị rỗng (`null`): 0 dòng.

4.4 Biến đổi và Trích xuất Đặc trưng (Feature Engineering)

Sau khi dữ liệu sản lượng và thời tiết được làm sạch tại tầng kho dữ liệu, tiến trình thực hiện tính toán biến đổi cấu trúc để chuẩn bị dữ liệu đầu vào tối ưu cho mô hình dự báo học máy.

4.4.1 Giải quyết độ lệch tần suất ghi nhận (Granularity Alignment)

Một thách thức lớn trong dữ liệu của dự án là độ lệch tần suất (Granularity Mismatch) giữa hai nguồn thông tin nghiệp vụ:

- Dữ liệu sản lượng điện được ghi nhận với tần suất cao (15 phút một dòng).
- Dữ liệu khí tượng viễn thám chỉ có sẵn theo chu kỳ giờ (60 phút một dòng).

Để giải quyết sự lệch pha này mà không làm mất mát thông tin xu hướng của bức xạ mặt trời, nhóm thiết lập thuật toán gom cụm (Aggregation) đưa dữ liệu về cùng chu kỳ giờ (1-hour grain). Chỉ số sản lượng điện mặt trời `energy_generated_kwh` trong 4 chu kỳ 15 phút của cùng một giờ được tính tổng cộng dồn (Sum Aggregation):

$$E_{\text{hour}} = \sum_{i=1}^4 E_{15\text{min},i} \quad (4.1)$$

Trong khi đó, các biến thời tiết đại diện cho giờ đó được giữ nguyên giá trị trung bình giờ. Thuật toán ghép nối sử dụng hàm kết hợp chính xác mốc thời gian chuẩn giờ, giúp tạo ra một bảng dữ liệu phẳng góc nhìn rộng (Wide-table) thống nhất, đảm bảo tính liên kết chặt chẽ và không có dữ liệu rò rỉ thời gian (Data Leakage).

4.4.2 Trích xuất các đặc trưng thời gian và lịch trình học tập

Điện năng mặt trời mang tính chu kỳ tự nhiên rất mạnh phụ thuộc vào quỹ đạo chuyển động của Trái Đất. Dự án tiến hành trích xuất các đặc trưng thời gian đa tầng từ trường mốc thời gian `timestamp`:

- **Đặc trưng giờ trong ngày (Hour):** Giá trị từ 0 đến 23, xác định góc chiếu mặt trời.
- **Đặc trưng tháng trong năm (Month):** Xác định tính mùa vụ thời tiết (Mùa hè bức xạ cao, mùa đông bức xạ thấp ở Nam bán cầu).
- **Đặc trưng ngày trong tuần (Day of Week):** Hỗ trợ phân tích hành vi tiêu thụ điện năng tại các khu học xá (Campus).

Đặc biệt, nhóm tích hợp thành công dữ liệu lịch học tập (`calender.csv`) của cơ sở đào tạo thông qua ba đặc trưng nhị phân:

- `is_holiday`: Đánh dấu các ngày nghỉ lễ quốc gia hoặc ngày nghỉ nội bộ.

- `is_semester`: Đánh dấu thời điểm đang trong học kỳ chính thức (nhu cầu sử dụng thiết bị điện cao đột biến).
- `is_exam`: Đánh dấu giai đoạn thi cử tập trung.

Sự kết hợp các thuộc tính lịch trình này giúp mô hình học máy phân biệt rõ rệt giữa biến động sản lượng do thời tiết tự nhiên và biến động tiêu thụ do hành vi con người gây ra, cải thiện độ chính xác dự báo sản lượng thực dùng tại các điểm nút phụ tải trạm.

Trực quan Dữ liệu và Xây dựng Dashboard

5.1 Chiến lược Kết nối Dữ liệu và Thiết kế UI/UX

[Kết nối các bảng Fact và Dimension từ Supabase vào công cụ BI (Tableau) thông qua các Relationship (1-M). Lựa chọn bộ màu sắc và bố cục Dashboard theo quy luật Gestalt để làm nổi bật các chỉ số quan trọng.]

5.2 Chi tiết Hệ thống Dashboard Phân tích

5.2.1 Dashboard 1: Tổng quan Vận hành (Executive Overview)

[Cung cấp cái nhìn toàn cảnh về sản lượng điện tổng, công suất hoạt động trung bình, và xu hướng theo thời gian của 42 trạm phát.]

5.2.2 Dashboard 2: Phân tích Hiệu suất và Khí hậu

[Phân tích tương quan giữa sản lượng điện với nhiệt độ và bức xạ. Phát hiện các mốc suy giảm hiệu suất.]

5.2.3 Dashboard 3: Giám sát Bất thường và Lỗi Cảm biến

[Trực quan hóa các điểm dữ liệu bất thường (Outliers), tần suất xuất hiện lỗi tại các trạm để kỹ sư có kế hoạch bảo trì.]

Khai phá Dữ liệu và Business Insights

Theo tinh thần phân tích chuyên sâu (Đừng chỉ mô tả → phải giải thích), chương này tập trung vào việc bóc tách các điểm nghẽn vận hành và đưa ra các phát hiện có giá trị kinh doanh (Business Insights) dựa trên logic dữ liệu, thay vì chỉ dựa vào các biểu đồ bề nổi. Các mô hình học máy cơ sở (ARIMA/Prophet) được tích hợp như một công cụ chẩn đoán hỗ trợ.

6.1 Insight 1: Hiện tượng suy giảm hiệu suất do nhiệt độ (Thermal Degradation)

[Dữ liệu chứng minh rằng khi nhiệt độ môi trường vượt quá ngưỡng giới hạn (ví dụ: 25°C), hiệu suất chuyển đổi quang điện của tấm pin sụt giảm đáng kể. Điều này giải thích tại sao vào buổi trưa bức xạ cao nhất nhưng công suất lại không đạt đỉnh.]

6.2 Insight 2: Điểm mù vận hành từ “Độ nhiễu ban đêm”

[Phát hiện hàng loạt trạm ghi nhận sản lượng phát điện vào ban đêm. Nguyên nhân được phân tích là do nhiễu xung điện từ biến tần (Inverter) hoặc dòng rò. Nếu không lọc bỏ, dữ liệu này sẽ làm sai lệch nghiêm trọng các báo cáo tổng sản lượng.]

6.3 Insight 3: Ứng dụng Mô hình dự báo (Baseline) để tối ưu vận hành

[Ứng dụng mô hình Time-Series (như Prophet) để thiết lập đường cơ sở (Baseline) dự báo sản lượng. Sự chênh lệch lớn giữa sản lượng thực tế và Baseline đóng vai trò là “cờ báo” (Alert) để ban quản lý cử đội bảo trì đến kiểm tra các tấm pin bị bụi bẩn bám dính hoặc hỏng hóc.]

Thiết kế, Huấn luyện và Đánh giá Mô hình Dự báo Sản lượng Quang điện

7.1 Tổng quan quy trình học máy

7.1.1 Phạm vi và dữ liệu đầu vào

Phần này trình bày toàn bộ quy trình học máy của dự án, bắt đầu từ tập dữ liệu đã làm sạch ở tầng ETL và kết thúc ở ứng dụng dự báo. Các bước trích xuất, biến đổi và nạp dữ liệu vào kho không thuộc phạm vi tài liệu này.

Đầu vào duy nhất của quy trình là tệp `data/mlmart_base/v4_final_cleaned.parquet`, gồm **2.731.946** bản ghi ở độ phân giải 15 phút, thu thập từ **42** dàn quang điện đặt tại **5** khuôn viên của Đại học La Trobe, Úc. Mỗi bản ghi mang giá trị sản lượng của một dàn tại một mốc thời gian, kèm các biến khí tượng tương ứng lấy từ Open-Meteo. Không phải mọi giá trị đều là số đo gốc — cột `energy_source` phân biệt dòng đo thật với dòng do tầng ETL điền khuyết, và Mục 2.1 trình bày tỷ lệ từng loại.

Phần sản lượng bắt nguồn từ bộ dữ liệu mở **UNISOLAR** do Wimalaratne và cộng sự [1] công bố. Bài báo mô tả đúng cấu hình mà dự án đang dùng — 42 dàn quang điện trên năm khuôn viên của Đại học La Trobe, bang Victoria, Úc, đo ở bước 15 phút — kèm vị trí địa lý và thông số kỹ thuật của từng dàn, xem Hình 7.1.

UNISOLAR đi kèm dữ liệu khí tượng của Cục Khí tượng Úc ở bước một phút. Dự án lấy biến khí tượng từ **Open-Meteo** theo toạ độ của từng khuôn viên, nên mọi kết luận về nhóm đặc trưng khí tượng trong tài liệu này thuộc về nguồn Open-Meteo.

Hai trạm mang số hiệu 19 và 24 có siêu dữ liệu công suất lắp đặt mâu thuẫn với sản lượng đo được, nên bị loại khỏi phạm vi huấn luyện và chấm điểm. Mô hình cuối cùng vì vậy được đánh giá trên 40 trạm; hai trạm còn lại vẫn nằm trong kho dữ liệu và vẫn hiển thị trên ứng dụng, chỉ không tham gia vào các con số được báo cáo.

UNISOLAR: An Open Dataset of Photovoltaic Solar Energy Generation in a Large Multi-Campus University Setting

Shashini Wimalaratne
Centre for Data Analytics and
Cognition (CDAC)
La Trobe University
Melbourne, Australia
shashini.18@cse.mrt.ac.lk

Dilantha Haputhanthri
Centre for Data Analytics and
Cognition (CDAC)
La Trobe University
Melbourne, Australia
d.haputhanthrige@latrobe.edu.au

Sachin Kahawala
Centre for Data Analytics and
Cognition (CDAC)
La Trobe University
Melbourne, Australia
s.kahawala@latrobe.edu.au

Gihan Gamage
Centre for Data Analytics and
Cognition (CDAC)
La Trobe University
Melbourne, Australia
g.gamage@latrobe.edu.au

Damminda Alahakoon
Centre for Data Analytics and
Cognition (CDAC)
La Trobe University
Melbourne, Australia
d.alahakoon@latrobe.edu.au

Andrew Jennings
Centre for Data Analytics and
Cognition (CDAC)
La Trobe University
Melbourne, Australia
andrew.jennings@latrobe.edu.au

Abstract— We introduce an open dataset of high-granularity Photovoltaic (PV) solar energy generation, solar irradiance, and weather data from 42 PV sites deployed across five campuses at La Trobe University, Victoria, Australia. The dataset includes approximately two years of PV solar energy generation data collected at 15-minute intervals. Geographical placement and engineering specifications for each of the sites are also provided to aid researchers in modelling solar energy generation. Weather data is available at 1-minute intervals and is provided by the Australian Bureau of Meteorology (BOM). Apparent temperature, air temperature, dew point temperature, relative humidity, wind speed, and wind direction were provided under the weather data. The paper describes the data collection methods, cleaning, and merging with weather data. This dataset can be used to forecast, benchmark, and enhance operational outcomes in solar sites.

Keywords—renewables, photovoltaic, dataset, solar energy generation, solar irradiance, weather, net-zero carbon emissions

rooftops of all university buildings across its five campuses. The university has installed PV systems on the rooftops at the Bundoora and Mildura campuses and solar carports have been constructed at Bendigo and Albury-Wodonga campuses. The main campus in Bundoora has 7500 solar panels installed across 25 buildings, which translates to a decrease of 4000 tonnes of CO₂ emissions per annum and 50% of daytime demand for electricity.

The La Trobe Energy AI/Analytics Platform (LEAP) is the flagship AI initiative of this commitment towards achieving Net Zero Carbon Emissions by 2029. LEAP draws on diverse datasets related to electricity consumption, renewables generation, energy utilization, as well as water and gas consumption. In this paper, we present UNISOLAR, an open dataset of high-granularity PV energy generation and weather data collected over 2.5 years (2020-2022) from the multi-campus setting of La Trobe University. This dataset contains PV data and weather data from 42 sites across the five campuses in the La Trobe university network: Bundoora.

Hình 7.1: Trang đầu bài báo công bố bộ dữ liệu UNISOLAR [1], IEEE *International Conference on Human-System Interaction* 2022. Phần tóm tắt xác nhận quy mô 42 dàn quang điện trên năm khuôn viên và bước đo 15 phút.

7.1.2 Bài toán và tầm dự báo

Mục tiêu dự báo là **sản lượng điện phát ra** của từng dàn quang điện, ký hiệu y , đơn vị kWh trên mỗi khoảng 15 phút. Đây là bài toán dự báo chuỗi thời gian có biến ngoại sinh: ngoài lịch sử sản lượng của chính dàn đó, mô hình còn được cung cấp các biến khí tượng và hình học Mặt Trời tại thời điểm cần dự báo.

Tầm dự báo (*forecast horizon*) là khoảng cách thời gian giữa thời điểm đưa ra dự báo và thời điểm được dự báo. Dự án huấn luyện hai cấu hình ứng với hai tầm:

- **H1** — dự báo sản lượng tại $T + 15$ phút, tức một bước phía trước.
- **H4** — dự báo sản lượng tại $T + 60$ phút, tức bốn bước phía trước.

Hai tầm này phục vụ hai nhu cầu vận hành khác nhau: H1 dùng cho điều độ tức thời, H4 dùng cho lập kế hoạch trong giờ tới. Mỗi tầm có một mô hình riêng, được huấn

luyện và chấm điểm độc lập.

Cơ sở chọn họ mô hình. Dự án dùng LightGBM — một mô hình cây tăng cường gradient — thay vì các kiến trúc học sâu dựa trên transformer. Lựa chọn này có tiền lệ định lượng trong tài liệu: Roy, Pyltsov và Hu [2] chấm 12 mô hình dự báo phụ tải điện trên cùng bộ dữ liệu của cuộc thi IISE PG&E Energy Analytics Challenge 2025, trải từ hồi quy tuyến tính từng khúc tới TimeGPT. Kết quả đo được cho thấy mô hình cây tăng cường gradient đạt sai số thấp hơn các kiến trúc học sâu ở cả ba kịch bản kiểm thử, với khoảng cách không nhỏ: RMSE 159,6 so với 239,5 của Transformer, tức thấp hơn 33%.

Table 4: Model Comparison Results

Metric	Test Case	Models											
		Piecewise	Poly	XGBoost	RF	MLP	GP	LSTM	TF	NHITS	TCN	TFT	TimeGPT
R^2	Year 1 → Year 2	-3.2	0.6	0.8	0.8	0.8	0.8	0.7	0.7	0.7	0.7	0.3	0.18
	Year 2 → Year 1	0.7	0.8	0.9	0.8	0.9	0.9	0.7	0.7	0.6	0.7	0.2	0.32
	Both years	-7054e3	-750e6	0.7	0.6	0.5	0.5	0.5	0.5	0.3	0.4	0.4	×
RMSE	Year 1 → Year 2	833.2	263.4	159.6	174.8	160.6	168.9	220.9	239.5	233.6	222.8	329.3	369.03
	Year 2 → Year 1	242.0	181.6	178.6	189.6	170.7	177.2	254.8	270.7	294.4	237.7	408.0	383.18
	Both years	1e6	12e6	263.7	286.5	312.5	308.1	311.6	309.9	368.5	334.9	348.7	×

Hình 7.2: Bảng 4 của Roy, Pyltsov và Hu [2], so sánh 12 mô hình trên cùng bộ dữ liệu. Khung đỏ đánh dấu ba dòng RMSE — chỉ số càng nhỏ càng tốt. Ở kịch bản *Year 1 → Year 2*, mô hình cây XGBoost đạt 159,6 trong khi Transformer (cột TF) là 239,5, LSTM là 220,9 và TimeGPT là 369,03.

Bảng kết quả của bài báo ở Hình 7.2. Bối cảnh của công trình đó gần với bài toán của dự án ở ba điểm: dữ liệu có cấu trúc chu kỳ mạnh theo giờ và theo mùa, kích thước tập huấn luyện ở mức triệu dòng chứ không phải hàng chục triệu, và yêu cầu vận hành đòi hỏi mô hình chạy lại được trên CPU. Bài báo làm trên bài toán **phụ tải điện**, không phải sản lượng quang điện; nguồn này được dẫn như **tiền lệ về lựa chọn họ mô hình**. Kết quả của dự án được chứng minh bằng phép đối chứng riêng với mô hình Prophet, trình bày ở phần đánh giá.

7.1.3 Nhân ngoại lai kế thừa từ tầng ETL

Tập dữ liệu đầu vào mang sẵn hai cột do tầng ETL sinh ra: `gmm_if_outlier_flag` và `gmm_if_outlier_reason`. Quy trình học máy không tự phát hiện ngoại lai mà **kế thừa** kết quả này. Vì các nhãn đó quyết định dòng nào được tham gia huấn luyện và dòng nào bị loại khỏi chỉ số báo cáo, phần dưới đây tóm tắt cách các nhãn này được tạo ra.

Thuật toán mang tên GMM-IF, ghép tên của hai kỹ thuật thành phần:

- **GMM** — *Gaussian Mixture Model*, mô hình hỗn hợp Gauss. Kỹ thuật này giả định dữ liệu sinh ra từ vài phân phối Gauss chồng lên nhau, rồi ước lượng **mật độ xác**

suất tại mỗi điểm. Điểm nằm ở vùng mật độ thấp là điểm hiếm. Câu hỏi nó trả lời: *điểm này hiếm tới mức nào so với phân bố chung.*

- **IF** — *Isolation Forest*, rừng cô lập. Kỹ thuật này dựng nhiều cây chia ngẫu nhiên và đếm **số nhất cắt cần thiết để tách riêng** một điểm khỏi phần còn lại. Điểm bất thường nằm tách biệt nên bị cô lập sau rất ít nhất cắt. Câu hỏi nó trả lời: *tách điểm này ra khỏi đám đông dễ hay khó.*

Hai kỹ thuật đo hai thứ khác nhau — một bên là mật độ, một bên là độ tách biệt — nên có thể bổ trợ cho nhau, xem Hình 7.3. Cách ghép chúng lại thích nghi từ công trình của Li và cộng sự [4]. Nhóm tác giả đó chỉ ra rằng dữ liệu chuỗi thời gian của hệ quang điện có tính phi tuyến và không dừng cao, nên khó mô tả bằng một phân phối Gauss duy nhất. Công trình đó đề xuất **phân đoạn dữ liệu trước rồi mới áp GMM** trong từng phân đoạn, đồng thời tích hợp Isolation Forest làm cơ chế quyết định ở bước chi tiết. Kết quả thực nghiệm của bài báo cho thấy phương án kết hợp cải thiện trung bình 3,8% về độ chính xác và 9,1% về F-value so với dùng riêng lẻ GMM hoặc Isolation Forest.

Hai nguyên lý này hỏi hai câu hỏi khác nhau về cùng một điểm dữ liệu. Hình 7.4 minh họa bằng chính dữ liệu của dự án.

Hình 7.4 cho thấy hai thuật toán không thay thế được nhau. Nửa trái, GMM gán cờ 156 điểm trên 8.176 quan sát, tức $156/8.176 = 1,91\%$, toàn bộ nằm ở đuôi trên của sản lượng và rải đều qua mọi mức bức xạ; đại lượng nó đo là mức hiếm của điểm trong phân bố. Nửa phải, Isolation Forest gán cờ 246 điểm, tức $246/8.176 = 3,01\%$, theo một đại lượng khác: số nhất cắt cần thiết để tách điểm đó khỏi phần còn lại.

Hai tập cờ **không trùng nhau**: phần giao chỉ còn 144 điểm, tức GMM mất $156 - 144 = 12$ điểm và Isolation Forest mất $246 - 144 = 102$ điểm khi bắt cả hai cùng đồng ý. Có những điểm GMM cho là hiếm nhưng Isolation Forest thấy vẫn dễ giải thích, và ngược lại. Pipeline lấy phép giao để chỉ giữ phần mà cả hai góc nhìn cùng đồng ý, sau đó hợp thêm với các luật rào chắn vật lý.

Trên toàn bộ tệp đầu vào, cột `gmm_if_outlier_flag` gán cờ **33.280** dòng trên tổng **2.731.946** dòng:

$$\frac{33.280}{2.731.946} = 0,012182 \rightarrow \mathbf{1,22\%} \quad (7.1)$$

Ba nhóm lý do chiếm phần lớn là vượt trần công suất, đồng thuận GMM-IF, và bước nhảy phân phối cục bộ.

Received 29 March 2025, accepted 13 June 2025, date of publication 20 June 2025, date of current version 30 June 2025.

Digital Object Identifier 10.1109/ACCESS.2025.3581641

RESEARCH ARTICLE

Outlier Detection of Photovoltaic Power Generation System Data Based on GMM-IF Algorithm

XIN LI^{1,2}, GUOXIN DU^{1,2}, YUMAN LI³, ZENGQIANG MA^{1,2}, LIHU LIU⁴,
MINGLONG JIANG^{1,2}, FEIYU LIU^{1,2}, AND TIANMING MU⁵

¹Hebei Provincial Collaborative Innovation Center of Transportation Power Grid Intelligent Integration Technology and Equipment, Shijiazhuang Tiedao University, Shijiazhuang, Hebei 050043, China

²School of Electrical and Electronics Engineering, Shijiazhuang Tiedao University, Shijiazhuang, Hebei 050043, China

³Department of Quality Inspection and Management, Hebei Chemical & Pharmaceutical College, Shijiazhuang, Hebei 050026, China

⁴National Pipeline Network Group Northern Pipeline Company Ltd., Langfang, Hebei 065000, China

⁵State Grid Shijiazhuang Electric Power Supply Company, Shijiazhuang 050051, China

Corresponding author: Yuman Li (ssqhx11@163.com)

This work was supported in part by the National Natural Science Foundation of China under Grant 12072207 and Grant 52205571, and in part by the Natural Science Foundation of Hebei Province under Grant E2021210105.

ABSTRACT The Gaussian Mixture Model (GMM) is widely used in anomaly detection due to its flexibility in handling complex data distributions and its soft classification mechanism. However, its modeling process relies on the assumption that data follows a Gaussian distribution. In contrast, time-series data from photovoltaic (PV) systems often exhibit high nonlinearity and non-stationarity, making it difficult to represent with a single Gaussian distribution, which affects detection performance. To address this issue and improve detection accuracy, this paper proposes a segmented GMM-IF outlier detection algorithm. In this method, the decision tree segmentation modeling strategy is used to structure the data to construct a local Gaussian-like distribution dataset to overcome the prior assumptions. Additionally, it integrates an Isolation Forest (IF) as the decision-making mechanism for detailed detection, further enhancing detection accuracy. Under different operating conditions and actual photovoltaic array datasets, comparative experiments were conducted using different evaluation metrics and algorithms to verify the effectiveness and superiority of the GMM-IF algorithm. Experimental results show that compared with the single model of GMM and IF, the GMM-IF algorithm has an average improvement of 3.8% in accuracy and 9.1% in F-value. Compared with other comparison algorithms, GMM-IF has obvious advantages, especially in terms of recall.

INDEX TERMS Photovoltaic power generation system, outlier detection, GMM algorithm, decision tree, IF.

I. INTRODUCTION


In recent years, environmental pollution is serious and energy crisis has arrived. The development and use of new energy have been highly concerned [1], [2]. The solar energy has the characteristics of large reserves, wide distribution and high efficiency. So it is widely used in the new energy field [3]. According to the International Agency (IEA) energy report, the global PV total has reached 760 GW by the end of 2020.

The associate editor coordinating the review of this manuscript and approving it for publication was Elizete Maria Lourenco.

It is expected to reach 1,721 GW by 2030 and to further increase to 4,670 GW by 2050 [4]. With the development of the PV industry and the increase of the total installed capacity of PV globally, it is particularly important to ensure the normal operation and maintenance of PV systems.

Due to the complex external situation of the PV array operation, the output power is susceptible to the influence of the environment such as temperature and irradiance, coupled with the abnormal operation of the PV equipment, which will lead to a large number of outliers in the output power. A large number of outliers will affect the realization of system

Hình 7.3: Trang 1 bản toàn văn của Li và cộng sự [4], *IEEE Access* tập 13, trang 108823–108837. Khung đỏ đánh dấu đúng hai ý mà dự án lấy làm ngữ cảnh: dùng *chiến lược phân đoạn bằng cây quyết định* để tạo các vùng gần Gauss, và *tích hợp Isolation Forest làm cơ chế quyết định* ở bước chi tiết. Hai con số 3,8% và 9,1% dẫn ở đoạn trên nằm ở cuối phần tóm tắt, do **trên dữ liệu của bài báo** — nơi nhóm tác giả có nhân đôi chiếu.



Hình 7.4: (Trích xuất từ Notebook 05d_thuc_nghiem_rao_chan_vat_ly.ipynb) Hai nguyên lý chạy trên dữ liệu thật của dự án: trạm 27, dải bức xạ 201–350 W/m², 8.176 quan sát. **Trái:** GMM hai thành phần, điểm đỏ là các quan sát có mật độ tương đối $P_{GMM} < 0,02$. **Phải:** phân bố điểm cô lập của Isolation Forest (100 cây), phần cam là vùng bị cắt theo $\text{contamination} = 0,03$.

Bốn phép đo thay cho precision và recall

Phát hiện ngoại lai ở đây là bài toán **học không giám sát**, và bộ dữ liệu không đi kèm nhãn sự cố do người vận hành xác nhận. Không có nhãn đối chiếu thì không tính được precision, recall hay F-score — nói cách khác, không có cách nào chấm điểm một ngưỡng là đúng hay sai. Vì vậy chất lượng của nhãn được đo bằng bốn đại lượng khác, mỗi đại lượng trả lời một câu hỏi kiểm chứng được.

Một — chất lượng phân đoạn của cây quyết định. Bước phân đoạn được chấm bằng hệ số xác định R^2 , đo trên toàn bộ 42 trạm: trung bình **0,758**, thấp nhất 0,606 và cao nhất 0,826. Con số này **không phải** độ chính xác của bộ phát hiện ngoại lai; nó chỉ đo mức các phân đoạn do cây tạo ra giữ được cấu trúc hình dạng phát điện của từng trạm, tức mức phân đoạn đủ đồng nhất để chạy GMM bên trong. Hệ số R^2 tính trên phần dư thấp hơn nhiều (0,118–0,346, trung bình 0,187), đúng như kỳ vọng, vì phần dư là phần biến động còn lại sau khi đã trừ ảnh hưởng của bức xạ nên chứa nhiều nhiễu thời tiết và sai số cảm biến.

Hai — mức giảm cảnh báo khi bắt hai cơ chế cùng đồng ý. Phép giao giữa GMM và Isolation Forest lọc bỏ phần lớn ứng viên của cả hai phía, xem Bảng 7.1.

Bản kiểm toán gốc của tầng ETL nằm trong thư mục kết quả cục bộ, không được theo dõi bằng git, nên người đọc báo cáo không dựng lại được. Để bảng dưới đây kiểm chứng được, nhóm viết script 07_local_gmm_if_audit.py trong srcs/02_transform/02_generate_outliers/. Script đọc bản kết xuất ML Mart có sẵn trên máy, tách lại ba tệp đệm mà thuật toán cần, rồi gọi chính 02_gmm_if.py nguyên bản — không viết lại thuật toán, và không mở kết nối tới cơ sở dữ liệu hay kho lưu trữ đám mây nào.

Bảng 7.1: Số ứng viên của từng cơ chế và phần còn lại sau khi bắt cả hai cùng đồng ý. Ngưỡng dùng cho GMM là $P_{GMM} < 0,02$; Isolation Forest chạy với $\text{contamination} = 0,03$. Dựng lại trên máy bằng `07_local_gmm_if_audit.py`; số liệu ghi ở `07_local_gmm_if_summary.json`.

Cơ chế	Số ứng viên	Qua được phép giao	Tỷ lệ sống sót
GMM	28.664	5.650	19,71%
Isolation Forest	36.295	5.650	15,57%

Hai tỷ lệ sống sót trong bảng là thương của cột thứ ba trên cột thứ hai:

$$\text{GMM: } \frac{5.650}{28.664} = 0,1971 \quad \text{và} \quad \text{Isolation Forest: } \frac{5.650}{36.295} = 0,1557 \quad (7.2)$$

Lớp đồng thuận vì vậy loại đi hơn bốn phần năm số cảnh báo của GMM và gần năm phần sáu số cảnh báo của Isolation Forest. Tỷ lệ này đo **mức giảm cảnh báo đơn lẻ**; nó không tương đương precision, vì phần bị loại chưa có nhãn xác nhận đúng hay sai.

Bản dựng lại cho ra cùng một kết quả. Chạy lại thuật toán trên máy, không kết nối cơ sở dữ liệu, cho 32.616 dòng bị gắn cờ so với 33.280 dòng của lần chạy ETL — chênh 664 dòng trên tổng 2.731.946. Hai lần chạy ra cùng một quyết định trên **99,75%** số dòng:

$$\frac{2.725.126}{2.731.946} = 0,99750 \rightarrow \mathbf{99,75\%} \quad (7.3)$$

Riêng trong nhóm dòng mà tầng ETL đã gắn cờ, bản dựng lại bắt lại được $29.536/33.280 = 88,75\%$. Hai tỷ lệ này khác nhau vì hai mẫu số khác nhau, không phải hai kết quả khác nhau.

Phần chênh nằm ở đầu vào chứ không ở thuật toán: tầng ETL chạy trên bản đệm trước khi ghép ML Mart, còn bản dựng lại chạy trên bản kết xuất ML Mart, nên tập dòng hai bên không trùng khít tuyệt đối. Vì vậy các con số trong mục này ghi theo bản dựng lại — đó là bản mà người đọc chạy lại được bằng một lệnh.

Ba — khả năng tách hạng của điểm cô lập. Điểm cô lập trung bình của các dòng bị gắn cờ cuối cùng là **0,5086**, so với **0,2119** ở các dòng bình thường. Khoảng cách giữa hai nhóm là $0,5086 - 0,2119 = \mathbf{0,2967}$, tức nhóm bị gắn cờ có điểm cao gấp $0,5086/0,2119 = 2,40$ lần. Chênh lệch dương và ổn định cho thấy điểm số có xếp hạng được hai nhóm, nhưng đây là bằng chứng về khả năng phân tách chứ không phải chứng nhận độ chính xác.

Bốn — độ tái lập của năm luật rào chắn vật lý. Một quy tắc lọc dữ liệu chỉ

đáng tin nếu người khác dựng lại được đúng kết quả của nó. Nhóm viết lại toàn bộ năm luật trong notebook 05d_thuc_nghiem_rao_chan_vat_ly, đọc đúng ba tệp đệm mà tầng ETL đọc — bảng đệm sản lượng, bảng đệm thời tiết và bảng chiều trạm — rồi đối chiếu từng dòng với cờ mà tầng ETL đã ghi. Kết quả ở Bảng 7.2.

Bảng 7.2: Đối chiếu số cờ do notebook dựng lại với số cờ tầng ETL đã ghi. Đọc từ ô kết quả của notebook 05d_thuc_nghiem_rao_chan_vat_ly.ipynb.

Luật	Tầng ETL ghi	Dựng lại	Trùng	Độ khớp
PHYSICAL_OVER_CAPACITY	26.501	26.819	26.501	100,0%
PHYSICAL_HIGH_ENERGY_NO_SUN	36	37	36	100,0%
PHYSICAL_HIGH_ENERGY_LOW_RAD	140	144	138	98,6%
PHYSICAL_LOW_ENERGY_STRONG_SUN	57	57	57	100,0%
PHYSICAL_DISTRIBUTION_JUMP	1.202	1.317	1.198	99,7%

Ba trên năm luật dựng lại bắt trọn 100% số cờ tầng ETL đã ghi; hai luật còn lại đạt 98,6% và 99,7%. Phần dựng lại nhiều hơn vài dòng là do ML Mart mất một ít dòng khi ghép khoá, không phải do khác công thức.

Cách dựng cận trên. Cận trên có dạng $Q_3 + m \cdot \text{safe_IQR}$, trong đó IQR được tính riêng cho từng ô (**trạm** $\times$ **mùa** $\times$ **dải bức xạ**) chứ không tính trên toàn chuỗi, để sản lượng của một điểm được so với đúng những điểm cùng hoàn cảnh nắng.

Chuỗi sản lượng ban đầu có nhiều khoảng trống thời gian, nên sau khi chia theo ba chiều đó, một số ô còn rất ít quan sát. Ô mỏng cho IQR co gần về 0; khi ấy cận $Q_3 + 1,5 \cdot IQR$ nằm sát ngay Q_3 và sẽ gấn cờ hàng loạt điểm hoàn toàn bình thường. Pipeline vì vậy đặt hai lớp bảo vệ:


- **Nhánh dự phòng theo cỡ mẫu.** Ô nào có dưới 50 quan sát thì bỏ chiều mùa, lấy thống kê của ô thô hơn (**trạm** $\times$ **dải bức xạ**) thay thế.
- **Sàn cho khoảng tứ phân vị.** Thay IQR bằng $\text{safe_IQR} = \max(IQR, 0,03 \cdot p_{95}, 0,1)$, nên dù IQR của ô có về 0 thì cận vẫn còn một biên tối thiểu suy từ quy mô của chính trạm đó.

Hệ số nhân cũng nâng từ 1,5 lên 4 để cận nghiêm hơn, tránh gấn cờ những dao động do mây che vốn hợp lệ.

Độ nhạy của ngưỡng. Cận $Q_3 + m \cdot \text{safe_IQR}$ quyết định bao nhiêu dòng bị loại khỏi tập huấn luyện, nên hệ số m được quét qua sáu mức trên cùng dữ liệu, từ mức Tukey chuẩn 1,5 tới 6. Kết quả ở Bảng 7.3 và Hình 7.5.

Bảng 7.3: Số dòng và sản lượng bị loại khi đổi hệ số nhân của `safe_IQR`. Tỷ lệ tính trên tổng 9,31 triệu kWh. Đọc từ tệp kết quả `05d_rao_chan_vat_ly/quet_he_so_safe_iqr.csv`.

Hệ số m	Số dòng bị loại	Sản lượng bị loại (kWh)	Tỷ lệ trên tổng
1,5	693	3.202	0,0344%
2	523	2.610	0,0280%
3	245	1.380	0,0148%
4 (đang dùng)	144	873	0,0094%
5	115	649	0,0070%
6	69	373	0,0040%



Hình 7.5: (Trích xuất từ Notebook `05d_thuc_nghiem_rao_chan_vat_ly.ipynb`) Quét hệ số nhân m của `safe_IQR` qua sáu mức. **Trái:** số dòng bị gán cờ. **Phải:** phần sản lượng bị ảnh hưởng, trực tung dừng ở 0,05%.


Nhìn Hình 7.5 thấy hai điều. Số dòng bị gán cờ giảm đều khi m tăng, đường giảm liên tục và **không có bậc nhảy** nào cho thấy một mức m đặc biệt tự tách ra khỏi phần còn lại. Phần sản lượng bị ảnh hưởng nằm gọn dưới mốc 0,05% trên toàn dải, cao nhất 0,0344% tại $m = 1,5$ và thấp nhất 0,0040% tại $m = 6$ — chênh nhau vốn vẹn 0,03 điểm phần trăm.

Hai quan sát trên dẫn tới một kết luận: dù chọn hệ số nào trong khoảng 1,5–6, lượng dữ liệu bị loại đều không vượt quá một phần nghìn của bộ dữ liệu, nên **lựa chọn hệ số không đủ sức làm thay đổi kết quả mô hình**. Mức 4 đang dùng là một quyết định nằm trong vùng an toàn, **không phải một mức tối ưu đã được chứng minh**.

7.1.4 Sơ đồ toàn cảnh

Hình 7.6 mô tả chín bước của quy trình. Bốn bước đầu lấy, làm sạch, chia và khảo sát dữ liệu; bước 5 sinh rồi chọn đặc trưng; bốn bước cuối huấn luyện, đánh giá, đưa mô

hình vào sử dụng và quản lý phiên bản dữ liệu cùng mô hình.



Hình 7.6: Chín bước của quy trình học máy. Đọc theo mũi tên: bước 1 ở ô trên cùng bên trái, sang phải là bước 2, xuống hàng dưới là bước 3 rồi 4, tiếp tục tới bước 9. Dòng cuối mỗi ô ghi tệp kết quả mà bước đó sinh ra.

Mỗi bước tương ứng với một notebook trong thư mục notebooks/forecasting_v4_energy/. Toàn bộ số liệu và hình ảnh trong các phần sau đều trích từ những tệp kết quả liệt kê ở Bảng 7.4.

7.1.5 Năm rào chắn chống rò rỉ dữ liệu

Rò rỉ dữ liệu là rủi ro lớn nhất của một bài toán dự báo chuỗi thời gian: chỉ cần một đặc trưng vô tình mang thông tin của tương lai, mọi chỉ số đánh giá đều trở nên vô nghĩa. Quy trình đặt năm rào chắn, mỗi rào chắn gắn với một bước cụ thể:

1. **Nhân quả trong ghép thời tiết** (bước 2). Mỗi bản ghi tại thời điểm T chỉ được ghép với khối khí tượng của giờ đã kết thúc trước T . Điều kiện này được kiểm tra

Bảng 7.4: Ánh xạ giữa bước trong quy trình và notebook thực hiện.

Bước	Notebook	Kết quả ghi ra
Chuẩn bị lưới thời gian	01_reindex_mask_outlier	lưới 15 phút liên tục
Chia dữ liệu	02_split_time_series	3 fold và tập test niêm phong
Khám phá dữ liệu	02_EDA	thống kê mô tả, ACF/PACF, tương quan
Đặc trưng thời gian	03_1_features_time	lag, rolling, chu kỳ lịch
Đặc trưng không gian	03_2_features_spatial	hình học Mặt Trời, site_scale
Đặc trưng tương tác	03_3_features_aggregate	tương tác, mã hoá phân loại
Chẩn đoán đa cộng tuyến	04_vif_diagnostics	bảng hệ số VIF
Chọn đặc trưng	05_select_features	selected_features.json
Huấn luyện	06_1, 06_2, 06_3	model.pkl, model_config.json
Chọn hàm mất mát	06_4_validate_model	bảng đối chiếu ba hàm
Đánh giá cuối	07_final_test	metrics_overall.json
Giải thích mô hình	08_explainable_ai	biểu đồ SHAP
Mô hình đối chứng	06_0b_baseline_prophet	prophet_test_summary.json

trên toàn bộ 2,73 triệu bản ghi.

- Không chồng lấn khi chia dữ liệu** (bước 3). Dữ liệu được cắt theo trục thời gian, không xáo trộn ngẫu nhiên. Tập test được tách ra trước mọi bước khác và chỉ được mở đúng một lần ở bước 7.
- Thống kê tính riêng theo từng fold** (bước 5). Các đại lượng tổng hợp như site_scale hay cs_factor được ước lượng riêng trong phần huấn luyện của từng fold, không nhìn sang phần kiểm định.
- Ngưỡng suy từ dữ liệu huấn luyện** (bước 6). Cận cắt của mục tiêu chuẩn hoá được tính từ phân vị của dữ liệu huấn luyện, rồi ghi vào tệp cấu hình để các bước sau đọc lại đúng giá trị đó thay vì tính lại trên tập khác.
- Tái lập được** (bước 6). LightGBM chạy ở chế độ tắt định trên CPU; chạy lại với cùng hạt giống ngẫu nhiên cho ra mô hình trùng khít.

Bốn rào chắn đầu được kiểm chứng bằng số liệu ở các phần tương ứng phía sau. Rào chắn thứ năm được kiểm chứng bằng hai phép chạy lại độc lập, trình bày ở Mục 4.5.

7.2 Chuẩn bị dữ liệu và chia tập

7.2.1 Dựng lại lưới thời gian liên tục

Dữ liệu sản lượng thu từ công tơ không phải lúc nào cũng đủ mốc: mất điện, mất kết nối hoặc lỗi ghi đều để lại lỗ hổng trên trục thời gian. Nếu đưa thẳng dữ liệu khuyết mốc vào bước sinh đặc trưng, các biến trễ và biến cửa sổ trượt sẽ tính sai — lag_4 lẽ ra phải lùi đúng 60 phút thì lại lùi 75 hay 90 phút, tùy vào chỗ bị khuyết.

Notebook 01_reindex_mask_outlier dựng lại lưới 15 phút liên tục cho từng trạm bằng `pd.date_range`, rồi đánh dấu những dòng vừa được chèn thêm. Thứ tự hai việc này là điều kiện bắt buộc: **dựng lưới trước, lọc sau**. Nếu lọc bỏ dòng ban đêm hay dòng ngoại lai trước khi dựng lưới, khoảng cách thời gian giữa các dòng còn lại sẽ không đều, và mọi đặc trưng trễ sau đó đều lệch.

Các dòng bị gán cờ ngoại lai ở tầng ETL không bị xóa khỏi lưới. Chúng được giữ nguyên vị trí để lịch sử không bị đứt quãng, nhưng mang nhãn loại trừ nên không đóng góp vào hàm mất mát khi huấn luyện, cũng không tham gia vào các chỉ số được báo cáo.

Ba ràng buộc thiết kế. Bước dựng lưới tuân thủ ba ràng buộc, cùng hướng tới một mục tiêu: không để thông tin của tương lai, hoặc thông tin không có thật, lọt vào lưới dữ liệu.

1. **Thời tiết chỉ được lấp theo chiều tiến.** Chỉ dùng `ffill()` theo từng trạm, tức kéo giá trị đã quan sát trong quá khứ sang hiện tại. Tuyệt đối không dùng `bfill()`, vì kéo ngược là lấy giá trị của mốc sau đắp cho mốc trước — đúng định nghĩa của rò rỉ dữ liệu.
2. **Siêu dữ liệu tĩnh thiếu thì giữ nguyên khuyết.** Các cột như `capacity_kw`, `number_of_panels`, vĩ độ và kinh độ nếu thiếu thì để nguyên khuyết, không lấp và không bịa giá trị.
3. **Điền mục tiêu theo bậc thang nhân quả.** Slot mới chèn được điền theo đúng thứ tự: `night_zero` → `causal_day_persistence` (cùng giờ hôm qua) → `causal_week_persistence` (cùng giờ tuần trước) → `causal_profile_median` → `fallback_zero`. Mọi bậc đều chỉ nhìn về quá khứ. Riêng khoảng trống từ 24 giờ trở lên được xếp vào `machine_failure_zero` và đánh dấu loại khỏi huấn luyện.

Kết quả thực thi. Khối dưới đây trích nguyên văn kết quả kết xuất của notebook 01_reindex_mask_outlier:

Đã reindex lưới 15 phút cho 42 site.

Tổng số dòng sau reindex: 2784438

- Dòng gốc: 2731946

- Dòng inserted: 52492

Forward-fill thời tiết (causal only, per-site):

- Số cột thời tiết: 15

- NaN trước: 812250

- NaN sau: 1890

- Đã lấp: 810360 giá trị

Đã điền target cho 52492 slot inserted.

--- PHÂN BỐ ENERGY_SOURCE SAU CASCADE ---

energy_source

etl_imputed 1536301

measured 1195645

machine_failure_zero 42055

night_zero 6287

causal_day_persistence 2668

fallback_zero 984

causal_profile_median 283

causal_week_persistence 215

--- GATE CHECK ---

- Target null: 0

- Energy_source rỗng: 0

PASS - Không còn target null hoặc energy_source rỗng.

Phân tích kết quả. Sáu nhãn thuộc bậc thang điền — machine_failure_zero, night_zero, causal_day_persistence, fallback_zero, causal_profile_median và causal_week_persistence — cộng lại bằng đúng 52.492, tức đúng số dòng đã chèn. Không dòng nào rơi ra ngoài bậc thang, cũng không dòng nào bị đếm hai lần. Cổng kiểm ở cuối xác nhận không còn mục tiêu khuyết và không còn energy_source rỗng.

Hạn chế của bước dựng lưới. Trong 52.492 dòng được chèn thì 42.055 dòng rơi vào nhãn machine_failure_zero, tức các khoảng trống từ 24 giờ trở lên, được gán 0 và loại khỏi huấn luyện:

$$\frac{42.055}{52.492} = 0,8012 \rightarrow 80,1\% \quad (7.4)$$

Bốn phần năm phần chèn thêm vì vậy **không mang thông tin mới**; chúng chỉ giữ chỗ để lưới thời gian không bị đứt. Phần còn lại được điền bằng các bậc suy từ lịch sử thật, gồm $6.287 + 2.668 + 984 + 283 + 215 = 10.437$ dòng, trong đó 6.287 dòng là night_zero — các mốc ban đêm vốn phải bằng 0. Số dòng thực sự được suy từ lịch sử

phát điện là $10.437 - 6.287 = 4.150$ đồng.

Một hạn chế nữa: sau khi lấp theo chiều tiến vẫn còn 1.890 ô thời tiết khuyết. Đó là các mốc nằm ở đầu chuỗi của từng trạm, nơi chưa có quan sát quá khứ nào để kéo sang. Chỉ có thể lấp những ô này bằng `bfill()`, tức lấy giá trị của mốc sau đắp cho mốc trước, mà phép đó đưa thông tin tương lai vào dữ liệu huấn luyện. Quy trình vì vậy giữ nguyên trạng thái khuyết ở các mốc đó, đổi lấy việc bảo toàn ràng buộc nhân quả. Theo khối kết xuất ở trên, phép lấp theo chiều tiến xử lý được 810.360 trên 812.250 ô khuyết ban đầu, tức $810.360/812.250 = 99,77\%$; phần còn lại là 1.890 ô. LightGBM nhận trực tiếp giá trị khuyết nên phần này không cần điền.

Cách xử lý này phù hợp với kết quả của Kim, Ko và Kim [3]. Nhóm tác giả đánh giá tác động của dữ liệu khuyết tới bài toán dự báo sản lượng quang điện và chỉ ra rằng cách xử lý phần khuyết ảnh hưởng trực tiếp tới sai số của mô hình dự báo, chứ không phải là một bước tiền xử lý trung tính, xem Hình 7.7.

However, PV power generation widely varies due to environmental factors; thus, the accurate forecasting of PV generation becomes essential. Meanwhile, weather data for environmental factors include many missing values; for example, when we estimated the missing values in the precipitation data of the Korea Meteorological Agency, they amounted to ~16% from 2015–2016, and further, 19% of the weather data were missing for 2017. Such missing values deteriorate the PV power generation prediction performance, and they need to be eliminated by filling in other values. Here, we explore the impact of missing data imputation methods that can be used to replace these missing values. We apply four missing data imputation methods to the training data and test data of the prediction

Hình 7.7: Trích đoạn abstract của Kim, Ko và Kim [3]. Khung đỏ đánh dấu câu khẳng định dữ liệu khuyết làm suy giảm hiệu năng dự báo sản lượng quang điện và cần được xử lý bằng cách điền giá trị thay thế. Đây là cơ sở để dự án tách bạch hai việc ở bước chuẩn bị dữ liệu.

Từ đó, dự án tách bạch hai việc: **dựng lại mốc thời gian** để cấu trúc chuỗi không bị đứt, và **đánh dấu nguồn gốc từng dòng** để phần dữ liệu không đáng tin không lọt vào chỉ số báo cáo. Phạm vi của bài báo và của dự án khác nhau ở một điểm: bài báo khảo sát bốn phương pháp điền khuyết cho **dữ liệu khí tượng** và kết luận phương pháp *k* láng giềng gần nhất cho kết quả tốt nhất, trong khi dự án chỉ mượn kết luận tổng quát rằng phần khuyết phải được xử lý có chủ đích.

7.2.2 Phân tích khám phá dữ liệu và các quyết định sinh đặc trưng

Trước khi sinh đặc trưng, dữ liệu được khảo sát ở notebook 02_EDA. Phạm vi khảo sát là **chỉ tập huấn luyện**, sau khi loại hai trạm 19 và 24: còn 1.480.000 dòng của 40 trạm. Đây là điều kiện bắt buộc — các quyết định sinh đặc trưng ở Phần 3 đều rút ra từ bước này, nên nếu khảo sát cả tập test thì tập test đã tham gia vào thiết kế mô hình, trái với nguyên tắc niêm phong nêu ở Mục 1.5.

Ba phạm vi con được tách riêng để mọi con số phía sau đều nói rõ nó thuộc phạm vi nào:

Doc vao : 1,550,856 dong x 12 cot | 42 tram
Sau khi bo tram [19, 24]: 1,480,000 dong | 40 tram

toan bo	1,480,000 dong	(100.00%)
ban ngay	742,116 dong	(50.14%)
do that ban ngay	606,112 dong	(40.95%)

Phân bố đơn biến của sản lượng

Bảng 7.5: Thống kê mô tả sản lượng theo ba phạm vi. Đọc từ ô kết quả của notebook 02_EDA.ipynb.


Phạm vi	Số dòng	Trung vị	Độ lệch	Độ nhọn	% bằng 0
Toàn bộ	1.480.000	0,0000	6,0612	47,3723	52,30
Ban ngày	742.116	2,7325	4,5148	25,3908	6,66
Đo thật ban ngày	606.112	3,2188	4,4313	24,5310	0,00

Phân bố lệch phải rất mạnh và nhọn: trên toàn bộ tập huấn luyện, độ lệch đạt 6,06 và độ nhọn đạt 47,37, trong khi phân phối chuẩn có cả hai bằng 0. Nguyên nhân trực tiếp là **52,30%** số quan sát bằng 0 — ban đêm và các khung giờ rìa ngày. Trung vị của toàn bộ tập cũng bằng 0, tức quá nửa dữ liệu không mang thông tin phát điện.

Hình 7.8 trình bày ba cách nhìn cùng một phân bố. Lọc về ban ngày kéo độ lệch xuống 4,51 và tỷ lệ giá trị 0 xuống 6,66%; lọc thêm điều kiện đo thật thì không còn giá trị 0 nào. Ba dòng của Bảng 7.5 vì vậy là căn cứ trực tiếp cho hai quyết định: **chỉ tính chỉ số báo cáo trên phạm vi đo thật ban ngày**, và **chuẩn hoá mục tiêu** để kéo phân bố về dạng đều hơn.

Mẫu hình phát điện và tác động của mây

Hai dạng ngày cho hai dạng chuỗi khác hẳn nhau. Ngày trời quang cho đường cong trơn dạng parabol; ngày nhiều mây cho chuỗi gập khúc liên tục. Notebook chọn hai ngày tương phản trên trạm phát mạnh nhất, và chỉ xét những ngày có ít nhất 40 mốc đo thật ban ngày cùng đủ 96 mốc trong ngày, để hình không rơi vào ngày do tăng ETL điền khuyết:



Hình 7.8: (Trích xuất từ Notebook 02_EDA.ipynb) **Trái:** histogram toàn bộ tập huấn luyện, trục tung thang loga. **Giữa:** chỉ ban ngày. **Phải:** boxplot đối chiếu hai phạm vi.

Tram 27 | 283 ngày dat dieu kien | 71 ngày nhiều nang
 Ngày trời quang: 2020-10-02 | do gap 0.0031
 Ngày nhiều mây : 2020-12-23 | do gap 0.0926

Hai ngày này không được chọn bằng mắt mà bằng một đại lượng đo trực tiếp trên chuỗi sản lượng, gọi là **độ gấp**: trung bình trị tuyệt đối của sai phân bậc hai trong ngày, chia cho đỉnh của chính ngày đó. Sai phân bậc hai đo mức đổi hướng giữa ba mốc liên tiếp, nên đường càng trơn thì độ gấp càng nhỏ; phép chia cho đỉnh khiến chỉ số không phụ thuộc quy mô trạm. Phép chọn chỉ xét trong nhóm 71 **ngày nhiều nắng** — nhóm có tổng sản lượng thuộc phần tư trên — rồi lấy ngày độ gấp nhỏ nhất làm ngày trời quang và ngày độ gấp lớn nhất làm ngày nhiều mây. Ràng buộc nhóm là cần thiết: một ngày âm u kéo dài cũng cho đường phẳng lì và độ gấp rất nhỏ, nếu không lọc trước thì nó sẽ bị chọn nhầm thành ngày trời quang.


Hình 7.9 đặt hai ngày cạnh nhau trên cùng thang trục tung. Ngày 02/10/2020 cho một đường cong trơn, lên đều rồi hạ gần đối xứng. Ngày 23/12/2020 đạt đỉnh tương đương nhưng chỉ giữ được trong ít bước, phần còn lại là chuỗi răng cưa. Độ gấp của hai ngày chênh nhau gần 30 lần: $0,0926/0,0031 = 29,9$.

Cả hai đều thuộc nhóm ngày nhiều nắng, tức lượng bức xạ khả dụng trong ngày tương đương, nhưng cho hai chuỗi khác hẳn. Phần chênh lệch đó là do mây, và mô hình không thể suy ra nó từ lịch hay từ vị trí Mặt Trời. Đây là căn cứ sinh hai đặc trưng `chi_so_troi_quang` và `rad_x_sinelev`: chúng cấp cho mô hình tín hiệu về mức che phủ **ngay tại bước hiện tại**, thay vì bắt mô hình suy ra gián tiếp từ các mốc trễ.

Tự tương quan

Bảng 7.6 ghi tự tương quan của chuỗi sản lượng tại các mốc trễ đáng chú ý.

Con số +0,9680 tại mốc 15 phút là điểm cần đọc kỹ. Ở mức tự tương quan đó, giá trị tại t gần như là bản sao của giá trị tại $t + 1$, nên một mô hình được cấp `lag_1` sẽ




Hình 7.9: (Trích xuất từ Notebook 02_EDA.ipynb) Sản lượng theo bước 15 phút tại trạm 27, hai ngày dùng chung thang trục tung. **Trái:** ngày trời quang 02/10/2020, độ gấp 0,0031. **Phải:** ngày nhiều mây 23/12/2020, độ gấp 0,0926. Trục hoành là giờ trong ngày, cắt trong khoảng 5–21 giờ vì ngoài khoảng đó sản lượng bằng 0. Số đo của hai ngày kiểm chứng được bằng `srcs/05_machine_learning/kiem_chung_bao_cao_v4.py`, mục 11.

Bảng 7.6: Tự tương quan của chuỗi sản lượng tại các mốc trễ đáng chú ý, trạm 27, 51.652 bước liên tục. Đọc từ ô kết quả của notebook 02_EDA.ipynb.

Mốc trễ	Khoảng cách	ACF
lag_1	15 phút	+0,9680
lag_4	1 giờ	+0,8942
lag_96	24 giờ	+0,7923
—	48 giờ	+0,7632
—	72 giờ	+0,7490

có lỗi tất hiển nhiên: lặp lại giá trị vừa đo. Mốc 1 giờ vẫn giữ tương quan cao +0,8942 nhưng đã đủ xa để không còn là bản sao, còn mốc 24 giờ ở +0,7923 mang thông tin chu kỳ ngày. Hình 7.10 là biểu đồ đầy đủ. Ba con số này là căn cứ định lượng cho lựa chọn trình bày ở Mục 3.1.



Hình 7.10: (Trích xuất từ Notebook 02_EDA.ipynb) **Trái:** ACF quét 288 bước = 72 giờ. **Phải:** PACF quét 96 bước = 24 giờ. Vạch đỏ chấm là mốc 96 bước.

Tương quan giữa các biến

Tương quan tính trên 606.112 dòng đo thật ban ngày, xem Bảng 7.7.

Bảng 7.7: Tương quan với sản lượng, tính trên phạm vi đo thật ban ngày, kèm cột đối chiếu khi gộp cả ban đêm. Đọc từ ô kết quả của notebook 02_EDA.ipynb.

Biến	Spearman ban ngày	Gộp cả đêm	Chênh
shortwave_radiation	+0,6043	+0,9024	+0,2981
direct_normal_irradiance	+0,5513	+0,8755	+0,3243
diffuse_solar_radiation	+0,3808	+0,8750	+0,4942
temperature_c	+0,2628	+0,4349	+0,1721
cloud_cover_total	−0,1591	+0,0330	+0,1921

Cột chênh lệch là kết quả đáng chú ý nhất của cả bước khảo sát. Nếu gộp cả ban đêm, tương quan của shortwave_radiation với sản lượng vọt từ +0,60 lên +0,90, và diffuse_solar_radiation vọt từ +0,38 lên +0,88. Mức tăng đó **không phản ánh quan hệ vật lý**: ban đêm mọi biến bức xạ và sản lượng đều bằng 0 cùng lúc, nên hơn một nửa số điểm nằm chồng tại gốc toạ độ và tự động đẩy hệ số tương quan lên. Ma trận đầy đủ ở Hình 7.11.


Cột cloud_cover_total cho thấy rõ nhất: ban ngày nó mang dấu **âm** −0,1591 — đúng ý nghĩa vật lý là mây che thì sản lượng giảm — nhưng gộp cả đêm thì đổi thành dấu dương +0,0330, tức đảo ngược hoàn toàn ý nghĩa. Vì vậy mọi tương quan trong tài liệu này đều tính trên phạm vi đo thật ban ngày.

Chẩn đoán đa cộng tuyến không nằm ở bước này. Hệ số phóng đại phương sai cần toàn bộ đặc trưng đã sinh xong, nên nó được tính ở notebook 04_vif_diagnostics và trình bày ở Mục 3.7.

7.2.3 Chia dữ liệu theo trục thời gian

Với bài toán dự báo, phép chia ngẫu nhiên thông thường là sai về nguyên tắc, vì cách chia đó cho phép mô hình học từ dữ liệu của tháng sau rồi đi dự báo tháng trước. Notebook 02_split_time_series vì vậy cắt dữ liệu **theo thứ tự thời gian**, không xáo trộn.

Trước hết, 15% số mốc thời gian cuối cùng được tách ra làm **tập test niêm phong** và cất đi. Phần còn lại, gọi là tập Phát triển, mới được dùng để sinh đặc trưng, chọn đặc trưng, tinh chỉnh siêu tham số và chọn hàm mất mát. Tập test chỉ được mở đúng một lần ở bước đánh giá cuối, sau khi mọi quyết định đã khoá.




Hình 7.11: (Trích xuất từ Notebook 02_EDA.ipynb) Ma trận tương quan Spearman trên 606.112 dòng đo thất ban ngày.

Phép cắt thực hiện trên **trục mốc thời gian**, không phải trên số dòng. Toàn bộ dữ liệu có 81.023 mốc thời gian phân biệt; cắt 15% cuối cho 12.154 mốc thuộc tập test và 68.869 mốc thuộc tập Phát triển. Ranh giới rơi vào 18/12/2021 lúc 09:30:

- **Tập Phát triển** — từ 01/01/2020 00:15 đến 18/12/2021 09:15.
- **Tập test niêm phong** — từ 18/12/2021 09:30 đến 23/04/2022 23:45.

Tỷ lệ 15% tính trên mốc thời gian tương ứng 510.468 dòng trên tổng 2.784.438, tức 18,33% khối lượng dữ liệu. Hai tỷ lệ lệch nhau do **số trạm hoạt động tăng dần theo thời gian**: đầu năm 2020 có 30 trạm phát sinh dữ liệu, tới cuối năm 2021 đủ 42 trạm, nên mỗi mốc thời gian ở giai đoạn sau mang nhiều dòng hơn giai đoạn trước. Hình 7.12 mô tả cách chia.

Phép cắt theo mốc được chọn thay vì cắt theo số dòng vì nó cho một ranh giới thời gian duy nhất áp dụng chung cho cả 42 trạm. Cắt theo số dòng sẽ khiến mỗi trạm có một mốc cắt riêng và tập test không còn là một giai đoạn liên mạch.



Hình 7.12: (Trích xuất từ Notebook 02_split_time_series.ipynb) Cách chia dữ liệu theo trục thời gian: tập test niêm phong tách ra từ phần cuối, phần Phát triển còn lại chia thành ba fold theo cửa sổ mở rộng.

7.2.4 Ba fold theo cửa sổ mở rộng

Tập Phát triển được chia thành ba fold theo kiểu **cửa sổ mở rộng** (*expanding window*): phần huấn luyện của fold sau chứa trọn phần huấn luyện lẫn phần kiểm định của fold trước. Cách này mô phỏng đúng tình huống vận hành thật — càng về sau càng có nhiều lịch sử để học — và bảo đảm phần kiểm định luôn nằm ở tương lai so với phần huấn luyện.

Phép chia fold cũng thực hiện trên trục mốc thời gian, mỗi fold nhận đúng 17.217 mốc cho phần kiểm định, còn phần huấn luyện nở rộng dần qua 17.218, 34.435 rồi 51.652 mốc.

Bảng 7.8: Ranh giới thời gian, kích thước và số trạm của ba fold, đọc từ các tệp `fold*_train_selected.parquet` và `fold*_val_selected.parquet`.

Fold	Phần huấn luyện			Phần kiểm định		
	đến	số dòng	trạm	đến	số dòng	trạm
1	28/06/2020 08:30	233.244	30	24/12/2020 16:45	606.105	39
2	24/12/2020 16:45	839.349	39	22/06/2021 01:00	711.507	42
3	22/06/2021 01:00	1.550.856	42	18/12/2021 09:15	723.114	42

Nhìn Bảng 7.8 thấy rõ tính chất mở rộng: mốc kết thúc huấn luyện của fold 2 trùng đúng mốc kết thúc kiểm định của fold 1, và tương tự giữa fold 3 với fold 2. Kích thước tập huấn luyện tăng dần từ 233 nghìn lên 1,55 triệu dòng, trong khi tập kiểm định giữ quy mô tương đương nhau, khoảng 600–720 nghìn dòng.

Hạn chế: fold sớm có trạm chưa từng xuất hiện khi huấn luyện. Cột số trạm trong Bảng 7.8 cho thấy một hệ quả trực tiếp của việc các trạm lần lượt đi vào vận hành theo thời gian. Ở fold 1, mô hình học trên 30 trạm nhưng bị chấm điểm trên 39 trạm; ở fold 2 là 39 trạm so với 42. Chênh lệch đó nghĩa là một phần dữ liệu kiểm định

thuộc về những trạm mà mô hình **chưa từng nhìn thấy một dòng nào** lúc huấn luyện. Tới fold 3 thì cả 42 trạm đều đã có mặt ở phần huấn luyện nên tình huống này không còn.

Ảnh hưởng của nó làm sai số đo trên fold 1 và fold 2 **bi quan hơn thực tế vận hành**, vì trong vận hành thật mô hình luôn đã có lịch sử của trạm mà nó dự báo. Chiều ảnh hưởng là an toàn — sai số bị đánh giá nặng hơn chứ không nhẹ đi — nhưng khi so sánh các cấu hình bằng WAPE gộp ba fold thì phần đóng góp của fold 1 vẫn mang theo thành phần sai lệch này.

7.2.5 Thực nghiệm: đo phần chồng lấn nhãn ở ranh giới fold

Ba fold được cắt liên tục, không chèn khoảng đệm giữa phần huấn luyện và phần kiểm định. Hai quy tắc chống rò rỉ nêu ở Mục 1.4 chỉ ràng buộc **đặc trưng đầu vào**; riêng **nhãn** cần một phép kiểm riêng. Nhãn của một dòng huấn luyện là sản lượng tại $T + h$, nên với những dòng nằm sát mốc cắt, thời điểm $T + h$ có thể đã rơi sang vùng kiểm định. Nhóm đo trực tiếp phần chồng lấn này.

Cách tiên hành. Với mỗi fold, đọc trực tiếp tệp `fold_i_train_selected.parquet`, lấy mốc thời gian lớn nhất $T_{\max}$ của phần huấn luyện. Một dòng có nhãn rơi sang vùng kiểm định khi và chỉ khi mốc thời gian của dòng đó lớn hơn $T_{\max} - 15h$ phút, với h là số bước của tầm dự báo. Đếm số dòng thoả điều kiện đó cho cả hai tầm H1 và H4. Phép đo chạy trên chính các tệp fold mà bước huấn luyện đọc vào, không dùng dữ liệu trung gian nào khác.

Bảng 7.9: Số dòng huấn luyện có nhãn rơi sang vùng kiểm định, tính trên từng fold và từng tầm dự báo. Đọc từ ô kết quả của notebook `05b_thuc_nghiem_tham_so_hardcode.ipynb`, Thí nghiệm 9.

Fold	Cỡ tập huấn luyện	Chồng lấn H1	Chồng lấn H4	Tỷ lệ H4
1	233.244	30	120	0,0514%
2	839.349	39	156	0,0186%
3	1.550.856	42	168	0,0108%

Trường hợp xấu nhất là fold 1 ở tầm H4: 120 dòng trên 233.244, tức **0,0514%**. Tỷ lệ nhỏ như vậy là hệ quả cấu trúc của phép cắt — chỉ những dòng nằm trong h bước cuối cùng của tập huấn luyện mới có nhãn vượt sang vùng kiểm định, mà h nhiều nhất là bốn bước.

Bảng 7.9 tự kiểm chứng được. Ở tầm H1 chỉ **một** bước cuối bị chồng lấn, nên số dòng phải bằng số trạm còn hoạt động tại bước đó: cột chồng lấn H1 cho 30, 39 và 42,

trùng khít cột số trạm ở Bảng 7.8. Cột H4 gấp đúng bốn lần các giá trị đó.

Với mức chồng lấn dưới một phần nghìn ở cả ba fold, phép cắt liên tục được giữ nguyên, không chèn khoảng đệm.

7.3 Sinh đặc trưng

Ba notebook liên tiếp bổ sung đặc trưng vào cùng một khung dữ liệu, mỗi notebook phụ trách một họ: 03_1_features_time sinh đặc trưng suy từ trục thời gian và từ lịch sử sản lượng, 03_2_features_spatial sinh đặc trưng hình học Mặt Trời cùng các đại lượng chuẩn hoá theo trạm, 03_3_features_aggregate sinh đặc trưng tương tác khí tượng và mã hoá biến phân loại. Hai notebook sau đó thu hẹp lại: 04_vif_diagnostics chẩn đoán đa cộng tuyến, 05_select_features chốt danh sách chính thức.

7.3.1 Đặc trưng thời gian, trễ và cửa sổ trượt

Notebook 03_1_features_time sinh ba nhóm đặc trưng, tóm tắt ở Bảng 7.10.

Bảng 7.10: Ba nhóm đặc trưng sinh tại notebook 03_1_features_time.ipynb. Cột cuối ghi tham số thực tế khai báo trong notebook.

Nhóm	Cột sinh ra	Tham số
Lịch và chu kỳ	minute_of_day, month, day_of_week, is_weekend, season, season_code, hour_sin, hour_cos, doy_sin, doy_cos	chu kỳ ngày 1440 phút; chu kỳ năm 365,25 ngày
Trễ	lag_4, lag_96	LAGS = (4, 96), tức $T - 60$ phút và $T - 24$ giờ
Cửa sổ trượt	rolling_mean, rolling_std, rolling_min, rolling_max cho mỗi cửa sổ	ROLLING_WINDOWS = (4, 96), bốn thống kê mỗi cửa sổ

Hai nhóm sau tạo ra 2 cột trễ cộng 8 cột cửa sổ trượt, bằng 10 cột suy từ chuỗi mục tiêu — đúng con số notebook in ra khi khai báo hàm sinh đặc trưng.

Mã hoá lịch bằng sin và cos. Nếu để giờ trong ngày ở dạng số nguyên, mốc 23:45 và mốc 00:00 cách nhau đúng một bước 15 phút trên thực tế nhưng cách nhau 23 đơn vị trên thang số. Cây quyết định chia theo ngưỡng sẽ coi hai mốc liền kề đó là hai vùng xa nhau. Cặp (sin, cos) đưa trục thời gian về một vòng tròn khép kín, nên khoảng cách

giữa hai mốc kề nhau qua nửa đêm trở lại đúng bằng khoảng cách thật. Cùng lý do, ngày trong năm được mã hoá bằng `day_sin` và `day_cos` theo chu kỳ 365,25 ngày.

Thực nghiệm: chọn mốc trễ

Khái niệm nền. *Persistence* là mô hình dự báo cơ sở: lấy giá trị quan sát tại t làm dự báo cho $t + h$. Dev và cộng sự [8] định nghĩa nó là phương pháp *giả định điều kiện tại thời điểm dự báo không thay đổi so với thời điểm quan sát*, và ghi nhận rằng cách này *chạy tốt ở các tầm dự báo ngắn*, khi điều kiện thời tiết biến thiên chậm — xem Hình 7.13.

using TES with other two common forecasting approaches, viz. persistence forecasting and average forecasting. The persistence forecasting method assumes that the conditions for the forecast do not change (especially for shorter lead times). This method works well in conditions when weather maps change very slowly with time. We also compare our approach

Hình 7.13: Trích mục *Benchmarking* của Dev và cộng sự [8]. Khung đỏ đánh dấu hai mệnh đề: *persistence* giả định điều kiện không đổi — *đặc biệt ở các tầm dự báo ngắn* — và *phương pháp này chạy tốt* khi điều kiện thời tiết biến thiên chậm.

Từ định nghĩa trên suy ra một hệ quả đại số mà bài báo không nêu: nếu $\hat{y}(t+h) = y(t)$ thì đường dự báo **chính là đường đo thật dịch phải h bước**, tức lệch pha đúng bằng tầm dự báo. Mặt khác, vì chuỗi biến thiên chậm ở tầm ngắn — đúng điều kiện mà bài báo nói *persistence* chạy tốt — nên hiệu giữa $y(t)$ và $y(t+h)$ nhỏ, và một chỉ số sai số tính theo từng điểm vẫn cho con số đẹp.

Tầm H1 của dự án đúng bằng 15 phút, nằm trọn trong vùng đó. Một mô hình lặp lại giá trị vừa đo sẽ cho **chỉ số sai số tốt** nhưng **đường dự báo trễ một nhịp** — con số đẹp ở đây không chứng minh năng lực dự báo.

Giả thuyết. Mốc trễ càng gần thời điểm dự báo thì tín hiệu càng mạnh, nhưng cũng càng dễ kéo mô hình về đúng dạng vừa nêu. Thực nghiệm này xác định mốc trễ nào được đưa vào.

Cách tiến hành. Ba cấu hình được đối chiếu trên cùng dữ liệu và cùng quy trình tinh chỉnh: cấu hình nền chỉ có `lag_96` ($T - 24$ giờ), cấu hình thêm `lag_1` ($T - 15$ phút), và cấu hình thêm `lag_4` ($T - 60$ phút). Mỗi cấu hình được chấm bằng WAPE và một phép đo lệch pha riêng: độ trễ trung bình giữa đường dự báo và đường đo thật trên từng trạm, kèm số trạm vượt ngưỡng cho phép. Ba mốc đã thử ghi ở Bảng 7.11.

Độc kết quả. Quyết định phân biệt `lag_1` với `lag_4` không dựa vào sai số mà dựa vào **lệch pha**. Nếu chỉ nhìn WAPE thì `lag_1` sẽ được chọn, vì nó cho con số thấp

Bảng 7.11: Ba mốc trễ đã được thử và quyết định tương ứng, ghi tại ô khai báo LAGS của notebook 03_1_features_time.ipynb.

Mốc trễ	Quyết định	Căn cứ ghi trong notebook
lag_96 ($T - 24$ giờ)	giữ	Chu kỳ ngày; xa thời điểm dự báo nên không tạo lệch pha
lag_1 ($T - 15$ phút)	loại	Gây lệch pha trên gần như toàn bộ đội hình; sai số theo từng điểm giảm nhưng là hệ quả của việc lặp lại giá trị vừa đo
lag_4 ($T - 60$ phút)	giữ	Đủ xa để không lặp lại được giá trị vừa đo, vẫn đủ gần để mang thông tin quán tính; qua được cổng lệch pha ở Mục 3.1.2

nhất — đúng như hệ quả đại số nêu ở đầu mục. Dự án chốt LAGS = (4, 96) và loại lag_1.

Cần nêu rõ giới hạn của bằng chứng này: notebook ghi lại **quyết định** và **căn cứ định tính**, không lưu một phép đối chứng có kiểm soát giữa ba cấu hình trên cùng một lần chạy. Bằng chứng định lượng cho cấu hình được chọn nằm ở cổng lệch pha trình bày ngay sau đây.

Cổng lệch pha đặt trước bước tinh chỉnh

Phép đo lệch pha không chạy song song với WAPE mà được đặt thành một **cổng chặn** ở đầu notebook huấn luyện: chỉ khi cổng đạt thì quy trình mới được phép chạy Optuna và huấn luyện thật.

Cách đo. Độ trễ suy từ quan hệ giữa sai số và độ dốc của đường đo thật. Nếu đường dự báo bị dịch c bước thì sai số xấp xỉ $-c$ nhân với độ dốc, nên hệ số hồi quy của sai số theo độ dốc chính là c :

$$\text{độ trễ (phút)} = -\frac{\sum_t d_t e_t}{\sum_t d_t^2} \times 15, \quad d_t = \frac{y_{t+1} - y_{t-1}}{2}, \quad e_t = \hat{y}_t - y_t. \quad (7.5)$$

Cách này **tách sai số biên độ khỏi sai số thời điểm**: dự báo cao hơn hay thấp hơn thực tế đều không làm đổi con số, chỉ việc đến sớm hay đến muộn mới làm đổi.

Ngưỡng và kết quả. Cổng yêu cầu độ trễ nằm trong ± 5 phút và không trạm nào vượt ngưỡng. Kết quả in ra ở notebook 06_1_train_mae:

TRAIN THU NHANH DE DO TRE (truoc khi tune)

Train thu 300,000 dong x 54 dac trung trong 9.3 giay

TREN 288,735 diem ban ngay cua tap test:

Do tre : +2.46 phut (duong = du bao di SAU thuc te)

Nguong cho phep: +/- 5.0 phut

WAPE tham khao : 22.47% (model nho, chua tune - chi de doi chieu)

Site vuot nguong: 0/40

Tre theo site: trung vi +2.79 phut | nho nhat +1.64 | lon nhat +3.71

CONG DO TRE: DAT - tre +2.46 phut, khong site nao vuot nguong.

Cho phep chay Optuna va train that.

Mô hình dùng ở cổng. Cổng chạy trên một mô hình nháp, cùng thuật toán và cùng hàm mất mát với mô hình cuối nhưng nhỏ hơn nhiều, xem Bảng 7.12.

Bảng 7.12: Mô hình nháp dùng ở cổng lệch pha so với mô hình cuối. Đọc từ ô cấu hình cổng lệch pha trong notebook 06_1_train_mae.ipynb.

	Mô hình nháp (cổng)	Mô hình cuối
Thuật toán	LightGBM	LightGBM
Hàm mất mát	l1 (MAE)	l1 (MAE)
Số đặc trưng	54	54
Trọng số mẫu	có	có
Quy mô tập đầu vào	300.000 lấy ngẫu nhiên	1.550.856
Số cây	200, đặt cố định	Optuna chọn
Tốc độ học	0,08, đặt cố định	Optuna chọn
num_leaves	63, đặt cố định	Optuna chọn
Thời gian huấn luyện	9,3 giây	hàng chục phút

Vì thuật toán, hàm mất mát và danh sách đặc trưng giống hệt mô hình cuối, cổng kiểm được đúng thứ nó cần kiểm: **bộ đặc trưng có đầy mô hình vào hành vi bám trụ hay không**. Nếu lag_1 có mặt thì mô hình nháp cũng sao chép giá trị gần nhất y như mô hình cuối.

Cổng này đặt trước bước tinh chỉnh nên chỉ kiểm bộ đặc trưng. Sau khi Optuna chọn xong siêu tham số và huấn luyện mô hình cuối, notebook chạy tiếp một phép quét độ trễ thứ hai trên toàn bộ tập kiểm định — trình bày ở phần đánh giá.

Rào chắn chống rò rỉ và ngữ cảnh lùi

Bước sinh đặc trưng đặt hai rào chắn. Thứ nhất, mọi đặc trưng suy từ mục tiêu đều được dịch: các cột của sổ trượt tính trên chuỗi mục tiêu **đã dịch một bước**, nên giá trị tại T không bao giờ chứa sản lượng đo tại chính T .

Thứ hai, một **mặt nạ lịch sử liên tục** kiểm tra rằng toàn bộ số bước của cửa sổ liền trước đều cách nhau đúng 15 phút; nếu cửa sổ vắt qua một chỗ đứt gãy, giá trị bị gán khuyết thay vì được tính bừa trên hai đoạn không liền nhau.

Ngữ cảnh lùi. Mỗi tập được nối thêm lịch sử của tập liền trước trước khi tính đặc trưng, rồi chỉ xuất phần dòng thuộc chính tập đó. Tập test dùng toàn bộ tập Phát triển làm ngữ cảnh, tập kiểm định dùng tập huấn luyện, và phần kiểm định của mỗi fold dùng phần huấn luyện của chính fold đó. Nhờ vậy dòng đầu tiên của mỗi tập vẫn có đủ lịch sử, mà mỗi fold vẫn là một thí nghiệm khép kín.

Kết quả thực thi. Khối dưới đây trích nguyên văn kết quả kết xuất của notebook 03_1_features_time:

```
So đặc trưng target sẽ tạo: 2 lag + 8 rolling = 10 cột
```

```
Đã sinh đặc trưng thời gian cho development và test  
(đã ghi file và giải phóng RAM).
```

```
- development: 2273970 dòng x 74 cột  
- test        : 510468 dòng x 75 cột
```

```
Đã sinh đặc trưng thời gian cho train/val (đã ghi file và giải phóng RAM).
```

```
- train_alias: 1550856 dòng x 75 cột  
- val_alias  : 723114 dòng x 75 cột
```

```
fold_1: train 233244 dòng | val 606105 dòng | 76 cột  
fold_2: train 839349 dòng | val 711507 dòng | 76 cột  
fold_3: train 1550856 dòng | val 723114 dòng | 76 cột
```

```
Số lượng NaN trong các tập:
```

```
- Train: 21000 (Đã dropna ở bước 7)  
- Val:    0  
- Test:   0
```

```
0 điểm đứt gãy - lưới thời gian liên tục 100% nhờ Reindex Notebook 01.  
(Tổng số dòng: 1550856)
```


Ô khuyết chỉ xuất hiện ở tập huấn luyện, tại các dòng đầu chuỗi chưa đủ 96 bước lịch sử để tính cửa sổ dài. Tập kiểm định và tập test không còn ô khuyết nào nhờ ngữ cảnh lùi.

7.3.2 Hình học Mặt Trời, bức xạ trời quang và chuẩn hoá theo trạm

Notebook 03_2_features_spatial sinh nhóm đặc trưng suy từ vị trí Mặt Trời, còn 03_3_features_aggregate sinh nhóm tương tác khí tượng và mã hoá biến phân loại. Cả hai nhóm đều là **hàm xác định của thời gian và vị trí** hoặc là tổ hợp của các biến đã có, nên không mang rủi ro rò rỉ.

Vị trí Mặt Trời theo thuật toán NOAA

Góc cao h và góc phương vị được tính theo thuật toán vị trí Mặt Trời chuẩn của NOAA — chuỗi Fourier cho độ xích vĩ, phương trình thời gian và góc giờ. Đây là công cụ tham chiếu chính thức, xem Hình 7.14.



Hình 7.14: NOAA Solar Calculator của Global Monitoring Laboratory — công cụ chính thức tính vị trí Mặt Trời mà hàm `tinh_goc_mat_troi` của dự án dựa theo.

Ba chi tiết cài đặt đáng nêu, tóm tắt ở Bảng 7.13.

Cách cắt mùa theo **nguyên tháng** là một xấp xỉ: giờ mùa hè ở Úc bắt đầu Chủ nhật đầu tiên của tháng 10 và kết thúc Chủ nhật đầu tiên của tháng 4, nên vài ngày đầu hai tháng đó nhận độ lệch chênh một giờ — khoảng 12 ngày mỗi năm.

Bức xạ trời quang theo mô hình Haurwitz

GHI (*Global Horizontal Irradiance*) là **tổng bức xạ Mặt Trời chiếu xuống một mặt phẳng nằm ngang**, đơn vị W/m^2 . Nó gồm hai thành phần cộng lại: phần trực xạ đi thẳng từ đĩa Mặt Trời và phần khuếch tán do bầu khí quyển và mây tán xạ. Trong dữ liệu của dự án, hai đại lượng này nằm ở **hai cột khác nhau** và không được lẫn:

Bảng 7.13: Ba chi tiết cài đặt của bước hình học Mặt Trời.

Chi tiết	Trong mã nguồn	Lý do
Quy đổi về giờ UTC	<code>utc = ts - tz_gio</code> , với <code>tz_gio</code> bằng 11 cho tháng 10-3 và 10 cho tháng 4-9	Mốc trong dữ liệu là giờ địa phương của Úc , còn công thức thiên văn cần giờ UTC. Úc áp dụng giờ mùa hè nên độ lệch đổi theo mùa
Góc phương vị	<code>np.arctan2(...)</code> thay cho <code>arccos</code>	<code>arccos</code> chỉ trả về miền $[0^\circ; 180^\circ]$ nên không phân biệt được buổi sáng với buổi chiều; <code>atan2</code> liên tục trên trọn vòng 360°
Dạng vòng của góc	<code>azimuth_sin, azimuth_cos</code>	Góc đo bằng độ gián đoạn ở mốc 0° và 360° : 359° và 1° kề nhau thực tế nhưng cách xa trên thang số

- `shortwave_radiation` — GHI đo được thực tế, do Open-Meteo cung cấp.
- `ghi_cs` — GHI_{cs} , giá trị lý thuyết khi trời hoàn toàn quang, do nhóm tự tính bằng mô hình Haurwitz từ góc cao Mặt Trời.

Vì GHI_{cs} ứng với điều kiện không mây, nó là mức trần mà bức xạ đo được chỉ có thể tiệm cận chứ không nên vượt qua.

Từ góc cao suy ra bức xạ ngang trời quang:

$$GHI_{cs} = 1098 \times \sin(h) \times \exp\left(-\frac{0,059}{\sin(h)}\right) \quad (\text{W/m}^2) \quad (7.6)$$

Cặp hằng số 1098 và 0,059 lấy đúng bản cài đặt Haurwitz của thư viện `pvlib`, vốn dẫn về hai bài gốc của Haurwitz [5]. Hình 7.15 là đoạn tóm tắt của bài báo nguồn.

ABSTRACT

From records of insolation and from observations of cloudiness and cloud density obtained at Blue Hill Observatory relations have been derived which give the amount of insolation, T , to be expected on the average with a given cloudiness, cloud density and solar air mass. These relations are of the form $T = (a/m)e^{-bm}$ where m = air mass (i.e. secant of zenith distance of the sun), e = base of natural logarithms, a and b are constants which depend on the cloudiness and cloud density. The effect of the cloud density on the insolation is of the same importance as cloudiness if the sky is largely covered.

The following table shows the insolation for different values of cloudiness and density and for air masses 1 and 3 in cal/cm²/hr. It will be seen that, especially with larger values of the cloudiness, the effect of the

Hình 7.15: Đoạn tóm tắt bài báo Haurwitz [5], *Journal of Meteorology* tập 2, tr. 154–166. Khung đỏ đánh dấu dạng công thức $T = (a/m)e^{-bm}$ với m là khối không khí — nguồn gốc của mô hình trời quang mà dự án dùng.

Mô hình trời quang thuần thiên văn ước lượng thiếu so với bức xạ đo tại các trạm, nên GHI_{cs} được nhân thêm hệ số hiệu chỉnh riêng từng trạm, đặt tên `cs_factor`. Hệ số này **tính riêng trên phần huấn luyện của từng fold**, xem Bảng 7.14.

Bảng 7.14: Hệ số hiệu chỉnh trời quang `cs_factor` theo từng fold. Đọc từ ô kết quả của notebook `03_2_features_spatial.ipynb`.

Phạm vi tính	Trung vị	Nhỏ nhất	Lớn nhất
Phần huấn luyện fold 1	1,460	1,105	1,827
Phần huấn luyện fold 2	1,538	1,520	1,819
Phần huấn luyện fold 3	1,557	1,541	1,809

Giá trị đổi rõ giữa các fold — trung vị từ 1,460 lên 1,557 — nên việc dùng chung một bộ thống kê cho cả ba fold sẽ đưa thông tin của giai đoạn sau vào fold sớm. Notebook ghi thẳng nguyên tắc này ở ô kết quả: *mỗi fold dùng thống kê quy mô tính riêng từ tập train của chính fold đó*.

Thực nghiệm: hạ độ phân giải bức xạ từ một giờ về mười lăm phút

Vấn đề. Dữ liệu khí tượng có tần suất một giờ, còn lưới sản lượng có tần suất 15 phút, nên mỗi giá trị bức xạ lặp lại bốn lần liên tiếp: trong một giờ, đặc trưng bức xạ không phân biệt được mốc 12:00 với mốc 12:15.

Nguyên lý. Bailey và cộng sự [6] mô tả thuật toán của Graham và Hollands (1990): tách chỉ số trời quang theo giờ k_t thành mô hình cộng $k_t = k_{tm} + \alpha$ gồm thành phần xu thế và thành phần nhiễu. Điểm cốt lõi là hạ độ phân giải **chỉ số trời quang** chứ không phải bức xạ — vì bức xạ mang cả biến thiên nhật triều, còn chỉ số trời quang thì không. Đoạn nguồn ở Hình 7.16.

Dự án giữ đúng thành phần xu thế k_{tm} — giữ chỉ số trời quang không đổi trong mỗi khối giờ rồi nhân lại với GHI_{cs} tính ở từng mốc 15 phút — và bỏ thành phần nhiễu α , vì α dùng để sinh chuỗi tổng hợp, còn ở đây bức xạ là đặc trưng đầu vào cho mô hình dự báo.

Kết quả đo. Thước đo là tỷ lệ bước có giá trị bức xạ thay đổi so với bước liền trước, tính riêng trên các dòng ban ngày. Khối kết quả của notebook:


```

--- TỶ LỆ BƯỚC CÓ GIÁ TRỊ BỨC XẠ THAY ĐỔI, TOÁN TẬP TRAIN (CHI BAN NGÀY) ---
Số dòng ban ngày: 751,408 / 1,550,856 (48.5%)
Trước downscale : 26.7%
Sau downscale   : 76.7%
Mục tiêu là trên 90 phần trăm.
[CANH BAO] Chưa đạt 90 phần trăm, kiểm lại bước downscale.
```

Tỷ lệ tăng gần ba lần, từ 26,7% lên 76,7%. Hình 7.17 cho thấy hiệu quả trên một cửa sổ sáu giờ.

surements of solar radiation to time series at a minute scale by matching the closest day between the hourly input of observed data and a generated hourly time series. There are many other studies that temporally downscale according to this first definition (Buster et al. (2021), Frimane et al. (2019), Zhang et al. (2018), Grantham et al. (2017), Skartveit & Olseth (1992)).

The second approach is less widely studied but important for future projections. Graham & Hollands (1990) developed a simple algorithm that disaggregates the hourly clear sky index, k_t , into an additive model: $k_t = k_{tm} + \alpha$. Here, the clear sky index is a measure of atmospheric transparency for incoming solar radiation. They identified sets $\{k_{tm}\}$, a trend component, and $\{\alpha\}$, a noise component, for all values of k_t , the daily average clear sky index, and assessed the variability observed in α by conditioning according to k_t . In this way, the method is similar to an analog method, which uses observed data at the desired spatial or time scale as the downsampled data (Zorita & Von Storch (1999)), but only for the errors, α . Aguiar & Collares-Pereira (1992) developed the Time-Dependent, Autoregressive, Gaussian (TAG) Model for hourly time series generation based on the daily clearness index as input. The TAG algorithm claims better consistency compared to Graham & Hollands (1990), which may be due to more locations that were used in its development. Grantham et al. (2016) proposes an additive model to generate hourly synthetic times series of GHI data. The model includes a Fourier series component, autoregressive component, and a stochastic component. The stochastic component bins errors according to solar elevation and zenith angle. Then, synthetic series are created by drawing from these bins to add stochastic error for the given solar angle and elevation at the hour being modeled. This method is similar to an analog method which essentially uses observed data as the final simulation. Finally, the distribution of the synthetic solar radiation is adjusted to match



Hình 7.17: (Trích xuất từ Notebook 03_2_features_spatial.ipynb) Bức xạ tại trạm 1, ngày 19/12/2020, từ 11 giờ đến 17 giờ. **Trên:** dữ liệu gốc theo giờ, mỗi giá trị lặp bốn lần nên đường đi thành bậc thang. **Dưới:** sau khi hạ độ phân giải, đường biến thiên theo từng bước 15 phút.

Chuẩn hoá quy mô theo trạm

Bốn mươi hai dàn quang điện có quy mô rất khác nhau, nên quy mô được ước lượng từ chính dữ liệu và **chỉ từ phần huấn luyện**: `site_scale` là phân vị 99 của sản lượng ban ngày, `tran_cong_suat` là phân vị 99,9. Bảng 7.15 trích tám trạm đầu trong bảng notebook in ra.

Bảng 7.15: Quy mô trạm tính trên tập huấn luyện, tám trạm lớn nhất. Đọc từ ô kết quả của notebook 03_2_features_spatial.ipynb.

Trạm	site_scale	tran_cong_suat	cs_factor
27	97,19	99,00	1,55
11	92,05	92,72	1,74
25	79,73	82,42	1,55
19	41,73	42,80	1,55
18	35,04	36,21	1,55
6	27,53	28,51	1,74
8	26,50	26,89	1,74
1	21,50	22,73	1,70

Một mô hình học thẳng trên sản lượng thô sẽ dành phần lớn sức mô tả để phân

biệt trạm lớn với trạm nhỏ, thay vì học quan hệ giữa thời tiết và sản lượng — đó là lý do mục tiêu được chuẩn hoá trước khi huấn luyện.

Tương tác khí tượng và mã hoá biến phân loại

Notebook 03_3_features_aggregate sinh năm đặc trưng tương tác, xem Bảng 7.16.

Bảng 7.16: Năm đặc trưng tương tác, tỷ lệ khuyết trên tập huấn luyện và tương quan Pearson với mục tiêu tính trên 763.740 dòng ban ngày. Đọc từ ô kết quả của notebook 03_3_features_aggregate.ipynb.

Đặc trưng	Định nghĩa	Khuyết	Pearson
temp_x_shortwave	hiệt độ × bức xạ ngang	0,01%	0,3487
diffuse_ratio	bức xạ khuếch tán / bức xạ ngang	47,43%	−0,2350
dni_ratio	bức xạ trực xạ / bức xạ ngang	47,43%	0,2350
cloud_x_shortwave	mây toàn phần × bức xạ ngang	0,01%	0,1921
cloud_low_x_shortwave	mây tầng thấp × bức xạ ngang	0,01%	0,1650

Tỷ lệ khuyết 47,43% (735.612 dòng) của hai đặc trưng dạng thương đến từ mẫu số: ban đêm bức xạ ngang bằng 0 nên phép chia không xác định. Giá trị khuyết được giữ nguyên thay vì điền 0, để mô hình cây học nhánh riêng cho dữ liệu khuyết. Số giá trị vô cực trên cả năm cột bằng 0.

Mã hoá biến phân loại. Bảng mã được khớp **chỉ trên phía huấn luyện** rồi áp cho phía kiểm định; notebook khớp được 8 bảng mã, và số ô gặp hạng mục lạ trên tập kiểm định bằng 0.

Kiểm chứng cuối bước sinh đặc trưng. Notebook in ra ba phép kiểm:

```

--- KIEM TRA 1: dac trung target deu duoc shift ---
Cot lag con lai sau khi khu tre pha: ['lag_4', 'lag_96']
lag_96(t) == target(t-96) tren mau: DAT
--- KIEM TRA 2: ty le dong co lich su day du ---
- train      : 99.74% dong co du lich su lien tục
- val        : 100.00% dong co du lich su lien tục
--- KIEM TRA 3: hang muc la (unseen category) ---
Tong so o gap hang muc la trong val: 0

```

Sau ba notebook sinh đặc trưng, tập huấn luyện đi từ 50 cột lên 114 cột, trong đó 46 cột là đặc trưng ứng viên; các fold mang 115 cột do có thêm cột đánh dấu fold.

7.3.3 Định nghĩa các đặc trưng dẫn xuất

Một số cột xuất hiện trong bảng chẩn đoán và bảng chấm điểm ở Mục 3.7 là đại lượng dẫn xuất, không đọc thẳng từ dữ liệu nguồn. Bảng 7.17 ghi công thức của chúng.

Bảng 7.17: Công thức các đặc trưng dẫn xuất. Đọc từ mã nguồn notebook 03_2_features_spatial.ipynb và 03_3_features_aggregate.ipynb.

Đặc trưng	Công thức	Ý nghĩa
ky_vong	$\text{site_scale} \times \max(\sin h, 0)$	Mức sản lượng kỳ vọng của trạm tại góc cao hiện tại, nếu trời hoàn toàn quang
ty_le_bao_hoa	$\text{clip}\left(\frac{\text{ky_vong}}{\text{tran_cong_suat}}, 0, 3\right)$	Mức kỳ vọng đã tiến sát trần công suất tới đâu
con_cach_tran	$\text{tran_cong_suat} - \text{ky_vong}$	Khoảng dư còn lại tới trần, tính bằng kWh
rad_x_sinelev	$\text{shortwave_radiation} \times \sin h$	Bức xạ chiếu hiệu dụng lên mặt phẳng ngang
clearsky_proxy	$(\sin h)^{1,2}$	Dạng đường cong ngày thuần hình học, nhọn hơn $\sin h$ một chút
chi_so_troi_quang	$\text{clip}\left(\frac{\text{shortwave_radiation}}{\text{ghi_cs}}, 0, 1,5\right)$	Tỷ lệ bức xạ đo được trên bức xạ trời quang đã hiệu chỉnh theo trạm
temp_x_shortwave	$\text{temperature_c} \times \text{shortwave_radiation}$	Tương tác nhiệt độ và bức xạ
diffuse_ratio	$\text{clip}\left(\frac{\text{diffuse_solar_rad.}}{\text{shortwave_rad.}}, 0, 10\right)$	Phần khuếch tán chiếm bao nhiêu trong tổng bức xạ
cloud_x_shortwave	$\text{cloud_cover_total} \times \text{shortwave_radiation}$	Tương tác mây toàn phần và bức xạ

Hai cột `con_cach_tran` và `clearsky_proxy` được sinh ra ở bước đặc trưng nhưng **không lọt vào bộ được chọn**: `clearsky_proxy` tương quan 0,9973 với `sin_elevation` nên mang thông tin trùng lặp, còn `con_cach_tran` không đạt

ngưỡng thông tin tương hỗ.

Một đỉnh chính về tên gọi. Tên `chi_so_troi_quang` gợi ý rằng giá trị 1,0 tương ứng trời hoàn toàn quang. Phép kiểm chứng cho thấy điều đó không đúng với cột này: sau khi GHI_{cs} đã nhân hệ số hiệu chỉnh theo trạm, tỷ lệ đo được **không đạt tới 1,0 ngay cả vào lúc quang nhất giữa trưa** — giá trị lớn nhất ở nhóm góc cao 50–90° chỉ đạt 0,760. Vì vậy tài liệu này không mô tả nó như một chỉ số trời quang có ý nghĩa vật lý trực tiếp, mà gọi đúng bản chất là **biến tỷ lệ bức xạ đã hiệu chỉnh theo từng trạm**. Nó vẫn hữu ích làm đặc trưng đầu vào vì thứ tự giữa các quan sát trong cùng một trạm được bảo toàn, mà cây quyết định chỉ dùng thứ tự để tách nhánh.

Về cột `pv_clr_loni_j`. Dự án có cài đặt chỉ số K của Lonij đúng nguyên bản — phân vị 80, của số trượt 15 ngày theo từng khung giờ, có `shift(1)` nên chỉ nhìn quá khứ — thành cột `pv_clr_loni_j`. Cột này đạt điểm quan trọng biến 1,959, đứng hạng 6 trong bảng chẩn đoán ở Mục 3.7, nhưng không lọt Top 35 theo thông tin tương hỗ và không nằm trong danh sách bảo vệ, nên bị loại ở bước chọn theo đúng quy tắc đã đặt trước.

Cột này nối trực tiếp với lập luận về mức phân vị ở Mục 3.5: dự án cài cả phương án phân vị 80 của Lonij lẫn phương án phân vị 99 của mình, rồi để bước chấm điểm quyết định bằng số liệu thay vì chọn trước bằng lập luận.

7.3.4 Thực nghiệm: khử độ trễ cài sẵn bằng đặc trưng tại thời điểm mục tiêu

Vấn đề. Nhân cần dự báo nằm ở thời điểm $T+h$, nhưng các đặc trưng hình học Mặt Trời và nhãn lịch — `sin_elevation`, `ghi_cs`, `hour` — vẫn là giá trị tại T . Mô hình do đó dùng vị trí Mặt Trời lúc T để dựng lại sản lượng lúc $T+h$, và đường dự báo sinh ra chính là đường Mặt Trời bị trễ đúng h bước. Đây là hệ quả cấu trúc của bài toán, và tác động của nó lan rộng vì cùng đại lượng đó cũng là mẫu số chuẩn hoá ở Mục 3.5.

Cách xử lý. Quy trình khai báo một danh sách 22 cột **tất định** — hình học Mặt Trời cùng các đại lượng suy ra từ nó, và toàn bộ nhãn thời gian theo lịch — rồi sinh thêm bản của chúng tại $T+h$ với hậu tố `_mt`, đồng thời **giữ nguyên** bản tại T . Ở tầm H1 sinh được 14 cột, nâng tổng số đặc trưng vào mô hình từ 40 lên 54.

Ranh giới hợp lệ của phép dịch. Vị trí Mặt Trời và nhãn lịch tại $T+h$ là kết quả tính toán thiên văn và lịch thuần túy; đứng ở thời điểm T đã biết chính xác chúng bằng bao nhiêu, không cần chờ tới $T+h$ mới đo. Điều này khác hẳn biến khí tượng: bức xạ và mây tại $T+h$ chỉ biết được sau khi đo, nên `shortwave_radiation`, `lag_96` và toàn bộ nhóm `rolling_*` bắt buộc giữ nguyên ở T . Ranh giới đó chính là điều kiện để phép dịch này hợp lệ.

Thêm chứ không thay thế. Phương án thay thế hẳn bản tại T bằng bản tại $T+h$ đã được thử và bị bác bỏ bằng số liệu. Phép đo lấy sai số MAE của đường bao $\hat{y} = \text{site_scale} \times \sin h$ so với sản lượng thật trên tập Phát triển, tính riêng theo khung giờ, cho kết quả ở Bảng 7.18.

Bảng 7.18: So sánh dùng đặc trưng tất định tại T với tại $T+h$, đo bằng MAE của đường bao $\text{site_scale} \times \max(\sin h, \varepsilon)$ so với sản lượng thật tại $T+15$ phút, trên 999.010 dòng ban ngày của tập Phát triển. Kiểm chứng bằng `srcs/05_machine_learning/kiem_chung_bao_cao_v4.py`, mục 10.

Khung giờ	Số dòng	Dùng tại T	Dùng tại $T+h$	Chênh
Toàn bộ ban ngày	999.010	3,1425	3,1296	−0,4%
Sáng 06–09h	246.305	2,1580	2,7258	+26,3%
Chiều 16–18h	189.966	2,9646	2,4136	−18,6%

Hai khung giờ cho hai kết luận ngược nhau, nên không phương án nào thắng tuyệt đối. Trên toàn bộ ban ngày hai bản chênh nhau 0,4%, tức gần như tương đương; chênh lệch chỉ lộ ra khi tách theo khung giờ. Buổi sáng sản lượng thật **đi sau** Mặt Trời, vì tấm pin còn lạnh và ẩm sương, inverter đang trong giai đoạn khởi động — nên giá trị tại T khớp hơn 26,3%; buổi chiều thì ngược lại, giá trị tại $T+h$ khớp hơn 18,6%. Quy trình vì vậy giữ cả hai bản và để mô hình tự chọn theo khung giờ, thay vì áp một phương án cho cả ngày.

Bảng này được tính lại từ dữ liệu chứ không chép từ khối ghi chú trong mã nguồn. Khối ghi chú đó ghi ba cặp số khác (3,1873 với 3,1884; 1,5934 với 2,1833; 3,4002 với 2,8574) nhưng không kèm phạm vi dòng nên không dựng lại được. Hai lần đo cùng chiều ở cả ba khung giờ; báo cáo lấy bản dựng lại được.

7.3.5 Chuẩn hoá mục tiêu theo vật lý

Bốn mươi trạm có quy mô chênh nhau nhiều lần, và sản lượng trong ngày biến thiên theo góc cao Mặt Trời. Nếu huấn luyện thẳng trên sản lượng thô, mô hình phải dành phần lớn sức mô tả để phân biệt trạm lớn với trạm nhỏ và để học lại nhịp ngày đêm — hai thứ đã biết trước bằng công thức. Mục tiêu vì vậy được đổi sang một tỷ số không thứ nguyên:

$$k_{\text{target}} = \text{clip}\left(\frac{y}{\text{site_scale} \times \max(\sin h, \varepsilon)}, 0, k_{\text{max}}\right) \quad (7.7)$$

Mẫu số gồm hai phần: `site_scale` khử chênh lệch quy mô giữa các trạm, còn $\sin h$ khử nhịp ngày đêm. Phép `max` đặt một sàn ε cho mẫu số, vì lúc Mặt Trời sát đường

chân trời thì $\sin h \rightarrow 0$ và tỷ số sẽ nổ tung.

Sau khi mô hình dự báo $\hat{k}$, giá trị được nhân ngược về kWh rồi chặn trần:

$$\hat{y} = \min\left(\hat{k} \times \text{site_scale} \times \max(\sin h, \varepsilon), \text{tran_cong_suat} \times 1,02\right) \quad (7.8)$$

Cả site_scale và tran_cong_suat đều là phân vị của chính chuỗi sản lượng nên mang đơn vị kWh trên mỗi bước 15 phút, cùng đơn vị với y ; phép chặn vì vậy không cần hệ số đổi đơn vị nào.

Cơ sở của cách chuẩn hoá. Việc chia sản lượng đo được cho một mức tham chiếu suy từ chính hệ thống là cách làm đã có trong tài liệu. Engerer và Mills [7] tổng kết các phương pháp trước đó và dẫn lại chỉ số K của Lonij và cộng sự [12], vốn định nghĩa mức tham chiếu bằng một **phân vị của chính sản lượng đo được**.

Điểm cần đọc kỹ ở tài liệu nguồn là **không có một mức phân vị chuẩn**. Ngay trên cùng một trang tổng kết, hai công trình tiền lệ chọn hai mức khác hẳn nhau, xem Hình 7.18.

where PV_{MEAS-G} is the measured 15-minute energy value for each system, E_{gtc} is the 15-minute clear-sky plane-of-array irradiance estimated using the Bird Clear Sky Model [3], and the factor of 1000 converts the irradiance to suns. After removing days with system outages, the clear-sky BPI (CSBPI) for each system is defined as the 93rd percentile of the set of BPI values in the training set.

The clearness index of Lonij et al. [36] is defined as

where E_{gt} is the plane-of-array irradiance, E_{gtc} is the clear-sky plane-of-array irradiance, PV_{MEAS-L} is the measured power output normalized by a system's peak power, and PV_{CLR-L} is its clear-sky normalized power output. PV_{CLR-L} is defined as the 80th percentile of PV_{MEAS-L} at the specified time of day on the previous 15 days for a system Lonij et al. [36]. System-specific factors, like shading, were then removed by taking the 80th percentile of an ensemble of 80 systems spread across a 50 x 50 km² region Lonij et al. [36].

The numerators in BPI and K are equivalent to that in K_{PV} : PV_{MEAS-G}

Hình 7.18: Trích trang 21 của Engerer và Mills [7]. Hai đoạn được đánh dấu cho thấy hai công trình tiền lệ dùng hai mức phân vị khác nhau để dựng mẫu số: Golnas lấy phân vị 93, còn Lonij và cộng sự [12] lấy phân vị 80.

Hai mức chênh nhau 13 điểm mà cả hai đều được công bố, vì mỗi bên dựng mẫu số theo một cách. Điều đó có nghĩa mức phân vị là **tham số thiết kế đi kèm cách dựng mẫu số**, không phải hằng số vật lý mượn được từ tài liệu. Mức của dự án vì vậy phải

được biện minh bằng thực nghiệm trên chính dữ liệu của dự án.

Cận cắt suy từ dữ liệu, không đặt tay. Tham số $k_{\max}$ không được gán một hằng số trong tệp cấu hình. Notebook huấn luyện đặt `CLIP_K = None` rồi gọi hàm `tinh_clip_tu_train()` để tính nó bằng phân vị 99 của k trên chính tập huấn luyện. Giá trị thu được và ghi vào `model_config.json` là **1,3764**, tính trên 681.536 giá trị k . Mức phân vị 99 được chọn bằng phép quét ở Bảng 7.19.

Bảng 7.19: Quét mức phân vị dùng làm cận cắt, chạy trên **tập kiểm định**. Đọc từ tệp kết quả `05_selected/quet_muc_phan_vi_nguong_cat.csv`.

Mức phân vị	Ngưỡng cắt	Tỷ lệ bị cắt (%)	WAPE kiểm định (%)
0,900	1,1525	10,00	22,6101
0,950	1,2341	5,00	22,5211
0,975	1,3090	2,50	22,4949
0,990	1,4015	1,00	22,4901
0,995	1,4832	0,50	22,4900
0,999	1,9297	0,10	22,4900
1,000	13,4137	0,00	22,4900

Đường cong WAPE phẳng từ mức 0,99 trở lên — ba mức cuối chỉ chênh nhau 0,0001 điểm phần trăm. Bên dưới mức đó thì sai số xấu dần, tới 22,6101% ở phân vị 0,90 vì cắt mất 10% dữ liệu. Dòng cuối cùng cho thấy phép cắt vẫn cần thiết: bỏ hẳn nó thì ngưỡng nhảy lên 13,4137, tức đuôi phân bố có những điểm gấp gần mười lần phần thân. Mức 0,99 là điểm mà đường cong bắt đầu phẳng mà vẫn chặn được đuôi đó.

Hai giá trị ngưỡng trong báo cáo. Bảng 7.19 ghi ngưỡng 1,4015 tại mức 0,99, còn tệp cấu hình mô hình ghi 1,3764. Hai con số này không mâu thuẫn: cùng một mức phân vị nhưng tính trên hai tập khác nhau. Phép quét chạy trên tập kiểm định để đo WAPE tương ứng với từng mức, nên ngưỡng của nó là phân vị 99 của k trên tập kiểm định (≈ 289.000 giá trị). Ngưỡng thực sự nạp vào mô hình bắt buộc phải suy từ tập huấn luyện, nên nó là phân vị 99 của k trên tập huấn luyện (681.536 giá trị), bằng 1,3764. Giá trị dùng để huấn luyện và để chấm điểm ở Phần 5 là 1,3764.

Hạn chế: ngưỡng cắt dùng chung cho hai tầm dự báo. Ngưỡng 1,3764 được tính ở tầm H1 rồi dùng lại cho tầm H4. Tính riêng cho H4 thì phân vị 99 của k là 2,0156. Nguyên nhân nằm ở cấu tạo của k : mẫu số lấy $\sin h$ tại thời điểm T , còn tử số là sản lượng tại $T + h$. Ở tầm 15 phút Mặt Trời gần như đứng yên nên hai vế khớp nhau; ở tầm 60 phút, buổi sáng Mặt Trời lên nhanh nên mẫu số nhỏ hơn hẳn tử số và k giàu lên.

Hệ quả đo được: dùng ngưỡng của H1 cho H4 thì tỷ lệ nhãn bị cắt tăng từ 1,00%

lên **8,59%**, và phần bị cắt dồn vào sườn lên buổi sáng, xem Bảng 7.20.

Bảng 7.20: Tỷ lệ nhân bị ngưỡng 1,3764 cắt, tách theo giờ trong ngày, tính trên tập huấn luyện. Kiểm chứng bằng `srcs/05_machine_learning/kiem_chung_bao_cao_v4.py`, mục 1.

Giờ	H1 bị cắt	Tỷ lệ H1	H4 bị cắt	Tỷ lệ H4
6	4	0,05%	3.192	42,98%
7	226	0,61%	13.505	36,17%
8	454	0,75%	18.004	29,92%
9	847	1,41%	13.942	23,17%
10	1.352	2,25%	7.172	11,93%
11	1.079	1,80%	2.113	3,52%
12	822	1,37%	514	0,86%
13–19	2.032	$\approx 0,6\%$	99	$< 0,1\%$
Tổng	6.816	1,00%	58.541	8,59%

Ngưỡng này chặn ở cả hai đầu: lúc huấn luyện nó cắt cụt nhân, và lúc dự báo nó chặn luôn đầu ra vì đầu ra cũng đi qua cùng phép cắt trước khi nhân ngược. Với tầm H4 vào buổi sáng, mô hình vừa không được học giá trị thật vừa bị áp trần khi dự báo, nên phần sườn lên bị hụt biên độ. Buổi chiều không có hiện tượng này vì Mặt Trời xuống nên tử số nhỏ hơn mẫu số.

Sửa đúng cách là gọi lại `tin_hclip_tu_train()` trong bước chuẩn bị ma trận của tầm H4. Việc đó kéo theo huấn luyện lại toàn bộ H4 và chạy lại cả dây chuyền đánh giá, nên nằm ngoài phạm vi đợt này và được ghi vào hướng phát triển ở Phần 8. Mọi con số H4 trong báo cáo đều là số của cấu hình đang dùng ngưỡng 1,3764.

7.3.6 Kiểm chứng các tham số cố định

Bốn tham số được gán giá trị cố định trong tệp cấu hình. Notebook `05b_thuc_nghiem_tham_so_hardcode` quét từng tham số qua nhiều mức, giữ nguyên mọi thứ còn lại, rồi huấn luyện và chấm lại trên tập kiểm định. Kết quả ở Bảng 7.21.

Bảng này phải đọc trung thực, vì không phải tham số nào cũng có tác động như nhau.

Sàn mẫu số ε không quyết định độ chính xác. Toàn dải từ 0,00 tới 0,15 chỉ chênh nhau 0,0717 điểm phần trăm WAPE. Cái mà ε thực sự điều khiển là số dòng

Bảng 7.21: Quét bốn tham số cố định, chấm trên 779.099 dòng của tập kiểm định. Đọc từ tệp kết quả 05b_thuc_nghiem_tham_so/thuc_nghiem_tham_so_hardcode.csv.

Tham số	Mức	Dòng huấn luyện	WAPE (%)	RMSE	R^2
eps_elev	0,00	604.200	20,5872	3,4733	0,8931
	0,02	602.937	20,5657	3,4895	0,8921
	0,05	599.174	20,5692	3,4799	0,8926
	0,10	582.252	20,5810	3,4832	0,8924
	0,15	557.266	20,5155	3,4630	0,8937
$k_{\max}$	1,0	599.174	24,1097	3,8230	0,8704
	1,2	599.174	21,1356	3,5535	0,8881
	1,5	599.174	20,5692	3,4799	0,8926
	2,0	599.174	20,4791	3,4638	0,8936
	3,0	599.174	20,4473	3,4502	0,8945
Hệ số nói trần	1,00	599.174	20,5710	3,4816	0,8925
	1,02	599.174	20,5692	3,4799	0,8926
	1,05	599.174	20,5669	3,4781	0,8928
	1,10	599.174	20,5650	3,4766	0,8928
Trọng số vùng đỉnh	0,0	599.174	20,4051	3,4623	0,8937
	0,5	599.174	20,5059	3,4650	0,8936
	1,0	599.174	20,5692	3,4799	0,8926
	2,0	599.174	20,6429	3,4928	0,8919

còn lại để huấn luyện: từ 604.200 xuống 557.266, mất 7,8%. Mức 0,05 ứng với góc nâng $\arcsin(0,05) = 2,87^\circ$. Tỷ lệ dòng giữ lại được so với mức không lọc là

$$\frac{599.174}{604.200} = 0,991682 \rightarrow \mathbf{99,17\%} \quad (7.9)$$

Con số này là tỷ lệ trên **các dòng thực sự vào hàm mục tiêu** của phép quét ở Bảng 7.21. Tính trên toàn bộ tập huấn luyện trước khi áp trọng số mẫu thì tỷ lệ là $681.536/709.954 = 96,00\%$. Hai con số khác nhau vì hai phạm vi khác nhau; báo cáo dùng 99,17% đúng theo phạm vi của bảng.

Phần bị loại nhỏ như vậy vì vành $0 < \sin h \leq 0,05$ rất hẹp và gần như không phát hiện. Trung bình mỗi trạm mỗi ngày có 47,1 bước ban ngày, trong đó chỉ 1,89 bước rơi

vào vành này. Sản lượng trung bình một bước trong vành là 0,1630 kWh, so với 6,5743 kWh ở các bước còn lại — kém 40 lần. Cộng lại, phần sản lượng nằm trong vành là

$$\frac{4.631 \text{ kWh}}{4.485.237 \text{ kWh}} = 0,001033 \rightarrow \mathbf{0,103\%} \quad (7.10)$$

Đặt sàn ở 0,05 vì vậy chặn được vùng mẫu số tiến về 0 mà chỉ bỏ đi một phần nghìn sản lượng ban ngày.

Cận cắt $k_{\max}$ là tham số có tác động rõ. Hạ xuống 1,0 làm WAPE xấu đi 3,54 điểm, vì cắt mất phần thân của phân bố chứ không chỉ đuôi. Nới lên 2,0 và 3,0 cải thiện thêm 0,09 và 0,12 điểm, nhưng đổi lại thì phép cắt gần như mất tác dụng chặn các điểm đo bất thường. Giá trị dùng thật là 1,3764 suy từ phân vị 99 của tập huấn luyện, nằm giữa hai mức 1,2 và 1,5 của phép quét.

Hệ số nới trần không phải lựa chọn về độ chính xác. Bốn mức từ 1,00 tới 1,10 chênh nhau 0,006 điểm WAPE, tức nằm trong mức nhiễu. Hệ số 1,02 được chọn theo lý do vật lý: chứa 2% dư địa quanh trần để không cắt oan các dao động ngắn do hiện tượng tăng cường bức xạ ở mép mây, chứ không phải khẳng định công suất lắp đặt thực tế cao hơn 2%.

Trọng số vùng đỉnh làm WAPE tổng thể xấu đi. Tắt hẳn cho 20,4051%, thấp hơn mức đang dùng 0,164 điểm. Đây là một đánh đổi có chủ đích chứ không phải tham số bị bỏ quên: trọng số này kéo mô hình chú ý vào khung giờ phát điện mạnh, nơi sai số có giá trị vận hành lớn nhất, và trả giá bằng một phần nhỏ sai số trung bình trên toàn tập.

Ngưỡng cắt chỉ số trời quang. Tham số CLIP_CSI chặn tỷ lệ bức xạ đo trên bức xạ trời quang. Bảng 7.22 cho thấy nó ảnh hưởng tới bao nhiêu điểm bị cắt.

Bảng 7.22: Số điểm bị ngưỡng CLIP_CSI cắt. Đọc từ tệp kết quả 05b_thuc_nghiem_tham_so/thuc_nghiem_clip_csi.csv.

Ngưỡng	Số điểm bị cắt	Tỷ lệ (%)
1,0	39.265	5,4592
1,1	33.127	4,6058
1,2	28.684	3,9880
1,3	24.393	3,3915
1,5	18.689	2,5984
2,0	11.179	1,5543

Ngưỡng 1,0 ứng với giả định bức xạ đo không bao giờ vượt bức xạ trời quang lý

thuyết — giả định đó cắt 5,46% số điểm, quá nhiều để coi là hợp lý, vì hiện tượng tăng cường bức xạ ở mép mây làm bức xạ đo vượt mức trời quang trong thời gian ngắn là có thật. Ngưỡng 1,5 cắt 2,60%, giữ lại phần vượt trần do vật lý và chỉ loại phần vượt xa.

7.3.7 Chẩn đoán và chọn đặc trưng

Sau ba notebook sinh đặc trưng, tập huấn luyện mang 114 cột. Hai notebook tiếp theo quyết định cột nào thực sự đi vào mô hình, với vai trò tách bạch: 04_vif_diagnostics **đo** và xuất bằng chứng, 05_select_features **quyết định**. Notebook chẩn đoán không tự loại cột nào — nó ghi bảng chỉ số ra tệp để bước chọn đọc lại.

Cách phân vai này có lý do: hệ số phóng đại phương sai chỉ đo mức một đặc trưng bị các đặc trưng còn lại giải thích, không đo mức đặc trưng đó giải thích được mục tiêu. Một cột có thể vừa cộng tuyến cao vừa mang thông tin vật lý không thay thế được, nên máy không được quyền tự loại.

Chẩn đoán đa cộng tuyến

Trong 114 cột, 86 cột được đưa vào chẩn đoán; 28 cột còn lại nằm ngoài phạm vi vì là mục tiêu, khoá định danh, cột ghi nguồn gốc dữ liệu, cờ ngoại lai hoặc cột thời gian thô. Kết quả phân loại trình bày ở Bảng 7.23.

Bảng 7.23: Phân bố nhãn chẩn đoán trên 86 đặc trưng số. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.

Nhãn	Số cột	Nghĩa
HIGH_VIF	41	Hệ số phóng đại phương sai vượt 10
OK	27	Không vướng tiêu chí nào
CONSTANT	9	Chỉ một giá trị duy nhất, phương sai bằng 0
DUPLICATE	8	Trùng lặp gần hoàn hảo với một cột khác
HIGH_MISSING	1	Tỷ lệ khuyết quá cao
Tổng	86	

Cột duy nhất mang nhãn khuyết cao là `source_gap_id` với 97,68% ô trống — đúng bản chất của nó, vì nó chỉ nhận giá trị tại các dòng nằm trong một khoảng trống nguồn.

Cột trùng lặp. Ở ngưỡng $|r| \geq 0,95$ notebook đếm được 44 cặp, nhưng chỉ những cặp đạt $|r| \geq 0,9999$ mới bị coi là trùng lặp thực sự, vì cộng tuyến hoàn hảo khiến

phép tính hệ số phóng đại phương sai không xác định. Tám cột bị loại ở bước này, xem Bảng 7.24.

Bảng 7.24: Tám cột trùng lặp gần hoàn hảo và cột đại diện được giữ lại. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.

Cột bị bỏ	Đại diện giữ lại	Số giá trị phân biệt
quarter_hour	minute_of_day	96
hour_of_day	hour	24
hour_bucket_raw	hour	24
hour_bucket_model	hour	24
day_of_week_model	day_of_week	7
month_model	month	12
number_of_panels_missing_flag	capacity_kw_missing_flag	2
dni_ratio	diffuse_ratio	37.341

Sáu nhóm đầu là các cách mã hoá khác nhau của cùng một đại lượng thời gian, sinh ra ở các bước khác nhau của quy trình rồi cùng tồn tại. Cặp diffuse_ratio và dni_ratio có $r = -1,0000$ vì hai tỷ lệ này cộng lại bằng 1 theo định nghĩa. Sau bước loại trùng, số đặc trưng còn 78.

Hệ số phóng đại phương sai. Bảng 7.25 lấy tám cột cao nhất.

Bảng 7.25: Tám đặc trưng có hệ số phóng đại phương sai cao nhất. Giá trị 9999 là mức chặn trên mà notebook đặt cho trường hợp cộng tuyến gần hoàn hảo. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.

Đặc trưng	VIF	Nguồn cộng tuyến
direct_normal_irradiance	9999	Ba cột bức xạ ràng buộc nhau qua quan hệ hình học
diffuse_solar_radiation	9999	
shortwave_radiation	9999	
tran_cong_suat	7.567,53	Cùng suy từ phân vị sản lượng của một trạm
site_scale	7.516,67	
day_of_year	5.228,18	Trùng thông tin với biến tháng
month	5.186,16	
sin_elevation	2.846,97	Hàm xác định của cùng góc cao Mặt Trời

Ba cột bức xạ đạt mức chặn trên vì GHI bằng tổng của thành phần trực xạ chiếu

xuống mặt ngang và thành phần khuếch tán, nên biết hai cột là suy ra được cột còn lại. Cặp `site_scale` và `tran_cong_suat` có $r = 0,9999$ vì cả hai là phân vị 99 và phân vị 99,9 của cùng một chuỗi sản lượng.

Không cột nào trong Bảng 7.25 bị loại. Cộng tuyến làm hệ số của mô hình tuyến tính mất ổn định, nhưng mô hình dùng ở đây là cây quyết định tăng cường gradient — nó chọn điểm cắt theo mức giảm hàm mất mát chứ không giải hệ phương trình chuẩn tắc, nên không chịu ảnh hưởng đó.

Đối chiếu bằng một phương pháp độc lập. Để không quyết định chỉ dựa trên một thước đo, notebook chạy thêm hồi quy bình phương tối thiểu riêng phần và lấy điểm quan trọng biến, đo theo hiệp phương sai với mục tiêu thay vì theo cộng tuyến giữa các đặc trưng. Bảy đặc trưng đứng đầu được ghi ở Bảng 7.26.

Bảng 7.26: Bảy đặc trưng dẫn đầu theo điểm quan trọng biến của hồi quy bình phương tối thiểu riêng phần, đặt cạnh hệ số phóng đại phương sai của chính chúng. Đọc từ ô kết quả của notebook `04_vif_diagnostics.ipynb`.

Đặc trưng	Điểm quan trọng	VIF
<code>rolling_mean_4</code>	2,265	461,18
<code>rolling_min_4</code>	2,251	882,04
<code>rolling_max_4</code>	2,224	1.375,52
<code>lag_4</code>	2,123	27,77
<code>ky_vong</code>	2,039	21,18
<code>pv_clr_loni_j</code>	1,959	10,80
<code>lag_96</code>	1,883	5,36

Sáu trong bảy đặc trưng dẫn đầu đồng thời mang nhãn cộng tuyến cao. Đây là lý do trực tiếp để bước chọn không dùng hệ số phóng đại phương sai làm tiêu chí loại: nếu cắt theo ngưỡng 10 thì sáu đặc trưng mạnh nhất theo thước đo độc lập sẽ bị loại hết.

Danh sách cấm

Trước khi chấm điểm, notebook `05_select_features` khai báo tường minh một danh sách cấm gồm 53 tên cột. Danh sách này chặn bốn loại: chính mục tiêu và các biến thể của nó, cờ ngoại lai và cột loại trừ huấn luyện, cột ghi nguồn gốc dữ liệu, và các khoá định danh cùng cột thời gian thô.

Danh sách được khai báo theo tên chứ không theo tập dữ liệu, nên nó bao cả những tên chỉ xuất hiện ở các bước khác của quy trình. Trong 114 cột của tệp đầu vào, 40 cột trùng tên với danh sách và bị loại; 74 cột còn lại đi tiếp vào bước chấm điểm. Cách khai

báo dư này là có chủ đích: thêm một tên không tồn tại thì vô hại, còn sót một tên rò rỉ thì hỏng cả kết quả.

Danh sách cấm được đặt trước phép chấm điểm chứ không sau, vì một cột rò rỉ luôn đạt điểm cao: nếu để nó dự thi thì chính thước đo sẽ chọn nó. Hình 7.19 là đoạn khai báo.

Chấm điểm bằng thông tin tương hỗ

Phép chấm điểm chạy trên **thông tin tương hỗ** giữa từng đặc trưng và mục tiêu. Thước đo này bắt được cả quan hệ phi tuyến, khác hệ số tương quan Pearson vốn chỉ đo quan hệ tuyến tính — điều cần thiết ở đây vì quan hệ giữa bức xạ và sản lượng bão hoà dần khi tới gần trần công suất.

Điểm chỉ tính trên các dòng hợp lệ, tức đã bỏ dòng mang cờ loại trừ huấn luyện:

Tổng số dòng ban đầu: 1550856
Số dòng hợp lệ (`exclude_from_training == False`): 1514314 (97.64%)
Số dòng bị loại trừ khỏi chấm điểm: 36542

Bảng 7.27 lấy mười đặc trưng đứng đầu trong 74 ứng viên, chấm trên mẫu 100.000 dòng.

Bảng 7.27: Mười đặc trưng có điểm thông tin tương hỗ cao nhất. Đọc từ ô kết quả của notebook `05_select_features.ipynb`.

Hạng	Đặc trưng	Điểm
1	rolling_max_4	1,1724
2	rolling_mean_4	1,1251
3	ky_vong	1,0785
4	rolling_min_4	1,0582
5	lag_96	1,0018
6	lag_4	0,8315
7	solar_elevation	0,8258
8	sin_elevation	0,7967
9	ty_le_bao_hoa	0,7949
10	ghi_cs	0,7939

Bốn vị trí đầu đều là đặc trưng của số trượt một giờ, và sáu vị trí đầu đều suy từ lịch sử của chính chuỗi sản lượng. Bảng xếp hạng này khớp với kết quả tự tương quan ở

```

"""Stage 07a: danh sach CAM (deny list) - chan ro ri nhan va cong tuyen cau truc.

Tach tu buoc 4 của run_select_features() trong 03_feature_selection.py.

DAY LA HANG RAO CHONG RO RI QUAN TRONG NHAT CUA CA PIPELINE. Bo sot 1 cot o day thi
model dat R2 rat cao tren train/val nhưng HOAN TOAN THAT BAI khi du bao that.
"""

from __future__ import annotations

import pandas as pd

# — 1. Chinh bien muc tieu —
DENY_TARGET = ["energy_generated_kwh"]

# — 2. Provenance / outlier —
# BANG CHUNG tu du lieu tho:
# - Khi exclude_from_training == True thi san luong = 0.0 o 100.00% trong hop
#   (36.847 dong trong tap train, deu la machine_failure zero do gap >= 24h).
# - Nhom outlier_group == physical_over_capacity co san luong trung binh 19,43 kWh,
#   vuot xa nhom normal (2,75 kWh).
# HAU QUA NEU DUA VAO MODEL: cac cot nay duoc tao SAU KHI da do va kiem tra target.
# Model chi can tra bang "thay co thi doan 0" -> diem cuc cao tren train/val nhưng
# THAT BAI khi du bao tuong lai (luc do chua co du lieu do de gan co).
# VAI TRU DUNG cua chung: (1) loc dong khoi train, (2) gan trong so mau,
# (3) khoanh vung tinh metric theo nhom. KHONG duoc lam dac trung dau vao.
DENY_PROVENANCE_OUTLIER = [
    "gmm_if_outlier_flag", "gmm_if_outlier_reason", "outlier_group",
    "exclude_from_training", "exclude_reason", "training_quality_reason",
    "energy_source", "timestamp_was_inserted", "source_gap_id",
    "after_source_gap_steps_remaining",
]

# — 3. Co ban ngay / audit —
DENY_DAYLIGHT_AUDIT = [
    "is_daylight", "weather_is_day", "sunshine_duration", "weather_is_observed",
]

# — 4. Khoa ID - tranh model hoc vet index thay vi hoc dac tinh vat ly —
DENY_IDS = [
    "gen_id", "site_id", "geo_id", "date_id", "time_id", "weather_id", "weather_type_id",
]

# — 5. Categorical tho (da duoc ma hoa thanh *_enc o stage s05) —
DENY_RAW_CATEGORICAL = [
    "site_id", "campus_name", "location_name", "site_metric", "panel",
    "inverter", "optimizers", "weather_join_method",
    "weather_condition", "weather_description",
]

# — 6. Thoi gian tho —
# 'year' bi cam vi TANG DON DIEU, khong tuan hoan:
# train year = {2020, 2021} | test year = {2021, 2022}
# -> 455.616 dong test (89%) co year = 2022 CHUA TUNG xuat hien luc train.
# Cay quyet dinh tach theo 'year <= 2021' se ap quy tac hoc tu gia tri chua he thay.
# Khac han month / day of year / day_sin / day_cos: nhung cai do TUAN HOAN, lap hang nam.
DENY_RAW_TIME = ["timestamp", "time_diff", "full_date", "weather_timestamp", "year"]

# — 7. Cong tuyen CAU TRUC (khong phai tuong quan ngau nhien) —
# dni_ratio: VIF vo cuc tren mau ban ngay. Giu diffuse_ratio (y nghia vat ly ro: ty le
#   may mu), bo dni_ratio.
# con_cach_tran = tran.cong.suat - ky.vong: to hop tuyen tinh CHINH XAC cua 2 cot con lai,
#   Khong mang thong tin moi
# site_scale va tran.cong.suat deu la hang so theo site (phan vi 99 va 99,9 cua CUNG mot
#   phan phoi) nen tuong quan gan tuyet doi; giu tran.cong.suat (dang dung truc tiep trong
#   ty le bao hoa/con_cach_tran), bo site_scale khoi tap dac trung train.
DENY_STRUCTURAL_COLLINEAR = ["dni_ratio", "con_cach_tran", "site_scale"]

# — 8. Metadata của buoc split (do stage s02 gan) —
# KHONG cam ca tien to 'v3_' vi cac dac trung that cung dung tien to nay.
SPLIT_META = [
    "v3_holdout_split", "v3_test_start_timestamp", "v3_split_strategy",
    "v3_n_time_series_splits", "v3_split", "v3_cv_fold", "v3_cv_role",
]

def dung_deny_list(df: pd.DataFrame, df_diag: pd.DataFrame | None = None) -> tuple[set, dict]:
    """Gop toan bo deny list. Tra ve (tap cam, chi tiet tung nhom de bao cao)."""
    cam = set()
    DENY_TARGET + DENY_PROVENANCE_OUTLIER + DENY_DAYLIGHT_AUDIT
    + DENY_IDS + DENY_RAW_TIME + DENY_RAW_CATEGORICAL + DENY_STRUCTURAL_COLLINEAR
    cam.update(c for c in SPLIT_META if c in df.columns)
    # Moi cot co chua 'timestamp' trong ten: thoi gian tho tang don dieu, model se hoc
    # theo do lon cua timestamp va khong ngoai suy duoc sang tuong lai.
    cam.update(c for c in df.columns if "timestamp" in c.lower())

    trung_lap = set()
    if df_diag is not None and "duplicate of" in df_diag.columns:
        trung_lap = set(df_diag.loc[df_diag["duplicate of"].notna(), "feature"])
        cam.update(trung_lap)

    chi_tiet = {
        "target": len(DENY_TARGET),
        "provenance_outlier": len(DENY_PROVENANCE_OUTLIER),
        "daylight_audit": len(DENY_DAYLIGHT_AUDIT),
        "ids": len(DENY_IDS),
        "raw_time": len(DENY_RAW_TIME),
        "raw_categorical": len(DENY_RAW_CATEGORICAL),
        "structural_collinear": len(DENY_STRUCTURAL_COLLINEAR),
        "trung_lap_tu_s06": len(trung_lap),
        "tong_cam": len(cam),
    }
    return cam, chi_tiet

def dac_trung_ung_vien(df: pd.DataFrame, cam: set) -> list[str]:
    return [c for c in df.columns if c not in cam]

```

Hình 7.19: Đoạn khai báo danh sách cấm trong quy trình chọn đặc trưng. Mỗi nhóm cột bị cấm đi kèm lý do ngay tại chỗ khai báo.

Mục 2.2: chuỗi mang tự tương quan +0,8942 tại mốc một giờ, nên các thống kê của cửa sổ một giờ gần nhất là nguồn thông tin mạnh nhất về giá trị sắp tới.

Danh sách bảo vệ

Lấy thẳng 35 đặc trưng đứng đầu sẽ loại mất một số biến khí tượng và hình học Mặt Trời có điểm thấp nhưng cần cho mô hình đọc được điều kiện vật lý tại bước hiện tại. Notebook vì vậy khai báo một danh sách bảo vệ gồm 22 đặc trưng, cả 22 đều có mặt trong dữ liệu, và bổ sung lại những đặc trưng nằm ngoài ngưỡng cắt:

```
--- DANH SACH BAO VE ---
Co trong du lieu : 22/22
Bi Top K cat, da bo sung lai (5): ['azimuth_sin', 'temperature_c',
                                   'rolling_min_96', 'doy_sin', 'doy_cos']
Tong dac trung duoc chon: 35 (Top K) + 5 (bao ve) = 40
```

Năm đặc trưng được bổ sung nằm ở hạng 36, 40, 49, 54 và 68 theo điểm thông tin tương hỗ. Hai cột do_y_sin và do_y_cos mã hoá vị trí trong năm dưới dạng vòng; điểm của chúng thấp vì trên một mẫu ngẫu nhiên rải khắp 18 tháng, mùa gần như không phân biệt được — nhưng mô hình cần chúng để không coi ngày 31/12 và ngày 01/01 là hai thời điểm xa nhau.

Kết quả áp cho mười tập

Bốn mươi đặc trưng đã chọn được áp đồng loạt cho mười tập dữ liệu — bốn tập chính và sáu phần của ba fold:

```
--- DA LOC 10 TAP THEO 40 DAC TRUNG DA CHON ---
      tap      dong  cot_truoc  cot_sau  feature  cot_phu  \
0      v4_train 1550856      114      50      40      10
1      v4_val   723114      114      50      40      10
2      v4_test  510468      114      50      40      10
3 v4_development 2273970      113      50      40      10
4  fold_1_train  233244      115      50      40      10
5  fold_1_val   606105      115      50      40      10
6  fold_2_train  839349      115      50      40      10
7  fold_2_val   711507      115      50      40      10
8  fold_3_train 1550856      115      50      40      10
9  fold_3_val   723114      115      50      40      10

feature_thieu
0          0
1          0
2          0
```

3	0
4	0
5	0
6	0
7	0
8	0
9	0

Mọi tập đều có đủ đặc trưng đã chọn.

Cột `feature_thieu` bằng 0 ở cả mười dòng, tức không tập nào thiếu đặc trưng đã chọn. Mỗi tập giữ 50 cột: 40 đặc trưng cùng 10 cột phụ trợ gồm mục tiêu, mốc thời gian, mã trạm và các cột phục vụ lọc phạm vi chấm điểm. Danh sách 40 tên cột được ghi ra tệp `selected_features.json` để các bước huấn luyện và phục vụ đọc lại đúng một danh sách duy nhất.

7.3.8 Tổng hợp bộ đặc trưng đưa vào mô hình

Bảng 7.28 liệt kê trọn 40 đặc trưng đã chọn, xếp theo sáu nhóm.

Mười bốn cột `_mt` sinh thêm ở bước huấn luyện đều thuộc hai nhóm đầu — hình học Mặt Trời và nhân lịch — đúng theo ranh giới hợp lệ đã nêu ở Mục 3.4:

```
Them 14 dac trung tat dinh tai T+15 phut:
['solar_elevation_mt', 'solar_azimuth_mt', 'azimuth_sin_mt',
 'azimuth_cos_mt', 'sin_elevation_mt', 'ghi_cs_mt', 'ky_vong_mt',
 'ty_le_bao_hoa_mt', 'minute_of_day_mt', 'hour_mt', 'hour_sin_mt',
 'hour_cos_mt', 'doy_sin_mt', 'doy_cos_mt']
Ma tran train : 599,174 dong x 54 dac trung
Muc tieu chuan hoa k: min 0.0028  trung vi 0.6423  max 1.3764
```

Không cột khí tượng nào có mặt trong danh sách này. Giá trị lớn nhất của mục tiêu chuẩn hoá bằng đúng 1,3764, tức cận sát suy từ phân vị 99 ở Mục 3.5 đang hoạt động.

7.4 Huấn luyện và chọn hàm mất mát

Mô hình là LightGBM hồi quy, huấn luyện riêng cho từng tầm dự báo: H1 dự báo mốc $T+15$ phút, H4 dự báo mốc $T+60$ phút. Mỗi tầm nhận 54 đặc trưng — 40 cột đã chọn ở Mục 3.7 cộng 14 cột tất định tại thời điểm mục tiêu đã trình bày ở Mục 3.4.

7.4.1 Chính sách trọng số cho dòng ngoại lai

Các dòng mang nhãn ngoại lai không bị xoá khỏi lưới. Chúng nhận trọng số bằng 0, tức không đóng góp vào hàm mục tiêu, nhưng vẫn nằm trong bảng để báo cáo truy ngược được.

Bảng 7.28: Bốn mươi đặc trưng được chọn, xếp theo nhóm. Đọc từ 05_selected/selected_features.json.

Nhóm	Số cột	Tên cột
Thời gian và lịch tuần hoàn	6	minute_of_day, hour, hour_sin, hour_cos, doy_sin, doy_cos
Hình học Mặt Trời và trời quang	8	solar_elevation, sin_elevation, solar_azimuth, azimuth_sin, azimuth_cos, ghi_cs, cs_factor, chi_so_troi_quang
Khí tượng đo được	5	shortwave_radiation, diffuse_solar_radiation, direct_normal_irradiance, temperature_c, cloud_cover_low
Tương tác và tỷ lệ	5	rad_x_sinelev, temp_x_shortwave, diffuse_ratio, cloud_x_shortwave, cloud_low_x_shortwave
Lịch sử chuỗi	10	lag_4, lag_96, rolling_mean_4, rolling_std_4, rolling_min_4, rolling_max_4, rolling_mean_96, rolling_std_96, rolling_min_96, rolling_max_96
Quy mô trạm và mã hoá	6	ky_vong, ty_le_bao_hoa, tran_cong_suat, site_id_enc, weather_condition_enc, weather_description_enc
Tổng	40	

--- CHINH SACH OUTLIER, experiment = measured_only_headline ---
Dong co weight = 0 khong tham gia ham muc tieu nhung van giu de bao cao.
Tong dong bi loai khoi ham muc tieu: 82,362 / 681,536 (12.08%)
trong do physical_over_capacity: 0 dong (luon bi loai o moi experiment)
Khoang thoi gian train: 2020-01-02 06:30:00 -> 2021-06-21 17:00:00

Cách gán trọng số 0 được chọn thay vì xoá dòng, vì xoá sẽ làm đứt lưới thời gian và mọi đặc trưng trễ, cửa sổ trượt tính sau đó đều đếm sai khoảng cách — đúng vấn đề mà bước dựng lưới ở Mục 2.1 đặt ra để tránh.

7.4.2 Tinh chỉnh siêu tham số

Mỗi hàm mất mát được Optuna chạy **một phiên tìm kiếm riêng** với ngân sách 20 trial, chấm bằng WAPE gộp trên ba fold của sổ mở rộng của tập Phát triển. Không

hàm nào phải dùng lại bộ tham số của hàm khác, và không hàm nào bị cố định mức điều hoà.

Miền tìm kiếm khai báo cố định trong cả ba notebook huấn luyện, ghi ở Bảng 7.29.

Bảng 7.29: Miền tìm kiếm siêu tham số khai báo cho Optuna. Đọc từ hàm `tham_so_co_ban` trong notebook `06_1_train_mae.ipynb`.

Siêu tham số	Miền	Vai trò
<code>n_estimators</code>	[400; 1200]	Số cây tối đa, early stopping chốt số thật
<code>learning_rate</code>	[0,02; 0,12] thang log	Tốc độ học
<code>num_leaves</code>	[63; 255]	Độ phức tạp mỗi cây
<code>min_child_samples</code>	[20; 120]	Số mẫu tối thiểu mỗi lá
<code>subsample</code>	[0,7; 1,0]	Tỷ lệ mẫu mỗi vòng
<code>colsample_bytree</code>	[0,7; 1,0]	Tỷ lệ cột mỗi cây
<code>reg_alpha</code>	[0; 10]	Điều hoà L_1
<code>reg_lambda</code>	[0; 10]	Điều hoà L_2
<code>alpha</code>	[0,5; 20] thang log	Điểm chuyển của Huber, chỉ Huber có

Vì `reg_alpha` và `reg_lambda` được thả độc lập trên cùng một miền, không gian tìm kiếm bao trùm cả ba chế độ điều hoà: L_1 thuần, L_2 thuần và dạng phối hợp. Mỗi hàm mất mát vì vậy được trao cơ hội ngang nhau để tự tìm mức điều hoà phù hợp trước khi đem ra so.

7.4.3 Sáu cấu hình Optuna chọn được

Bảng 7.30: Siêu tham số tốt nhất do Optuna chọn, theo từng hàm mất mát và tầm dự báo. Cả sáu cấu hình dùng chung `random_state = 42`, `deterministic = true` và `max_bin = 127` trên CPU. Đọc từ khoá `best_params` trong tệp kết quả của mỗi notebook huấn luyện.

Cấu hình	Số cây	Tốc độ học	Số lá	Mẫu/lá	Tỷ lệ mẫu	Tỷ lệ cột	L_1	L_2
MAE — H1	800	0,03019	82	88	0,700	0,817	2,58	4,82
Huber — H1	386	0,05781	71	81	0,751	0,720	9,49	9,66
MSE — H1	329	0,05121	146	49	0,884	0,742	2,92	3,66
MAE — H4	400	0,04857	69	111	0,778	0,899	3,12	5,20
Huber — H4	526	0,02849	99	71	0,950	0,770	9,88	4,18
MSE — H4	509	0,03570	134	46	0,869	0,810	9,81	3,99

Điểm chuyển của Huber được Optuna chọn rất khác nhau giữa hai tầm: $\alpha = 9,86$ ở H1 nhưng chỉ 0,73 ở H4. Đọc ngang bảng còn thấy hai xu hướng. Các cấu hình MSE

dùng số lá lớn hơn hẳn — 146 và 134 so với 71–99 của Huber — tức cây sâu và chia nhỏ hơn, phù hợp với việc MSE phạt nặng sai số lớn nên có động cơ khớp sát từng vùng dữ liệu. Mức phạt L_1 mà Optuna chọn cho Huber ở cả hai tầm đều gần chạm cận trên của miền (9,49 và 9,88), cho thấy cấu hình này cần ràng buộc mạnh mới ổn định.

Hai chỗ chạm biên miền tìm kiếm. subsample của MAE–H1 bằng 0,7003, tức đúng cận dưới; reg_alpha của Huber đạt 9,49–9,88 trên miền $[0; 10]$. Khi một siêu tham số dừng ngay tại biên, không thể loại trừ khả năng giá trị tốt hơn nằm ngoài miền đã khai báo. Vì vậy tài liệu này không tuyên bố đây là cấu hình tối ưu toàn cục, mà chỉ là cấu hình tốt nhất tìm được trong miền và ngân sách 20 trial đã khoá từ trước. Mở rộng miền ở hai chỗ đó là việc nên làm ở lần huấn luyện sau.

7.4.4 Chọn hàm mất mát

Ba hàm được chấm trên tập kiểm định — phần dữ liệu mô hình chưa từng nhìn thấy — ở phạm vi đo thật ban ngày. Phạm vi này xét **dòng nhãn tại $T+h$** đúng như ở bước đánh giá cuối tại Mục 5.2, và loại hai trạm 19, 24 cho khớp với phạm vi huấn luyện. Kết quả đầy đủ của sáu cấu hình ở Bảng 7.31.

Bảng 7.31: Sai số trên tập kiểm định, phạm vi đo thật ban ngày. Trong mỗi tầm, cả ba hàm được chấm trên đúng cùng số quan sát. Đọc từ metrics_val.json của sáu cấu hình dưới 06_train/.

Tầm	Hàm mất mát	WAPE (%)	RMSE	MAE	R^2
<i>H1 — 288.811 quan sát cho cả ba hàm</i>					
H1	MAE	22,0515	3,6737	1,5062	0,8984
H1	MSE	22,6588	3,6372	1,5477	0,9004
H1	Huber	22,7936	3,6608	1,5569	0,8991
<i>H4 — 272.569 quan sát cho cả ba hàm</i>					
H4	MAE	26,9585	4,3592	1,9329	0,8628
H4	MSE	27,3309	4,2847	1,9596	0,8675
H4	Huber	27,4040	4,2893	1,9648	0,8672

MAE cho sai số thấp nhất ở cả hai tầm và được chọn cho cả hai. Trong mỗi tầm, ba hàm được chấm trên đúng cùng số quan sát — điều kiện để phép so sánh có nghĩa, vì nếu một cấu hình được chấm trên tập sạch hơn thì chênh lệch WAPE phản ánh phạm vi chứ không phản ánh hàm mất mát.

Đáng chú ý là MAE thắng theo WAPE nhưng thua theo RMSE ở cả hai tầm. Điều này đúng với bản chất hai hàm: MSE phạt bình phương sai số nên ép sai số lớn xuống

mạnh hơn, cho RMSE tốt hơn; MAE phạt tuyến tính nên bám phần thân phân bố, cho sai số tương đối tổng thể thấp hơn. Dự án lấy WAPE làm tiêu chí chọn vì nó là chỉ số được báo cáo, và vì mục tiêu vận hành là tổng sai số trên tổng sản lượng chứ không phải khổng chế vài sai số cực trị.

Phép chọn này thực hiện hoàn toàn trên tập kiểm định; tập test không tham gia. Notebook 10_compare_optuna_current có một cổng kiểm tự động cho đúng điều đó, và nó báo PASS.

7.4.5 Cấu hình tắt định

Toàn bộ sáu lần huấn luyện chạy trên CPU với `deterministic = true`, `force_col_wise = true`, `max_bin = 127`, `random_state = 42` và `n_jobs = 6`. Chế độ GPU bị tắt có chủ đích. Tài liệu tham số của LightGBM ghi rõ `deterministic` chỉ có tác dụng với thiết bị CPU, xem Hình 7.20; bật GPU thì cờ này bị bỏ qua. Quy trình đặt tính tái lập lên trước tốc độ nên chọn CPU.



Hình 7.20: Mục `deterministic` trong tài liệu tham số của LightGBM. Dòng đầu ghi tham số này chỉ dùng được với thiết bị CPU.

Kiểm chứng bằng hai phép chạy lại. Sau khi cấu hình đã khoá và tập test đã mở, cả sáu cấu hình được huấn luyện lại từ đầu bằng cùng hạt giống. Kết quả trên tập kiểm định của lần chạy lại này chính là Bảng 7.31 ở Mục 4.4, và thứ tự giữa ba hàm mất mát giữ nguyên so với lần khoá cấu hình. Đây là bằng chứng cho rào chắn thứ năm ở Mục 1.5.

Phép chạy lại thứ hai nằm ở bước giải thích mô hình: bước tính SHAP ở Phần 6 được chạy lại trên mô hình vừa huấn luyện lại và cho bảng xếp hạng cùng giá trị trùng khít tới từng chữ số với lần chạy trước.

7.5 Đánh giá trên tập test niêm phong

Tập test được tách ra từ đầu ở Mục 2.3 và cất đi. Nó chỉ được mở đúng một lần, ở bước này, sau khi hàm mất mát và bộ siêu tham số đã khoá.

7.5.1 Thước đo

Chỉ số chính của toàn bộ tài liệu là **WAPE** — sai số phần trăm tuyệt đối có trọng số:

$$WAPE = \frac{\sum_i |y_i - \hat{y}_i|}{\sum_i |y_i|} \times 100\% \quad (7.11)$$

Ba điểm về cách áp dụng.

Gộp một lần trên toàn bộ phạm vi. Tử số và mẫu số cộng dồn qua mọi trạm và mọi mốc thời gian trong phạm vi đang xét, rồi mới chia. Đây không phải trung bình của WAPE từng trạm; cách gộp này khiến trạm phát nhiều đóng góp nhiều hơn vào con số cuối, đúng với ý nghĩa vận hành là tổng sai số trên tổng sản lượng.

Mẫu số không bao giờ bằng 0. Phạm vi chấm điểm luôn yêu cầu dòng ban ngày và đo thật, nên trong tập được chấm không có trường hợp tổng sản lượng bằng 0.

Chọn WAPE thay cho MAPE. MAPE chia theo từng điểm nên nổ tung ở các mốc sản lượng gần 0 lúc rạng sáng và chập tối — chính những mốc chiếm phần lớn dữ liệu. WAPE đặt tổng ở mẫu số nên không gặp vấn đề đó. Dạng công thức trên trùng với định nghĩa WAPE trong bảng chỉ số của Temporal-Neto và cộng sự [9], xem Hình 7.21.

Weighted Absolute Percentage Error	$WAP E(y, \hat{y}) = \frac{\sum_{i=1}^n y_i - \hat{y}_i }{\sum_{i=1}^n y_i }$
--	---

Hình 7.21: Dòng *Weighted Absolute Percentage Error* trong Bảng 1 của Temporal-Neto và cộng sự [9], cắt từ bảng chỉ số đánh giá mô hình dự báo. Công thức trùng với dạng dự án dùng. Cách chia tập và cách lọc phạm vi là thiết kế riêng của dự án.

7.5.2 Phạm vi chấm điểm

Không phải mọi dòng trong tập test đều dùng để tính chỉ số. Bốn điều kiện lọc được áp đúng như ở bước huấn luyện, đưa 510.468 dòng xuống 478.942 dòng.

Phép dịch nhãn lên $T+h$ loại thêm một phần nữa. Sau khi lọc, lưới thời gian không còn liên tục, nên *shift* ($-h$) theo trạm có thể trở tới dòng hợp lệ kế tiếp chứ không phải mốc $T+h$. Bước chấm điểm vì vậy đối chiếu mốc thời gian của dòng bị dịch tới và chỉ giữ dòng nào lệch đúng 15h phút: H1 loại 3.303 dòng còn **475.599**, H4 loại 12.964 dòng còn **465.818**. Kiểm lại trên tệp `prediction_audit.parquet` thì không còn dòng nào lệch tầm ở cả hai tầm.

Chỉ số được báo ở ba phạm vi lồng nhau. Điều kiện phạm vi xét **dòng nhãn tại $T+h$** , không phải dòng đặc trưng tại T : hai cột `energy_source` và `is_daylight` được dịch sang mốc nhãn thành `nhan_energy_source` và `nhan_is_daylight` rồi mới dùng để lọc.

- **Toàn bộ** — mọi dòng còn lại sau bốn điều kiện lọc và phép kiểm tầm.
- **Đo thật** — thêm điều kiện `nhan_energy_source = measured`.
- **Đo thật ban ngày** — thêm điều kiện `nhan_is_daylight = true`. Đây là phạm vi chính thức mà tài liệu dùng để báo chỉ số: 229.548 dòng ở H1 và 229.297 dòng ở H4.

Bản trước lọc theo cột tại T . Vì nhãn là sản lượng tại $T+h$, cách đó để lọt vào phạm vi "đo thật ban ngày" những dòng mà nhãn thực chất do bước điền khuyết của tầng ETL sinh ra hoặc rơi vào ban đêm. Sửa lại cho bám mốc nhãn làm WAPE H1 tăng 0,05 điểm và H4 tăng 0,13 điểm — tức con số cũ dễ hơn thực tế.

7.5.3 Kết quả

Bảng 7.32 là kết quả chính của toàn bộ tài liệu.

Bảng 7.32: Sai số WAPE trên tập test niêm phong theo ba phạm vi. Đọc từ ô kết quả của notebook `07_final_test.ipynb` và tệp `metrics_overall.json` của từng tầm.

Phạm vi	H1 (%)	H4 (%)
Toàn bộ	17,12	21,94
Đo thật	17,76	22,65
Đo thật ban ngày	17,74	22,62

Cả hai tầm dùng cấu hình MAE — đúng hai cấu hình thắng trên tập kiểm định ở Mục 4.4.

Phạm vi chính thức gồm 229.713 dòng ở H1 và 229.596 dòng ở H4.

Sai số phân bố không đều giữa các trạm. Ở H1, trạm tốt nhất đạt 11,89% còn trạm kém nhất 28,32%, trung vị 18,12%; ở H4 khoảng này là 15,12% đến 35,88%, trung vị 22,72%. Chênh lệch hơn hai lần giữa hai đầu cho thấy một mô hình dùng chung cho cả 40 trạm vẫn để lại phần khác biệt riêng của từng trạm mà đặc trưng hiện có chưa mô tả hết.

7.5.4 Chênh lệch giữa sai số trên test và trên kiểm định

Bảng 7.33 đặt cạnh nhau ba con số của cùng một mô hình ở ba phạm vi đánh giá khác nhau. Chúng **không so trực tiếp được** với nhau, phải đọc kèm phạm vi.

Bảng 7.33: Cùng mô hình, ba phạm vi đánh giá. Đọc từ 08_baseline_prophet_test/optuna_vs_current_wape.csv.

Phạm vi đánh giá	H1 (%)	H4 (%)
Optuna, gộp ba fold kiểm định	24,1767	29,4090
Test niêm phong, toàn bộ	17,0963	21,8627
Test niêm phong, đo thật ban ngày	17,7409	22,6181
Cùng phạm vi với Prophet	17,7934	22,3645

Sai số trên test thấp hơn trên ba fold kiểm định tới hơn sáu điểm. Nguyên nhân nằm ở vị trí của hai tập trên trục thời gian, không phải ở việc test dễ hơn. Ba fold kiểm định nằm ở giai đoạn **sớm** của chuỗi, nơi lịch sử dùng để tính lag₉₆ và các cửa sổ trượt còn ngắn, nên nhiều mốc dự báo thiếu ngữ cảnh. Tập test nằm ở **cuối** chuỗi, mọi mốc đều đã có đủ lịch sử phía sau. Chênh lệch này đến từ phạm vi dữ liệu và không cho phép kết luận rằng tập test đã tham gia vào việc chọn mô hình — hàm mất mát và siêu tham số đều khoá trên tập Phát triển trước khi tập test được mở.

7.5.5 Đối chứng với Prophet

Chỉ số dự báo vượt trội

Một con số WAPE đứng một mình không nói lên chất lượng. Nó cần được đặt cạnh một mô hình đối chứng. Chỉ số **Forecast Skill Score** đo phần sai số cắt giảm được so với đối chứng:

$$SS = \left(1 - \frac{WAP E_{\text{mô hình}}}{WAP E_{\text{đối chứng}}}\right) \times 100\% \quad (7.12)$$

Triết lý đánh giá theo nhiều chỉ số so với một đường cơ sở tham chiếu lấy từ Zhang và cộng sự [11]; công thức cụ thể dùng WAPE ở trên là cách áp dụng của dự án, không trích nguyên văn từ bài báo đó. Hình 7.22 là đoạn nguồn.

of the data. Conventional measures of solar forecasting accuracy include root mean square error (RMSE), mean bias error (MBE), and mean absolute error (MAE) [3, 4].

Hình 7.22: Đoạn được đánh dấu trong Zhang và cộng sự [11], NREL/CP-5500-60142: các thước đo thông dụng của dự báo quang điện gồm RMSE, MBE và MAE. Dự án lấy tinh thần đánh giá bằng nhiều chỉ số đặt cạnh một mô hình đối chứng, thay vì đọc một giá trị sai số đơn lẻ.

Điều kiện so sánh

Prophet là mô hình chuỗi thời gian cộng tính, chỉ học xu thế và chu kỳ ngày/tuần từ chính lịch sử sản lượng, **không dùng bất kỳ biến khí tượng nào**. Nó được huấn luyện trong cùng cửa sổ thời gian Phát triển với mô hình chính, rồi dự báo tại đúng các mốc mục tiêu của tập test.

Khi chấm điểm, hai mô hình dùng **cùng một tập dòng**, cùng tử số và cùng mẫu số. Phạm vi này yêu cầu cả giá trị tại T lẫn nhãn tại $T+h$ đều là số đo thật, đồng thời dòng tại T là ban ngày — chặt hơn phạm vi đo thật ban ngày của mô hình chính, nên số dòng nhỏ hơn: 220.260 ở H1 và 202.955 ở H4. Kết quả ở Bảng 7.34.

Bảng 7.34: Đối chứng với Prophet trên cùng tập dòng. Đọc từ 08_baseline_prophet_test/prophet_bang_bao_cao.csv và prophet_test_summary.json.

Tầm và mô hình	Số dòng	WAPE (%)	RMSE	MAE	R^2
H1 — LightGBM	220.260	17,7934	3,4432	1,4010	0,9232
H1 — Prophet	220.260	35,2563	5,4666	2,7759	0,8063
<i>Skill Score H1</i>		+49,53%			
H4 — LightGBM	202.955	22,3645	4,3447	1,8483	0,8815
H4 — Prophet	202.955	35,0858	5,6147	2,8997	0,8021
<i>Skill Score H4</i>		+36,26%			

Giới hạn của phép đối chứng

Chênh lệch 17,46 điểm WAPE ở H1 là kết quả cuối cùng của hai phương án, nhưng **không tách được** thành phần đóng góp của riêng nhóm đặc trưng khí tượng. Lý do là hai mô hình khác nhau đồng thời ở **hai điểm**: thuật toán (phân rã chuỗi cộng tính so với cây tăng cường gradient) và tập đầu vào (không có biến khí tượng so với có). Muốn tách thì phải chạy thêm hai cấu hình đối chứng nữa: LightGBM bỏ hết biến khí tượng, và Prophet có biến ngoại sinh. Hai cấu hình đó nằm ở Mục 8.3 như hướng phát triển tiếp theo.

Ngoài ra, chỉ số vượt trội đo mức cải thiện so với **một** mô hình đối chứng cụ thể, không phải so với mọi phương án khả dĩ. Một đường cơ sở yếu hơn sẽ cho chỉ số cao hơn mà không phản ánh năng lực mô hình tốt hơn.

7.5.6 Kiểm chứng độ trễ pha trên mô hình cuối

Nguyên cơ lớn nhất của một mô hình dự báo quang điện là nó học cách lặp lại giá trị vừa đo thay vì thật sự dự báo — khi đó đường dự báo trông rất khớp nhưng thực chất chỉ là đường thực tế bị đẩy sang phải. Notebook 09_kiem_chung_tre pha đo trực tiếp hiện tượng đó trên 478.902 dòng dự báo H1 của tập test, bằng cách so mốc đạt đỉnh của đường dự báo với mốc đạt đỉnh của đường thực tế, cho từng trạm từng ngày:

```
--- LECH DINH LOCAL: 40 site x 5,080 ngày ---
lech_phut duong = du bao den SAU thuc te (dich phai / tre). am = du bao den SOM.

count    5080.00
mean     -1.05
std       78.63
min     -495.00
25%     -45.00
50%      15.00
75%      45.00
max      270.00

So ngay du bao dich PHAI (tre) : 2,791 / 5,080 (54.9%)
So ngay dung khop (lech = 0)   : 384 / 5,080 (7.6%)
So ngay du bao dich TRAI (som) : 1,905 / 5,080 (37.5%)
```

Trung bình lệch $-1,05$ phút, tức gần như không thiên về bên nào; trung vị $+15$ phút, đúng một bước. Nếu mô hình chỉ lặp lại giá trị vừa đo thì độ lệch phải bằng đúng tầm dự báo ở gần như mọi ngày, và tỷ lệ dịch phải sẽ tiến tới 100%. Con số thực tế là 54,9% dịch phải so với 37,5% dịch trái — phân bố hai phía, không phải dấu hiệu của mô hình sao chép.

Độ lệch chuẩn 78,63 phút cho thấy mức phân tán giữa các ngày vẫn lớn, và 32 trên 40 trạm có trung vị nghiêng về phía trễ. Đây là giới hạn còn lại của mô hình, ghi nhận để lần huấn luyện sau xử lý tiếp.

Notebook còn đo một giả thuyết cạnh tranh: nếu độ lệch bắt nguồn từ việc dữ liệu khí tượng chỉ có độ phân giải một giờ, thì đỉnh thực tế xảy ra càng gần cuối khối giờ sẽ càng lệch nhiều. Số đo bác bỏ điều đó — cả bốn vị trí trong khối giờ đều cho trung vị đúng 15 phút, xem Bảng 7.35.

7.6 Giải thích mô hình bằng SHAP

Cây tăng cường gradient cho sai số thấp nhưng bản thân mô hình không nói được nó dựa vào đâu để ra một con số. Bước này dùng SHAP để quy phần đóng góp của từng đặc trưng vào từng dự báo.

Bảng 7.35: Độ lệch đỉnh theo vị trí của đỉnh thực tế trong khối giờ. Đọc từ tệp kết quả 09_kiem_chung_tre_pha/lech-theo-vi-tri-trong-gio_h1.csv.

Phút trong giờ	Số ngày	Độ lệch trung vị (phút)
0–14	1.052	15,0
15–29	1.112	15,0
30–44	1.631	15,0
45–59	1.285	15,0

7.6.1 Cơ sở phương pháp

SHAP quy phần đóng góp theo giá trị Shapley của lý thuyết trò chơi hợp tác: mỗi đặc trưng được coi là một người chơi, và phần đóng góp của nó là mức thay đổi trung bình của dự báo khi thêm nó vào mọi tổ hợp đặc trưng khác. Cách quy này có tính chất cộng — tổng đóng góp của tất cả đặc trưng cộng với giá trị nền bằng đúng dự báo — nên đọc được ở mức từng dòng dữ liệu. Lundberg và Lee [10] là công trình đề xuất khung thống nhất này, xem Hình 7.23.

Phạm vi tính: mô hình thắng ở tầm H1 (cấu hình MAE), chạy trên toàn bộ 478.902 dòng của tập test với 54 đặc trưng. Giá trị SHAP tính trên thang mục tiêu đã chuẩn hoá k , không phải thang kWh.

Ma trận đặc trưng dùng để tính SHAP lấy đúng tệp `X_test_h1.parquet` mà bước đánh giá đã ghi ra, nên phạm vi dòng trùng khít với Phần 5. Bước này đã được chạy lại một lần nữa sau khi mô hình được huấn luyện lại: kết quả xếp hạng và giá trị SHAP trùng khít tới từng chữ số với lần chạy trước, phù hợp với chế độ tắt định nêu ở Mục 4.5.

7.6.2 Tầm quan trọng tổng thể

Bảng 7.36 xếp hạng đặc trưng theo trung bình trị tuyệt đối giá trị SHAP trên toàn tập test.

Bảng này cho một kết quả đáng chú ý khi đặt cạnh bảng thông tin tương hỗ ở Mục 3.7. Ở bước chọn đặc trưng, bốn vị trí đầu đều là thống kê của sổ trượt một giờ. Ở đây, đứng đầu lại là `direct_normal_irradiance` — một biến khí tượng đo được — và vị trí thứ tư thuộc về `ghi_cs_mt`, tức bức xạ trời quang **tại thời điểm mục tiêu**.

Hai điểm rút ra. Thứ nhất, thông tin tương hỗ đo quan hệ của một đặc trưng với mục tiêu khi đứng riêng, còn SHAP đo phần đóng góp của nó **trong mô hình đã huấn luyện**, nơi các đặc trưng chia nhau thông tin; hai thước đo trả lời hai câu hỏi khác nhau nên không buộc phải trùng thứ hạng. Thứ hai, việc `ghi_cs_mt` lọt vào nhóm bốn đầu

A Unified Approach to Interpreting Model Predictions

Scott M. Lundberg

Paul G. Allen School of Computer Science
University of Washington
Seattle, WA 98105
slund1@cs.washington.edu

Su-In Lee

Paul G. Allen School of Computer Science
Department of Genome Sciences
University of Washington
Seattle, WA 98105
suinlee@cs.washington.edu

Abstract

Understanding why a model makes a certain prediction can be as crucial as the prediction's accuracy in many applications. However, the highest accuracy for large modern datasets is often achieved by complex models that even experts struggle to interpret, such as ensemble or deep learning models, creating a tension between *accuracy* and *interpretability*. In response, various methods have recently been proposed to help users interpret the predictions of complex models, but it is often unclear how these methods are related and when one method is preferable over another. To address this problem, we present a unified framework for interpreting predictions, SHAP (SHapley Additive exPlanations). SHAP assigns each feature an importance value for a particular prediction. Its novel components include: (1) the identification of a new class of additive feature importance measures, and (2) theoretical results showing there is a unique solution in this class with a set of desirable properties. The new class unifies six existing methods, notable because several recent methods in the class lack the proposed desirable properties. Based on insights from this unification, we present new methods that show improved computational performance and/or better consistency with human intuition than previous approaches.


Hình 7.23: Trang đầu bài báo Lundberg và Lee [10], *A Unified Approach to Interpreting Model Predictions*, NeurIPS 2017 — nguồn của phương pháp quy đóng góp mà bước này sử dụng.

Bảng 7.36: Mười đặc trưng có tầm quan trọng tổng thể lớn nhất, đo bằng trung bình trị tuyệt đối giá trị SHAP. Đọc từ 08_explain/shap_importance.csv.

Hạng	Đặc trưng	SHAP trung bình	Nhóm
1	direct_normal_irradiance	0,0872	Khí tượng đo được
2	ky_vong	0,0851	Quy mô trạm
3	rolling_min_4	0,0799	Lịch sử chuỗi
4	ghi_cs_mt	0,0745	Trời quang tại $T+h$
5	rolling_max_4	0,0671	Lịch sử chuỗi
6	rolling_mean_4	0,0565	Lịch sử chuỗi
7	minute_of_day	0,0469	Thời gian
8	tran_cong_suat	0,0391	Quy mô trạm
9	rolling_std_4	0,0334	Lịch sử chuỗi
10	weather_condition_enc	0,0219	Khí tượng phân loại

là bằng chứng cho thấy nhóm đặc trưng tất định tại $T+h$ ở Mục 3.4 thực sự được mô hình dùng, chứ không phải cột thừa.

Hình 7.24 trình bày phân bố giá trị SHAP của từng đặc trưng trên toàn bộ tập test.



Hình 7.24: (Trích xuất từ Notebook 08_explainable_ai.ipynb) Biểu đồ beeswarm. Mỗi điểm là một dòng dữ liệu; vị trí ngang là giá trị SHAP, màu là độ lớn của chính đặc trưng đó.

7.6.3 Giải thích ba dự báo cụ thể

Tính cộng của SHAP cho phép mổ xẻ một dự báo đơn lẻ. Notebook chọn ba trường hợp tương phản trong tập test, ghi ở Bảng 7.37.

Ba trường hợp này minh họa ba chế độ khác nhau của mô hình. Ở ca đẩy lên, đóng góp lớn nhất đến từ `direct_normal_irradiance` (+0,1047) và `rolling_min_4`

Bảng 7.37: Ba dự báo được mổ xẻ. Đọc từ 08_explain/local_shap_cases.csv.

Trường hợp	Trạm	Thời điểm	Thực tế (kWh)	Tổng SHAP
Đẩy dự báo lên	10	07/04/2022 10:30	5,9688	+0,5972
Kéo dự báo xuống	40	18/04/2022 08:00	0,1250	-0,6860
Gần mức nền	28	21/02/2022 11:15	1,8066	-0,0004

(+0,0695) — bức xạ trực xạ mạnh cộng với nền sản lượng giờ trước còn cao. Ở ca kéo xuống, hai đặc trưng đẩy mạnh nhất theo chiều âm là `rolling_max_4` (-0,1953) và `rolling_min_4` (-0,1111), kèm `direct_normal_irradiance` (-0,1019): sáng sớm, sản lượng giờ trước gần như bằng không và bức xạ trực xạ chưa lên. Ở ca gần nền, tổng đóng góp gần triệt tiêu vì các phần dương và âm cân nhau. Ba hình dạng thác trình bày ở Hình 7.25.

7.6.4 Giới hạn diễn giải

SHAP quy phần đóng góp của đặc trưng vào **dự báo của mô hình**, không phải vào sản lượng thật. Nó cho biết mô hình đã dựa vào đâu, không cho biết quan hệ nhân quả vật lý. Khi hai đặc trưng tương quan cao — mà Mục 3.7 cho thấy có nhiều cặp như vậy — phần đóng góp có thể bị chia giữa chúng theo cách phụ thuộc vào cấu trúc cây đã học, nên không nên đọc thứ hạng như một xếp hạng tầm quan trọng vật lý.

7.7 Ứng dụng trực quan hoá kết quả


Kết quả dự báo được đưa vào một ứng dụng Streamlit gồm ba trang, mã nguồn tại `srcs/07_dashboard/`. Ứng dụng đọc lại đúng các tệp kết quả mà Phần 5 dùng, không tính lại chỉ số. Ba trang lần lượt ở Hình 7.26, Hình 7.27 và Hình 7.28.

7.7.1 Trang giám sát chuỗi thời gian

Trang này đặt đường thực tế cạnh đường dự báo theo từng trạm và từng khoảng thời gian, kèm bảng chỉ số theo trạm và biểu đồ đối chiếu với Prophet.

7.7.2 Trang giải thích dự báo

Trang này đưa kết quả SHAP ở Phần 6 lên giao diện: tỷ trọng đóng góp theo nhóm đặc trưng, xếp hạng đặc trưng, và giải thích một dự báo cụ thể do người dùng chọn.



Hình 7.25: (Trích xuất từ Notebook 08_explainable_ai.ipynb) Biểu đồ thác cho hai dự báo tương phản. **Trên:** trường hợp các đặc trưng cùng đẩy dự báo lên. **Dưới:** trường hợp cùng kéo xuống.

Time Series & Baseline

Model Explainability (XAI)

Dự báo tới & What-if

Solar Forecast Analytics

The Outliers - Energy Forecasting

Bộ lọc

Horizon

h1 (15 phút)

Artifact đang hiển thị: MAE · H1 —
chọn từ validation

Site

1

☐ Chỉ dòng ban ngày

☒ Chỉ dữ liệu đo thật (bỏ
outlier/impute)

☒ Hiện đường Prophet (đối chứng)

Khoảng ngày

☒ Cửa sổ 7 ngày

☐ Tự chọn

Cửa sổ

2021-12-30 00:00:00



Dự báo sản lượng điện mặt trời 15 phút — kết quả trên tập test niêm phong

Mô hình được chọn: H1 = MAE (WAPE validation 22.05%), H4 = MAE (WAPE validation 26.97%). Quyết định chỉ dùng validation; các số dưới đây đo trên tập Test niêm phong.

TẬP TEST NIÊM PHONG

WAPE

17.74%

▲ Skill Score common
+49.5%

TRỄ PHA

+2.77 phút

đường = dự báo đi sau

SKILL SCORE

+49.5%

▲ common scope với
Prophet

MAE

1.3783 kWh

sai số tuyệt đối

R²

0.9243

▲ độ khớp mô hình


RMSE

3.4131 kWh

383 dòng đang xem

KPI WAPE/RMSE/MAE/R² lấy từ phạm vi Test chính thức measured + daylight (n=229713) của model MAE · H1; Skill Score lấy từ phạm vi chung với Prophet (n=220260). Các KPI không đổi khi chỉnh Site hay khoảng ngày; chart và bảng bên dưới mới lọc theo sidebar.

Thực tế vs Dự báo — Trạm 1 (2021-12-30 → 2022-01-06)




Đường chấm xanh là là Prophet — mô hình chuỗi thời gian không dùng đặc trưng thời tiết. Sao vàng/tím là đỉnh thực tế/dự báo từng ngày. Dấu X đỏ là outlier bị loại khỏi huấn luyện.

Xếp hạng 42 trạm theo WAPE




Phân bố sai số (residual)



Lịch quanh 0 và đối xứng nghĩa là mô hình không thiên vị theo một hướng.

Thực tế vs Dự báo (scatter)



Điểm nằm trên đường chéo là dự báo khớp thực tế.

Chi tiết theo trạm

site_id	rows	waape	rmse	mae	r2	horizon
1	6108	12.87	2.31	1.30	0.89	1
2	6085	13.17	2.04	1.15	0.89	1
3	5993	14.55	1.46	0.88	0.88	1
4	5400	15.57	0.22	0.15	0.84	1
5	4085	15.80	0.23	0.15	0.84	1
6	6064	15.22	3.03	2.01	0.89	1

waape/rmse/mae: xanh = thấp = tốt. r2 ngược lại: xanh = gần 1 = tốt.

Đối chứng với Prophet


Hình 7.26: Trang 1 của ứng dụng — giám sát chuỗi thời gian theo trạm.

7.7.3 Trang dự báo và phân tích giả định

Trang này gọi `forecast_service.py` để sinh dự báo mới. Điểm cần nêu về mặt kỹ thuật: dịch vụ này **đọc lại** `clip_k` và các tham số chuẩn hoá từ `model_config.json` của chính mô hình đang dùng, thay vì khai báo lại trong mã phục vụ. Nhờ vậy phép nhân ngược từ k về kWh ở lúc suy luận trùng khít với lúc huấn luyện; nếu hai bên khai báo riêng thì chỉ cần một lần sửa cấu hình là kết quả trên giao diện lệch khỏi kết quả trong


app
TimeSeries
SHAP
Du Bao

Bộ lọc XAI
Mô hình / horizon
MAE - H1



Hình 7.27: Trang 2 của ứng dụng — giải thích dự báo bằng SHAP.

báo cáo mà không ai phát hiện.



Hình 7.28: Trang 3 của ứng dụng — dự báo và phân tích giả định.

7.8 Kết luận và hướng phát triển

7.8.1 Kết quả đạt được

Quy trình dựng được một mô hình LightGBM dùng chung cho 40 trạm quang điện, đạt WAPE 17,74% ở tầm 15 phút và 22,62% ở tầm một giờ trên tập test niêm phong, phạm vi đo thật ban ngày. So với đối chứng Prophet trên cùng tập dòng, chỉ số vượt trội đạt +49,53% và +36,26%.

Điều đáng nói hơn con số là cách các con số đó được bảo vệ. Năm rào chắn ở Mục 1.5 được kiểm chứng bằng số liệu chứ không bằng lập luận: phép ghép thời tiết nhân quả đưa số dòng dùng thời tiết tương lai về 0; thống kê quy mô tính riêng theo từng fold; cận cắt suy từ phân vị của tập huấn luyện; tập test mở đúng một lần. Khi phát hiện tầm H4 có thể cho kết quả tốt hơn với cấu hình MAE huấn luyện sau, nhóm không chấm lại tập test, vì mở tập niêm phong lần thứ hai chính là điều mà toàn bộ quy trình được dựng ra để ngăn.

7.8.2 Giới hạn

- **Bộ dữ liệu độc lập nhỏ hơn con số 42.** Bốn mươi hai dàn quang điện nằm trên năm khuôn viên, nên dữ liệu khí tượng bị nhân bản giữa các trạm cùng khuôn viên; số mẫu thời tiết độc lập thực chất là năm.
- **Sai số phân bố không đều giữa các trạm,** từ 11,89% tới 28,32% ở tầm H1, và 15,12% tới 35,88% ở tầm H4. Mô hình dùng chung chưa mô tả hết phần khác biệt riêng của từng trạm.
- **Độ trễ pha còn tồn tại ở mức thấp:** trung vị +15 phút, và 32 trên 40 trạm nghiêng về phía trễ.
- **Phép đối chứng Prophet không tách được đóng góp của biến khí tượng,** vì hai mô hình khác nhau đồng thời ở thuật toán và tập đầu vào.
- **Hai siêu tham số dừng ngay tại biên miền tìm kiếm,** nên không thể tuyên bố cấu hình hiện tại là tối ưu.
- **Thời tiết chỉ có độ phân giải một giờ,** và bước hạ độ phân giải mới đưa tỷ lệ bước có giá trị thay đổi lên 76,7%, chưa phủ hết các khối rìa sáng và rìa chiều.

7.8.3 Hướng phát triển

Bốn việc cụ thể, xếp theo mức dễ làm:

1. Huấn luyện bổ sung cấu hình MAE cho tầm H4 rồi khoá lại trước khi mở một tập test mới, để phép so ở H4 có đủ ba hàm mất mát.
2. Mở rộng miền tìm kiếm ở hai chỗ chạm biên — hạ cận dưới của `subsample` và nâng cận trên của `reg_alpha`.
3. Chạy hai cấu hình đối chứng còn thiếu để tách phần đóng góp của nhóm đặc trưng khí tượng: một LightGBM bỏ hết biến khí tượng, và một Prophet có biến ngoại sinh.
4. Xử lý phần khác biệt giữa các trạm, hoặc bằng đặc trưng riêng cho trạm, hoặc bằng cách hiệu chỉnh đầu ra theo từng trạm sau khi dự báo.

Tài liệu tham khảo

- [1] S. Wimalaratne, D. Haputhanthri, S. Kahawala, G. Gamage, D. Alahakoon và A. Jennings (2022), “UNISOLAR: An Open Dataset of Photovoltaic Solar Energy Generation in a Large Multi-Campus University Setting”, *15th International Conference on Human System Interaction (HSI)*, IEEE. DOI: [10.1109/HSI55341.2022.9869474](https://doi.org/10.1109/HSI55341.2022.9869474)
- [2] M. Roy, V. Pyltsov và Y. Hu (2025), “IISE PG&E Energy Analytics Challenge 2025: Hourly-Binned Regression Models Beat Transformers in Load Forecasting”, Columbia University, arXiv:2505.11390. <https://arxiv.org/abs/2505.11390>
- [3] T. Kim, W. Ko và J. Kim (2019), “Analysis and Impact Evaluation of Missing Data Imputation in Day-ahead PV Generation Forecasting”, *Applied Sciences*, tập 9, số 1, bài 204. DOI: [10.3390/app9010204](https://doi.org/10.3390/app9010204)
- [4] X. Li, G. Du, Y. Li, Z. Ma, L. Liu, M. Jiang, F. Liu và T. Mu (2025), “Outlier Detection of Photovoltaic Power Generation System Data Based on GMM-IF Algorithm”, *IEEE Access*, tập 13, tr. 108823–108837. DOI: [10.1109/ACCESS.2025.3581641](https://doi.org/10.1109/ACCESS.2025.3581641)
- [5] B. Haurwitz (1945), “Insolation in Relation to Cloudiness and Cloud Density”, *Journal of Meteorology*, tập 2, số 3, tr. 154–166. https://journals.ametsoc.org/view/journals/atsc/2/3/1520-0469_1945_002_0154_iirtca_2_0_co_2.xml
- [6] M. D. Bailey và cộng sự (2024), “Temporal and Spatial Downscaling for Solar Radiation”, arXiv:2405.11046. <https://arxiv.org/abs/2405.11046>
- [7] N. A. Engerer và F. P. Mills (2014), “KPV: A clear-sky index for photovoltaics”, *Solar Energy*, tập 105, tr. 679–693. DOI: [10.1016/j.solener.2014.04.019](https://doi.org/10.1016/j.solener.2014.04.019)
- [8] S. Dev, T. AlSkaif, M. Hossari, R. Godina, A. Louwen và W. van Sark (2018), “Solar Irradiance Forecasting Using Triple Exponential Smoothing”, *IEEE International Conference on Smart Energy Systems and Technologies (SEST)*. arXiv:1807.05872. <https://arxiv.org/abs/1807.05872>
- [9] A. Temporal-Neto và cộng sự (2025), “PIN: A new metric to evaluate solar irradiance forecast models”, *Energy Reports*, tập 13, tr. 1–12. DOI: [10.1016/j.egyr.2025.01.076](https://doi.org/10.1016/j.egyr.2025.01.076)

- [10] S. M. Lundberg và S.-I. Lee (2017), “A Unified Approach to Interpreting Model Predictions”, *Advances in Neural Information Processing Systems (NeurIPS)*, tập 30. arXiv:1705.07874. <https://arxiv.org/abs/1705.07874>
- [11] J. Zhang, B.-M. Hodge, A. Florita, S. Lu, H. F. Hamann và V. Banunarayanan (2013), “Metrics for Evaluating the Accuracy of Solar Power Forecasting”, NREL/CP-5500-60142, *3rd International Workshop on Integration of Solar Power into Power Systems*. OSTI Report No. 1114086. <https://www.nrel.gov/docs/fy14osti/60142.pdf>
- [12] V. P. Lonij, A. E. Brooks, K. Koch và A. D. Cronin (2012), “Analysis of 80 Rooftop PV Systems in the Tucson, AZ Area”, *38th IEEE Photovoltaic Specialists Conference (PVSC)*, tr. 549–553. DOI: [10.1109/PVSC.2012.6317674](https://doi.org/10.1109/PVSC.2012.6317674). Nguồn của chỉ số K dùng phân vị sản lượng đo được của chính hệ thống làm mẫu số.

Kết luận và Hướng phát triển

8.1 Kết luận Tổng quan

[Tóm tắt lại việc hoàn thành các mục tiêu dự án: Xây dựng thành công Data Warehouse, làm sạch dữ liệu nhiễu, và phát triển hệ thống Dashboard trực quan giúp doanh nghiệp chuyển đổi từ quản lý thụ động sang giám sát dựa trên dữ liệu.]

8.2 Khuyến nghị Chiến lược (Actionable Insights)

[Đề xuất các hành động cụ thể: Lắp đặt hệ thống làm mát tự động để giảm suy hao nhiệt, thiết lập quy trình kiểm tra Inverter định kỳ để khắc phục độ nhiễu ban đêm, và ứng dụng kết quả dự báo để lập kế hoạch vệ sinh tấm pin.]

8.3 Hạn chế của Dự án

[Những giới hạn về phần cứng, thời gian xử lý dữ liệu lớn, hoặc sự thiếu hụt của các mô hình học sâu (Deep Learning) phức tạp hơn.]

8.4 Hướng phát triển trong tương lai

8.4.1 Nâng cấp Hệ thống Phân tích Dự đoán (Predictive Analytics)

[Tích hợp các mô hình Machine Learning mạnh mẽ hơn (XGBoost, LSTM) để dự báo biến động công suất theo thời gian thực.]

8.4.2 Tự động hóa và Đưa lên Đám mây (Cloud & Automation)

[Triển khai toàn bộ Pipeline ETL lên các dịch vụ Cloud như AWS/GCP để xử lý luồng dữ liệu Streaming từ các cảm biến IoT.]

Phụ lục A: Kế hoạch Thực hiện

[Bảng phân công nhiệm vụ chi tiết và kế hoạch 14 tuần thực hiện dự án của các thành viên.]

Phụ lục B: Cấu trúc Mã nguồn

[Sơ đồ cấu trúc thư mục của package Python du_an_tot_nghiep và các script tiện ích.]

Tài liệu Tham khảo

- [1] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control*. 5th ed. Wiley.
- [2] Taylor, S. J., & Letham, B. (2018). Forecasting at Scale. *The American Statistician*, 72(1), 37–45.
- [3] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of KDD 2016*, 785–794.
- [5] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.
- [6] Vaswani, A., et al. (2017). Attention Is All You Need. *Proceedings of NeurIPS 2017*, 5998–6008.
- [7] Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit*. 3rd ed. Wiley.
- [8] NASA POWER Project. (2024). <https://power.larc.nasa.gov/>.
- [9] Supabase Documentation. (2024). <https://supabase.com/docs>.
- [10] IEA – International Energy Agency. (2024). <https://www.iea.org/reports/renewables-2024>.
- [11] Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly Detection: A Survey. *ACM Computing Surveys*, 41(3), Article 15.
- [12] Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.