

TRƯỜNG CAO ĐẲNG FPT POLYTECHNIC



FPT POLYTECHNIC

DỰ ÁN TỐT NGHIỆP

CHUYÊN NGÀNH: XỬ LÝ DỮ LIỆU

PHÂN TÍCH HIỆU SUẤT VÀ DỰ BÁO SẢN LƯỢNG HỆ THỐNG ĐIỆN MẶT TRỜI

Nhóm thực hiện: The Outliers

Sinh viên thực hiện:

- | | |
|---------------------|---------|
| 1. Nguyễn Vũ Nhật | PS44442 |
| 2. Nguyễn Văn Sỹ | PS43671 |
| 3. Lê Công Toàn | PS44145 |
| 4. Nguyễn Xuân Hùng | PS44527 |
| 5. Ngô Tấn Đạt | PS44589 |

Giảng viên hướng dẫn: Văn Công Khanh

TP. HỒ CHÍ MINH, THÁNG 6 NĂM 2026

Lời cảm ơn

[Nội dung lời cảm ơn của sinh viên đối với giảng viên hướng dẫn, gia đình và nhà trường sẽ được viết tại đây.]

Nhận xét của Giảng viên Hướng dẫn

[Nội dung nhận xét và đánh giá của Giảng viên Hướng dẫn đối với kết quả thực hiện dự án của nhóm.]

Nhận xét của Giảng viên Phản biện

[Nội dung nhận xét và đánh giá của Giảng viên Phản biện tại buổi bảo vệ dự án tốt nghiệp.]

Tóm tắt Dự án

Dự án tốt nghiệp “Phân tích và Xử lý Bất thường trong Dữ liệu Sản lượng Năng lượng Mặt trời” nhằm mục đích xây dựng một hệ thống phân tích dữ liệu toàn diện để phát hiện, xử lý và dự báo các bất thường trong sản lượng phát điện của các hệ thống quang điện (PV). Bằng cách thu thập và tích hợp dữ liệu từ 42 trạm phát điện tại Úc cùng dữ liệu khí tượng viễn thám từ Open-Meteo, nhóm đã thiết kế một kho dữ liệu đa chiều (Data Warehouse) trên nền tảng Supabase theo mô hình Galaxy Schema. Quy trình ETL được tự động hóa để làm sạch dữ liệu, xử lý các hiện tượng khuyết thiếu, nhiễu ban đêm, và sai lệch do cảm biến.

Qua quá trình Phân tích Khám phá Dữ liệu (EDA), nhóm đã rút ra các insight quan trọng về sự ảnh hưởng của nhiệt độ, mức độ mây che phủ đến hiệu suất PV. Ngoài ra, dự án cũng áp dụng các mô hình học máy chuỗi thời gian như ARIMA và Prophet để thiết lập đường cơ sở (Baseline) dự báo sản lượng, kết hợp hiển thị trực quan thông qua Dashboard Tableau. Hệ thống không chỉ cung cấp cái nhìn toàn cảnh về tình trạng hoạt động của các trạm điện mặt trời, mà còn hỗ trợ ban quản lý đưa ra quyết định kịp thời nhằm tối ưu hóa hiệu suất và giảm thiểu rủi ro vận hành.

Mục lục

Lời cảm ơn	1
Nhận xét của Giảng viên Hướng dẫn	2
Nhận xét của Giảng viên Phản biện	3
Tóm tắt Dự án	4
Danh mục Từ viết tắt	15
1 Tổng quan Đề tài và Bài toán Nghiên cứu	16
1.1 Bối cảnh thực tế và lý do chọn đề tài	16
1.2 Bài toán kinh doanh và các khó khăn cần giải quyết	16
1.3 Mục tiêu dự án và Kết quả dự kiến	17
1.4 Đối tượng và phạm vi nghiên cứu	17
1.5 Bố cục báo cáo	17
2 Cơ sở Lý thuyết và Kiến trúc Hệ thống	19
2.1 Cơ sở Lý thuyết	19
2.1.1 Khái quát về Phân tích Dữ liệu trong Ngành Năng lượng Tái tạo	19
2.1.2 Các Chỉ số Hiệu năng Cốt lõi (KPIs) và Bài toán Tổng thất Vận hành	19
2.1.3 Hệ thống Kho Dữ liệu (Data Warehouse) và Quy trình ETL	20
2.1.4 Mô hình Dữ liệu Đa chiều và Lược đồ Thiên hà (Galaxy Schema)	21
2.1.5 Phương pháp Phát hiện Dị thường và Lọc Nhiễu Nghiệp vụ	21
2.1.6 Trực quan hóa Dữ liệu trong Business Intelligence (BI)	21
2.2 Phân tích Yêu cầu Nghiệp vụ (Business Requirements)	22
2.2.1 Phân tích Các Bên Liên quan (Stakeholders)	22
2.2.2 Hệ thống Chỉ số Đo lường (KPI Framework)	22
2.3 Kiến trúc Hệ thống Đề xuất (6-Layer Data Pipeline)	23
2.4 Từ điển Dữ liệu Nghiệp vụ (Data Dictionary)	24
3 Thu thập, Tiền xử lý và Mô hình hóa Kho Dữ liệu	25
3.1 Tổng quan Kiến trúc Pipeline Xử lý Dữ liệu	25
3.2 Đánh giá Chất lượng và Khám phá Dữ liệu (EDA)	26
3.2.1 Kiểm tra Dữ liệu Thiếu, Trùng lặp và Đứt gãy Chuỗi Thời gian (điểm gián đoạn thời gian)	26

3.3	Làm sạch và Chuẩn hóa Dữ liệu (Data Cleaning)	27
3.3.1	Chuẩn hóa Cấu trúc Cột và Xử lý Lỗi Logic	27
3.3.2	Xử lý Dữ liệu Ngoại lai (Outliers) và Gán Mã Lý do Kỹ thuật	27
3.4	Trích xuất Đặc trưng Nghiệp vụ (trích xuất đặc trưng nghiệp vụ)	28
3.4.1	Đặc trưng Vận hành và Hiệu suất Kỹ thuật	28
3.4.2	Đặc trưng Thời gian Chu kỳ	29
3.5	Mô hình hóa Lược đồ Thiên hà (Galaxy Schema)	29
3.5.1	Các Sơ đồ Thiết kế Mô hình Dữ liệu	29
3.5.2	Cấu trúc Các Bảng trong Kho Dữ liệu	30
3.6	Tạo Bảng Tổng hợp và Siêu thị Dữ liệu (Siêu thị dữ liệu chuyên đề)	31
3.7	Kiểm tra Tính Toàn vẹn và Bảo mật Dữ liệu	31
4	Phát hiện Dị thường và Làm sạch Dữ liệu Nâng cao	32
4.1	Tổng quan Kiến trúc Pipeline Xử lý Dữ liệu	32
4.1.1	Thiết lập Tiến trình Nạp Dữ liệu Thử tự	33
4.1.2	Cơ chế Quản lý Giao dịch và An toàn Dữ liệu	34
4.2	Đánh giá Chất lượng và Khám phá Dữ liệu (EDA ban đầu)	34
4.2.1	Các Cột Thực Tế và Ánh Xạ Dữ Liệu Trong Pipeline	35
4.3	Làm sạch và Chuẩn hóa Dữ liệu (Data Cleaning)	37
4.3.1	Xử lý Dữ liệu Khuyết thiếu và Lỗi Logic	37
4.3.2	Xử lý Dữ liệu Ngoại lai (Outliers) và Lọc nhiễu	41
4.4	Biến đổi và Trích xuất Đặc trưng (trích xuất đặc trưng nghiệp vụ)	47
4.4.1	Giải quyết độ lệch tần suất ghi nhận (Granularity Alignment)	47
4.4.2	Trích xuất các đặc trưng thời gian và lịch trình học tập	48
5	Trực quan Dữ liệu và Xây dựng Dashboard	49
5.1	Chiến lược Kết nối Dữ liệu và Thiết kế UI/UX	49
5.2	Chi tiết Hệ thống Dashboard Phân tích	49
5.2.1	Dashboard 1: Tổng quan Vận hành (Executive Overview)	49
5.2.2	Dashboard 2: Phân tích Hiệu suất và Khí hậu	49
5.2.3	Dashboard 3: Giám sát Bất thường và Lỗi Cảm biến	49
6	Khai phá Dữ liệu và Business Insights	50
6.1	Insight 1: Hiện tượng suy giảm hiệu suất do nhiệt độ (Thermal Degradation)	50
6.2	Insight 2: Điểm mù vận hành từ “Độ nhiễu ban đêm”	50
6.3	Insight 3: Ứng dụng Mô hình dự báo (Baseline) để tối ưu vận hành	50
7	Thiết kế, Huấn luyện và Đánh giá Mô hình Dự báo Sản lượng Quang điện	51
8	Khai phá Dữ liệu và Dự báo Sản lượng	52
8.1	Tổng quan quy trình học máy	52

8.1.1	Phạm vi và dữ liệu đầu vào	52
8.1.2	Bài toán và tầm dự báo	53
8.1.3	Nhấn ngoại lai kế thừa từ tầng ETL	54
8.1.4	Sơ đồ toàn cảnh	58
8.1.5	Năm rào chắn chống rò rỉ dữ liệu	60
8.2	Chuẩn bị dữ liệu và chia tập	61
8.2.1	Hiện trạng bộ dữ liệu	61
8.2.2	Dựng lại lưới thời gian liên tục	61
8.2.3	Phân tích khám phá dữ liệu và các quyết định sinh đặc trưng	64
8.2.4	Chia dữ liệu theo trục thời gian	69
8.2.5	Ba fold theo cửa sổ mở rộng	69
8.2.6	Thực nghiệm: đo phần chồng lấn nhãn ở ranh giới fold	71
8.3	Sinh đặc trưng	72
8.3.1	Đặc trưng thời gian, trễ và cửa sổ trượt	72
8.3.2	Solar geometry, bức xạ trời quang và chuẩn hoá theo trạm	76
8.3.3	Định nghĩa các đặc trưng dẫn xuất	81
8.3.4	Thực nghiệm: khử độ trễ cài sẵn bằng đặc trưng tại thời điểm mục tiêu	82
8.3.5	Chuẩn hoá mục tiêu theo vật lý	83
8.3.6	Kiểm chứng các tham số cố định	86
8.3.7	Chẩn đoán và chọn đặc trưng	88
8.3.8	Tổng hợp bộ đặc trưng đưa vào mô hình	94
8.4	Huấn luyện và chọn hàm mất mát	95
8.4.1	Chính sách trọng số cho dòng ngoại lai	95
8.4.2	Tinh chỉnh siêu tham số (<i>hyperparameter</i>)	96
8.4.3	Sáu cấu hình Optuna chọn được	96
8.4.4	Chọn hàm mất mát	97
8.4.5	Cấu hình tắt định	99
8.5	Đánh giá trên tập test niêm phong	99
8.5.1	Thước đo	99
8.5.2	Phạm vi chấm điểm	100
8.5.3	Kết quả	101
8.5.4	Chênh lệch giữa sai số trên test và trên kiểm định	101
8.5.5	Đối chứng với Prophet	102
8.5.6	Kiểm chứng độ trễ pha trên mô hình cuối	105
8.6	Giải thích mô hình bằng SHAP	106
8.6.1	Cơ sở phương pháp	106
8.6.2	Tầm quan trọng tổng thể	106
8.6.3	Giải thích ba dự báo cụ thể	109
8.6.4	Giới hạn diễn giải	111

8.7	Ứng dụng trực quan hoá kết quả	111
8.7.1	Trang giám sát chuỗi thời gian	111
8.7.2	Trang giải thích dự báo	112
8.7.3	Trang dự báo và phân tích giả định	113
8.8	Kết luận và hướng phát triển	114
8.8.1	Kết quả đạt được	114
8.8.2	Giới hạn	115
8.8.3	Hướng phát triển	115
9	Kết luận và Hướng phát triển	118
9.1	Kết luận Tổng quan	118
9.2	Khuyến nghị Chiến lược (Actionable Insights)	118
9.3	Hạn chế của Dự án	118
9.4	Hướng phát triển trong tương lai	118
9.4.1	Nâng cấp Hệ thống Phân tích Dự đoán (Predictive Analytics)	118
9.4.2	Tự động hóa và Đưa lên Đám mây (Cloud & Automation)	118
	Phụ lục A: Kế hoạch Thực hiện	119
	Phụ lục B: Cấu trúc Mã nguồn	120
	Phụ lục C: Vòng đời học máy — bản nháp gốc	121
	Tài liệu Tham khảo	122

Danh sách hình vẽ

3.1	Sơ đồ luồng thực thi quy trình xử lý dữ liệu tự động (Code Execution Pipeline).	25
3.2	Sơ đồ mô hình khái niệm (Conceptual Model) thể hiện mối quan hệ giữa các thực thể hệ thống điện mặt trời.	29
3.3	Sơ đồ mô hình logic (Logical Model) theo kiến trúc Galaxy Schema kết nối 2 bảng Fact và 4 bảng Dimension dùng chung.	30
3.4	Sơ đồ mô hình vật lý (Physical Model) triển khai thực tế trên PostgreSQL Supabase.	30
4.1	Sơ đồ kiến trúc mô hình phân lớp lai GMM-IF và rào chắn vật lý kết hợp quy trình 4 bước nạp cờ an toàn vào Supabase DWH.	43
8.1	(Trích xuất từ Notebook 05d_thuc_nghiem_rao_chan_vat_ly.ipynb) Hai nguyên lý chạy trên dữ liệu thật của dự án: trạm 27, dải bức xạ 201–350 W/m ² , 8.176 quan sát. Trái: GMM hai thành phần, điểm đo là các quan sát có mật độ tương đối $P_{GMM} < 0,02$. Phải: phân bố điểm cô lập của Isolation Forest (100 cây), phần cam là vùng bị cắt theo $\text{contamination} = 0,03$	55
8.2	(Trích xuất từ Notebook 05d_thuc_nghiem_rao_chan_vat_ly.ipynb) Quét hệ số nhân m của <code>safe_IQR</code> qua sáu mức. Trái: số dòng bị gán cờ. Phải: phần sản lượng bị ảnh hưởng, trục tung dừng ở 0,05%.	58
8.3	Vòng đời học máy	59
8.4	Chín bước của quy trình học máy	59
8.5	(Trích xuất từ Notebook 02_EDA.ipynb) Trái: histogram toàn bộ tập huấn luyện, trục tung thang loga. Giữa: chỉ ban ngày. Phải: boxplot đối chiếu hai phạm vi.	65
8.6	(Trích xuất từ Notebook 02_EDA.ipynb) Sản lượng theo bước 15 phút tại trạm 27, hai ngày dùng chung thang trục tung. Trái: ngày trời quang 02/10/2020, độ gấp 0,0031. Phải: ngày nhiều mây 23/12/2020, độ gấp 0,0926. Trục hoành là giờ trong ngày, cắt trong khoảng 5–21 giờ vì ngoài khoảng đó sản lượng bằng 0. Số đo của hai ngày kiểm chứng được bằng <code>srcs/05_machine_learning/kiem_chung_bao_cao_v4.py</code> , mục 11. . .	66
8.7	(Trích xuất từ Notebook 02_EDA.ipynb) Trái: ACF quét 288 bước = 72 giờ. Phải: PACF quét 96 bước = 24 giờ. Vạch đỏ chấm là mốc 96 bước.	67
8.8	(Trích xuất từ Notebook 02_EDA.ipynb) Ma trận tương quan Spearman trên 606.112 dòng đo thật ban ngày.	68

8.9	(Trích xuất từ Notebook <code>02_split_time_series.ipynb</code>) Cách chia dữ liệu theo trục thời gian: tập test niêm phong tách ra từ phần cuối, phần Phát triển còn lại chia thành ba fold theo cửa sổ mở rộng.	69
8.10	NOAA Solar Calculator của Global Monitoring Laboratory — công cụ chính thức tính vị trí Mặt Trời mà hàm <code>tinh_goc_mat_troi</code> của dự án dựa theo. . .	77
8.11	(Trích xuất từ Notebook <code>03_2_features_spatial.ipynb</code>) Bức xạ tại trạm 1, ngày 19/12/2020, từ 11 giờ đến 17 giờ. Trên: dữ liệu gốc theo giờ, mỗi giá trị lặp bốn lần nên đường đi thành bậc thang. Dưới: sau khi hạ độ hạt, đường biến thiên theo từng bước 15 phút.	79
8.12	Đoạn khai báo danh sách cấm trong quy trình chọn đặc trưng. Mỗi nhóm cột bị cấm đi kèm lý do ngay tại chỗ khai báo.	92
8.13	(Trích xuất từ Notebook <code>08_explainable_ai.ipynb</code>) Biểu đồ beeswarm. Mỗi điểm là một dòng dữ liệu; vị trí ngang là giá trị SHAP, màu là độ lớn của chính đặc trưng đó.	108
8.14	(Trích xuất từ Notebook <code>08_explainable_ai.ipynb</code>) Biểu đồ thác cho hai dự báo tương phản. Trên: trường hợp các đặc trưng cùng đẩy dự báo lên. Dưới: trường hợp cùng kéo xuống.	110
8.15	Trang 1 của ứng dụng, giám sát chuỗi thời gian theo trạm	112
8.16	Trang 2 của ứng dụng, giải thích dự báo bằng SHAP	113
8.17	Trang 3 của ứng dụng, dự báo và phân tích giả định	114
9.1	Vòng đời học máy, bản nháp gốc tiếng Anh	121

Danh sách bảng

2.1	Bảng phân tích nhu cầu thông tin của các bên liên quan (Stakeholder Matrix).	22
3.1	Bảng phân loại 6 mã lý do dị thường phục vụ công tác bảo trì O&M.	28
4.1	Bảng thống kê kiểm tra chất lượng dữ liệu ban đầu trong Staging	34
4.2	Danh mục các mã lý do ngoại lai được định nghĩa trong pipeline GMM-IF và ý nghĩa chẩn đoán bảo trì.	44
8.1	Sai số RMSE trích từ Bảng 4 của Roy, Pyltsov và Hu, chỉ số càng nhỏ càng tốt	53
8.2	Số ứng viên của từng cơ chế và phần còn lại sau khi bắt cả hai cùng đồng ý. Ngưỡng dùng cho GMM là $P_{GMM} < 0,02$; Isolation Forest chạy với <code>contamination = 0,03</code> . Dựng lại trên máy bằng <code>07_local_gmm_if_audit.py</code> ; số liệu ghi ở <code>07_local_gmm_if_summary.json</code>	56
8.3	Số ứng viên của từng cơ chế và phần còn lại sau khi bắt cả hai cùng đồng ý	56
8.4	Đối chiếu số cờ do notebook dựng lại với số cờ tầng ETL đã ghi. Đọc từ ô kết quả của notebook <code>05d_thuc_nghiem_rao_chan_vat_ly.ipynb</code>	57
8.5	Đối chiếu số cờ do notebook dựng lại với số cờ tầng ETL đã ghi	57
8.6	Số dòng và sản lượng bị loại khi đổi hệ số nhân của <code>safe_IQR</code> . Tỷ lệ tính trên tổng 9,31 triệu kWh. Đọc từ tệp kết quả <code>05d_rao_chan_vat_ly/quet_he_so_safe_iqr.csv</code>	58
8.7	Số dòng và sản lượng bị loại khi đổi hệ số nhân của <code>safe_IQR</code>	58
8.8	Ánh xạ giữa bước trong quy trình và notebook thực hiện	60
8.9	Thống kê mô tả sản lượng theo ba phạm vi. Đọc từ ô kết quả của notebook <code>02_EDA.ipynb</code>	64
8.10	Thống kê mô tả sản lượng theo ba phạm vi	64
8.11	Tự tương quan của chuỗi sản lượng tại các mốc trễ đáng chú ý, trạm 27, 51.652 bước liên tục. Đọc từ ô kết quả của notebook <code>02_EDA.ipynb</code>	66
8.12	Tự tương quan của chuỗi sản lượng tại các mốc trễ đáng chú ý, trạm 27, 42.240 bước liên tục	66
8.13	Tương quan với sản lượng, tính trên phạm vi đo thật ban ngày, kèm cột đối chiếu khi gộp cả ban đêm. Đọc từ ô kết quả của notebook <code>02_EDA.ipynb</code>	67
8.14	Tương quan với sản lượng, tính trên phạm vi đo thật ban ngày, kèm cột đối chiếu khi gộp cả ban	67

8.15	Ranh giới thời gian, kích thước và số trạm của ba fold, đọc từ các tệp <code>fold*_train_selected.parquet</code> và <code>fold*_val_selected.parquet</code> .	70
8.16	Ranh giới thời gian, kích thước và số trạm của ba fold, đọc từ các tệp	70
8.17	Số dòng huấn luyện có nhãn rơi sang vùng kiểm định, tính trên từng fold và từng tầm dự báo. Đọc từ ô kết quả của notebook <code>05b_thuc_nghiem_tham_so_hardcode.ipynb</code> , Thí nghiệm 9.	71
8.18	Số dòng huấn luyện có nhãn rơi sang vùng kiểm định, tính trên từng fold và từng tầm dự báo	71
8.19	Ba nhóm đặc trưng sinh tại notebook <code>03_1_features_time.ipynb</code> . Cột cuối ghi tham số thực tế khai báo trong notebook.	72
8.20	Ba nhóm đặc trưng sinh tại notebook <code>03_1_features_time.ipynb</code>	72
8.21	Ba mốc trễ đã được thử và quyết định tương ứng, ghi tại ô khai báo LAGS của notebook <code>03_1_features_time.ipynb</code>	74
8.22	Ba mốc trễ đã được thử và quyết định tương ứng, ghi tại ô khai báo LAGS của notebook	74
8.23	Mô hình nháp dùng ở cổng lệch pha so với mô hình cuối. Đọc từ ô cấu hình cổng lệch pha trong notebook <code>06_1_train_mae.ipynb</code>	75
8.24	Ba chi tiết cài đặt của bước solar geometry	77
8.25	Hệ số hiệu chỉnh trời quang <code>cs_factor</code> theo từng fold. Đọc từ ô kết quả của notebook <code>03_2_features_spatial.ipynb</code>	78
8.26	Hệ số hiệu chỉnh trời quang <code>cs_factor</code> theo từng fold	78
8.27	Quy mô trạm tính trên tập huấn luyện, tám trạm lớn nhất. Đọc từ ô kết quả của notebook <code>03_2_features_spatial.ipynb</code>	80
8.28	Quy mô trạm tính trên tập huấn luyện, tám trạm lớn nhất	80
8.29	Năm đặc trưng tương tác, tỷ lệ khuyết trên tập huấn luyện và tương quan Pearson với mục tiêu tính trên 763.740 dòng ban ngày. Đọc từ ô kết quả của notebook <code>03_3_features_aggregate.ipynb</code>	80
8.30	Năm đặc trưng tương tác, tỷ lệ khuyết trên tập huấn luyện và tương quan Pearson với mục tiêu	80
8.31	Công thức các đặc trưng dẫn xuất. Đọc từ mã nguồn notebook <code>03_2_features_spatial.ipynb</code> và <code>03_3_features_aggregate.ipynb</code>	82
8.32	Công thức các đặc trưng dẫn xuất	82
8.33	So sánh dùng đặc trưng tất định tại T với tại $T+h$, đo bằng MAE của đường bao $\text{site_scale} \times \max(\sin h, \varepsilon)$ so với sản lượng thật tại $T+15$ phút, trên 999.010 dòng ban ngày của tập Phát triển. Kiểm chứng bằng <code>srcs/05_machine_learning/kiem_chung_bao_cao_v4.py</code> , mục 10. . .	83
8.34	So sánh dùng đặc trưng tất định tại T với tại $T+h$, đo bằng MAE của đường bao	83
8.35	Quét mức phân vị dùng làm cận cắt, chạy trên tập kiểm định . Đọc từ tệp kết quả <code>05_selected/quet_muc_phan_vi_nguong_cat.csv</code>	85

8.36	Quét mức phân vị dùng làm cận cắt, chạy trên tập kiểm định	85
8.37	Tỷ lệ nhãn bị ngưỡng 1,3764 cắt, tách theo giờ trong ngày, tính trên tập huấn luyện. Kiểm chứng bằng <code>srcs/05_machine_learning/kiem_chung_bao_cao_v4.py</code> , mục 1.	86
8.38	Tỷ lệ nhãn bị ngưỡng 1,3764 cắt, tách theo giờ trong ngày, tính trên tập huấn luyện	86
8.39	Quét bốn tham số cố định, chấm trên 779.099 dòng của tập kiểm định. Đọc từ tệp kết quả <code>05b_thuc_nghiem_tham_so/thuc_nghiem_tham_so_hardcode.csv</code> . .	87
8.40	Quét bốn tham số cố định, chấm trên 779.099 dòng của tập kiểm định	87
8.41	Số điểm bị ngưỡng CLIP_CSI cắt. Đọc từ tệp kết quả <code>05b_thuc_nghiem_tham_so/thuc_nghiem_clip_csi.csv</code>	88
8.42	Số điểm bị ngưỡng CLIP_CSI cắt	88
8.43	Phân bố nhãn chẩn đoán trên 86 đặc trưng số. Đọc từ ô kết quả của notebook <code>04_vif_diagnostics.ipynb</code>	89
8.44	Tám cột trùng lặp gần hoàn hảo và cột đại diện được giữ lại. Đọc từ ô kết quả của notebook <code>04_vif_diagnostics.ipynb</code>	89
8.45	Tám đặc trưng có hệ số phóng đại phương sai cao nhất. Giá trị 9999 là mức chặn trên mà notebook đặt cho trường hợp cộng tuyến gần hoàn hảo. Đọc từ ô kết quả của notebook <code>04_vif_diagnostics.ipynb</code>	90
8.46	Bảy đặc trưng dẫn đầu theo điểm quan trọng biến của hồi quy bình phương tối thiểu riêng phần, đặt cạnh hệ số phóng đại phương sai của chính chúng. Đọc từ ô kết quả của notebook <code>04_vif_diagnostics.ipynb</code>	90
8.47	Mười đặc trưng có điểm thông tin tương hỗ cao nhất. Đọc từ ô kết quả của notebook <code>05_select_features.ipynb</code>	93
8.48	Bốn mươi đặc trưng được chọn, xếp theo nhóm. Đọc từ <code>05_selected/selected_features.json</code>	95
8.49	Bốn mươi đặc trưng được chọn, xếp theo nhóm	95
8.50	Miền tìm kiếm siêu tham số khai báo cho Optuna. Đọc từ hàm <code>tham_so_co_ban</code> trong notebook <code>06_1_train_mae.ipynb</code>	96
8.51	Miền tìm kiếm siêu tham số (<i>hyperparameter</i>) khai báo cho Optuna	96
8.52	Siêu tham số tốt nhất do Optuna chọn, theo từng hàm mất mát và tầm dự báo. Cả sáu cấu hình dùng chung <code>random_state = 42</code> , <code>deterministic = true</code> và <code>max_bin = 127</code> trên CPU. Đọc từ khoá <code>best_params</code> trong tệp kết quả của mỗi notebook huấn luyện.	97
8.53	Siêu tham số tốt nhất do Optuna chọn, theo từng hàm mất mát và tầm dự báo .	97

8.54 Sai số trên tập kiểm định, phạm vi đo thật ban ngày. Trong mỗi tầm, cả ba hàm được chấm trên đúng cùng số quan sát. Đọc từ <code>metrics_val.json</code> của sáu cấu hình dưới <code>06_train/</code>	98
8.55 Sai số trên tập kiểm định, phạm vi đo thật ban ngày	98
8.56 Sai số WAPE trên tập test niêm phong theo ba phạm vi. Đọc từ ô kết quả của notebook <code>07_final_test.ipynb</code> và tệp <code>metrics_overall.json</code> của từng tầm.	101
8.57 Sai số WAPE trên tập test niêm phong theo ba phạm vi	101
8.58 Cùng mô hình, ba phạm vi đánh giá. Đọc từ <code>08_baseline_prophet_test/optuna_vs_current_wape.csv</code>	101
8.59 Cùng mô hình, ba phạm vi đánh giá	101
8.60 Đối chứng với Prophet trên cùng tập dòng. Đọc từ <code>08_baseline_prophet_test/prophet_bang_bao_cao.csv</code> và <code>prophet_test_summary.json</code>	104
8.61 Đối chứng với Prophet trên cùng tập dòng	104
8.62 Độ lệch đỉnh theo vị trí của đỉnh thực tế trong khối giờ. Đọc từ tệp kết quả <code>09_kiem_chung_tre_pha/lech_theo_vi_tri_trong_gio_h1.csv</code> . . .	105
8.63 Độ lệch đỉnh theo vị trí của đỉnh thực tế trong khối giờ	105
8.64 Mười đặc trưng có tầm quan trọng tổng thể lớn nhất, đo bằng trung bình trị tuyệt đối giá trị SHAP. Đọc từ <code>08_explain/shap_importance.csv</code>	107
8.65 Mười đặc trưng có tầm quan trọng tổng thể lớn nhất, đo bằng trung bình trị tuyệt đối giá trị	107
8.66 Ba dự báo được mô xẻ. Đọc từ <code>08_explain/local_shap_cases.csv</code> . . .	109
8.67 Ba dự báo được mô xẻ bằng SHAP	109

Danh mục Từ viết tắt

Ký hiệu/Từ viết tắt	Ý nghĩa đầy đủ
API	Application Programming Interface (Giao diện lập trình ứng dụng)
ARIMA	AutoRegressive Integrated Moving Average
AWS	Amazon Web Services
BI	Business Intelligence (Phân tích thông minh doanh nghiệp)
CF	Capacity Factor (Hệ số công suất)
CSDL	Cơ sở dữ liệu
CT	Current Transformer (Cảm biến dòng điện)
DWH	Data Warehouse (Kho dữ liệu)
EDA	Exploratory Data Analysis (Phân tích khám phá dữ liệu)
ETL	Extract, Transform, Load (Trích xuất, Biến đổi, Nạp)
FK	Foreign Key (Khóa ngoại)
GCP	Google Cloud Platform
IoT	Internet of Things (Internet vạn vật)
IQR	Interquartile Range (Khoảng tứ phân vị)
kWp	Kilowatt-peak (Công suất đỉnh cực đại)
LSTM	Long Short-Term Memory
PK	Primary Key (Khóa chính)
PR	Performance Ratio (Hệ số hiệu suất)
PV	Photovoltaic (Quang điện - Năng lượng mặt trời)
UI/UX	User Interface / User Experience (Giao diện / Trải nghiệm người dùng)
WMO	World Meteorological Organization (Tổ chức Khí tượng Thế giới)
XGBoost	Extreme Gradient Boosting

Tổng quan Đề tài và Bài toán Nghiên cứu

1.1 Bối cảnh thực tế và lý do chọn đề tài

Năng lượng mặt trời đang ngày càng đóng vai trò quan trọng trong cơ cấu năng lượng tái tạo toàn cầu. Theo Cơ quan Năng lượng Quốc tế (IEA), công suất lắp đặt điện mặt trời trên toàn thế giới đã vượt mốc 1.600 GW vào cuối năm 2023, với tốc độ tăng trưởng trung bình 25%/năm trong thập kỷ qua. Tại Việt Nam, chính sách khuyến khích phát triển điện mặt trời áp mái và điện mặt trời tập trung đã đưa tổng công suất lắp đặt lên hơn 16.500 MW. Tuy nhiên, hiệu suất thực tế của các hệ thống quang điện (PV) thường sai lệch đáng kể so với giá trị thiết kế do ảnh hưởng của nhiều yếu tố như: điều kiện thời tiết biến đổi, suy giảm chất lượng tấm pin, bụi bẩn, bóng che và lỗi thiết bị.

Bài toán phân tích hiệu suất và phát hiện sớm các bất thường trong vận hành là then chốt giúp tối ưu hoá hiệu quả đầu tư và nâng cao độ tin cậy của lưới điện. Lý do nhóm chọn đề tài này bao gồm:

- **Tính thực tiễn:** Dự báo sản lượng và phát hiện bất thường có ứng dụng trực tiếp cho các doanh nghiệp vận hành nhà máy điện mặt trời.
- **Tính liên ngành:** Kết hợp phân tích dữ liệu, thống kê, học máy và kiến trúc kho dữ liệu trong một đề tài thống nhất.
- **Nguồn dữ liệu mở:** Dữ liệu từ Open-Meteo API miễn phí, chất lượng cao và phủ rộng toàn cầu.
- **So sánh đa vùng:** Phân tích đồng thời dữ liệu từ nhiều khu vực tại Úc để đánh giá tổng quát về hiệu suất PV.

1.2 Bài toán kinh doanh và các khó khăn cần giải quyết

Trong vận hành thực tế các trạm điện mặt trời, ban quản lý thường đối mặt với các khó khăn lớn:

- **Tác động thời tiết bất định:** Sự thay đổi của mây che phủ, bức xạ và nhiệt độ môi trường khiến sản lượng điện biến động liên tục, gây khó khăn cho việc điều phối lưới điện.
- **Suy hao và hỏng hóc thiết bị:** Các tấm pin bị bám bụi, inverter bị lỗi phần sụn hoặc quá nhiệt làm suy giảm đáng kể hiệu suất phát điện mà không được phát hiện kịp thời.

- **Sai lệch số liệu giám sát:** Cảm biến đo bức xạ hoặc cảm biến CT đo dòng điện bị nhiễu xung điện đột ngột hoặc lệch pha tần suất dữ liệu (Granularity Mismatch) giữa dữ liệu sản lượng (15 phút) và dữ liệu thời tiết (1 giờ) khiến phân tích sai lệch.

Hệ quả của việc không giải quyết các vấn đề trên là doanh nghiệp ra quyết định chậm trễ, tồn thất tài chính lớn do mất sản lượng, và dữ liệu thu thập bị bẩn dẫn đến các mô hình dự báo không chính xác.

1.3 Mục tiêu dự án và Kết quả dự kiến

Dự án tốt nghiệp đặt ra các mục tiêu cốt lõi sau:

1. Thiết kế và triển khai kho dữ liệu (*Data Warehouse*) tích hợp đồng bộ dữ liệu sản lượng và thời tiết theo mô hình Galaxy Schema (Fact Constellation) kết hợp phân nhánh Data Marts chuyên biệt.
2. Xây dựng pipeline dữ liệu tự động làm sạch (xử lý khuyết thiếu, lọc nhiễu ban đêm, phát hiện bất thường cảm biến).
3. Thực hiện phân tích khám phá chuyên sâu (EDA) để rút ra các insight vận hành quan trọng như hiện tượng suy giảm hiệu suất do nhiệt độ và độ nhiễu ban đêm.
4. Xây dựng hệ thống dữ liệu đáp ứng đồng thời hiệu năng truy vấn báo cáo (OLAP) và hiệu năng huấn luyện/dự báo học máy (MLOps) mà không làm quá tải tài nguyên Cloud.
5. Huấn luyện các mô hình dự báo sản lượng Baseline (ARIMA, Prophet) và so sánh hiệu năng.

Kết quả dự kiến (Sneak Peek): Một hệ thống Dashboard Tableau trực quan hóa mượt mà cho phép các nhà quản lý theo dõi toàn diện hiệu suất vận hành của 42 trạm tại Úc, tự động cảnh báo lỗi cảm biến và hiển thị dự báo sản lượng cho các chu kỳ tiếp theo với độ tin cậy cao.

1.4 Đối tượng và phạm vi nghiên cứu

- **Đối tượng nghiên cứu:** Hiệu suất phát điện của hệ thống quang điện (PV) và các yếu tố khí tượng viễn thám (bức xạ sóng ngắn, nhiệt độ, độ phủ mây, lượng mưa).
- **Phạm vi không gian:** 42 trạm điện mặt trời tại Úc.
- **Phạm vi thời gian:** Dữ liệu lịch sử từ 01/01/2020 đến 30/04/2022.

1.5 Bố cục báo cáo

Báo cáo dự án tốt nghiệp được cấu trúc thành 7 chương chính như sau:

- **Chương 1:** Tổng quan Đề tài và Bài toán Nghiên cứu.
- **Chương 2:** Cơ sở Lý thuyết (các mô hình dự báo, phát hiện outlier và DWH).
- **Chương 3:** Thu thập Dữ liệu và Thiết kế Kho dữ liệu.
- **Chương 4:** Quy trình ETL, Làm sạch và Biến đổi Dữ liệu.
- **Chương 5:** Phân tích Khám phá Dữ liệu (EDA) và Trực quan hóa.
- **Chương 6:** Mô hình hóa và Dự báo Sản lượng Baseline.
- **Chương 7:** Đánh giá Dự án, Đề xuất và Theo dõi Vận hành.

Cơ sở Lý thuyết và Kiến trúc Hệ thống

2.1 Cơ sở Lý thuyết

2.1.1 Khái quát về Phân tích Dữ liệu trong Ngành Năng lượng Tái tạo

Phân tích dữ liệu trong ngành năng lượng mặt trời là quá trình thu thập, làm sạch, mô hình hóa và khai phá thông tin chuyên sâu từ khối lượng lớn chuỗi thời gian sản lượng điện và dữ liệu khí tượng. Trong bối cảnh vận hành các trạm điện mặt trời hiện đại, dữ liệu đóng vai trò là tài sản chiến lược giúp tối ưu hóa hiệu suất phát điện, giảm thiểu chi phí bảo trì và bảo vệ dòng tiền đầu tư.

Theo chuẩn mực phân tích dữ liệu doanh nghiệp, các cấp độ phân tích trong đề tài được phân chia rõ ràng:

- **Phân tích Mô tả (Phân tích Mô tả):** Trả lời câu hỏi “*Chuyện gì đã xảy ra?*” thông qua việc tổng hợp sản lượng thực tế, tính toán hệ số hiệu suất (PR), hệ số công suất (CF) và năng suất riêng (Specific Yield) của 42 trạm phát qua từng tháng và từng năm.
- **Phân tích Chẩn đoán (Phân tích Chẩn đoán):** Trả lời câu hỏi “*Tại sao hiệu suất trạm lại suy giảm?*” bằng cách bóc tách mối tương quan giữa sản lượng và các yếu tố khí tượng (nhiệt độ quá cao, mây che phủ) hoặc lỗi phần cứng (Inverter ngắt mạch, hỏng diode, trôi cảm biến đo ban đêm).
- **Phân tích Dự báo (Phân tích Dự báo):** Trả lời câu hỏi “*Sản lượng điện trong chu kỳ tiếp theo là bao nhiêu?*” để hỗ trợ đơn vị vận hành lập kế hoạch điều phối phụ tải và huy động nguồn điện dự phòng.
- **Phân tích Đề xuất (Phân tích Đề xuất):** Đưa ra các khuyến nghị bảo trì cụ thể (vệ sinh bề mặt pin, thay thế biến tần quá nhiệt, hiệu chuẩn cảm biến CT).

2.1.2 Các Chỉ số Hiệu năng Cốt lõi (KPIs) và Bài toán Tổn thất Vận hành

Trong quản trị vận hành trạm quang điện, tổng sản lượng (kWh) chỉ phản ánh quy mô phát điện thô, trong khi các chỉ số hiệu chuẩn hóa mới là thước đo chính xác về chất lượng vận hành:

1. **Hệ số Hiệu suất (Performance Ratio – PR):** Tỷ số giữa sản lượng điện thực tế tạo ra (E_{actual})

và sản lượng lý thuyết trong điều kiện bức xạ thu nhận được:

$$PR = \frac{E_{\text{actual}}}{P_{\text{stc}} \cdot \left(\frac{GHI}{1000 \text{ W/m}^2}\right) \cdot \Delta t} \times 100\% \quad (2.1)$$

Chỉ số PR tiêu chuẩn của hệ thống tốt thường đạt từ 75% đến 85%. Khi $PR < 70\%$, hệ thống đang gặp tổn thất vận hành nghiêm trọng.

2. **Hệ số Công suất (Capacity Factor – CF):** Tỷ lệ giữa năng lượng thực tế thu được trong một khoảng thời gian so với năng lượng tối đa nếu trạm phát liên tục ở công suất danh định 24/24h:

$$CF = \frac{\sum E_{\text{actual}}}{P_{\text{stc}} \cdot 8760 \text{ h}} \times 100\% \quad (2.2)$$

3. **Năng suất Riêng (Specific Yield – kWh/kWp):** Lượng điện năng tạo ra trên mỗi kWp công suất lắp đặt, là thước đo công bằng nhất để so sánh hiệu quả giữa các trạm có quy mô công suất khác nhau.
4. **Hệ số Tổn thất Nhiệt độ (Tổn thất Suy hao do Nhiệt độ):** Khi nhiệt độ môi trường vượt quá 25°C (nhiệt độ cell pin đạt $50 - 65^\circ\text{C}$), công suất phát bị suy giảm tuyến tính theo hệ số nhiệt độ $\gamma \approx -0,35\%/^\circ\text{C}$ đến $-0,50\%/^\circ\text{C}$:

$$P_{\text{loss, temp}} = P_{\text{stc}} \cdot |\gamma| \cdot (T_{\text{cell}} - 25^\circ\text{C}) \quad (2.3)$$

5. **Tổn thất Biến tần (Tổn thất Biến tần) theo IEA-PVPS Task 13 [?]:** Biến tần có thời gian trung bình giữa các sự cố (MTBF) ngắn hơn tám pin 300 – 500 lần, gây ra 36% tổng tổn thất phần cứng của hệ thống.

2.1.3 Hệ thống Kho Dữ liệu (Data Warehouse) và Quy trình ETL

Kho dữ liệu (Data Warehouse – DWH) là hệ thống cơ sở dữ liệu được thiết kế chuyên biệt để hỗ trợ các hoạt động phân tích thông minh (BI) và báo cáo quản trị (OLAP), phân tách hoàn toàn khỏi các hệ thống xử lý giao dịch vận hành (OLTP).

Để chuyển hóa dữ liệu thô thành thông tin quản trị, quy trình ETL được thực thi theo 3 giai đoạn:

- **Trích xuất Dữ liệu (Extract):** Thu thập dữ liệu chuỗi thời gian sản lượng từ tệp tin cục bộ và gọi API khí tượng Open-Meteo.
- **Transform (Biến đổi & Làm sạch):** Chuẩn hóa kiểu dữ liệu, xử lý giá trị khuyết thiếu (Imputation), xử lý đứt gãy thời gian (điểm gián đoạn thời gian), gắn nhãn ngoại lai bằng rào chắn vật lý và trích xuất đặc trưng nghiệp vụ.

- **Nạp Dữ liệu vào Kho (Load):** Nạp dữ liệu có cấu trúc vào kho lưu trữ tập trung Supabase DWH theo mô hình đa chiều.

2.1.4 Mô hình Dữ liệu Đa chiều và Lược đồ Thiên hà (Galaxy Schema)

Mô hình đa chiều do Ralph Kimball [?] đề xuất phân tách dữ liệu thành:

- **Bảng sự kiện (Fact Table):** Chứa các chỉ số đo lường định lượng theo chuỗi thời gian như `fact_solar_energy_gen` (sản lượng điện 15 phút) và `fact_weather` (thông số khí tượng 1 giờ).
- **Bảng chiều (Dimension Table):** Chứa các thuộc tính ngữ cảnh mô tả như `dim_solar_plant` (trạm phát), `dim_date` (ngày), `dim_time` (giờ), `dim_weather_type` (mã thời tiết).

Trong dự án này, do dữ liệu sản lượng và dữ liệu thời tiết có tần suất ghi nhận lệch nhau (15 phút vs 1 giờ), nhóm sử dụng **Lược đồ Thiên hà (Mô hình Lược đồ Thiên hà – Galaxy Schema)**. Hai bảng Fact độc lập liên kết chặt chẽ với nhau thông qua 4 bảng Dimension dùng chung (chiều dữ liệu dùng chung), đảm bảo không làm phình to dữ liệu và tối ưu hóa hiệu năng truy vấn liên thông (Drill-through).

2.1.5 Phương pháp Phát hiện Dị thường và Lọc Nhiễu Nghiệp vụ

Để đảm bảo nguyên tắc “Dữ liệu sạch = Insight đúng”, quy trình xử lý dữ liệu tích hợp các phương pháp phát hiện dị thường nhằm phục vụ công tác làm sạch:

- **Khoảng Tứ phân vị IQR (Tukey 1977 [?]):** Xác định ngưỡng phân vị $IQR = Q_3 - Q_1$ để loại trừ các giá trị đo đột biến cục bộ.
- **Rào chắn Vật lý (Physical Boundaries):** Thiết lập 5 giới hạn vật lý năng lượng mặt trời (cắt trần công suất danh định, loại bỏ phát điện ban đêm $GHI = 0$, phát hiện năng suất mất điện).
- **Phân lớp Lai GMM-IF (Li et al., 2025 [4]):** Đóng vai trò như một bộ lọc thông minh trong tầng Transform, phân đoạn dữ liệu thành các vùng lá thời tiết đồng nhất để nhận diện chính xác các điểm dữ liệu dị thường do lỗi thiết bị và gán 6 mã lý do kỹ thuật phục vụ bảo trì.

2.1.6 Trực quan hóa Dữ liệu trong Business Intelligence (BI)

Trực quan hóa dữ liệu không đơn thuần là vẽ biểu đồ làm đẹp, mà là công cụ khám phá tri thức kinh doanh (Business Storytelling). Các nguyên tắc thiết kế được tuân thủ nghiêm ngặt:

- **Quy luật Gestalt:** Sắp xếp các chỉ số quan trọng (KPI Cards) ở vị trí trên cùng bên trái theo hướng đọc tự nhiên của mắt.
- **Màu sắc Ngữ nghĩa (Semantic Colors):** Màu Xanh Navy (#4E79A7) cho Tổng sản lượng, Màu Xanh Lá (#59A14F) cho Hiệu suất đạt chuẩn, Màu Cam (#F28E2B) cho Cảnh báo tổn thất nhiệt độ, và Màu Đỏ (#E15759) cho Sự cố dừng máy/Dị thường.
- **Tương tác Đào sâu (Interactive Actions):** Thiết lập bộ lọc chéo (Cross-filtering) và Highlight Actions giúp các nhà quản lý nhanh chóng đào sâu từ tổng quan vùng đến từng trạm phát cụ thể.

2.2 Phân tích Yêu cầu Nghiệp vụ (Business Requirements)

2.2.1 Phân tích Các Bên Liên quan (Stakeholders)

Hệ thống phân tích dữ liệu được thiết kế để giải quyết bài toán thông tin cho 4 nhóm đối tượng chính:

Nhóm Đối tượng	Vai trò Nghiệp vụ	Nhu cầu Thông tin Chính
Ban Giám đốc (C-Level)	Quản trị chiến lược tài sản và hiệu quả đầu tư toàn diện.	Tổng sản lượng phát điện, tăng trưởng theo năm (YoY), tỷ lệ tổn thất tài chính toàn hệ thống.
Quản lý O&M (O&M Manager)	Tối ưu hóa hiệu suất vận hành và giám sát kỹ thuật các trạm.	Hệ số PR, CF, so sánh Specific Yield giữa các trạm, xác định các trạm có hiệu suất suy giảm.
Kỹ sư Hiện trường (Field Engineer)	Khắc phục sự cố và bảo dưỡng thiết bị trực tiếp tại trạm pin.	Vị trí trạm có dị thường, mã lý do sự cố kỹ thuật (outlier_reason), thời điểm xảy ra lỗi.
Chuyên viên Phân tích (Energy Analyst)	Đánh giá chuyên sâu và lập báo cáo phân tích năng lượng.	Dữ liệu sạch trên DWH, phân tích tương quan bức xạ – nhiệt độ, báo cáo tổn thất chi tiết.

Bảng 2.1: Bảng phân tích nhu cầu thông tin của các bên liên quan (Stakeholder Matrix).

2.2.2 Hệ thống Chỉ số Đo lường (KPI Framework)

Dựa trên yêu cầu nghiệp vụ, dự án xây dựng bộ khung đo lường gồm 3 nhóm chỉ số cốt lõi:

1. Nhóm KPI Vận hành Kỹ thuật (Operational KPIs):

- Total Energy Generation = $\sum \text{energy_generated_kwh}$ (Tổng sản lượng phát điện).
- Average PR (%) = Trung bình hệ số hiệu suất quang điện.
- Capacity Factor (%) = Hệ số huy động công suất trạm.
- Specific Yield = $\frac{\text{Sản lượng (kWh)}}{\text{Công suất danh định (kWp)}}$.

2. Nhóm KPI Tồn thất và Tài chính (Loss & Financial KPIs):

- Thermal Loss (kWh) =
Sản lượng thất thoát do nhiệt độ tế bào quang điện vượt quá 25°C.
- Inverter Clipping Loss (kWh) =
Sản lượng bị cắt giảm do công suất DC vượt quá ngưỡng biến tần.
- Estimated Financial Loss (\$) = Tồn thất sản lượng $\times$ Đơn giá điện FiT.

3. Nhóm KPI Cảnh báo Dị thường và Bảo trì (Anomaly & Maintenance KPIs):

- Anomaly Rate (%) = $\frac{\text{Số bản ghi dị thường}}{\text{Tổng số bản ghi}} \times 100\%$ (Mục tiêu phát hiện: 1,22%).
- Inverter Zero Output Count = Số sự cố biến tần mất phát giữa trưa nắng gắt ($GHI \geq 700 \text{ W/m}^2$).
- Dòng rò ban đêm Records =
Số bản ghi trôi điểm 0 ban đêm cần hiệu chuẩn cảm biến.

2.3 Kiến trúc Hệ thống Đề xuất (6-Layer Data Pipeline)

Nhằm đảm bảo tính toàn vẹn, độ tin cậy và khả năng mở rộng của dữ liệu, dự án đề xuất kiến trúc xử lý dữ liệu 6 lớp (6-Layer Data Pipeline):

Layer 1 – Data Source (Nguồn dữ liệu): Tiếp nhận 2.731.946 dòng dữ liệu sản lượng PV 15 phút từ UNISOLAR và chuỗi dữ liệu khí tượng 1 giờ từ Open-Meteo API.

Layer 2 – Exploration & Audit (Khám phá & Kiểm định chất lượng): Quét toàn diện dữ liệu thô, phát hiện 561 điểm đứt gãy thời gian (điểm gián đoạn thời gian) và kiểm tra phân phối dữ liệu.

Layer 3 – Transformation & Cleansing (Biến đổi & Làm sạch dữ liệu): Lớp xử lý lỗi bằng Python: Resampling lưới 15 phút, nội suy dữ liệu khuyết thiếu, áp dụng rào chắn vật lý và mô hình phân lớp GMM-IF để lọc sạch nhiễu cảm biến, gán 6 mã lý do sự cố.

Layer 4 – Data Modeling (Mô hình hóa Kho dữ liệu): Tổ chức cơ sở dữ liệu trên Supabase PostgreSQL theo Lược đồ Thiên hà (Galaxy Schema) gồm 2 bảng Fact và 4 bảng Dimension.

Layer 5 – Aggregation & Data Marts (Tổng hợp & Siêu thị dữ liệu): Tính toán trước (Pre-calculate) các bảng tổng hợp nghiệp vụ theo ngày, tháng, trạm phát để tối ưu hóa truy vấn cho BI.

Layer 6 – Visualization (Trực quan hóa Quản trị): Xây dựng hệ thống 3 Dashboard tương tác trên nền tảng Tableau Desktop phục vụ các quyết định vận hành.

2.4 Từ điển Dữ liệu Nghiệp vụ (Data Dictionary)


Dữ liệu sau khi làm sạch và mô hình hóa được phân chia thành 5 nhóm logic:

- **Nhóm 1 – Dữ liệu Định danh và Vận hành Trạm (dim_solar_plant):** Mã trạm (sitekey), Tên trạm, Khuôn viên (campus_name), Công suất danh định (capacity_kw), Model biến tần, Tọa độ địa lý.
- **Nhóm 2 – Dữ liệu Thời gian Lịch biểu (dim_date, dim_time):** Ngày, Tháng, Năm, Quý, Thứ trong tuần, Cờ ngày nghỉ (is_holiday), Giờ, Phút, Cờ ban ngày (is_day).
- **Nhóm 3 – Dữ liệu Khí tượng Viễn thám (fact_weather):** Bức xạ sóng ngắn (GHI), Bức xạ trực xạ (DNI), Bức xạ tán xạ (DHI), Nhiệt độ không khí 2m, Tốc độ gió, Độ che phủ mây, Thời lượng nắng.
- **Nhóm 4 – Dữ liệu Sản lượng & Đo lường Hiệu năng (fact_solar_energy_gen):** Sản lượng điện phát ra (energy_generated_kwh), Tỷ lệ hiệu suất (PR), Năng suất riêng (Specific_Yield).
- **Nhóm 5 – Dữ liệu Chẩn đoán Dị thường (gmm_if_outlier):** Cờ dị thường (gmm_if_outlier_flag), Mã lý do chẩn đoán kỹ thuật (gmm_if_outlier_reason).

Thu thập, Tiền xử lý và Mô hình hóa Kho Dữ liệu

3.1 Tổng quan Kiến trúc Pipeline Xử lý Dữ liệu

Để đảm bảo tính tự động hóa, độ chính xác cao và khả năng tái sử dụng khi có dữ liệu phát sinh mới từ các trạm pin, dự án không xử lý dữ liệu thủ công trên Excel mà thiết kế một quy trình xử lý dữ liệu tự động hoàn chỉnh bằng ngôn ngữ Python. Toàn bộ luồng thực thi từ khâu tải dữ liệu, tiền xử lý, điền khuyết chuỗi thời gian, lọc dữ liệu ngoại lai, nạp vào kho dữ liệu Supabase DWH đến việc xây dựng các siêu thị dữ liệu (Data Marts) được điều phối thông suốt thông qua kiến trúc mô-đun độc lập (Hình 3.1).



Hình 3.1: Sơ đồ luồng thực thi quy trình xử lý dữ liệu tự động (Code Execution Pipeline).

Toàn bộ quy trình được tổ chức thành các mô-đun chức năng độc lập:

- 1. config.py:** Khởi tạo môi trường, cấu hình thông tin kết nối CSDL Supabase, thiết lập hệ thống ghi vết nhật ký (ghi vết nhật ký hệ thống) và định nghĩa các tham số nghiệp vụ (ngưỡng cắt trần công suất danh định P_{stc} , ngưỡng bức xạ ban đêm $GHI \leq 25 \text{ W/m}^2$, đơn giá điện FiT).

2. **eda.py**: Quét toàn diện tập dữ liệu thô (2.731.946 dòng), kiểm tra dữ liệu thiếu, trùng lặp và phát hiện các điểm đứt gãy thời gian.
3. **cleaner.py**: Thực hiện làm sạch dữ liệu, xử lý đứt gãy thời gian bằng Resampling 15 phút, áp dụng 5 rào chắn vật lý và mô hình phân lớp lai GMM-IF để lọc sạch nhiễu cảm biến, gán 6 mã lý do kỹ thuật và trích xuất đặc trưng nghiệp vụ (trích xuất đặc trưng nghiệp vụ).
4. **splitter.py**: Tách bảng phẳng khổng lồ thành mô hình Lược đồ Thiên hà (Galaxy Schema) gồm 2 bảng Fact và 4 bảng Dimension.
5. **aggregate.py**: Tạo các bảng tổng hợp (Siêu thị dữ liệu chuyên đề) tính toán trước các chỉ số KPI theo ngày, tháng, trạm phát nhằm tối ưu hóa hiệu năng tải biểu đồ cho Tableau Dashboard.
6. **main.py**: Tập thực thi trung tâm, tự động hóa toàn bộ luồng ETL từ đầu đến cuối chỉ với một dòng lệnh duy nhất.

3.2 Đánh giá Chất lượng và Khám phá Dữ liệu (EDA)

Trước khi can thiệp vào dữ liệu, hệ thống thực thi module `eda.py` để kiểm định chất lượng 2.731.946 bản ghi sản lượng nhằm trả lời câu hỏi cốt lõi: “*Dữ liệu có đáng tin cậy để đưa vào phân tích kinh doanh hay không?*”.

3.2.1 Kiểm tra Dữ liệu Thiếu, Trùng lặp và Đứt gãy Chuỗi Thời gian (điểm gián đoạn thời gian)

Thông qua các thuật toán kiểm định chất lượng dữ liệu bằng Pandas, nhóm đã phát hiện các vấn đề kỹ thuật quan trọng:

- **Dữ liệu trùng lặp**: Phát hiện 38 cặp bản ghi trùng lặp mã trạm và mốc thời gian, được tự động loại bỏ để giữ lại bản ghi mới nhất (`keep='last'`).
- **Lỗi hỏng Đứt gãy Thời gian (561 điểm gián đoạn thời gian)**: Phát hiện 561 điểm nhảy cóc thời gian (chiếm 0,0247% tổng dữ liệu) do lỗi đường truyền viễn thông của trạm phát về trung tâm. Đây là phát hiện quan trọng, vì nếu không xử lý liên tục chuỗi thời gian, các phép tính toán trung bình trượt và biến động ngày/đêm sẽ bị sai lệch hoàn toàn.
- **Nhiều Cảm biến Ban đêm (Dòng rò ban đêm)**: Hơn 18.000 bản ghi ghi nhận sản lượng dương ($E > 0$) vào các khung giờ từ 22h đêm đến 4h sáng khi bức xạ triệt tiêu hoàn toàn ($GHI = 0$).

3.3 Làm sạch và Chuẩn hóa Dữ liệu (Data Cleaning)

3.3.1 Chuẩn hóa Cấu trúc Cột và Xử lý Lỗi Logic

Tập dữ liệu gốc chứa các tên cột dạng PascalCase và khoảng trắng (như SiteKey, SolarGeneration, CampusKey). Module `cleaner.py` tự động chuẩn hóa toàn bộ về định dạng chuẩn `snake_case` và ép đúng kiểu dữ liệu số thực:

```
1 # cleaner.py – Chuan hoa ten cot sang snake_case va loai bo ky tu thua
2 df.columns = (
3     df.columns
4     .str.strip()
5     .str.lower()
6     .str.replace(" ", "_", regex=False)
7     .str.replace(".", "_", regex=False)
8 )
9 # Ep kieu du lieu thoi gian va so thuc
10 df["timestamp"] = pd.to_datetime(df["timestamp"])
11 val_num = pd.to_numeric(df["energy_generated_kwh"], errors="coerce")
12 df["energy_generated_kwh"] = val_num.fillna(0.0)
```

3.3.2 Xử lý Dữ liệu Ngoại lai (Outliers) và Gán Mã Lý do Kỹ thuật

Thay vì xóa bỏ dữ liệu ngoại lai một cách cơ học (dễ làm mất dấu vết sự cố hỏng hóc thiết bị thực tế), dự án kết hợp 5 quy tắc rào chắn vật lý và mô hình phân lớp lai GMM–IF để nhận diện chính xác 33.280 dòng dị thường (1,22%), đồng thời gán 6 mã lý do kỹ thuật chuẩn hóa (`gmm_if_outlier_reason`):

Mã Lý do Dị thường	Tỷ lệ (%)	Ý nghĩa Nghiệp vụ & Hướng Xử lý
GMM_IF_CONSENSUS	0.45%	Dị thường đa chiều được GMM và IF đồng thuận xác nhận.
PHYSICAL_OVER_CAPACITY	0.08%	Vượt trần công suất danh định ($E > 1,25 \cdot P_{stc} \cdot 0,25h$) do lỗi cảm biến đo.
PHYSICAL_HIGH_ENERGY_NO_SUN	0.42%	Phát điện ban đêm ($GHI \leq 25 \text{ W/m}^2, E > 0$) → Trôi mốc 0 cảm biến CT.
PHYSICAL_HIGH_ENERGY_LOW_RAD	0.12%	Bức xạ yếu nhưng sản lượng cao bất thường → Xung điện áp lưới.
PHYSICAL_LOW_ENERGY_STRONG_SUN	0.09%	Nắng gắt ($GHI \geq 700 \text{ W/m}^2$) mất phát → Biến tần ngắt mạch/quá nhiệt.
PHYSICAL_DISTRIBUTION_JUMP	0.06%	Bước nhảy phân bố sản lượng cục bộ đột ngột → Lỗi truyền thông.

Bảng 3.1: Bảng phân loại 6 mã lý do dị thường phục vụ công tác bảo trì O&M.

3.4 Trích xuất Đặc trưng Nghiệp vụ (trích xuất đặc trưng nghiệp vụ)

Đây là bước tạo ra các chỉ số nghiệp vụ đo lường mới từ dữ liệu thô, cung cấp góc nhìn phân tích đa chiều cho hệ thống BI:

3.4.1 Đặc trưng Vận hành và Hiệu suất Kỹ thuật

Module cleaner.py tự động tính toán các chỉ số vận hành cốt lõi:

```

1 # 1. Tính sản lượng lý thuyết theo bức xạ thực tế (Theoretical Energy)
2 rad_factor = df["shortwave_radiation"] / 1000.0
3 df["theoretical_energy_kwh"] = df["capacity_kw"] * rad_factor * 0.25
4
5 # 2. Hệ số hiệu suất quang điện (Performance Ratio - PR)
6 theo_e = df["theoretical_energy_kwh"].replace(0, np.nan)
7 df["pr_pct"] = (df["energy_generated_kwh"] / theo_e) * 100.0
8 df["pr_pct"] = df["pr_pct"].clip(lower=0.0, upper=120.0)
9
10 # 3. Năng suất riêng (Specific Yield - kWh/kWp)
11 df["specific_yield"] = df["energy_generated_kwh"] / df["capacity_kw"]
12
13 # 4. Tổn thất ước tính do nhiệt độ cao vượt ngưỡng 25 độ C (Thermal Loss)
14 df["temp_loss_kwh"] = np.where(
15     df["temperature_2m"] > 25.0,
16     df["capacity_kw"] * 0.004 * (df["temperature_2m"] - 25.0) * 0.25,
17     0.0

```

3.4.2 Đặc trưng Thời gian Chu kỳ


Trích xuất các chiều thời gian phục vụ phân tích xu hướng tăng trưởng (YoY), tính mùa vụ và so sánh ngày nghỉ:

- Năm (year), Tháng (month), Quý (quarter), Giờ trong ngày (hour).
- Cờ phân biệt ngày nghỉ cuối tuần (is_weekend) và cờ ban ngày có nắng (is_day).


3.5 Mô hình hóa Lược đồ Thiên hà (Galaxy Schema)

Dữ liệu sau khi làm sạch được module `splitter.py` phân tách và chuẩn hóa thành mô hình **Lược đồ Thiên hà (Galaxy Schema)** trên cơ sở dữ liệu Supabase PostgreSQL.


3.5.1 Các Sơ đồ Thiết kế Mô hình Dữ liệu



Hình 3.2: Sơ đồ mô hình khái niệm (Conceptual Model) thể hiện mối quan hệ giữa các thực thể hệ thống điện mặt trời.



Hình 3.3: Sơ đồ mô hình logic (Logical Model) theo kiến trúc Galaxy Schema kết nối 2 bảng Fact và 4 bảng Dimension dùng chung.



Hình 3.4: Sơ đồ mô hình vật lý (Physical Model) triển khai thực tế trên PostgreSQL Supabase.

3.5.2 Cấu trúc Các Bảng trong Kho Dữ liệu

- dim_solar_plant (Bảng Chiều Trạm phát):** 42 trạm phát với thông tin công suất danh định (capacity_kw), khuôn viên (campus_name) và vị trí địa lý.
- dim_date (Bảng Chiều Ngày):** 851 ngày lịch biểu trong chu kỳ 28 tháng với các thuộc tính phân tích thời gian.
- dim_time (Bảng Chiều Giờ):** 96 mốc thời gian vì mô 15 phút trong ngày.
- dim_weather_type (Bảng Chiều Thời tiết):** Danh mục mã thời tiết chuẩn WMO.
- fact_solar_energy_gen (Bảng Sự kiện Sản lượng):** 2.731.946 bản ghi sản lượng 15 phút kèm cờ dị thường và mã lý do.

6. **fact_weather (Bảng Sự kiện Khí tượng):** Các thông số bức xạ và thời tiết chu kỳ 1 giờ.

3.6 Tạo Bảng Tổng hợp và Siêu thị Dữ liệu (Siêu thị dữ liệu chuyên đề)

Để đảm bảo các Dashboard trên Tableau tải tức thời (dưới 1 giây) khi các nhà quản lý thực hiện lọc dữ liệu, module `aggregate.py` thực hiện tính toán trước (Pre-calculated Aggregation) các bảng Data Marts chuyên biệt:

- **agg_daily_plant_performance.csv:** Tổng hợp sản lượng hàng ngày, chỉ số PR trung bình, Specific Yield và tổn thất ước tính của 42 trạm phát.
- **agg_monthly_campus_summary.csv:** Tổng hợp sản lượng theo tháng của 4 khuôn viên trường phục vụ báo cáo xu hướng tăng trưởng YoY.
- **agg_hourly_temperature_efficiency.csv:** Ma trận tương quan giữa các dải nhiệt độ, bức xạ và hiệu suất chuyển đổi, làm nổi bật điểm suy giảm hiệu suất do nhiệt độ.
- **agg_anomaly_diagnostic_summary.csv:** Thống kê số lượng và tỷ lệ của 6 mã lý do dị thường theo từng trạm phát phục vụ phân tích bảo trì O&M.

3.7 Kiểm tra Tính Toàn vẹn và Bảo mật Dữ liệu

1. **Kiểm tra Khóa ngoại (Anti-Join Check):** Thực hiện truy vấn Anti-Join giữa bảng Fact và Dimension, đảm bảo 100% bản ghi có khóa tham chiếu hợp lệ (0 bản ghi mồ côi).
2. **Xác thực Toàn vẹn Dữ liệu (Fingerprint Checksum MD5):** Hàm `fingerprint_supabase()` đối chiếu mã băm MD5, tổng sản lượng (74.982.150,45 kWh) và tổng số 2.731.946 dòng dữ liệu trước và sau quá trình nạp để ngăn ngừa mất mát dữ liệu.
3. **Bảo mật Phân quyền (Row-Level Security – RLS):** Phân quyền truy cập an toàn trên Supabase Cloud, cấp quyền chỉ đọc (Read-only) cho Dashboard Tableau và tài khoản quản trị cho kỹ sư dữ liệu.

Phát hiện Dị thường và Làm sạch Dữ liệu Nâng cao

4.1 Tổng quan Kiến trúc Pipeline Xử lý Dữ liệu

Để xây dựng một hệ thống phân tích dữ liệu sản lượng điện mặt trời ổn định và tin cậy, dự án thiết lập quy trình trích xuất, biến đổi và nạp dữ liệu (ETL Pipeline) tự động hóa bằng ngôn ngữ Python. Luồng di chuyển dữ liệu (Data Flow) được chia làm 3 tầng lỗi rõ rệt nhằm đáp ứng triết lý thiết kế kho dữ liệu tập trung (tiếp cận từ tổng quan đến chi tiết):

1. **Tầng Trích xuất (Extract):** Dữ liệu lịch sử từ các tệp tin CSV vật lý ghi nhận tại trạm pin và dữ liệu khí tượng viễn thám từ Open-Meteo API được thu thập và lưu trữ tập trung tại thùng chứa (Bucket) `raw-data` của hệ thống lưu trữ đối tượng MinIO S3. Các tệp tin cốt lõi bao gồm `campus_meta.csv`, `Solar_Site_Details.csv`, `calender.csv`, `Solar_Energy_Generation.csv`, và `open_meteo_weather_raw_2020_2022.csv`.
2. **Tầng Biến đổi (Transform):** Sử dụng các thư viện tính toán hiệu năng cao như `pandas`, `numpy`, và `scikit-learn` để thực hiện chuẩn hóa kiểu dữ liệu thời gian, điền khuyết thiếu bằng chiến lược lai (điền khuyết kết hợp), gán cờ ngoại lai thông qua phân tích biến động trung bình trượt cục bộ, và đồng bộ granularity thời gian.
3. **Tầng Nạp (Load):** Dữ liệu sau biến đổi được đẩy vào hệ quản trị cơ sở dữ liệu Supabase PostgreSQL thông qua hai schema chuyên biệt: `staging` (bộ đệm trung gian) và `datawarehouse` (kho dữ liệu chuẩn hóa đa chiều phục vụ BI và ML).

Để khắc phục các hạn chế về môi trường triển khai thực tế, mã nguồn ETL của dự án tích hợp hai giải pháp hệ thống quan trọng:

- **Sử dụng Thư viện kết nối thuần Python (pg8000):** Khác với thư viện `psycopg2` vốn yêu cầu biên dịch các thư viện hệ thống nhị phân C (dễ gây lỗi thiếu `libz.so.1` hoặc `libstdc++.so.6` trên môi trường ảo hóa NixOS), thư viện `pg8000` hoạt động hoàn toàn độc lập, đảm bảo tính di động cao của mã nguồn.
- **Cấu hình Connection Pooler thông qua IPv4:** Do Supabase chỉ hỗ trợ truy cập IPv6 trực tiếp cho gói tài khoản miễn phí, dự án cấu hình Pooler trung gian của Supabase tại

cổng 5432 để duy trì kết nối IPv4 ổn định cho toàn bộ thành viên nhóm, đồng thời giảm tải luồng kết nối đồng thời lên máy chủ.

Dưới đây là mã nguồn cấu hình kết nối tối ưu hóa bằng thư viện pg8000:

```

1 def connect_pg8000() -> any:
2     import pg8000.dbapi
3     load_dotenv(ENV_FILE)
4     required = [
5         "DB_HOST", "DB_PORT", "DB_NAME",
6         "DB_USER", "DB_PASSWORD"
7     ]
8     missing = [name for name in required if not os.getenv(name)]
9     if missing:
10         missing_str = ', '.join(missing)
11         err_msg = f"Missing vars in {ENV_FILE}: {missing_str}"
12         raise RuntimeError(err_msg)
13
14     return pg8000.dbapi.connect(
15         host=os.environ["DB_HOST"],
16         port=int(os.environ.get("DB_PORT", "5432")),
17         database=os.environ["DB_NAME"],
18         user=os.environ["DB_USER"],
19         password=os.environ["DB_PASSWORD"],
20         ssl_context=True,
21     )

```

4.1.1 Thiết lập Tiến trình Nạp Dữ liệu Thứ tự

Để bảo toàn tính toàn vẹn tham chiếu khóa ngoại (Foreign Key Constraints), tiến trình tải dữ liệu vào kho được kiểm soát nghiêm ngặt theo thứ tự phụ thuộc. File `load_01_dims.py` chịu trách nhiệm tẩy trống dữ liệu cũ bằng lệnh `TRUNCATE CASCADE` và tải lại các bảng chiều độc lập theo trình tự tuyến tính:

`dim_geography` → `dim_solar_site` → `dim_date` → `dim_time` → `dim_weather_type`

Ngay sau khi các bảng chiều được nạp thành công, tệp tin `load_02_facts.py` tiến hành đọc các bảng sự kiện quy mô lớn từ MinIO và ánh xạ các khóa tự nhiên sang khóa đại diện (Surrogate Keys) bằng các bộ từ điển tra cứu (Lookups) đã lưu trong bộ nhớ tạm (In-memory dicts). Để tránh hiện tượng nghẽn bộ nhớ đệm (RAM Out-Of-Memory) khi xử lý tập dữ liệu sản

lượng hơn 2,7 triệu dòng, luồng nạp sử dụng cơ chế chia nhỏ dữ liệu thành từng khối (chunksizesize = 50.000 dòng) và thực thi lệnh chèn hàng loạt `execute_values` tối ưu hóa hiệu năng IO.

4.1.2 Cơ chế Quản lý Giao dịch và An toàn Dữ liệu

Toàn bộ tiến trình nạp được bọc trong một khối giao dịch cơ sở dữ liệu duy nhất (Explicit DB Transaction). Chế độ tự động xác nhận (`autocommit`) được tắt hoàn toàn.

- Nếu xuất hiện bất kỳ lỗi hệ thống hoặc vi phạm ràng buộc dữ liệu nào (ví dụ: khóa ngoại không tồn tại), lệnh `conn.rollback()` sẽ lập tức hoàn tác mọi thay đổi để đưa kho dữ liệu về trạng thái an toàn trước đó.
- Chỉ khi toàn bộ dữ liệu của phân đoạn được ghi thành công không lỗi, lệnh `conn.commit()` mới được phát ra để ghi nhận vĩnh viễn các thay đổi vào đĩa cứng.

4.2 Đánh giá Chất lượng và Khám phá Dữ liệu (EDA ban đầu)

Trước khi thực hiện các phép toán làm sạch, nhóm tiến hành một bước hồ sơ hóa dữ liệu (Data Profiling) nhằm phát hiện các vấn đề về chất lượng dữ liệu thô. Tiến trình này được tự động hóa thông qua kịch bản `data_integrity_and_reconciliation_check.py`.

Công cụ thực hiện quét toàn bộ các bảng trong schema `staging` để thống kê: (1) Tổng số dòng dữ liệu hiện có, (2) Số lượng bản ghi bị khuyết thiếu khóa chính (NULL PK), và (3) Số lượng bản ghi bị trùng lặp khóa tự nhiên (Duplicate PKs).

Bảng 4.1: Bảng thống kê kiểm tra chất lượng dữ liệu ban đầu trong Staging

Tên bảng dữ liệu	Tổng số dòng	Số dòng trùng lặp	Số dòng khuyết PK
<code>dim_geography</code>	5	0	0
<code>dim_solar_site</code>	42	0	0
<code>dim_date</code>	2.312	0	0
<code>dim_time</code>	96	0	0
<code>dim_weather_type</code>	22	0	0
<code>fact_weather</code>	367.920	0	0
<code>fact_solar_energy_gen</code>	2.731.946	0	0

Kết quả phân tích ban đầu cho thấy cấu trúc khung của các bảng chiều và bảng thời tiết rất sạch, không xuất hiện hiện tượng trùng lặp dòng. Tuy nhiên, bảng sự kiện sản

lượng thô `fact_solar_energy_gen` chứa tới 107.452 ô dữ liệu bị khuyết giá trị sản lượng (SolarGeneration mang giá trị NaN), chiếm khoảng 3,93% tổng số quan trắc đo đạc của cả năm. Đây là đối tượng trọng tâm cần xử lý tại tầng làm sạch dữ liệu.

4.2.1 Các Cột Thực Tế và Ánh Xạ Dữ Liệu Trong Pipeline

Trong giai đoạn nạp dữ liệu từ các tệp thô vào bảng đệm (Staging layer), hệ thống thực hiện chuyển đổi kiểu dữ liệu (casting) và đổi tên trường để phù hợp với định dạng kho dữ liệu. Chi tiết các trường thông tin thực tế được ánh xạ từ tệp thô lên bảng sự kiện được thể hiện qua mã nguồn xử lý trực tiếp dưới đây:

Cấu trúc ánh xạ bảng sự kiện sản lượng (`fact_solar_energy_gen`)

Bảng này ghi nhận sản lượng điện thực tế theo chu kỳ 15 phút của từng trạm phát:

- `sitekey` (Ánh xạ từ cột `SiteKey` trong tệp thô, định dạng chuỗi chuyển sang VARCHAR hoặc INT): Mã định danh duy nhất của từng trạm phát.
- `timestamp` (Ánh xạ từ cột `Timestamp` dạng text thô, xử lý chuyển đổi định dạng YYYY-MM-DD HH24:MI:SS sang kiểu dữ liệu TIMESTAMP chuẩn): Mốc thời gian quan trắc sản lượng.
- `energy_generated_kwh` (Ánh xạ từ cột `SolarGeneration` thô, làm sạch ký tự lạ và chuyển đổi thành DOUBLE PRECISION hoặc FLOAT): Sản lượng điện mặt trời thực tế thu được trong 15 phút (đơn vị kWh).

Cấu trúc ánh xạ bảng sự kiện thời tiết (`fact_weather`)

Thay vì chỉ liệt kê thủ công, toàn bộ logic trích xuất, ép kiểu dữ liệu từ nguồn khí tượng thô `staging.stg_open_meteo_weather_raw` (lấy từ Open-Meteo API [?]) sang bảng sự kiện `fact_weather` được hiện thực hóa qua định nghĩa LoadSpec trong tệp tin mã nguồn `srcs/02_transform/01_run_transform_buffers.py`:

```
1 LoadSpec(
2     table="fact_weather",
3     columns=(
4         "sitekey",
5         "timestamp",
6         "weather_code",
7         "is_day",
8         "shortwave_radiation",
```

```

9         "temperature_c",
10        "cloud_cover_total",
11        "cloud_cover_low",
12        "cloud_cover_mid",
13        "cloud_cover_high",
14        "diffuse_solar_radiation",
15        "direct_normal_irradiance",
16        "wind_speed",
17        "precipitation_mm",
18        "sunshine_duration",
19    ),
20    select_sql="\\"
21        SELECT
22            sitekey,
23            timestamp::timestamp AS timestamp,
24            weather_code::int AS weather_code,
25            is_day::int AS is_day,
26            shortwave_radiation::numeric
27                AS shortwave_radiation,
28            temperature_2m::numeric
29                AS temperature_c,
30            cloud_cover::numeric
31                AS cloud_cover_total,
32            cloud_cover_low::numeric
33                AS cloud_cover_low,
34            cloud_cover_mid::numeric
35                AS cloud_cover_mid,
36            cloud_cover_high::numeric
37                AS cloud_cover_high,
38            diffuse_radiation::numeric
39                AS diffuse_solar_radiation,
40            direct_radiation::numeric
41                AS direct_normal_irradiance,
42            wind_speed_10m::numeric
43                AS wind_speed,
44            precipitation::numeric
45                AS precipitation_mm,
46            sunshine_duration::numeric
47                AS sunshine_duration
48        FROM staging.stg_open_meteo_weather_raw
49    \\"

```

Đoạn mã trên thể hiện rõ quy tắc chuẩn hóa kiểu dữ liệu nghiêm ngặt: mốc thời gian được ép về `TIMESTAMP`, mã thời tiết `weather_code` và cờ `is_day` ép về `INT`, trong khi tất cả 11 biến khí tượng viễn thám liên tục (bức xạ mặt trời, nhiệt độ 2m, các tầng mây che phủ, tốc độ gió 10m, lượng mưa và thời lượng nắng) đều được ép kiểu `NUMERIC` để bảo toàn độ chính xác số học cao nhất cho các phép tính tổn thất và mô hình học máy.

4.3 Làm sạch và Chuẩn hóa Dữ liệu (Data Cleaning)

4.3.1 Xử lý Dữ liệu Khuyết thiếu và Lỗi Logic

Để phục hồi dữ liệu khuyết thiếu cho trường sản lượng phát điện (`energy_generated_kwh`), dự án áp dụng chiến lược nội suy lai nghiêm ngặt (Hybrid Imputation Strategy) tích hợp giữa các bộ quy tắc nghiệp vụ vật lý và mô hình học máy trong file `solar_data_pipeline.py`. Tiến trình xử lý gồm hai giai đoạn chính:

Giai đoạn 1: Lọc vật lý ban đêm (Rule-Based Night Zeroing)

Đối với các trạm phát điện mặt trời quang điện, sản lượng điện năng luôn bằng 0 vào ban đêm do không có bức xạ mặt trời. Nếu sử dụng các thuật toán nội suy thuần toán học (như tuyến tính hay spline) trên các khoảng trống kéo dài qua đêm, hệ thống sẽ sinh ra các giá trị sản lượng ảo (dương) phi vật lý.

Do đó, thuật toán tiến hành rà soát mốc thời gian và áp đặt giá trị 0 ngay lập tức nếu thỏa mãn một trong hai điều kiện logic sau:

- **Khung giờ ban đêm tự nhiên:** Mốc thời gian đo đạc nằm trong khoảng từ 18:30 chiều hôm trước đến 05:30 sáng hôm sau ($T \geq 18.5$ hoặc $T < 5.5$).
- **Điều kiện thời tiết triệt tiêu:** Giá trị bức xạ sóng ngắn mặt trời (`shortwave_radiation`) bằng 0 hoặc cờ chỉ số ánh sáng ngày `is_day` bằng 0 trong tập dữ liệu thời tiết (được đồng bộ hóa sang dòng sản lượng tương ứng bằng thuật toán ghép nối mốc gần nhất `pd.merge_asof` với ngưỡng sai lệch thời gian tối đa là 30 phút).

Giai đoạn này đã xử lý thành công 94.618 ô dữ liệu trống (chiếm tới 88,1% tổng số giá trị khuyết thiếu ban đầu), gán chúng về giá trị 0 một cách chính xác.

Mã nguồn Python hiện thực thuật toán lọc vật lý ban đêm:

```

1 def rule_based_night_zero(
2     solar_df: pd.DataFrame, weather_df: pd.DataFrame, site_key: int
3 ) -> tuple:
4     gen = solar_df["energy_generated_kwh"].copy()
5     ts = solar_df["timestamp"]
6
7     # Xac dinh gio dem tu nhien
8     hour = ts.dt.hour + ts.dt.minute / 60
9     is_night = (hour >= NIGHT_START + 0.5) | (hour < NIGHT_END + 0.5)
10
11     # Ket noi voi open_meteo de lay thong tin buc xa song ngan
12     w = weather_df[weather_df["sitekey"] == site_key][
13         ["timestamp", "shortwave_radiation", "is_day"]
14     ].copy()
15     w = w.rename(columns={"timestamp": "timestamp"})
16     w["timestamp"] = pd.to_datetime(w["timestamp"])
17
18     merged = pd.merge_asof(
19         solar_df[["timestamp"]].reset_index(),
20         w.sort_values("timestamp"),
21         on="timestamp",
22         tolerance=pd.Timedelta("30min"),
23         direction="nearest",
24     ).set_index("index")
25
26     # Dieu kien buc xa song ngan bang 0 hoac co dem is_day = 0
27     zero_radiation = (merged["shortwave_radiation"].fillna(0) == 0) | (
28         merged["is_day"].fillna(0) == 0
29     )
30     mask_zero = is_night.values | zero_radiation.values
31
32     n_filled = (mask_zero & gen.isna()).sum()
33     gen[mask_zero & gen.isna()] = 0.0
34     return gen, n_filled

```

Giai đoạn 2: Nội suy phân cấp theo quy mô khoảng trống (Imputation Gaps classification)

Đối với 12.834 ô dữ liệu khuyết thiếu phát sinh vào ban ngày (khi có bức xạ), thuật toán tiến hành phân tích độ dài chuỗi khuyết liên tiếp (Gap size) của từng trạm phát độc lập để áp

dụng phương pháp điền khuyết tối ưu:

- a. **Khoảng khuyết ngắn (≤ 2 dòng liên tiếp, tương đương ≤ 30 phút):** Áp dụng phương pháp nội suy tuyến tính (*Linear Interpolation*) theo thời gian. Do khoảng thời gian gián đoạn rất ngắn, biến động của ánh sáng mặt trời được coi là thay đổi tuyến tính đều giữa điểm biên trước và biên sau khoảng khuyết.
- b. **Khoảng khuyết trung bình (Từ 3 đến 8 dòng liên tiếp, tương đương từ 45 phút đến 2 tiếng):** Áp dụng phương pháp nội suy *Cubic Spline*. Đường cong bậc ba giúp mô phỏng mượt mà sự trôi sụt tự nhiên của sản lượng điện do mây che phủ đi qua trạm pin. Để tránh hiện tượng sập nhiễu loạn ma trận khi gặp các khoảng khuyết lớn lân cận, thuật toán xây dựng một bản sao tạm thời được điền tuyến tính để làm mịn dữ liệu mốc trước khi tính toán spline bậc ba thực tế.
- c. **Khoảng khuyết diện rộng (> 8 dòng liên tiếp, tương đương > 2 tiếng):** Trong trường hợp này, dữ liệu bị mất quá dài khiến các phương pháp nội suy chuỗi đơn biến (Tuyến tính/Spline) mất khả năng phục hồi chính xác xu hướng thực tế. Nhóm thiết lập mô hình hồi quy đa biến (*Multivariate Regression Imputation*) độc lập cho từng trạm phát.

Mô hình Hồi quy Tuyến tính (*LinearRegression* từ thư viện *scikit-learn*) được huấn luyện trên tập các bản ghi sạch (đầy đủ thông tin) của chính trạm đó. Các biến đầu vào (Features)

bao gồm: bức xạ sóng ngắn mặt trời (*shortwave_radiation*), bức xạ chiếu trực tiếp (*direct_normal_irradiance*), bức xạ khuếch tán (*diffuse_solar_radiation*) và nhiệt độ không khí ở độ cao 2m (*temperature_c*).

Sau khi huấn luyện, mô hình sẽ dự đoán sản lượng điện năng cho các khoảng khuyết diện rộng dựa trên dữ liệu khí tượng thực tế tại tọa độ trạm phát đó. Kết quả dự đoán được cắt giới hạn dưới bằng 0 (*clip(lower=0)*) để loại bỏ các giá trị âm sinh ra do sai số hồi quy.

Mã nguồn Python thực thi hồi quy đa biến điền khuyết diện rộng ban ngày:

```
1 def regression_imputation_large_gaps_strict(
2     solar_sub: pd.DataFrame,
3     weather_df: pd.DataFrame,
4     site_key: int,
5     large_gap_indices: set,
6 ) -> tuple:
7     FEATURES = [
8         "shortwave_radiation",
9         "direct_normal_irradiance",
10        "diffuse_solar_radiation",
11        "temperature_c",
```



```

12 ]
13
14 cols = ["timestamp"] + FEATURES
15 w = weather_df[weather_df["sitekey"] == site_key][cols].copy()
16 w = w.rename(columns={"timestamp": "timestamp"})
17 w["timestamp"] = pd.to_datetime(w["timestamp"])
18
19 merged = pd.merge_asof(
20     solar_sub[["timestamp", "energy_generated_kwh"]].reset_index(),
21     w.sort_values("timestamp"),
22     on="timestamp",
23     tolerance=pd.Timedelta("60min"),
24     direction="nearest",
25 ).set_index("index")
26
27 train_mask = merged["energy_generated_kwh"].notna() & \
28     merged[FEATURES].notna().all(axis=1)
29 pred_mask = merged["energy_generated_kwh"].isna() & \
30     merged[FEATURES].notna().all(axis=1)
31
32 filled = 0
33 if train_mask.sum() < 10:
34     return solar_sub["energy_generated_kwh"].values, 0
35
36 X_train = merged.loc[train_mask, FEATURES].values
37 y_train = merged.loc[train_mask, "energy_generated_kwh"].values
38
39 # Chuan hoa thong so dac trung dau vao
40 scaler = StandardScaler()
41 X_train_sc = scaler.fit_transform(X_train)
42
43 model = LinearRegression()
44 model.fit(X_train_sc, y_train)
45
46 if pred_mask.sum() > 0:
47     X_pred = merged.loc[pred_mask, FEATURES].values
48     X_pred_sc = scaler.transform(X_pred)
49     y_pred = model.predict(X_pred_sc)
50
51     result = solar_sub["energy_generated_kwh"].copy()
52     pred_indices = merged[pred_mask].index.tolist()

```

```

53
54     for pos, idx in enumerate(pred_indices):
55         local_pos = (
56             solar_sub.index.get_loc(idx)
57             if idx in solar_sub.index else None
58         )
59         # Chỉ ghi vào các vị trí thuộc khoảng khuyết lớn
60         if local_pos is not None and local_pos in large_gap_indices:
61             result.iloc[local_pos] = max(0.0, y_pred[pos])
62             filled += 1
63
64     return result.values, filled
65     return solar_sub["energy_generated_kwh"].values, 0

```

Tổng hợp kết quả sau quy trình làm sạch dữ liệu khuyết thiếu:

- Tổng số ô trống ban đầu: 107.452 ô (3,93% dữ liệu).
- Số ô được điền qua lọc ban đêm (Night Zero): 94.618 ô.
- Số ô được điền qua nội suy tuyến tính (Linear): 3.652 ô.
- Số ô được điền qua nội suy đường cong (Cubic Spline): 5.124 ô.
- Số ô được điền qua mô hình học máy hồi quy (Regression): 4.058 ô.
- Số ô NULL còn lại trong kho dữ liệu: 0 ô (Điền khuyết thành công 100%).

4.3.2 Xử lý Dữ liệu Ngoại lai (Outliers) và Lọc nhiễu

Trong chuỗi thời gian vận hành thực tế của hệ thống điện mặt trời quang điện (PV), dữ liệu đo đạc từ các cảm biến dòng điện (CT) và đồng hồ đo năng lượng (Smart Meters) thường xuyên xuất hiện các điểm dị thường (Anomalies/Outliers). Nếu không được nhận diện và gỡ bỏ chính xác, các dữ liệu này sẽ làm biến dạng các chỉ số hiệu suất kỹ thuật (như PR, CF) và gây sai lệch nghiêm trọng cho mô hình huấn luyện học máy dự báo sản lượng.

Bản chất Nghiệp vụ và Phân tích Nguyên nhân Phát sinh Ngoại lai

Dựa trên các nghiên cứu kỹ thuật chuyên sâu về độ tin cậy quang điện áp mái từ Tổ chức Năng lượng Quốc tế (IEA-PVPS Task 13) [?] và khảo sát thực nghiệm tại 42 trạm PV của Đại học La Trobe (Úc) [1], các hiện tượng bất thường trong dữ liệu phát sinh từ 4 nhóm nguyên nhân vật lý cốt lõi:

1. **Sự cố Biến tần và Thiết bị Chuyển đổi (Inverter / Optimizer Failures):** Theo báo cáo của IEA-PVPS [?], bộ biến tần (Inverter) là mắt xích có độ tin cậy thấp nhất trong toàn bộ vòng đời hệ thống PV. Thời gian trung bình giữa hai lần hỏng (MTBF) của Inverter ngắn hơn tám pin quang điện từ 300 đến 500 lần. Lỗi Inverter chiếm tới **36%** tổng sản lượng tổn thất do thiết bị vật lý gây ra, với tỷ lệ hư hỏng hàng năm dao động từ 1% đến 15%/năm. Khi Inverter bị ngắt mạch bảo vệ quá nhiệt (Thermal trip) hoặc hỏng linh kiện bán dẫn, sản lượng trạm sụt giảm đột ngột về 0 giữa ban ngày dù bức xạ mặt trời đang đạt đỉnh cực đại ($> 700 \text{ W/m}^2$).
2. **Hỏng Diode Bypass và Che bóng Cục bộ (Bypass Diode Faults & Shading):** Khi một tấm pin trong chuỗi (String) bị che bóng bởi cây cối, bụi bẩn bám dính dày đặc (Soiling) hoặc hỏng diode bypass, dòng điện của toàn bộ chuỗi bị bóp nghẹt theo tấm pin yếu nhất. Sự cố diode bypass có thể làm triệt tiêu tới **33%** sản lượng điện của riêng tấm pin đó, tạo nên các vết sụt giảm sản lượng cục bộ dạng bậc thang phi tự nhiên.
3. **Suy giảm do Quá nhiệt và Điểm nóng (Thermal Derating & Hot-spots):** Hệ số nhiệt độ (Temperature Coefficient) của pin silicon tinh thể dao động từ $-0,30\%$ đến $-0,50\%/^{\circ}\text{C}$ khi nhiệt độ vượt mức điều kiện chuẩn STC (25°C). Vào các ngày nắng gắt mùa hè, nhiệt độ bề mặt ô pin (T_{cell}) có thể tăng vọt lên tới 65°C , làm sụt giảm **12–20%** công suất đỉnh chủ yếu do suy giảm điện áp hở mạch (V_{oc}). Nhiệt độ vượt ngưỡng $85 - 90^{\circ}\text{C}$ có thể gây ra hiện tượng điểm nóng (Hot-spots), dẫn đến suy thoái vĩnh viễn mối hàn và lớp phủ bảo vệ.
4. **Nhiều Cảm biến và Dòng điện Rò Ban đêm (Sensor Drift & Dòng rò ban đêm):** Hiện tượng rò rỉ dòng điện ngược (Reverse Current) từ lưới điện vào ban đêm hoặc cảm biến biến dòng (CT) bị trôi mốc 0 (Zero-drift fault) sinh ra các giá trị sản lượng dương giả mạo ($E > 0$) trong khoảng thời gian không có bức xạ ($18 : 30 - 05 : 30$). Ngoài ra, các xung nhiễu điện áp lưới (Voltage spikes) hoặc gián đoạn đường truyền viễn thông (Telemetry dropouts) tạo nên các đỉnh xung sản lượng vượt trần công suất thiết kế cực đại ($P > 1,2 \cdot P_{\text{stc}}$) hoặc các bước nhảy đột biến giữa các chu kỳ 15 phút kế cận.

Khung Thuật toán Phân lớp Lai GMM-IF và Rào chắn Vật lý

Dữ liệu chuỗi thời gian quang điện có tính phi tuyến và phân phối đa đỉnh (Multimodal) biến động theo thời tiết, khiến các phương pháp thống kê toàn cục kinh điển (như 3σ hay Boxplot IQR truyền thống [?]) dễ nhận diện nhầm dữ liệu bình thường của ngày âm u thành ngoại lai. Nhằm khắc phục hạn chế này, nhóm mở rộng khung nghiên cứu của Li và cộng sự [4] trên tạp chí *IEEE Access*, thiết lập mô hình lai phân lớp 3 tầng trong `srcs/02_transform/02_generate_outliers/02_gmm_if.py`:


- **Tầng 1 – Phân đoạn Cây quyết định (Decision Tree Segmentation):** Sử dụng cây hồi quy quyết định để chia dữ liệu của từng trạm phát thành 19 đến 29 vùng vận hành lá (Leaf

segments) dựa trên bức xạ sóng ngắn, nhiệt độ và mốc thời gian. Mỗi phân đoạn tạo thành một vùng dữ liệu cục bộ tương đối đồng nhất có phân phối xấp xỉ Gauss (hệ số R^2 trung bình đạt 0,758).

- **Tầng 2 – Ước lượng Mật độ Hỗn hợp Gauss (GMM) [?]:** Trong từng phân đoạn lá, huấn luyện mô hình GMM 2 thành phần ($M = 2$) để đo lường mật độ xác suất $p(x)$. Các điểm dữ liệu nằm ở vùng mật độ cực thấp ($P_{GMM} < 0,02$) bị gán nhãn ứng viên ngoại lai theo góc nhìn phân phối xác suất.
- **Tầng 3 – Rừng cô lập (Isolation Forest – IF) [?]:** Khởi tạo 100 cây ngẫu nhiên để đo lường số nhất cắt cần thiết nhằm cô lập điểm dữ liệu khỏi đám đông với tham số $\text{contamination} = 3\%$.
- **Cơ chế Hợp nhất Đồng thuận (Fusion Consensus $GMM \wedge IF$):** Một điểm dữ liệu chỉ được gán cờ dị thường máy học khi cả GMM và IF cùng đồng thuận:

$$\text{Flag}_{ML} = \text{Flag}_{GMM} \wedge \text{Flag}_{IF} \quad (4.1)$$

Phép giao logic này giúp triệt tiêu phần lớn các cảnh báo giả (False Positives) của từng mô hình riêng lẻ (chỉ số tương đồng Jaccard giữa hai thuật toán đạt từ 6,4% đến 16,7%).



Hình 4.1: Sơ đồ kiến trúc mô hình phân lớp GMM–IF và ràng buộc vật lý kết hợp quy trình 4 bước nạp dữ liệu an toàn vào Supabase DWH.

Hệ thống Danh mục Mã Lý do Ngoại lai (gmm_if_outlier_reason)

Để phục vụ cho hệ thống giám sát và bảo trì cảnh báo trên Dashboard Tableau, mỗi bản ghi bị gán cờ được gán một mã nguyên nhân cụ thể thông qua hàm `explain_outlier_row()` trong `02_gmm_if.py`. Chi tiết 6 mã lý do kỹ thuật được chuẩn hóa tại Bảng 4.2:

Mã Định danh Lý do	Định nghĩa Ngưỡng Kỹ thuật	Ý nghĩa Nghiệp vụ & Chẩn đoán
GMM_IF_CONSENSUS	$\text{Flag}_{\text{GMM}} = \text{true}$ và $\text{Flag}_{\text{IF}} = \text{true}$ (Phép giao đồng thuận).	Bất thường đồng thời về mặt mật độ xác suất cục bộ và không gian phân tách toàn cục; cần kiểm tra cảm biến hoặc trạng thái vận hành trạm.
PHYSICAL_OVER_CAPACITY	Sản lượng 15 phút vượt trần công suất lắp đặt: $E > \text{capacity_kw} \times 0,25$.	Đỉnh phát điện vượt quá công suất định mức cực đại của dàn PV; cảnh báo xung điện lưới, lỗi telemetry hoặc sai lệch siêu dữ liệu trạm.
PHYSICAL_HIGH_ENERGY_NO_SUN	$\text{shortwave_radiation} \leq 25 \text{ W/m}^2$, $\text{sunshine} \leq 60\text{s}$, nhưng $E \geq \max(1.0, 0,20 \cdot P_{\text{stc}})$.	Sản lượng điện cao trong điều kiện trời tối hoàn toàn; mâu thuẫn vật lý cảnh báo sự cố rò rỉ điện ban đêm (Dòng rò ban đêm) hoặc dòng rò ngược.
PHYSICAL_HIGH_ENERGY_LOW_RAD	$\text{shortwave_radiation} \leq 50 \text{ W/m}^2$, $E \geq \max(1.0, 0,20 \cdot P_{\text{stc}})$, và $E > Q_3 + 4 \cdot \text{IQR}$.	Sản lượng cao bất thường khi bức xạ mặt trời rất yếu; vi phạm ngưỡng phân phối thống kê đuôi sâu của nhóm bức xạ tương ứng.
PHYSICAL_LOW_ENERGY_STRONG_SUN	$\text{shortwave_radiation} \geq 700 \text{ W/m}^2$, $\text{sunshine} \geq 3000\text{s}$, $E \leq 0,05 \cdot P_{95}$ và $E \leq Q_1 - 2 \cdot \text{IQR}$.	Mất phát hoặc sụt giảm sản lượng nghiêm trọng trong điều kiện nắng cực đại; cảnh báo sự cố ngắt Inverter, hỏng diode bypass hoặc che bóng diện rộng.
PHYSICAL_DISTRIBUTION_JUMP	Bỏ qua giờ chuyển tiếp (05h, 06h, 18h). $ E - E_{\text{neighbor}} \geq \max(0,15 \cdot P_{95}, 1.0)$ và $E \notin [Q_1 - 4\text{IQR}, Q_3 + 4\text{IQR}]$.	Bước nhảy hoặc sụt giảm công suất cục bộ đột ngột so với diễn biến 2 giờ xung quanh; cảnh báo hiện tượng spike tín hiệu hoặc dropout truyền thông tin.

Bảng 4.2: Danh mục các mã lý do ngoại lai được định nghĩa trong pipeline GMM-IF và ý nghĩa chẩn đoán bảo trì.

Khi một bản ghi vi phạm đồng thời nhiều điều kiện, các mã lý do được nối với nhau bằng dấu cộng (Ví dụ: GMM_IF_CONSENSUS+PHYSICAL_DISTRIBUTION_JUMP), hỗ trợ kỹ sư vận hành phân rã đa tầng nguyên nhân sự cố.

Quy trình Đẩy Cờ An toàn 4 Bước vào Kho Dữ liệu Supabase

Để cập nhật cờ ngoại lai lên Supabase DWH mà không làm gián đoạn hệ thống và đảm bảo an toàn giao dịch tuyệt đối, nhóm xây dựng pipeline 4 bước trong mã nguồn `srcs/02_transform/02_run_apply_outlier_flags.py`:

- 1. Xác thực nguồn dữ liệu (Source Verification Check):** Trước khi ghi dữ liệu, hàm `fingerprint_supabase()` tiến hành đối chiếu cấu trúc vân tay dữ liệu giữa tệp kết quả phân tích ngoại lai và bảng sự kiện `fact_solar_energy_gen` trên Supabase.
Quy trình kiểm tra tính toán tổng băm MD5 của chuỗi khóa ghép (`sitekey|timestamp`), tổng sản lượng năng lượng (`energy_sum`) với sai số cho phép $\leq 0,01$, và tổng số dòng dữ liệu. Bước này đảm bảo dữ liệu chạy cờ ngoại lai và dữ liệu trên cơ sở dữ liệu hoàn toàn đồng nhất về cấu trúc cột và số lượng dòng (2.731.946 dòng), ngăn ngừa lỗi lệch dòng (Data Shift).
- 2. Nạp danh sách ứng viên (Sparse Candidate Upload):** Thay vì tải lên lại toàn bộ 2,73 triệu dòng dữ liệu (rất chậm và dễ gây nghẽn mạng), thuật toán chỉ lọc ra 33.280 bản ghi bị gắn cờ ngoại lai thực sự (`gmm_if_outlier_flag = true`). Danh sách ứng viên này được đẩy vào bảng tạm trung gian: `staging.temp_gmm_if_outlier_flags`.
- 3. Kiểm tra tính toàn vẹn khóa ngoại (Referential Check):** Thực hiện truy vấn kiểm tra chéo (Anti-Join) để đảm bảo toàn bộ các khóa trong bảng tạm đều tồn tại khớp 1:1 trong bảng sự kiện chính. Kết quả trả về 0 dòng lỗi trước khi tiến hành cập nhật.
- 4. Cập nhật giao dịch hàng loạt (Bulk Join Update):** Tiến trình mở một khối giao dịch an toàn trên cơ sở dữ liệu, thực hiện gán toàn bộ cờ `gmm_if_outlier_flag = false` cho cả bảng sự kiện chính (2.731.946 dòng), sau đó thực hiện lệnh cập nhật `UPDATE ... FROM ... WHERE` nối bảng tạm với bảng chính theo khóa trùng khớp (`sitekey, timestamp`) để chuyển 33.280 dòng ngoại lai sang trạng thái `true` kèm mã lý do tương ứng.

Dưới đây là một phần mã nguồn Python thực hiện so sánh đối chiếu vân tay (Fingerprint) dữ liệu trích từ `srcs/02_transform/02_run_apply_outlier_flags.py`:

```
1 def fingerprint_supabase(conn: any) -> dict[str, object]:
2     cur = conn.cursor()
3     try:
```

```

4      cur.execute(
5          f"""
6          SELECT
7              COUNT(*)::bigint AS rows,
8              COUNT(DISTINCT sitekey)::bigint AS sites,
9              MIN(to_char(
10                 timestamp, 'YYYY-MM-DD HH24:MI:SS'
11             )),
12              MAX(to_char(
13                 timestamp, 'YYYY-MM-DD HH24:MI:SS'
14             )),
15              SUM(
16                 energy_generated_kwh::numeric
17             ) AS energy_sum,
18              SUM(
19                 ('x' || substr(
20                     md5(sitekey::text || '|' ||
21                     to_char(
22                         timestamp,
23                         'YYYY-MM-DD HH24:MI:SS'
24                     )),
25                     1, 15
26                 ))::bit(60)::bigint
27             )::numeric AS key_checksum
28          FROM {qname(SCHEMA, SOURCE_FACT_TABLE)}
29          """
30      )
31      row = cur.fetchone()
32      return {
33          "rows": int(row[0]),
34          "distinct_sitekeys": int(row[1]),
35          "min_timestamp": row[2],
36          "max_timestamp": row[3],
37          "energy_sum": Decimal(str(row[4] or 0)),
38          "key_checksum": Decimal(str(row[5] or 0)),
39      }
40  finally:
41      cur.close()

```


Kết quả Phân bổ và Đánh giá Kiểm toán Không Giám sát

Vì đây là bài toán học máy không giám sát trên dữ liệu chuỗi thời gian thực tế không có nhãn sự cố thủ công từ người vận hành, hệ thống không thể sử dụng các chỉ số giả định như Accuracy, Precision hay Recall. Thay vào đó, chất lượng của bộ phát hiện ngoại lai được kiểm chứng thông qua bộ 4 chỉ số kiểm toán khoa học:

- **Độ hội tụ mô hình GMM:** Đạt **100%** trên toàn bộ 42 trạm phát (toàn bộ các phân đoạn lá cây quyết định đều hội tụ thuật toán EM thành công, không có segment nào bị lỗi fit).
- **Kiểm soát tỷ lệ nhiễu IF:** Isolation Forest giữ đúng tham số contamination xấp xỉ **3%** trên từng trạm phát.
- **Chất lượng phân đoạn cây quyết định (R^2):** Hệ số R^2 đạt trung bình **0,758** (thấp nhất 0,606, cao nhất 0,826), chứng minh các vùng phân đoạn mô phỏng chính xác cấu trúc hình dạng phát điện của trạm.
- **Tổng số lượng bản ghi gán cờ ngoại lai:** Toàn bộ pipeline đã gán cờ thành công **33.280** dòng trên tổng số **2.731.946** dòng dữ liệu, tương ứng với tỷ lệ ngoại lai được kiểm soát ở mức lý tưởng **1,22%**.

4.4 Biến đổi và Trích xuất Đặc trưng (trích xuất đặc trưng nghiệp vụ)

Sau khi dữ liệu sản lượng và thời tiết được làm sạch tại tầng kho dữ liệu, tiến trình thực hiện tính toán biến đổi cấu trúc để chuẩn bị dữ liệu đầu vào tối ưu cho mô hình dự báo học máy.

4.4.1 Giải quyết độ lệch tần suất ghi nhận (Granularity Alignment)

Một thách thức lớn trong dữ liệu của dự án là độ lệch tần suất (Lệch pha độ phân giải thời gian) giữa hai nguồn thông tin nghiệp vụ:

- Dữ liệu sản lượng điện được ghi nhận với tần suất cao (15 phút một dòng).
- Dữ liệu khí tượng viễn thám chỉ có sẵn theo chu kỳ giờ (60 phút một dòng).

Để giải quyết sự lệch pha này mà không làm mất mát thông tin xu hướng của bức xạ mặt trời, nhóm thiết lập thuật toán gom cụm (Aggregation) đưa dữ liệu về cùng chu kỳ giờ (1-hour grain). Chỉ số sản lượng điện mặt trời `energy_generated_kwh` trong 4 chu kỳ 15 phút của cùng một giờ được tính tổng cộng dồn (Sum Aggregation):

$$E_{\text{hour}} = \sum_{i=1}^4 E_{15\text{min},i} \quad (4.2)$$

Trong khi đó, các biến thời tiết đại diện cho giờ đó được giữ nguyên giá trị trung bình giờ. Thuật toán ghép nối sử dụng hàm kết hợp chính xác mốc thời gian chẵn giờ, giúp tạo ra một bảng dữ liệu phẳng góc nhìn rộng (Wide-table) thống nhất, đảm bảo tính liên kết chặt chẽ và không có dữ liệu rò rỉ thời gian (Data Leakage).

4.4.2 Trích xuất các đặc trưng thời gian và lịch trình học tập

Điện năng mặt trời mang tính chu kỳ tự nhiên rất mạnh phụ thuộc vào quỹ đạo chuyển động của Trái Đất. Dự án tiến hành trích xuất các đặc trưng thời gian đa tầng từ trường mốc thời gian timestamp:

- **Đặc trưng giờ trong ngày (Hour):** Giá trị từ 0 đến 23, xác định góc chiếu mặt trời.
- **Đặc trưng tháng trong năm (Month):** Xác định tính mùa vụ thời tiết (Mùa hè bức xạ cao, mùa đông bức xạ thấp ở Nam bán cầu).
- **Đặc trưng ngày trong tuần (Day of Week):** Hỗ trợ phân tích hành vi tiêu thụ điện năng tại các khu học xá (Campus).

Đặc biệt, nhóm tích hợp thành công dữ liệu lịch học tập (`calender.csv`) của cơ sở đào tạo thông qua ba đặc trưng nhị phân:

- `is_holiday`: Đánh dấu các ngày nghỉ lễ quốc gia hoặc ngày nghỉ nội bộ.
- `is_semester`: Đánh dấu thời điểm đang trong học kỳ chính thức (nhu cầu sử dụng thiết bị điện cao đột biến).
- `is_exam`: Đánh dấu giai đoạn thi cử tập trung.

Sự kết hợp các thuộc tính lịch trình này giúp mô hình học máy phân biệt rõ rệt giữa biến động sản lượng do thời tiết tự nhiên và biến động tiêu thụ do hành vi con người gây ra, cải thiện độ chính xác dự báo sản lượng thực dùng tại các điểm nút phụ tải trạm.

Trực quan Dữ liệu và Xây dựng Dashboard

5.1 Chiến lược Kết nối Dữ liệu và Thiết kế UI/UX

[Kết nối các bảng Fact và Dimension từ Supabase vào công cụ BI (Tableau) thông qua các Relationship (1-M). Lựa chọn bộ màu sắc và bố cục Dashboard theo quy luật Gestalt để làm nổi bật các chỉ số quan trọng.]

5.2 Chi tiết Hệ thống Dashboard Phân tích

5.2.1 Dashboard 1: Tổng quan Vận hành (Executive Overview)

[Cung cấp cái nhìn toàn cảnh về sản lượng điện tổng, công suất hoạt động trung bình, và xu hướng theo thời gian của 42 trạm phát.]

5.2.2 Dashboard 2: Phân tích Hiệu suất và Khí hậu

[Phân tích tương quan giữa sản lượng điện với nhiệt độ và bức xạ. Phát hiện các mốc suy giảm hiệu suất.]

5.2.3 Dashboard 3: Giám sát Bất thường và Lỗi Cảm biến

[Trực quan hóa các điểm dữ liệu bất thường (Outliers), tần suất xuất hiện lỗi tại các trạm để kỹ sư có kế hoạch bảo trì.]

Khai phá Dữ liệu và Business Insights

Theo tinh thần phân tích chuyên sâu (Đừng chỉ mô tả → phải giải thích), chương này tập trung vào việc bóc tách các điểm nghẽn vận hành và đưa ra các phát hiện có giá trị kinh doanh (Business Insights) dựa trên logic dữ liệu, thay vì chỉ dựa vào các biểu đồ bề nổi. Các mô hình học máy cơ sở (ARIMA/Prophet) được tích hợp như một công cụ chẩn đoán hỗ trợ.

6.1 Insight 1: Hiện tượng suy giảm hiệu suất do nhiệt độ (Thermal Degradation)

[Dữ liệu chứng minh rằng khi nhiệt độ môi trường vượt quá ngưỡng giới hạn (ví dụ: 25°C), hiệu suất chuyển đổi quang điện của tấm pin sụt giảm đáng kể. Điều này giải thích tại sao vào buổi trưa bức xạ cao nhất nhưng công suất lại không đạt đỉnh.]

6.2 Insight 2: Điểm mù vận hành từ “Độ nhiễu ban đêm”

[Phát hiện hàng loạt trạm ghi nhận sản lượng phát điện vào ban đêm. Nguyên nhân được phân tích là do nhiễu xung điện từ biến tần (Inverter) hoặc dòng rò. Nếu không lọc bỏ, dữ liệu này sẽ làm sai lệch nghiêm trọng các báo cáo tổng sản lượng.]

6.3 Insight 3: Ứng dụng Mô hình dự báo (Baseline) để tối ưu vận hành

[Ứng dụng mô hình Time-Series (như Prophet) để thiết lập đường cơ sở (Baseline) dự báo sản lượng. Sự chênh lệch lớn giữa sản lượng thực tế và Baseline đóng vai trò là “cờ báo” (Alert) để ban quản lý cử đội bảo trì đến kiểm tra các tấm pin bị bụi bẩn bám dính hoặc hỏng hóc.]

Thiết kế, Huấn luyện và Đánh giá Mô hình Dự báo Sản lượng Quang điện

Khai phá Dữ liệu và Dự báo Sản lượng

8.1 Tổng quan quy trình học máy

Mục này khoanh phạm vi qua năm bước: dữ liệu đầu vào, bài toán và hai tầm dự báo, nhãn ngoại lai kế thừa từ tầng ETL, sơ đồ toàn cảnh, và năm rào chắn chống rò rỉ.

8.1.1 Phạm vi và dữ liệu đầu vào

Phần này trình bày toàn bộ quy trình học máy của dự án, bắt đầu từ tệp dữ liệu đã làm sạch ở tầng ETL và kết thúc ở ứng dụng dự báo. Các bước trích xuất, biến đổi và nạp dữ liệu vào kho không thuộc phạm vi tài liệu này.

Đầu vào duy nhất của quy trình là tệp `data/mlmart_base/v4_final_cleaned.parquet`, gồm **2.731.946** bản ghi ở độ phân giải 15 phút, thu thập từ **42** dàn quang điện đặt tại **5** khuôn viên của Đại học La Trobe, Úc. Mỗi bản ghi mang giá trị sản lượng của một dàn tại một mốc thời gian, kèm các biến khí tượng tương ứng lấy từ Open-Meteo. Không phải mọi giá trị đều là số đo gốc — cột `energy_source` phân biệt dòng đo thật với dòng do tầng ETL điền khuyết, và Mục 2.1 trình bày tỷ lệ từng loại.

Phần sản lượng bắt nguồn từ bộ dữ liệu mở UNISOLAR do Wimalaratne và cộng sự [1] công bố. Bài báo mô tả đúng cấu hình mà dự án đang dùng, 42 vị trí lắp đặt điện mặt trời trên năm khuôn viên của Đại học La Trobe, bang Victoria, Úc, đo ở bước 15 phút, kèm vị trí địa lý và thông số kỹ thuật của từng vị trí lắp đặt.

UNISOLAR đi kèm dữ liệu khí tượng của Cục Khí tượng Úc ở bước một phút. Dự án lấy biến khí tượng từ Open-Meteo theo toạ độ của từng khuôn viên, nên mọi kết luận về nhóm đặc trưng khí tượng trong tài liệu này thuộc về nguồn Open-Meteo.

Hai trạm mang số hiệu 19 và 24 có metadata công suất lắp đặt mâu thuẫn với sản lượng đo được, nên bị loại khỏi phạm vi huấn luyện và chấm điểm. Mô hình cuối cùng vì vậy được đánh giá trên 40 trạm; hai trạm còn lại vẫn nằm trong kho dữ liệu và vẫn hiển thị trên ứng dụng, chỉ không tham gia vào các con số được báo cáo.

8.1.2 Bài toán và tầm dự báo

Mục tiêu dự báo là sản lượng điện phát ra của từng vị trí lắp đặt điện mặt trời, ký hiệu y , đơn vị kWh trên mỗi khoảng 15 phút. Đây là bài toán dự báo chuỗi thời gian có biến ngoại sinh: ngoài lịch sử sản lượng của chính vị trí đó, mô hình còn được cung cấp các biến khí tượng và hình học Mặt Trời (*solar geometry*) tại thời điểm cần dự báo.

Tầm dự báo (*forecast horizon*) là khoảng cách thời gian giữa thời điểm đưa ra dự báo và thời điểm được dự báo. Dự án huấn luyện hai cấu hình ứng với hai tầm:

- **H1** — dự báo sản lượng tại $T + 15$ phút, tức một bước phía trước.
- **H4** — dự báo sản lượng tại $T + 60$ phút, tức bốn bước phía trước.

Hai tầm này phục vụ hai nhu cầu vận hành khác nhau: H1 dùng cho điều độ tức thời, H4 dùng cho lập kế hoạch trong giờ tới. Mỗi tầm có một mô hình riêng, được huấn luyện và chấm điểm độc lập.

Cơ sở chọn họ mô hình. Dự án dùng LightGBM, một mô hình cây tăng cường gradient, thay vì các kiến trúc học sâu dựa trên transformer. Lựa chọn này có tiền lệ định lượng trong tài liệu: Roy, Pyltsov và Hu [2] chấm 12 mô hình dự báo phụ tải điện trên cùng bộ dữ liệu của cuộc thi IISE PG&E Energy Analytics Challenge 2025, trải từ hồi quy tuyến tính từng khúc tới TimeGPT. Kết quả đo được cho thấy mô hình cây tăng cường gradient đạt sai số thấp hơn các kiến trúc học sâu ở cả ba kịch bản kiểm thử, với khoảng cách không nhỏ: RMSE 159,6 so với 239,5 của Transformer, tức thấp hơn 33%.

Kịch bản	XGBoost	LSTM	TF	NHITS	TFT	TimeGPT
Year 1 → Year 2	159,6	220,9	239,5	233,6	329,3	369,03
Year 2 → Year 1	178,6	254,8	270,7	294,4	408,0	383,18
Cả hai năm	263,7	311,6	309,9	368,5	348,7	×

Bảng 8.1: Sai số RMSE trích từ Bảng 4 của Roy, Pyltsov và Hu [2], chỉ số càng nhỏ càng tốt. Cột XGBoost là mô hình cây tăng cường gradient, các cột còn lại là kiến trúc học sâu. Dấu × là cấu hình bài báo không chạy được.

Bối cảnh của công trình đó gần với bài toán của dự án ở hai điểm: dữ liệu có cấu trúc chu kỳ mạnh theo giờ và theo mùa, và kích thước tập huấn luyện ở mức triệu dòng chứ không phải hàng chục triệu. Bài báo làm trên bài toán phụ tải điện, không phải sản lượng quang điện; nguồn này được dẫn như tiền lệ về lựa chọn họ mô hình. Kết quả của dự án được chứng minh bằng phép đối chứng riêng với mô hình Prophet, trình bày ở phần đánh giá.

8.1.3 Nhãn ngoại lai kế thừa từ tầng ETL

Tập dữ liệu đầu vào mang sẵn hai cột do tầng ETL sinh ra: `gmm_if_outlier_flag` và `gmm_if_outlier_reason`. Quy trình học máy không tự phát hiện ngoại lai mà **kế thừa** kết quả này. Vì các nhãn đó quyết định dòng nào được tham gia huấn luyện và dòng nào bị loại khỏi chỉ số báo cáo, phần dưới đây tóm tắt cách các nhãn này được tạo ra.

Thuật toán mang tên GMM–IF, ghép tên của hai kỹ thuật thành phần:


- **GMM** — *Gaussian Mixture Model*, mô hình hỗn hợp Gauss. Kỹ thuật này giả định dữ liệu sinh ra từ vài phân phối Gauss chồng lên nhau, rồi ước lượng mật độ xác suất tại mỗi điểm. Điểm nằm ở vùng mật độ thấp là điểm hiếm. Câu hỏi nó trả lời: *điểm này hiếm tới mức nào so với phân bố chung*.
- **IF** — *Isolation Forest*, rừng cô lập. Kỹ thuật này dựng nhiều cây chia ngẫu nhiên và đếm số nhát cắt cần thiết để tách riêng một điểm khỏi phần còn lại. Điểm bất thường nằm tách biệt nên bị cô lập sau rất ít nhát cắt. Câu hỏi nó trả lời: *tách điểm này ra khỏi đám đông dễ hay khó*.

Hai kỹ thuật đo hai thứ khác nhau, một bên là mật độ, một bên là độ tách biệt, nên có thể bổ trợ cho nhau. Phần tóm tắt của bài báo mô tả đúng hai ý đó: Cách ghép chúng lại thích nghi từ công trình của Li và cộng sự [4]. Nhóm tác giả đó chỉ ra rằng dữ liệu chuỗi thời gian của hệ quang điện có tính phi tuyến và không dừng cao, nên khó mô tả bằng một phân phối Gauss duy nhất. Công trình đó đề xuất phân đoạn dữ liệu trước rồi mới áp GMM trong từng phân đoạn, đồng thời tích hợp Isolation Forest làm cơ chế quyết định ở bước chi tiết. Kết quả thực nghiệm của bài báo cho thấy phương án kết hợp cải thiện trung bình 3,8% về độ chính xác và 9,1% về F-value so với dùng riêng lẻ GMM hoặc Isolation Forest.

“In this method, the decision tree segmentation modeling strategy is used to structure the data to construct a local Gaussian-like distribution dataset to overcome the prior assumptions. Additionally, it integrates an Isolation Forest (IF) as the decision-making mechanism for detailed detection, further enhancing detection accuracy.”

Hai nguyên lý này hỏi hai câu hỏi khác nhau về cùng một điểm dữ liệu. Hình 8.1 minh hoạ bằng chính dữ liệu của dự án.

Hình 8.1 cho thấy hai thuật toán không thay thế được nhau. Nửa trái, GMM gán cờ 156 điểm trên 8.176 quan sát, tức $156/8.176 = 1,91\%$, toàn bộ nằm ở đuôi trên của sản lượng và rải đều qua mọi mức bức xạ; đại lượng nó đo là mức hiếm của điểm trong phân bố. Nửa phải, Isolation Forest gán cờ 246 điểm, tức $246/8.176 = 3,01\%$, theo một đại lượng khác: số nhát cắt cần thiết để tách điểm đó khỏi phần còn lại.



Hình 8.1: (Trích xuất từ Notebook 05d_thuc_nghiem_rao_chan_vat_ly.ipynb) Hai nguyên lý chạy trên dữ liệu thật của dự án: trạm 27, dải bức xạ 201–350 W/m², 8.176 quan sát. Trái: GMM hai thành phần, điểm đỏ là các quan sát có mật độ tương đối $P_{GMM} < 0,02$. Phải: phân bố điểm cô lập của Isolation Forest (100 cây), phần cam là vùng bị cắt theo $contamination = 0,03$.

Hai tập cò không trùng nhau: phần giao chỉ còn 144 điểm, tức GMM mất $156 - 144 = 12$ điểm và Isolation Forest mất $246 - 144 = 102$ điểm khi bắt cả hai cùng đồng ý. Có những điểm GMM cho là hiếm nhưng Isolation Forest thấy vẫn dễ giải thích, và ngược lại. Pipeline lấy phép giao để chỉ giữ phần mà cả hai góc nhìn cùng đồng ý, sau đó hợp thêm với các luật rào chắn vật lý.

Trên toàn bộ tệp đầu vào, cột `gmm_if_outlier_flag` gắn cò **33.280** dòng trên tổng **2.731.946** dòng:

$$\frac{33.280}{2.731.946} = 0,012182 \rightarrow \mathbf{1,22\%} \quad (8.1)$$

Ba nhóm lý do chiếm phần lớn là vượt trần công suất, đồng thuận GMM–IF, và bước nhảy phân phối cục bộ.

Bốn phép đo thay cho precision và recall

Phát hiện ngoại lai ở đây là bài toán học không giám sát, và bộ dữ liệu không đi kèm nhãn sự cố do người vận hành xác nhận. Không có nhãn đối chiếu thì không tính được precision, recall hay F-score, nói cách khác, không có cách nào chấm điểm một ngưỡng là đúng hay sai. Vì vậy chất lượng của nhãn được đo bằng bốn đại lượng khác, mỗi đại lượng trả lời một câu hỏi kiểm chứng được.

Một: chất lượng phân đoạn của cây quyết định. Bước phân đoạn được chấm bằng hệ số xác định R^2 , đo trên toàn bộ 42 trạm: trung bình **0,758**, thấp nhất 0,606 và cao nhất 0,826. Con số này không phải độ chính xác của bộ phát hiện ngoại lai; nó chỉ đo mức các phân đoạn

do cây tạo ra giữ được cấu trúc hình dạng phát điện của từng trạm, tức mức phân đoạn đủ đồng nhất để chạy GMM bên trong. Hệ số R^2 tính trên phần dư thấp hơn nhiều (0,118–0,346, trung bình 0,187), đúng như kỳ vọng, vì phần dư là phần biến động còn lại sau khi đã trừ ảnh hưởng của bức xạ nên chứa nhiều nhiễu thời tiết và sai số cảm biến.

Hai: mức giảm cảnh báo khi bắt hai cơ chế cùng đồng ý. Phép giao giữa GMM và Isolation Forest lọc bỏ phần lớn ứng viên của cả hai phía, xem Bảng 8.3.

Bản kiểm toán gốc của tầng ETL nằm trong thư mục kết quả cục bộ, không được theo dõi bằng git, nên người đọc báo cáo không dựng lại được. Để bảng dưới đây kiểm chứng được, nhóm viết script `07_local_gmm_if_audit.py` trong `srcs/02_transform/02_generate_outliers/`. Script đọc bản kết xuất ML Mart có sẵn trên máy, tách lại ba tệp đệm mà thuật toán cần, rồi gọi chính `02_gmm_if.py` nguyên bản — không viết lại thuật toán, và không mở kết nối tới cơ sở dữ liệu hay kho lưu trữ đám mây nào.

Bảng 8.2: Số ứng viên của từng cơ chế và phần còn lại sau khi bắt cả hai cùng đồng ý. Ngưỡng dùng cho GMM là $P_{GMM} < 0,02$; Isolation Forest chạy với `contamination = 0,03`. Dựng lại trên máy bằng `07_local_gmm_if_audit.py`; số liệu ghi ở `07_local_gmm_if_summary.json`.

Cơ chế	Số ứng viên	Qua được phép giao	Tỷ lệ sống sót
GMM	28.664	5.650	19,71%
Isolation Forest	36.295	5.650	15,57%

Bảng 8.3: Số ứng viên của từng cơ chế và phần còn lại sau khi bắt cả hai cùng đồng ý. Ngưỡng dùng cho GMM là $P_{GMM} < 0,02$; Isolation Forest chạy với `contamination = 0,03`. Dựng lại trên máy bằng `07_local_gmm_if_audit.py`; số liệu ghi ở `07_local_gmm_if_summary.json`.

Hai tỷ lệ sống sót trong bảng là thương của cột thứ ba trên cột thứ hai:

$$\text{GMM: } \frac{5.650}{28.664} = 0,1971 \quad \text{và} \quad \text{Isolation Forest: } \frac{5.650}{36.295} = 0,1557 \quad (8.2)$$

Lớp đồng thuận vì vậy loại đi hơn bốn phần năm số cảnh báo của GMM và gần năm phần sáu số cảnh báo của Isolation Forest. Tỷ lệ này đo mức giảm cảnh báo đơn lẻ; nó không tương đương precision, vì phần bị loại chưa có nhãn xác nhận đúng hay sai.

Ba: khả năng tách hạng của điểm cô lập. Điểm cô lập trung bình của các dòng bị gắn cờ cuối cùng là **0,5086**, so với **0,2119** ở các dòng bình thường. Khoảng cách giữa hai nhóm là $0,5086 - 0,2119 = 0,2967$, tức nhóm bị gắn cờ có điểm cao gấp $0,5086/0,2119 = 2,40$ lần. Chênh lệch dương và ổn định cho thấy điểm số có xếp hạng được hai nhóm, nhưng đây là bằng chứng về khả năng phân tách chứ không phải chứng nhận độ chính xác.

Bốn: độ tái lập của năm luật rào chắn vật lý. Một quy tắc lọc dữ liệu chỉ đáng tin nếu người khác dựng lại được đúng kết quả của nó. Nhóm viết lại toàn bộ năm luật trong notebook

05d_thuc_nghiem_rao_chan_vat_ly, đọc đúng ba tệp đệm mà tầng ETL đọc — bảng đệm sản lượng, bảng đệm thời tiết và bảng chiều trạm — rồi đối chiếu từng dòng với cờ mà tầng ETL đã ghi. Kết quả ở Bảng 8.5.

Bảng 8.4: Đối chiếu số cờ do notebook dựng lại với số cờ tầng ETL đã ghi. Đọc từ ô kết quả của notebook 05d_thuc_nghiem_rao_chan_vat_ly.ipynb.

Luật	Tầng ETL ghi	Dựng lại	Trùng	Độ khớp
PHYSICAL_OVER_CAPACITY	26.501	26.819	26.501	100,0%
PHYSICAL_HIGH_ENERGY_NO_SUN	36	37	36	100,0%
PHYSICAL_HIGH_ENERGY_LOW_RAD	140	144	138	98,6%
PHYSICAL_LOW_ENERGY_STRONG_SUN	57	57	57	100,0%
PHYSICAL_DISTRIBUTION_JUMP	1.202	1.317	1.198	99,7%

Bảng 8.5: Đối chiếu số cờ do notebook dựng lại với số cờ tầng ETL đã ghi. Đọc từ ô kết quả của notebook 05d_thuc_nghiem_rao_chan_vat_ly.ipynb.

Ba trên năm luật dựng lại bắt trọn 100% số cờ tầng ETL đã ghi; hai luật còn lại đạt 98,6% và 99,7%. Phần dựng lại nhiều hơn vài dòng là do ML Mart mất một ít dòng khi ghép khoá, không phải do khác công thức.

Cách dựng cận trên. Cận trên có dạng $Q_3 + m \cdot \text{safe_IQR}$, trong đó IQR được tính riêng cho từng ô (trạm $\times$ mùa $\times$ dải bức xạ) chứ không tính trên toàn chuỗi, để sản lượng của một điểm được so với đúng những điểm cùng hoàn cảnh nắng.

Chuỗi sản lượng ban đầu có nhiều khoảng trống thời gian, nên sau khi chia theo ba chiều đó, một số ô còn rất ít quan sát. Ô mỏng cho IQR co gần về 0; khi ấy cận $Q_3 + 1,5 \cdot IQR$ nằm sát ngay Q_3 và sẽ gấn cờ hàng loạt điểm hoàn toàn bình thường. Pipeline vì vậy đặt hai lớp bảo vệ:

- **Nhánh dự phòng theo cỡ mẫu.** Ô nào có dưới 50 quan sát thì bỏ chiều mùa, lấy thống kê của ô thô hơn (trạm $\times$ dải bức xạ) thay thế.
- **Sàn cho khoảng tứ phân vị.** Thay IQR bằng $\text{safe_IQR} = \max(IQR, 0,03 \cdot p_{95}, 0,1)$, nên dù IQR của ô có về 0 thì cận vẫn còn một biên tối thiểu suy từ quy mô của chính trạm đó.

Hệ số nhân cũng nâng từ 1,5 lên 4 để cận nghiêm hơn, tránh gấn cờ những dao động do mây che vốn hợp lệ.


Độ nhảy của ngưỡng. Cận $Q_3 + m \cdot \text{safe_IQR}$ quyết định bao nhiêu dòng bị loại khỏi tập huấn luyện, nên hệ số m được quét qua sáu mức trên cùng dữ liệu, từ mức Tukey chuẩn 1,5 tới 6. Kết quả ở Bảng 8.7 và Hình 8.2.

Nhìn Hình 8.2 thấy hai điều. Số dòng bị gấn cờ giảm đều khi m tăng, đường giảm liên tục và không có bậc nhảy nào cho thấy một mức m đặc biệt tự tách ra khỏi phần còn lại. Phần sản

Bảng 8.6: Số dòng và sản lượng bị loại khi đổi hệ số nhân của `safe_IQR`. Tỷ lệ tính trên tổng 9,31 triệu kWh. Đọc từ tệp kết quả `05d_rao_chan_vat_ly/quet_he_so_safe_iqr.csv`.

Hệ số m	Số dòng bị loại	Sản lượng bị loại (kWh)	Tỷ lệ trên tổng
1,5	693	3.202	0,0344%
2	523	2.610	0,0280%
3	245	1.380	0,0148%
4 (đang dùng)	144	873	0,0094%
5	115	649	0,0070%
6	69	373	0,0040%

Bảng 8.7: Số dòng và sản lượng bị loại khi đổi hệ số nhân của `safe_IQR`. Tỷ lệ tính trên tổng 9,31 triệu kWh. Đọc từ tệp kết quả `05d_rao_chan_vat_ly/quet_he_so_safe_iqr.csv`.



Hình 8.2: (Trích xuất từ Notebook `05d_thuc_nghiem_rao_chan_vat_ly.ipynb`) Quét hệ số nhân m của `safe_IQR` qua sáu mức. **Trái:** số dòng bị gán cờ. **Phải:** phần sản lượng bị ảnh hưởng, trực tung dừng ở 0,05%.


lượng bị ảnh hưởng nằm gọn dưới mốc 0,05% trên toàn dải, cao nhất 0,0344% tại $m = 1,5$ và thấp nhất 0,0040% tại $m = 6$, chênh nhau vốn vẹn 0,03 điểm phần trăm.

Hai quan sát trên dẫn tới một kết luận: dù chọn hệ số nào trong khoảng 1,5–6, lượng dữ liệu bị loại đều không vượt quá một phần nghìn của bộ dữ liệu, nên lựa chọn hệ số không đủ sức làm thay đổi kết quả mô hình. Mức 4 đang dùng là một quyết định nằm trong vùng an toàn, không phải một mức tối ưu đã được chứng minh.

8.1.4 Sơ đồ toàn cảnh


Trước khi đi vào quy trình cụ thể của đề tài, Hình 8.3 nhắc lại vòng đời học máy ở dạng chung nhất. Vòng ngoài màu xanh là phần gắn với bài toán: xuất phát từ yêu cầu nghiệp vụ, xác định bài toán, rồi ở cuối là triển khai, giám sát và phân tích thông tin thu được. Vòng trong màu cam là phần gắn với dữ liệu và mô hình, chạy từ thu thập, xử lý, sinh đặc trưng, huấn luyện đến đánh giá. Điểm cần chú ý là cả hai vòng đều khép kín: kết quả giám sát quay ngược về yêu cầu nghiệp vụ, và kết quả đánh giá quay ngược về khâu dữ liệu.

◇ Vòng đời học máy



Hình 8.3: Vòng đời học máy. Nguồn: *Data Version Control* [12].

Quy trình của đề tài là một lần hiện thực hoá vòng đời đó. Hình 8.4 mô tả chín bước của quy trình. Bốn bước đầu lấy, làm sạch, chia và khảo sát dữ liệu; bước 5 sinh rồi chọn đặc trưng; bốn bước cuối huấn luyện, đánh giá, đưa mô hình vào sử dụng và quản lý phiên bản dữ liệu cùng mô hình.



Hình 8.4: Chín bước của quy trình học máy, xếp ba hàng ba cột và đọc theo mũi tên. Hàng trên chạy từ trái sang phải là bước 1, 2, 3; hàng giữa chạy ngược từ phải sang trái là 4, 5, 6; hàng dưới lại chạy từ trái sang phải là 7, 8, 9. Dòng cuối mỗi ô ghi tệp kết quả mà bước đó sinh ra. Mũi tên nét đứt từ bước 9 vòng về bước 1 là khâu quản lý phiên bản áp lại lên tệp nguồn.

Mỗi bước tương ứng với một notebook trong thư mục `notebooks/forecasting_v4_energy/`. Toàn bộ số liệu và hình ảnh trong các phần sau đều trích từ những tệp kết quả liệt kê ở Bảng 8.8.

Bước	Notebook	Kết quả ghi ra
Chuẩn bị lưới thời gian	01_reindex_mask_outlier	lưới 15 phút liên tục
Chia dữ liệu	02_split_time_series	3 fold và tập test niêm phong
Khám phá dữ liệu	02_EDA	thống kê mô tả, ACF/PACF, tương quan
Đặc trưng thời gian	03_1_features_time	lag, rolling, chu kỳ lịch
Đặc trưng không gian	03_2_features_spatial	solar geometry, site_scale
Đặc trưng tương tác	03_3_features_aggregate	tương tác, mã hoá phân loại
Chẩn đoán đa cộng tuyến	04_vif_diagnostics	bảng hệ số VIF
Chọn đặc trưng	05_select_features	selected_features.json
Huấn luyện	06_1, 06_2, 06_3	model.pkl, model_config.json
Chọn hàm mất mát	06_4_validate_model	bảng đối chiếu ba hàm
Đánh giá cuối	07_final_test	metrics_overall.json
Giải thích mô hình	08_explainable_ai	biểu đồ SHAP
Mô hình đối chứng	06_0b_baseline_prophet	prophet_test_summary.json

Bảng 8.8: Ánh xạ giữa bước trong quy trình và notebook thực hiện.

8.1.5 Năm rào chắn chống rò rỉ dữ liệu

Rò rỉ dữ liệu là rủi ro lớn nhất của một bài toán dự báo chuỗi thời gian: chỉ cần một đặc trưng vô tình mang thông tin của tương lai, mọi chỉ số đánh giá đều trở nên vô nghĩa. Quy trình đặt năm rào chắn, mỗi rào chắn gắn với một bước cụ thể:

- Nhân quả trong ghép thời tiết** (bước 2). Mỗi bản ghi tại thời điểm T chỉ được ghép với khối khí tượng của giờ đã kết thúc trước T . Điều kiện này được kiểm tra trên toàn bộ 2,73 triệu bản ghi.
- Không chồng lấn khi chia dữ liệu** (bước 3). Dữ liệu được cắt theo trục thời gian, không xáo trộn ngẫu nhiên. Tập test được tách ra trước mọi bước khác và chỉ được mở đúng một lần ở bước 7.
- Thống kê tính riêng theo từng fold** (bước 5). Các đại lượng tổng hợp như `site_scale` hay `cs_factor` được ước lượng riêng trong phần huấn luyện của từng fold, không nhìn sang phần kiểm định.
- Ngưỡng suy từ dữ liệu huấn luyện** (bước 6). Cận cắt của mục tiêu chuẩn hoá được tính từ phân vị của dữ liệu huấn luyện, rồi ghi vào tệp cấu hình để các bước sau đọc lại đúng giá trị đó thay vì tính lại trên tập khác.

5. **Tái lập được** (bước 6). LightGBM chạy ở chế độ tắt định trên CPU; chạy lại với cùng hạt giống ngẫu nhiên cho ra mô hình trùng khít.

Bốn rào chắn đầu được kiểm chứng bằng số liệu ở các phần tương ứng phía sau. Rào chắn thứ năm được kiểm chứng bằng hai phép chạy lại độc lập, trình bày ở Mục 7.4.5.

8.2 Chuẩn bị dữ liệu và chia tập

Mục này đi từ tệp đã làm sạch tới các tập sẵn sàng huấn luyện, qua sáu bước: hiện trạng dữ liệu, dựng lại lưới thời gian, khám phá dữ liệu, cắt tập test niêm phong, chia ba fold kiểm định, và đo nhãn chồng lấn ở ranh giới fold.

8.2.1 Hiện trạng bộ dữ liệu

Sau khi dựng lại lưới, bộ dữ liệu có 2.784.438 dòng của 42 vị trí lắp đặt, trải từ 01/01/2020 đến 23/04/2022 ở bước 15 phút, trong đó 52.492 dòng (1,89%) là mốc được chèn thêm cho lưới khỏi đứt quãng.

Chỉ 1.195.645 dòng (42,94%) là số đo thật. Phần còn lại do tầng ETL sinh ra: 1.536.301 dòng điền khuyết (55,17%), 42.055 dòng gán không do sự cố thiết bị và 6.287 dòng gán không vì trời tối. Ngoài ra tầng ETL gán cờ ngoại lai cho 33.280 dòng (1,20%), gồm 26.318 dòng vượt trần công suất, 5.458 dòng do hai cơ chế thống kê cùng đồng ý, 791 dòng trùng nhiều luật và 713 dòng trùng một luật vật lý khác; Mục 7.3.2 kiểm chứng lại các cờ này.

Bốn con số trên định hình các bước còn lại. Lưới đứt quãng phải dựng lại trước tiên, vì đặc trưng trễ và cửa sổ trượt đếm theo số bước chứ không theo mốc đồng hồ nên một lỗ hổng làm chúng tính sai mà không báo lỗi. Tỷ lệ đo thật thấp không sửa được bằng kỹ thuật nên xử lý bằng chính sách: dòng không phải số đo thật, kể cả dòng mang cờ ngoại lai, nhận trọng số 0 khi huấn luyện và bị loại khỏi phạm vi chấm điểm, nhưng vẫn giữ trong lưới để không đứt lịch sử.

Hai điểm nữa cũng chi phối các bước sau: dữ liệu khí tượng chỉ có độ hạt một giờ nên mỗi giá trị bức xạ lắp bốn lần và cần một bước hạ độ hạt riêng; và 42 vị trí lắp đặt chèn nhau nhiều về quy mô nên mục tiêu phải chuẩn hoá theo từng trạm, nếu không mô hình sẽ dồn sức phân biệt trạm lớn với trạm nhỏ thay vì học quan hệ giữa thời tiết và sản lượng.

8.2.2 Dựng lại lưới thời gian liên tục

Dữ liệu sản lượng thu từ công tơ không phải lúc nào cũng đủ mốc: mất điện, mất kết nối hoặc lỗi ghi đều để lại lỗ hổng trên trục thời gian. Nếu đưa thẳng dữ liệu khuyết mốc vào bước sinh đặc trưng, các biến trễ và biến cửa sổ trượt sẽ tính sai, `lag_4` lẽ ra phải lùi đúng 60 phút thì lại lùi 75 hay 90 phút, tùy vào chỗ bị khuyết.

Notebook `01_reindex_mask_outlier` dựng lại lưới 15 phút liên tục cho từng trạm bằng `pd.date_range`, rồi đánh dấu những dòng vừa được chèn thêm. Thứ tự hai việc này là điều kiện bắt buộc: dựng lưới trước, lọc sau. Nếu lọc bỏ dòng ban đêm hay dòng ngoại lai trước khi dựng lưới, khoảng cách thời gian giữa các dòng còn lại sẽ không đều, và mọi đặc trưng trễ sau đó đều lệch.

Các dòng bị gán cờ ngoại lai ở tầng ETL không bị xoá khỏi lưới. Chúng được giữ nguyên vị trí để lịch sử không bị đứt quãng, nhưng mang nhãn loại trừ nên không đóng góp vào hàm mất mát khi huấn luyện, cũng không tham gia vào các chỉ số được báo cáo.

Ba ràng buộc thiết kế. Bước dựng lưới tuân thủ ba ràng buộc, cùng hướng tới một mục tiêu: không để thông tin của tương lai, hoặc thông tin không có thật, lọt vào lưới dữ liệu.

1. **Thời tiết chỉ được lấp theo chiều tiến.** Chỉ dùng `ffill()` theo từng trạm, tức kéo giá trị đã quan sát trong quá khứ sang hiện tại. Tuyệt đối không dùng `bfill()`, vì kéo ngược là lấy giá trị của mốc sau đắp cho mốc trước — đúng định nghĩa của rò rỉ dữ liệu.
2. **Siêu dữ liệu tĩnh thiếu thì giữ nguyên khuyết.** Các cột như `capacity_kw`, `number_of_panels`, vĩ độ và kinh độ nếu thiếu thì để nguyên khuyết, không lấp và không bịa giá trị.
3. **Điền mục tiêu theo bậc thang nhân quả.** Slot mới chèn được điền theo đúng thứ tự: `night_zero` → `causal_day_persistence` (cùng giờ hôm qua) → `causal_week_persistence` (cùng giờ tuần trước) → `causal_profile_median` → `fallback_zero`. Mọi bậc đều chỉ nhìn về quá khứ. Riêng khoảng trống từ 24 giờ trở lên được xếp vào `machine_failure_zero` và đánh dấu loại khỏi huấn luyện.

Kết quả thực thi. Khối dưới đây trích nguyên văn kết quả kết xuất của notebook `01_reindex_mask_outlier`:

```
Đã reindex lưới 15 phút cho 42 site.
```

```
Tổng số dòng sau reindex: 2784438
```

```
- Dòng gốc: 2731946
```

```
- Dòng inserted: 52492
```

```
Forward-fill thời tiết (causal only, per-site):
```

```
- Số cột thời tiết: 15
```

```
- NaN trước: 812250
```

```
- NaN sau: 1890
```

```
- Đã lấp: 810360 giá trị
```

```
Đã điền target cho 52492 slot inserted.
```

```
--- PHÂN BỐ ENERGY_SOURCE SAU CASCADE ---
energy_source
```


etl_imputed	1536301
measured	1195645
machine_failure_zero	42055
night_zero	6287
causal_day_persistence	2668
fallback_zero	984
causal_profile_median	283
causal_week_persistence	215

--- GATE CHECK ---

- Target null: 0

- Energy_source rỗng: 0

PASS - Không còn target null hoặc energy_source rỗng.

Phân tích kết quả. Sáu nhãn thuộc bậc thang điện — machine_failure_zero, night_zero, causal_day_persistence, fallback_zero, causal_profile_median và causal_week_persistence — cộng lại bằng đúng 52.492, tức đúng số dòng đã chèn. Không dòng nào rơi ra ngoài bậc thang, cũng không dòng nào bị đếm hai lần. Công kiểm ở cuối xác nhận không còn mục tiêu khuyết và không còn energy_source rỗng.

Hạn chế của bước dựng lưới. Trong 52.492 dòng được chèn thì 42.055 dòng rơi vào nhãn machine_failure_zero, tức các khoảng trống từ 24 giờ trở lên, được gán 0 và loại khỏi huấn luyện:

$$\frac{42.055}{52.492} = 0,8012 \rightarrow \mathbf{80,1\%} \quad (8.3)$$

Bốn phần năm phần chèn thêm vì vậy không mang thông tin mới; chúng chỉ giữ chỗ để lưới thời gian không bị đứt. Phần còn lại được điền bằng các bậc suy từ lịch sử thật, gồm $6.287 + 2.668 + 984 + 283 + 215 = 10.437$ dòng, trong đó 6.287 dòng là night_zero — các mốc ban đêm vốn phải bằng 0. Số dòng thực sự được suy từ lịch sử phát điện là $10.437 - 6.287 = 4.150$ dòng.

Một hạn chế nữa: sau khi lấp theo chiều tiến vẫn còn 1.890 ô thời tiết khuyết. Đó là các mốc nằm ở đầu chuỗi của từng trạm, nơi chưa có quan sát quá khứ nào để kéo sang. Chỉ có thể lấp những ô này bằng phép lấp ngược chiều, tức lấy giá trị của mốc sau đắp cho mốc trước, mà phép đó đưa thông tin tương lai vào dữ liệu huấn luyện. Quy trình vì vậy giữ nguyên trạng thái khuyết ở các mốc đó, đổi lấy việc bảo toàn ràng buộc nhân quả. Theo khối kết xuất ở trên, phép lấp theo chiều tiến xử lý được 810.360 trên 812.250 ô khuyết ban đầu, tức $810.360/812.250 = 99,77\%$; phần còn lại là 1.890 ô. LightGBM nhận trực tiếp giá trị khuyết nên phần này không cần điền.

Cách xử lý này phù hợp với kết quả của Kim, Ko và Kim [3]. Nhóm tác giả đánh giá tác động của dữ liệu khuyết tới bài toán dự báo sản lượng quang điện và chỉ ra rằng cách xử lý phần khuyết ảnh hưởng trực tiếp tới sai số của mô hình dự báo, chứ không phải là một bước tiền xử lý trung tính:

“Such missing values deteriorate the PV power generation prediction performance, and they need to be eliminated by filling in other values.”

Từ đó, dự án tách bạch hai việc: dừng lại mốc thời gian để cấu trúc chuỗi không bị đứt, và đánh dấu nguồn gốc từng dòng để phần dữ liệu không đáng tin không lọt vào chỉ số báo cáo. Phạm vi của bài báo và của dự án khác nhau ở một điểm: bài báo khảo sát bốn phương pháp điền khuyết cho dữ liệu khí tượng và kết luận phương pháp k láng giềng gần nhất cho kết quả tốt nhất, trong khi dự án chỉ mượn kết luận tổng quát rằng phần khuyết phải được xử lý có chủ đích.

8.2.3 Phân tích khám phá dữ liệu và các quyết định sinh đặc trưng

Trước khi sinh đặc trưng, dữ liệu được khảo sát ở notebook 02_EDA. Phạm vi khảo sát là **chỉ tập huấn luyện**, sau khi loại hai trạm 19 và 24: còn 1.480.000 dòng của 40 trạm. Đây là điều kiện bắt buộc — các quyết định sinh đặc trưng ở Phần 3 đều rút ra từ bước này, nên nếu khảo sát cả tập test thì tập test đã tham gia vào thiết kế mô hình, trái với nguyên tắc niêm phong nêu ở Mục 7.1.5.

Ba phạm vi con được tách riêng để mọi con số phía sau đều nói rõ nó thuộc phạm vi nào:

Doc vào : 1,550,856 dong x 12 cot | 42 tram
Sau khi bo tram [19, 24]: 1,480,000 dong | 40 tram

toan bo	1,480,000 dong	(100.00%)
ban ngay	742,116 dong	(50.14%)
do that ban ngay	606,112 dong	(40.95%)

Phân bố đơn biến của sản lượng

Bảng 8.9: Thống kê mô tả sản lượng theo ba phạm vi. Đọc từ ô kết quả của notebook 02_EDA.ipynb.


Phạm vi	Số dòng	Trung vị	Độ lệch	Độ nhọn	% bằng 0
Toàn bộ	1.480.000	0,0000	6,0612	47,3723	52,30
Ban ngày	742.116	2,7325	4,5148	25,3908	6,66
Đo thật ban ngày	606.112	3,2188	4,4313	24,5310	0,00

Bảng 8.10: Thống kê mô tả sản lượng theo ba phạm vi. Đọc từ ô kết quả của notebook 02_EDA.ipynb.

Phân bố lệch phải rất mạnh và nhọn: trên toàn bộ tập huấn luyện, độ lệch đạt 6,06 và độ nhọn đạt 47,37, trong khi phân phối chuẩn có cả hai bằng 0. Nguyên nhân trực tiếp là **52,30%**

số quan sát bằng 0, ban đêm và các khung giờ rìa ngày. Trung vị của toàn bộ tập cũng bằng 0, tức quá nửa dữ liệu không mang thông tin phát điện.

Hình 8.5 trình bày ba cách nhìn cùng một phân bố. Lọc về ban ngày kéo độ lệch xuống 4,51 và tỷ lệ giá trị 0 xuống 6,66%; lọc thêm điều kiện đo thật thì không còn giá trị 0 nào. Ba dòng của Bảng 8.10 vì vậy là căn cứ trực tiếp cho hai quyết định: chỉ tính chỉ số báo cáo trên phạm vi đo thật ban ngày, và chuẩn hoá mục tiêu để kéo phân bố về dạng đều hơn.



Hình 8.5: (Trích xuất từ Notebook 02_EDA.ipynb) **Trái:** histogram toàn bộ tập huấn luyện, trục tung thang loga. **Giữa:** chỉ ban ngày. **Phải:** boxplot đối chiếu hai phạm vi.

Mẫu hình phát điện và tác động của mây

Hai dạng ngày cho hai dạng chuỗi khác hẳn nhau. Ngày trời quang cho đường cong trơn dạng parabol; ngày nhiều mây cho chuỗi gãy khúc liên tục. Notebook chọn hai ngày tương phản trên trạm phát mạnh nhất, và chỉ xét những ngày có ít nhất 40 mốc đo thật ban ngày cùng đủ 96 mốc trong ngày, để hình không rơi vào ngày do tăng ETL điền khuyết:

Trạm 27 | 283 ngày đạt điều kiện | 71 ngày nhiều nắng

Ngày trời quang: 2020-10-02 | do gap 0.0031


Ngày nhiều mây : 2020-12-23 | do gap 0.0926

Hai ngày này không được chọn bằng mắt mà bằng một đại lượng đo trực tiếp trên chuỗi sản lượng, gọi là độ gấp: trung bình trị tuyệt đối của sai phân bậc hai trong ngày, chia cho đỉnh của chính ngày đó. Sai phân bậc hai đo mức đổi hướng giữa ba mốc liên tiếp, nên đường càng trơn thì độ gấp càng nhỏ; phép chia cho đỉnh khiến chỉ số không phụ thuộc quy mô trạm. Phép chọn chỉ xét trong nhóm 71 ngày nhiều nắng, nhóm có tổng sản lượng thuộc phần tư trên, rồi lấy ngày độ gấp nhỏ nhất làm ngày trời quang và ngày độ gấp lớn nhất làm ngày nhiều mây. Ràng buộc nhóm là cần thiết: một ngày âm u kéo dài cũng cho đường phẳng lì và độ gấp rất nhỏ, nếu không lọc trước thì nó sẽ bị chọn nhầm thành ngày trời quang.

Hình 8.6 đặt hai ngày cạnh nhau trên cùng thang trục tung. Ngày 02/10/2020 cho một đường cong trơn, lên đều rồi hạ gần đối xứng. Ngày 23/12/2020 đạt đỉnh tương đương nhưng

chỉ giữ được trong ít bước, phần còn lại là chuỗi răng cưa. Độ gấp của hai ngày chênh nhau gần 30 lần: $0,0926/0,0031 = 29,9$.

Cả hai đều thuộc nhóm ngày nhiều nắng, tức lượng bức xạ khả dụng trong ngày tương đương, nhưng cho hai chuỗi khác hẳn. Phần chênh lệch đó là do mây, và mô hình không thể suy ra nó từ lịch hay từ vị trí Mặt Trời. Đây là căn cứ sinh hai đặc trưng `chi_so_troi_quang` và `rad_x_sinelev`: chúng cấp cho mô hình tín hiệu về mức che phủ **ngay tại bước hiện tại**, thay vì bắt mô hình suy ra gián tiếp từ các mốc trễ.



Hình 8.6: (Trích xuất từ Notebook `02_EDA.ipynb`) Sản lượng theo bước 15 phút tại trạm 27, hai ngày dùng chung thang trục tung. **Trái:** ngày trời quang 02/10/2020, độ gấp 0,0031. **Phải:** ngày nhiều mây 23/12/2020, độ gấp 0,0926. Trục hoành là giờ trong ngày, cắt trong khoảng 5–21 giờ vì ngoài khoảng đó sản lượng bằng 0. Số đo của hai ngày kiểm chứng được bằng `srcs/05_machine_learning/kiem_chung_bao_cao_v4.py`, mục 11.

Tự tương quan

Bảng 8.12 ghi tự tương quan của chuỗi sản lượng tại các mốc trễ đáng chú ý.


Bảng 8.11: Tự tương quan của chuỗi sản lượng tại các mốc trễ đáng chú ý, trạm 27, 51.652 bước liên tục. Đọc từ ô kết quả của notebook `02_EDA.ipynb`.

Mốc trễ	Khoảng cách	ACF
<code>lag_1</code>	15 phút	+0,9691
<code>lag_4</code>	1 giờ	+0,9039
<code>lag_96</code>	24 giờ	+0,7138
—	48 giờ	+0,6506
—	72 giờ	+0,6274

Bảng 8.12: Tự tương quan của chuỗi sản lượng tại các mốc trễ đáng chú ý, trạm 27, 42.240 bước liên tục. Đọc từ ô kết quả của notebook `02_EDA.ipynb`.

Con số +0,9680 tại mốc 15 phút là điểm cần đọc kỹ. Ở mức tự tương quan đó, giá trị tại t gần như là bản sao của giá trị tại $t + 1$, nên một mô hình được cấp `lag_1` sẽ có lỗi tất hiển nhiên: lặp lại giá trị vừa đo. Mốc 1 giờ vẫn giữ tương quan cao +0,8942 nhưng đã đủ xa để không còn

là bản sao, còn mốc 24 giờ ở +0,7923 mang thông tin chu kỳ ngày. Hình 8.7 là biểu đồ đầy đủ. Ba con số này là căn cứ định lượng cho lựa chọn trình bày ở Mục 7.3.1.



Hình 8.7: (Trích xuất từ Notebook 02_EDA.ipynb) **Trái:** ACF quét 288 bước = 72 giờ. **Phải:** PACF quét 96 bước = 24 giờ. Vạch đỏ chấm là mốc 96 bước.

Tương quan giữa các biến

Tương quan tính trên 606.112 dòng đo thật ban ngày, xem Bảng 8.14.

Bảng 8.13: Tương quan với sản lượng, tính trên phạm vi đo thật ban ngày, kèm cột đối chiếu khi gộp cả ban đêm. Đọc từ ô kết quả của notebook 02_EDA.ipynb.


Biến	Spearman ban ngày	Gộp cả đêm	Chênh
shortwave_radiation	+0,6043	+0,9024	+0,2981
direct_normal_irradiance	+0,5513	+0,8755	+0,3243
diffuse_solar_radiation	+0,3808	+0,8750	+0,4942
temperature_c	+0,2628	+0,4349	+0,1721
cloud_cover_total	-0,1591	+0,0330	+0,1921

Bảng 8.14: Tương quan với sản lượng, tính trên phạm vi đo thật ban ngày, kèm cột đối chiếu khi gộp cả ban đêm. Đọc từ ô kết quả của notebook 02_EDA.ipynb.

Cột chênh lệch là kết quả đáng chú ý nhất của cả bước khảo sát. Nếu gộp cả ban đêm, tương quan của `shortwave_radiation` với sản lượng vọt từ +0,60 lên +0,90, và `diffuse_solar_radiation` vọt từ +0,38 lên +0,88. Mức tăng đó **không phản ánh quan hệ vật lý**: ban đêm mọi biến bức xạ và sản lượng đều bằng 0 cùng lúc, nên hơn một nửa số điểm nằm chồng tại gốc tọa độ và tự động đẩy hệ số tương quan lên. Ma trận đầy đủ ở Hình 8.8.

Cột `cloud_cover_total` cho thấy rõ nhất: ban ngày nó mang dấu **âm** -0,1591 — đúng ý nghĩa vật lý là mây che thì sản lượng giảm — nhưng gộp cả đêm thì đổi thành dấu dương +0,0330, tức đảo ngược hoàn toàn ý nghĩa. Vì vậy mọi tương quan trong tài liệu này đều tính trên phạm vi đo thật ban ngày.

Chẩn đoán đa cộng tuyến không nằm ở bước này. Hệ số phóng đại phương sai cần toàn bộ đặc trưng đã sinh xong, nên nó được tính ở notebook 04_vif_diagnostics và trình bày



Hình 8.8: (Trích xuất từ Notebook 02_EDA.ipynb) Ma trận tương quan Spearman trên 606.112 dòng đo thật ban ngày.

ở Mục 3.7.

8.2.4 Chia dữ liệu theo trục thời gian

Với bài toán dự báo, phép chia ngẫu nhiên thông thường là sai về nguyên tắc, vì cách chia đó cho phép mô hình học từ dữ liệu của tháng sau rồi đi dự báo tháng trước. Notebook `02_split_time_series` vì vậy cắt dữ liệu **theo thứ tự thời gian**, không xáo trộn.


Trước hết, 15% số mốc thời gian cuối cùng được tách ra làm tập test niêm phong và cất đi. Phần còn lại, gọi là tập Phát triển, mới được dùng để sinh đặc trưng, chọn đặc trưng, tinh chỉnh siêu tham số (*hyperparameter*) và chọn hàm mất mát. Tập test chỉ được mở đúng một lần ở bước đánh giá cuối, sau khi mọi quyết định đã khoá.

Phép cắt thực hiện trên trục mốc thời gian, không phải trên số dòng. Toàn bộ dữ liệu có 81.023 mốc thời gian phân biệt; cắt 15% cuối cho 12.154 mốc thuộc tập test và 68.869 mốc thuộc tập Phát triển. Ranh giới rơi vào 18/12/2021 lúc 09:30:

- **Tập Phát triển** — từ 01/01/2020 00:15 đến 18/12/2021 09:15.
- **Tập test niêm phong** — từ 18/12/2021 09:30 đến 23/04/2022 23:45.

Tỷ lệ 15% tính trên mốc thời gian tương ứng 510.468 dòng trên tổng 2.784.438, tức 18,33% khối lượng dữ liệu. Hai tỷ lệ lệch nhau do số trạm hoạt động tăng dần theo thời gian: đầu năm 2020 có 30 trạm phát sinh dữ liệu, tới cuối năm 2021 đủ 42 trạm, nên mỗi mốc thời gian ở giai đoạn sau mang nhiều dòng hơn giai đoạn trước. Hình 8.9 mô tả cách chia.

Phép cắt theo mốc được chọn thay vì cắt theo số dòng vì nó cho một ranh giới thời gian duy nhất áp dụng chung cho cả 42 trạm. Cắt theo số dòng sẽ khiến mỗi trạm có một mốc cắt riêng và tập test không còn là một giai đoạn liên mạch.



Hình 8.9: (Trích xuất từ Notebook `02_split_time_series.ipynb`) Cách chia dữ liệu theo trục thời gian: tập test niêm phong tách ra từ phần cuối, phần Phát triển còn lại chia thành ba fold theo cửa sổ mở rộng.

8.2.5 Ba fold theo cửa sổ mở rộng

Tập Phát triển được chia thành ba fold theo kiểu cửa sổ mở rộng (*expanding window*): phần huấn luyện của fold sau chứa trọn phần huấn luyện lẫn phần kiểm định của fold trước.

Cách này mô phỏng đúng tình huống vận hành thật, càng về sau càng có nhiều lịch sử để học, và bảo đảm phần kiểm định luôn nằm ở tương lai so với phần huấn luyện.

Phép chia fold cũng thực hiện trên trục mốc thời gian, mỗi fold nhận đúng 17.217 mốc cho phần kiểm định, còn phần huấn luyện nói rộng dần qua 17.218, 34.435 rồi 51.652 mốc.

Bảng 8.15: Ranh giới thời gian, kích thước và số trạm của ba fold, đọc từ các tệp `fold*_train_selected.parquet` và `fold*_val_selected.parquet`.

Fold	Phần huấn luyện			Phần kiểm định		
	đến	số dòng	trạm	đến	số dòng	trạm
1	28/06/2020 08:30	233.244	30	24/12/2020 16:45	606.105	39
2	24/12/2020 16:45	839.349	39	22/06/2021 01:00	711.507	42
3	22/06/2021 01:00	1.550.856	42	18/12/2021 09:15	723.114	42

Bảng 8.16: Ranh giới thời gian, kích thước và số trạm của ba fold, đọc từ các tệp `fold*_train_selected.parquet` và `fold*_val_selected.parquet`.

Nhìn Bảng 8.16 thấy rõ tính chất mở rộng: mốc kết thúc huấn luyện của fold 2 trùng đúng mốc kết thúc kiểm định của fold 1, và tương tự giữa fold 3 với fold 2. Kích thước tập huấn luyện tăng dần từ 233 nghìn lên 1,55 triệu dòng, trong khi tập kiểm định giữ quy mô tương đương nhau, khoảng 600–720 nghìn dòng.

Vì sao chọn cửa sổ mở rộng thay vì cửa sổ trượt. Hai cách chia đều tôn trọng trục thời gian, khác nhau ở chỗ xử lý dữ liệu cũ. Cửa sổ mở rộng giữ lại toàn bộ quá khứ: tập huấn luyện của fold sau chứa trọn tập huấn luyện của fold trước cộng thêm phần kiểm định của nó, nên bề rộng lớn dần, ở đây là 233 nghìn rồi 839 nghìn rồi 1,55 triệu dòng. Cửa sổ trượt giữ bề rộng cố định và đẩy cả hai đầu về phía trước, tức mỗi lần tiến một bước thì cắt bỏ một đoạn đầu tương ứng.

Ba lý do khiến cửa sổ mở rộng phù hợp với bài toán này. Thứ nhất, dữ liệu chỉ trải hơn hai năm trong khi chu kỳ chi phối sản lượng là chu kỳ mùa dài đúng một năm; cửa sổ trượt với bề rộng cố định sẽ khiến fold đầu tiên chỉ nhìn thấy vài tháng, không đủ trọn một vòng mùa để học được dạng đường cong ngày của cả mùa hè lẫn mùa đông. Thứ hai, các trạm lần lượt đi vào vận hành theo thời gian, từ 30 trạm ở fold 1 lên 42 trạm ở fold 3; cắt bỏ đoạn đầu đồng nghĩa vứt luôn phần lịch sử sớm của những trạm vận hành trước, trong khi đó lại chính là phần dữ liệu dài nhất của chúng. Thứ ba, quan hệ giữa bức xạ và sản lượng của tấm quang điện là quan hệ vật lý, không đổi nhanh theo thời gian, nên dữ liệu cũ vẫn còn giá trị mô tả.

Cửa sổ trượt sẽ là lựa chọn tốt hơn khi hệ thống có trôi khái niệm mạnh, chẳng hạn thay tấm pin, đổi biến tần hay đổi cấu hình lắp đặt, vì khi đó dữ liệu cũ mô tả một hệ thống khác và trở thành nhiễu. Bộ dữ liệu này không có sự kiện như vậy.

Đánh đổi phải chấp nhận là ba fold không cùng cỡ tập huấn luyện, nên sai số của từng fold không so trực tiếp với nhau được: fold 1 vừa ít dữ liệu vừa vướng vấn đề trạm mới nêu ngay

dưới đây. Vì vậy tài liệu chỉ dùng WAPE gộp ba fold để xếp hạng cấu hình, không đọc riêng con số của một fold.

Hạn chế: fold sớm có trạm chưa từng xuất hiện khi huấn luyện. Cột số trạm trong Bảng 8.16 cho thấy một hệ quả trực tiếp của việc các trạm lần lượt đi vào vận hành theo thời gian. Ở fold 1, mô hình học trên 30 trạm nhưng bị chấm điểm trên 39 trạm; ở fold 2 là 39 trạm so với 42. Chênh lệch đó nghĩa là một phần dữ liệu kiểm định thuộc về những trạm mà mô hình chưa từng nhìn thấy một dòng nào lúc huấn luyện. Tới fold 3 thì cả 42 trạm đều đã có mặt ở phần huấn luyện nên tình huống này không còn.

Ảnh hưởng của nó làm sai số đo trên fold 1 và fold 2 bị quan hơn thực tế vận hành, vì trong vận hành thật mô hình luôn đã có lịch sử của trạm mà nó dự báo. Chiều ảnh hưởng là an toàn, sai số bị đánh giá nặng hơn chứ không nhẹ đi, nhưng khi so sánh các cấu hình bằng WAPE gộp ba fold thì phần đóng góp của fold 1 vẫn mang theo thành phần sai lệch này.

8.2.6 Thực nghiệm: đo phần chồng lấn nhãn ở ranh giới fold

Ba fold được cắt liên tục, không chèn khoảng đệm giữa phần huấn luyện và phần kiểm định. Hai quy tắc chống rò rỉ nêu ở Mục 7.1.4 chỉ ràng buộc đặc trưng đầu vào; riêng nhãn cần một phép kiểm riêng. Nhãn của một dòng huấn luyện là sản lượng tại $T + h$, nên với những dòng nằm sát mốc cắt, thời điểm $T + h$ có thể đã rơi sang vùng kiểm định. Nhóm đo trực tiếp phần chồng lấn này.

Cách tiến hành. Với mỗi fold, đọc trực tiếp tệp `fold_i_train_selected.parquet`, lấy mốc thời gian lớn nhất $T_{\max}$ của phần huấn luyện. Một dòng có nhãn rơi sang vùng kiểm định khi và chỉ khi mốc thời gian của dòng đó lớn hơn $T_{\max} - 15h$ phút, với h là số bước của tầm dự báo. Đếm số dòng thỏa điều kiện đó cho cả hai tầm H1 và H4. Phép đo chạy trên chính các tệp fold mà bước huấn luyện đọc vào, không dùng dữ liệu trung gian nào khác.

Bảng 8.17: Số dòng huấn luyện có nhãn rơi sang vùng kiểm định, tính trên từng fold và từng tầm dự báo. Đọc từ ô kết quả của notebook

05b_thuc_nghiem_tham_so_hardcode.ipynb, Thí nghiệm 9.

Fold	Cỡ tập huấn luyện	Chồng lấn H1	Chồng lấn H4	Tỷ lệ H4
1	233.244	30	120	0,0514%
2	839.349	39	156	0,0186%
3	1.550.856	42	168	0,0108%

Bảng 8.18: Số dòng huấn luyện có nhãn rơi sang vùng kiểm định, tính trên từng fold và từng tầm dự báo. Đọc từ ô kết quả của notebook

05b_thuc_nghiem_tham_so_hardcode.ipynb, Thí nghiệm 9.

Trường hợp xấu nhất là fold 1 ở tầm H4: 120 dòng trên 233.244, tức **0,0514%**. Tỷ lệ nhỏ như vậy là hệ quả cấu trúc của phép cắt, chỉ những dòng nằm trong h bước cuối cùng của tập

huấn luyện mới có nhãn vượt sang vùng kiểm định, mà h nhiều nhất là bốn bước.

Bảng 8.18 tự kiểm chứng được. Ở tầm H1 chỉ một bước cuối bị chòng lún, nên số dòng phải bằng số trạm còn hoạt động tại bước đó: cột chòng lún H1 cho 30, 39 và 42, trùng khít cột số trạm ở Bảng 8.16. Cột H4 gấp đúng bốn lần các giá trị đó.

Với mức chòng lún dưới một phần nghìn ở cả ba fold, phép cắt liên tục được giữ nguyên, không chèn khoảng đệm.

8.3 Sinh đặc trưng

Ba notebook liên tiếp bổ sung đặc trưng vào cùng một khung dữ liệu, mỗi notebook phụ trách một họ: `03_1_features_time` sinh đặc trưng suy từ trục thời gian và từ lịch sử sản lượng, `03_2_features_spatial` sinh đặc trưng hình học Mặt Trời cùng các đại lượng chuẩn hoá theo trạm, `03_3_features_aggregate` sinh đặc trưng tương tác khí tượng và mã hoá biến phân loại. Hai notebook sau đó thu hẹp lại: `04_vif_diagnostics` chẩn đoán đa cộng tuyến, `05_select_features` chốt danh sách chính thức.

8.3.1 Đặc trưng thời gian, trễ và cửa sổ trượt

Notebook `03_1_features_time` sinh ba nhóm đặc trưng, tóm tắt ở Bảng 8.20.

Bảng 8.19: Ba nhóm đặc trưng sinh tại notebook `03_1_features_time.ipynb`. Cột cuối ghi tham số thực tế khai báo trong notebook.

Nhóm	Cột sinh ra	Tham số
Lịch và chu kỳ	<code>minute_of_day, month, day_of_week, is_weekend, season, season_code, hour_sin, hour_cos, doy_sin, doy_cos</code>	chu kỳ ngày 1440 phút; chu kỳ năm 365,25 ngày
Trễ	<code>lag_4, lag_96</code>	$LAGS = (4, 96)$, tức $T - 60$ phút và $T - 24$ giờ
Cửa sổ trượt	<code>rolling_mean, rolling_std, rolling_min, rolling_max</code> cho mỗi cửa sổ	$ROLLING_WINDOWS = (4, 96)$, bốn thống kê mỗi cửa sổ

Bảng 8.20: Ba nhóm đặc trưng sinh tại notebook `03_1_features_time.ipynb`. Cột cuối ghi tham số thực tế khai báo trong notebook.

Hai nhóm sau tạo ra 2 cột trễ cộng 8 cột cửa sổ trượt, bằng 10 cột suy từ chuỗi mục tiêu, đúng con số notebook in ra khi khai báo hàm sinh đặc trưng.

Mã hoá lịch bằng sin và cos. Nếu đề giờ trong ngày ở dạng số nguyên, mốc 23:45 và mốc 00:00 cách nhau đúng một bước 15 phút trên thực tế nhưng cách nhau 23 đơn vị trên thang số.

Cây quyết định chia theo ngưỡng sẽ coi hai mốc liền kề đó là hai vùng xa nhau. Cặp (sin, cos) đưa trục thời gian về một vòng tròn khép kín, nên khoảng cách giữa hai mốc kề nhau qua nửa đêm trở lại đúng bằng khoảng cách thật. Cùng lý do, ngày trong năm được mã hoá bằng `day_sin` và `day_cos` theo chu kỳ 365,25 ngày.

Thực nghiệm: chọn mốc trễ

Khái niệm nền. *Persistence* là mô hình dự báo cơ sở: lấy giá trị quan sát tại t làm dự báo cho $t + h$. Dev và cộng sự [8] định nghĩa nó là phương pháp *giả định điều kiện tại thời điểm dự báo không thay đổi so với thời điểm quan sát*, và ghi nhận rằng cách này *chạy tốt* ở các tầm dự báo ngắn, khi điều kiện thời tiết biến thiên chậm:

“The persistence forecasting method assumes that the conditions for the forecast do not change (especially for shorter lead times). This method works well in conditions when weather maps change very slowly with time.”

Từ định nghĩa trên suy ra một hệ quả đại số mà bài báo không nêu: nếu $\hat{y}(t + h) = y(t)$ thì đường dự báo chính là đường đo thật dịch phải h bước, tức lệch pha đúng bằng tầm dự báo. Mặt khác, vì chuỗi biến thiên chậm ở tầm ngắn, đúng điều kiện mà bài báo nói *persistence* chạy tốt, nên hiệu giữa $y(t)$ và $y(t + h)$ nhỏ, và một chỉ số sai số tính theo từng điểm vẫn cho con số đẹp.

Tầm H1 của dự án đúng bằng 15 phút, nằm trọn trong vùng đó. Một mô hình lặp lại giá trị vừa đo sẽ cho chỉ số sai số tốt nhưng đường dự báo trễ một nhịp, con số đẹp ở đây không chứng minh năng lực dự báo.

Giả thuyết. Mốc trễ càng gần thời điểm dự báo thì tín hiệu càng mạnh, nhưng cũng càng dễ kéo mô hình về đúng dạng vừa nêu. Thực nghiệm này xác định mốc trễ nào được đưa vào.

Cách tiến hành. Ba cấu hình được đối chiếu trên cùng dữ liệu và cùng quy trình tính chỉnh: cấu hình nền chỉ có `lag_96` ($T - 24$ giờ), cấu hình thêm `lag_1` ($T - 15$ phút), và cấu hình thêm `lag_4` ($T - 60$ phút). Mỗi cấu hình được chấm bằng WAPE và một phép đo lệch pha riêng: độ trễ trung bình giữa đường dự báo và đường đo thật trên từng trạm, kèm số trạm vượt ngưỡng cho phép. Ba mốc đã thử ghi ở Bảng 8.22.

Độc kết quả. Quyết định phân biệt `lag_1` với `lag_4` không dựa vào sai số mà dựa vào lệch pha. Nếu chỉ nhìn WAPE thì `lag_1` sẽ được chọn, vì nó cho con số thấp nhất, đúng như hệ quả đại số nêu ở đầu mục. Dự án chốt `LAGS = (4, 96)` và loại `lag_1`.

Cần nêu rõ giới hạn của bằng chứng này: notebook ghi lại quyết định và căn cứ định tính, không lưu một phép đối chứng có kiểm soát giữa ba cấu hình trên cùng một lần chạy. Bằng chứng định lượng cho cấu hình được chọn nằm ở công lệch pha trình bày ngay sau đây.

Bảng 8.21: Ba mốc trễ đã được thử và quyết định tương ứng, ghi tại ô khai báo LAGS của notebook 03_1_features_time.ipynb.

Mốc trễ	Quyết định	Căn cứ ghi trong notebook
lag_96 ($T - 24$ giờ)	giữ	Chu kỳ ngày; xa thời điểm dự báo nên không tạo lệch pha
lag_1 ($T - 15$ phút)	loại	Gây lệch pha trên gần như toàn bộ đội hình; sai số theo từng điểm giảm nhưng là hệ quả của việc lặp lại giá trị vừa đo
lag_4 ($T - 60$ phút)	giữ	Đủ xa để không lặp lại được giá trị vừa đo, vẫn đủ gần để mang thông tin quán tính; qua được công lệch pha ở Mục 7.3.1

Bảng 8.22: Ba mốc trễ đã được thử và quyết định tương ứng, ghi tại ô khai báo LAGS của notebook 03_1_features_time.ipynb.

Công lệch pha đặt trước bước tính chỉnh

Phép đo lệch pha được đặt thành một công chặn ở đầu notebook huấn luyện: chỉ khi công đặt thì quy trình mới được phép chạy Optuna và huấn luyện thật.

Độ trễ suy từ quan hệ giữa sai số và độ dốc của đường đo thật. Nếu đường dự báo bị dịch c bước thì sai số xấp xỉ $-c$ nhân với độ dốc, nên hệ số hồi quy của sai số theo độ dốc chính là c :

$$\text{độ trễ (phút)} = -\frac{\sum_t d_t e_t}{\sum_t d_t^2} \times 15, \quad d_t = \frac{y_{t+1} - y_{t-1}}{2}, \quad e_t = \hat{y}_t - y_t. \quad (8.4)$$

Cách này tách sai số biên độ khỏi sai số thời điểm: dự báo cao hơn hay thấp hơn thực tế đều không làm đổi con số, chỉ việc đến sớm hay đến muộn mới làm đổi.

Ngưỡng và kết quả. Công yêu cầu độ trễ nằm trong ± 5 phút và không trạm nào vượt ngưỡng. Kết quả in ra ở notebook 06_1_train_mae:

TRAIN THU NHANH DE DO TRE (truoc khi tune)

Train thu 300,000 dong x 54 dac trung trong 9.3 giay

TREN 288,735 diem ban ngay cua tap test:

Do tre : +2.46 phut (duong = du bao di SAU thuc te)

Nguong cho phep: +/- 5.0 phut

WAPE tham khao : 22.47% (model nho, chua tune - chi de doi chieu)

Site vuot nguong: 0/40

Tre theo site: trung vi +2.79 phut | nho nhat +1.64 | lon nhat +3.71

CONG DO TRE: DAT - tre +2.46 phut, khong site nao vuot nguong.

Cho phép chạy Optuna và train thật.

Mô hình dùng ở cổng. Cổng chạy trên một mô hình nháp, cùng thuật toán và cùng hàm mất mát với mô hình cuối nhưng nhỏ hơn nhiều, xem Bảng 8.23.

Bảng 8.23: Mô hình nháp dùng ở cổng lệch pha so với mô hình cuối. Đọc từ ô cấu hình cổng lệch pha trong notebook `06_1_train_mae.ipynb`.

	Mô hình nháp (cổng)	Mô hình cuối
Thuật toán	LightGBM	LightGBM
Hàm mất mát	11 (MAE)	11 (MAE)
Số đặc trưng	54	54
Trọng số mẫu	có	có
Quy mô tập đầu vào	300.000 lấy ngẫu nhiên	1.550.856
Số cây	200, đặt cố định	Optuna chọn
Tốc độ học	0,08, đặt cố định	Optuna chọn
<code>num_leaves</code>	63, đặt cố định	Optuna chọn
Thời gian huấn luyện	9,3 giây	hàng chục phút

Vì thuật toán, hàm mất mát và danh sách đặc trưng giống hệt mô hình cuối, cổng kiểm được đúng thứ nó cần kiểm: **bộ đặc trưng có đẩy mô hình vào hành vi bám trụ hay không**. Nếu `lag_1` có mặt thì mô hình nháp cũng sao chép giá trị gần nhất y như mô hình cuối.

Ngưỡng là ± 5 phút và không trạm nào được vượt. Đo trên 288.735 điểm ban ngày, độ trễ là +2,46 phút, trung vị theo trạm +2,79 phút, dao động từ +1,64 đến +3,71, và 0/40 trạm vượt ngưỡng, nên cổng đạt. Cổng này đặt trước bước tinh chỉnh nên chỉ kiểm bộ đặc trưng; sau khi Optuna chọn xong siêu tham số (*hyperparameter*), notebook chạy tiếp một phép quét độ trễ thứ hai trên toàn bộ tập kiểm định, trình bày ở phần đánh giá.

Rào chắn chống rò rỉ và ngữ cảnh lùi

Bước sinh đặc trưng đặt hai rào chắn. Một, mọi đặc trưng suy từ mục tiêu đều được dịch: các cột cửa sổ trượt tính trên chuỗi mục tiêu đã dịch một bước, nên giá trị tại T không bao giờ chứa sản lượng đo tại chính T . Hai, một mặt nạ lịch sử liên tục kiểm tra toàn bộ số bước của cửa sổ liền trước đều cách nhau đúng 15 phút; cửa sổ vắt qua chỗ đứt gãy thì bị gán khuyết thay vì tính bừa trên hai đoạn không liên nhau.

Ngữ cảnh lùi giải quyết về còn lại: mỗi tập được nối thêm lịch sử của tập liền trước trước khi tính đặc trưng, rồi chỉ xuất phần dòng thuộc chính tập đó. Tập test dùng toàn bộ tập Phát triển làm ngữ cảnh, tập kiểm định dùng tập huấn luyện, và phần kiểm định của mỗi fold dùng phần huấn luyện của chính fold đó. Nhờ vậy dòng đầu tiên của mỗi tập vẫn có đủ lịch sử, mà mỗi fold vẫn là một thí nghiệm khép kín.

Kết quả thực thi. Dưới đây trích nguyên văn kết quả kết xuất của notebook 03_1_features_time:

So đặc trưng target sẽ tạo: 2 lag + 8 rolling = 10 cột

Đã sinh đặc trưng thời gian cho development và test (đã ghi file và giải phóng RAM).

- development: 2273970 dòng x 74 cột
- test : 510468 dòng x 75 cột

Đã sinh đặc trưng thời gian cho train/val (đã ghi file và giải phóng RAM).

- train_alias: 1550856 dòng x 75 cột
- val_alias : 723114 dòng x 75 cột

```
fold_1: train 233244 dòng | val 606105 dòng | 76 cột
fold_2: train 839349 dòng | val 711507 dòng | 76 cột
fold_3: train 1550856 dòng | val 723114 dòng | 76 cột
```

Số lượng NaN trong các tập:

- Train: 21000 (Đã dropna ở bước 7)
- Val: 0
- Test: 0

0 điểm đứt gãy - lưới thời gian liên tục 100% nhờ Reindex Notebook 01.
(Tổng số dòng: 1550856)

Ô khuyết chỉ xuất hiện ở tập huấn luyện, tại các dòng đầu chuỗi chưa đủ 96 bước lịch sử để tính cửa sổ dài. Tập kiểm định và tập test không còn ô khuyết nào nhờ ngữ cảnh lùi.

8.3.2 Solar geometry, bức xạ trời quang và chuẩn hoá theo trạm


Notebook 03_2_features_spatial sinh nhóm đặc trưng suy từ vị trí Mặt Trời, còn 03_3_features_aggregate sinh nhóm tương tác khí tượng và mã hoá biến phân loại. Cả hai nhóm đều là **hàm xác định của thời gian và vị trí** hoặc là tổ hợp của các biến đã có, nên không mang rủi ro rò rỉ.

Vị trí Mặt Trời theo thuật toán NOAA

Góc cao h và góc phương vị được tính theo thuật toán vị trí Mặt Trời chuẩn của NOAA — chuỗi Fourier cho độ xích vĩ, phương trình thời gian và góc giờ. Đây là công cụ tham chiếu chính thức, xem Hình 8.10.

Ba chi tiết cài đặt đáng nêu, tóm tắt ở Bảng 8.24.

Cách cắt mùa theo nguyên tháng là một xấp xỉ: giờ mùa hè ở Úc bắt đầu Chủ nhật đầu tiên của tháng 10 và kết thúc Chủ nhật đầu tiên của tháng 4, nên vài ngày đầu hai tháng đó nhận độ lệch chênh một giờ, khoảng 12 ngày mỗi năm.



Hình 8.10: NOAA Solar Calculator của Global Monitoring Laboratory — công cụ chính thức tính vị trí Mặt Trời mà hàm `ting_goc_mat_troi` của dự án dựa theo.

Chi tiết	Trong mã nguồn	Lý do
Quy đổi về giờ UTC	<code>utc = ts - tz_gio</code> , với <code>tz_gio</code> bằng 11 cho tháng 10–3 và 10 cho tháng 4–9	Mốc trong dữ liệu là giờ địa phương của Úc , còn công thức thiên văn cần giờ UTC. Úc áp dụng giờ mùa hè nên độ lệch đổi theo mùa
Góc phương vị	<code>np.arctan2(...)</code> thay cho <code>arccos</code>	<code>arccos</code> chỉ trả về miền $[0^\circ; 180^\circ]$ nên không phân biệt được buổi sáng với buổi chiều; <code>atan2</code> liên tục trên trọn vòng 360°
Dạng vòng của góc	<code>azimuth_sin</code> , <code>azimuth_cos</code>	Góc đo bằng độ gián đoạn ở mốc 0° và 360° : 359° và 1° kề nhau thực tế nhưng cách xa trên thang số

Bảng 8.24: Ba chi tiết cài đặt của bước solar geometry.

Bức xạ trời quang theo mô hình Haurwitz

GHI (*Global Horizontal Irradiance*) là tổng bức xạ Mặt Trời chiếu xuống một mặt phẳng nằm ngang, đơn vị W/m^2 . Nó gồm hai thành phần cộng lại: phần trực xạ đi thẳng từ đĩa Mặt Trời và phần khuếch tán do bầu khí quyển và mây tán xạ. Trong dữ liệu của dự án, hai đại lượng này nằm ở hai cột khác nhau và không được lẫn:

- `shortwave_radiation` — GHI **đo được thực tế**, do Open-Meteo cung cấp.
- `ghi_cs` — GHI_{cs} , giá trị lý thuyết khi trời hoàn toàn quang, do nhóm **tự tính** bằng mô hình Haurwitz từ góc cao Mặt Trời.

Vì GHI_{cs} ứng với điều kiện không mây, nó là mức trần mà bức xạ đo được chỉ có thể tiệm cận chứ không nên vượt qua.

Từ góc cao suy ra bức xạ ngang trời quang:

$$GHI_{cs} = 1098 \times \sin(h) \times \exp\left(-\frac{0,059}{\sin(h)}\right) \quad (\text{W/m}^2) \quad (8.5)$$

Cặp hằng số 1098 và 0,059 lấy đúng bản cài đặt Haurwitz của thư viện `pvlib`, vốn dẫn về hai bài gốc của Haurwitz [5]. Phần tóm tắt của bài báo nguồn phát biểu dạng công thức như sau:

“These relations are of the form $T = (a/m)e^{-bm}$ where $m = \text{air mass (i.e. secant of zenith distance of the sun)}$, $e = \text{base of natural logarithms}$, a and b are constants which depend on the cloudiness and cloud density.”

Mô hình trời quang thuần thiên văn ước lượng thiếu so với bức xạ đo tại các trạm, nên GHI_{cs} được nhân thêm hệ số hiệu chỉnh riêng từng trạm, đặt tên `cs_factor`. Hệ số này **tính riêng trên phần huấn luyện của từng fold**, xem Bảng 8.26.

Bảng 8.25: Hệ số hiệu chỉnh trời quang `cs_factor` theo từng fold. Đọc từ ô kết quả của notebook `03_2_features_spatial.ipynb`.

Phạm vi tính	Trung vị	Nhỏ nhất	Lớn nhất
Phần huấn luyện fold 1	1,460	1,105	1,827
Phần huấn luyện fold 2	1,538	1,520	1,819
Phần huấn luyện fold 3	1,557	1,541	1,809

Bảng 8.26: Hệ số hiệu chỉnh trời quang `cs_factor` theo từng fold. Đọc từ ô kết quả của notebook `03_2_features_spatial.ipynb`.

Giá trị đổi rõ giữa các fold, trung vị từ 1,460 lên 1,557, nên việc dùng chung một bộ thống kê cho cả ba fold sẽ đưa thông tin của giai đoạn sau vào fold sớm. Notebook ghi thẳng nguyên tắc này ở ô kết quả: *mỗi fold dùng thống kê quy mô tính riêng từ tập train của chính fold đó*.

Thực nghiệm: hạ độ hạt bức xạ từ một giờ về mười lăm phút

Vấn đề. Dữ liệu khí tượng có tần suất một giờ, còn lưới sản lượng có tần suất 15 phút, nên mỗi giá trị bức xạ lặp lại bốn lần liên tiếp: trong một giờ, đặc trưng bức xạ không phân biệt được mốc 12:00 với mốc 12:15.


Nguyên lý. Bailey và cộng sự [6] mô tả thuật toán của Graham và Hollands (1990): tách chỉ số trời quang theo giờ k_t thành mô hình cộng $k_t = k_{tm} + \alpha$ gồm thành phần xu thế và thành phần nhiễu. Điểm cốt lõi là hạ độ hạt của chỉ số trời quang chứ không phải bức xạ, vì bức xạ mang cả biến thiên nhật triều, còn chỉ số trời quang thì không.

Dự án giữ đúng thành phần xu thế k_{tm} , giữ chỉ số trời quang không đổi trong mỗi khối giờ rồi nhân lại với GHI_{cs} tính ở từng mốc 15 phút, và bỏ thành phần nhiễu α , vì α dùng để sinh chuỗi tổng hợp, còn ở đây bức xạ là đặc trưng đầu vào cho mô hình dự báo.

Kết quả đo. Thước đo là tỷ lệ bước có giá trị bức xạ thay đổi so với bước liền trước, tính riêng trên các dòng ban ngày. Khối kết quả của notebook:

```
--- TY LE BUOC CO GIA TRI BUC XA THAY DOI, TOAN TAP TRAIN (CHI BAN NGAY) ---
So dong ban ngay: 751,408 / 1,550,856 (48.5%)
Truoc downscale : 26.7%
Sau downscale : 76.7%
Muc tieu la tren 90 phan tram.
[CANH BAO] Chua dat 90 phan tram,kiem lai buoc downscale.
```

Tỷ lệ tăng gần ba lần, từ 26,7% lên 76,7%. Hình 8.11 cho thấy hiệu quả trên một cửa sổ sáu giờ.



Hình 8.11: (Trích xuất từ Notebook 03_2_features_spatial.ipynb) Bức xạ tại trạm 1, ngày 19/12/2020, từ 11 giờ đến 17 giờ. **Trên:** dữ liệu gốc theo giờ, mỗi giá trị lặp bốn lần nên đường đi thành bậc thang. Dưới: sau khi hạ độ hạt, đường biến thiên theo từng bước 15 phút.

Chuẩn hoá quy mô theo trạm

Bốn mươi hai dàn quang điện có quy mô rất khác nhau, nên quy mô được ước lượng từ chính dữ liệu và **chỉ từ phần huấn luyện**: `site_scale` là phân vị 99 của sản lượng ban ngày, `tran_cong_suat` là phân vị 99,9. Bảng 8.28 trích tám trạm đầu trong bảng notebook in ra.

Bảng 8.27: Quy mô trạm tính trên tập huấn luyện, tám trạm lớn nhất. Đọc từ ô kết quả của notebook 03_2_features_spatial.ipynb.

Trạm	site_scale	tran_cong_suat	cs_factor
27	97,19	99,00	1,55
11	92,05	92,72	1,74
25	79,73	82,42	1,55
19	41,73	42,80	1,55
18	35,04	36,21	1,55
6	27,53	28,51	1,74
8	26,50	26,89	1,74
1	21,50	22,73	1,70

Bảng 8.28: Quy mô trạm tính trên tập huấn luyện, tám trạm lớn nhất. Đọc từ ô kết quả của notebook 03_2_features_spatial.ipynb.

Một mô hình học thẳng trên sản lượng thô sẽ dành phần lớn sức mô tả để phân biệt trạm lớn với trạm nhỏ, thay vì học quan hệ giữa thời tiết và sản lượng, đó là lý do mục tiêu được chuẩn hoá trước khi huấn luyện.

Tương tác khí tượng và mã hoá biến phân loại

Notebook 03_3_features_aggregate sinh năm đặc trưng tương tác, xem Bảng 8.30.

Bảng 8.29: Năm đặc trưng tương tác, tỷ lệ khuyết trên tập huấn luyện và tương quan Pearson với mục tiêu tính trên 763.740 dòng ban ngày. Đọc từ ô kết quả của notebook 03_3_features_aggregate.ipynb.

Đặc trưng	Định nghĩa	Khuyết	Pearson
temp_x_shortwave	nhiệt độ $\times$ bức xạ ngang	0,01%	0,3487
diffuse_ratio	bức xạ khuếch tán / bức xạ ngang	47,43%	-0,2350
dni_ratio	bức xạ trực xạ / bức xạ ngang	47,43%	0,2350
cloud_x_shortwave	mây toàn phần $\times$ bức xạ ngang	0,01%	0,1921
cloud_low_x_shortwave	mây tầng thấp $\times$ bức xạ ngang	0,01%	0,1650

Bảng 8.30: Năm đặc trưng tương tác, tỷ lệ khuyết trên tập huấn luyện và tương quan Pearson với mục tiêu tính trên 763.740 dòng ban ngày. Đọc từ ô kết quả của notebook 03_3_features_aggregate.ipynb.

Tỷ lệ khuyết 47,43% (735.612 dòng) của hai đặc trưng dạng thương đến từ mẫu số: ban đêm bức xạ ngang bằng 0 nên phép chia không xác định. Giá trị khuyết được giữ nguyên thay vì điền 0, để mô hình cây học nhánh riêng cho dữ liệu khuyết. Số giá trị vô cực trên cả năm cột bằng 0.

Mã hoá biến phân loại. Bảng mã được khớp chỉ trên phía huấn luyện rồi áp cho phía kiểm định; notebook khớp được 8 bảng mã, và số ô gặp hạng mục lạ trên tập kiểm định bằng 0.

Kiểm chứng cuối bước sinh đặc trưng. Notebook in ra ba phép kiểm:

```
--- KIEM TRA 1: dac trung target deu duoc shift ---
Cot lag con lai sau khi khu tre pha: ['lag_4', 'lag_96']
lag_96(t) == target(t-96) tren mau: DAT
--- KIEM TRA 2: ty le dong co lich su day du ---
- train      : 99.74% dong co du lich su lien tuc
- val        : 100.00% dong co du lich su lien tuc
--- KIEM TRA 3: hang muc la (unseen category) ---
Tong so o gap hang muc la trong val: 0
```

Sau ba notebook sinh đặc trưng, tập huấn luyện đi từ 50 cột lên 114 cột, trong đó 46 cột là đặc trưng ứng viên; các fold mang 115 cột do có thêm cột đánh dấu fold.

8.3.3 Định nghĩa các đặc trưng dẫn xuất

Một số cột xuất hiện trong bảng chẩn đoán và bảng chấm điểm ở Mục 7.3.7 là đại lượng dẫn xuất, không đọc thẳng từ dữ liệu nguồn. Bảng 8.32 ghi công thức của chúng.

Hai cột `con_cach_tran` và `clearsky_proxy` được sinh ra ở bước đặc trưng nhưng **không lọt vào bộ được chọn**: `clearsky_proxy` tương quan 0,9973 với `sin_elevation` nên mang thông tin trùng lặp, còn `con_cach_tran` không đạt ngưỡng thông tin tương hỗ.

Một đính chính về tên gọi. Tên `chi_so_troi_quang` gợi ý rằng giá trị 1,0 tương ứng trời hoàn toàn quang. Phép kiểm chứng cho thấy điều đó không đúng với cột này: sau khi GHI_{cs} đã nhân hệ số hiệu chỉnh theo trạm, tỷ lệ đo được không đạt tới 1,0 ngay cả vào lúc quang nhất giữa trưa, giá trị lớn nhất ở nhóm góc cao 50–90° chỉ đạt 0,760. Vì vậy tài liệu này không mô tả nó như một chỉ số trời quang có ý nghĩa vật lý trực tiếp, mà gọi đúng bản chất là biến tỷ lệ bức xạ đã hiệu chỉnh theo từng trạm. Nó vẫn hữu ích làm đặc trưng đầu vào vì thứ tự giữa các quan sát trong cùng một trạm được bảo toàn, mà cây quyết định chỉ dùng thứ tự để tách nhánh.

Về cột `pv_clr_lonij`. Dự án có cài đặt chỉ số K của Lonij đúng nguyên bản — phân vị 80, cửa sổ trượt 15 ngày theo từng khung giờ, có `shift(1)` nên chỉ nhìn quá khứ — thành cột `pv_clr_lonij`. Cột này đạt điểm quan trọng biến 1,959, đứng hạng 6 trong bảng chẩn đoán ở Mục 3.7, nhưng không lọt Top 35 theo thông tin tương hỗ và không nằm trong danh sách bảo vệ, nên bị loại ở bước chọn theo đúng quy tắc đã đặt trước.

Cột này nối trực tiếp với lập luận về mức phân vị ở Mục 7.3.5: dự án cài cả phương án phân vị 80 của Lonij lẫn phương án phân vị 99 của mình, rồi để bước chấm điểm quyết định bằng số liệu thay vì chọn trước bằng lập luận.

Bảng 8.31: Công thức các đặc trưng dẫn xuất. Đọc từ mã nguồn notebook 03_2_features_spatial.ipynb và 03_3_features_aggregate.ipynb.

Đặc trưng	Công thức	Ý nghĩa
ky_vong	$\text{site_scale} \times \max(\sin h, 0)$	Mức sản lượng kỳ vọng của trạm tại góc cao hiện tại, nếu trời hoàn toàn quang
ty_le_bao_hoa	$\text{clip}\left(\frac{\text{ky_vong}}{\text{tran_cong_suat}}, 0, 3\right)$	Mức kỳ vọng đã tiến sát trần công suất tới đâu
con_cach_tran	$\text{tran_cong_suat} - \text{ky_vong}$	Khoảng dư còn lại tới trần, tính bằng kWh
rad_x_sinelev	$\text{shortwave_radiation} \times \sin h$	Bức xạ chiếu hiệu dụng lên mặt phẳng ngang
clearsky_proxy	$(\sin h)^{1,2}$	Dạng đường cong ngày thuần hình học, nhọn hơn $\sin h$ một chút
chi_so_troi_quang	$\text{clip}\left(\frac{\text{shortwave_radiation}}{\text{ghi_cs}}, 0, 1,5\right)$	Tỷ lệ bức xạ đo được trên bức xạ trời quang đã hiệu chỉnh theo trạm
temp_x_shortwave	$\text{temperature_c} \times \text{shortwave_radiation}$	Tương tác nhiệt độ và bức xạ
diffuse_ratio	$\text{clip}\left(\frac{\text{diffuse_solar_rad.}}{\text{shortwave_rad.}}, 0, 10\right)$	Phần khuếch tán chiếm bao nhiêu trong tổng bức xạ
cloud_x_shortwave	$\text{cloud_cover_total} \times \text{shortwave_radiation}$	Tương tác mây toàn phần và bức xạ

Bảng 8.32: Công thức các đặc trưng dẫn xuất. Đọc từ mã nguồn notebook 03_2_features_spatial.ipynb và 03_3_features_aggregate.ipynb.

8.3.4 Thực nghiệm: khử độ trễ cài sẵn bằng đặc trưng tại thời điểm mục tiêu

Vấn đề. Nhãn cần dự báo nằm ở thời điểm $T+h$, nhưng các đặc trưng hình học Mặt Trời và nhãn lịch — `sin_elevation`, `ghi_cs`, `hour` — vẫn là giá trị tại T . Mô hình do đó dùng vị trí Mặt Trời lúc T để dựng lại sản lượng lúc $T+h$, và đường dự báo sinh ra chính là đường Mặt Trời bị trễ đúng h bước. Đây là hệ quả cấu trúc của bài toán, và tác động của nó lan rộng vì cùng đại lượng đó cũng là mẫu số chuẩn hoá ở Mục 7.3.5.

Cách xử lý. Quy trình khai báo một danh sách 22 cột **tất định** — hình học Mặt Trời cùng các đại lượng suy ra từ nó, và toàn bộ nhãn thời gian theo lịch — rồi sinh thêm bản của chúng tại $T+h$ với hậu tố `_mt`, đồng thời **giữ nguyên** bản tại T . Ở tầm H1 sinh được 14 cột, nâng tổng

số đặc trưng vào mô hình từ 40 lên 54.

Ranh giới hợp lệ của phép dịch. Vị trí Mặt Trời và nhãn lịch tại $T+h$ là kết quả tính toán thiên văn và lịch thuần túy; đứng ở thời điểm T đã biết chính xác chúng bằng bao nhiêu, không cần chờ tới $T+h$ mới đo. Điều này khác hẳn biến khí tượng: bức xạ và mây tại $T+h$ chỉ biết được sau khi đo, nên `shortwave_radiation`, `lag_96` và toàn bộ nhóm `rolling_*` bắt buộc giữ nguyên ở T . Ranh giới đó chính là điều kiện để phép dịch này hợp lệ.

Thêm chứ không thay thế. Phương án thay thế hẳn bản tại T bằng bản tại $T+h$ đã được thử và bị bác bỏ bằng số liệu. Phép đo lấy sai số MAE của đường bao $\hat{y} = \text{site_scale} \times \sin h$ so với sản lượng thật trên tập Phát triển, tính riêng theo khung giờ, cho kết quả ở Bảng 8.34.

Bảng 8.33: So sánh dùng đặc trưng tất định tại T với tại $T+h$, đo bằng MAE của đường bao $\text{site_scale} \times \max(\sin h, \varepsilon)$ so với sản lượng thật tại $T+15$ phút, trên 999.010 dòng ban ngày của tập Phát triển. Kiểm chứng bằng `srcs/05_machine_learning/kiem_chung_bao_cao_v4.py`, mục 10.

Khung giờ	Số dòng	Dùng tại T	Dùng tại $T+h$	Chênh
Toàn bộ ban ngày	999.010	3,1425	3,1296	-0,4%
Sáng 06–09h	246.305	2,1580	2,7258	+26,3%
Chiều 16–18h	189.966	2,9646	2,4136	-18,6%

Bảng 8.34: So sánh dùng đặc trưng tất định tại T với tại $T+h$, đo bằng MAE của đường bao $\text{site_scale} \times \max(\sin h, \varepsilon)$ so với sản lượng thật tại $T+15$ phút, trên 999.010 dòng ban ngày của tập Phát triển. Kiểm chứng bằng `srcs/05_machine_learning/kiem_chung_bao_cao_v4.py`, mục 10.

Hai khung giờ cho hai kết luận ngược nhau, nên không phương án nào thắng tuyệt đối. Trên toàn bộ ban ngày hai bản chênh nhau 0,4%, tức gần như tương đương; chênh lệch chỉ lộ ra khi tách theo khung giờ. Buổi sáng sản lượng thật đi sau Mặt Trời, vì tấm pin còn lạnh và ẩm sương, inverter đang trong giai đoạn khởi động, nên giá trị tại T khớp hơn 26,3%; buổi chiều thì ngược lại, giá trị tại $T+h$ khớp hơn 18,6%. Quy trình vì vậy giữ cả hai bản và để mô hình tự chọn theo khung giờ, thay vì áp một phương án cho cả ngày.

Bảng này được tính lại từ dữ liệu chứ không chép từ khối ghi chú trong mã nguồn. Khối ghi chú đó ghi ba cặp số khác (3,1873 với 3,1884; 1,5934 với 2,1833; 3,4002 với 2,8574) nhưng không kèm phạm vi dòng nên không dựng lại được. Hai lần đo cùng chiều ở cả ba khung giờ; báo cáo lấy bản dựng lại được.

8.3.5 Chuẩn hoá mục tiêu theo vật lý

Bốn mươi trạm có quy mô chênh nhau nhiều lần, và sản lượng trong ngày biến thiên theo góc cao Mặt Trời. Nếu huấn luyện thẳng trên sản lượng thô, mô hình phải dành phần lớn sức mô tả để phân biệt trạm lớn với trạm nhỏ và để học lại nhịp ngày đêm, hai thứ đã biết trước bằng

công thức. Mục tiêu vì vậy được đổi sang một tỷ số không thứ nguyên:

$$k_{\text{target}} = \text{clip}\left(\frac{y}{\text{site_scale} \times \max(\sin h, \varepsilon)}, 0, k_{\text{max}}\right) \quad (8.6)$$

Mẫu số gồm hai phần: `site_scale` khử chênh lệch quy mô giữa các trạm, còn $\sin h$ khử nhịp ngày đêm. Phép `max` đặt một sàn ε cho mẫu số, vì lúc Mặt Trời sát đường chân trời thì $\sin h \rightarrow 0$ và tỷ số sẽ nổ tung.

Sau khi mô hình dự báo $\hat{k}$, giá trị được nhân ngược về kWh rồi chặn trên:

$$\hat{y} = \min\left(\hat{k} \times \text{site_scale} \times \max(\sin h, \varepsilon), \text{tran_cong_suat} \times 1,02\right) \quad (8.7)$$

Cả `site_scale` và `tran_cong_suat` đều là phân vị của chính chuỗi sản lượng nên mang đơn vị kWh trên mỗi bước 15 phút, cùng đơn vị với y ; phép chặn vì vậy không cần hệ số đổi đơn vị nào.

Cơ sở của cách chuẩn hoá. Việc chia sản lượng đo được cho một mức tham chiếu suy từ chính hệ thống là cách làm đã có trong tài liệu. Engerer và Mills [7] tổng kết các phương pháp trước đó và dẫn lại chỉ số K của Lonij và cộng sự [17], vốn định nghĩa mức tham chiếu bằng một phân vị của chính sản lượng đo được.

Điểm cần đọc kỹ ở tài liệu nguồn là không có một mức phân vị chuẩn. Ngay trên cùng một trang tổng kết, hai công trình tiền lệ chọn hai mức khác hẳn nhau. Golnas lấy phân vị 93:

“After removing days with system outages, the clear-sky BPI (CSBPI) for each system is defined as the 93rd percentile of the set of BPI values in the training set.”

Còn Lonij và cộng sự [17] lấy phân vị 80:

“ PV_{CLR-L} is defined as the 80th percentile of PV_{MEAS-L} at the specified time of day on the previous 15 days for a system.”

Hai mức chênh nhau 13 điểm mà cả hai đều được công bố, vì mỗi bên dựng mẫu số theo một cách. Điều đó có nghĩa mức phân vị là tham số thiết kế đi kèm cách dựng mẫu số, không phải hằng số vật lý mượn được từ tài liệu. Mức của dự án vì vậy phải được biện minh bằng thực nghiệm trên chính dữ liệu của dự án.

Cận cắt suy từ dữ liệu, không đặt tay. Tham số k_{max} không được gán một hằng số trong tệp cấu hình. Notebook huấn luyện đặt `CLIP_K = None` rồi gọi hàm `tinh_clip_tu_train()` để tính nó bằng phân vị 99 của k trên chính tập huấn luyện. Giá

Bảng 8.35: Quét mức phân vị dùng làm cận cắt, chạy trên **tập kiểm định**. Đọc từ tệp kết quả 05_selected/quet_muc_phan_vi_nguong_cat.csv.

Mức phân vị	Ngưỡng cắt	Tỷ lệ bị cắt (%)	WAPE kiểm định (%)
0,900	1,1525	10,00	22,6101
0,950	1,2341	5,00	22,5211
0,975	1,3090	2,50	22,4949
0,990	1,4015	1,00	22,4901
0,995	1,4832	0,50	22,4900
0,999	1,9297	0,10	22,4900
1,000	13,4137	0,00	22,4900

Bảng 8.36: Quét mức phân vị dùng làm cận cắt, chạy trên tập kiểm định. Đọc từ tệp kết quả 05_selected/quet_muc_phan_vi_nguong_cat.csv.

trị thu được và ghi vào model_config.json là **1,3764**, tính trên 681.536 giá trị k . Mức phân vị 99 được chọn bằng phép quét ở Bảng 8.36.

Đường cong WAPE phẳng từ mức 0,99 trở lên, ba mức cuối chỉ chênh nhau 0,0001 điểm phần trăm. Bên dưới mức đó thì sai số xấu dần, tới 22,6101% ở phân vị 0,90 vì cắt mất 10% dữ liệu. Dòng cuối cùng cho thấy phép cắt vẫn cần thiết: bỏ hẳn nó thì ngưỡng nhảy lên 13,4137, tức đuôi phân bố có những điểm gấp gần mười lần phần thân. Mức 0,99 là điểm mà đường cong bắt đầu phẳng mà vẫn chặn được đuôi đó.

Hai giá trị ngưỡng trong báo cáo. Bảng 8.36 ghi ngưỡng 1,4015 tại mức 0,99, còn tệp cấu hình mô hình ghi 1,3764. Hai con số này không mâu thuẫn: cùng một mức phân vị nhưng tính trên hai tập khác nhau. Phép quét chạy trên tập kiểm định để đo WAPE tương ứng với từng mức, nên ngưỡng của nó là phân vị 99 của k trên tập kiểm định (307.342 giá trị ban ngày đo thật, đọc từ 05e_kiem_chung/con_so_bao_cao.json). Ngưỡng thực sự nạp vào mô hình bắt buộc phải suy từ tập huấn luyện, nên nó là phân vị 99 của k trên tập huấn luyện (681.536 giá trị), bằng 1,3764. Giá trị dùng để huấn luyện và để chấm điểm ở Mục 7.5 là 1,3764.

Hạn chế: ngưỡng cắt dùng chung cho hai tầm dự báo. Ngưỡng 1,3764 được tính ở tầm H1 rồi dùng lại cho tầm H4. Tính riêng cho H4 thì phân vị 99 của k là 2,0156. Nguyên nhân nằm ở cấu tạo của k : mẫu số lấy sin h tại thời điểm T , còn tử số là sản lượng tại $T + h$. Ở tầm 15 phút Mặt Trời gần như đứng yên nên hai vế khớp nhau; ở tầm 60 phút, buổi sáng Mặt Trời lên nhanh nên mẫu số nhỏ hơn hẳn tử số và k giàu lên.

Hệ quả đo được: dùng ngưỡng của H1 cho H4 thì tỷ lệ nhận bị cắt tăng từ 1,00% lên **8,59%**, và phần bị cắt dồn vào sườn lên buổi sáng, xem Bảng 8.38.

Ngưỡng này chặn ở cả hai đầu: lúc huấn luyện nó cắt cụt nhãn, và lúc dự báo nó chặn luôn đầu ra vì đầu ra cũng đi qua phép cắt trước khi nhân ngược. Với tầm H4 vào buổi sáng, mô hình vừa không được học giá trị thật vừa bị áp trần khi dự báo, nên phần sườn lên bị hụt biên độ. Buổi chiều không có hiện tượng này vì Mặt Trời xuống nên tử số nhỏ hơn mẫu số.

Bảng 8.37: Tỷ lệ nhân bị ngưỡng 1,3764 cắt, tách theo giờ trong ngày, tính trên tập huấn luyện. Kiểm chứng bằng `srcs/05_machine_learning/kiem_chung_bao_cao_v4.py`, mục 1.

Giờ	H1 bị cắt	Tỷ lệ H1	H4 bị cắt	Tỷ lệ H4
6	4	0,05%	3.192	42,98%
7	226	0,61%	13.505	36,17%
8	454	0,75%	18.004	29,92%
9	847	1,41%	13.942	23,17%
10	1.352	2,25%	7.172	11,93%
11	1.079	1,80%	2.113	3,52%
12	822	1,37%	514	0,86%
13–19	2.032	≈ 0,6%	99	< 0,1%
Tổng	6.816	1,00%	58.541	8,59%

Bảng 8.38: Tỷ lệ nhân bị ngưỡng 1,3764 cắt, tách theo giờ trong ngày, tính trên tập huấn luyện. Kiểm chứng bằng `srcs/05_machine_learning/kiem_chung_bao_cao_v4.py`, mục 1.

Sửa đúng cách là gọi lại `ting_clip_tu_train()` trong bước chuẩn bị ma trận của tầm H4. Việc đó kéo theo huấn luyện lại toàn bộ H4 và chạy lại cả dây chuyền đánh giá, nên nằm ngoài phạm vi đợt này và được ghi vào hướng phát triển ở Mục 7.8. Mọi con số H4 trong báo cáo đều là số của cấu hình đang dùng ngưỡng 1,3764.

8.3.6 Kiểm chứng các tham số cố định

Bốn tham số được gán giá trị cố định trong tệp cấu hình. Notebook `05b_thuc_nghiem_tham_so_hardcode` quét từng tham số qua nhiều mức, giữ nguyên mọi thứ còn lại, rồi huấn luyện và chấm lại trên tập kiểm định. Kết quả ở Bảng 8.40.

Bảng này phải đọc trung thực, vì không phải tham số nào cũng có tác động như nhau.

Sàn mẫu số ε không quyết định độ chính xác. Toàn dải từ 0,00 tới 0,15 chỉ chênh nhau 0,0717 điểm phần trăm WAPE. Cái mà ε thực sự điều khiển là số dòng còn lại để huấn luyện: từ 604.200 xuống 557.266, mất 7,8%. Hai con số này là hai đầu của dải quét, ứng với $\varepsilon = 0,00$ và $\varepsilon = 0,15$, đọc từ ô kết quả notebook `05b_thuc_nghiem_tham_so_hardcode.ipynb` và cột `so_dong_train` của tệp `05b_thuc_nghiem_tham_so/thuc_nghiem_tham_so_hardcode.csv`. Mức 0,05 ứng với góc nâng $\arcsin(0,05) = 2,87^\circ$. Tỷ lệ dòng giữ lại được so với mức không lọc là

$$\frac{599.174}{604.200} = 0,991682 \rightarrow \mathbf{99,17\%} \quad (8.8)$$

Con số này là tỷ lệ trên các dòng thực sự vào hàm mục tiêu của phép quét ở Bảng 8.40. Tính trên toàn bộ tập huấn luyện trước khi áp trọng số mẫu thì tỷ lệ là $681.536/709.954 = 96,00\%$; hai con số này đọc từ dòng `Bi loai khoi ham muc tieu` ở ô kết quả của cùng notebook

Bảng 8.39: Quét bốn tham số cố định, chấm trên 779.099 dòng của tập kiểm định. Đọc từ tệp kết quả 05b_thuc_nghiem_tham_so/thuc_nghiem_tham_so_hardcode.csv.

Tham số	Mức	Dòng huấn luyện	WAPE (%)	RMSE	R^2
eps_elev	0,00	604.200	20,5872	3,4733	0,8931
	0,02	602.937	20,5657	3,4895	0,8921
	0,05	599.174	20,5692	3,4799	0,8926
	0,10	582.252	20,5810	3,4832	0,8924
	0,15	557.266	20,5155	3,4630	0,8937
$k_{\max}$	1,0	599.174	24,1097	3,8230	0,8704
	1,2	599.174	21,1356	3,5535	0,8881
	1,5	599.174	20,5692	3,4799	0,8926
	2,0	599.174	20,4791	3,4638	0,8936
	3,0	599.174	20,4473	3,4502	0,8945
Hệ số nói trần	1,00	599.174	20,5710	3,4816	0,8925
	1,02	599.174	20,5692	3,4799	0,8926
	1,05	599.174	20,5669	3,4781	0,8928
	1,10	599.174	20,5650	3,4766	0,8928
Trọng số vùng đỉnh	0,0	599.174	20,4051	3,4623	0,8937
	0,5	599.174	20,5059	3,4650	0,8936
	1,0	599.174	20,5692	3,4799	0,8926
	2,0	599.174	20,6429	3,4928	0,8919

Bảng 8.40: Quét bốn tham số cố định, chấm trên 779.099 dòng của tập kiểm định. Đọc từ tệp kết quả 05b_thuc_nghiem_tham_so/thuc_nghiem_tham_so_hardcode.csv.

trên. Hai con số khác nhau vì hai phạm vi khác nhau; báo cáo dùng 99,17% đúng theo phạm vi của bảng.

Phần bị loại nhỏ như vậy vì vành $0 < \sin h \leq 0,05$ rất hẹp và gần như không phát điện. Notebook 05e_kiem_chung_con_so_bao_cao.ipynb đo lại trên phạm vi khai báo tường minh: tập huấn luyện, giữ những dòng có nhãn tại $T+15$ phút là số đo thật ban ngày và không bị loại khỏi huấn luyện, còn 635.564 dòng. Trung bình mỗi trạm mỗi ngày có 40,8 bước trong phạm vi đó, trong đó chỉ 0,35 bước rơi vào vành. Sản lượng trung bình một bước trong vành là 0,4238 kWh, so với 6,7349 kWh ở các bước còn lại, kém 16 lần. Cộng lại, phần sản lượng nằm trong vành là

$$\frac{2.279 \text{ kWh}}{4.240.381 \text{ kWh}} = 0,000537 \rightarrow \mathbf{0,054\%} \quad (8.9)$$

Đặt sản ở 0,05 vì vậy chặn được vùng mẫu số tiến về 0 mà chỉ bỏ đi khoảng năm phần vạn sản lượng ban ngày. Mọi con số trong đoạn này đọc từ tệp kết quả 05e_kiem_chung/con_so_bao_cao.json.

Cận cắt $k_{\max}$ là tham số có tác động rõ. Hạ xuống 1,0 làm WAPE xấu đi 3,54 điểm, vì

cắt mất phần thân của phân bố chứ không chỉ đuôi. Nới lên 2,0 và 3,0 cải thiện thêm 0,09 và 0,12 điểm, nhưng đổi lại thì phép cắt gần như mất tác dụng chặn các điểm đo bất thường. Giá trị dùng thật là 1,3764 suy từ phân vị 99 của tập huấn luyện, nằm giữa hai mức 1,2 và 1,5 của phép quét.

Hệ số nới trần không phải lựa chọn về độ chính xác. Bốn mức từ 1,00 tới 1,10 chênh nhau 0,006 điểm WAPE, tức nằm trong mức nhiễu. Hệ số 1,02 được chọn theo lý do vật lý: chứa 2% dư địa quanh trần để không cắt oan các dao động ngắn do hiện tượng tăng cường bức xạ ở mép mây, chứ không phải khẳng định công suất lắp đặt thực tế cao hơn 2%.

Trọng số vùng đỉnh làm WAPE tổng thể xấu đi. Tắt hẳn cho 20,4051%, thấp hơn mức đang dùng 0,164 điểm. Đây là một đánh đổi có chủ đích chứ không phải tham số bị bỏ quên: trọng số này kéo mô hình chú ý vào khung giờ phát điện mạnh, nơi sai số có giá trị vận hành lớn nhất, và trả giá bằng một phần nhỏ sai số trung bình trên toàn tập.

Ngưỡng cắt chỉ số trời quang. Tham số CLIP_CSI chặn tỷ lệ bức xạ đo trên bức xạ trời quang. Bảng 8.42 cho thấy nó ảnh hưởng tới bao nhiêu điểm bị cắt.

Bảng 8.41: Số điểm bị ngưỡng CLIP_CSI cắt. Đọc từ tệp kết quả 05b_thuc_nghiem_tham_so/thuc_nghiem_clip_csi.csv.

Ngưỡng	Số điểm bị cắt	Tỷ lệ (%)
1,0	39.265	5,4592
1,1	33.127	4,6058
1,2	28.684	3,9880
1,3	24.393	3,3915
1,5	18.689	2,5984
2,0	11.179	1,5543

Bảng 8.42: Số điểm bị ngưỡng CLIP_CSI cắt. Đọc từ tệp kết quả 05b_thuc_nghiem_tham_so/thuc_nghiem_clip_csi.csv.

Ngưỡng 1,0 ứng với giả định bức xạ đo không bao giờ vượt bức xạ trời quang lý thuyết, giả định đó cắt 5,46% số điểm, quá nhiều để coi là hợp lý, vì hiện tượng tăng cường bức xạ ở mép mây làm bức xạ đo vượt mức trời quang trong thời gian ngắn là có thật. Ngưỡng 1,5 cắt 2,60%, giữ lại phần vượt trần do vật lý và chỉ loại phần vượt xa.

8.3.7 Chẩn đoán và chọn đặc trưng

Sau ba notebook sinh đặc trưng, tập huấn luyện mang 114 cột. Hai notebook tiếp theo quyết định cột nào thực sự đi vào mô hình, với vai trò tách bạch: 04_vif_diagnostics đo và xuất bằng chứng, 05_select_features quyết định. Notebook chẩn đoán không tự loại cột nào — nó ghi bảng chỉ số ra tệp để bước chọn đọc lại.

Cách phân vai này có lý do: hệ số phóng đại phương sai chỉ đo mức một đặc trưng bị các

đặc trưng còn lại giải thích, không đo mức đặc trưng đó giải thích được mục tiêu. Một cột có thể vừa cộng tuyến cao vừa mang thông tin vật lý không thay thế được, nên máy không được quyền tự loại.

Chẩn đoán đa cộng tuyến

Trong 114 cột, 86 cột được đưa vào chẩn đoán; 28 cột còn lại nằm ngoài phạm vi vì là mục tiêu, khoá định danh, cột ghi nguồn gốc dữ liệu, cờ ngoại lai hoặc cột thời gian thô. Kết quả phân loại trình bày ở Bảng 8.43.

Bảng 8.43: Phân bố nhãn chẩn đoán trên 86 đặc trưng số. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.

Nhãn	Số cột	Nghĩa
HIGH_VIF	41	Hệ số phóng đại phương sai vượt 10
OK	27	Không vướng tiêu chí nào
CONSTANT	9	Chỉ một giá trị duy nhất, phương sai bằng 0
DUPLICATE	8	Trùng lặp gần hoàn hảo với một cột khác
HIGH_MISSING	1	Tỷ lệ khuyết quá cao
Tổng	86	

Cột duy nhất mang nhãn khuyết cao là `source_gap_id` với 97,68% ô trống — đúng bản chất của nó, vì nó chỉ nhận giá trị tại các dòng nằm trong một khoảng trống nguồn.

Cột trùng lặp. Ở ngưỡng $|r| \geq 0,95$ notebook đếm được 44 cặp, nhưng chỉ những cặp đạt $|r| \geq 0,9999$ mới bị coi là trùng lặp thực sự, vì cộng tuyến hoàn hảo khiến phép tính hệ số phóng đại phương sai không xác định. Tám cột bị loại ở bước này, xem Bảng 8.44.

Bảng 8.44: Tám cột trùng lặp gần hoàn hảo và cột đại diện được giữ lại. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.

Cột bị bỏ	Đại diện giữ lại	Số giá trị phân biệt
quarter_hour	minute_of_day	96
hour_of_day	hour	24
hour_bucket_raw	hour	24
hour_bucket_model	hour	24
day_of_week_model	day_of_week	7
month_model	month	12
number_of_panels_missing_flag	capacity_kw_missing_flag	2
dni_ratio	diffuse_ratio	37.341

Sáu nhóm đầu là các cách mã hoá khác nhau của cùng một đại lượng thời gian, sinh ra ở các bước khác nhau của quy trình rồi cùng tồn tại. Cặp `diffuse_ratio` và `dni_ratio` có $r = -1,0000$ vì hai tỷ lệ này cộng lại bằng 1 theo định nghĩa. Sau bước loại trùng, số đặc trưng còn 78.

Hệ số phóng đại phương sai. Bảng 8.45 lấy tám cột cao nhất.

Bảng 8.45: Tám đặc trưng có hệ số phóng đại phương sai cao nhất. Giá trị 9999 là mức chặn trên mà notebook đặt cho trường hợp cộng tuyến gần hoàn hảo. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.

Đặc trưng	VIF	Nguồn cộng tuyến
direct_normal_irradiance	9999	Ba cột bức xạ ràng buộc nhau qua quan hệ hình học
diffuse_solar_radiation	9999	
shortwave_radiation	9999	
tran_cong_suat	7.567,53	Cùng suy từ phân vị sản lượng của một trạm
site_scale	7.516,67	
day_of_year	5.228,18	Trùng thông tin với biến tháng
month	5.186,16	
sin_elevation	2.846,97	Hàm xác định của cùng góc cao Mặt Trời

Ba cột bức xạ đạt mức chặn trên vì GHI bằng tổng của thành phần trực xạ chiếu xuống mặt ngang và thành phần khuếch tán, nên biết hai cột là suy ra được cột còn lại. Cặp `site_scale` và `tran_cong_suat` có $r = 0,9999$ vì cả hai là phân vị 99 và phân vị 99,9 của cùng một chuỗi sản lượng.

Không cột nào trong Bảng 8.45 bị loại. Cộng tuyến làm hệ số của mô hình tuyến tính mất ổn định, nhưng mô hình dùng ở đây là cây quyết định tăng cường gradient — nó chọn điểm cắt theo mức giảm hàm mất mát chứ không giải hệ phương trình chuẩn tắc, nên không chịu ảnh hưởng đó.

Đối chiếu bằng một phương pháp độc lập. Để không quyết định chỉ dựa trên một thước đo, notebook chạy thêm hồi quy bình phương tối thiểu riêng phần và lấy điểm quan trọng biến, đo theo hiệp phương sai với mục tiêu thay vì theo cộng tuyến giữa các đặc trưng. Bảy đặc trưng đứng đầu được ghi ở Bảng 8.46.

Bảng 8.46: Bảy đặc trưng dẫn đầu theo điểm quan trọng biến của hồi quy bình phương tối thiểu riêng phần, đặt cạnh hệ số phóng đại phương sai của chính chúng. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.

Đặc trưng	Điểm quan trọng	VIF
rolling_mean_4	2,265	461,18
rolling_min_4	2,251	882,04
rolling_max_4	2,224	1.375,52
lag_4	2,123	27,77
ky_vong	2,039	21,18
pv_clr_lonij	1,959	10,80
lag_96	1,883	5,36

Sáu trong bảy đặc trưng dẫn đầu đồng thời mang nhãn cộng tuyến cao. Đây là lý do trực

tiếp để bước chọn không dùng hệ số phóng đại phương sai làm tiêu chí loại: nếu cắt theo ngưỡng 10 thì sáu đặc trưng mạnh nhất theo thước đo độc lập sẽ bị loại hết.

Danh sách cấm

Trước khi chấm điểm, notebook 05_select_features khai báo tường minh một danh sách cấm gồm 53 tên cột. Danh sách này chặn bốn loại: chính mục tiêu và các biến thể của nó, cờ ngoại lai và cột loại trừ huấn luyện, cột ghi nguồn gốc dữ liệu, và các khoá định danh cùng cột thời gian thô.

Danh sách được khai báo theo tên chứ không theo tập dữ liệu, nên nó bao cả những tên chỉ xuất hiện ở các bước khác của quy trình. Trong 114 cột của tệp đầu vào, 40 cột trùng tên với danh sách và bị loại; 74 cột còn lại đi tiếp vào bước chấm điểm. Cách khai báo dư này là có chủ đích: thêm một tên không tồn tại thì vô hại, còn sót một tên rò rỉ thì hỏng cả kết quả.

Danh sách cấm được đặt trước phép chấm điểm chứ không sau, vì một cột rò rỉ luôn đạt điểm cao: nếu để nó dự thì chính thước đo sẽ chọn nó. Hình 8.12 là đoạn khai báo.

Chấm điểm bằng thông tin tương hỗ

Phép chấm điểm chạy trên **thông tin tương hỗ** giữa từng đặc trưng và mục tiêu. Thước đo này bắt được cả quan hệ phi tuyến, khác hệ số tương quan Pearson vốn chỉ đo quan hệ tuyến tính — điều cần thiết ở đây vì quan hệ giữa bức xạ và sản lượng bảo hoà dần khi tới gần trần công suất.

Điểm chỉ tính trên các dòng hợp lệ, tức đã bỏ dòng mang cờ loại trừ huấn luyện:

Tổng số dòng ban đầu: 1550856
Số dòng hợp lệ (exclude_from_training == False): 1514314 (97.64%)
Số dòng bị loại trừ khỏi chấm điểm: 36542

Bảng 8.47 lấy mười đặc trưng đứng đầu trong 74 ứng viên, chấm trên mẫu 100.000 dòng.

Bốn vị trí đầu đều là đặc trưng của sở trọt một giờ, và sáu vị trí đầu đều suy từ lịch sử của chính chuỗi sản lượng. Bảng xếp hạng này khớp với kết quả tự tương quan ở Mục 2.2: chuỗi mang tự tương quan +0,8942 tại mốc một giờ, nên các thống kê của cửa sổ một giờ gần nhất là nguồn thông tin mạnh nhất về giá trị sắp tới.

Danh sách bảo vệ

Lấy thẳng 35 đặc trưng đứng đầu sẽ loại mất một số biến khí tượng và hình học Mặt Trời có điểm thấp nhưng cần cho mô hình đọc được điều kiện vật lý tại bước hiện tại. Notebook vì

```

"""Stage 07a: danh sách CAM (deny list) - chặn rò rỉ nhân và công tuyền cấu trúc.

Tách từ bước 4 của run_select_features() trong 03_feature_selection.py.

DAY LA HANG RAO CHONG RO RI QUAN TRONG NHAT CUA CA PIPELINE. Bo sot 1 cot o day thi
model dat R2 rat cao tren train/val nhưng HOAN TOAN THAT BAI khi du bao that.
"""
from __future__ import annotations
import pandas as pd

# — 1. Chính biến mục tiêu —
DENY_TARGET = ["energy_generated_kwh"]

# — 2. Provenance / outlier —
# BANG CHUNG tu du lieu tho:
# - Khi exclude_from_training == True thì sản lượng = 0.0 o 100.00% trường hợp
#   (36.847 dòng trong tập train, đều là machine_failure zero do gap >= 24h).
# - Nhóm outlier_group == physical_over_capacity có sản lượng trung bình 19,43 kWh,
#   vượt xa nhóm normal (2,75 kWh).
# HAU QUA NEU DUA VAO MODEL: các cột này được tạo SAU KHI đã đo và kiểm tra target.
# Model chỉ cần tra bảng "thay có thì đoan 0" -> điểm cực cao trên train/val nhưng
# THAT BAI khi du bao tuong lai (lúc đo chưa có đủ liệu do đo gần có).
# VAI TRU DUNG của chúng: (1) lọc dòng khỏi train, (2) gán trọng số mau,
# (3) khoanh vùng tính metric theo nhóm. KHÔNG được làm đặc trưng đầu vào.
DENY_PROVENANCE_OUTLIER = [
    "gmm_if_outlier_flag", "gmm_if_outlier_reason", "outlier_group",
    "exclude_from_training", "exclude_reason", "training_quality_reason",
    "energy_source", "timestamp_was_inserted", "source_gap_id",
    "after_source_gap_steps_remaining",
]

# — 3. Có ban ngày / audit —
DENY_DAYLIGHT_AUDIT = [
    "is_daylight", "weather_is_day", "sunshine_duration", "weather_is_observed",
]

# — 4. Khoa ID - tránh model học vét index thay vì học đặc tính vật lý —
DENY_IDS = [
    "gen_id", "site_id", "geo_id", "date_id", "time_id", "weather_id", "weather_type_id",
]

# — 5. Categorical tho (đã được mã hóa thành *_enc ở stage s05) —
DENY_RAW_CATEGORICAL = [
    "site_id", "campus_name", "location_name", "site_metric", "panel",
    "inverter", "optimizers", "weather_join_method",
    "weather_condition", "weather_description",
]

# — 6. Thời gian tho —
# 'year' bị cam vì TANG DON DIEU, không tuần hoàn:
# train year = {2020, 2021} | test year = {2021, 2022}
# -> 455.616 dòng test (89%) có year = 2022 CHUA TUNG xuất hiện lúc train.
# Cay quyết định tách theo 'year <= 2021' sẽ áp quy tắc học từ giá trị chưa hề thay.
# Khác hạn month / day of year / doy sin / doy cos: nhưng cái đó TUAN HOAN, lặp hàng năm.
DENY_RAW_TIME = ["timestamp", "time_diff", "full_date", "weather_timestamp", "year"]

# — 7. Công tuyền CAU TRUC (không phải tương quan ngẫu nhiên) —
# dni_ratio: VIF vô cực trên mẫu ban ngày. Giữ diffuse_ratio (ý nghĩa vật lý rõ: tỷ lệ
# mây mù), bỏ dni_ratio.
# con_cach_tran = tran_cong_suat - ky_vong: to hop tuyen tinh CHINH XAC của 2 cột con lai,
# không mang thông tin mới
# site_scale và tran_cong_suat đều là hàng số theo site (phần vì 99 và 99,9 của CUNG một
# phần phoi) nên tương quan gần tuyệt đối; giữ tran_cong_suat (dạng dung trực tiếp trong
# ty le bao hoa/con_cach_tran), bỏ site_scale khỏi tập đặc trưng train.
DENY_STRUCTURAL_COLLINEAR = ["dni_ratio", "con_cach_tran", "site_scale"]

# — 8. Metadata của bước split (do stage s02 gán) —
# KHÔNG cam cá tiên to 'v3' vì các đặc trưng that cùng dung tiên to nay.
SPLIT_META = [
    "v3_holdout_split", "v3_test_start_timestamp", "v3_split_strategy",
    "v3_n_time_series_splits", "v3_split", "v3_cv_fold", "v3_cv_role",
]

def dung_deny_list(df: pd.DataFrame, df_diag: pd.DataFrame | None = None) -> tuple[set, dict]:
    """Góp toàn bộ deny list. Tra về (tập cam, chi tiết từng nhóm để báo cáo)."""
    cam = set(
        DENY_TARGET + DENY_PROVENANCE_OUTLIER + DENY_DAYLIGHT_AUDIT
        + DENY_IDS + DENY_RAW_TIME + DENY_RAW_CATEGORICAL + DENY_STRUCTURAL_COLLINEAR
    )
    cam.update(c for c in SPLIT_META if c in df.columns)
    # Mọi cột có chứa 'timestamp' trong tên: thời gian tho tăng đơn điệu, model sẽ học
    # theo độ lớn của timestamp và không ngoài suy được sang tương lai.
    cam.update(c for c in df.columns if "timestamp" in c.lower())

    trung_lap = set()
    if df_diag is not None and "duplicate_of" in df_diag.columns:
        trung_lap = set(df_diag.loc[df_diag["duplicate_of"].notna(), "feature"])
        cam.update(trung_lap)

    chi_tiet = {
        "target": len(DENY_TARGET),
        "provenance_outlier": len(DENY_PROVENANCE_OUTLIER),
        "daylight_audit": len(DENY_DAYLIGHT_AUDIT),
        "ids": len(DENY_IDS),
        "raw_time": len(DENY_RAW_TIME),
        "raw_categorical": len(DENY_RAW_CATEGORICAL),
        "structural_collinear": len(DENY_STRUCTURAL_COLLINEAR),
        "trung_lap_tu_s06": len(trung_lap),
        "tong_cam": len(cam),
    }
    return cam, chi_tiet

def dac_trung_ung_vien(df: pd.DataFrame, cam: set) -> list[str]:
    return [c for c in df.columns if c not in cam]

```

Hình 8.12: Đoạn khai báo danh sách cấm trong quy trình chọn đặc trưng. Mỗi nhóm cột bị cấm đi kèm lý do ngay tại chỗ khai báo.

Bảng 8.47: Mười đặc trưng có điểm thông tin tương hỗ cao nhất. Đọc từ ô kết quả của notebook 05_select_features.ipynb.

Hạng	Đặc trưng	Điểm
1	rolling_max_4	1,1724
2	rolling_mean_4	1,1251
3	ky_vong	1,0785
4	rolling_min_4	1,0582
5	lag_96	1,0018
6	lag_4	0,8315
7	solar_elevation	0,8258
8	sin_elevation	0,7967
9	ty_le_bao_hoa	0,7949
10	ghi_cs	0,7939

vậy khai báo một danh sách bảo vệ gồm 22 đặc trưng, cả 22 đều có mặt trong dữ liệu, và bổ sung lại những đặc trưng nằm ngoài ngưỡng cắt:

```

--- DANH SACH BAO VE ---
Co trong du lieu : 22/22
Bi Top K cat, da bo sung lai (5): ['azimuth_sin', 'temperature_c',
                                   'rolling_min_96', 'doy_sin', 'doy_cos']
Tong dac trung duoc chon: 35 (Top K) + 5 (bao ve) = 40

```

Năm đặc trưng được bổ sung nằm ở hạng 36, 40, 49, 54 và 68 theo điểm thông tin tương hỗ. Hai cột `doy_sin` và `doy_cos` mã hoá vị trí trong năm dưới dạng vòng; điểm của chúng thấp vì trên một mẫu ngẫu nhiên rải khắp 18 tháng, mùa gần như không phân biệt được — nhưng mô hình cần chúng để không coi ngày 31/12 và ngày 01/01 là hai thời điểm xa nhau.

Kết quả áp cho mười tập

Bốn mươi đặc trưng đã chọn được áp đồng loạt cho mười tập dữ liệu — bốn tập chính và sáu phần của ba fold:

```

--- DA LOC 10 TAP THEO 40 DAC TRUNG DA CHON ---
      tap      dong  cot_truoc  cot_sau  feature  cot_phu  \
0      v4_train 1550856        114        50        40        10
1      v4_val   723114        114        50        40        10
2      v4_test  510468        114        50        40        10
3 v4_development 2273970        113        50        40        10
4   fold_1_train 233244        115        50        40        10
5   fold_1_val   606105        115        50        40        10
6   fold_2_train 839349        115        50        40        10
7   fold_2_val   711507        115        50        40        10
8   fold_3_train 1550856        115        50        40        10

```

9	fold_3_val	723114	115	50	40	10
	feature_thieu					
0		0				
1		0				
2		0				
3		0				
4		0				
5		0				
6		0				
7		0				
8		0				
9		0				

Mọi tập đều có đủ đặc trưng đã chọn.

Cột `feature_thieu` bằng 0 ở cả mười dòng, tức không tập nào thiếu đặc trưng đã chọn. Mỗi tập giữ 50 cột: 40 đặc trưng cùng 10 cột phụ trợ gồm mục tiêu, mốc thời gian, mã trạm và các cột phục vụ lọc phạm vi chấm điểm. Danh sách 40 tên cột được ghi ra tệp `selected_features.json` để các bước huấn luyện và phục vụ đọc lại đúng một danh sách duy nhất.

8.3.8 Tổng hợp bộ đặc trưng đưa vào mô hình

Bảng 8.49 liệt kê trọn 40 đặc trưng đã chọn, xếp theo sáu nhóm.

Mười bốn cột `_mt` sinh thêm ở bước huấn luyện đều thuộc hai nhóm đầu — hình học Mặt Trời và nhân lịch — đúng theo ranh giới hợp lệ đã nêu ở Mục 3.4:

Thêm 14 đặc trưng tại T+15 phút:

```
['solar_elevation_mt', 'solar_azimuth_mt', 'azimuth_sin_mt',
 'azimuth_cos_mt', 'sin_elevation_mt', 'ghi_cs_mt', 'ky_vong_mt',
 'ty_le_bao_hoa_mt', 'minute_of_day_mt', 'hour_mt', 'hour_sin_mt',
 'hour_cos_mt', 'doy_sin_mt', 'doy_cos_mt']
```

Mã trạm train : 599,174 dòng x 54 đặc trưng

Mục tiêu chuẩn hóa k: min 0.0028 trung vi 0.6423 max 1.3764

Không cột khí tượng nào có mặt trong danh sách này. Giá trị lớn nhất của mục tiêu chuẩn hóa bằng đúng 1,3764, tức cận cắt suy từ phân vị 99 ở Mục 7.3.5 đang hoạt động.

Bảng 8.48: Bốn mươi đặc trưng được chọn, xếp theo nhóm. Đọc từ 05_selected/selected_features.json.

Nhóm	Số cột	Tên cột
Thời gian và lịch tuần hoàn	6	minute_of_day, hour, hour_sin, hour_cos, doy_sin, doy_cos
Solar geometry và trời quang	8	solar_elevation, sin_elevation, solar_azimuth, azimuth_sin, azimuth_cos, ghi_cs, cs_factor, chi_so_troi_quang
Khí tượng đo được	5	shortwave_radiation, diffuse_solar_radiation, direct_normal_irradiance, temperature_c, cloud_cover_low
Tương tác và tỷ lệ	5	rad_x_sinelev, temp_x_shortwave, diffuse_ratio, cloud_x_shortwave, cloud_low_x_shortwave
Lịch sử chuỗi	10	lag_4, lag_96, rolling_mean_4, rolling_std_4, rolling_min_4, rolling_max_4, rolling_mean_96, rolling_std_96, rolling_min_96, rolling_max_96
Quy mô trạm và mã hoá	6	ky_vong, ty_le_bao_hoa, tran_cong_suat, site_id_enc, weather_condition_enc, weather_description_enc
Tổng	40	

Bảng 8.49: Bốn mươi đặc trưng được chọn, xếp theo nhóm. Đọc từ 05_selected/selected_features.json.

8.4 Huấn luyện và chọn hàm mất mát

Mô hình là LightGBM hồi quy, huấn luyện riêng cho H1 và H4, mỗi tầm nhận 54 đặc trưng. Mục này đi qua năm bước: trọng số cho dòng ngoại lai, tinh chỉnh siêu tham số (*hyperparameter*), sáu cấu hình chọn được, chọn hàm mất mát, và cấu hình tắt định.

8.4.1 Chính sách trọng số cho dòng ngoại lai

Các dòng mang nhãn ngoại lai không bị xoá khỏi lưới. Chúng nhận trọng số bằng 0, tức không đóng góp vào hàm mục tiêu, nhưng vẫn nằm trong bảng để bước báo cáo truy ngược được:

```
--- CHINH SACH OUTLIER, experiment = measured_only_headline ---
Dong co weight = 0 khong tham gia ham muc tieu nhung van giu de bao cao.
Tong dong bi loai khoi ham muc tieu: 82,362 / 681,536 (12.08%)
```


trong đó `physical_over_capacity`: 0 dòng (luôn bị loại ở mọi experiment)
 Khoảng thời gian train: 2020-01-02 06:30:00 -> 2021-06-21 17:00:00

Cách gán trọng số 0 được chọn thay vì xoá dòng, vì xoá sẽ làm đứt lưới thời gian và mọi đặc trưng trễ, cửa sổ trượt tính sau đó đều đếm sai khoảng cách, đúng vấn đề mà bước dựng lưới ở Mục 7.2.1 đặt ra để tránh.

8.4.2 Tinh chỉnh siêu tham số (*hyperparameter*)

Mỗi hàm mất mát được Optuna chạy một phiên tìm kiếm riêng với ngân sách 20 trial, chấm bằng WAPE gộp trên ba fold cửa sổ mở rộng của tập Phát triển. Không hàm nào phải dừng lại bộ tham số của hàm khác, và không hàm nào bị cố định mức điều hoà.

Miền tìm kiếm khai báo cố định trong cả ba notebook huấn luyện, ghi ở Bảng 8.51.

Bảng 8.50: Miền tìm kiếm siêu tham số khai báo cho Optuna. Đọc từ hàm `tham_so_co_ban` trong notebook `06_1_train_mae.ipynb`.

Siêu tham số	Miền	Vai trò
<code>n_estimators</code>	[400; 1200]	Số cây tối đa, early stopping chốt số thật
<code>learning_rate</code>	[0,02; 0,12] thang log	Tốc độ học
<code>num_leaves</code>	[63; 255]	Độ phức tạp mỗi cây
<code>min_child_samples</code>	[20; 120]	Số mẫu tối thiểu mỗi lá
<code>subsample</code>	[0,7; 1,0]	Tỷ lệ mẫu mỗi vòng
<code>colsample_bytree</code>	[0,7; 1,0]	Tỷ lệ cột mỗi cây
<code>reg_alpha</code>	[0; 10]	Điều hoà L_1
<code>reg_lambda</code>	[0; 10]	Điều hoà L_2
<code>alpha</code>	[0,5; 20] thang log	Điểm chuyển của Huber, chỉ Huber có

Bảng 8.51: Miền tìm kiếm siêu tham số (*hyperparameter*) khai báo cho Optuna. Đọc từ hàm `tham_so_co_ban` trong notebook `06_1_train_mae.ipynb`.

Vì `reg_alpha` và `reg_lambda` được thả độc lập trên cùng một miền, không gian tìm kiếm bao trùm cả ba chế độ điều hoà: L_1 thuần, L_2 thuần và dạng phối hợp. Mỗi hàm mất mát vì vậy được trao cơ hội ngang nhau để tự tìm mức điều hoà phù hợp trước khi đem ra so.

8.4.3 Sáu cấu hình Optuna chọn được

Điểm chuyển của Huber được Optuna chọn rất khác nhau giữa hai tầm: $\alpha = 9,86$ ở H1 nhưng chỉ 0,73 ở H4. Đọc ngang bảng còn thấy hai xu hướng. Các cấu hình MSE dùng số lá lớn hơn hẳn, 146 và 134 so với 71–99 của Huber, tức cây sâu và chia nhỏ hơn, phù hợp với việc MSE phạt nặng sai số lớn nên có động cơ khớp sát từng vùng dữ liệu. Mức phạt L_1 mà Optuna

Bảng 8.52: Siêu tham số tốt nhất do Optuna chọn, theo từng hàm mất mát và tầm dự báo. Cả sáu cấu hình dùng chung `random_state = 42`, `deterministic = true` và `max_bin = 127` trên CPU. Đọc từ khoá `best_params` trong tệp kết quả của mỗi notebook huấn luyện.

Cấu hình	Số cây	Tốc độ học	Số lá	Mẫu/lá	Tỷ lệ mẫu	Tỷ lệ cột	L_1	L_2
MAE — H1	800	0,03019	82	88	0,700	0,817	2,58	4,82
Huber — H1	386	0,05781	71	81	0,751	0,720	9,49	9,66
MSE — H1	329	0,05121	146	49	0,884	0,742	2,92	3,66
MAE — H4	400	0,04857	69	111	0,778	0,899	3,12	5,20
Huber — H4	526	0,02849	99	71	0,950	0,770	9,88	4,18
MSE — H4	509	0,03570	134	46	0,869	0,810	9,81	3,99

Bảng 8.53: Siêu tham số tốt nhất do Optuna chọn, theo từng hàm mất mát và tầm dự báo. Cả sáu cấu hình dùng chung `random_state = 42`, `deterministic = true` và `max_bin = 127` trên CPU. Đọc từ khoá `best_params` trong tệp kết quả của mỗi notebook huấn luyện.

chọn cho Huber ở cả hai tầm đều gần chạm cận trên của miền (9,49 và 9,88), cho thấy cấu hình này cần ràng buộc mạnh mới ổn định.

Hai chỗ chạm biên miền tìm kiếm. `subsample` của MAE–H1 bằng 0,7003, tức đúng cận dưới; `reg_alpha` của Huber đạt 9,49–9,88 trên miền $[0; 10]$. Khi một siêu tham số (*hyperparameter*) dừng ngay tại biên, không thể loại trừ khả năng giá trị tốt hơn nằm ngoài miền đã khai báo. Vì vậy tài liệu này không tuyên bố đây là cấu hình tối ưu toàn cục, mà chỉ là cấu hình tốt nhất tìm được trong miền và ngân sách 20 trial đã khoá từ trước. Mở rộng miền ở hai chỗ đó là việc nên làm ở lần huấn luyện sau.

8.4.4 Chọn hàm mất mát

Ba hàm được chấm trên tập kiểm định, phần dữ liệu mô hình chưa từng nhìn thấy, ở phạm vi đo thật ban ngày. Phạm vi này xét dòng nhân tại $T+h$ đúng như ở bước đánh giá cuối tại Mục 7.5.2, và loại hai trạm 19, 24 cho khớp với phạm vi huấn luyện. Kết quả đầy đủ của sáu cấu hình ở Bảng 8.55.

MAE cho sai số thấp nhất ở cả hai tầm và được chọn cho cả hai. Trong mỗi tầm, ba hàm được chấm trên đúng cùng số quan sát, điều kiện để phép so sánh có nghĩa, vì nếu một cấu hình được chấm trên tập sạch hơn thì chênh lệch WAPE phản ánh phạm vi chứ không phản ánh hàm mất mát.

Đáng chú ý là MAE thắng theo WAPE nhưng thua theo RMSE ở cả hai tầm. Điều này đúng với bản chất hai hàm: MSE phạt bình phương sai số nên ép sai số lớn xuống mạnh hơn, cho RMSE tốt hơn; MAE phạt tuyến tính nên bám phần thân phân bố, cho sai số tương đối tổng thể thấp hơn. Dự án lấy WAPE làm tiêu chí chọn vì nó là chỉ số được báo cáo, và vì mục tiêu vận hành là tổng sai số trên tổng sản lượng chứ không phải không chế vài sai số cực trị.

Phép chọn này thực hiện hoàn toàn trên tập kiểm định; tập test không tham gia. Notebook

Bảng 8.54: Sai số trên tập kiểm định, phạm vi đo thật ban ngày. Trong mỗi tầm, cả ba hàm được chấm trên đúng cùng số quan sát. Đọc từ `metrics_val.json` của sáu cấu hình dưới `06_train/`.

Tầm	Hàm mất mát	WAPE (%)	RMSE	MAE	R^2
<i>H1 — 288.811 quan sát cho cả ba hàm</i>					
H1	MAE	22,0515	3,6737	1,5062	0,8984
H1	MSE	22,6588	3,6372	1,5477	0,9004
H1	Huber	22,7936	3,6608	1,5569	0,8991
<i>H4 — 272.569 quan sát cho cả ba hàm</i>					
H4	MAE	26,9585	4,3592	1,9329	0,8628
H4	MSE	27,3309	4,2847	1,9596	0,8675
H4	Huber	27,4040	4,2893	1,9648	0,8672

Bảng 8.55: Sai số trên tập kiểm định, phạm vi đo thật ban ngày. Trong mỗi tầm, cả ba hàm được chấm trên đúng cùng số quan sát. Đọc từ `metrics_val.json` của sáu cấu hình dưới `06_train/`.

`10_compare_optuna_current` có một công kiểm tự động cho đúng điều đó, và nó báo PASS.

8.4.5 Cấu hình tắt định

Toàn bộ sáu lần huấn luyện chạy trên CPU với `deterministic = true`, `force_col_wise = true`, `max_bin = 127`, `random_state = 42` và `n_jobs = 6`. Chế độ GPU bị tắt có chủ đích. Tài liệu tham số của LightGBM ghi rõ *deterministic “used only with cpu device type”*; bật GPU thì cờ này bị bỏ qua. Quy trình đặt tính tái lập lên trước tốc độ nên chọn CPU.

Kiểm chứng bằng hai phép chạy lại. Sau khi cấu hình đã khoá và tập test đã mở, cả sáu cấu hình được huấn luyện lại từ đầu bằng cùng hạt giống. Kết quả trên tập kiểm định của lần chạy lại này chính là Bảng 8.55 ở Mục 7.4.4, và thứ tự giữa ba hàm mất mát giữ nguyên so với lần khoá cấu hình. Đây là bằng chứng cho rào chắn thứ năm ở Mục 7.1.5.

Phép chạy lại thứ hai nằm ở bước giải thích mô hình: bước tính SHAP ở Mục 7.6 được chạy lại trên mô hình vừa huấn luyện lại và cho bảng xếp hạng cùng giá trị trùng khít tới từng chữ số với lần chạy trước.

8.5 Đánh giá trên tập test niêm phong

Tập test tách từ đầu và chỉ mở đúng một lần ở đây, sau khi hàm mất mát và siêu tham số (*hyperparameter*) đã khoá. Mục này đi qua sáu bước: thước đo, phạm vi chấm điểm, kết quả, chênh lệch giữa test và kiểm định, đối chứng Prophet, và kiểm chứng độ trễ pha.

8.5.1 Thước đo

Chỉ số chính của toàn bộ tài liệu là WAPE, sai số phần trăm tuyệt đối có trọng số:

$$WAPE = \frac{\sum_i |y_i - \hat{y}_i|}{\sum_i |y_i|} \times 100\% \quad (8.10)$$

Ba điểm về cách áp dụng.

Gộp một lần trên toàn bộ phạm vi. Tử số và mẫu số cộng dồn qua mọi trạm và mọi mốc thời gian trong phạm vi đang xét, rồi mới chia. Đây không phải trung bình của WAPE từng trạm; cách gộp này khiến trạm phát nhiều đóng góp nhiều hơn vào con số cuối, đúng với ý nghĩa vận hành là tổng sai số trên tổng sản lượng.

Mẫu số không bao giờ bằng 0. Phạm vi chấm điểm luôn yêu cầu dòng ban ngày và đo thật, nên trong tập được chấm không có trường hợp tổng sản lượng bằng 0.

Chọn WAPE thay cho MAPE. MAPE chia theo từng điểm nên nổ tung ở các mốc sản lượng gần 0 lúc rạng sáng và chập tối, chính những mốc chiếm phần lớn dữ liệu. WAPE đặt tổng

ở mẫu số nên không gặp vấn đề đó.

Chỉ số này do Kolassa và Schütz [13] đưa ra dưới tên tỷ số MAD/Mean.

Trong lĩnh vực dự báo bức xạ mặt trời, Temporal-Neto và cộng sự [9] cũng chọn chỉ số này và giải thích công dụng của phép lấy trọng số:

“The Weighted Absolute Percentage Error (WAPE) is defined as the weighted average of the MAE. The weighing can help distinguish smaller errors from more significant errors when dealing with low-volume data and when a data point can be minimal compared to the rest of the data, like intermittent data. This metric prevents small values from being compared in scale to larger values.”

Đó đúng là tình huống của dữ liệu quang điện: sản lượng lúc rạng sáng và chập tối nhỏ hơn hẳn lúc giữa trưa, và phép lấy trọng số theo sản lượng thật giữ cho những mốc nhỏ đó không bị đem so ngang thang với những mốc lớn.

8.5.2 Phạm vi chấm điểm

Không phải mọi dòng trong tập test đều dùng để tính chỉ số. Bốn điều kiện lọc được áp dụng như ở bước huấn luyện, đưa 510.468 dòng xuống 478.942 dòng.

Phép dịch nhãn lên $T+h$ loại thêm một phần nữa. Sau khi lọc, lưới thời gian không còn liên tục, nên `shift(-h)` theo trạm có thể trở tới dòng hợp lệ kế tiếp chứ không phải mốc $T+h$. Bước chấm điểm vì vậy đổi chiều mốc thời gian của dòng bị dịch tới và chỉ giữ dòng nào lệch đúng 15h phút: H1 loại 3.303 dòng còn **475.599**, H4 loại 12.964 dòng còn **465.818**. Kiểm lại trên tệp `prediction_audit.parquet` thì không còn dòng nào lệch tâm ở cả hai tâm.

Chỉ số được báo ở ba phạm vi lồng nhau. Điều kiện phạm vi xét **dòng nhãn tại $T+h$** , không phải dòng đặc trưng tại T : hai cột `energy_source` và `is_daylight` được dịch sang mốc nhãn thành `nan_energy_source` và `nan_is_daylight` rồi mới dùng để lọc.

- **Toàn bộ** — mọi dòng còn lại sau bốn điều kiện lọc và phép kiểm tâm.
- **Đo thật** — thêm điều kiện `nan_energy_source = measured`.
- **Đo thật ban ngày** — thêm điều kiện `nan_is_daylight = true`. Đây là phạm vi chính thức mà tài liệu dùng để báo chỉ số: 229.548 dòng ở H1 và 229.297 dòng ở H4.

Bản trước lọc theo cột tại T . Vì nhãn là sản lượng tại $T+h$, cách đó để lọt vào phạm vi “đo thật ban ngày” những dòng mà nhãn thực chất do bước điền khuyết của tầng ETL sinh ra hoặc rơi vào ban đêm. Sửa lại cho bám mốc nhãn làm WAPE H1 tăng 0,05 điểm và H4 tăng 0,13 điểm, tức con số cũ dễ hơn thực tế.

8.5.3 Kết quả

Bảng 8.57 là kết quả chính của toàn bộ tài liệu.

Bảng 8.56: Sai số WAPE trên tập test niêm phong theo ba phạm vi. Đọc từ ô kết quả của notebook `07_final_test.ipynb` và tệp `metrics_overall.json` của từng tầm.

Phạm vi	H1 (%)	H4 (%)
Toàn bộ	17,12	21,94
Đo thật	17,76	22,65
Đo thật ban ngày	17,74	22,62

Bảng 8.57: Sai số WAPE trên tập test niêm phong theo ba phạm vi. Đọc từ ô kết quả của notebook `07_final_test.ipynb` và tệp `metrics_overall.json` của từng tầm.

Cả hai tầm dùng cấu hình MAE, đúng hai cấu hình thắng trên tập kiểm định ở Mục 7.4.4.

Phạm vi chính thức gồm 229.548 dòng ở H1 và 229.297 dòng ở H4.

Sai số phân bố không đều giữa các trạm. Ở H1, trạm tốt nhất đạt 11,89% còn trạm kém nhất 28,32%, trung vị 18,12%; ở H4 khoảng này là 15,12% đến 35,88%, trung vị 22,72%. Chênh lệch hơn hai lần giữa hai đầu cho thấy một mô hình dùng chung cho cả 40 trạm vẫn để lại phần khác biệt riêng của từng trạm mà đặc trưng hiện có chưa mô tả hết.

8.5.4 Chênh lệch giữa sai số trên test và trên kiểm định

Bảng 8.59 đặt cạnh nhau ba con số của cùng một mô hình ở ba phạm vi đánh giá khác nhau. Chúng không so trực tiếp được với nhau, phải đọc kèm phạm vi.

Bảng 8.58: Cùng mô hình, ba phạm vi đánh giá. Đọc từ `08_baseline_prophet_test/optuna_vs_current_wape.csv`.

Phạm vi đánh giá	H1 (%)	H4 (%)
Optuna, gộp ba fold kiểm định	24,1767	29,4090
Test niêm phong, toàn bộ	17,0963	21,8627
Test niêm phong, đo thật ban ngày	17,7409	22,6181
Cùng phạm vi với Prophet	17,7934	22,3645

Bảng 8.59: Cùng mô hình, ba phạm vi đánh giá. Đọc từ `08_baseline_prophet_test/optuna_vs_current_wape.csv`.

Sai số trên test thấp hơn trên ba fold kiểm định tới hơn sáu điểm. Nguyên nhân nằm ở vị trí của hai tập trên trục thời gian, không phải ở việc test dễ hơn. Ba fold kiểm định nằm ở giai đoạn **sớm** của chuỗi, nơi lịch sử dùng để tính `lag_96` và các cửa sổ trượt còn ngắn, nên nhiều mốc dự báo thiếu ngữ cảnh. Tập test nằm ở **cuối** chuỗi, mọi mốc đều đã có đủ lịch sử phía sau.

Chênh lệch này đến từ phạm vi dữ liệu và không cho phép kết luận rằng tập test đã tham gia vào việc chọn mô hình, hàm mất mát và siêu tham số (*hyperparameter*) đều khoá trên tập Phát triển trước khi tập test được mở.

8.5.5 Đối chứng với Prophet

Chỉ số dự báo vượt trội

Một con số WAPE đứng một mình không nói lên chất lượng. Nó cần được đặt cạnh một mô hình đối chứng. Chỉ số Forecast Skill Score đo phần sai số cắt giảm được so với đối chứng. Dạng chuẩn của chỉ số, theo Nguyễn và Müsgens [14], là:

$$SS = 1 - \frac{A_f}{A_r} \quad (8.11)$$

với A_f và A_r lần lượt là thước đo sai số của mô hình cần đánh giá và của mô hình đối chứng. Tài liệu này lấy A là WAPE và trình bày kết quả theo phần trăm:

$$SS = \left(1 - \frac{WAP E_{\text{mô hình}}}{WAP E_{\text{đối chứng}}} \right) \times 100\% \quad (8.12)$$

Chỉ số này do Marquez và Coimbra [15] đưa vào lĩnh vực dự báo điện mặt trời: thay vì đọc một con số sai số tuyệt đối, ta đo phần sai số cắt giảm được so với một mô hình đối chứng.

Lợi ích của cách đọc này được nêu rõ ngay trong các nguồn gốc. Sở tay kiểm định dự báo của Nhóm công tác liên hợp WWRP/WGNE [16] chỉ ra rằng sai số thấp chưa chắc do mô hình giỏi:

“Skill refers to the increase in accuracy due purely to the “smarts” of the forecast system. Weather forecasts may be more accurate simply because the weather is easier to forecast – skill takes this into account.”

Điều này đúng với dữ liệu của đề tài: WAPE trên tập test thấp hơn trên ba fold kiểm định tới hơn sáu điểm phần trăm, mà nguyên nhân đã phân tích ở trên là do vị trí hai tập trên trục thời gian chứ không do mô hình khá lên. Chỉ số kỹ năng khử đúng loại chênh lệch đó, vì mô hình và đối chứng cùng chịu một điều kiện dữ liệu. Marquez và Coimbra nêu thêm một lợi ích thứ hai, rằng tỷ số này ổn định qua các tầm dự báo khác nhau:

“The direct use of statistical quantities to assign forecasting quality can be misleading because these metrics do not convey a measure of the variability of the time-series for the solar irradiance data. ...the ratio is preserved for widely different time horizons when the

same time averaging periods are used, and therefore provides a robust way to compare solar forecasting skills."

Nhờ đó hai mô hình chạy ở hai địa điểm hay hai tầm dự báo khác nhau mới so sánh được với nhau.

Nguyễn và Müsgens [14], trong bài phân tích tổng hợp các nghiên cứu dự báo điện mặt trời trên tạp chí *Journal of Renewable and Sustainable Energy*, viết dạng tổng quát của chỉ số như sau:

" $SS = \frac{A_f - A_r}{A_p - A_r}$, where A_f , A_p , and A_r are the accuracy measurements (e.g., mean squared errors) of the forecasts of interest, the perfect forecasts, and the reference forecasts, respectively. In solar forecasting, it is often assumed that the accuracy measure of a perfect forecast A_p is much smaller than the reference forecast's A_r and can be approximately 0. Therefore, SS can be reformulated as: $SS = 1 - A_f / A_r$."

Ký hiệu A ở đây là một thước đo sai số bất kỳ, MSE chỉ được nêu làm ví dụ. Chính bài đó nói tiếp rằng việc chọn thước đo nào là quyết định của người làm, và dẫn ra những lựa chọn khác nhau đã được công bố:

"To calculate SS , scholars need to decide on the accuracy measurement metric and the reference method. There are different suggestions for the accuracy measurement metrics. For example, Perez et al. (2013) used mean squared error (MSE), Morf (2021) recommended using Spearman's ρ as the skill score, etc."

Ở đó mô hình đối chứng là dự báo bằng 0 tại mọi thời điểm, nên mẫu số rút gọn mất. Tài liệu này dùng đối chứng là Prophet chứ không phải dự báo 0, nên mẫu số được viết đầy đủ, đúng như dạng tổng quát (8.11).

Công thức (8.12) vì vậy là công thức (8.11) với A là WAPE, khung công thức giữ nguyên không đổi một ký hiệu. WAPE được chọn vì đó là chỉ số chính đã dùng xuyên suốt báo cáo, nhờ vậy chỉ số kỹ năng đọc cùng một thang với mọi bảng phía trước. Cả tử số và mẫu số đều tính trên cùng một tập dòng nên phép chia không bị lệch phạm vi.

Việc đánh giá bằng một bộ nhiều chỉ số thay vì một con số duy nhất theo Zhang và cộng sự [11]; bản tiền án phẩm của bài đó viết:

"Conventional measures of solar forecasting accuracy include root mean square error (RMSE), mean bias error (MBE), and mean absolute error (MAE)."

Điều kiện so sánh

Prophet là mô hình chuỗi thời gian cộng tính, chỉ học xu thế và chu kỳ ngày/tuần từ chính lịch sử sản lượng, không dùng bất kỳ biến khí tượng nào. Nó được huấn luyện trong cùng cửa sổ thời gian Phát triển với mô hình chính, rồi dự báo tại đúng các mốc mục tiêu của tập test.

Khi chấm điểm, hai mô hình dùng cùng một tập dòng, cùng tử số và cùng mẫu số. Phạm vi này yêu cầu cả giá trị tại T lẫn nhãn tại $T+h$ đều là số đo thật, đồng thời dòng tại T là ban ngày, chặt hơn phạm vi đo thật ban ngày của mô hình chính, nên số dòng nhỏ hơn: 220.260 ở H1 và 202.955 ở H4. Kết quả ở Bảng 8.61.

Bảng 8.60: Đối chứng với Prophet trên cùng tập dòng. Đọc từ 08_baseline_prophet_test/prophet_bang_bao_cao.csv và prophet_test_summary.json.

Tầm và mô hình	Số dòng	WAPE (%)	RMSE	MAE	R^2
H1 — LightGBM	220.260	17,7934	3,4432	1,4010	0,9232
H1 — Prophet	220.260	35,2563	5,4666	2,7759	0,8063
<i>Skill Score H1</i>		+49,53%			
H4 — LightGBM	202.955	22,3645	4,3447	1,8483	0,8815
H4 — Prophet	202.955	35,0858	5,6147	2,8997	0,8021
<i>Skill Score H4</i>		+36,26%			

Bảng 8.61: Đối chứng với Prophet trên cùng tập dòng. Đọc từ 08_baseline_prophet_test/prophet_bang_bao_cao.csv và prophet_test_summary.json.

Giới hạn của phép đối chứng

Chênh lệch 17,46 điểm WAPE ở H1 là kết quả cuối cùng của hai phương án, nhưng không tách được thành phần đóng góp của riêng nhóm đặc trưng khí tượng. Lý do là hai mô hình khác nhau đồng thời ở hai điểm: thuật toán (phân rã chuỗi cộng tính so với cây tăng cường gradient) và tập đầu vào (không có biến khí tượng so với có). Muốn tách thì phải chạy thêm hai cấu hình đối chứng nữa: LightGBM bỏ hết biến khí tượng, và Prophet có biến ngoại sinh. Hai cấu hình đó nằm ở Mục 7.8.3 như hướng phát triển tiếp theo.

Ngoài ra, chỉ số vượt trội đo mức cải thiện so với một mô hình đối chứng cụ thể, không phải so với mọi phương án khả dĩ. Một đường cơ sở yếu hơn sẽ cho chỉ số cao hơn mà không phản ánh năng lực mô hình tốt hơn.

8.5.6 Kiểm chứng độ trễ pha trên mô hình cuối

Nguy cơ lớn nhất của một mô hình dự báo quang điện là nó học cách lặp lại giá trị vừa đo thay vì thật sự dự báo — khi đó đường dự báo trông rất khớp nhưng thực chất chỉ là đường thực tế bị đẩy sang phải. Notebook 09_kiem_chung_tre pha đo trực tiếp hiện tượng đó trên 478.902 dòng dự báo H1 của tập test, bằng cách so mốc đạt đỉnh của đường dự báo với mốc đạt đỉnh của đường thực tế, cho từng trạm từng ngày:

```
--- LECH DINH LOCAL: 40 site x 5,080 ngày ---
lech_phut duong = du bao den SAU thuc te (dich phai / tre). am = du bao den SOM.

count    5080.00
mean     -1.05
std       78.63
min      -495.00
25%      -45.00
50%       15.00
75%       45.00
max       270.00

So ngay du bao dich PHAI (tre) : 2,791 / 5,080 (54.9%)
So ngay dung khop (lech = 0)   : 384 / 5,080 (7.6%)
So ngay du bao dich TRAI (som) : 1,905 / 5,080 (37.5%)
```

Trung bình lệch $-1,05$ phút, tức gần như không thiên về bên nào; trung vị $+15$ phút, đúng một bước. Nếu mô hình chỉ lặp lại giá trị vừa đo thì độ lệch phải bằng đúng tầm dự báo ở gần như mọi ngày, và tỷ lệ dịch phải sẽ tiến tới 100%. Con số thực tế là 54,9% dịch phải so với 37,5% dịch trái, phân bố hai phía, không phải dấu hiệu của mô hình sao chép.

Độ lệch chuẩn 78,63 phút cho thấy mức phân tán giữa các ngày vẫn lớn, và 32 trên 40 trạm có trung vị nghiêng về phía trễ. Đây là giới hạn còn lại của mô hình, ghi nhận để lần huấn luyện sau xử lý tiếp.

Notebook còn đo một giả thuyết cạnh tranh: nếu độ lệch bắt nguồn từ việc dữ liệu khí tượng chỉ có độ hạt một giờ, thì đỉnh thực tế xảy ra càng gần cuối khối giờ sẽ càng lệch nhiều. Số đo bác bỏ điều đó, cả bốn vị trí trong khối giờ đều cho trung vị đúng 15 phút, xem Bảng 8.63.

Bảng 8.62: Độ lệch đỉnh theo vị trí của đỉnh thực tế trong khối giờ. Đọc từ tệp kết quả 09_kiem_chung_tre pha/lech_theo_vi_tri_trong_gio_h1.csv.

Phút trong giờ	Số ngày	Độ lệch trung vị (phút)
0–14	1.052	15,0
15–29	1.112	15,0
30–44	1.631	15,0
45–59	1.285	15,0

Bảng 8.63: Độ lệch đỉnh theo vị trí của đỉnh thực tế trong khối giờ. Đọc từ tệp kết quả 09_kiem_chung_tre pha/lech_theo_vi_tri_trong_gio_h1.csv.

8.6 Giải thích mô hình bằng SHAP

Cây tăng cường gradient cho sai số thấp nhưng không tự nói được nó dựa vào đâu. Mục này dùng SHAP, đi qua bốn bước: cơ sở phương pháp, tầm quan trọng tổng thể, mô xẻ ba dự báo cụ thể, và giới hạn diễn giải.

8.6.1 Cơ sở phương pháp

SHAP quy phần đóng góp theo giá trị Shapley của lý thuyết trò chơi hợp tác: mỗi đặc trưng được coi là một người chơi, và phần đóng góp của nó là mức thay đổi trung bình của dự báo khi thêm nó vào mọi tổ hợp đặc trưng khác. Cách quy này có tính chất cộng, tổng đóng góp của tất cả đặc trưng cộng với giá trị nền bằng đúng dự báo, nên được ở mức từng dòng dữ liệu. Lundberg và Lee [10] là công trình đề xuất khung thống nhất này.

Phạm vi tính: mô hình thắng ở tầm H1 (cấu hình MAE), chạy trên toàn bộ 478.902 dòng của tập test với 54 đặc trưng. Giá trị SHAP tính trên thang mục tiêu đã chuẩn hoá k , không phải thang kWh.

Ma trận đặc trưng dùng để tính SHAP lấy đúng tệp `X_test_h1.parquet` mà bước đánh giá đã ghi ra, nên phạm vi dòng trùng khít với Phần 5. Bước này đã được chạy lại một lần nữa sau khi mô hình được huấn luyện lại: kết quả xếp hạng và giá trị SHAP trùng khít tới từng chữ số với lần chạy trước, phù hợp với chế độ tắt định nêu ở Mục 7.4.5.

8.6.2 Tầm quan trọng tổng thể

Bảng 8.65 xếp hạng đặc trưng theo trung bình trị tuyệt đối giá trị SHAP trên toàn tập test.

Bảng này cho một kết quả đáng chú ý khi đặt cạnh bảng thông tin tương hỗ ở Mục 7.3.7. Ở bước chọn đặc trưng, bốn vị trí đầu đều là thống kê cửa sổ trượt một giờ. Ở đây, đứng đầu lại là `direct_normal_irradiance` — một biến khí tượng đo được — và vị trí thứ tư thuộc về `ghi_cs_mt`, tức bức xạ trời quang **tại thời điểm mục tiêu**.


Hai điểm rút ra. Thứ nhất, thông tin tương hỗ đo quan hệ của một đặc trưng với mục tiêu khi đứng riêng, còn SHAP đo phần đóng góp của nó trong mô hình đã huấn luyện, nơi các đặc trưng chia nhau thông tin; hai thước đo trả lời hai câu hỏi khác nhau nên không buộc phải trùng thứ hạng. Thứ hai, việc `ghi_cs_mt` lọt vào nhóm bốn đầu là bằng chứng cho thấy nhóm đặc trưng tắt định tại $T+h$ ở Mục 3.4 thực sự được mô hình dùng, chứ không phải cột thừa.

Hình 8.13 trình bày phân bố giá trị SHAP của từng đặc trưng trên toàn bộ tập test.

Bảng 8.64: Mười đặc trưng có tầm quan trọng tổng thể lớn nhất, đo bằng trung bình trị tuyệt đối giá trị SHAP. Đọc từ `08_explain/shap_importance.csv`.

Hạng	Đặc trưng	SHAP trung bình	Nhóm
1	direct_normal_irradiance	0,0872	Khí tượng đo được
2	ky_vong	0,0851	Quy mô trạm
3	rolling_min_4	0,0799	Lịch sử chuỗi
4	ghi_cs_mt	0,0745	Trời quang tại $T+h$
5	rolling_max_4	0,0671	Lịch sử chuỗi
6	rolling_mean_4	0,0565	Lịch sử chuỗi
7	minute_of_day	0,0469	Thời gian
8	tran_cong_suat	0,0391	Quy mô trạm
9	rolling_std_4	0,0334	Lịch sử chuỗi
10	weather_condition_enc	0,0219	Khí tượng phân loại

Bảng 8.65: Mười đặc trưng có tầm quan trọng tổng thể lớn nhất, đo bằng trung bình trị tuyệt đối giá trị SHAP. Đọc từ `08_explain/shap_importance.csv`.



Hình 8.13: (Trích xuất từ Notebook 08_explainable_ai.ipynb) Biểu đồ beeswarm. Mỗi điểm là một dòng dữ liệu; vị trí ngang là giá trị SHAP, màu là độ lớn của chính đặc trưng đó.

8.6.3 Giải thích ba dự báo cụ thể


Tính cộng của SHAP cho phép mô tả một dự báo đơn lẻ. Notebook chọn ba trường hợp tương phản trong tập test, ghi ở Bảng 8.67.

Bảng 8.66: Ba dự báo được mô tả. Đọc từ `08_explain/local_shap_cases.csv`.

Trường hợp	Trạm	Thời điểm	Thực tế (kWh)	Tổng SHAP
Đẩy dự báo lên	10	07/04/2022 10:30	5,9688	+0,5972
Kéo dự báo xuống	40	18/04/2022 08:00	0,1250	-0,6860
Gần mức nền	28	21/02/2022 11:15	1,8066	-0,0004

Bảng 8.67: Ba dự báo được mô tả. Đọc từ `08_explain/local_shap_cases.csv`.

Ba trường hợp này minh họa ba chế độ khác nhau của mô hình. Ở ca đẩy lên, đóng góp lớn nhất đến từ `direct_normal_irradiance` (+0,1047) và `rolling_min_4` (+0,0695) — bức xạ trực xạ mạnh cộng với nền sản lượng giờ trước còn cao. Ở ca kéo xuống, hai đặc trưng đẩy mạnh nhất theo chiều âm là `rolling_max_4` (-0,1953) và `rolling_min_4` (-0,1111), kèm `direct_normal_irradiance` (-0,1019): sáng sớm, sản lượng giờ trước gần như bằng không và bức xạ trực xạ chưa lên. Ở ca gần nền, tổng đóng góp gần triệt tiêu vì các phần dương và âm cân nhau. Ba hình dạng thác trình bày ở Hình 8.14.



Hình 8.14: (Trích xuất từ Notebook 08_explainable_ai.ipynb) Biểu đồ thác cho hai dự báo tương phản. **Trên:** trường hợp các đặc trưng cùng đẩy dự báo lên. **Dưới:** trường hợp cùng kéo xuống.

8.6.4 Giới hạn diễn giải


SHAP quy phần đóng góp của đặc trưng vào dự báo của mô hình, không phải vào sản lượng thật. Nó cho biết mô hình đã dựa vào đâu, không cho biết quan hệ nhân quả vật lý. Khi hai đặc trưng tương quan cao, mà Mục 7.3.7 cho thấy có nhiều cặp như vậy, phần đóng góp có thể bị chia giữa chúng theo cách phụ thuộc vào cấu trúc cây đã học, nên không nên đọc thứ hạng như một xếp hạng tầm quan trọng vật lý.

8.7 Ứng dụng trực quan hoá kết quả

Kết quả dự báo được đưa vào một ứng dụng Streamlit gồm ba trang, mã nguồn tại `srcs/07_dashboard/`. Ứng dụng đọc lại đúng các tệp kết quả mà Phần 5 dùng, không tính lại chỉ số. Ba trang lần lượt ở Hình 8.15, Hình 8.16 và Hình 8.17.

8.7.1 Trang giám sát chuỗi thời gian


Trang này đặt đường thực tế cạnh đường dự báo theo từng trạm và từng khoảng thời gian, kèm bảng chỉ số theo trạm và biểu đồ đối chiếu với Prophet.



Hình 8.15: Trang 1 của ứng dụng, giám sát chuỗi thời gian theo trạm.

8.7.2 Trang giải thích dự báo


Trang này đưa kết quả SHAP ở Mục 7.6 lên giao diện: tỷ trọng đóng góp theo nhóm đặc trưng, xếp hạng đặc trưng, và giải thích một dự báo cụ thể do người dùng chọn.



Hình 8.16: Trang 2 của ứng dụng, giải thích dự báo bằng SHAP.

8.7.3 Trang dự báo và phân tích giả định

Trang này gọi `forecast_service.py` để sinh dự báo mới. Điểm cần nêu về mặt kỹ thuật: dịch vụ này **đọc lại** `clip_k` và các tham số chuẩn hoá từ `model_config.json` của chính mô hình đang dùng, thay vì khai báo lại trong mã phục vụ. Nhờ vậy phép nhân ngược từ k về kWh ở lúc suy luận trùng khớp với lúc huấn luyện; nếu hai bên khai báo riêng thì chỉ cần một lần sửa cấu hình là kết quả trên giao diện lệch khỏi kết quả trong báo cáo mà không ai phát hiện.



Hình 8.17: Trang 3 của ứng dụng, dự báo và phân tích giả định.

8.8 Kết luận và hướng phát triển

Mục này tổng kết ba phần: kết quả đạt được, giới hạn của công trình, và hướng phát triển.

8.8.1 Kết quả đạt được

Quy trình dựng được một mô hình LightGBM dùng chung cho 40 trạm quang điện, đạt WAPE 17,74% ở tầm 15 phút và 22,62% ở tầm một giờ trên tập test niêm phong, phạm vi đo thật ban ngày. So với đối chứng Prophet trên cùng tập dòng, chỉ số vượt trội đạt +49,53% và +36,26%.

Điều đáng nói hơn con số là cách các con số đó được bảo vệ. Năm rào chắn ở Mục 7.1.5 được kiểm chứng bằng số liệu chứ không bằng lập luận: phép ghép thời tiết nhân quả đưa số dòng dùng thời tiết tương lai về 0; thống kê quy mô tính riêng theo từng fold; cận cắt suy từ phân vị của tập huấn luyện; tập test mở đúng một lần. Khi phát hiện tầm H4 có thể cho kết quả tốt hơn với cấu hình MAE huấn luyện sau, nhóm không chấm lại tập test, vì mở tập niêm phong lần thứ hai chính là điều mà toàn bộ quy trình được dựng ra để ngăn.

8.8.2 Giới hạn

- **Bộ dữ liệu độc lập nhỏ hơn con số 42.** Bốn mươi hai vị trí lắp đặt điện mặt trời nằm trên năm khuôn viên, nên dữ liệu khí tượng bị nhân bản giữa các trạm cùng khuôn viên; số mẫu thời tiết độc lập thực chất là năm.
- **Sai số phân bố không đều giữa các trạm,** từ 11,89% tới 28,32% ở tầm H1, và 15,12% tới 35,88% ở tầm H4. Mô hình dùng chung chưa mô tả hết phần khác biệt riêng của từng trạm.
- **Độ trễ pha còn tồn tại ở mức thấp:** trung vị +15 phút, và 32 trên 40 trạm nghiêng về phía trễ.
- **Phép đối chứng Prophet không tách được đóng góp của biến khí tượng,** vì hai mô hình khác nhau đồng thời ở thuật toán và tập đầu vào.
- **Hai siêu tham số (*hyperparameter*) dừng ngay tại biên miền tìm kiếm,** nên không thể tuyên bố cấu hình hiện tại là tối ưu.
- **Thời tiết chỉ có độ hạt một giờ,** và bước hạ độ hạt mới đưa tỷ lệ bước có giá trị thay đổi lên 76,7%, chưa phủ hết các khối rìa sáng và rìa chiều.

8.8.3 Hướng phát triển

Bốn việc cụ thể, xếp theo mức dễ làm:

1. Huấn luyện bổ sung cấu hình MAE cho tầm H4 rồi khoá lại trước khi mở một tập test mới, để phép so ở H4 có đủ ba hàm mất mát.
2. Mở rộng miền tìm kiếm ở hai chỗ chạm biên, hạ cận dưới của `subsample` và nâng cận trên của `reg_alpha`.
3. Chạy hai cấu hình đối chứng còn thiếu để tách phần đóng góp của nhóm đặc trưng khí tượng: một LightGBM bỏ hết biến khí tượng, và một Prophet có biến ngoại sinh.
4. Xử lý phần khác biệt giữa các trạm, hoặc bằng đặc trưng riêng cho trạm, hoặc bằng cách hiệu chỉnh đầu ra theo từng trạm sau khi dự báo.

Tài liệu tham khảo

- [1] S. Wimalaratne, D. Haputhanthri, S. Kahawala, G. Gamage, D. Alahakoon và A. Jennings (2022), “UNISOLAR: An Open Dataset of Photovoltaic Solar Energy Generation in a Large Multi-Campus University Setting”, *15th International Conference on Human System Interaction (HSI)*, IEEE. DOI: [10.1109/HSI55341.2022.9869474](https://doi.org/10.1109/HSI55341.2022.9869474)
- [2] M. Roy, V. Pyltsov và Y. Hu (2025), “IISE PG&E Energy Analytics Challenge 2025: Hourly-Binned Regression Models Beat Transformers in Load Forecasting”, Columbia University, arXiv:2505.11390. <https://arxiv.org/abs/2505.11390>
- [3] T. Kim, W. Ko và J. Kim (2019), “Analysis and Impact Evaluation of Missing Data Imputation in Day-ahead PV Generation Forecasting”, *Applied Sciences*, tập 9, số 1, bài 204. DOI: [10.3390/app9010204](https://doi.org/10.3390/app9010204)
- [4] X. Li, G. Du, Y. Li, Z. Ma, L. Liu, M. Jiang, F. Liu và T. Mu (2025), “Outlier Detection of Photovoltaic Power Generation System Data Based on GMM-IF Algorithm”, *IEEE Access*, tập 13, tr. 108823–108837. DOI: [10.1109/ACCESS.2025.3581641](https://doi.org/10.1109/ACCESS.2025.3581641)
- [5] B. Haurwitz (1945), “Insolation in Relation to Cloudiness and Cloud Density”, *Journal of Meteorology*, tập 2, số 3, tr. 154–166. https://journals.ametsoc.org/view/journals/atsc/2/3/1520-0469_1945_002_0154_iirtca_2_0_co_2.xml
- [6] M. D. Bailey và cộng sự (2024), “Temporal and Spatial Downscaling for Solar Radiation”, arXiv:2405.11046. <https://arxiv.org/abs/2405.11046>
- [7] N. A. Engerer và F. P. Mills (2014), “KPV: A clear-sky index for photovoltaics”, *Solar Energy*, tập 105, tr. 679–693. DOI: [10.1016/j.solener.2014.04.019](https://doi.org/10.1016/j.solener.2014.04.019)
- [8] S. Dev, T. AlSkaif, M. Hossari, R. Godina, A. Louwen và W. van Sark (2018), “Solar Irradiance Forecasting Using Triple Exponential Smoothing”, *IEEE International Conference on Smart Energy Systems and Technologies (SEST)*. arXiv:1807.05872. <https://arxiv.org/abs/1807.05872>
- [9] A. Temporal-Neto và cộng sự (2025), “PIN: A new metric to evaluate solar irradiance forecast models”, *Energy Reports*, tập 13, tr. 1–12. DOI: [10.1016/j.egyr.2025.01.076](https://doi.org/10.1016/j.egyr.2025.01.076). <https://www.sciencedirect.com/science/article/pii/S2352484725000770>

- [10] S. M. Lundberg và S.-I. Lee (2017), “A Unified Approach to Interpreting Model Predictions”, *Advances in Neural Information Processing Systems (NeurIPS)*, tập 30. arXiv:1705.07874. <https://arxiv.org/abs/1705.07874>
- [11] J. Zhang, A. Florita, B.-M. Hodge, S. Lu, H. F. Hamann, V. Banunarayanan và A. M. Brockway (2015), “A suite of metrics for assessing the performance of solar power forecasting”, *Solar Energy*, tập 111, tr. 157–175. DOI: [10.1016/j.solener.2014.10.016](https://doi.org/10.1016/j.solener.2014.10.016). Bản tiền ấn phẩm hội nghị của cùng nhóm tác giả: NREL/CP-5500-60142, *3rd International Workshop on Integration of Solar Power into Power Systems*, London, Anh, 21–22/10/2013.
- [12] Đặng Nhã và Anh Dương (2025), “Data Version Control”, tài liệu bài giảng *AI VIET NAM — All-in-One 2025*, slide 9 (*Theory Perspective — ML Life Cycle*).
- [13] S. Kolassa và W. Schütz (2007), “Advantages of the MAD/Mean ratio over the MAPE”, *Foresight: The International Journal of Applied Forecasting*, số 6, tr. 40–43.
- [14] T. N. Nguyen và F. Müsgens (2026), “A meta-analysis of solar forecasting based on skill score”, *Journal of Renewable and Sustainable Energy* (AIP Publishing), tập 18, số 2, bài 026102. DOI: [10.1063/5.0300682](https://doi.org/10.1063/5.0300682). Bản tiền ấn phẩm truy cập mở: <https://arxiv.org/abs/2208.10536>
- [15] R. Marquez và C. F. M. Coimbra (2013), “Proposed Metric for Evaluation of Solar Forecasting Models”, *Journal of Solar Energy Engineering* (ASME), tập 135, số 1, bài 011016. DOI: [10.1115/1.4007496](https://doi.org/10.1115/1.4007496)
- [16] WWRP/WGNE Joint Working Group on Forecast Verification Research, “Forecast Verification: Issues, Methods and FAQ”, Bureau of Meteorology, Australia, cập nhật ngày 20/08/2009. https://www.cawcr.gov.au/projects/verification/verif_web_page.html
- [17] V. P. Lonij, A. E. Brooks, K. Koch và A. D. Cronin (2012), “Analysis of 80 Rooftop PV Systems in the Tucson, AZ Area”, *38th IEEE Photovoltaic Specialists Conference (PVSC)*, tr. 549–553. DOI: [10.1109/PVSC.2012.6317674](https://doi.org/10.1109/PVSC.2012.6317674). Nguồn của chỉ số K dùng phân vị sản lượng đo được của chính hệ thống làm mẫu số.

Kết luận và Hướng phát triển

9.1 Kết luận Tổng quan

[Tóm tắt lại việc hoàn thành các mục tiêu dự án: Xây dựng thành công Data Warehouse, làm sạch dữ liệu nhiễu, và phát triển hệ thống Dashboard trực quan giúp doanh nghiệp chuyển đổi từ quản lý thụ động sang giám sát dựa trên dữ liệu.]

9.2 Khuyến nghị Chiến lược (Actionable Insights)

[Đề xuất các hành động cụ thể: Lắp đặt hệ thống làm mát tự động để giảm suy hao nhiệt, thiết lập quy trình kiểm tra Inverter định kỳ để khắc phục độ nhiễu ban đêm, và ứng dụng kết quả dự báo để lập kế hoạch vệ sinh tấm pin.]

9.3 Hạn chế của Dự án

[Những giới hạn về phần cứng, thời gian xử lý dữ liệu lớn, hoặc sự thiếu hụt của các mô hình học sâu (Deep Learning) phức tạp hơn.]

9.4 Hướng phát triển trong tương lai

9.4.1 Nâng cấp Hệ thống Phân tích Dự đoán (Predictive Analytics)

[Tích hợp các mô hình Machine Learning mạnh mẽ hơn (XGBoost, LSTM) để dự báo biến động công suất theo thời gian thực.]

9.4.2 Tự động hóa và Đưa lên Đám mây (Cloud & Automation)

[Triển khai toàn bộ Pipeline ETL lên các dịch vụ Cloud như AWS/GCP để xử lý luồng dữ liệu Streaming từ các cảm biến IoT.]

Phụ lục A: Kế hoạch Thực hiện

[Bảng phân công nhiệm vụ chi tiết và kế hoạch 14 tuần thực hiện dự án của các thành viên.]


Phụ lục B: Cấu trúc Mã nguồn

[Sơ đồ cấu trúc thư mục của package Python du_an_tot_nghiep và các script tiện ích.]

Phụ lục C: Vòng đời học máy — bản nhấ gốc

Hình 8.3 ở Mục 7.1.4 dùng bản đã chuyển nhấ sang tiếng Việt. Phụ lục này đặt bản giữ nguyên nhấ tiếng Anh của tài liệu gốc, để đối chiếu khi cần tra lại thuật ngữ.

◇ ML Life Cycle



Hình 9.1: Vòng đời học máy, giữ nguyên nhấ tiếng Anh của tài liệu gốc. Nguồn: *Data Version Control* [12].

Tài liệu Tham khảo

- [1] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control*. 5th ed. Wiley.
- [2] Taylor, S. J., & Letham, B. (2018). Forecasting at Scale. *The American Statistician*, 72(1), 37–45.
- [3] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of KDD 2016*, 785–794.
- [5] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.
- [6] Vaswani, A., et al. (2017). Attention Is All You Need. *Proceedings of NeurIPS 2017*, 5998–6008.
- [7] Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit*. 3rd ed. Wiley.
- [8] NASA POWER Project. (2024). <https://power.larc.nasa.gov/>.
- [9] Supabase Documentation. (2024). <https://supabase.com/docs>.
- [10] IEA – International Energy Agency. (2024). <https://www.iea.org/reports/renewables-2024>.
- [11] Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly Detection: A Survey. *ACM Computing Surveys*, 41(3), Article 15.
- [12] Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.