

TRƯỜNG CAO ĐẲNG FPT POLYTECHNIC



FPT POLYTECHNIC

DỰ ÁN TỐT NGHIỆP
CHUYÊN NGÀNH: XỬ LÝ DỮ LIỆU

PHÂN TÍCH HIỆU SUẤT VÀ DỰ BÁO SẢN LƯỢNG HỆ THỐNG ĐIỆN MẶT TRỜI

Nhóm thực hiện: The Outliers

Sinh viên thực hiện:

- | | |
|---------------------|---------|
| 1. Nguyễn Vũ Nhật | PS44442 |
| 2. Nguyễn Văn Sỹ | PS43671 |
| 3. Lê Công Toàn | PS44145 |
| 4. Nguyễn Xuân Hùng | PS44527 |
| 5. Ngô Tấn Đạt | PS44589 |

Giảng viên hướng dẫn: Thầy Văn Công Khanh

TP. HỒ CHÍ MINH, THÁNG 8 NĂM 2026

Lời cảm ơn

Lời đầu tiên, nhóm tác giả xin bày tỏ lòng biết ơn sâu sắc và chân thành nhất đến Ban Giám hiệu Trường Cao đẳng FPT Polytechnic, cùng toàn thể quý Thầy, Cô thuộc Bộ môn Công nghệ Thông tin và Chuyên ngành Xử lý Dữ liệu đã tận tình truyền đạt những tri thức nền tảng và chuyên sâu về Kho dữ liệu (Data Warehouse), Quy trình ETL, Phân tích Khám phá Dữ liệu (EDA), và Hệ thống Thông minh Doanh nghiệp (Business Intelligence) trong suốt thời gian nhóm học tập và rèn luyện tại trường.

Đặc biệt, nhóm xin gửi lời tri ân sâu sắc nhất đến Thầy Văn Công Khanh – Giảng viên Hướng dẫn dự án tốt nghiệp. Trong suốt quá trình thực hiện đề tài, Thầy đã luôn dành nhiều tâm huyết định hướng phương pháp luận khoa học, kiên nhẫn chỉ dẫn từ việc kiểm định chất lượng dữ liệu, thiết kế mô hình hóa kho dữ liệu Galaxy Schema, đến tư duy phân tích các giá trị kinh doanh thực tiễn. Những lời phản biện sắc bén, sự động viên kịp thời và những góp ý quý báu của Thầy chính là nguồn động lực to lớn giúp nhóm vượt qua các thử thách kỹ thuật và hoàn thành đồ án tốt nghiệp này theo đúng chuẩn mực phân tích dữ liệu thực tế tại doanh nghiệp.

Nhóm cũng xin gửi lời cảm ơn trân trọng đến quý Thầy, Cô trong Hội đồng phản biện tốt nghiệp đã dành thời gian quý báu đánh giá và đóng góp những ý kiến chuyên môn sâu sắc giúp đề tài ngày càng hoàn thiện hơn.

Sau cùng, chúng con xin gửi lời tri ân sâu sắc đến gia đình, người thân cùng tất cả bạn bè đã luôn là điểm tựa vững chắc, đồng hành và tạo mọi điều kiện thuận lợi nhất để chúng con hoàn thành trọn vẹn đồ án tốt nghiệp này.

Mặc dù nhóm đã nỗ lực hết mình với tinh thần trách nhiệm cao nhất, song do giới hạn về kinh nghiệm thực tế, báo cáo khó tránh khỏi những thiếu sót nhất định. Nhóm rất mong tiếp tục nhận được sự chỉ bảo và đóng góp ý kiến quý báu từ Thầy Văn Công Khanh và quý Thầy, Cô.

TP. Hồ Chí Minh, tháng 8 năm 2026
Nhóm sinh viên thực hiện (The Outliers)

Nhận xét của Giảng viên Hướng dẫn

1. Về tinh thần, thái độ làm việc của nhóm sinh viên:

2. Về chất lượng nội dung và kết quả thực hiện đề tài:

3. Về tính thực tiễn và khả năng ứng dụng của sản phẩm:

4. Những hạn chế cần khắc phục:

5. Điểm đánh giá và kết luận:

• Điểm số: / 10

TP. Hồ Chí Minh, ngàythángnăm 2026

Giảng viên Hướng dẫn

Văn Công Khanh

Nhận xét của Giảng viên Phản biện

1. Về bố cục, hình thức trình bày của báo cáo tốt nghiệp:

2. Về phương pháp nghiên cứu và hàm lượng công nghệ kỹ thuật:

3. Về kết quả thực nghiệm và giá trị ứng dụng thực tế:

4. Các câu hỏi chất vấn dành cho nhóm sinh viên tại buổi bảo vệ:

5. Điểm đánh giá và kết luận:

• Điểm số: / 10

TP. Hồ Chí Minh, ngàythángnăm 2026

Giảng viên Phản biện

(Ký và ghi rõ họ tên)

Tóm tắt Dự án

Dự án tốt nghiệp “*Phân tích Hiệu suất và Dự báo Sản lượng Hệ thống Điện Mặt Trời*” có mục tiêu nhằm xây dựng một quy trình phân tích và khai phá dữ liệu toàn diện cho hệ thống điện mặt trời quang điện (PV), bao gồm ba phân hệ cốt lõi: Kỹ thuật Dữ liệu (Data Engineering & Data Warehouse), Phân tích Trực quan Quản trị (Business Intelligence trên Tableau), và Dự báo Sản lượng bằng Học máy (Machine Learning & Explainable AI).

1. Bối cảnh và Nguồn Dữ liệu Nghiên cứu: Dự án sử dụng bộ dữ liệu thực tế UNISOLAR thu thập từ 42 trạm phát điện mặt trời áp mái với tổng công suất 2.428 kWp phân bố tại 5 khuôn viên của Đại học La Trobe (bang Victoria, Úc) trong chu kỳ 28 tháng (2020–2022), bao gồm 2.731.946 bản ghi sản lượng chu kỳ 15 phút. Dữ liệu sản lượng được tích hợp đồng bộ với dữ liệu khí tượng tái phân tích ERA5-Land (bức xạ GHI, DNI, DHI, nhiệt độ, độ ẩm, sức gió và mây che phủ) thu thập qua Open-Meteo API.

2. Kỹ thuật Dữ liệu, Xử lý Dị thường và Kho Dữ liệu (ETL & DWH): Nhóm đã xây dựng pipeline ETL tự động bằng ngôn ngữ Python:

- Chuẩn hóa chuỗi thời gian về lưới 15 phút cố định, giải quyết 561 điểm đứt gãy dữ liệu thông qua cơ chế Điền khuyết nhân quả (Causal Cascade Imputation).
- Áp dụng 5 rào chắn vật lý kết hợp thuật toán phân lớp lai GMM-IF (Gaussian Mixture Model – Isolation Forest) để lọc sạch nhiễu cảm biến và phân loại chính xác 33.280 bản ghi bất thường thành 6 mã nguyên nhân kỹ thuật (zero_drift, night_leakage, underperformance, inverter_zero_output, thermal_derating, inverter_clipping).
- Mô hình hóa Kho Dữ liệu trên hệ quản trị PostgreSQL (nền tảng Supabase Cloud) theo cấu trúc Lược đồ Thiên hà (Galaxy Schema) gồm 2 bảng Fact (fact_solar_energy_gen, fact_weather) kết nối 4 bảng Dimension dùng chung, được tối ưu hóa bằng phân vùng bảng vật lý và chỉ mục phức hợp. Xây dựng các bảng Data Marts (BI Mart) phục vụ trực quan hóa hiệu năng cao.

3. Hệ thống Trực quan Quản trị (Business Intelligence trên Tableau): Thiết lập đường truyền kết nối trực tiếp PostgreSQL bảo mật TLS/SSL từ Tableau Desktop tới Supabase Connection Pooler. Xây dựng bộ 3 Dashboard tương tác:

- Executive Overview:* Giám sát tổng sản lượng phát điện (74,98 GWh), hệ số hiệu suất trung bình (PR 78,4%), hệ số công suất (CF) và năng suất riêng (Specific Yield 4,35 kWh/kWp/ngày).
- Loss & Financial Analysis:* Phân tích chi tiết tổn thất sản lượng do nhiệt độ tăng cao (14,8%), tổn thất do giới hạn công suất biến tần (Inverter Clipping 2,3%) và ước tính tổn thất tài chính theo biểu giá điện FiT.
- Plant Health & O&M Diagnostic:* Thống kê tần suất và phân bố của 6 mã dị thường kỹ thuật theo từng trạm phát và khuôn viên, hỗ trợ định hướng bảo trì thiết bị.

4. Khai phá Dữ liệu và Dự báo Sản lượng Học máy (Machine Learning): Xây dựng quy trình học máy tuân thủ nguyên lý nhân quả nghiêm ngặt (chống rò rỉ dữ liệu), trích xuất 40 đặc trưng chọn lọc (mở rộng thành 53 đặc trưng sau khi thêm các biến trễ mục tiêu $T + h$ cho mô hình dự báo trực tiếp H1) từ chuỗi thời gian, bức xạ quang học và góc chiếu mặt trời tất định Haurwitz/NOAA:

- Đánh giá trên sơ đồ kiểm tra chéo chuỗi thời gian 3-Fold Expanding Window; tối ưu hóa siêu tham số mô hình LightGBM hồi quy L1/Huber bằng thuật toán Bayesian TPE qua 50 Trials Optuna.
- Mô hình đạt sai số phần trăm tuyệt đối gia quyền WAPE 12,48% trên tập kiểm thử (Test) niêm phong, cải thiện vượt trội so với mô hình cơ sở Facebook Prophet.
- Ứng dụng kỹ thuật SHAP TreeExplainer để giải thích mức độ đóng góp toàn cục và cục bộ của các đặc trưng vào kết quả dự báo.
- Đóng gói sản phẩm thành dịch vụ dự báo độc lập (`forecast_service.py`) và ứng dụng giao diện trực quan tương tác bằng Streamlit (`app.py`).

Mục Lục

Lời cảm ơn	1
Nhận xét của Giảng viên Hướng dẫn	2
Nhận xét của Giảng viên Phản biện	3
Tóm tắt Dự án	4
Danh mục Từ viết tắt	13
1 Tổng quan Đề tài và Bài toán Dự án	14
1.1 Bối cảnh Thực tế và Lý do Chọn Đề tài	14
1.2 Thực trạng và Thách thức trong Xử lý Dữ liệu Năng lượng Mặt trời	14
1.3 Mục tiêu và Nhiệm vụ của Dự án	15
1.3.1 Mục tiêu Tổng quát	15
1.3.2 Mục tiêu và Nhiệm vụ Cụ thể	15
1.4 Đối tượng và Phạm vi Nghiên cứu	16
1.5 Ý nghĩa Khoa học và Giá trị Ứng dụng Thực tiễn	17
1.6 Kế hoạch Thực hiện Dự án (14 Tuần Agile/Scrum)	18
1.7 Bố cục Báo cáo Đồ án Tốt nghiệp	19
2 Cơ sở Lý thuyết và Kiến trúc Hệ thống	20
2.1 Cơ sở Lý thuyết	20
2.1.1 Khái quát về Phân tích Dữ liệu trong Ngành Năng lượng Tái tạo	20
2.1.2 Các Chỉ số Hiệu năng Cốt lõi (KPIs) và Bài toán Tổn thất Vận hành	20
2.1.3 Hệ thống Kho Dữ liệu (Data Warehouse) và Quy trình ETL	21
2.1.4 Mô hình Dữ liệu Đa chiều và Lược đồ Thiên hà (Galaxy Schema)	21
2.1.5 Phương pháp Phát hiện Dị thường và Lọc Nhiễu Nghiệp vụ	22
2.1.6 Trực quan hóa Dữ liệu trong Business Intelligence (BI)	22
2.2 Phân tích Yêu cầu Nghiệp vụ (Business Requirements)	22
2.2.1 Phân tích Các Bên Liên quan (Stakeholders)	22
2.2.2 Hệ thống Chỉ số Đo lường (KPI Framework)	23
2.3 Kiến trúc Hệ thống Đề xuất (6-Layer Data Pipeline)	23
2.4 Từ điển Dữ liệu Nghiệp vụ (Data Dictionary)	24
3 Thu thập, Tiền xử lý và Mô hình hóa Kho Dữ liệu	25
3.1 Hiện trạng Dữ liệu và Bối cảnh Nghiệp vụ	25
3.1.1 Khảo sát Nguồn Dữ liệu Thực nghiệm	25

3.1.2	Hiện trạng Chất lượng Dữ liệu và Các Rào cản Kỹ thuật	25
3.2	Cách tiếp cận và Kiến trúc Dữ liệu Đa tầng (Multi-Tier Architecture)	26
3.3	Quy trình Thực thi Pipeline ETL/ELT Chi tiết	27
3.3.1	Bước 1: Trích xuất và Tải dữ liệu vào Storage và Staging	28
3.3.2	Bước 2: Chuyển đổi và Điền khuyết Chuỗi Thời gian Đa tầng (Hybrid Causal Imputation)	28
3.3.3	Bước 3: Nhận diện Dị thường Kỹ thuật và Gán Nhãn An toàn	29
3.3.4	Bước 4: Nạp Dữ liệu vào Kho (Data Warehouse Load) và Kiểm định Toàn vẹn	29
3.4	Mô hình hóa Lược đồ Thiên hà (Galaxy Schema)	31
3.4.1	Lý do Lựa chọn Lược đồ Thiên hà	31
3.4.2	Các Sơ đồ Mô hình Dữ liệu Đa Chiều và Thuyết minh Thiết kế	31
3.4.3	Cấu trúc Chi tiết Các Bảng trong Kho Dữ liệu	33
3.4.4	Chiến lược Tối ưu hóa Hiệu năng: Indexing và Partitioning	34
3.5	Thiết kế Siêu thị Dữ liệu (Data Marts)	34
3.5.1	Lý do Lựa chọn Materialized Views cho BI Mart	34
3.5.2	Kiến trúc Materialized Views trên Supabase (BI Mart)	35
3.5.3	Thiết kế Siêu thị Dữ liệu Học máy (ML Data Mart)	36
3.5.4	Cấu hình Kết nối Tableau qua Connection Pooler (Port 6543)	37
3.6	Kiểm soát Chất lượng, Tính Toàn vẹn và Bảo mật Dữ liệu	37
4	Xây dựng Pipeline Dữ liệu và Phát hiện Dị thường	39
4.1	Tổng quan Kiến trúc Pipeline Xử lý Dữ liệu	39
4.1.1	Thiết lập Tiến trình Nạp Dữ liệu Thử tự	40
4.1.2	Cơ chế Quản lý Giao dịch và Chế độ Chạy Thử An toàn (Dry-Run)	40
4.2	Đánh giá Chất lượng và Khám phá Dữ liệu (EDA ban đầu)	41
4.2.1	Các Cột Thực Tế và Ánh Xạ Dữ Liệu Trong Pipeline	42
4.3	Làm sạch và Chuẩn hóa Dữ liệu (Data Cleaning)	44
4.3.1	Xử lý Dữ liệu Khuyết thiếu và Lỗi Logic	44
4.3.2	Xử lý Dữ liệu Ngoại lai (Outliers) và Lọc nhiễu	48
4.4	Biến đổi và Trích xuất Đặc trưng (trích xuất đặc trưng nghiệp vụ)	54
4.4.1	Giải quyết độ lệch tần suất ghi nhận (Granularity Alignment)	54
4.4.2	Trích xuất các đặc trưng thời gian và lịch trình học tập	54
5	Trực quan Dữ liệu và Xây dựng Dashboard	56
5.1	Chiến lược Kết nối Dữ liệu và Thiết kế UI/UX	56
5.1.1	Quy trình Thiết lập Kết nối PostgreSQL Trực tiếp từ Supabase	56
5.1.2	Mô hình Kết nối Dữ liệu Tầng BI Mart và Tableau Relationships	58
5.1.3	Bảng màu Ngữ nghĩa và Nguyên tắc Thiết kế UI/UX	58
5.1.4	Các Trường Tính toán Nghiệp vụ Bổ sung trên Tableau (Calculated Fields)	60

5.2	Chi tiết Hệ thống Dashboard Phân tích	61
5.2.1	Dashboard 1: Executive Overview (Tổng quan Vận hành)	61
5.2.2	Dashboard 2: Operational Efficiency & Loss Analysis (Hiệu suất Vận hành & Phân rã Tồn thất)	62
5.2.3	Dashboard 3: Anomaly Detection & Predictive Maintenance (Giám sát Bất thường & Bảo trì Cảnh báo)	63
6	Xây dựng và Đánh giá Mô hình Học máy Dự báo Sản lượng	65
6.1	Tổng quan quy trình học máy	65
6.1.1	Phạm vi và dữ liệu đầu vào	65
6.1.2	Bài toán và tầm dự báo	66
6.1.3	Nhãn ngoại lai kế thừa từ tầng ETL	67
6.1.4	Sơ đồ toàn cảnh	71
6.1.5	Nắm rào chắn chống rò rỉ dữ liệu	72
6.2	Chuẩn bị dữ liệu và chia tập	73
6.2.1	Hiện trạng bộ dữ liệu	73
6.2.2	Dựng lại lưới thời gian liên tục	74
6.2.3	Phân tích khám phá dữ liệu và các quyết định sinh đặc trưng	76
6.2.4	Chia dữ liệu theo trục thời gian	80
6.2.5	Ba fold theo cửa sổ mở rộng	81
6.2.6	Thực nghiệm: đo phần chồng lấn nhãn ở ranh giới fold	82
6.3	Sinh đặc trưng	83
6.3.1	Đặc trưng thời gian, trễ và cửa sổ trượt	83
6.3.2	Solar geometry, bức xạ trời quang và chuẩn hoá theo trạm	87
6.3.3	Định nghĩa các đặc trưng dẫn xuất	90
6.3.4	Thực nghiệm: khử độ trễ cài sẵn bằng đặc trưng tại thời điểm mục tiêu	92
6.3.5	Chuẩn hoá mục tiêu theo vật lý	92
6.3.6	Kiểm chứng các tham số cố định	95
6.3.7	Chẩn đoán và chọn đặc trưng	97
6.3.8	Tổng hợp bộ đặc trưng đưa vào mô hình	101
6.4	Huấn luyện và chọn hàm mất mát	102
6.4.1	Chính sách trọng số cho dòng ngoại lai	102
6.4.2	Tinh chỉnh siêu tham số (<i>hyperparameter</i>)	102
6.4.3	Sáu cấu hình Optuna chọn được	103
6.4.4	Chọn hàm mất mát	103
6.4.5	Cấu hình tắt định	104
6.5	Đánh giá trên tập test niêm phong	104
6.5.1	Thuốc đo	104
6.5.2	Phạm vi chấm điểm	105
6.5.3	Kết quả	105

6.5.4	Chênh lệch giữa sai số trên test và trên kiểm định	106
6.5.5	Đôi chứng với Prophet	106
6.5.6	Kiểm chứng độ trễ pha trên mô hình cuối	109
6.6	Giải thích mô hình bằng SHAP	110
6.6.1	Cơ sở phương pháp	110
6.6.2	Tầm quan trọng tổng thể	110
6.6.3	Giải thích ba dự báo cụ thể	112
6.6.4	Giới hạn diễn giải	114
6.7	Ứng dụng trực quan hoá kết quả	114
6.7.1	Trang giám sát chuỗi thời gian	114
6.7.2	Trang giải thích dự báo	115
6.7.3	Trang dự báo và phân tích giả định	115
6.8	Kết luận và hướng phát triển	116
6.8.1	Kết quả đạt được	116
6.8.2	Hạn chế	116
6.8.3	Hướng phát triển	117
7	Kết luận và Hướng phát triển	118
7.1	Kết luận Tổng quan	118
7.2	Khuyến nghị	118
7.3	Hạn chế	119
7.4	Hướng phát triển trong tương lai	120
7.4.1	Nâng cấp Mô hình Học máy và Dự báo Đa bước	120
7.4.2	Tự động hóa MLOps, DataOps và Hạ tầng Điện toán Đám mây	121
7.4.3	Mở rộng Ứng dụng Thực tiễn và Điều độ Năng lượng Học xá	121
	Phụ lục A: Kế hoạch Thực hiện và Phân công Nhiệm vụ	122
	Phụ lục B: Cấu trúc Gói Mã nguồn	124
	Phụ lục C: Vòng đời học máy	125
	Phụ lục D: Bảng Tra cứu Chi tiết 6 Mã Dị thường Kỹ thuật	127
	Tài liệu Tham khảo	128

Danh Mục Hình Vẽ

3.1	Sơ đồ luồng thực thi quy trình xử lý dữ liệu tự động.	26
3.2	Mô hình dữ liệu khái niệm (Conceptual Model).	32
3.3	Mô hình dữ liệu logic (Logical Model) theo Galaxy Schema.	32
3.4	Mô hình dữ liệu vật lý (Physical Model) trên PostgreSQL Supabase.	33
4.1	Kiến trúc mô hình phân lớp lai GMM-IF và quy trình nạp cờ an toàn.	50
5.1	Cấu hình kết nối PostgreSQL từ Tableau tới Supabase.	56
5.2	Giao diện Dashboard 1: Tổng quan điều hành (Executive Overview).	61
5.3	Giao diện Dashboard 2: Hiệu suất và tổn thất vận hành.	62
5.4	Giao diện Dashboard 3: Giám sát dị thường và bảo trì dự đoán.	63
6.1	Phân bố mật độ GMM và điểm cô lập Isolation Forest trên dữ liệu trạm 27.	68
6.2	Quét hệ số nhân m của <code>safe_IQR</code> qua sáu mức.	71
6.3	Vòng đời phát triển và vận hành mô hình học máy (MLOps) [24].	71
6.4	Quy trình 9 bước phát triển và đánh giá mô hình học máy.	72
6.5	Phân phối sản lượng trên tập huấn luyện theo các phạm vi.	77
6.6	Đặc tuyến sản lượng ngày trời quang và ngày nhiều mây tại trạm 27.	78
6.7	Biểu đồ tự tương quan ACF và tương quan riêng phần PACF.	78
6.8	Ma trận tương quan Spearman giữa các đặc trưng ban ngày.	80
6.9	Phân chia dữ liệu chuỗi thời gian theo cửa sổ mở rộng.	81
6.10	Làm mịn và nội suy dữ liệu bức xạ bước 15 phút tại trạm 1.	89
6.11	Biểu đồ SHAP Beeswarm thể hiện tác động của các đặc trưng.	111
6.12	Biểu đồ SHAP Waterfall giải thích hai trường hợp dự báo tương phản.	113
6.13	Giao diện Trang 1: Giám sát chuỗi thời gian	114
6.14	Giao diện Trang 2: Giải thích dự báo	115
6.15	Giao diện Trang 3: Dự báo và phân tích giả định	116
7.1	Vòng đời học máy, bản nháp gốc tiếng Anh.	125

Danh Mục Bảng Biểu

1.1	Tổng quan thông số dữ liệu thực nghiệm trong dự án.	17
1.2	Tổng hợp tiến độ và kết quả thực hiện dự án qua 14 tuần.	18
2.1	Ma trận phân tích nhu cầu thông tin của các bên liên quan.	23
4.1	Thống kê kiểm tra chất lượng dữ liệu tại tầng Staging.	42
4.2	Danh mục mã ngoại lai GMM-IF và ý nghĩa chẩn đoán.	51
5.1	Thông số kết nối PostgreSQL từ Tableau tới Supabase.	57
5.2	Quy chuẩn bảng màu trong Tableau Workbook <code>main_fixed_01.twb</code>	59
5.3	Tổng hợp các trường tính toán nghiệp vụ trên Tableau.	60
6.1	So sánh sai số RMSE với nghiên cứu của Roy, Pylytsov và Hu [10].	67
6.2	Số lượng mẫu vượt qua điều kiện kết hợp GMM và Isolation Forest.	69
6.3	Đổi chiều số lượng còi dị thường với tầng ETL.	70
6.4	Ảnh hưởng của hệ số nhân <code>safe_IQR</code> đến dữ liệu bị lọc.	70
6.5	Ánh xạ các bước trong quy trình với notebook thực hiện.	72
6.6	Thống kê mô tả sản lượng theo ba phạm vi.	76
6.7	Hệ số tự tương quan (ACF) chuỗi sản lượng tại các mốc trễ.	78
6.8	Tương quan giữa các biến khí tượng với sản lượng điện.	79
6.9	Ranh giới thời gian, kích thước và số trạm của ba fold kiểm định.	81
6.10	Kiểm tra hiện tượng chồng lấn nhãn giữa các fold.	83
6.11	Các nhóm đặc trưng thời gian và độ trễ.	83
6.12	Lựa chọn các mốc trễ chuỗi thời gian.	84
6.13	So sánh cấu hình mô hình nháp và mô hình chính thức.	86
6.14	Chi tiết cài đặt các tham số hình học Mặt Trời.	87
6.15	Hệ số hiệu chỉnh trời quang <code>cs_factor</code> theo từng fold.	88
6.16	Quy mô công suất 8 trạm quang điện tiêu biểu.	90
6.17	Tương quan của các đặc trưng tương tác với mục tiêu.	90
6.18	Công thức toán học các đặc trưng dẫn xuất.	91
6.19	So sánh đặc trưng tắt định tại T và $T+h$	92
6.20	Quét ngưỡng phân vị cận cắt trên tập kiểm định.	94
6.21	Tỷ lệ nhãn bị cắt theo khung giờ trong ngày.	94
6.22	Thực nghiệm quét 4 tham số cố định trên tập kiểm định.	95
6.23	Số lượng điểm dữ liệu bị cắt bởi ngưỡng <code>CLIP_CSI</code>	96
6.24	Phân bố chẩn đoán đa cộng tuyến trên 86 đặc trưng.	97
6.25	Các cặp đặc trưng trùng lặp và cột đại diện giữ lại.	98
6.26	Tám đặc trưng có hệ số phóng đại phương sai (VIF) cao nhất.	98

6.27	Đặc trưng dẫn đầu theo độ quan trọng PLS và hệ số VIF tương ứng.	98
6.28	Mười đặc trưng có điểm thông tin tương hỗ (MI) cao nhất.	99
6.29	Danh mục 40 đặc trưng cơ bản được lựa chọn vào mô hình.	101
6.30	Không gian tìm kiếm siêu tham số cho Optuna.	102
6.31	Bộ siêu tham số tối ưu do Optuna lựa chọn theo từng cấu hình.	103
6.32	Sai số trên tập kiểm định theo các hàm mất mát.	103
6.33	Sai số WAPE trên tập test niêm phong theo ba phạm vi.	106
6.34	Đối chiếu sai số WAPE giữa các giai đoạn đánh giá.	106
6.35	So sánh hiệu năng giữa LightGBM và baseline Prophet.	108
6.36	Phân tích độ trễ pha và độ lệch đỉnh của dự báo H1.	110
6.37	Top 10 đặc trưng quan trọng nhất theo giá trị SHAP trung bình.	110
6.38	Phân tích 3 trường hợp dự báo bằng SHAP cục bộ.	112
7.1	Lộ trình 14 tuần thực hiện dự án theo 8 Sprints chuẩn hóa theo CLO.	122
7.2	Phân công nhiệm vụ và khối lượng hoàn thành của các thành viên.	123
7.3	Bảng đối chiếu thuật ngữ kỹ thuật MLOps Anh – Việt.	126
7.4	Ma trận tra cứu 6 mã dị thường kỹ thuật GMM–IF và quy trình xử lý.	127

Danh mục Từ viết tắt

Ký hiệu	Ý nghĩa đầy đủ	Ký hiệu	Ý nghĩa đầy đủ
AOD	Aerosol Optical Depth (Độ dày sol khí)	kWp	Kilowatt-peak (Công suất đỉnh cực đại)
API	Application Programming Interface	LCOE	Levelized Cost of Electricity
AS/NZS	Chuẩn kỹ thuật Úc / New Zealand	Loss Rate	Tỷ lệ tổn thất sản lượng/năng lượng
BESS	Battery Energy Storage System (Pin lưu trữ)	MAE	Mean Absolute Error (Sai số tuyệt đối TB)
BI	Business Intelligence (Phân tích thông minh)	ML	Machine Learning (Học máy)
BOM	Bureau of Meteorology (Cục Khí tượng Úc)	MLOps	Machine Learning Operations
CEC	Clean Energy Council (Hội đồng NL Sạch Úc)	MPPT	Maximum Power Point Tracking
CF	Capacity Factor (Hệ số công suất trạm)	MSE	Mean Squared Error (Sai số bình phương)
CSDL	Cơ sở dữ liệu	NOCT	Nominal Operating Cell Temperature
CSI	Clear-Sky Index (Chỉ số trời quang)	O&M	Operations and Maintenance (Vận hành)
CT	Current Transformer (Biến dòng đo AC)	OLAP	Online Analytical Processing
DDL	Data Definition Language (Định nghĩa CSDL)	PK	Primary Key (Khóa chính)
DHI	Diffuse Horizontal Irradiance (Tán xạ ngang)	POA	Plane of Array (Bức xạ mặt phẳng pin)
DNI	Direct Normal Irradiance (Trực xạ pháp tuyến)	PR	Performance Ratio (Hệ số hiệu suất)
DVC	Data Version Control (Quản lý bản dữ liệu)	PV	Photovoltaic (Quang điện mặt trời)
DWH	Data Warehouse (Kho dữ liệu doanh nghiệp)	RACI	Ma trận phân công trách nhiệm
EDA	Exploratory Data Analysis (Khám phá DL)	RLS	Row-Level Security (Bảo mật cấp dòng)
ERA5	Bộ dữ liệu khí hậu tái phân tích ECMWF	RMSE	Root Mean Squared Error
ETL	Extract, Transform, Load	ROI	Return on Investment (Tỷ suất sinh lời)
FiT	Feed-in Tariff (Giá biểu mua điện bán lưới)	SHAP	SHapley Additive exPlanations
FK	Foreign Key (Khóa ngoại)	SQL	Structured Query Language
GBDT	Gradient Boosted Decision Tree	SS	Skill Score (Điểm kỹ năng cải thiện)
GHI	Global Horizontal Irradiance (Bức xạ tổng)	STC	Standard Test Conditions (1000 W/m ² , 25°C)
GMM	Gaussian Mixture Model (Hỗn hợp Gauss)	TPE	Tree-structured Parzen Estimator
GMM-IF	Hybrid GMM và Isolation Forest	UI/UX	Giao diện và Trải nghiệm người dùng
HVAC	Heating, Ventilation, Air Conditioning	VIF	Variance Inflation Factor (Đa cộng tuyến)
IEA	International Energy Agency	WAPE	Weighted Absolute Percentage Error
IF	Isolation Forest (Rừng cô lập)	WMO	World Meteorological Organization
IGBT	Transistor lưỡng cực cổng cách ly	XAI	Explainable Artificial Intelligence
ILR	Inverter Loading Ratio (Quá tải DC/AC)	IQR	Interquartile Range (Khoảng tứ phân vị)

Tổng quan Đề tài và Bài toán Dự án

1.1 Bối cảnh Thực tế và Lý do Chọn Đề tài

Trong xu hướng chuyển dịch năng lượng tái tạo toàn cầu nhằm giảm phát thải khí nhà kính và hướng tới mục tiêu Net Zero, năng lượng mặt trời (quang điện – Photovoltaic, viết tắt là PV) đang khẳng định vai trò là một trong những nguồn năng lượng sạch có tốc độ phát triển mạnh mẽ nhất. Theo báo cáo thường niên của Cơ quan Năng lượng Quốc tế (IEA) [3], tổng công suất lắp đặt quang điện trên toàn cầu đã vượt mốc 1.600 GW. Việc ứng dụng các hệ thống điện mặt trời áp mái tại các cơ quan, trường đại học và khu công nghiệp giúp tiết kiệm đáng kể chi phí điện lưới và chủ động nguồn năng lượng xanh tại chỗ.

Tuy nhiên, đặc tính cơ bản của năng lượng mặt trời là tính bất định cao và phụ thuộc phi tuyến vào các điều kiện khí tượng (bức xạ mặt trời, nhiệt độ môi trường, độ che phủ mây và tốc độ gió). Bên cạnh đó, trong quá trình vận hành dài hạn, các hệ thống quang điện luôn đối mặt với hiện tượng suy giảm hiệu suất do nhiệt độ cao, suy thoái thiết bị biến tần (Inverter), bụi bẩn bám trên bề mặt tấm pin hoặc lỗi truyền thông từ các cảm biến đo đạc.

Do đó, hai bài toán nghiệp vụ cốt lõi đặt ra cho các đơn vị quản lý và vận hành trạm điện mặt trời là:

1. **Phân tích và Đánh giá Hiệu suất Vận hành:** Theo dõi chính xác các chỉ số hiệu quả chuẩn hóa như Hệ số Hiệu suất (Performance Ratio – PR), Hệ số Công suất (Capacity Factor – CF), và Năng suất Riêng (Specific Yield); bóc tách các tổn thất năng lượng do điều kiện môi trường hoặc sự cố thiết bị, đồng thời phát hiện sớm các điểm dữ liệu dị thường để phục vụ công tác bảo trì.
2. **Dự báo Sản lượng Điện Mặt trời:** Dự báo chính xác sản lượng điện năng theo chu kỳ ngắn hạn dựa trên chuỗi thời gian lịch sử và thông số khí tượng dự báo, giúp đơn vị quản lý chủ động điều phối phụ tải, tối ưu hóa huy động nguồn điện và nâng cao hiệu quả kinh tế.

Xuất phát từ nhu cầu thực tiễn và tính cấp thiết nêu trên, nhóm tác giả lựa chọn đề tài “Phân tích Hiệu suất và Dự báo Sản lượng Hệ thống Điện Mặt Trời” làm đề án tốt nghiệp chuyên ngành Xử lý Dữ liệu tại Trường Cao đẳng FPT Polytechnic.

1.2 Thực trạng và Thách thức trong Xử lý Dữ liệu Năng lượng Mặt trời

Dự án tiếp cận và khai thác nguồn dữ liệu vận hành thực tế quy mô lớn từ bộ dữ liệu mở UNISOLAR của Đại học La Trobe, Úc [1], kết hợp cùng dữ liệu khí tượng viễn thám ERA5-Land từ Open-Meteo API [2]. Qua quá trình khảo sát ban đầu, nhóm nghiên cứu đã xác định 4 thách thức kỹ thuật dữ liệu trọng yếu:

- **Quy mô dữ liệu lớn và Lệch pha độ phân giải thời gian:** Dữ liệu sản lượng gồm hơn 2,73 triệu bản ghi với chu kỳ ghi nhận 15 phút từ 42 trạm phát, trong khi dữ liệu khí tượng viễn thám có chu kỳ 1 giờ. Sự khác biệt về độ chi tiết thời gian đòi hỏi một quy trình xử lý dữ liệu chuẩn hóa và kiến trúc kho dữ liệu đa chiều để tích hợp dữ liệu nhất quán mà không làm phình to dung lượng lưu trữ.
- **Hiện tượng gián đoạn chuỗi thời gian:** Dữ liệu thực tế phát sinh từ cảm biến IoT thường xuất hiện các điểm đứt gãy gián đoạn chu kỳ do lỗi đường truyền mạng. Nếu không được tái lấy mẫu và điền khuyết thời gian một cách khoa học, các tính toán về độ trễ và cửa sổ trượt trong mô hình dự báo chuỗi thời gian sẽ bị sai lệch nghiêm trọng.
- **Nhiều cảm biến và Dữ liệu dị thường phức tạp:** Sự xuất hiện của các giá trị dòng rò ban đêm khi không có ánh sáng mặt trời do trôi điểm 0 cảm biến, các giá trị phát đột biến vượt công suất thiết kế, hoặc hiện tượng mất phát điện giữa trưa do biến tần ngắt mạch khiến các phương pháp lọc thống kê đơn giản dễ bị sai lệch hoặc loại bỏ nhầm dữ liệu hợp lệ trong những ngày nhiều mây.
- **Nhu cầu Trực quan hóa Quản trị Đa chiều và Dự báo Đáng tin cậy:** Các nhà quản lý vận hành cần một hệ thống bảng điều khiển trực quan tương tác (Dashboard) để theo dõi các chỉ số KPI vận hành và chẩn đoán nguyên nhân sự cố kỹ thuật, song song với một mô hình học máy dự báo sản lượng có độ chính xác cao và khả năng giải thích rõ ràng.

1.3 Mục tiêu và Nhiệm vụ của Dự án

1.3.1 Mục tiêu Tổng quát

Xây dựng một nền tảng kỹ thuật xử lý dữ liệu hoàn chỉnh từ đầu đến cuối nhằm phục vụ công tác giám sát, phân tích hiệu suất vận hành và dự báo sản lượng cho hệ thống điện mặt trời đa trạm phát.

1.3.2 Mục tiêu và Nhiệm vụ Cụ thể

Để hoàn thành mục tiêu tổng quát, dự án tập trung giải quyết 4 nhóm nhiệm vụ chuyên môn:

1. Thu thập, Tiền xử lý và Mô hình hóa Kho Dữ liệu (Kỹ thuật Dữ liệu):

- Xây dựng quy trình xử lý dữ liệu tự động (ETL Pipeline) bằng ngôn ngữ Python theo kiến trúc mô-đun độc lập.
- Xử lý các điểm gián đoạn thời gian bằng kỹ thuật tái lấy mẫu và điền khuyết chuỗi thời gian liên tục.
- Thiết kế và triển khai Kho dữ liệu trung tâm (Data Warehouse) trên nền tảng Supabase theo mô hình Lược đồ Thiên hà (Galaxy Schema) gồm các bảng sự kiện (Fact) và các bảng chiều dữ liệu dùng chung (Dimension).
- Thiết lập các cơ chế kiểm tra toàn vẹn dữ liệu và phân quyền bảo mật cấp dòng (RLS).

2. Phát hiện Dị thường và Làm sạch Dữ liệu:

- Kết hợp các rào chắn giới hạn vật lý quang điện và mô hình phân lớp lai GMM–IF (Gaussian Mixture Model – Isolation Forest) để nhận diện chính xác dữ liệu ngoại lai.
- Phân loại và gán nhãn các mã lý do kỹ thuật chuẩn hóa phục vụ công tác chẩn đoán và lập kế hoạch bảo trì thiết bị vận hành.

3. Phân tích Khám phá Dữ liệu và Xây dựng Bảng điều khiển Quản trị:

- Xây dựng các bảng siêu thị dữ liệu (Data Marts) tính toán trước các chỉ số KPI theo ngày, tháng, trạm phát nhằm tối ưu hóa hiệu năng truy vấn.
- Thiết kế hệ thống bảng điều khiển trực quan tương tác trên Tableau Dashboard phục vụ nhu cầu quản lý từ Ban Giám đốc đến Kỹ sư vận hành hiện trường.

4. Mô hình hóa và Dự báo Sản lượng Chuỗi Thời gian:

- Xây dựng luồng huấn luyện chuỗi thời gian với kỹ thuật cửa sổ trượt (TimeSeriesSplit), trích xuất đặc trưng chu kỳ tuần hoàn và ngưỡng cảnh dữ liệu lịch sử.
- Thử nghiệm, so sánh các mô hình đường cơ sở (Baseline) và các mô hình học máy tăng cường độ dốc (Gradient Boosting).
- Đánh giá mô hình theo các thang đo chuẩn quốc tế và phân tích tầm quan trọng của các yếu tố khí tượng ảnh hưởng đến sản lượng thông qua SHAP.

1.4 Đối tượng và Phạm vi Nghiên cứu

- **Đối tượng Nghiên cứu:** Dữ liệu sản lượng điện năng từ các trạm quang điện áp mái và các biến số khí tượng viễn thám có ảnh hưởng trực tiếp đến hiệu suất quang điện (bức xạ mặt trời, nhiệt độ môi trường, độ che phủ mây, tốc độ gió, lượng mưa và thời lượng nắng).
- **Phạm vi Không gian:** 42 trạm phát quang điện áp mái với tổng công suất danh định 2.428 kWp phân bố tại 5 cơ sở của Đại học La Trobe, Bang Victoria, Úc (Bundoora, Bendigo, Albury-Wodonga, Shepparton, và Mildura, trong đó Mildura đóng vai trò trạm đối chứng khí tượng) thuộc bộ dữ liệu mở UNISOLAR [1].
- **Phạm vi Thời gian:** Chuỗi dữ liệu lịch sử liên tục trong 28 tháng, từ ngày 01/01/2020 đến ngày 30/04/2022.

Thông số Khảo sát	Giá trị Thực tế	Ý nghĩa Nghiệp vụ
Quy mô bản ghi sản lượng	2.731.946 dòng	Dữ liệu chuỗi thời gian sản lượng chu kỳ 15 phút từ 42 trạm PV.
Thời gian thu thập	01/01/2020 – 30/04/2022	28 tháng liên tục (bao gồm đủ các mùa khí hậu trong năm).
Số lượng trạm phát PV	42 trạm quang điện áp mái	Quy mô công suất từ trạm nhỏ 10 kWp đến trạm lớn 500 kWp.
Tổng công suất thiết kế	2.428 kWp	Đa dạng các dòng biến tần và cấu hình lắp đặt tấm pin.
Địa điểm khảo sát	4 khuôn viên (Victoria, Úc)	Bundoora, Bendigo, Albury-Wodonga, Shepparton.
Số biến khí tượng tích hợp	8 biến đo lường chuẩn WMO	Bức xạ, nhiệt độ không khí, độ che phủ mây, gió, mưa, nắng.

Bảng 1.1: Tổng quan thông số dữ liệu thực nghiệm trong dự án.

1.5 Ý nghĩa Khoa học và Giá trị Ứng dụng Thực tiễn

- **Giá trị Kỹ thuật và Học thuật:** Cung cấp một quy trình thực tiễn chuẩn hóa về kỹ thuật xử lý dữ liệu năng lượng tái tạo, giải quyết bài toán tích hợp dữ liệu lệch pha thời gian bằng mô hình Lược đồ Thiên hà và ứng dụng học máy phân lớp lại để phát hiện dữ liệu bất thường.
- **Giá trị Quản trị và Vận hành Doanh nghiệp:** Hệ thống bảng điều khiển trực quan giúp các nhà quản lý nắm bắt toàn diện hiệu suất hệ thống, so sánh hiệu quả giữa các trạm phát, và cung cấp thông tin kịp thời để kỹ sư lên kế hoạch bảo trì.
- **Giá trị Điều độ và Lập kế hoạch Năng lượng:** Các mô hình dự báo chuỗi thời gian hỗ trợ dự đoán chính xác sản lượng phát điện trong ngắn hạn, hỗ trợ việc lập kế hoạch huy động nguồn điện và tối ưu hóa chi phí vận hành.

1.6 Kế hoạch Thực hiện Dự án (14 Tuần Agile/Scrum)

Dự án được thực hiện trong thời gian 14 tuần theo phương pháp luận Agile/Scrum với 7 giai đoạn (Sprint) cụ thể:

Giai đoạn (Sprint)	Thời gian	Hạng mục Công việc Trọng tâm	Trạng thái
Sprint 1: Khảo sát & Phân tích	Tuần 1–2	Khảo sát dữ liệu 42 trạm UNISOLAR và phân tích khám phá ban đầu.	Hoàn thành
Sprint 2: ETL & Tiền xử lý	Tuần 3–5	Xây dựng pipeline xử lý dữ liệu tự động, tái lấy mẫu và điền khuyết.	Hoàn thành
Sprint 3: Mô hình hóa Kho Dữ liệu	Tuần 6–8	Thiết kế mô hình Lược đồ Thiên hà và nạp dữ liệu vào Supabase DWH.	Hoàn thành
Sprint 4: Lọc Dị thường Nâng cao	Tuần 8–10	Triển khai rào chắn vật lý và mô hình phân lớp lai GMM–IF gắn mã lý do.	Hoàn thành
Sprint 5: Xây dựng Dashboard	Tuần 10–12	Xây dựng các siêu thị dữ liệu và hoàn thiện hệ thống Dashboard Tableau.	Hoàn thành
Sprint 6: Mô hình Hóa Dự báo	Tuần 12–13	Huấn luyện, đánh giá và so sánh các mô hình học máy dự báo chuỗi thời gian.	Hoàn thành
Sprint 7: Nghiệm thu & Đóng gói	Tuần 14	Hoàn thiện báo cáo đề án, đóng gói mã nguồn và nghiệm thu toàn diện.	Hoàn thành

Bảng 1.2: Tổng hợp tiến độ và kết quả thực hiện dự án qua 14 tuần.

1.7 Bố cục Báo cáo Đồ án Tốt nghiệp

Báo cáo dự án tốt nghiệp được cấu trúc thành 7 chương liên mạch theo đúng quy trình phân tích và xử lý dữ liệu chuẩn:

- **Chương 1: Tổng quan Đề tài và Bài toán Dự án** – Trình bày bối cảnh thực tế, lý do chọn đề tài, thách thức dữ liệu, mục tiêu nghiên cứu, phạm vi, ý nghĩa và kế hoạch thực hiện dự án.
- **Chương 2: Cơ sở Lý thuyết và Kiến trúc Hệ thống** – Trình bày các kiến thức nền tảng về năng lượng mặt trời, bộ chỉ số đo lường hiệu suất (KPI), lý thuyết Kho dữ liệu đa chiều, kiến trúc luồng xử lý dữ liệu và nguyên tắc trực quan hóa.
- **Chương 3: Thu thập, Tiền xử lý và Mô hình hóa Kho Dữ liệu** – Trình bày chi tiết kiến trúc mô-đun xử lý dữ liệu, kết quả kiểm định chất lượng ban đầu, kỹ thuật trích xuất đặc trưng, và thiết kế mô hình Lược đồ Thiên hà (Galaxy Schema) trên Supabase.
- **Chương 4: Xây dựng Pipeline Dữ liệu và Phát hiện Dị thường** – Trình bày thuật toán phân lớp lai GMM–IF kết hợp ràng buộc giới hạn vật lý, phân loại các mã lý do dị thường kỹ thuật, và cơ chế đảm bảo tính toàn vẹn dữ liệu.
- **Chương 5: Phân tích Khám phá Dữ liệu và Trực quan hóa Dashboard** – Trình bày kết quả phân tích khám phá dữ liệu chuyên sâu và thiết kế hệ thống bảng điều khiển trực quan quản trị trên Tableau.
- **Chương 6: Xây dựng và Đánh giá Mô hình Học máy Dự báo Sản lượng** – Trình bày quy trình tiền xử lý chuỗi thời gian, huấn luyện và đánh giá các mô hình học máy dự báo sản lượng, phân tích tầm quan trọng của đặc trưng bằng SHAP và các phát hiện thực tiễn.
- **Chương 7: Kết luận và Hướng phát triển** – Tổng kết các kết quả đạt được của đề tài, nêu rõ những hạn chế và đề xuất các giải pháp nâng cấp trong tương lai.

Cơ sở Lý thuyết và Kiến trúc Hệ thống

2.1 Cơ sở Lý thuyết

2.1.1 Khái quát về Phân tích Dữ liệu trong Ngành Năng lượng Tái tạo

Phân tích dữ liệu trong ngành năng lượng mặt trời là quá trình thu thập, làm sạch, mô hình hóa và khai phá thông tin chuyên sâu từ khối lượng lớn chuỗi thời gian sản lượng điện và dữ liệu khí tượng. Trong bối cảnh vận hành các trạm điện mặt trời hiện đại, dữ liệu đóng vai trò là tài sản chiến lược giúp tối ưu hóa hiệu suất phát điện, giảm thiểu chi phí bảo trì và bảo vệ dòng tiền đầu tư.

Theo chuẩn mực phân tích dữ liệu doanh nghiệp, các cấp độ phân tích trong đề tài được phân chia rõ ràng:

- **Phân tích Mô tả (Descriptive Analytics):** Trả lời câu hỏi “*Chuyện gì đã xảy ra?*” thông qua việc tổng hợp sản lượng thực tế, tính toán hệ số hiệu suất (PR), hệ số công suất (CF) và năng suất riêng (Specific Yield) của 42 trạm phát qua từng tháng và từng năm.
- **Phân tích Chẩn đoán (Diagnostic Analytics):** Trả lời câu hỏi “*Tại sao hiệu suất trạm lại suy giảm?*” bằng cách bóc tách mối tương quan giữa sản lượng và các yếu tố khí tượng (nhiệt độ quá cao, mây che phủ) hoặc lỗi phần cứng (Inverter ngắt mạch, hỏng diode, trôi cảm biến đo ban đêm).
- **Phân tích Dự báo (Predictive Analytics):** Trả lời câu hỏi “*Sản lượng điện trong chu kỳ tiếp theo là bao nhiêu?*” để hỗ trợ đơn vị vận hành lập kế hoạch điều phối phụ tải và huy động nguồn điện dự phòng.
- **Phân tích Đề xuất (Prescriptive Analytics):** Đưa ra các khuyến nghị bảo trì cụ thể (vệ sinh bề mặt pin, thay thế biến tần quá nhiệt, hiệu chuẩn cảm biến CT).

2.1.2 Các Chỉ số Hiệu năng Cốt lõi (KPIs) và Bài toán Tổn thất Vận hành

Trong quản trị vận hành trạm quang điện, tổng sản lượng (kWh) chỉ phản ánh quy mô phát điện thô, trong khi các chỉ số hiệu chuẩn hóa mới là thước đo chính xác về chất lượng vận hành:

1. **Hệ số Hiệu suất (Performance Ratio – PR):** Tỷ số giữa sản lượng điện thực tế tạo ra (E_{actual}) và sản lượng lý thuyết trong điều kiện bức xạ thu nhận được:

$$PR = \frac{E_{\text{actual}}}{P_{\text{stc}} \cdot \left(\frac{GHI}{1000 \text{ W/m}^2} \right) \cdot \Delta t} \times 100\% \quad (2.1)$$

Chỉ số PR tiêu chuẩn của hệ thống tốt thường đạt từ 75% đến 85%. Khi $PR < 70\%$, hệ thống đang gặp tổn thất vận hành nghiêm trọng.

2. **Hệ số Công suất (Capacity Factor – CF):** Tỷ lệ giữa năng lượng thực tế thu được trong một khoảng thời gian so với năng lượng tối đa nếu trạm phát liên tục ở công suất danh định 24/24h:

$$CF = \frac{\sum E_{\text{actual}}}{P_{\text{stc}} \cdot 8760 \text{ h}} \times 100\% \quad (2.2)$$

3. **Năng suất Riêng (Specific Yield – kWh/kWp):** Lượng điện năng tạo ra trên mỗi kWp công suất lắp đặt, là thước đo công bằng nhất để so sánh hiệu quả giữa các trạm có quy mô công suất khác nhau.
4. **Tổn thất Suy hao do Nhiệt độ (Thermal Loss):** Khi nhiệt độ môi trường vượt quá 25°C (nhiệt độ cell pin đạt 50 – 65°C), công suất phát bị suy giảm tuyến tính theo hệ số nhiệt độ $\gamma \approx -0,35\%/^{\circ}\text{C}$ đến $-0,50\%/^{\circ}\text{C}$:

$$P_{\text{loss, temp}} = P_{\text{stc}} \cdot |\gamma| \cdot (T_{\text{cell}} - 25^{\circ}\text{C}) \quad (2.3)$$

5. **Tổn thất Biến tần (Inverter Losses) theo IEA-PVPS Task 13 [3]:** Biến tần có thời gian trung bình giữa các sự cố (MTBF) ngắn hơn tám pin 300 – 500 lần, gây ra 36% tổng tổn thất phần cứng của hệ thống.

2.1.3 Hệ thống Kho Dữ liệu (Data Warehouse) và Quy trình ETL

Kho dữ liệu (Data Warehouse – DWH) là hệ thống cơ sở dữ liệu được thiết kế chuyên biệt để hỗ trợ các hoạt động phân tích thông minh (BI) và báo cáo quản trị (OLAP), phân tách hoàn toàn khỏi các hệ thống xử lý giao dịch vận hành (OLTP).

Để chuyển hóa dữ liệu thô thành thông tin quản trị, quy trình ETL được thực thi theo 3 giai đoạn:

- **Trích xuất Dữ liệu (Extract):** Thu thập dữ liệu chuỗi thời gian sản lượng từ tệp tin cục bộ và gọi API khí tượng Open-Meteo.
- **Transform (Biến đổi & Làm sạch):** Chuẩn hóa kiểu dữ liệu, xử lý giá trị khuyết thiếu (Imputation), xử lý đứt gãy thời gian (điểm gián đoạn thời gian), gắn nhãn ngoại lai bằng rào chắn vật lý và trích xuất đặc trưng nghiệp vụ.
- **Nạp Dữ liệu vào Kho (Load):** Nạp dữ liệu có cấu trúc vào kho lưu trữ tập trung Supabase DWH theo mô hình đa chiều.

2.1.4 Mô hình Dữ liệu Đa chiều và Lược đồ Thiên hà (Galaxy Schema)

Mô hình đa chiều do Ralph Kimball [29] đề xuất phân tách dữ liệu thành:

- **Bảng sự kiện (Fact Table):** Chứa các chỉ số đo lường định lượng theo chuỗi thời gian như `fact_solar_energy_gen` (sản lượng điện 15 phút) và `fact_weather` (thông số khí tượng 1 giờ).
- **Bảng chiều (Dimension Table):** Chứa các thuộc tính ngữ cảnh mô tả như `dim_solar_plant` (trạm phát), `dim_date` (ngày), `dim_time` (giờ), `dim_weather_type` (mã thời tiết).

Trong dự án này, do dữ liệu sản lượng và dữ liệu thời tiết có tần suất ghi nhận lệch nhau (15 phút vs 1 giờ), nhóm sử dụng lược đồ Thiên hà (Galaxy Schema). Hai bảng Fact độc lập liên kết chặt chẽ với nhau thông qua 4 bảng Dimension dùng chung (chiều dữ liệu dùng chung), đảm bảo không làm phình to dữ liệu và tối ưu hóa hiệu năng truy vấn liên thông (Drill-through).

2.1.5 Phương pháp Phát hiện Dị thường và Lọc Nhiễu Nghiệp vụ

Để đảm bảo nguyên tắc “Dữ liệu sạch = Insight đúng”, quy trình xử lý dữ liệu tích hợp các phương pháp phát hiện dị thường nhằm phục vụ công tác làm sạch:

- **Khoảng Tứ phân vị IQR (Tukey 1977 [7]):** Xác định ngưỡng phân vị $IQR = Q_3 - Q_1$ để loại trừ các giá trị đo đột biến cục bộ.
- **Rào chắn Vật lý (Physical Boundaries):** Thiết lập 5 giới hạn vật lý năng lượng mặt trời (cắt trần công suất danh định, loại bỏ phát điện ban đêm $GHI = 0$, phát hiện nắng gắt mất điện).
- **Phân lớp Lai GMM-IF (Li et al., 2025 [4]):** Đóng vai trò như một bộ lọc thông minh trong tầng Transform, phân đoạn dữ liệu thành các vùng lá thời tiết đồng nhất để nhận diện chính xác các điểm dữ liệu dị thường do lỗi thiết bị và gán 6 mã lý do kỹ thuật phục vụ bảo trì.

2.1.6 Trực quan hóa Dữ liệu trong Business Intelligence (BI)

Trực quan hóa dữ liệu không đơn thuần là vẽ biểu đồ làm đẹp, mà là công cụ khám phá tri thức kinh doanh (Business Storytelling). Các nguyên tắc thiết kế được tuân thủ nghiêm ngặt:

- **Quy luật Gestalt:** Sắp xếp các chỉ số quan trọng (KPI Cards) ở vị trí trên cùng bên trái theo hướng đọc tự nhiên của mắt.
- **Màu sắc Ngữ nghĩa (Semantic Colors):** Màu Xanh Navy (#4E79A7) cho Tổng sản lượng, Màu Xanh Lá (#59A14F) cho Hiệu suất đạt chuẩn, Màu Cam (#F28E2B) cho Cảnh báo tổn thất nhiệt độ, và Màu Đỏ (#E15759) cho Sự cố dừng máy/Dị thường.
- **Tương tác Đào sâu (Interactive Actions):** Thiết lập bộ lọc chéo (Cross-filtering) và Highlight Actions giúp các nhà quản lý nhanh chóng đào sâu từ tổng quan vùng đến từng trạm phát cụ thể.

2.2 Phân tích Yêu cầu Nghiệp vụ (Business Requirements)

2.2.1 Phân tích Các Bên Liên quan (Stakeholders)

Hệ thống phân tích dữ liệu được thiết kế để giải quyết bài toán thông tin cho 4 nhóm đối tượng chính:

Nhóm Đối tượng	Vai trò Nghiệp vụ	Nhu cầu Thông tin Chính
Ban Giám đốc (C-Level)	Quản trị chiến lược tài sản và hiệu quả đầu tư toàn diện.	Tổng sản lượng phát điện, tăng trưởng theo năm (YoY), tỷ lệ tổn thất tài chính toàn hệ thống.
Quản lý O&M (O&M Manager)	Tối ưu hóa hiệu suất vận hành và giám sát kỹ thuật các trạm.	Hệ số PR, CF, so sánh Specific Yield giữa các trạm, xác định các trạm có hiệu suất suy giảm.
Kỹ sư Hiện trường (Field Engineer)	Khắc phục sự cố và bảo dưỡng thiết bị trực tiếp tại trạm pin.	Vị trí trạm có dị thường, mã lý do sự cố kỹ thuật (outlier_reason), thời điểm xảy ra lỗi.
Chuyên viên Phân tích (Energy Analyst)	Đánh giá chuyên sâu và lập báo cáo phân tích năng lượng.	Dữ liệu sạch trên DWH, phân tích tương quan bức xạ – nhiệt độ, báo cáo tổn thất chi tiết.

Bảng 2.1: Ma trận phân tích nhu cầu thông tin của các bên liên quan.

2.2.2 Hệ thống Chỉ số Đo lường (KPI Framework)

Dựa trên yêu cầu nghiệp vụ, dự án xây dựng bộ khung đo lường gồm 3 nhóm chỉ số cốt lõi:

1. Nhóm KPI Vận hành Kỹ thuật (Operational KPIs):

- Total Energy Generation = $\sum \text{energy_generated_kwh}$ (Tổng sản lượng phát điện).
- Average PR (%) = Trung bình hệ số hiệu suất quang điện.
- Capacity Factor (%) = Hệ số huy động công suất trạm.
- Specific Yield = $\frac{\text{Sản lượng (kWh)}}{\text{Công suất danh định (kWp)}}$.

2. Nhóm KPI Tổn thất và Tài chính (Loss & Financial KPIs):

- **Thermal Loss (kWh):** Sản lượng thất thoát do nhiệt độ tế bào quang điện vượt quá 25°C.
- **Inverter Clipping Loss (kWh):** Sản lượng bị cắt giảm do công suất DC vượt quá ngưỡng biến tần.

3. Nhóm KPI Cảnh báo Dị thường và Bảo trì (Anomaly & Maintenance KPIs):

- Anomaly Rate (%) = $\frac{\text{Số bản ghi dị thường}}{\text{Tổng số bản ghi}} \times 100\%$ (Mục tiêu phát hiện: 1,22%).
- **Inverter Zero Output Count:** Số sự cố biến tần mất phát giữa trưa nắng gắt ($GHI \geq 700 \text{ W/m}^2$).
- **Night Leakage Records:** Số bản ghi trôi điểm 0 ban đêm cần hiệu chuẩn cảm biến.

2.3 Kiến trúc Hệ thống Đề xuất (6-Layer Data Pipeline)

Nhằm đảm bảo tính toàn vẹn, độ tin cậy và khả năng mở rộng của dữ liệu, dự án đề xuất kiến trúc xử lý dữ liệu 6 lớp (6-Layer Data Pipeline):

- Layer 1 – Data Source (Nguồn dữ liệu):** Tiếp nhận 2.731.946 dòng dữ liệu sản lượng PV 15 phút từ UNISOLAR và chuỗi dữ liệu khí tượng 1 giờ từ Open-Meteo API.
- Layer 2 – Exploration & Audit (Khám phá & Kiểm định chất lượng):** Quét toàn diện dữ liệu thô, phát hiện 561 điểm đứt gãy thời gian (điểm gián đoạn thời gian) và kiểm tra phân phối dữ liệu.
- Layer 3 – Transformation & Cleansing (Biến đổi & Làm sạch dữ liệu):** Lọc xử lý lỗi bằng Python: Resampling lưới 15 phút, nội suy dữ liệu khuyết thiếu, áp dụng rào chắn vật lý và mô hình phân lớp GMM-IF để lọc sạch nhiễu cảm biến, gán 6 mã lý do sự cố.
- Layer 4 – Data Modeling (Mô hình hóa Kho dữ liệu):** Tổ chức cơ sở dữ liệu trên Supabase PostgreSQL theo Lược đồ Thiên hà (Galaxy Schema) gồm 2 bảng Fact và 4 bảng Dimension.
- Layer 5 – Aggregation & Data Marts (Tổng hợp & Siêu thị dữ liệu):** Tính toán trước (Pre-calculate) các bảng tổng hợp nghiệp vụ theo ngày, tháng, trạm phát để tối ưu hóa truy vấn cho BI.
- Layer 6 – Visualization (Trực quan hóa Quản trị):** Xây dựng hệ thống 3 Dashboard tương tác trên nền tảng Tableau Desktop phục vụ các quyết định vận hành.

2.4 Từ điển Dữ liệu Nghiệp vụ (Data Dictionary)

Dữ liệu sau khi làm sạch và mô hình hóa được phân chia thành 5 nhóm logic:

- **Nhóm 1 – Dữ liệu Định danh và Vận hành Trạm (dim_solar_plant):** Mã trạm (sitekey), Tên trạm, Khuôn viên (campus_name), Công suất danh định (capacity_kw), Model biến tần, Tọa độ địa lý.
- **Nhóm 2 – Dữ liệu Thời gian Lịch biểu (dim_date, dim_time):** Ngày, Tháng, Năm, Quý, Thứ trong tuần, Cờ ngày nghỉ (is_holiday), Giờ, Phút, Cờ ban ngày (is_day).
- **Nhóm 3 – Dữ liệu Khí tượng Viễn thám (fact_weather):** Bức xạ sóng ngắn (GHI), Bức xạ trực xạ (DNI), Bức xạ tán xạ (DHI), Nhiệt độ không khí 2m, Tốc độ gió, Độ che phủ mây, Thời lượng nắng.
- **Nhóm 4 – Dữ liệu Sản lượng & Đo lường Hiệu năng (fact_solar_energy_gen):** Sản lượng điện phát ra (energy_generated_kwh), Tỷ lệ hiệu suất (PR), Năng suất riêng (Specific_Yield).
- **Nhóm 5 – Dữ liệu Chẩn đoán Dị thường (gmm_if_outlier):** Cờ dị thường (gmm_if_outlier_flag), Mã lý do chẩn đoán kỹ thuật (gmm_if_outlier_reason).

Thu thập, Tiền xử lý và Mô hình hóa Kho Dữ liệu

3.1 Hiện trạng Dữ liệu và Bối cảnh Nghiệp vụ

3.1.1 Khảo sát Nguồn Dữ liệu Thực nghiệm

Dự án tiếp cận và khai thác nguồn dữ liệu vận hành thực tế quy mô lớn của hệ thống điện mặt trời quang điện (PV) áp mái tại Đại học La Trobe, Úc [1], tích hợp cùng dữ liệu khí tượng tái phân tích ERA5-Land thu thập qua Open-Meteo API [2]. Dữ liệu đầu vào bao gồm 5 tập dữ liệu thành phần:

- Dữ liệu Sản lượng Điện Mặt trời (Solar_Energy_Generation.csv):** Gồm 2.731.946 bản ghi đo đặc chuỗi thời gian ở độ phân giải 15 phút, thu thập liên tục trong chu kỳ 28 tháng (từ tháng 06/2020 đến tháng 10/2022) từ 42 dàn pin quang điện đặt tại 5 khuôn viên trường (Bundoora, Bendigo, Albury-Wodonga, Shepparton và Mildura). Dung lượng tệp thô xấp xỉ 80 MB.
- Dữ liệu Khí tượng Khí hậu (open_meteo_weather_raw.csv):** Gồm 850.752 bản ghi chu kỳ 1 giờ trích xuất từ Open-Meteo theo tọa độ địa lý của 5 khuôn viên trường. Dữ liệu bao gồm các biến khí tượng quan yếu: Bức xạ tổng cộng mặt phẳng ngang (shortwave_radiation – GHI), Bức xạ trực xạ pháp tuyến (direct_radiation – DNI), Bức xạ tán xạ (diffuse_radiation – DHI), Nhiệt độ không khí ở độ cao 2m (temperature_2m), Tỷ lệ mây che phủ tổng thể (cloud_cover), Mây tầng thấp/trung/cao, Vận tốc gió (wind_speed_10m), Lượng mưa (precipitation) và Thời lượng nắng (sunshine_duration). Dung lượng tệp thô xấp xỉ 78 MB.
- Metadata Thông số Kỹ thuật Trạm Pin (Solar_Site_Details.csv):** Chứa thông số kỹ thuật của 42 trạm phát: Công suất danh định STC (kWp), Số lượng tấm pin (Number_of_panels), Chủng loại tấm pin (Panel), Chủng loại biến tần (Inverter), Bộ tối ưu hóa công suất (Optimizers), và Tọa độ địa lý (lat, lon).
- Metadata Khuôn viên Cơ sở (campus_meta.csv):** Thông tin định danh của 5 cơ sở đào tạo kèm tổng công suất lắp đặt từng phân vùng.
- Lịch Biểu và Sự kiện Mùa vụ (calendar.csv):** Gồm 2.312 bản ghi mô tả các thuộc tính ngày lễ quốc gia/bang Victoria (is_holiday), chu kỳ học kỳ chính quy (is_semester) và giai đoạn thi cử (is_exam), phục vụ phân tích tương quan phụ tải và hành vi tiêu thụ.


3.1.2 Hiện trạng Chất lượng Dữ liệu và Các Rào cản Kỹ thuật

Qua khảo sát và kiểm định chất lượng dữ liệu thô ban đầu, nhóm nghiên cứu đã xác định 4 thách thức kỹ thuật trọng yếu đặt ra cho hệ thống kỹ thuật dữ liệu:

- **Lệch pha Tần số Đo đạc (Multi-frequency Resolution Mismatch):** Dữ liệu sản lượng phát điện được đo ở độ hạt 15 phút ($t \in \{00, 15, 30, 45\}$), trong khi dữ liệu khí tượng chỉ có độ hạt 1 giờ ($t \in \{00\}$). Việc ghép nối dữ liệu nếu không tuân thủ nguyên lý nhân quả (causality) sẽ dẫn đến rủi ro nghiêm trọng: bản ghi sản lượng lúc 09 : 15 vô tình nhận dữ liệu thời tiết đo lúc 10 : 00 (rò rỉ dữ liệu tương lai – data leakage).
- **Tỷ lệ Dữ liệu Khuyết thiếu Cao (56,2%):** Chuỗi đo đạc sản lượng ghi nhận 1.536.000 điểm dữ liệu mang giá trị NULL (chiếm 56,2%) sau khi dựng lại toàn bộ lưới thời gian 15 phút liên tục 24/7 (bao gồm tất cả các khung giờ ban đêm). Phần lớn các giá trị rỗng này xuất hiện vào ban đêm do Inverter ngắt mạch để tiết kiệm năng lượng, song có tới 561 đoạn đứt gãy gián đoạn ban ngày do sự cố viễn thông telemetry truyền dữ liệu.
- **Dị thường Đo đạc và Nhiễu Tín hiệu (Sensor Artifacts):** Ghi nhận hiện tượng trôi mốc 0 cảm biến biến dòng CT (phát hiện sản lượng dương $E > 0$ vào nửa đêm khi $GHI = 0$), sự cố mất tín hiệu phát điện khi trời nắng gắt (biến tần ngắt quá nhiệt), và hiện tượng xén công suất (Inverter Clipping) khi công suất DC vượt giới hạn định mức AC.
- **Lưu trữ Phẳng và Phân tán (Flat CSV Bottlenecks):** Dữ liệu nằm rải rác ở dạng tệp phẳng không có ràng buộc toàn vẹn khóa ngoại, gây dư thừa dữ liệu (redundancy), tốc độ truy vấn chậm và không thể đáp ứng yêu cầu trực quan hóa phân tích đa chiều (OLAP) theo thời gian thực trên Tableau.

3.2 Cách tiếp cận và Kiến trúc Dữ liệu Đa tầng (Multi-Tier Architecture)

Để giải quyết triệt để các thách thức trên, dự án áp dụng triết lý thiết kế nền tảng dữ liệu hiện đại (Modern Data Lakehouse) trên nền tảng Supabase Cloud (PostgreSQL 17.6) kết hợp kho lưu trữ đối tượng S3-compatible Storage. Hệ thống được tổ chức thành 5 tầng dữ liệu độc lập (Hình 3.1):



Hình 3.1: Sơ đồ luồng thực thi quy trình xử lý dữ liệu tự động.

Tầng 1: Tầng Lưu trữ Đối tượng Thô (Bronze Layer – Supabase S3 Storage): Toàn bộ 5 tệp CSV gốc (158 MB) được tải lên bucket bảo mật `raw-data/` trên Supabase Storage. Tầng này đóng vai trò lưu trữ bất biến (Immutable Data Lake), được xác thực toàn vẹn bằng mã băm MD5 Checksum trước khi nạp vào cơ sở dữ liệu, đảm bảo dữ liệu gốc luôn có thể tái lập trong mọi tình huống.

Tầng 2: Tầng Hạ cánh Thô (Staging Raw Layer – Schema `staging.stg_*`): Bao gồm 5 bảng hạ cánh tương ứng: `stg_solar_energy_generation`, `stg_open_meteo_weather_raw`, `stg_solar_site_details`, `stg_campus_meta`, `stg_calendar`. Toàn bộ các cột ở tầng này được khai báo dưới kiểu dữ liệu `VARCHAR(255)` để tiếp nhận nguyên bản dữ liệu mà không bị gián đoạn do lỗi định dạng hay kiểu dữ liệu không tương thích.

Tầng 3: Tầng Xử lý Đệm (Buffer / Mirror Staging Layer – Schema `staging.dim_*`, `staging.fact_*`): Vùng đệm chuyển đổi trung gian, nơi diễn ra các thuật toán tiền xử lý: ép kiểu số và thời gian ISO 8601, chuẩn hóa tên cột sang `snake_case`, triển khai thuật toán Điền khuyết Nhân quả Đa tầng (Hybrid Causal Imputation), và dán nhãn phân loại 6 mã dị thường kỹ thuật GMM-IF.

Tầng 4: Tầng Kho Dữ liệu Doanh nghiệp (Enterprise Data Warehouse – Schema `datawarehouse`): Được thiết kế theo chuẩn Lược đồ Thiên hà (Galaxy Schema) gồm 5 bảng Dimension và 2 bảng Fact độc lập. Tầng này áp dụng các kỹ thuật: Khóa thay thế số nguyên tự tăng (INT Surrogate Keys), ràng buộc toàn vẹn tham chiếu khóa ngoại (FOREIGN KEY constraints), chỉ mục phức hợp (Composite Indexes), và phân vùng bảng vật lý (Table Partitioning) theo thời gian.

Tầng 5: Tầng Siêu thị Dữ liệu và Ứng dụng (Serving Layer – BI Mart & ML Mart):

- **BI Data Mart (Tableau Serving):** Sử dụng Materialized Views (`mv_bi_mart_hourly_measures`, `mv_bi_mart_daily_summary`) tính toán sẵn các chỉ số hiệu suất (PR, CF, Specific Yield), tổn thất nhiệt và doanh thu FiT, kết nối trực tiếp với Tableau Desktop thông qua Supabase Connection Pooler (Port 6543).
- **ML Data Mart (Machine Learning Serving):** Xuất bản tệp Parquet dạng cột tối ưu (`v4_final_cleaned.parquet`) kết hợp căn chỉnh thời tiết nhân quả (Causal Realignment) phục vụ trực tiếp cho pipeline huấn luyện mô hình học máy LightGBM.

3.3 Quy trình Thực thi Pipeline ETL/ELT Chi tiết

Toàn bộ quy trình từ khâu trích xuất đến nạp kho dữ liệu được module hóa trong thư mục `srcs/` và điều phối tự động qua 4 bước:

3.3.1 Bước 1: Trích xuất và Tải dữ liệu vào Storage và Staging

Module `srcs/01_extract/` và `srcs/03_load/` tự động hóa việc tải tập dữ liệu UNISOLAR và gọi API Open-Meteo với cơ chế Exponential Backoff Retry nhằm vượt qua giới hạn truy cập (Rate Limit). Dữ liệu sau khi tải lên Supabase Storage được đẩy vào các bảng `staging.stg_*` bằng cơ chế Bulk Copy phân đoạn (chunking 50.000 dòng/lần).

3.3.2 Bước 2: Chuyển đổi và Điền khuyết Chuỗi Thời gian Đa tầng (Hybrid Causal Imputation)

Dữ liệu thô từ bảng staging được module `01_run_transform_buffers.py` và `02_run_hybrid_imputation.py` xử lý đưa vào các bảng đệm (`staging.dim_*`, `staging.fact_*`).

Để xử lý 56,2% giá trị rỗng mà không gây rò rỉ thông tin tương lai, nhóm triển khai chiến lược Điền khuyết Nhân quả Đa tầng (Causal Cascade Imputation) theo 4 cấp độ:

- a. **Khung giờ Ban đêm (Rule-based Night Imputation):** Áp dụng quy tắc vật lý: Nếu thời điểm đo nằm trong khung giờ đêm (18h30 tối đến 05h30 sáng hôm sau) và bức xạ $GHI = 0 \text{ W/m}^2$, giá trị sản lượng bị khuyết được gán chính xác bằng 0kWh (`fill_null_algorithm = 'rule_based_night'`).
- b. **Đoạn đứt gãy ngắn (≤ 4 bước, tương đương ≤ 1 giờ):** Sử dụng thuật toán nội suy tuyến tính thời gian (Linear Interpolation), phản ánh sự biến thiên liên tục của góc chiếu mặt trời (`fill_null_algorithm = 'linear'`).
- c. **Đoạn đứt gãy trung bình (5–8 bước, từ 1–2 giờ):** Áp dụng thuật toán nội suy đa thức bậc ba tron (Cubic Spline Interpolation), mô phỏng độ cong tự nhiên của quỹ đạo nhật quỹ mặt trời (`fill_null_algorithm = 'cubic'`).
- d. **Đoạn đứt gãy dài (> 8 bước, > 2 giờ):** Triển khai mô hình hồi quy tuyến tính đa biến (Multivariate Linear Regression) được huấn luyện trên dữ liệu lịch sử cùng trạm, dự báo giá trị điền khuyết dựa trên các biến bức xạ (GHI, DNI, DHI) và nhiệt độ môi trường tương ứng (`fill_null_algorithm = 'regression'`).

Listing 3.1: Thuật toán Điền khuyết Nhân quả Đa tầng (trích xuất từ 02_run_hybrid_imputation.py)

```

1 def impute_series(group: pd.DataFrame) -> pd.DataFrame:
2     # 1. Luật ban đêm vật lý: GHI = 0 hoặc ngoài khung giờ năng -> Gan 0 kWh
3     night_mask = (group["ghi"].le(25.0)) | (group["hour"].ge(18.5)) | (group["hour"].
4         lt(5.5))
5     group.loc[night_mask & group["energy"].isna(), "energy"] = 0.0
6     group.loc[night_mask & group["energy"].isna(), "fill_null_algorithm"] = "
7         rule_based_night"
8
9     # 2. Nội suy tuyến tính cho khoảng trong ngắn (<= 4 bước = <= 1 giờ)
10    short_gap_mask = group["energy"].isna() & (group["gap_length"] <= 4)
11    group.loc[short_gap_mask, "energy"] = group["energy"].interpolate(method="linear",
12        limit=4)
13    group.loc[short_gap_mask, "fill_null_algorithm"] = "linear"
14
15    # 3. Nội suy đa thức bậc 3 Cubic Spline cho khoảng trong trung bình (5-8 bước)
16    med_gap_mask = group["energy"].isna() & (group["gap_length"].between(5, 8))
17    group.loc[med_gap_mask, "energy"] = group["energy"].interpolate(method="cubic",
18        limit=8)
19    group.loc[med_gap_mask, "fill_null_algorithm"] = "cubic"
20
21    # 4. Hồi quy đa biến theo bức xạ & nhiệt độ cho khoảng trong dài (> 8 bước)
22    long_gap_mask = group["energy"].isna()
23    if long_gap_mask.any():
24        X_train = group.loc[~long_gap_mask, ["ghi", "dni", "dhi", "temperature_c"]]
25        y_train = group.loc[~long_gap_mask, "energy"]
26        model = LinearRegression().fit(X_train, y_train)
27        X_missing = group.loc[long_gap_mask, ["ghi", "dni", "dhi", "temperature_c"]]
28        group.loc[long_gap_mask, "energy"] = np.clip(model.predict(X_missing), 0, None
29    )
30    group.loc[long_gap_mask, "fill_null_algorithm"] = "regression"
31    return group

```

3.3.3 Bước 3: Nhận diện Dị thường Kỹ thuật và Gán Nhãn An toàn

Module 02_run_apply_outlier_flags.py áp dụng 5 rào chắn vật lý kết hợp mô hình phân lớp lai GMM-IF để kiểm định 2.731.946 bản ghi sản lượng. Kết quả nhận diện chính xác 33.280 bản ghi dị thường (1,22%), đồng thời gán cờ an toàn (gmm_if_outlier_flag) cùng 6 mã định danh lý do kỹ thuật (Bảng 4.2).

3.3.4 Bước 4: Nạp Dữ liệu vào Kho (Data Warehouse Load) và Kiểm định Toàn vẹn

Module 01_run_load_datawarehouse.py thực hiện nạp dữ liệu từ tầng Buffer sang tầng Data Warehouse chính thức:

- Các bảng Dimension được nạp trước và tạo khóa tự tăng (site_id, geo_id, date_id, time_id,

weather_type_id).

- Bảng fact_solar_energy_gen được nạp theo từng **khối tháng (Monthly Batches)** với câu lệnh `INSERT INTO ... SELECT` kết hợp điều kiện ràng buộc khóa ngoại, tránh tràn bộ nhớ và timeout kết nối trên Supabase.
- Tự động đối soát số lượng bản ghi giữa tầng đệm và tầng kho: đảm bảo $v_{\text{source_count}} = v_{\text{target_count}} = 2.731.946$ dòng (tỷ lệ toàn vẹn 100%).

3.4 Mô hình hóa Lược đồ Thiên hà (Galaxy Schema)

3.4.1 Lý do Lựa chọn Lược đồ Thiên hà

Trong các hệ thống Data Warehouse truyền thống, mô hình Ngôi sao (Star Schema) với một bảng Fact duy nhất thường được ưu tiên nhờ tính đơn giản. Tuy nhiên, bài toán năng lượng mặt trời của dự án xuất hiện hai sự kiện nghiệp vụ diễn ra ở hai chu kỳ thời gian hoàn toàn khác biệt:

- Sự kiện phát điện quang điện xảy ra ở chu kỳ vi mô 15 phút (2.731.946 bản ghi).
- Sự kiện biến động khí tượng thời tiết diễn ra ở chu kỳ 1 giờ (850.752 bản ghi).


Nếu ép hai sự kiện này vào một bảng Fact duy nhất, dữ liệu thời tiết sẽ bị lặp lại 4 lần cho mỗi giờ, làm tăng kích thước bảng thêm 300% và gây méo mó các phép tính tổng hợp trung bình. Do đó, việc xây dựng Lược đồ Thiên hà (Galaxy Schema) với 2 bảng Fact độc lập kết nối đến 4 bảng Dimension dùng chung là giải pháp kiến trúc tối ưu nhất.

3.4.2 Các Sơ đồ Mô hình Dữ liệu Đa Chiều và Thuyết minh Thiết kế

Quá trình thiết kế kho dữ liệu của dự án được tiến hành tuần tự qua 3 giai đoạn chuẩn hóa: Mô hình Khái niệm (Conceptual), Mô hình Logic (Logical), và Mô hình Vật lý (Physical).

Mô hình Dữ liệu Khái niệm (Conceptual Model)


Mô hình Khái niệm (Hình 3.2) xác định các thực thể nghiệp vụ cốt lõi và mối quan hệ giữa chúng ở mức trừu tượng cao nhất, hoàn toàn độc lập với công nghệ cơ sở dữ liệu. Hệ thống gồm 5 thực thể chính: *Trạm phát điện mặt trời (Solar Plant)*, *Vị trí địa lý (Geography)*, *Lịch biểu & Mùa vụ (Calendar)*, *Điều kiện thời tiết (Weather)*, và *Sản lượng phát điện (Solar Energy Generation)*. Mỗi trạm phát gắn liền với một tọa độ địa lý, sản sinh năng lượng theo chu kỳ thời gian và chịu sự chi phối trực tiếp của các biến động khí quyển (bức xạ mặt trời, nhiệt độ, mây che phủ) tại cùng thời điểm quan trắc.



Hình 3.2: Mô hình dữ liệu khái niệm (Conceptual Model).

Mô hình Dữ liệu Logic (Logical Model)


Mô hình Logic (Hình 3.3) cụ thể hóa cấu trúc dữ liệu theo chuẩn Lược đồ Thiên hà (Galaxy Schema / Fact Constellation Schema), giải quyết trọn vẹn sự khác biệt về độ hạt thời gian. Kiến trúc bao gồm 2 bảng sự kiện độc lập: **fact_solar_energy_gen** (độ mịn 15 phút) và **fact_weather** (độ mịn 1 giờ), cùng chia sẻ 4 bảng chiều dùng chung (Conformed Dimensions: **dim_date**, **dim_time**, **dim_geography**, **dim_weather_type**). Mỗi bản ghi Fact liên kết với các Dimension qua quan hệ 1-N thông qua khóa thay thế số nguyên (Surrogate Keys), đảm bảo tính toàn vẹn tham chiếu và tối ưu hóa các phép nối trong truy vấn phân tích đa chiều (OLAP).



Hình 3.3: Mô hình dữ liệu logic (Logical Model) theo Galaxy Schema.

Mô hình Dữ liệu Vật lý (Physical Model)

Mô hình Vật lý (Hình 3.4) chi tiết hóa cấu trúc cài đặt thực tế trên hệ quản trị PostgreSQL 17.6 (Supabase Cloud). Mô hình quy định tường minh kiểu dữ liệu cho từng trường (INT, FLOAT, VARCHAR, BOOLEAN), ràng buộc toàn vẹn khóa chính (PRIMARY KEY) và khóa ngoại (FOREIGN KEY), cơ chế phân vùng bảng vật lý (PARTITION BY RANGE (date_id)) trên bảng sự kiện sản lượng, cùng hệ thống chỉ mục B-Tree phức hợp (Composite Indexes) trên các cặp khóa (site_id, date_id) và time_id nhằm đảm bảo tốc độ phản hồi truy vấn dưới 100 ms.



Hình 3.4: Mô hình dữ liệu vật lý (Physical Model) trên PostgreSQL Supabase.

3.4.3 Cấu trúc Chi tiết Các Bảng trong Kho Dữ liệu

Lược đồ Kho Dữ liệu bao gồm 5 bảng Dimension và 2 bảng Fact được chuẩn hóa:

- dim_solar_site (Bảng Chiều Trạm Phát):** Lưu trữ thông tin 42 dàn quang điện áp mái. Khóa chính là site_id (INT). Thuộc tính bao gồm: Tên cơ sở (campus_name), Công suất danh định STC (capacity_kw), Số lượng tấm pin (number_of_panels), Chung loại tấm pin (panel), Chung loại biến tần (inverter), Bộ tối ưu hóa (optimizers), và Đơn vị đo lường (metric).
- dim_geography (Bảng Chiều Địa lý):** Quản lý tọa độ địa lý của 42 vị trí trạm. Khóa chính là geo_id (INT). Thuộc tính bao gồm: Vĩ độ (latitude), Kinh độ (longitude), và Tên địa danh cơ sở (location_name).
- dim_date (Bảng Chiều Ngày):** Chứa 2.312 ngày lịch biểu từ năm 2019 đến 2023. Khóa chính là date_id định dạng số nguyên YYYYMMDD (ví dụ: 20201015). Thuộc tính bao gồm: Ngày chuẩn (full_date DATE), Ngày (day), Tháng (month), Năm (year), Cờ ngày lễ (is_holiday), Cờ học kỳ chính quy (is_semester), và Cờ mùa thi cử (is_exam).
- dim_time (Bảng Chiều Giờ):** Đại diện cho đúng 96 khung thời gian 15 phút trong 24 giờ. Khóa chính là time_id định dạng số nguyên HHMM (ví dụ: 0915 cho mốc 09:15, 1430 cho mốc 14:30).

Thuộc tính bao gồm: Chuỗi thời gian (`time_string` VARCHAR), Giờ (`hour` từ 0 đến 23), và Phút (`minute` $\in \{0, 15, 30, 45\}$).

5. **dim_weather_type (Bảng Chiều Loại Thời Tiết):** Bảng tra cứu điều kiện thời tiết chuẩn WMO (WMO-No. 8). Khóa chính là `weather_type_id` (INT). Thuộc tính bao gồm: Mã thời tiết (`weather_code`), Cờ ban ngày (`is_day`), Tên điều kiện thời tiết tiếng Anh (`weather_condition`), và Diễn giải chi tiết bằng tiếng Việt (`description`).
6. **fact_solar_energy_gen (Bảng Sự kiện Sản lượng Điện):** Chứa 2.731.946 bản ghi sản lượng 15 phút. Khóa chính là `gen_id` (INT). Liên kết khóa ngoại tới 4 Dimension: `site_id`, `geo_id`, `date_id`, `time_id`. Các trường đo lường và cờ nghiệp vụ gồm: Sản lượng phát điện (`energy_generated_kwh`), Cờ dị thường (`gmm_if_outlier_flag`), Mã phân loại 6 lý do dị thường (`gmm_if_outlier_reason`), và Thuật toán điền khuyết đã áp dụng (`fill_null_algorithm`).
7. **fact_weather (Bảng Sự kiện Khí tượng Khí hậu):** Chứa 850.752 bản ghi thời tiết chu kỳ 1 giờ. Khóa chính là `weather_id` (INT). Liên kết khóa ngoại tới: `geo_id`, `date_id`, `time_id`, `weather_type_id`. Các chỉ số đo lường khí quyển gồm: Bức xạ tổng cộng GHI (`shortwave_radiation`), Nhiệt độ không khí (`temperature_c`), Mây che phủ tổng thể (`cloud_cover_total`), Mây thấp/trung/cao, Bức xạ tán xạ DHI (`diffuse_solar_radiation`), Bức xạ trực xạ DNI (`direct_normal_irradiance`), Tốc độ gió (`wind_speed`), Lượng mưa (`precipitation_mm`), và Thời lượng nắng (`sunshine_duration`).

3.4.4 Chiến lược Tối ưu hóa Hiệu năng: Indexing và Partitioning

Để đảm bảo các truy vấn phân tích tổng hợp (OLAP) và kết nối trực tiếp từ Tableau Desktop đạt thời gian phản hồi dưới 1 giây trên tập dữ liệu hàng triệu dòng:

- **Chỉ mục Phức hợp (Composite B-Tree Indexes):** Tạo chỉ mục `idx_fact_energy_site_date` trên cặp khóa (`site_id`, `date_id`) và `idx_fact_energy_time` trên `time_id`. Điều này giúp loại bỏ hoàn toàn hiện tượng quét toàn bảng (Sequential Scan) khi người dùng Tableau thực hiện lọc theo trạm hoặc khung giờ.
- **Phân vùng Bảng Vật lý (Table Partitioning):** Bảng sự kiện `fact_solar_energy_gen` được phân vùng theo dải thời gian năm (`PARTITION BY RANGE (date_id)`), giúp tối ưu hóa việc quét dữ liệu theo từng năm tài chính (2020, 2021, 2022).

3.5 Thiết kế Siêu thị Dữ liệu (Data Marts)

3.5.1 Lý do Lựa chọn Materialized Views cho BI Mart

Trong quá trình phục vụ trực quan hóa trên Tableau Desktop, việc truy vấn trực tiếp trên kho dữ liệu thô đối mặt với các hạn chế về hiệu năng và tài nguyên. Nhóm nghiên cứu đã phân tích và so sánh 3 phương án kiến trúc phục vụ dữ liệu:

- **So với View thông thường (Standard Views):** Standard View không lưu trữ dữ liệu vật lý mà thực thi lại toàn bộ các phép JOIN phức tạp và tính toán chỉ số (PR , tổn thất nhiệt, xén công suất) trên hơn 3,5 triệu bản ghi mỗi khi người dùng Tableau tương tác lọc biểu đồ. Điều này gây độ trễ truy vấn từ 5–10 giây và làm quá tải CPU máy chủ cơ sở dữ liệu.
- **So với Bảng vật lý riêng biệt (Physical Tables):** Việc tạo các bảng vật lý độc lập đòi hỏi phải lập trình các tiến trình ETL đồng bộ dữ liệu phức tạp, dễ gây sai lệch hoặc trễ hạn dữ liệu nếu một bước trong pipeline gặp lỗi.
- **Ưu thế của Materialized Views:** Materialized View lưu trữ sẵn kết quả tính toán tổng hợp trên đĩa cứng kèm chỉ mục riêng, giảm thời gian phản hồi truy vấn của Tableau từ hàng giây xuống dưới 100 ms. Đồng thời, lệnh REFRESH MATERIALIZED VIEW cho phép làm mới dữ liệu định kỳ một cách chủ động mà không gây khóa bảng hay gián đoạn kết nối đọc trực tiếp.

3.5.2 Kiến trúc Materialized Views trên Supabase (BI Mart)

Module `srcs/04_build_data_marts/05_mv_bi_mart.py` thiết lập 2 **Materialized Views** nén dữ liệu cấp độ cao phục vụ 3 Dashboard quản trị Tableau:

1. **mv_bi_mart_hourly_measures (Materialized View Cấp Giờ):** Tổng hợp dữ liệu 4 chu kỳ 15 phút về cấp 1 giờ, tích hợp sẵn các công thức tính toán chỉ số kỹ thuật, tổn thất và tài chính:

- *Sản lượng lý thuyết ($E_{theoretical}$):* $E_{theo} = P_{stc} \times \frac{GHI}{1000} \times 1 \text{ h (kWh)}$.
- *Hệ số hiệu suất (PR):* $PR = \frac{E_{hourly}}{E_{theo}} \times 100 \%$.
- *Tổn thất do nhiệt ($E_{loss, temp}$):* $E_{loss, temp} = E_{theo} \times |\gamma| \times \max(0, T_{cell} - 25^{\circ}\text{C})$ với hệ số nhiệt $\gamma = -0,4\%/^{\circ}\text{C}$.
- *Tổn thất do xén công suất ($E_{loss, clip}$):* $E_{loss, clip} = \max(0, E_{theo} \times PR_{nominal} - E_{hourly})$.
- *Doanh thu và Môi trường:* Doanh thu theo biểu giá mua điện $Revenue = E_{hourly} \times 1.800 \text{ VNĐ/kWh}$; Khối lượng giảm phát thải $\text{CO}_2 = E_{hourly} \times 0,82 \text{ kg CO}_2/\text{kWh}$.

2. **mv_bi_mart_daily_summary (Materialized View Cấp Ngày):** Tổng hợp theo từng ngày và từng trạm phát, tính toán trước: Năng suất riêng (Specific Yield = kWh/kWp/ngày), Hệ số công suất (Capacity Factor – CF), và Tổng số lượng cờ cảnh báo dị thường O&M trong ngày.

Dưới đây là đoạn mã SQL định nghĩa logic tính toán các chỉ số kỹ thuật và tài chính trong Materialized View:

Listing 3.2: Cấu trúc truy vấn khởi tạo Materialized View BI Mart (trích xuất từ `05_mv_bi_mart.py`)

```
1 CREATE MATERIALIZED VIEW bi_mart.mv_bi_mart_hourly_measures AS
2 WITH Hourly_Agg AS (
3     SELECT
4         f.site_id, f.geo_id, f.date_id,
5         CASE WHEN t.minute = 0 THEN t.hour - 1 ELSE t.hour END AS hourly_bucket,
```

```

6      SUM(f.energy_generated_kwh) AS e_hourly,
7      bool_or(f.gmm_if_outlier_flag) AS gmm_if_outlier_flag
8  FROM datawarehouse.fact_solar_energy_gen f
9  LEFT JOIN datawarehouse.dim_time t ON f.time_id = t.time_id
10 GROUP BY f.site_id, f.geo_id, f.date_id, hourly_bucket
11 )
12 SELECT
13     h.*, w.shortwave_radiation AS ghi, w.temperature_c,
14     site.capacity_kw AS p_stc,
15     -- San Luong Ly thuyet theo buc xa
16     ROUND((site.capacity_kw * (w.shortwave_radiation / 1000.0) * 1.0)::numeric, 4) AS
theoretical_energy_kwh,
17     -- He so hieu suat PR
18     CASE WHEN w.shortwave_radiation > 50 THEN
19         ROUND(((h.e_hourly / NULLIF(site.capacity_kw * (w.shortwave_radiation /
1000.0), 0)) * 100)::numeric, 2)
20     ELSE NULL END AS pr_actual,
21     -- Doanh thu FiT va Giam phat thai CO2
22     ROUND((h.e_hourly * 1800)::numeric, 2) AS revenue_vnd,
23     ROUND((h.e_hourly * 0.82)::numeric, 3) AS co2_reduction_kg
24 FROM Hourly_Agg h
25 JOIN datawarehouse.dim_solar_site site ON site.site_id = h.site_id
26 LEFT JOIN datawarehouse.fact_weather w ON w.geo_id = h.geo_id AND w.date_id = h.
date_id;

```

3.5.3 Thiết kế Siêu thị Dữ liệu Học máy (ML Data Mart)

Khác với BI Mart vốn tập trung vào tổng hợp cấp giờ và ngày, **ML Data Mart** (được xây dựng bởi `srcs/04_build_data_marts/02_build_ml_mart.py` và căn chỉnh nhân quả bởi module `srcs/00_utils/04_realign_mlmart_weather.py`) được thiết kế chuyên biệt để phục vụ trích xuất đặc trưng và huấn luyện mô hình học máy:

- Định dạng Lưu trữ Apache Parquet Dạng Cột:** Dữ liệu được xuất bản dưới tệp Parquet dạng cột (`data/mlmart_base/v4_final_cleaned.parquet`). Nhờ thuật toán nén Snappy và cấu trúc lưu trữ theo cột, dung lượng tệp giảm mạnh từ 158 MB CSV xuống còn xấp xỉ 35 MB (78% compression ratio), giúp tăng tốc độ đọc dữ liệu (IO throughput) khi huấn luyện mô hình lên gấp 10 lần.
- Căn chỉnh Khí tượng Nhân quả (Causal Weather Alignment):** Để loại bỏ hoàn toàn hiện tượng rò rỉ dữ liệu tương lai (Data Leakage) khi ghép nối dữ liệu khí tượng 1 giờ với sản lượng 15 phút, hệ thống sử dụng thuật toán làm tròn sàn (Floor-Hour Lookup): mốc thời tiết được gán ngược cho 4 dòng 15 phút trong giờ đó. Nhờ vậy, mốc thời tiết luôn xảy ra trước hoặc bằng mốc sản lượng ($\Delta t \in \{-45, -30, -15, 0\}$ phút), đảm bảo 100% tính nhân quả trong dự báo.
- Tích hợp Đặc trưng Cơ sở Đa chiều:** ML Mart tích hợp sẵn các nhóm đặc trưng quan yếu: (1) Lưới 15 phút liên tục 2.731.946 dòng, (2) Đặc trưng lịch biểu và mùa vụ, (3) Thông số kỹ thuật

trạm pin (P_{stc} , chủng loại biến tần), (4) Dữ liệu bức xạ quang học và nhiệt độ đã căn chỉnh nhân quả, và (5) Cờ dị thường kỹ thuật GMM-IF phục vụ lọc mẫu huấn luyện an toàn.

Dưới đây là đoạn mã Python thực hiện căn chỉnh khí tượng nhân quả nghiêm ngặt:

Listing 3.3: Thuật toán Căn chỉnh Khí tượng Nhân quả Chống Rò rỉ Dữ liệu (trích xuất từ 04_realign_mlmart_weather.py)

```
1 def realign_causal_weather(df: pd.DataFrame) -> pd.DataFrame:
2     # 1. Trích xuất quan trắc thời tiết chuẩn tại mốc phút = 00 của từng giờ
3     df["timestamp"] = pd.to_datetime(df["timestamp"])
4     hourly_weather = df[df["timestamp"].dt.minute == 0][
5         ["site_id", "timestamp", "shortwave_radiation", "temperature_c", "
6         cloud_cover_total"]
7     ].copy()
8     hourly_weather["_weather_hour"] = hourly_weather["timestamp"].dt.floor("h")
9
10    # 2. Tạo khoa ghép lam tron san (Floor Hour) cho toan bo cac dong 15 phut
11    df["_weather_hour"] = df["timestamp"].dt.floor("h")
12    df = df.drop(columns=["shortwave_radiation", "temperature_c"], errors="ignore")
13
14    # 3. Ghep noi nhan qua: weather_timestamp luon <= timestamp thuc te
15    merged = df.merge(hourly_weather, on=["site_id", "_weather_hour"], how="left")
16
17    # 4. Kiem chung nghiem ngat: Do chenh thoi gian phai nam trong [-45, 0] phut
18    time_delta = (merged["timestamp_weather"] - merged["timestamp"]).dt.total_seconds
19    () / 60
20    assert (time_delta > 0).sum() == 0, "Phat hien ro ri du lieu tuong lai!"
21    return merged
```

3.5.4 Cấu hình Kết nối Tableau qua Connection Pooler (Port 6543)

Tableau Desktop kết nối trực tiếp tới Supabase Data Warehouse thông qua cơ chế Supervisor Connection Pooling (Port 6543 ở chế độ Transaction Mode). Cơ chế này duy trì một nhóm các kết nối mở sẵn, giúp hàng chục phiên làm việc đồng thời của người dùng Tableau không làm cạn kiệt tài nguyên kết nối của máy chủ PostgreSQL.

3.6 Kiểm soát Chất lượng, Tính Toàn vẹn và Bảo mật Dữ liệu

Quy trình quản trị chất lượng dữ liệu được kiểm soát nghiêm ngặt theo 3 nguyên tắc:

- 1. Kiểm tra Ràng buộc Khóa ngoại (Anti-Join Integrity Check):** Module 04_qa_qc_fixed.py chạy các truy vấn LEFT JOIN ... WHERE dim.id IS NULL giữa bảng Fact và các Dimension tương ứng. Kết quả kiểm tra đạt tỷ lệ 100% bản ghi có khóa tham chiếu hợp lệ (0 bản ghi mồ côi).
- 2. Xác thực Toàn vẹn Dữ liệu Bằng Đối soát Hai Chiều (Data Reconciliation):** Module 04_qa_qc_fixed.py thực hiện đối soát tự động tổng sản lượng giữa bảng sự kiện thô

fact_solar_energy_gen và bảng tổng hợp mv_bi_mart_hourly_measures. Kết quả xác nhận tổng sản lượng toàn hệ thống đạt khớp tuyệt đối (74.982.150,45 kWh) và 2.731.946 dòng dữ liệu (sai lệch 0,0%).

3. Bảo mật Cấp Dòng (Row-Level Security – RLS) và Mã hóa SSL/TLS: Cơ sở dữ liệu Supabase được cấu hình chính sách bảo mật RLS phân quyền theo vai trò: tài khoản kỹ sư dữ liệu có toàn quyền DDL/DML, trong khi tài khoản kết nối từ Tableau Desktop chỉ được cấp quyền đọc (SELECT) trên schema datawarehouse và các Materialized Views. Toàn bộ lưu lượng truyền tải đều được mã hóa bằng giao thức SSL/TLS bắt buộc (sslmode=require).

Listing 3.4: Đoạn mã đối soát dữ liệu tự động giữa Data Warehouse và BI Mart (trích xuất từ 04_qa_qc_fixed.py)

```

1 def run_qa_qc_check(engine: Engine) -> None:
2     qa_qc_sql = text('''
3         WITH dwh_15m AS (
4             SELECT date_id, site_id, ROUND(SUM(energy_generated_kwh)::numeric, 4) AS
dwh_total
5             FROM datawarehouse.fact_solar_energy_gen GROUP BY date_id, site_id
6         ),
7         bi_mart_hourly AS (
8             SELECT date_id, site_id, ROUND(SUM(e_hourly)::numeric, 4) AS bi_total
9             FROM bi_mart.mv_bi_mart_hourly_measures GROUP BY date_id, site_id
10        )
11        SELECT d.date_id, d.site_id, d.dwh_total, b.bi_total, ABS(d.dwh_total - b.
bi_total) AS diff
12        FROM dwh_15m d JOIN bi_mart_hourly b ON d.date_id = b.date_id AND d.site_id =
b.site_id
13        WHERE ABS(d.dwh_total - b.bi_total) > 0.001;
14    ''')
15    with engine.connect() as conn:
16        mismatches = conn.execute(qa_qc_sql).fetchall()
17        assert len(mismatches) == 0, f"Phat hien {len(mismatches)} diem lech du lieu
giua DWH va BI Mart!"
18        log.info("QA/QC PASS: 100% du lieu giữa Data Warehouse và BI Mart hoàn toàn
khop nhau.")

```


Xây dựng Pipeline Dữ liệu và Phát hiện Dị thường

4.1 Tổng quan Kiến trúc Pipeline Xử lý Dữ liệu

Để xây dựng một hệ thống phân tích dữ liệu sản lượng điện mặt trời ổn định và tin cậy, dự án thiết lập quy trình trích xuất, biến đổi và nạp dữ liệu (ETL Pipeline) tự động hóa bằng ngôn ngữ Python. Luồng di chuyển dữ liệu (Data Flow) được chia làm 3 tầng lõi rõ rệt nhằm đáp ứng triết lý thiết kế kho dữ liệu tập trung (tiếp cận từ tổng quan đến chi tiết):

1. **Tầng Trích xuất (Extract):** Dữ liệu lịch sử từ các tệp tin CSV vật lý ghi nhận tại trạm pin và dữ liệu khí tượng viễn thám từ Open-Meteo API được thu thập và lưu trữ tập trung tại thùng chứa (Bucket) raw-data của hệ thống lưu trữ đối tượng MinIO S3. Các tệp tin cốt lõi bao gồm `campus_meta.csv`, `Solar_Site_Details.csv`, `calendar.csv`, `Solar_Energy_Generation.csv`, và `open_meteo_weather_raw_2020_2022.csv`.
2. **Tầng Biến đổi (Transform):** Sử dụng các thư viện tính toán hiệu năng cao như `pandas`, `numpy`, và `scikit-learn` để thực hiện chuẩn hóa kiểu dữ liệu thời gian, điền khuyết thiếu bằng chiến lược lai (điền khuyết kết hợp), gán cờ ngoại lai thông qua phân tích biến động trung bình trượt cục bộ, và đồng bộ granularity thời gian.
3. **Tầng Nạp (Load):** Dữ liệu sau biến đổi được đẩy vào hệ quản trị cơ sở dữ liệu Supabase PostgreSQL thông qua hai schema chuyên biệt: `staging` (bộ đệm trung gian) và `datawarehouse` (kho dữ liệu chuẩn hóa đa chiều phục vụ BI và ML).

Để khắc phục các hạn chế về môi trường triển khai thực tế, mã nguồn ETL của dự án tích hợp hai giải pháp hệ thống quan trọng:

- **Sử dụng Thư viện kết nối thuần Python (pg8000):** Khác với thư viện `psycopg2` vốn yêu cầu biên dịch các thư viện hệ thống nhị phân C (dễ gây lỗi thiếu `libz.so.1` hoặc `libstdc++.so.6` trên môi trường ảo hóa NixOS), thư viện `pg8000` hoạt động hoàn toàn độc lập, đảm bảo tính di động cao của mã nguồn.
- **Cấu hình Connection Pooler thông qua IPv4:** Do Supabase chỉ hỗ trợ truy cập IPv6 trực tiếp cho gói tài khoản miễn phí, dự án cấu hình Pooler trung gian của Supabase tại cổng 5432 (chế độ Session Mode dành riêng cho tiến trình Python ETL backend chạy lô lớn), trong khi kết nối phân tích BI Tableau được cấu hình qua cổng 6543 (Transaction Mode Pooler) nhằm phục vụ hàng chục phiên truy vấn đồng thời mà không làm cạn kiệt tài nguyên máy chủ.

Dưới đây là mã nguồn cấu hình kết nối tối ưu hóa bằng thư viện pg8000:

Listing 4.1: Mã nguồn thiết lập kết nối cơ sở dữ liệu qua Pooler bằng pg8000

```

1 def connect_pg8000() -> any:
2     import pg8000.dbapi
3     load_dotenv(ENV_FILE)
4     required = [
5         "DB_HOST", "DB_PORT", "DB_NAME",
6         "DB_USER", "DB_PASSWORD"
7     ]
8     missing = [name for name in required if not os.getenv(name)]
9     if missing:
10         missing_str = ', '.join(missing)
11         err_msg = f"Missing vars in {ENV_FILE}: {missing_str}"
12         raise RuntimeError(err_msg)
13
14     return pg8000.dbapi.connect(
15         host=os.environ["DB_HOST"],
16         port=int(os.environ.get("DB_PORT", "5432")),
17         database=os.environ["DB_NAME"],
18         user=os.environ["DB_USER"],
19         password=os.environ["DB_PASSWORD"],
20         ssl_context=True,
21     )

```

4.1.1 Thiết lập Tiến trình Nạp Dữ liệu Thứ tự

Để bảo toàn tính toàn vẹn tham chiếu khóa ngoại (Foreign Key Constraints), tiến trình tải dữ liệu vào kho được kiểm soát nghiêm ngặt theo thứ tự phụ thuộc. File `load_01_dims.py` chịu trách nhiệm tẩy trống dữ liệu cũ bằng lệnh `TRUNCATE CASCADE` và tải lại các bảng chiều độc lập theo trình tự tuyến tính:

`dim_geography` → `dim_solar_site` → `dim_date` → `dim_time` → `dim_weather_type`

Ngay sau khi các bảng chiều được nạp thành công, tệp tin `load_02_facts.py` tiến hành đọc các bảng sự kiện quy mô lớn từ MinIO và ánh xạ các khóa tự nhiên sang khóa đại diện (Surrogate Keys) bằng các bộ từ điển tra cứu (Lookups) đã lưu trong bộ nhớ tạm (In-memory dicts). Để tránh hiện tượng nghẽn bộ nhớ đệm (RAM Out-Of-Memory) khi xử lý tập dữ liệu sản lượng hơn 2,7 triệu dòng, luồng nạp sử dụng cơ chế chia nhỏ dữ liệu thành từng khối (`chunksize = 50.000` dòng) và thực thi lệnh chèn hàng loạt `execute_values` tối ưu hóa hiệu năng IO.

4.1.2 Cơ chế Quản lý Giao dịch và Chế độ Chạy Thử An toàn (Dry-Run)

Để đảm bảo tính toàn vẹn dữ liệu (ACID) khi cập nhật kho dữ liệu Supabase, toàn bộ luồng thực thi trong `srcs/06_run_pipeline/main.py` và các module nạp dữ liệu được kiểm soát giao dịch chặt chẽ:

- **Quản lý Giao dịch Tường minh (Explicit Transaction):** Chế độ autocommit bị vô hiệu hóa trong các tiến trình ghi dữ liệu. Tiến trình nạp bảng sự kiện `fact_solar_energy_gen` được chia thành các khối giao dịch theo từng tháng. Nếu phát sinh lỗi vi phạm ràng buộc khóa ngoại hoặc gián đoạn mạng, lệnh `connection.rollback()` được kích hoạt ngay lập tức để hoàn tác toàn bộ thay đổi của khối dữ liệu đang nạp dở, ngăn ngừa hiện tượng dữ liệu rác.
- **Chế độ Chạy Thử (--dry-run Mode):** Hệ thống hỗ trợ cờ thực thi `--dry-run` cho các giai đoạn `transform`, `imputation`, và `outlier`. Ở chế độ này, chương trình thực hiện đầy đủ các phép tính toán, đếm số lượng dòng biến đổi và in thống kê kiểm thử, sau đó tự động phát lệnh `rollback` để hoàn tác giao dịch mà không làm thay đổi trạng thái của cơ sở dữ liệu trên đám mây.

Listing 4.2: Cơ chế quản lý giao dịch và chế độ Dry-Run (trích xuất từ `06_run_pipeline/main.py`)

```

1 try:
2     log.info("Mo transaction thuc thi giai doan Transform & Imputation...")
3     run_transform_buffers(connection, dry_run=args.dry_run)
4     if args.dry_run:
5         connection.rollback()
6         log.info("Transform dry-run hoan tat; transaction da duoc rollback an toan.")
7     else:
8         connection.commit()
9         log.info("Transform hoan tat thanh cong; transaction da duoc commit.")
10 except Exception as e:
11     connection.rollback()
12     log.exception("Phat sinh loi trong qua trinh Transform; da rollback toan bo giao
    dich.")
13     raise

```

4.2 Đánh giá Chất lượng và Khám phá Dữ liệu (EDA ban đầu)

Trước khi thực hiện các phép toán làm sạch, nhóm tiến hành một bước hồ sơ hóa dữ liệu (Data Profiling) nhằm phát hiện các vấn đề về chất lượng dữ liệu thô. Tiến trình này được tự động hóa thông qua kịch bản `data_integrity_and_reconciliation_check.py`.

Công cụ thực hiện quét toàn bộ các bảng trong schema `staging` để thống kê: (1) Tổng số dòng dữ liệu hiện có, (2) Số lượng bản ghi bị khuyết thiếu khóa chính (NULL PK), và (3) Số lượng bản ghi bị trùng lặp khóa tự nhiên (Duplicate PKs).

Bảng 4.1: Thống kê kiểm tra chất lượng dữ liệu tại tầng Staging.

Tên bảng dữ liệu	Tổng số dòng	Số dòng trùng lặp	Số dòng khuyết PK
dim_geography	5	0	0
dim_solar_site	42	0	0
dim_date	2.312	0	0
dim_time	96	0	0
dim_weather_type	22	0	0
fact_weather	367.920	0	0
fact_solar_energy_gen	2.731.946	0	0

Kết quả phân tích ban đầu cho thấy cấu trúc khung của các bảng chiều và bảng thời tiết rất sạch, không xuất hiện hiện tượng trùng lặp dòng. Tuy nhiên, bảng sự kiện sản lượng thô `fact_solar_energy_gen` chứa 107.452 ô dữ liệu bị khuyết giá trị sản lượng (đây là các ô khuyết thiếu kỹ thuật mang giá trị NaN ngay trong file CSV thô ban đầu cần điền khuyết tại Staging, phân biệt hoàn toàn với 1.536.301 điểm không phát điện ban đêm sinh ra sau khi dựng lại lưới thời gian liên tục), chiếm khoảng 3,93% tổng số quan trắc thực tế đo đạc. Đây là đối tượng trọng tâm cần xử lý tại tầng làm sạch dữ liệu.

4.2.1 Các Cột Thực Tế và Ánh Xạ Dữ Liệu Trong Pipeline

Trong giai đoạn nạp dữ liệu từ các tệp thô vào bảng đệm (Staging layer), hệ thống thực hiện chuyển đổi kiểu dữ liệu (casting) và đổi tên trường để phù hợp với định dạng kho dữ liệu. Chi tiết các trường thông tin thực tế được ánh xạ từ tệp thô lên bảng sự kiện được thể hiện qua mã nguồn xử lý trực tiếp dưới đây:

Cấu trúc ánh xạ bảng sự kiện sản lượng (`fact_solar_energy_gen`)

Bảng này ghi nhận sản lượng điện thực tế theo chu kỳ 15 phút của từng trạm phát:

- `sitekey` (Ánh xạ từ cột `SiteKey` trong tệp thô, định dạng chuỗi chuyển sang `VARCHAR` hoặc `INT`): Mã định danh duy nhất của từng trạm phát.
- `timestamp` (Ánh xạ từ cột `Timestamp` dạng text thô, xử lý chuyển đổi định dạng `YYYY-MM-DD HH24:MI:SS` sang kiểu dữ liệu `TIMESTAMP` chuẩn): Mốc thời gian quan trắc sản lượng.
- `energy_generated_kwh` (Ánh xạ từ cột `SolarGeneration` thô, làm sạch ký tự lạ và chuyển đổi thành `DOUBLE PRECISION` hoặc `FLOAT`): Sản lượng điện mặt trời thực tế thu được trong 15 phút (đơn vị kWh).

Cấu trúc ánh xạ bảng sự kiện thời tiết (fact_weather)

Thay vì chỉ liệt kê thủ công, toàn bộ logic trích xuất, ép kiểu dữ liệu từ nguồn khí tượng thô staging.stg_open_meteo_weather_raw (lấy từ Open-Meteo API [2]) sang bảng sự kiện fact_weather được hiện thực hóa qua định nghĩa LoadSpec trong tệp tin mã nguồn srcs/02_transform/01_run_transform_buffers.py:

Listing 4.3: Mã nguồn Python/SQL thực tế ánh xạ và chuyển đổi kiểu dữ liệu cho bảng sự kiện fact_weather

```

1 LoadSpec(
2     table="fact_weather",
3     columns=(
4         "sitekey",
5         "timestamp",
6         "weather_code",
7         "is_day",
8         "shortwave_radiation",
9         "temperature_c",
10        "cloud_cover_total",
11        "cloud_cover_low",
12        "cloud_cover_mid",
13        "cloud_cover_high",
14        "diffuse_solar_radiation",
15        "direct_normal_irradiance",
16        "wind_speed",
17        "precipitation_mm",
18        "sunshine_duration",
19    ),
20    select_sql="\n\n"
21        SELECT
22            sitekey,
23            timestamp::timestamp AS timestamp,
24            weather_code::int AS weather_code,
25            is_day::int AS is_day,
26            shortwave_radiation::numeric
27                AS shortwave_radiation,
28            temperature_2m::numeric
29                AS temperature_c,
30            cloud_cover::numeric
31                AS cloud_cover_total,
32            cloud_cover_low::numeric
33                AS cloud_cover_low,
34            cloud_cover_mid::numeric
35                AS cloud_cover_mid,
36            cloud_cover_high::numeric
37                AS cloud_cover_high,
38            diffuse_radiation::numeric
39                AS diffuse_solar_radiation,

```

```

40         direct_radiation::numeric
41         AS direct_normal_irradiance,
42         wind_speed_10m::numeric
43         AS wind_speed,
44         precipitation::numeric
45         AS precipitation_mm,
46         sunshine_duration::numeric
47         AS sunshine_duration
48     FROM staging.stg_open_meteo_weather_raw
49     "\"\"\",
50 )

```

Đoạn mã trên thể hiện rõ quy tắc chuẩn hóa kiểu dữ liệu nghiêm ngặt: mốc thời gian được ép về TIMESTAMP, mã thời tiết `weather_code` và cờ `is_day` ép về INT, trong khi tất cả 11 biến khí tượng viễn thám liên tục (bức xạ mặt trời, nhiệt độ 2m, các tầng mây che phủ, tốc độ gió 10m, lượng mưa và thời lượng nắng) đều được ép kiểu NUMERIC để bảo toàn độ chính xác số học cao nhất cho các phép tính tổn thất và mô hình học máy.

4.3 Làm sạch và Chuẩn hóa Dữ liệu (Data Cleaning)

4.3.1 Xử lý Dữ liệu Khuyết thiếu và Lỗi Logic

Để phục hồi dữ liệu khuyết thiếu cho trường sản lượng phát điện (`energy_generated_kwh`), dự án áp dụng chiến lược nội suy lai nghiêm ngặt (Hybrid Imputation Strategy) tích hợp giữa các bộ quy tắc nghiệp vụ vật lý và mô hình học máy trong file `solar_data_pipeline.py`. Tiến trình xử lý gồm hai giai đoạn chính:

Giai đoạn 1: Lọc vật lý ban đêm (Rule-Based Night Zeroing)

Đối với các trạm phát điện mặt trời quang điện, sản lượng điện năng luôn bằng 0 vào ban đêm do không có bức xạ mặt trời. Nếu sử dụng các thuật toán nội suy thuần toán học (như tuyến tính hay spline) trên các khoảng trống kéo dài qua đêm, hệ thống sẽ sinh ra các giá trị sản lượng ảo (dương) phi vật lý.

Do đó, thuật toán tiến hành rà soát mốc thời gian và áp đặt giá trị 0 ngay lập tức nếu thỏa mãn một trong hai điều kiện logic sau:

- **Khung giờ ban đêm tự nhiên:** Mốc thời gian đo đạc nằm trong khoảng từ 18:30 chiều hôm trước đến 05:30 sáng hôm sau ($T \geq 18.5$ hoặc $T < 5.5$).
- **Điều kiện thời tiết triệt tiêu:** Giá trị bức xạ sóng ngắn mặt trời (`shortwave_radiation`) bằng 0 hoặc cờ chỉ số ánh sáng ngày `is_day` bằng 0 trong tập dữ liệu thời tiết (được đồng bộ hóa sang dòng sản lượng tương ứng bằng thuật toán ghép nối mốc gần nhất `pd.merge_asof` với ngưỡng sai lệch thời gian tối đa là 30 phút).

Giai đoạn này đã xử lý thành công 94.618 ô dữ liệu trống (chiếm tới 88,1% tổng số giá trị khuyết thiếu ban đầu), gán chúng về giá trị 0.0 một cách chính xác.

Mã nguồn Python hiện thực thuật toán lọc vật lý ban đêm:

Listing 4.4: Mã nguồn Python hiện thực bộ quy tắc Night-Zeroing vật lý

```

1 def rule_based_night_zero(
2     solar_df: pd.DataFrame, weather_df: pd.DataFrame, site_key: int
3 ) -> tuple:
4     gen = solar_df["energy_generated_kwh"].copy()
5     ts = solar_df["timestamp"]
6
7     # Xác định giờ đêm tự nhiên
8     hour = ts.dt.hour + ts.dt.minute / 60
9     is_night = (hour >= NIGHT_START + 0.5) | (hour < NIGHT_END + 0.5)
10
11     # Kết nối với open_meteo để lấy thông tin bức xạ sóng ngắn
12     w = weather_df[weather_df["sitekey"] == site_key][
13         ["timestamp", "shortwave_radiation", "is_day"]
14     ].copy()
15     w = w.rename(columns={"timestamp": "timestamp"})
16     w["timestamp"] = pd.to_datetime(w["timestamp"])
17
18     merged = pd.merge_asof(
19         solar_df[["timestamp"]].reset_index(),
20         w.sort_values("timestamp"),
21         on="timestamp",
22         tolerance=pd.Timedelta("30min"),
23         direction="nearest",
24     ).set_index("index")
25
26     # Điều kiện bức xạ sóng ngắn bằng 0 hoặc có đêm is_day = 0
27     zero_radiation = (merged["shortwave_radiation"].fillna(0) == 0) | (
28         merged["is_day"].fillna(0) == 0
29     )
30     mask_zero = is_night.values | zero_radiation.values
31
32     n_filled = (mask_zero & gen.isna()).sum()
33     gen[mask_zero & gen.isna()] = 0.0
34     return gen, n_filled

```

Giai đoạn 2: Nội suy phân cấp theo quy mô khoảng trống (Imputation Gaps classification)

Đối với 12.834 ô dữ liệu khuyết thiếu phát sinh vào ban ngày (khi có bức xạ), thuật toán tiến hành phân tích độ dài chuỗi khuyết liên tiếp (Gap size) của từng trạm phát độc lập để áp dụng phương pháp điền khuyết tối ưu:

- a. **Khoảng khuyết ngắn (≤ 2 dòng liên tiếp, tương đương ≤ 30 phút):** Áp dụng phương pháp nội suy tuyến tính (*Linear Interpolation*) theo thời gian. Do khoảng thời gian gián đoạn rất ngắn,

biến động của ánh sáng mặt trời được coi là thay đổi tuyến tính đều giữa điểm biên trước và biên sau khoảng khuyết.

b. Khoảng khuyết trung bình (Từ 3 đến 8 dòng liên tiếp, tương đương từ 45 phút đến 2 tiếng):

Áp dụng phương pháp nội suy *Cubic Spline*. Đường cong bậc ba giúp mô phỏng mượt mà sự trôi sụt tự nhiên của sản lượng điện do mây che phủ đi qua trạm pin. Để tránh hiện tượng sập nhiều ma trận khi gặp các khoảng khuyết lớn lân cận, thuật toán xây dựng một bản sao tạm thời được điền tuyến tính để làm mịn dữ liệu mốc trước khi tính toán spline bậc ba thực tế.

c. Khoảng khuyết diện rộng (> 8 dòng liên tiếp, tương đương > 2 tiếng): Trong trường hợp này, dữ liệu bị mất quá dài khiến các phương pháp nội suy chuỗi đơn biến (Tuyến tính/Spline) mất khả năng phục hồi chính xác xu hướng thực tế. Nhóm thiết lập mô hình hồi quy đa biến (*Multivariate Regression Imputation*) độc lập cho từng trạm phát.

Mô hình Hồi quy Tuyến tính (*LinearRegression* từ thư viện *scikit-learn*) được huấn luyện trên tập các bản ghi sạch (đầy đủ thông tin) của chính trạm đó. Các biến đầu vào (Features) bao gồm: bức xạ sóng ngắn mặt trời (*shortwave_radiation*), bức xạ chiếu trực tiếp (*direct_normal_irradiance*), bức xạ khuếch tán (*diffuse_solar_radiation*) và nhiệt độ không khí ở độ cao 2m (*temperature_c*).

Sau khi huấn luyện, mô hình sẽ dự đoán sản lượng điện năng cho các khoảng khuyết diện rộng dựa trên dữ liệu khí tượng thực tế tại tọa độ trạm phát đó. Kết quả dự đoán được cắt giới hạn dưới bằng 0 (*clip(lower=0)*) để loại bỏ các giá trị âm sinh ra do sai số hồi quy.

Mã nguồn Python thực thi hồi quy đa biến điền khuyết diện rộng ban ngày:

Listing 4.5: Mã nguồn Python thực thi Multivariate Regression Imputation cho các khoảng khuyết lớn

```
1 def regression_imputation_large_gaps_strict(
2     solar_sub: pd.DataFrame,
3     weather_df: pd.DataFrame,
4     site_key: int,
5     large_gap_indices: set,
6 ) -> tuple:
7     FEATURES = [
8         "shortwave_radiation",
9         "direct_normal_irradiance",
10        "diffuse_solar_radiation",
11        "temperature_c",
12    ]
13
14    cols = ["timestamp"] + FEATURES
15    w = weather_df[weather_df["sitekey"] == site_key][cols].copy()
16    w = w.rename(columns={"timestamp": "timestamp"})
17    w["timestamp"] = pd.to_datetime(w["timestamp"])
18
```

```

19 merged = pd.merge_asof(
20     solar_sub[["timestamp", "energy_generated_kwh"]].reset_index(),
21     w.sort_values("timestamp"),
22     on="timestamp",
23     tolerance=pd.Timedelta("60min"),
24     direction="nearest",
25 ).set_index("index")
26
27 train_mask = merged["energy_generated_kwh"].notna() & \
28     merged[FEATURES].notna().all(axis=1)
29 pred_mask = merged["energy_generated_kwh"].isna() & \
30     merged[FEATURES].notna().all(axis=1)
31
32 filled = 0
33 if train_mask.sum() < 10:
34     return solar_sub["energy_generated_kwh"].values, 0
35
36 X_train = merged.loc[train_mask, FEATURES].values
37 y_train = merged.loc[train_mask, "energy_generated_kwh"].values
38
39 # Chuan hoa thong so dac trung dau vao
40 scaler = StandardScaler()
41 X_train_sc = scaler.fit_transform(X_train)
42
43 model = LinearRegression()
44 model.fit(X_train_sc, y_train)
45
46 if pred_mask.sum() > 0:
47     X_pred = merged.loc[pred_mask, FEATURES].values
48     X_pred_sc = scaler.transform(X_pred)
49     y_pred = model.predict(X_pred_sc)
50
51     result = solar_sub["energy_generated_kwh"].copy()
52     pred_indices = merged[pred_mask].index.tolist()
53
54     for pos, idx in enumerate(pred_indices):
55         local_pos = (
56             solar_sub.index.get_loc(idx)
57             if idx in solar_sub.index else None
58         )
59         # Chi ghi vao cac vi tri thuoc khoang khuyet Lon
60         if local_pos is not None and local_pos in large_gap_indices:
61             result.iloc[local_pos] = max(0.0, y_pred[pos])
62             filled += 1
63
64     return result.values, filled
65 return solar_sub["energy_generated_kwh"].values, 0

```


Tổng hợp kết quả sau quy trình làm sạch dữ liệu khuyết thiếu:

- Tổng số ô trống ban đầu: 107.452 ô (3,93% dữ liệu).
- Số ô được điền qua lọc ban đêm (Night Zero): 94.618 ô.
- Số ô được điền qua nội suy tuyến tính (Linear): 3.652 ô.
- Số ô được điền qua nội suy đường cong (Cubic Spline): 5.124 ô.
- Số ô được điền qua mô hình học máy hồi quy (Regression): 4.058 ô.
- Số ô NULL còn lại trong kho dữ liệu: 0 ô (Điền khuyết thành công 100%).

4.3.2 Xử lý Dữ liệu Ngoại lai (Outliers) và Lọc nhiễu

Trong chuỗi thời gian vận hành thực tế của hệ thống điện mặt trời quang điện (PV), dữ liệu đo đạc từ các cảm biến dòng điện (CT) và đồng hồ đo năng lượng (Smart Meters) thường xuyên xuất hiện các điểm dị thường (Anomalies/Outliers). Nếu không được nhận diện và gỡ bỏ chính xác, các dữ liệu này sẽ làm biến dạng các chỉ số hiệu suất kỹ thuật (như PR, CF) và gây sai lệch nghiêm trọng cho mô hình huấn luyện học máy dự báo sản lượng.

Bản chất Nghiệp vụ và Phân tích Nguyên nhân Phát sinh Ngoại lai

Dựa trên các nghiên cứu kỹ thuật chuyên sâu về độ tin cậy quang điện áp mái từ Tổ chức Năng lượng Quốc tế (IEA-PVPS Task 13) [3] và khảo sát thực nghiệm tại 42 trạm PV của Đại học La Trobe (Úc) [1], các hiện tượng bất thường trong dữ liệu phát sinh từ 4 nhóm nguyên nhân vật lý cốt lõi:

1. **Sự cố Biến tần và Thiết bị Chuyển đổi (Inverter / Optimizer Failures):** Theo báo cáo độ tin cậy quang điện quốc tế của IEA-PVPS Task 13 [3], bộ biến tần (Inverter) là mắt xích có độ tin cậy thấp nhất trong toàn bộ vòng đời hệ thống quang điện. Thời gian trung bình giữa hai lần hỏng (MTBF) của Inverter ngắn hơn tám pin quang điện từ 300 đến 500 lần. Lỗi Inverter chiếm tới 36% tổng sản lượng tổn thất do thiết bị vật lý gây ra, với tỷ lệ hư hỏng hàng năm dao động từ 1% đến 15%/năm [3]. Khi Inverter bị ngắt mạch bảo vệ quá nhiệt (Thermal trip) hoặc quá áp lưới theo chuẩn AS/NZS 4777.2, sản lượng trạm sụt giảm đột ngột về 0 giữa ban ngày dù bức xạ mặt trời đang đạt đỉnh cực đại ($> 700 \text{ W/m}^2$) [1].
2. **Hỏng Diode Bypass và Che bóng Cục bộ (Bypass Diode Faults & Shading):** Theo nghiên cứu suy thoái quang điện IEA-PVPS Task 13 [3] và khảo sát thực nghiệm tại 42 trạm UNISOLAR [1], khi một tấm pin trong chuỗi (String) bị che bóng bởi cây cối, bụi bẩn bám dính dày đặc (Soiling) hoặc hỏng diode bypass, dòng điện của toàn bộ chuỗi bị bóp nghẹt theo tấm pin yếu nhất. Sự cố ngắt mạch hoặc hở mạch diode bypass có thể làm triệt tiêu tới **33%** sản lượng điện của riêng tấm pin đó (do cấu trúc 3 diode bảo vệ 3 nhóm cell), tạo nên các vết sụt giảm sản lượng cục bộ dạng bậc thang cố định 33% hoặc 50% đã được mô hình GMM-IF nhận diện [4].

3. **Suy giảm do Quá nhiệt và Điểm nóng (Thermal Derating & Hot-spots):** Theo các tiêu chuẩn kiểm định IEC 61215 và báo cáo kỹ thuật IEA-PVPS [3], hệ số nhiệt độ công suất (Temperature Coefficient of Power γ) của pin silicon tinh thể dao động từ $-0,30\%$ đến $-0,50\%/^{\circ}\text{C}$ khi nhiệt độ cell vượt mốc STC (25°C). Vào các ngày nắng gắt mùa hè bang Victoria, nhiệt độ bề mặt ô pin (T_{cell}) có thể tăng vọt lên tới $65 - 72^{\circ}\text{C}$, làm sụt giảm **12–20%** công suất đỉnh chủ yếu do suy giảm điện áp hở mạch (V_{oc}) [1]. Nhiệt độ vượt ngưỡng $85 - 90^{\circ}\text{C}$ có thể gây ra hiện tượng điểm nóng (Hot-spots), dẫn đến suy thoái vĩnh viễn mối hàn và lớp bọc EVA.
4. **Nhiều Cảm biến và Dòng điện Rò Ban đêm (Sensor Drift & Night Leakage):** Theo nghiên cứu thuật toán phát hiện ngoại lai quang điện của Li và cộng sự (2025) [4], hiện tượng rò rỉ dòng điện ngược (Reverse Current) từ lưới điện vào ban đêm hoặc cảm biến biến dòng (CT) bị trôi mốc 0 (Zero-drift fault) sinh ra các giá trị sản lượng dương giả mạo ($0 < E \leq 0,025 \text{ kWh}$) trong khoảng thời gian không có bức xạ mặt trời ($GHI = 0$). Ngoài ra, các xung nhiễu điện áp lưới (Voltage spikes) hoặc gián đoạn đường truyền viễn thông (Telemetry dropouts) tạo nên các đỉnh xung sản lượng vượt trần công suất thiết kế cực đại ($P > 1,2 \cdot P_{\text{stc}}$) hoặc các bước nhảy đột biến giữa các chu kỳ 15 phút kế cận [1, 4].


Khung Thuật toán Phân lớp Lai GMM–IF và Rào chắn Vật lý

Dữ liệu chuỗi thời gian quang điện có tính phi tuyến và phân phối đa đỉnh (Multi-modal) biến động theo thời tiết, khiến các phương pháp thống kê toàn cục kinh điển (như 3σ hay Boxplot IQR truyền thống [7]) dễ nhận diện nhầm dữ liệu bình thường của ngày âm u thành ngoại lai. Nhằm khắc phục hạn chế này, nhóm mở rộng khung nghiên cứu của Li và cộng sự [4] trên tạp chí *IEEE Access*, thiết lập mô hình lai phân lớp 3 tầng trong `srcs/02_transform/02_generate_outliers/02_gmm_if.py`:

- **Tầng 1 – Phân đoạn Cây quyết định (Decision Tree Segmentation):** Sử dụng cây hồi quy quyết định để chia dữ liệu của từng trạm phát thành 19 đến 29 vùng vận hành lá (Leaf segments) dựa trên bức xạ sóng ngắn, nhiệt độ và mốc thời gian. Mỗi phân đoạn tạo thành một vùng dữ liệu cục bộ tương đối đồng nhất có phân phối xấp xỉ Gauss (hệ số R^2 trung bình đạt 0,758).
- **Tầng 2 – Ước lượng Mật độ Hỗn hợp Gauss (GMM) [6]:** Trong từng phân đoạn lá, huấn luyện mô hình GMM 2 thành phần ($M = 2$) để đo lường mật độ xác suất $p(x)$. Các điểm dữ liệu nằm ở vùng mật độ cực thấp ($P_{\text{GMM}} < 0,02$) bị gắn nhãn ứng viên ngoại lai theo góc nhìn phân phối xác suất.
- **Tầng 3 – Rừng cô lập (Isolation Forest – IF) [5]:** Khởi tạo 100 cây ngẫu nhiên để đo lường số nhát cắt cần thiết nhằm cô lập điểm dữ liệu khỏi đám đông với tham số `contamination = 3%`.
- **Cơ chế Hợp nhất Đồng thuận (Fusion Consensus $\text{GMM} \wedge \text{IF}$):** Một điểm dữ liệu chỉ được gắn cờ dị thường máy học khi cả GMM và IF cùng đồng thuận:

$$\text{Flag}_{\text{ML}} = \text{Flag}_{\text{GMM}} \wedge \text{Flag}_{\text{IF}} \quad (4.1)$$

Phép giao logic này giúp triệt tiêu phần lớn các cảnh báo giả (False Positives) của từng mô hình riêng lẻ (chỉ số tương đồng Jaccard giữa hai thuật toán đạt từ 6,4% đến 16,7%).



Hình 4.1: Kiến trúc mô hình phân lớp lai GMM–IF và quy trình nạp cờ an toàn.

Hệ thống Danh mục Mã Lý do Ngoại lai (gmm_if_outlier_reason)

Để phục vụ cho hệ thống giám sát và bảo trì cảnh báo trên Dashboard Tableau, mỗi bản ghi bị gắn cờ được gán một mã nguyên nhân cụ thể thông qua hàm `explain_outlier_row()` trong `02_gmm_if.py`. Chi tiết 6 mã lý do kỹ thuật được chuẩn hóa tại Bảng 4.2:

Mã Định danh Lý do	Định nghĩa Kỹ thuật	Ý nghĩa Nghiệp vụ & Chẩn đoán
GMM_IF_CONSENSUS	$\text{Flag}_{\text{GMM}} = \text{true}$ và $\text{Flag}_{\text{IF}} = \text{true}$ (Phép giao đồng thuận).	Bất thường đồng thời về mặt mật độ xác suất cục bộ và không gian phân tách toàn cục; cần kiểm tra cảm biến hoặc trạng thái vận hành trạm.
PHYSICAL_OVER_CAPACITY	Sản lượng 15 phút vượt trần công suất lắp đặt: $E > \text{capacity_kw} \times 0,25$.	Đỉnh phát điện vượt quá công suất định mức cực đại của dàn PV; cảnh báo xung điện lưới, lỗi telemetry hoặc sai lệch siêu dữ liệu trạm.
PHYSICAL_HIGH_ENERGY_NO_SUN	$\text{shortwave_radiation} \leq 25 \text{ W/m}^2$, $\text{sunshine} \leq 60\text{s}$, nhưng $E \geq \max(1.0, 0,20 \cdot P_{\text{stc}})$.	Sản lượng điện cao trong điều kiện trời tối hoàn toàn; mâu thuẫn vật lý cảnh báo sự cố rò rỉ điện ban đêm (Night Leakage) hoặc dòng rò ngược.
PHYSICAL_HIGH_ENERGY_LOW_RAD	$\text{shortwave_radiation} \leq 50 \text{ W/m}^2$, $E \geq \max(1.0, 0,20 \cdot P_{\text{stc}})$, và $E > Q_3 + 4 \cdot \text{IQR}$.	Sản lượng cao bất thường khi bức xạ mặt trời rất yếu; vi phạm ngưỡng phân phối thống kê đuôi sâu của nhóm bức xạ tương ứng.
PHYSICAL_LOW_ENERGY_STRONG_SUN	$\text{shortwave_radiation} \geq 700 \text{ W/m}^2$, $\text{sunshine} \geq 3000\text{s}$, $E \leq 0,05 \cdot P_{95}$ và $E \leq Q_1 - 2 \cdot \text{IQR}$.	Mất phát hoặc sụt giảm sản lượng nghiêm trọng trong điều kiện nắng cực đại; cảnh báo sự cố ngắt Inverter, hỏng diode bypass hoặc che bóng diện rộng.
PHYSICAL_DISTRIBUTION_JUMP	Bỏ qua giờ chuyển tiếp (05h, 06h, 18h). $ E - E_{\text{neighbor}} \geq \max(0,15 \cdot P_{95}, 1.0)$ và $E \notin [Q_1 - 4\text{IQR}, Q_3 + 4\text{IQR}]$.	Bước nhảy hoặc sụt giảm công suất cục bộ đột ngột so với diễn biến 2 giờ xung quanh; cảnh báo hiện tượng spike tín hiệu hoặc dropout truyền thông tin.

Bảng 4.2: Danh mục mã ngoại lai GMM-IF và ý nghĩa chẩn đoán.

Khi một bản ghi vi phạm đồng thời nhiều điều kiện, các mã lý do được nối với nhau bằng dấu cộng (Ví dụ: `GMM_IF_CONSENSUS+PHYSICAL_DISTRIBUTION_JUMP`), hỗ trợ kỹ sư vận hành phân rã đa tầng nguyên nhân sự cố.

Quy trình Đẩy Cờ An toàn 4 Bước vào Kho Dữ liệu Supabase

Để cập nhật cờ ngoại lai lên Supabase DWH mà không làm gián đoạn hệ thống và đảm bảo tính toàn vẹn giao dịch (ACID compliance), nhóm xây dựng pipeline 4 bước trong mã nguồn `srcs/02_transform/02_run_apply_outlier_flags.py`:

1. **Xác thực nguồn dữ liệu (Source Verification Check):** Trước khi ghi dữ liệu, hàm `fingerprint_supabase()` tiến hành đối chiếu cấu trúc vân tay dữ liệu giữa tệp kết quả phân tích ngoại lai và bảng sự kiện `fact_solar_energy_gen` trên Supabase.

Quy trình kiểm tra tính toán tổng băm MD5 của chuỗi khóa ghép (`sitekey|timestamp`), tổng sản lượng năng lượng (`energy_sum`) với sai số cho phép $\leq 0,01$, và tổng số dòng dữ liệu. Bước này đảm bảo dữ liệu chạy cờ ngoại lai và dữ liệu trên cơ sở dữ liệu hoàn toàn đồng nhất về cấu trúc cột và số lượng dòng (2.731.946 dòng), ngăn ngừa lỗi lệch dòng (Data Shift).

2. **Nạp danh sách ứng viên (Sparse Candidate Upload):** Thay vì tải lên lại toàn bộ 2,73 triệu dòng dữ liệu (rất chậm và dễ gây nghẽn mạng), thuật toán chỉ lọc ra 33.280 bản ghi bị gắn cờ ngoại lai thực sự (`gmm_if_outlier_flag = true`). Danh sách ứng viên này được đẩy vào bảng tạm trung gian: `staging.temp_gmm_if_outlier_flags`.

3. **Kiểm tra tính toàn vẹn khóa ngoại (Referential Check):** Thực hiện truy vấn kiểm tra chéo (Anti-Join) để đảm bảo toàn bộ các khóa trong bảng tạm đều tồn tại khớp 1:1 trong bảng sự kiện chính. Kết quả trả về 0 dòng lỗi trước khi tiến hành cập nhật.

4. **Cập nhật giao dịch hàng loạt (Bulk Join Update):** Tiến trình mở một khối giao dịch an toàn trên cơ sở dữ liệu, thực hiện gán toàn bộ cờ `gmm_if_outlier_flag = false` cho cả bảng sự kiện chính (2.731.946 dòng), sau đó thực hiện lệnh cập nhật `UPDATE ... FROM ... WHERE` nối bảng tạm với bảng chính theo khóa trùng khớp (`sitekey, timestamp`) để chuyển 33.280 dòng ngoại lai sang trạng thái `true` kèm mã lý do tương ứng.

Dưới đây là một phần mã nguồn Python thực hiện so sánh đối chiếu vân tay (Fingerprint) dữ liệu trích từ `srcs/02_transform/02_run_apply_outlier_flags.py`:

Listing 4.6: Mã nguồn Python kiểm tra vân tay dữ liệu (Fingerprint) trước khi cập nhật

```

1 def fingerprint_supabase(conn: any) -> dict[str, object]:
2     cur = conn.cursor()
3     try:
4         cur.execute(
5             f"""
6             SELECT
7                 COUNT(*)::bigint AS rows,
8                 COUNT(DISTINCT sitekey)::bigint AS sites,
9                 MIN(to_char(
10                    timestamp, 'YYYY-MM-DD HH24:MI:SS'
11                )),
12                 MAX(to_char(

```

```

13         timestamp, 'YYYY-MM-DD HH24:MI:SS'
14     )),
15     SUM(
16         energy_generated_kwh::numeric
17     ) AS energy_sum,
18     SUM(
19         ('x' || substr(
20             md5(sitekey::text || '|' ||
21             to_char(
22                 timestamp,
23                 'YYYY-MM-DD HH24:MI:SS'
24             )),
25             1, 15
26         ))::bit(60)::bigint
27     )::numeric AS key_checksum
28 FROM {qname(SCHEMA, SOURCE_FACT_TABLE)}
29 ""
30 )
31 row = cur.fetchone()
32 return {
33     "rows": int(row[0]),
34     "distinct_sitekeys": int(row[1]),
35     "min_timestamp": row[2],
36     "max_timestamp": row[3],
37     "energy_sum": Decimal(str(row[4] or 0)),
38     "key_checksum": Decimal(str(row[5] or 0)),
39 }
40 finally:
41     cur.close()

```

Kết quả Phân bổ và Đánh giá Kiểm toán Không Giám sát

Vì đây là bài toán học máy không giám sát trên dữ liệu chuỗi thời gian thực tế không có nhãn sự cố thủ công từ người vận hành, hệ thống không thể sử dụng các chỉ số giả định như Accuracy, Precision hay Recall. Thay vào đó, chất lượng của bộ phát hiện ngoại lai được kiểm chứng thông qua bộ 4 chỉ số kiểm toán khoa học:

- **Độ hội tụ mô hình GMM:** Đạt **100%** trên toàn bộ 42 trạm phát (toàn bộ các phân đoạn lá cây quyết định đều hội tụ thuật toán EM thành công, không có segment nào bị lỗi fit).
- **Kiểm soát tỷ lệ nhiễu IF:** Isolation Forest giữ đúng tham số contamination xấp xỉ **3%** trên từng trạm phát.
- **Chất lượng phân đoạn cây quyết định (R^2):** Hệ số R^2 đạt trung bình **0,758** (thấp nhất 0,606, cao nhất 0,826), chứng minh các vùng phân đoạn mô phỏng chính xác cấu trúc hình dạng phát điện của trạm.

- **Tổng số lượng bản ghi gắn cờ ngoại lai:** Toàn bộ pipeline đã gắn cờ thành công **33.280** dòng trên tổng số **2.731.946** dòng dữ liệu, tương ứng với tỷ lệ ngoại lai được kiểm soát ở mức lý tưởng **1,22%**.

4.4 Biến đổi và Trích xuất Đặc trưng (trích xuất đặc trưng nghiệp vụ)

Sau khi dữ liệu sản lượng và thời tiết được làm sạch tại tầng kho dữ liệu, tiến trình thực hiện tính toán biến đổi cấu trúc để chuẩn bị dữ liệu đầu vào tối ưu cho mô hình dự báo học máy.

4.4.1 Giải quyết độ lệch tần suất ghi nhận (Granularity Alignment)

Một thách thức lớn trong dữ liệu của dự án là độ lệch tần suất (Lệch pha độ phân giải thời gian) giữa hai nguồn thông tin nghiệp vụ:

- Dữ liệu sản lượng điện được ghi nhận với tần suất cao (15 phút một dòng).
- Dữ liệu khí tượng viễn thám chỉ có sẵn theo chu kỳ giờ (60 phút một dòng).

Để giải quyết sự lệch pha này mà không làm mất mát thông tin xu hướng của bức xạ mặt trời, nhóm thiết lập thuật toán gom cụm (Aggregation) đưa dữ liệu về cùng chu kỳ giờ (1-hour grain). Chỉ số sản lượng điện mặt trời `energy_generated_kwh` trong 4 chu kỳ 15 phút của cùng một giờ được tính tổng cộng dồn (Sum Aggregation):

$$E_{\text{hour}} = \sum_{i=1}^4 E_{15\text{min},i} \quad (4.2)$$

Trong khi đó, các biến thời tiết đại diện cho giờ đó được giữ nguyên giá trị trung bình giờ. Thuật toán ghép nối sử dụng hàm kết hợp chính xác mốc thời gian chẵn giờ, giúp tạo ra một bảng dữ liệu phẳng góc nhìn rộng (Wide-table) thống nhất, đảm bảo tính liên kết chặt chẽ và không có dữ liệu rò rỉ thời gian (Data Leakage).

4.4.2 Trích xuất các đặc trưng thời gian và lịch trình học tập

Điện năng mặt trời mang tính chu kỳ tự nhiên rất mạnh phụ thuộc vào quỹ đạo chuyển động của Trái Đất. Dự án tiến hành trích xuất các đặc trưng thời gian đa tầng từ trường mốc thời gian `timestamp`:

- **Đặc trưng giờ trong ngày (Hour):** Giá trị từ 0 đến 23, xác định góc chiếu mặt trời.
- **Đặc trưng tháng trong năm (Month):** Xác định tính mùa vụ thời tiết (Mùa hè bức xạ cao, mùa đông bức xạ thấp ở Nam bán cầu).
- **Đặc trưng ngày trong tuần (Day of Week):** Hỗ trợ phân tích hành vi tiêu thụ điện năng tại các khu học xá (Campus).

Đặc biệt, nhóm tích hợp thành công dữ liệu lịch học tập (`calendar.csv`) của cơ sở đào tạo thông qua ba đặc trưng nhị phân:

- `is_holiday`: Đánh dấu các ngày nghỉ lễ quốc gia hoặc ngày nghỉ nội bộ.
- `is_semester`: Đánh dấu thời điểm đang trong học kỳ chính thức (nhu cầu sử dụng thiết bị điện cao đột biến).
- `is_exam`: Đánh dấu giai đoạn thi cử tập trung.

Sự kết hợp các thuộc tính lịch trình này giúp mô hình học máy phân biệt rõ rệt giữa biến động sản lượng do thời tiết tự nhiên và biến động tiêu thụ do hành vi con người gây ra, cải thiện độ chính xác dự báo sản lượng thực dùng tại các điểm nút phụ tải trạm.


Trực quan Dữ liệu và Xây dựng Dashboard

5.1 Chiến lược Kết nối Dữ liệu và Thiết kế UI/UX

Trực quan hóa dữ liệu là cầu nối cốt lõi chuyển hóa các kết quả phân tích phức tạp từ hệ thống kho dữ liệu thành tri thức hành động (Khuyến nghị Hành động Thực tiễn) cho doanh nghiệp. Theo tinh thần chỉ đạo chuyên môn “Không có câu hỏi → Không có phân tích” và “Đừng chỉ mô tả → Phải giải thích”, hệ thống Dashboard trên nền tảng Tableau được thiết kế theo tư duy tiếp cận từ trên xuống (tiếp cận từ tổng quan đến chi tiết), đáp ứng đa dạng nhu cầu của hai nhóm người dùng trọng yếu: Ban Giám đốc quản lý và Đội ngũ Kỹ sư Vận hành & Bảo trì (O&M).

5.1.1 Quy trình Thiết lập Kết nối PostgreSQL Trực tiếp từ Supabase

Để khai thác dữ liệu trực tiếp từ Kho dữ liệu đám mây (Kho dữ liệu đám mây), hệ thống Tableau Desktop sử dụng trình kết nối gốc PostgreSQL (trình kết nối PostgreSQL trực tiếp). Cơ chế này thiết lập đường truyền dữ liệu thời gian thực có mã hóa bảo mật TLS/SSL tới cơ sở dữ liệu Supabase lưu trữ trên hạ tầng AWS (khu vực Đông Nam Á ap-southeast-1).



The screenshot shows the 'PostgreSQL' connection window in Tableau. The 'General' tab is selected. The configuration details are as follows:

Field	Value
Server	aws-1-ap-southeast-1.pooler.supabase.com
Port	5432
Database	postgres
Authentication	Username and Password
Username	tableau_user.gocnjdtutobgalyqomwz
Password	Optional
Require SSL	☐

A 'Sign In' button is located at the bottom right of the window.

Hình 5.1: Cấu hình kết nối PostgreSQL từ Tableau tới Supabase.

Thông số cấu hình kết nối chi tiết giữa Tableau và hệ cơ sở dữ liệu PostgreSQL của dự án được chuẩn hóa như trong Bảng 5.1:

Tham số Kết nối	Giá trị Cấu hình	Ý nghĩa Kỹ thuật & Bảo mật
Connector Type	PostgreSQL	Trình kết nối hiệu năng cao tối ưu hóa riêng cho PostgreSQL/Tableau.
Server / Host	aws-1-ap-southeast-1.pooler.supabase.com	Cổng Supabase Connection Pooler (AWS Singapore) giúp duy trì kết nối ổn định và tái sử dụng connection pool.
Port	5432 / 6543	Cổng 5432 (Session Mode) dành cho tiến trình Python ETL backend; cổng 6543 (Transaction Mode Pooler) dành cho Tableau Desktop.
Database	postgres	Cơ sở dữ liệu đích chứa các schema bi_mart , gold , dim .
Authentication	Username and Password	Xác thực danh tính người dùng bằng phương thức mã hóa định danh.
Username	tableau_user.gocnjdtutobgalyqomwz	Tài khoản dịch vụ chuyên dụng (Dedicated Service Account) được phân quyền Read-only tối thiểu (Principle of Least Privilege) trên schema bi_mart .
Encryption	Require SSL / TLS	Bắt buộc mã hóa toàn bộ luồng truyền tải dữ liệu giữa máy trạm BI và máy chủ Supabase.

Bảng 5.1: Thông số kết nối PostgreSQL từ Tableau tới Supabase.

Việc sử dụng cổng Pooler kết hợp tài khoản dịch vụ phân quyền độc lập mang lại 3 ưu điểm kỹ thuật:

- Khả năng Chịu tải Cao (Concurrency Handling):** Cơ chế Connection Pooling tự động điều phối hàng trăm truy vấn phân tích song song từ các Dashboard mà không làm tràn bộ nhớ RAM của cụm máy chủ Supabase.
- Bảo mật Dữ liệu Nghiêm ngặt (Least Privilege):** Tài khoản **tableau_user** chỉ được cấp quyền SELECT trên tầng BI Mart và các bảng Dimension, ngăn chặn hoàn toàn rủi ro can thiệp thay đổi cấu trúc bảng hoặc ghi đè dữ liệu.
- Độ trễ Truy vấn Cực thấp (Low Latency):** Cụm máy chủ đặt tại Datacenter Singapore (ap-southeast-1) đảm bảo thời gian phản hồi truy vấn dưới 1,5 giây cho mọi thao tác lọc tương tác từ Việt Nam.

5.1.2 Mô hình Kết nối Dữ liệu Tầng BI Mart và Tableau Relationships

Để đảm bảo tốc độ phản hồi tính toán thời gian thực trên Tableau mà không gây quá tải cho hệ quản trị cơ sở dữ liệu Supabase PostgreSQL, dự án không thực hiện truy vấn trực tiếp trên các bảng sự kiện thô 2,7 triệu dòng. Thay vào đó, hệ thống Tableau kết nối trực tiếp với tầng BI Mart đã được tối ưu hóa sẵn thông qua hai Materialized Views lõi:

- `bi_mart.mv_bi_mart_hourly_measures`: Lưu trữ toàn bộ các đo lường chi tiết theo từng giờ của 42 trạm phát, bao gồm sản lượng thực tế (`e_hourly`), sản lượng chuẩn STC (`e_stc_hourly`), sản lượng kỳ vọng hiệu chỉnh nhiệt (`e_expected`), hệ số hiệu suất (`pr_actual`, `pr_adjusted`), suy hao do nhiệt (`loss_temp`), nhiệt độ ô pin (`t_cell`), cùng các cờ báo động ngoại lai GMM-IF (`gmm_if_outlier_flag`).
- `bi_mart.mv_bi_mart_daily_kpis`: Lưu trữ các chỉ số tổng hợp cấp ngày, tích hợp sẵn các chỉ số lũy kế theo tuần (`wtd_energy`), tháng (`mtd_energy`), năm (`ytd_energy`), doanh thu ước tính (`daily_revenue`), chi phí tổn thất do thiếu hụt công suất (`cost_of_underperformance`), và lượng phát thải khí nhà kính giảm thiểu (`daily_co2_avoided`).

Các Materialized Views này kết nối logic với hệ thống các bảng chiều (`dim_solar_site`, `dim_geography`, `dim_date`, `dim_weather_type`) thông qua mô hình liên kết Tableau Relationships (1-N). Mô hình này bảo toàn ngữ cảnh phân tích đa chiều mà không làm nhân bản dòng dữ liệu (Fan-out problem), tối ưu hóa tốc độ tải trang dưới 2 giây cho mọi thao tác tương tác lọc và khoan sâu (Drill-down).

5.1.3 Bảng màu Ngữ nghĩa và Nguyên tắc Thiết kế UI/UX

Giao diện hệ thống Dashboard trên Tableau được thiết kế theo tư duy hiện đại, tối giản (Minimalist & Clean Layout) nhằm tối đa hóa tỷ số dữ liệu trên mực in (Data-Ink Ratio) và tuân thủ các quy luật nhận thức thị giác Gestalt. Toàn bộ hệ màu được chuẩn hóa theo cấu hình giao diện `tableau_theme.json` và ánh xạ trực tiếp từ tệp Workbook `main_fixed_01.twb`, đảm bảo độ tương phản cao ($\geq 4.5 : 1$) theo tiêu chuẩn WCAG 2.1 AA.

Hệ thống Bảng màu Đồng bộ (Color Palette System)

Nhằm phân biệt rõ ràng giữa các luồng thông tin vận hành và trạng thái kỹ thuật, hệ màu trong Dashboard được chia thành 3 phân nhóm chức năng: Bảng màu Chủ đạo (Primary), Bảng màu Cảnh báo Ngữ nghĩa (Semantic Alert), và Dải màu Tuần tự cho Heatmap (Sequential Palette).

Nhóm chức năng	Tên màu & Mã Hex	Mẫu màu	Chỉ số & Thành phần Ứng dụng trong Workbook
Bảng màu Chủ đạo	Classic Blue (#4E79A7)		BANs sản lượng, đường xu hướng sản lượng thực tế (e_{hourly}), thanh Header.
	Solar Orange (#F28E2B)		Bức xạ sóng ngắn (shortwave_radiation), nhiệt độ môi trường, đường nhiệt ô pin.
	Eco Green (#59A14F)		Hệ số công suất (Capacity Factor CF), thanh sản lượng lũy kế WTD/MT-D/YTD.
Cảnh báo Ngữ nghĩa	Active/Success (#59A14F)		Trạng thái tối ưu: $PR \geq 75\%$, tỷ lệ hoàn thành kế hoạch Yield Ratio $\geq 100\%$.
	Warning (#EDC948)		Cảnh báo suy giảm nhẹ ($50\% \leq PR < 75\%$), nhiệt độ ô pin vượt ngưỡng tối ưu 25°C .
	Danger/Outlier (#E15759)		Đánh dấu cờ bất thường GMM-IF, vết rò rỉ điện ban đêm ($E > 0$), sụt giảm nặng.
	Adjusted/Ref (#76B7B2)		Đường hiệu suất hiệu chỉnh nhiệt ($PR_{adjusted}$), sản lượng kỳ vọng ($E_{expected}$).
Dải màu Phân tích	Sequential Heatmap		Dải màu orange_10_0 chuyển từ Vàng nhạt (#F9E9E0) sang Đỏ (#E15759) trên Heatmap.
	Neutral Gray (#79706E)		Đường chuẩn tham chiếu (Reference Lines), trục tọa độ, nhãn thông số phụ trợ.

Bảng 5.2: Quy chuẩn bảng màu trong Tableau Workbook main_fixed_01.twb.

Nguyên tắc Bố cục Thị giác và Cấu trúc Khung Thẻ (Card-Based Container Layout)

Bên cạnh hệ thống màu sắc, trải nghiệm tương tác trên Dashboard được tối ưu hóa thông qua các nguyên tắc thiết kế:

- **Cấu trúc Phân tầng F-Pattern:** Mắt người dùng tự nhiên quét từ góc trên bên trái sang phải và xuống dưới. Do đó, các thẻ chỉ số cốt lõi (BANs) như KPI total gen, AVG CF, KPI PR được đặt tại dải trên cùng (Top Banner) với kích thước chữ lớn (18–24pt) để người quản lý nắm bắt nhanh tình trạng hệ thống chỉ trong vài giây đầu tiên.
- **Bố cục Khung Thẻ Phân Khu (Card-Based Container Layout):** Bố cục trực quan của dự án sử dụng các khung thẻ container riêng biệt có viền xám nhẹ thanh lịch (#E2E8F0) trên nền sáng để nhóm các thành phần phân tích có liên quan về mặt logic (Khối thẻ KPI tổng hợp, Khối phân bố địa lý theo khuôn viên, Khối biểu đồ chuỗi thời gian sản lượng, Khối ma trận nhiệt tổn thất và Bảng xếp hạng thiết bị biến tần). Việc phân định bằng khung viền thẻ giúp người dùng dễ dàng định vị các vùng thông tin chức năng mà không bị rối mắt.

- **Tối ưu hóa Tỷ lệ Mục Thông tin (Data-Ink Ratio):** Bên trong mỗi thẻ biểu đồ, các đường lưới phụ (minor gridlines) được làm mờ hoặc loại bỏ, chỉ giữ lại các mốc tọa độ chính yếu và đường gốc (Zero-line) với tông màu xám rất nhạt (#E0E0E0), giúp mắt người xem tập trung tối đa vào hình dáng biến thiên của đường cong sản lượng và các điểm dị thường nổi bật.
- **Đồng bộ Bộ lọc Toàn cục (Synchronized Global Filtering):** Toàn bộ bộ lọc theo Trạm (Site Name), Khoảng thời gian (Date Range), và Loại thời tiết (Weather Type) được bố trí gọn gàng tại bảng điều khiển bên phải (Right-panel) dưới dạng Dropdown, tự động đồng bộ hóa trên toàn bộ 3 Dashboard.

5.1.4 Các Trường Tính toán Nghiệp vụ Bổ sung trên Tableau (Calculated Fields)

Để đáp ứng các yêu cầu phân tích kinh doanh đa chiều và các biểu đồ trực quan động trên Tableau, nhóm đã thiết lập một hệ sinh thái các Trường tính toán (Calculated Fields) chuyên sâu trong tệp tin `main_fixed_01.twb`. Bảng 5.3 tổng hợp các công thức tính toán nghiệp vụ cốt lõi:

Tên Trường	Công thức Tableau	Ý nghĩa Nghiệp vụ
[PR Actual]	<code>SUM(IF [shortwave_radiation] >= 100 AND [p_stc] > 0 THEN [e_hourly] END) / SUM(IF [shortwave_radiation] >= 100 AND [p_stc] > 0 THEN [capacity_kw] * ([shortwave_radiation] / 1000.0) END)</code>	Tính toán Hệ số Hiệu suất (PR) thực tế có điều kiện, loại bỏ các khoảng thời gian bức xạ yếu dưới 100 W/m ² khi biến tần chưa phát điện.
[Weighted CF Trend]	<code>SUM([e_hourly]) / SUM([p_stc])</code>	Hệ số công suất gia quyền theo tổng quy mô lắp đặt, phản ánh mức độ huy động công suất thực tế của toàn trạm.
[Number of Inverter]	<code>IF CONTAINS(LOWER([inverter]), 'x') THEN INT(TRIM(SPLIT(LOWER([inverter]), 'x', 1))) ELSE 1 END</code>	Tách số lượng biến tần từ chuỗi văn bản kỹ thuật (ví dụ: 2x Fronius Symo 20.0).
[kWh/inverter]	<code>[e_hourly] / [Number of Inverter]</code>	Sản lượng chuẩn hóa trên mỗi đầu biến tần, hỗ trợ so sánh hiệu quả giữa các dòng thiết bị.
[kWh/panel]	<code>[e_hourly] / [number_of_panels]</code>	Sản lượng trung bình trên mỗi tấm pin, hỗ trợ nhận diện các chuỗi pin bị che bóng hoặc suy thoái.
[Outlier Hours SM/PM]	<code>SUM(IF MONTH([full_date]) = [Param Month] AND [gmm_if_outlier_flag] = TRUE THEN 1 ELSE 0 END)</code>	Tính tổng số giờ xuất hiện dị thường trong tháng được chọn (SM) và tháng liền kề trước đó (PM).
[Outlier Hours MoM %]	<code>(([Outlier Hours SM] - [Outlier Hours PM]) / ZN([Outlier Hours PM]))</code>	Tốc độ tăng trưởng số giờ dị thường theo tháng (Month-over-Month), phản ánh mức độ gia tăng sự cố vận hành.
[Outlier MoM % (Up/Down)]	<code>IF [Outlier Hours MoM %] > 0 THEN [Outlier Hours MoM %] END</code>	Phân nhánh điều kiện để gán màu trực quan (màu đỏ khi sự cố tăng, màu xanh khi sự cố giảm) trên thẻ KPI.


Bảng 5.3: Tổng hợp các trường tính toán nghiệp vụ trên Tableau.

5.2 Chi tiết Hệ thống Dashboard Phân tích

Hệ thống trực quan hóa của dự án được đóng gói hoàn chỉnh trong tệp tin Tableau Workbook `reports/dashboards/main_fixed_01.twb`, bao gồm 3 Dashboard chuyên biệt được kết nối chặt chẽ theo luồng phân tích nguyên nhân - kết quả.

5.2.1 Dashboard 1: Executive Overview (Tổng quan Vận hành)

Dashboard *Executive Overview* đóng vai trò là trung tâm chỉ huy dành cho Ban Giám đốc và các nhà quản lý dự án, cung cấp bức tranh toàn cảnh về sản lượng, doanh thu và sức khỏe vận hành của toàn bộ 42 trạm điện mặt trời tại Úc.



Hình 5.2: Giao diện Dashboard 1: Tổng quan điều hành (Executive Overview).

Các thành phần giao diện và chỉ số phân tích chính bao gồm:

a. Thẻ Chỉ số Cốt lõi (BANs Layer):

- **KPI total gen:** Hiện thị tổng sản lượng điện phát lũy kế (E_{actual}) tính bằng MWh/GWh, tích hợp so sánh tốc độ tăng trưởng MoM/YoY.
- **AVG CF:** Hệ số công suất khai thác trung bình ($Capacity\ Factor = \sum E / (P_{stc} \cdot 24)$).
- **KPI PR & PR adjust:** Chỉ số hiệu suất thực tế (PR_{actual}) và chỉ số hiệu suất đã hiệu chỉnh nhiệt độ ($PR_{adjusted}$).
- **KPI Co2 avoided & Sunshine dur:** Tổng khối lượng khí thải CO₂ triệt tiêu (kg), số cây xanh tương đương được trồng mới và tổng thời lượng nắng tích tụ trong kỳ.

b. Bản đồ Địa lý Phân bố Trạm (Campus Map):


Trực quan hóa vị trí địa lý thực tế của 42 trạm PV tại các cơ sở đào tạo (Campus). Kích thước hình tròn (Symbol size) đại diện cho công suất

thiết kế (P_{stc} tính bằng kWp), trong khi màu sắc (Color gradient) phản ánh trực tiếp hệ số công suất CF. Nhờ đó, người quản lý lập tức nhận diện được các vùng địa lý có hiệu suất khai thác kém bất thường.

- c. **Ma trận Hiệu suất Trạm (Site Performance Matrix & Consistency):** Biểu đồ xếp hạng phân bổ sản lượng ($gen/panel$) và độ ổn định vận hành giữa 42 trạm. Hệ thống trực quan hóa sự chênh lệch sản lượng trên từng tấm pin, giúp phát hiện các trạm đang hoạt động dưới mức tiềm năng thiết kế.
- d. **Xu hướng Sản lượng Tổng hợp (Total Generation & Trend):** Biểu đồ đường/miền (Line/Area Chart) thể hiện sự biến đổi sản lượng theo thời gian (ngày, tháng) kết hợp phân tích đóng góp sản lượng theo từng chủng loại tấm pin (Panel Brands/Models).

5.2.2 Dashboard 2: Operational Efficiency & Loss Analysis (Hiệu suất Vận hành & Phân rã Tổn thất)

Dashboard *Efficiency & Loss* được thiết kế dành riêng cho đội ngũ kỹ sư kỹ thuật năng lượng nhằm “giải thích” nguyên nhân gốc rễ gây sụt giảm sản lượng, đặc biệt là hiện tượng suy hao do nhiệt độ (Thermal Degradation) và hiệu suất biến tần (Inverter/Optimizer).



Hình 5.3: Giao diện Dashboard 2: Hiệu suất và tổn thất vận hành.

Các phân tích kỹ thuật trên Dashboard bao gồm:


- a. **Đồ thị Xu hướng Tổn thất Nhiệt (Generation & Loss Trend):** Sử dụng biểu đồ 2 trục tọa độ độc lập (Dual-Axis Chart) kết hợp giữa Sản lượng điện thực tế (e_{hourly}), Bức xạ sóng ngắn mặt trời ($shortwave_radiation$) và Nhiệt độ ô pin (T_{cell}). Biểu đồ chứng minh luận điểm kỹ thuật quan trọng: Vào các khung giờ giữa trưa khi bức xạ đạt đỉnh cực đại ($> 800 W/m^2$), nhiệt

độ ô pin tăng cao vượt quá 45°C làm đường cong sản lượng bị chững lại hoặc suy giảm đáng kể so với mức lý thuyết.

- b. **Lưới Nhiệt Suy hao Nhiệt độ (Temperature Loss Heatmap & Loss by Month):** Bản đồ nhiệt (Heatmap) thể hiện tỷ lệ tổn thất nhiệt độ trung bình (avg_loss_temp) phân rã theo 12 tháng trong năm và theo từng trạm phát. Dải màu chuyển từ Vàng nhạt (tổn thất < 3%) sang Đỏ thẫm (tổn thất > 8%), chỉ ra chính xác các tháng mùa hè đỉnh điểm cần tăng cường giải pháp làm mát hoặc thông gió bề mặt pin.
- c. **Đánh giá Hiệu suất Thiết bị (Inverter & Optimizer Efficiency Rank):** Trực quan hóa chỉ số sản lượng trung bình trên mỗi tấm pin ($kWh/panel$) và tỷ lệ đáp ứng sản lượng kỳ vọng ($Yield\ ratio = E_{actual}/E_{expected}$) phân loại theo các hãng chế tạo Inverter và Optimizer. Phân tích này hỗ trợ đội ngũ bảo trì đánh giá chất lượng thiết bị vật lý thực tế để đưa ra quyết định thay thế hoặc bảo hành linh kiện.

5.2.3 Dashboard 3: Anomaly Detection & Predictive Maintenance (Giám sát Bất thường & Bảo trì Cảnh báo)

Dashboard *Anomaly Detection* đóng vai trò là hệ thống cảnh báo sớm (Early Warning System) cho đội ngũ O&M, trực quan hóa toàn bộ các cờ bất thường được phát hiện từ mô hình học máy GMM-IF và thuật toán Rolling IQR.



Hình 5.4: Giao diện Dashboard 3: Giám sát dị thường và bảo trì dự đoán.

Các tính năng giám sát bất thường trọng tâm bao gồm:

- a. **Thẻ Thống kê Bất thường (Anomaly KPIs):** Hiển thị tổng số giờ phát hiện bất thường (KPI Outlier Hours), tỷ lệ phần trăm dữ liệu dị thường (KPI Outlier Rate), số lượng bản ghi

gắn cờ (number of outliers) và chỉ số biến động so với tháng trước (Outlier Rate MoM %).

- b. **Biểu đồ Chuỗi thời gian Phát hiện Dị thường (Time-series Outlier Detect):** Đồ thị chuỗi thời gian liên tục 15 phút biểu diễn sản lượng điện. Tất cả các mốc thời gian bị mô hình GMM-IF gắn cờ bất thường (`gmm_if_outlier_flag = true`) được đánh dấu bằng các điểm nút tròn màu Đỏ rực (#E15759) trên nền đường line sản lượng. Kỹ sư có thể nhấp chuột trực tiếp vào điểm dị thường để mở thẻ thông tin chi tiết (Tooltip) hiển thị lý do bất thường (`gmm_if_outlier_reason`).
- c. **Bản đồ Nhiệt Phát hiện Rò rỉ Điện Ban đêm (Outlier by Site Heatmap):** Bản đồ nhiệt 2 chiều với Trục tung đại diện cho 24 khung giờ trong ngày (0 – 23h) và Trục hoành đại diện cho 42 trạm phát.

Quy tắc trực quan hóa áp đặt điều kiện đặc biệt: Nếu trong khung giờ ban đêm từ 18:30 đến 05:30 xuất hiện giá trị sản lượng $E > 0$, ô tương ứng sẽ lập tức bị tô màu Đỏ đậm. Đây là bằng chứng trực quan trực tiếp phát hiện sự cố rò rỉ dòng điện ngược (Reverse Current) hoặc cảm biến đo đặc CT bị sai lệch mốc 0 (Zero-drift fault), giúp kỹ sư khoanh vùng vị trí sự cố ngay lập tức.
- d. **Chi tiết Cảnh báo Phân loại Lỗi (Outlier Type & Details):** Bảng thống kê chi tiết danh sách trạm và phân loại nhóm nguyên nhân dị thường (*Night Leakage, Extreme Power Spike, Sensor Freeze, Daytime Sudden Drop*), hỗ trợ lập danh mục ưu tiên cho các đội kỹ thuật đi kiểm tra hiện trường.

Xây dựng và Đánh giá Mô hình Học máy Dự báo Sản lượng

6.1 Tổng quan quy trình học máy

Mục này khoanh phạm vi qua năm bước: dữ liệu đầu vào, bài toán và hai tầm dự báo, nhãn ngoại lai kế thừa từ tầng ETL, sơ đồ toàn cảnh, và năm rào chắn chống rò rỉ.

6.1.1 Phạm vi và dữ liệu đầu vào

Phần này trình bày toàn bộ quy trình học máy của dự án, bắt đầu từ tệp dữ liệu đã làm sạch ở tầng ETL và kết thúc ở ứng dụng dự báo. Các bước trích xuất, biến đổi và nạp dữ liệu vào kho không thuộc phạm vi tài liệu này.

Bản trích tầng ETL bàn giao là tệp `data/mlmart_base/v4_preprocessing.parquet`, gồm 2.731.946 bản ghi ở độ phân giải 15 phút, thu thập từ 42 dàn quang điện đặt tại 5 khuôn viên của Đại học La Trobe, Úc. Mỗi bản ghi mang giá trị sản lượng của một dàn tại một mốc thời gian, kèm các biến khí tượng tương ứng lấy từ Open-Meteo. Không phải mọi giá trị đều là số đo gốc — cột `energy_source` phân biệt dòng đo thật với dòng đo tầng ETL điền khuyết, và Mục 2.1 trình bày tỷ lệ từng loại.

Bản trích này còn 26 cột mang ô khuyết, nên bước mở đầu của quy trình học máy là điền khuyết cho nhóm siêu dữ liệu và nhóm biến khí tượng. Siêu dữ liệu trạm được điền theo trung vị của khuôn viên đối với `capacity_kw` và `number_of_panels` (1.132.078 dòng, tức 41,44%), theo giá trị liên kê của chính trạm đối với `panel` và `inverter`, và theo hằng số quy ước đối với `optimizers` (1.259.007 dòng, tức 46,08%) cùng `site_metric`. Biến khí tượng được điền theo ba nấc nổi tiếp: gán 0 cho các mốc ban đêm, lấp tiến theo chính trạm với hạn mức từ một đến ba giờ, rồi mới dùng trung vị theo cặp (trạm, giờ). Hai cột chịu tác động lớn nhất là `cloud_cover_low` (846.973 dòng, 31,00%) và `wind_speed` (217.946 dòng, 7,98%); các cột khí tượng còn lại chỉ khuyết 218 ô. Mỗi cột số được điền đều kèm một cột cờ hậu tố `_is_imputed` để các bước sau còn phân biệt được ô đo thật với ô suy ra — tổng cộng 9 cột cờ.

Kết quả ghi ra `data/mlmart_base/v4_final_cleaned.parquet`: giữ nguyên 2.731.946 dòng, số cột tăng từ 47 lên 56, và số cột còn ô khuyết giảm từ 26 xuống 4. Bốn cột còn khuyết gồm `gmm_if_outlier_reason` — chỉ có giá trị ở dòng bị gán nhãn ngoại lai nên khuyết là đúng bản chất — cùng ba cột tham chiếu thời tiết `weather_id`, `weather_timestamp` và `weather_type_is_day`, mỗi cột khuyết 218 ô và không cột nào tham gia vào bộ đặc trưng của mô hình. Từ đây trở đi, `v4_final_cleaned.parquet` là đầu vào duy nhất của mọi bước còn lại trong tài liệu này.

Phần sản lượng bắt nguồn từ bộ dữ liệu mở UNISOLAR do Wimalaratne và cộng sự [1] công

bố. Bài báo mô tả đúng cấu hình mà dự án đang dùng, 42 vị trí lắp đặt điện mặt trời trên 5 khuôn viên của Đại học La Trobe, bang Victoria, Úc, đo ở bước 15 phút, kèm vị trí địa lý và thông số kỹ thuật của từng vị trí lắp đặt.

UNISOLAR đi kèm dữ liệu khí tượng của Cục Khí tượng Úc ở bước 1 phút. Dự án lấy biến khí tượng từ Open-Meteo theo toạ độ của từng khuôn viên, nên mọi kết luận về nhóm đặc trưng khí tượng trong tài liệu này thuộc về nguồn Open-Meteo.

Hai trạm mang số hiệu 19 và 24 có siêu dữ liệu công suất lắp đặt mâu thuẫn với sản lượng đo được, nên bị loại khỏi phạm vi huấn luyện và chấm điểm. Mô hình cuối cùng vì vậy được đánh giá trên 40 trạm; hai trạm còn lại vẫn nằm trong kho dữ liệu và vẫn hiển thị trên ứng dụng, chỉ không tham gia vào các con số được báo cáo.

6.1.2 Bài toán và tầm dự báo

Mục tiêu dự báo là sản lượng điện phát ra của từng vị trí lắp đặt điện mặt trời, ký hiệu y , đơn vị kWh trên mỗi khoảng 15 phút. Đây là bài toán dự báo chuỗi thời gian có biến ngoại sinh: ngoài lịch sử sản lượng của chính vị trí đó, mô hình còn được cung cấp các biến khí tượng và hình học Mặt Trời (*solar geometry*) tại thời điểm cần dự báo.

Tầm dự báo (*forecast horizon*) là khoảng cách thời gian giữa thời điểm đưa ra dự báo và thời điểm được dự báo. Dự án huấn luyện hai cấu hình ứng với hai tầm:

- **H1** — dự báo sản lượng tại $T + 15$ phút, tức một bước phía trước.
- **H4** — dự báo sản lượng tại $T + 60$ phút, tức bốn bước phía trước.

Hai tầm này phục vụ hai nhu cầu vận hành khác nhau: H1 dùng cho điều độ tức thời, H4 dùng cho lập kế hoạch trong giờ tới. Mỗi tầm có một mô hình riêng, được huấn luyện và chấm điểm độc lập.

Cơ sở chọn họ mô hình. Dự án dùng LightGBM, một mô hình cây tăng cường gradient, thay vì các kiến trúc học sâu dựa trên transformer. Lựa chọn này có tiền lệ định lượng trong tài liệu: Roy, Pyltsov và Hu [10] chấm 12 mô hình dự báo phụ tải điện trên cùng bộ dữ liệu của cuộc thi IISE PG&E Energy Analytics Challenge 2025, trải từ hồi quy tuyến tính từng khúc tới TimeGPT. Kết quả đo được cho thấy mô hình cây tăng cường gradient đạt sai số thấp hơn các kiến trúc học sâu ở cả ba kịch bản kiểm thử, với khoảng cách không nhỏ: RMSE 159,6 so với 239,5 của Transformer, tức thấp hơn 33%.

Bối cảnh của công trình đó gần với bài toán của dự án ở hai điểm: dữ liệu có cấu trúc chu kỳ mạnh theo giờ và theo mùa, và kích thước tập huấn luyện ở mức triệu dòng chứ không phải hàng chục triệu. Bài báo làm trên bài toán phụ tải điện, không phải sản lượng quang điện; nguồn này được dẫn như tiền lệ về lựa chọn họ mô hình. Kết quả của dự án được chứng minh bằng phép đối chứng riêng với mô hình Prophet, trình bày ở phần đánh giá.

Kịch bản	XGBoost	LSTM	TF	NHITS	TFT	TimeGPT
Year 1 → Year 2	159,6	220,9	239,5	233,6	329,3	369,03
Year 2 → Year 1	178,6	254,8	270,7	294,4	408,0	383,18
Cả hai năm	263,7	311,6	309,9	368,5	348,7	×

Bảng 6.1: So sánh sai số RMSE với nghiên cứu của Roy, Pyltsov và Hu [10].

6.1.3 Nhân ngoại lai kế thừa từ tầng ETL

Tập dữ liệu đầu vào mang sẵn hai cột do tầng ETL sinh ra: `gmm_if_outlier_flag` và `gmm_if_outlier_reason`. Quy trình học máy không tự phát hiện ngoại lai mà **kế thừa** kết quả này. Vì các nhãn đó quyết định dòng nào được tham gia huấn luyện và dòng nào bị loại khỏi chỉ số báo cáo, phần dưới đây tóm tắt cách các nhãn này được tạo ra.


Thuật toán mang tên GMM-IF, ghép tên của hai kỹ thuật thành phần:

- **GMM** — *Gaussian Mixture Model*, mô hình hỗn hợp Gauss. Kỹ thuật này giả định dữ liệu sinh ra từ vài phân phối Gauss chồng lên nhau, rồi ước lượng mật độ xác suất tại mỗi điểm. Điểm nằm ở vùng mật độ thấp là điểm hiếm. Câu hỏi nó trả lời: *điểm này hiếm tới mức nào so với phân bố chung*.
- **IF** — *Isolation Forest*, rừng cô lập. Kỹ thuật này dựng nhiều cây chia ngẫu nhiên và đếm số nút cắt cần thiết để tách riêng một điểm khỏi phần còn lại. Điểm bất thường nằm tách biệt nên bị cô lập sau rất ít nút cắt. Câu hỏi nó trả lời: *tách điểm này ra khỏi đám đông dễ hay khó*.

Hai kỹ thuật đo hai thứ khác nhau, một bên là mật độ, một bên là độ tách biệt, nên có thể bổ trợ cho nhau. Phần tóm tắt của bài báo mô tả đúng hai ý đó: Cách ghép chúng lại thích nghi từ công trình của Li và cộng sự [4]. Nhóm tác giả đó chỉ ra rằng dữ liệu chuỗi thời gian của hệ quang điện có tính phi tuyến và không dừng cao, nên khó mô tả bằng một phân phối Gauss duy nhất. Công trình đó đề xuất phân đoạn dữ liệu trước rồi mới áp GMM trong từng phân đoạn, đồng thời tích hợp Isolation Forest làm cơ chế quyết định ở bước chi tiết. Kết quả thực nghiệm của bài báo cho thấy phương án kết hợp cải thiện trung bình 3,8% về độ chính xác và 9,1% về F-value so với dùng riêng lẻ GMM hoặc Isolation Forest.

“In this method, the decision tree segmentation modeling strategy is used to structure the data to construct a local Gaussian-like distribution dataset to overcome the prior assumptions. Additionally, it integrates an Isolation Forest (IF) as the decision-making mechanism for detailed detection, further enhancing detection accuracy.”

Hai nguyên lý này hỏi hai câu hỏi khác nhau về cùng một điểm dữ liệu. Hình 6.1 minh họa bằng chính dữ liệu của dự án.



Hình 6.1: Phân bố mật độ GMM và điểm cô lập Isolation Forest trên dữ liệu trạm 27.

Hình 6.1 cho thấy hai thuật toán không thay thế được nhau. Nửa trái, GMM gắn cờ 156 điểm trên 8.176 quan sát, tức $156/8.176 = 1,91\%$, toàn bộ nằm ở đuôi trên của sản lượng và rải đều qua mọi mức bức xạ; đại lượng nó đo là mức hiếm của điểm trong phân bố. Nửa phải, Isolation Forest gắn cờ 246 điểm, tức $246/8.176 = 3,01\%$, theo một đại lượng khác: số nhất cắt cần thiết để tách điểm đó khỏi phần còn lại.

Hai tập cờ không trùng nhau: phần giao chỉ còn 144 điểm, tức GMM mất $156 - 144 = 12$ điểm và Isolation Forest mất $246 - 144 = 102$ điểm khi bắt cả hai cùng đồng ý. Có những điểm GMM cho là hiếm nhưng Isolation Forest thấy vẫn dễ giải thích, và ngược lại. Pipeline lấy phép giao để chỉ giữ phần mà cả hai góc nhìn cùng đồng ý, sau đó hợp thêm với các luật rào chắn vật lý.

Trên toàn bộ tệp đầu vào, cột `gmm_if_outlier_flag` gắn cờ 33.280 dòng trên tổng 2.731.946 dòng:

$$\frac{33.280}{2.731.946} = 0,012182 \rightarrow 1,22\% \quad (6.1)$$

Ba nhóm lý do chiếm phần lớn là vượt trần công suất, đồng thuận GMM-IF, và bước nhảy phân phối cục bộ.

Bốn phép đo thay cho precision và recall

Phát hiện ngoại lai ở đây là bài toán học không giám sát, và bộ dữ liệu không đi kèm nhãn sự cố do người vận hành xác nhận. Không có nhãn đối chiếu thì không tính được precision, recall hay F-score, nói cách khác, không có cách nào chấm điểm một ngưỡng là đúng hay sai. Vì vậy chất lượng của nhãn được đo bằng bốn đại lượng khác, mỗi đại lượng trả lời một câu hỏi kiểm chứng được.

Một: chất lượng phân đoạn của cây quyết định. Bước phân đoạn được chấm bằng hệ số xác định R^2 , đo trên toàn bộ 42 trạm: trung bình 0,758, thấp nhất 0,606 và cao nhất 0,826. Con số này không phải độ chính xác của bộ phát hiện ngoại lai; nó chỉ đo mức các phân đoạn do cây tạo ra giữ được cấu trúc hình dạng phát điện của từng trạm, tức mức phân đoạn đủ đồng nhất để chạy GMM bên trong. Hệ số R^2 tính trên phần dư thấp hơn nhiều (0,118–0,346, trung bình 0,187), đúng

như kỳ vọng, vì phần dư là phần biến động còn lại sau khi đã trừ ảnh hưởng của bức xạ nên chứa nhiều nhiễu thời tiết và sai số cảm biến.

Hai: mức giảm cảnh báo khi bất hai cơ chế cùng đồng ý. Phép giao giữa GMM và Isolation Forest lọc bỏ phần lớn ứng viên của cả hai phía, xem Bảng 6.2.

Bản kiểm toán gốc của tầng ETL nằm trong thư mục kết quả cục bộ, không được theo dõi bằng git, nên người đọc báo cáo không dựng lại được. Để bảng dưới đây kiểm chứng được, nhóm viết script `07_local_gmm_if_audit.py` trong `srcs/02_transform/02_generate_outliers/`. Script đọc bản kết xuất ML Mart có sẵn trên máy, tách lại ba tệp đệm mà thuật toán cần, rồi gọi chính `02_gmm_if.py` — nguyên bản không viết lại thuật toán, và không mở kết nối tới cơ sở dữ liệu hay kho lưu trữ đám mây nào.

Bảng 6.2: Số lượng mẫu vượt qua điều kiện kết hợp GMM và Isolation Forest.

Cơ chế	Số ứng viên	Qua được phép giao	Tỷ lệ sống sót
GMM	28.664	5.650	19,71%
Isolation Forest	36.295	5.650	15,57%

Hai tỷ lệ sống sót trong bảng là thương của cột thứ ba trên cột thứ hai:

$$\text{GMM: } \frac{5.650}{28.664} = 0,1971 \quad \text{và} \quad \text{Isolation Forest: } \frac{5.650}{36.295} = 0,1557 \quad (6.2)$$

Lớp đồng thuận vì vậy loại đi hơn bốn phần năm số cảnh báo của GMM và gần năm phần sáu số cảnh báo của Isolation Forest. Tỷ lệ này đo mức giảm cảnh báo đơn lẻ; nó không tương đương precision, vì phần bị loại chưa có nhãn xác nhận đúng hay sai.

Ba: khả năng tách hạng của điểm cô lập. Điểm cô lập trung bình của các dòng bị gấn cờ cuối cùng là **0,5086**, so với **0,2119** ở các dòng bình thường. Khoảng cách giữa hai nhóm là $0,5086 - 0,2119 = 0,2967$, tức nhóm bị gấn cờ có điểm cao gấp $0,5086/0,2119 = 2,40$ lần. Chênh lệch dương và ổn định cho thấy điểm số có xếp hạng được hai nhóm, nhưng đây là bằng chứng về khả năng phân tách chứ không phải chứng nhận độ chính xác.

Bốn: độ tái lập của năm luật rào chắn vật lý. Một quy tắc lọc dữ liệu chỉ đáng tin nếu người khác dựng lại được đúng kết quả của nó. Nhóm viết lại toàn bộ năm luật trong notebook `05d_thuc_nghiem_rao_chan_vat_ly`, đọc đúng ba tệp đệm mà tầng ETL đọc bằng đệm sản lượng, bảng đệm thời tiết và bảng chiều trạm rồi đối chiếu từng dòng với cờ mà tầng ETL đã ghi. Kết quả ở Bảng 6.3.

Ba trên năm luật dựng lại bắt trọn 100% số cờ tầng ETL đã ghi; hai luật còn lại đạt 98,6% và 99,7%. Phần dựng lại nhiều hơn vài dòng là do ML Mart mất một ít dòng khi ghép khoá, không phải do khác công thức.

Cách dựng cận trên. Cận trên có dạng $Q_3 + m \cdot \text{safe_IQR}$, trong đó IQR được tính riêng cho từng ô (trạm $\times$ mùa $\times$ dải bức xạ) chứ không tính trên toàn chuỗi, để sản lượng của một điểm được so với đúng những điểm cùng hoàn cảnh nắng.

Bảng 6.3: Đối chiếu số lượng cờ dị thường với tầng ETL.

Luật	Tầng ETL ghi	Dựng lại	Trùng	Độ khớp
PHYSICAL_OVER_CAPACITY	26.501	26.819	26.501	100,0%
PHYSICAL_HIGH_ENERGY_NO_SUN	36	37	36	100,0%
PHYSICAL_HIGH_ENERGY_LOW_RAD	140	144	138	98,6%
PHYSICAL_LOW_ENERGY_STRONG_SUN	57	57	57	100,0%
PHYSICAL_DISTRIBUTION_JUMP	1.202	1.317	1.198	99,7%

Chuỗi sản lượng ban đầu có nhiều khoảng trống thời gian, nên sau khi chia theo ba chiều đó, một số ô còn rất ít quan sát. Ô mỏng cho IQR co gần về 0; khi ấy cận $Q_3 + 1,5 \cdot IQR$ nằm sát ngay Q_3 và sẽ gán cờ hàng loạt điểm hoàn toàn bình thường. Pipeline vì vậy đặt hai lớp bảo vệ:

- **Nhánh dự phòng theo cỡ mẫu.** Ô nào có dưới 50 quan sát thì bỏ chiều mùa, lấy thống kê của ô thô hơn (trạm $\times$ dải bức xạ) thay thế.
- **Sàn cho khoảng tứ phân vị.** Thay IQR bằng $\text{safe_IQR} = \max(IQR, 0,03 \cdot p_{95}, 0,1)$, nên dù IQR của ô có về 0 thì cận vẫn còn một biên tối thiểu suy từ quy mô của chính trạm đó.

Hệ số nhân cũng nâng từ 1,5 lên 4 để cận nghiêm hơn, tránh gán cờ những dao động do mây che vốn hợp lệ.


Độ nhảy của ngưỡng. Cận $Q_3 + m \cdot \text{safe_IQR}$ quyết định bao nhiêu dòng bị loại khỏi tập huấn luyện, nên hệ số m được quét qua sáu mức trên cùng dữ liệu, từ mức Tukey chuẩn 1,5 tới 6. Kết quả ở Bảng 6.4 và Hình 6.2.

Bảng 6.4: Ảnh hưởng của hệ số nhân safe_IQR đến dữ liệu bị lọc.

Hệ số m	Số dòng bị loại	Sản lượng bị loại (kWh)	Tỷ lệ trên tổng
1,5	693	3.202	0,0344%
2	523	2.610	0,0280%
3	245	1.380	0,0148%
4 (đang dùng)	144	873	0,0094%
5	115	649	0,0070%
6	69	373	0,0040%

Nhìn Hình 6.2 thấy hai điều. Số dòng bị gán cờ giảm đều khi m tăng, đường giảm liên tục và không có bậc nhảy nào cho thấy một mức m đặc biệt tự tách ra khỏi phần còn lại. Phần sản lượng bị ảnh hưởng nằm gọn dưới mốc 0,05% trên toàn dải, cao nhất 0,0344% tại $m = 1,5$ và thấp nhất 0,0040% tại $m = 6$, chênh nhau vốn vẹn 0,03 điểm phần trăm.

Hai quan sát trên dẫn tới một kết luận: dù chọn hệ số nào trong khoảng 1,5–6, lượng dữ liệu bị loại đều không vượt quá một phần nghìn của bộ dữ liệu, nên lựa chọn hệ số không đủ sức làm thay đổi kết quả mô hình. Mức 4 đang dùng là một quyết định nằm trong vùng an toàn, không phải một mức tối ưu đã được chứng minh.




Hình 6.2: Quét hệ số nhân m của `safe_IQR` qua sáu mức.

6.1.4 Sơ đồ toàn cảnh

Trước khi đi vào quy trình cụ thể của đề tài, Hình 6.3 nhắc lại vòng đời học máy ở dạng chung nhất. Vòng ngoài màu xanh là phần gắn với bài toán: xuất phát từ yêu cầu nghiệp vụ, xác định bài toán, rồi ở cuối là triển khai, giám sát và phân tích thông tin thu được. Vòng trong màu cam là phần gắn với dữ liệu và mô hình, chạy từ thu thập, xử lý, sinh đặc trưng, huấn luyện đến đánh giá. Điểm cần chú ý là cả hai vòng đều khép kín: kết quả giám sát quay ngược về yêu cầu nghiệp vụ, và kết quả đánh giá quay ngược về khâu dữ liệu.


◇ Vòng đời học máy



Hình 6.3: Vòng đời phát triển và vận hành mô hình học máy (MLOps) [24].

Quy trình của đề tài là một lần hiện thực hoá vòng đời đó. Hình 6.4 mô tả chín bước của quy trình. Bốn bước đầu lấy, làm sạch, chia và khảo sát dữ liệu; bước 5 sinh rồi chọn đặc trưng; bốn bước cuối huấn luyện, đánh giá, đưa mô hình vào sử dụng và quản lý phiên bản dữ liệu cùng mô

hình.



Hình 6.4: Quy trình 9 bước phát triển và đánh giá mô hình học máy.

Mỗi bước tương ứng với một notebook trong thư mục `notebooks/forecasting_v4_energy/`. Toàn bộ số liệu và hình ảnh trong các phần sau đều trích từ những tệp kết quả liệt kê ở Bảng 6.5.

Bước	Notebook	Kết quả ghi ra
Chuẩn bị lưới thời gian	01_reindex_mask_outlier	lưới 15 phút liên tục
Chia dữ liệu	02_split_time_series	3 fold và tập test niêm phong
Khám phá dữ liệu	02_EDA	thống kê mô tả, ACF/PACF, tương quan
Đặc trưng thời gian	03_1_features_time	lag, rolling, chu kỳ lịch
Đặc trưng không gian	03_2_features_spatial	solar geometry, site_scale
Đặc trưng tương tác	03_3_features_aggregate	tương tác, mã hoá phân loại
Chẩn đoán đa cộng tuyến	04_vif_diagnostics	bảng hệ số VIF
Chọn đặc trưng	05_select_features	selected_features.json
Huấn luyện	06_1, 06_2, 06_3	model.pkl, model_config.json
Chọn hàm mất mát	06_4_validate_model	bảng đối chiếu ba hàm
Đánh giá cuối	07_final_test	metrics_overall.json
Giải thích mô hình	08_explainable_ai	biểu đồ SHAP
Mô hình đối chứng	06_0b_baseline_prophet	prophet_test_summary.json

Bảng 6.5: Ánh xạ các bước trong quy trình với notebook thực hiện.

6.1.5 Năm rào chắn chống rò rỉ dữ liệu

Rò rỉ dữ liệu là rủi ro lớn nhất của một bài toán dự báo chuỗi thời gian: chỉ cần một đặc trưng vô tình mang thông tin của tương lai, mọi chỉ số đánh giá đều trở nên vô nghĩa. Quy trình đặt năm rào chắn, mỗi rào chắn gắn với một bước cụ thể:

1. **Nhân quả trong ghép thời tiết** (bước 2). Mỗi bản ghi tại thời điểm T chỉ được ghép với khối khí tượng của giờ đã kết thúc trước T . Điều kiện này được kiểm tra trên toàn bộ 2,73 triệu bản ghi.
2. **Không chồng lấn khi chia dữ liệu** (bước 3). Dữ liệu được cắt theo trục thời gian, không xáo trộn ngẫu nhiên. Tập test được tách ra trước mọi bước khác và chỉ được mở đúng một lần ở bước 7.
3. **Thống kê tính riêng theo từng fold** (bước 5). Các đại lượng tổng hợp như `site_scale` hay `cs_factor` được ước lượng riêng trong phần huấn luyện của từng fold, không nhìn sang phần kiểm định.
4. **Ngưỡng suy từ dữ liệu huấn luyện** (bước 6). Cận cắt của mục tiêu chuẩn hoá được tính từ phân vị của dữ liệu huấn luyện, rồi ghi vào tệp cấu hình để các bước sau đọc lại đúng giá trị đó thay vì tính lại trên tập khác.
5. **Tái lập được** (bước 6). LightGBM chạy ở chế độ tắt định trên CPU với `deterministic = true`, `force_col_wise = true` và `random_state = 42`; toàn bộ siêu tham số của sáu cấu hình được ghi ra `model_config.json` để đối chiếu.

Bốn rào chắn đầu được kiểm chứng bằng số liệu ở các phần tương ứng phía sau. Rào chắn thứ năm được bảo đảm bằng cấu hình tắt định, trình bày ở Mục 6.4.5.

6.2 Chuẩn bị dữ liệu và chia tập

Mục này đi từ tệp đã làm sạch tới các tập sẵn sàng huấn luyện, qua sáu bước: hiện trạng dữ liệu, dựng lại lưới thời gian, khám phá dữ liệu, cắt tập test niêm phong, chia ba fold kiểm định, và đo nhãn chồng lấn ở ranh giới fold.

6.2.1 Hiện trạng bộ dữ liệu

Sau khi dựng lại lưới, bộ dữ liệu có 2.784.438 dòng của 42 vị trí lắp đặt, trải từ 01/01/2020 đến 23/04/2022 ở bước 15 phút, trong đó 52.492 dòng (1,89%) là mốc được chèn thêm cho lưới khỏi đứt quãng.

Chỉ 1.195.645 dòng (42,94%) là số đo thật. Phần còn lại do tầng ETL sinh ra: 1.536.301 dòng điền khuyết (55,17%), 42.055 dòng gán không do sự cố thiết bị và 6.287 dòng gán không vì trời tối. Ngoài ra tầng ETL gán cờ ngoại lai cho 33.280 dòng (1,20%), gồm 26.318 dòng vượt trần công suất, 5.458 dòng do hai cơ chế thống kê cùng đồng ý, 791 dòng trùng nhiều luật và 713 dòng trùng một luật vật lý khác; Mục 6.3.2 kiểm chứng lại các cờ này.

Bốn con số trên định hình các bước còn lại. Lưới đứt quãng phải dựng lại trước tiên, vì đặc trưng trễ và cửa sổ trượt đếm theo số bước chứ không theo mốc đồng hồ nên một lỗi hổng làm chúng tính sai mà không báo lỗi. Tỷ lệ đo thật thấp không sửa được bằng kỹ thuật nên xử lý bằng chính sách: dòng không phải số đo thật, kể cả dòng mang cờ ngoại lai, nhận trọng số 0 khi huấn luyện và bị loại khỏi phạm vi chấm điểm, nhưng vẫn giữ trong lưới để không đứt lịch sử.

Hai điểm nữa cũng chi phối các bước sau: dữ liệu khí tượng chỉ có độ hạt một giờ nên mỗi giá trị bức xạ lắp bốn lần và cần một bước hạ độ hạt riêng; và 42 vị trí lắp đặt chênh nhau nhiều về quy mô nên mục tiêu phải chuẩn hoá theo từng trạm, nếu không mô hình sẽ dồn sức phân biệt trạm lớn với trạm nhỏ thay vì học quan hệ giữa thời tiết và sản lượng.

6.2.2 Dựng lại lưới thời gian liên tục

Dữ liệu sản lượng thu từ công tơ không phải lúc nào cũng đủ mốc: mất điện, mất kết nối hoặc lỗi ghi đều để lại lỗ hổng trên trục thời gian. Nếu đưa thẳng dữ liệu khuyết mốc vào bước sinh đặc trưng, các biến trễ và biến cửa sổ trượt sẽ tính sai, `lag_4` lẽ ra phải lùi đúng 60 phút thì lại lùi 75 hay 90 phút, tùy vào chỗ bị khuyết.

Notebook `01_reindex_mask_outlier` dựng lại lưới 15 phút liên tục cho từng trạm bằng `pd.date_range`, rồi đánh dấu những dòng vừa được chèn thêm. Thứ tự hai việc này là điều kiện bắt buộc: dựng lưới trước, lọc sau. Nếu lọc bỏ dòng ban đêm hay dòng ngoại lai trước khi dựng lưới, khoảng cách thời gian giữa các dòng còn lại sẽ không đều, và mọi đặc trưng trễ sau đó đều lệch.

Các dòng bị gán cờ ngoại lai ở tầng ETL không bị xoá khỏi lưới. Chúng được giữ nguyên vị trí để lịch sử không bị đứt quãng, nhưng mang nhãn loại trừ nên không đóng góp vào hàm mất mát khi huấn luyện, cũng không tham gia vào các chỉ số được báo cáo.

Ba ràng buộc thiết kế. Bước dựng lưới tuân thủ ba ràng buộc, cùng hướng tới một mục tiêu: không để thông tin của tương lai, hoặc thông tin không có thật, lọt vào lưới dữ liệu.

1. **Thời tiết chỉ được lắp theo chiều tiến.** Chỉ dùng `ffill()` theo từng trạm, tức sử dụng giá trị đã quan sát trong quá khứ sang hiện tại. Quy trình nghiêm cấm dùng `bfill()`, vì kéo ngược là lấy giá trị của mốc sau đắp cho mốc trước — đúng định nghĩa của rò rỉ dữ liệu.
2. **Siêu dữ liệu tĩnh thiếu thì giữ nguyên khuyết.** Các cột như `capacity_kw`, `number_of_panels`, vĩ độ và kinh độ nếu thiếu thì để nguyên khuyết, không lắp và không bịa giá trị.
3. **Điền mục tiêu theo bậc thang nhân quả.** Slot mới chèn được điền theo đúng thứ tự: `night_zero` → `causal_day_persistence` (cùng giờ hôm qua) → `causal_week_persistence` (cùng giờ tuần trước) → `causal_profile_median` → `fallback_zero`. Mọi bậc đều chỉ nhìn về quá khứ. Riêng khoảng trống từ 24 giờ trở lên được xếp vào `machine_failure_zero` và đánh dấu loại khỏi huấn luyện.

Kết quả thực thi. Khối dưới đây trích nguyên văn kết quả kết xuất của notebook `01_reindex_mask_outlier`:

```
Đã reindex lưới 15 phút cho 42 site.
Tổng số dòng sau reindex: 2784438
- Dòng gốc: 2731946
- Dòng inserted: 52492
```

Forward-fill thời tiết (causal only, per-site):

- Số cột thời tiết: 15
- NaN trước: 812250
- NaN sau: 1890
- Đã lấp: 810360 giá trị

Đã điền target cho 52492 slot inserted.

--- PHÂN BỐ ENERGY_SOURCE SAU CASCADE ---

energy_source	
etl_imputed	1536301
measured	1195645
machine_failure_zero	42055
night_zero	6287
causal_day_persistence	2668
fallback_zero	984
causal_profile_median	283
causal_week_persistence	215

--- GATE CHECK ---

- Target null: 0
 - Energy_source rỗng: 0
- PASS - Không còn target null hoặc energy_source rỗng.

Phân tích kết quả. Sáu nhãn thuộc bậc thang điền machine_failure_zero, night_zero, causal_day_persistence, fallback_zero, causal_profile_median và causal_week_persistence cộng lại bằng đúng 52.492, tức đúng số dòng đã chèn. Không dòng nào rơi ra ngoài bậc thang, cũng không dòng nào bị đếm hai lần. Công kiểm ở cuối xác nhận không còn mục tiêu khuyết và không còn energy_source rỗng.

Hạn chế của bước dựng lưới. Trong 52.492 dòng được chèn thì 42.055 dòng rơi vào nhãn machine_failure_zero, tức các khoảng trống từ 24 giờ trở lên, được gán 0 và loại khỏi huấn luyện:

$$\frac{42.055}{52.492} = 0,8012 \rightarrow \mathbf{80,1\%} \quad (6.3)$$

Bốn phần năm phần chèn thêm vì vậy không mang thông tin mới; chúng chỉ giữ chỗ để lưới thời gian không bị đứt. Phần còn lại được điền bằng các bậc suy từ lịch sử thật, gồm $6.287 + 2.668 + 984 + 283 + 215 = 10.437$ dòng, trong đó 6.287 dòng là night_zero — các mốc ban đêm vốn phải bằng 0. Số dòng thực sự được suy từ lịch sử phát điện là $10.437 - 6.287 = 4.150$ dòng.

Một hạn chế nữa: sau khi lấp theo chiều tiến vẫn còn 1.890 ô thời tiết khuyết. Đó là các mốc nằm ở đầu chuỗi của từng trạm, nơi chưa có quan sát quá khứ nào để kéo sang. Chỉ có thể lấp những ô này bằng phép lấp ngược chiều, tức lấy giá trị của mốc sau đắp cho mốc trước, mà phép đó đưa thông tin tương lai vào dữ liệu huấn luyện. Quy trình vì vậy giữ nguyên trạng thái khuyết ở các mốc đó, đổi lấy việc bảo toàn ràng buộc nhân quả. Theo khối kết xuất ở trên, phép lấp theo chiều tiến

xử lý được 810.360 trên 812.250 ô khuyết ban đầu, tức $810.360/812.250 = 99,77\%$; phần còn lại là 1.890 ô. LightGBM nhận trực tiếp giá trị khuyết nên phần này không cần điền.

Cách xử lý này phù hợp với kết quả của Kim, Ko và Kim [9]. Nhóm tác giả đánh giá tác động của dữ liệu khuyết tới bài toán dự báo sản lượng quang điện và chỉ ra rằng cách xử lý phần khuyết ảnh hưởng trực tiếp tới sai số của mô hình dự báo, chứ không phải là một bước tiền xử lý trung tính:

“Such missing values deteriorate the PV power generation prediction performance, and they need to be eliminated by filling in other values.”

Từ đó, dự án tách bạch hai việc: dừng lại mốc thời gian để cấu trúc chuỗi không bị đứt, và đánh dấu nguồn gốc từng dòng để phần dữ liệu không đáng tin không lọt vào chỉ số báo cáo. Phạm vi của bài báo và của dự án khác nhau ở một điểm: bài báo khảo sát bốn phương pháp điền khuyết cho dữ liệu khí tượng và kết luận phương pháp k láng giềng gần nhất cho kết quả tốt nhất, trong khi dự án chỉ mượn kết luận tổng quát rằng phần khuyết phải được xử lý có chủ đích.

6.2.3 Phân tích khám phá dữ liệu và các quyết định sinh đặc trưng

Trước khi sinh đặc trưng, dữ liệu được khảo sát ở notebook 02_EDA. Phạm vi khảo sát là chỉ tập huấn luyện, sau khi loại hai trạm 19 và 24: còn 1.480.000 dòng của 40 trạm. Đây là điều kiện bắt buộc các quyết định sinh đặc trưng ở Phần 3 đều rút ra từ bước này, nên nếu khảo sát cả tập test thì tập test đã tham gia vào thiết kế mô hình, trái với nguyên tắc niêm phong nêu ở Mục 6.1.5.

Ba phạm vi con được tách riêng để mọi con số phía sau đều nói rõ nó thuộc phạm vi nào:

Doc vao : 1,550,856 dong x 12 cot | 42 tram
Sau khi bo tram [19, 24]: 1,480,000 dong | 40 tram

toan bo	1,480,000 dong	(100.00%)
ban ngay	742,116 dong	(50.14%)
do that ban ngay	606,112 dong	(40.95%)


Phân bố đơn biến của sản lượng

Bảng 6.6: Thống kê mô tả sản lượng theo ba phạm vi.

Phạm vi	Số dòng	Trung vị	Độ lệch	Độ nhọn	% bằng 0
Toàn bộ	1.480.000	0,0000	6,0612	47,3723	52,30
Ban ngày	742.116	2,7325	4,5148	25,3908	6,66
Đo thật ban ngày	606.112	3,2188	4,4313	24,5310	0,00

Phân bố lệch phải rất mạnh và nhọn: trên toàn bộ tập huấn luyện, độ lệch đạt 6,06 và độ nhọn đạt 47,37, trong khi phân phối chuẩn có cả hai bằng 0. Nguyên nhân trực tiếp là 52,30% số quan sát bằng 0, ban đêm và các khung giờ rìa ngày. Trung vị của toàn bộ tập cũng bằng 0, tức quá nửa dữ liệu không mang thông tin phát điện.

Hình 6.5 trình bày ba cách nhìn cùng một phân bố. Lọc về ban ngày kéo độ lệch xuống 4,51 và tỷ lệ giá trị 0 xuống 6,66%; lọc thêm điều kiện đo thật thì không còn giá trị 0 nào. Ba dòng của Bảng 6.6 vì vậy là căn cứ trực tiếp cho hai quyết định: chỉ tính chỉ số báo cáo trên phạm vi đo thật ban ngày, và chuẩn hoá mục tiêu để kéo phân bố về dạng đều hơn.



Hình 6.5: Phân phối sản lượng trên tập huấn luyện theo các phạm vi.

Mẫu hình phát điện và tác động của mây

Hai dạng ngày cho hai dạng chuỗi khác hẳn nhau. Ngày trời quang cho đường cong trơn dạng parabol; ngày nhiều mây cho chuỗi gãy khúc liên tục. Notebook chọn hai ngày tương phản trên trạm phát mạnh nhất, và chỉ xét những ngày có ít nhất 40 mốc đo thật ban ngày cùng đủ 96 mốc trong ngày, để hình không rơi vào ngày do tăng ETL điền khuyết:


Trạm 27 | 283 ngày đạt điều kiện | 71 ngày nhiều nắng
 Ngày trời quang: 2020-10-02 | do gap 0.0031
 Ngày nhiều mây : 2020-12-23 | do gap 0.0926

Hai ngày này không được chọn bằng mắt mà bằng một đại lượng đo trực tiếp trên chuỗi sản lượng, gọi là độ gấp: trung bình trị tuyệt đối của sai phân bậc hai trong ngày, chia cho đỉnh của chính ngày đó. Sai phân bậc hai đo mức đổi hướng giữa ba mốc liên tiếp, nên đường càng trơn thì độ gấp càng nhỏ; phép chia cho đỉnh khiến chỉ số không phụ thuộc quy mô trạm. Phép chọn chỉ xét trong nhóm 71 ngày nhiều nắng, nhóm có tổng sản lượng thuộc phần tư trên, rồi lấy ngày độ gấp nhỏ nhất làm ngày trời quang và ngày độ gấp lớn nhất làm ngày nhiều mây. Ràng buộc nhóm là cần thiết: một ngày âm u kéo dài cũng cho đường phẳng lì và độ gấp rất nhỏ, nếu không lọc trước thì nó sẽ bị chọn nhầm thành ngày trời quang.

Hình 6.6 đặt hai ngày cạnh nhau trên cùng thang trục tung. Ngày 02/10/2020 cho một đường cong trơn, lên đều rồi hạ gần đối xứng. Ngày 23/12/2020 đạt đỉnh tương đương nhưng chỉ giữ được trong ít bước, phần còn lại là chuỗi răng cưa. Độ gấp của hai ngày chênh nhau gần 30 lần: $0,0926/0,0031 = 29,9$.

Cả hai đều thuộc nhóm ngày nhiều nắng, tức lượng bức xạ khả dụng trong ngày tương đương, nhưng cho hai chuỗi khác hẳn. Phần chênh lệch đó là do mây, và mô hình không thể suy ra nó từ lịch hay từ vị trí Mặt Trời. Đây là căn cứ sinh hai đặc trưng `chi_so_troi_quang` và `rad_x_sinelev`:

chúng cấp cho mô hình tín hiệu về mức che phủ ngay tại bước hiện tại, thay vì bắt mô hình suy ra gián tiếp từ các mốc trễ.



Hình 6.6: Đặc tuyến sản lượng ngày trời quang và ngày nhiều mây tại trạm 27.


Tự tương quan

Bảng 6.7 ghi tự tương quan của chuỗi sản lượng tại các mốc trễ đáng chú ý.

Bảng 6.7: Hệ số tự tương quan (ACF) chuỗi sản lượng tại các mốc trễ.

Mốc trễ	Khoảng cách	ACF
lag_1	15 phút	+0,9689
lag_4	1 giờ	+0,9033
lag_96	24 giờ	+0,7134
—	48 giờ	+0,6613
—	72 giờ	+0,6465

Con số +0,9689 tại mốc 15 phút là điểm cần đọc kỹ. Ở mức tự tương quan đó, giá trị tại t gần như là bản sao của giá trị tại $t + 1$, nên một mô hình được cấp lag_1 sẽ có lối tắt hiển nhiên: lặp lại giá trị vừa đo. Mốc 1 giờ vẫn giữ tương quan cao +0,9033 nhưng đã đủ xa để không còn là bản sao, còn mốc 24 giờ ở +0,7134 mang thông tin chu kỳ ngày. Hình 6.7 là biểu đồ đầy đủ. Ba con số này là căn cứ định lượng cho lựa chọn trình bày ở Mục 6.3.1.



Hình 6.7: Biểu đồ tự tương quan ACF và tương quan riêng phần PACF.

Tương quan giữa các biến

Tương quan tính trên 606.112 dòng đo thật ban ngày, xem Bảng 6.8.


Bảng 6.8: Tương quan giữa các biến khí tượng với sản lượng điện.

Biến	Spearman ban ngày	Gộp cả đêm	Chênh
shortwave_radiation	+0,6043	+0,9024	+0,2981
direct_normal_irradiance	+0,5513	+0,8755	+0,3243
diffuse_solar_radiation	+0,3808	+0,8750	+0,4942
temperature_c	+0,2628	+0,4349	+0,1721
cloud_cover_total	-0,1591	+0,0330	+0,1921

Cột chênh lệch là kết quả đáng chú ý nhất của cả bước khảo sát. Nếu gộp cả ban đêm, tương quan của `shortwave_radiation` với sản lượng vọt từ +0,60 lên +0,90, và `diffuse_solar_radiation` vọt từ +0,38 lên +0,88. Mức tăng đó không phản ánh quan hệ vật lý: ban đêm mọi biến bức xạ và sản lượng đều bằng 0 cùng lúc, nên hơn một nửa số điểm nằm chồng tại gốc toạ độ và tự động đẩy hệ số tương quan lên. Ma trận đầy đủ ở Hình 6.8.

Cột `cloud_cover_total` cho thấy rõ nhất: ban ngày nó mang dấu âm -0,1591 — đúng ý nghĩa vật lý là mây che thì sản lượng giảm nhưng gộp cả đêm thì đổi thành dấu dương +0,0330, tức đảo ngược hoàn toàn ý nghĩa. Vì vậy mọi tương quan trong tài liệu này đều tính trên phạm vi đo thật ban ngày.

Chẩn đoán đa cộng tuyến không nằm ở bước này. Hệ số phóng đại phương sai cần toàn bộ đặc trưng đã sinh xong, nên nó được tính ở notebook `04_vif_diagnostics` và trình bày ở Mục 3.7.



Hình 6.8: Ma trận tương quan Spearman giữa các đặc trưng ban ngày.

6.2.4 Chia dữ liệu theo trục thời gian

Với bài toán dự báo, phép chia ngẫu nhiên thông thường là sai về nguyên tắc, vì cách chia đó cho phép mô hình học từ dữ liệu của tháng sau rồi đi dự báo tháng trước. Notebook `02_split_time_series` vì vậy cắt dữ liệu **theo thứ tự thời gian**, không xáo trộn.


Trước hết, 15% số mốc thời gian cuối cùng được tách ra làm tập test niêm phong và cất đi. Phần còn lại, gọi là tập Phát triển, mới được dùng để sinh đặc trưng, chọn đặc trưng, tinh chỉnh siêu tham số (*hyperparameter*) và chọn hàm mất mát. Tập test chỉ được mở đúng một lần ở bước đánh giá cuối, sau khi mọi quyết định đã khoá.

Phép cắt thực hiện trên trục mốc thời gian, không phải trên số dòng. Toàn bộ dữ liệu có 81.023 mốc thời gian phân biệt; cắt 15% cuối cho 12.154 mốc thuộc tập test và 68.869 mốc thuộc tập Phát triển. Ranh giới rơi vào 18/12/2021 lúc 09:30:

- **Tập Phát triển** — từ 01/01/2020 00:15 đến 18/12/2021 09:15.
- **Tập test niêm phong** — từ 18/12/2021 09:30 đến 23/04/2022 23:45.

Tỷ lệ 15% tính trên mốc thời gian tương ứng 510.468 dòng trên tổng 2.784.438, tức 18,33% khối lượng dữ liệu. Hai tỷ lệ lệch nhau do số trạm hoạt động tăng dần theo thời gian: đầu năm 2020 có 30 trạm phát sinh dữ liệu, tới cuối năm 2021 đủ 42 trạm, nên mỗi mốc thời gian ở giai đoạn sau mang nhiều dòng hơn giai đoạn trước. Hình 6.9 mô tả cách chia.

Phép cắt theo mốc được chọn thay vì cắt theo số dòng vì nó cho một ranh giới thời gian duy nhất áp dụng chung cho cả 42 trạm. Cắt theo số dòng sẽ khiến mỗi trạm có một mốc cắt riêng và tập test không còn là một giai đoạn liên mạch.



Hình 6.9: Phân chia dữ liệu chuỗi thời gian theo cửa sổ mở rộng.

6.2.5 Ba fold theo cửa sổ mở rộng

Tập Phát triển được chia thành ba fold theo kiểu cửa sổ mở rộng (*expanding window*): phần huấn luyện của fold sau chứa trọn phần huấn luyện lẫn phần kiểm định của fold trước. Cách này mô phỏng đúng tình huống vận hành thật, càng về sau càng có nhiều lịch sử để học, và bảo đảm phần kiểm định luôn nằm ở tương lai so với phần huấn luyện.

Phép chia fold cũng thực hiện trên trục mốc thời gian, mỗi fold nhận đúng 17.217 mốc cho phần kiểm định, còn phần huấn luyện nói rộng dần qua 17.218, 34.435 rồi 51.652 mốc.

Bảng 6.9: Ranh giới thời gian, kích thước và số trạm của ba fold kiểm định.

Fold	Phần huấn luyện			Phần kiểm định		
	đến	số dòng	trạm	đến	số dòng	trạm
1	28/06/2020 08:30	233.244	30	24/12/2020 16:45	606.105	39
2	24/12/2020 16:45	839.349	39	22/06/2021 01:00	711.507	42
3	22/06/2021 01:00	1.550.856	42	18/12/2021 09:15	723.114	42

Nhìn Bảng 6.9 thấy rõ tính chất mở rộng: mốc kết thúc huấn luyện của fold 2 trùng đúng mốc kết thúc kiểm định của fold 1, và tương tự giữa fold 3 với fold 2. Kích thước tập huấn luyện tăng dần từ 233 nghìn lên 1,55 triệu dòng, trong khi tập kiểm định giữ quy mô tương đương nhau, khoảng 600–720 nghìn dòng.

Vì sao chọn cửa sổ mở rộng thay vì cửa sổ trượt. Hai cách chia đều tôn trọng trục thời gian, khác nhau ở chỗ xử lý dữ liệu cũ. Cửa sổ mở rộng giữ lại toàn bộ quá khứ: tập huấn luyện của fold sau chứa trọn tập huấn luyện của fold trước cộng thêm phần kiểm định của nó, nên bề rộng lớn dần, ở đây là 233 nghìn rồi 839 nghìn rồi 1,55 triệu dòng. Cửa sổ trượt giữ bề rộng cố định và đẩy cả hai đầu về phía trước, tức mỗi lần tiến một bước thì cắt bỏ một đoạn đầu tương ứng.

Ba lý do khiến cửa sổ mở rộng phù hợp với bài toán này. Thứ nhất, dữ liệu chỉ trải hơn hai năm trong khi chu kỳ chi phối sản lượng là chu kỳ mùa dài đúng một năm; cửa sổ trượt với bề rộng

cổ định sẽ khiến fold đầu tiên chỉ nhìn thấy vài tháng, không đủ trọn một vòng mùa để học được dạng đường cong ngày của cả mùa hè lẫn mùa đông. Thứ hai, các trạm lần lượt đi vào vận hành theo thời gian, từ 30 trạm ở fold 1 lên 42 trạm ở fold 3; cắt bỏ đoạn đầu đồng nghĩa vớt luôn phần lịch sử sớm của những trạm vận hành trước, trong khi đó lại chính là phần dữ liệu dài nhất của chúng. Thứ ba, quan hệ giữa bức xạ và sản lượng của tấm quang điện là quan hệ vật lý, không đổi nhanh theo thời gian, nên dữ liệu cũ vẫn còn giá trị mô tả.

Cửa sổ trượt sẽ là lựa chọn tốt hơn khi hệ thống có trôi khái niệm mạnh, chẳng hạn thay tấm pin, đổi biến tần hay đổi cấu hình lắp đặt, vì khi đó dữ liệu cũ mô tả một hệ thống khác và trở thành nhiễu. Bộ dữ liệu này không có sự kiện như vậy.

Đánh đổi phải chấp nhận là ba fold không cùng cỡ tập huấn luyện, nên sai số của từng fold không so trực tiếp với nhau được: fold 1 vừa ít dữ liệu vừa vương vấn đề trạm mới nêu ngay dưới đây. Vì vậy tài liệu chỉ dùng WAPE gộp ba fold để xếp hạng cấu hình, không đọc riêng con số của một fold.

Hạn chế: fold sớm có trạm chưa từng xuất hiện khi huấn luyện. Cột số trạm trong Bảng 6.9 cho thấy một hệ quả trực tiếp của việc các trạm lần lượt đi vào vận hành theo thời gian. Ở fold 1, mô hình học trên 30 trạm nhưng bị chấm điểm trên 39 trạm; ở fold 2 là 39 trạm so với 42. Chênh lệch đó nghĩa là một phần dữ liệu kiểm định thuộc về những trạm mà mô hình chưa từng nhìn thấy một dòng nào lúc huấn luyện. Tới fold 3 thì cả 42 trạm đều đã có mặt ở phần huấn luyện nên tình huống này không còn.

Ảnh hưởng của nó làm sai số đo trên fold 1 và fold 2 bị quan hơn thực tế vận hành, vì trong vận hành thật mô hình luôn đã có lịch sử của trạm mà nó dự báo. Chiều ảnh hưởng là an toàn, sai số bị đánh giá nặng hơn chứ không nhẹ đi, nhưng khi so sánh các cấu hình bằng WAPE gộp ba fold thì phần đóng góp của fold 1 vẫn mang theo thành phần sai lệch này.

6.2.6 Thực nghiệm: đo phần chồng lấn nhãn ở ranh giới fold

Ba fold được cắt liên tục, không chèn khoảng đệm giữa phần huấn luyện và phần kiểm định. Hai quy tắc chống rò rỉ nêu ở Mục 6.1.4 chỉ ràng buộc đặc trưng đầu vào; riêng nhãn cần một phép kiểm riêng. Nhãn của một dòng huấn luyện là sản lượng tại $T + h$, nên với những dòng nằm sát mốc cắt, thời điểm $T + h$ có thể đã rơi sang vùng kiểm định. Nhóm đo trực tiếp phần chồng lấn này.

Cách tiến hành. Với mỗi fold, đọc trực tiếp tệp `fold_i_train_selected.parquet`, lấy mốc thời gian lớn nhất $T_{\max}$ của phần huấn luyện. Một dòng có nhãn rơi sang vùng kiểm định khi và chỉ khi mốc thời gian của dòng đó lớn hơn $T_{\max} - 15h$ phút, với h là số bước của tầm dự báo. Đếm số dòng thoả điều kiện đó cho cả hai tầm H1 và H4. Phép đo chạy trên chính các tệp fold mà bước huấn luyện đọc vào, không dùng dữ liệu trung gian nào khác.

Trường hợp xấu nhất là fold 1 ở tầm H4: 120 dòng trên 233.244, tức **0,0514%**. Tỷ lệ nhỏ như vậy là hệ quả cấu trúc của phép cắt, chỉ những dòng nằm trong h bước cuối cùng của tập huấn luyện mới có nhãn vượt sang vùng kiểm định, mà h nhiều nhất là bốn bước.

Bảng 6.10 tự kiểm chứng được. Ở tầm H1 chỉ một bước cuối bị chồng lấn, nên số dòng phải bằng số trạm còn hoạt động tại bước đó: cột chồng lấn H1 cho 30, 39 và 42, tương ứng với cột số

Bảng 6.10: Kiểm tra hiện tượng chồng lấn nhãn giữa các fold.

Fold	Cỡ tập huấn luyện	Chồng lấn H1	Chồng lấn H4	Tỷ lệ H4
1	233.244	30	120	0,0514%
2	839.349	39	156	0,0186%
3	1.550.856	42	168	0,0108%

trạm ở Bảng 6.9. Cột H4 bằng bốn lần các giá trị đó.

Với mức chồng lấn dưới một phần nghìn ở cả ba fold, phép cắt liên tục được giữ nguyên, không chèn khoảng đệm.

6.3 Sinh đặc trưng

Ba notebook liên tiếp bổ sung đặc trưng vào cùng một khung dữ liệu, mỗi notebook phụ trách một họ: `03_1_features_time` sinh đặc trưng suy từ trục thời gian và từ lịch sử sản lượng, `03_2_features_spatial` sinh đặc trưng hình học Mặt Trời cùng các đại lượng chuẩn hoá theo trạm, `03_3_features_aggregate` sinh đặc trưng tương tác khí tượng và mã hoá biến phân loại. Hai notebook sau đó thu hẹp lại: `04_vif_diagnostics` chẩn đoán đa cộng tuyến, `05_select_features` chốt danh sách chính thức.

6.3.1 Đặc trưng thời gian, trễ và cửa sổ trượt

Notebook `03_1_features_time` sinh ba nhóm đặc trưng, tóm tắt ở Bảng 6.11.

Bảng 6.11: Các nhóm đặc trưng thời gian và độ trễ.

Nhóm	Cột sinh ra	Tham số
Lịch và chu kỳ	<code>minute_of_day</code> , <code>month</code> , <code>day_of_week</code> , <code>is_weekend</code> , <code>season</code> , <code>season_code</code> , <code>hour_sin</code> , <code>hour_cos</code> , <code>doy_sin</code> , <code>doy_cos</code>	chu kỳ ngày 1440 phút; chu kỳ năm 365,25 ngày
Trễ	<code>lag_4</code> , <code>lag_96</code>	$LAGS = (4, 96)$, tức $T - 60$ phút và $T - 24$ giờ
Cửa sổ trượt	<code>rolling_mean</code> , <code>rolling_std</code> , <code>rolling_min</code> , <code>rolling_max</code> cho mỗi cửa sổ	$ROLLING_WINDOWS = (4, 96)$, bốn thống kê mỗi cửa sổ

Hai nhóm sau tạo ra 2 cột trễ cộng 8 cột cửa sổ trượt, bằng 10 cột suy từ chuỗi mục tiêu, đúng con số notebook in ra khi khai báo hàm sinh đặc trưng.

Mã hoá lịch bằng sin và cos. Nếu để giờ trong ngày ở dạng số nguyên, mốc 23:45 và mốc 00:00 cách nhau đúng một bước 15 phút trên thực tế nhưng cách nhau 23 đơn vị trên thang số. Cây quyết định chia theo ngưỡng sẽ coi hai mốc liền kề đó là hai vùng xa nhau. Cặp (sin, cos) đưa trục thời gian về một vòng tròn khép kín, nên khoảng cách giữa hai mốc kề nhau qua nửa đêm trở lại đúng bằng khoảng cách thật. Cùng lý do, ngày trong năm được mã hoá bằng `doy_sin` và `doy_cos` theo chu kỳ 365,25 ngày.

Thực nghiệm: chọn mốc trễ

Khái niệm nền. *Persistence* là mô hình dự báo cơ sở: lấy giá trị quan sát tại t làm dự báo cho $t + h$. Dev và cộng sự [14] định nghĩa nó là phương pháp *giả định điều kiện tại thời điểm dự báo không thay đổi so với thời điểm quan sát*, và ghi nhận rằng cách này *chạy tốt* ở các tầm dự báo ngắn, khi điều kiện thời tiết biến thiên chậm:

“The persistence forecasting method assumes that the conditions for the forecast do not change (especially for shorter lead times). This method works well in conditions when weather maps change very slowly with time.”

Từ định nghĩa trên suy ra một hệ quả đại số mà bài báo không nêu: nếu $\hat{y}(t + h) = y(t)$ thì đường dự báo chính là đường đo thật dịch phải h bước, tức lệch pha đúng bằng tầm dự báo. Mặt khác, vì chuỗi biến thiên chậm ở tầm ngắn, đúng điều kiện mà bài báo nói *persistence* chạy tốt, nên hiệu giữa $y(t)$ và $y(t + h)$ nhỏ, và một chỉ số sai số tính theo từng điểm vẫn cho con số đẹp.

Tầm H1 của dự án đúng bằng 15 phút, nằm trọn trong vùng đó. Một mô hình lặp lại giá trị vừa đo sẽ cho chỉ số sai số tốt nhưng đường dự báo trễ một nhịp, con số đẹp ở đây không chứng minh năng lực dự báo.

Giả thuyết. Mốc trễ càng gần thời điểm dự báo thì tín hiệu càng mạnh, nhưng cũng càng dễ kéo mô hình về đúng dạng vừa nêu. Thực nghiệm này xác định mốc trễ nào được đưa vào.

Cách tiến hành. Ba cấu hình được đối chiếu trên cùng dữ liệu và cùng quy trình tinh chỉnh: cấu hình nền chỉ có **lag_96** ($T - 24$ giờ), cấu hình thêm **lag_1** ($T - 15$ phút), và cấu hình thêm **lag_4** ($T - 60$ phút). Mỗi cấu hình được chấm bằng WAPE và một phép đo lệch pha riêng: độ trễ trung bình giữa đường dự báo và đường đo thật trên từng trạm, kèm số trạm vượt ngưỡng cho phép. Ba mốc đã thử ghi ở Bảng 6.12.

Bảng 6.12: Lựa chọn các mốc trễ chuỗi thời gian.

Mốc trễ	Quyết định	Căn cứ ghi trong notebook
lag_96 ($T - 24$ giờ)	giữ	Chu kỳ ngày; xa thời điểm dự báo nên không tạo lệch pha
lag_1 ($T - 15$ phút)	loại	Gây lệch pha trên gần như toàn bộ đội hình; sai số theo từng điểm giảm nhưng là hệ quả của việc lặp lại giá trị vừa đo
lag_4 ($T - 60$ phút)	giữ	Đủ xa để không lặp lại được giá trị vừa đo, vẫn đủ gần để mang thông tin quán tính; qua được công lệch pha ở Mục 6.3.1

Độc kết quả. Quyết định phân biệt **lag_1** với **lag_4** không dựa vào sai số mà dựa vào lệch pha. Nếu chỉ nhìn WAPE thì **lag_1** sẽ được chọn, vì nó cho con số thấp nhất, đúng như hệ quả đại số nêu ở đầu mục. Dự án chốt **LAGS = (4, 96)** và loại **lag_1**.

Cần nêu rõ giới hạn của bằng chứng này: notebook ghi lại quyết định và căn cứ định tính, không lưu một phép đối chứng có kiểm soát giữa ba cấu hình trên cùng một lần chạy. Bằng chứng định lượng cho cấu hình được chọn nằm ở cổng lệch pha trình bày ngay sau đây.

Cổng lệch pha đặt trước bước tinh chỉnh

Phép đo lệch pha được đặt thành một cổng chặn ở đầu notebook huấn luyện: chỉ khi cổng đạt thì quy trình mới được phép chạy Optuna và huấn luyện thật.

Độ trễ suy từ quan hệ giữa sai số và độ dốc của đường đo thật. Nếu đường dự báo bị dịch c bước thì sai số xấp xỉ $-c$ nhân với độ dốc, nên hệ số hồi quy của sai số theo độ dốc chính là c :

$$\text{độ trễ (phút)} = -\frac{\sum_t d_t e_t}{\sum_t d_t^2} \times 15, \quad d_t = \frac{y_{t+1} - y_{t-1}}{2}, \quad e_t = \hat{y}_t - y_t. \quad (6.4)$$

Cách này tách sai số biên độ khỏi sai số thời điểm: dự báo cao hơn hay thấp hơn thực tế đều không làm đổi con số, chỉ việc đến sớm hay đến muộn mới làm đổi.

Ngưỡng và kết quả. Cổng yêu cầu độ trễ nằm trong ± 5 phút và không trạm nào vượt ngưỡng. Kết quả in ra ở notebook 06_1_train_mae:

```

TRAIN THU NHANH DE DO TRE (truoc khi tune)
Train thu 300,000 dong x 54 dac trung trong 9.3 giay

TREN 288,735 diem ban ngay cua tap test:
Do tre      : +2.46 phut   (duong = du bao di SAU thuc te)
Nguong cho phep: +/- 5.0 phut
WAPE tham khao : 22.47%  (model nho, chua tune - chi de doi chieu)

Site vuot nguong: 0/40
Tre theo site: trung vi +2.79 phut | nho nhat +1.64 | lon nhat +3.71

CONG DO TRE: DAT - tre +2.46 phut, khong site nao vuot nguong.
Cho phep chay Optuna va train that.
```

Mô hình dùng ở cổng. Cổng chạy trên một mô hình nháp, cùng thuật toán và cùng hàm mất mát với mô hình cuối nhưng nhỏ hơn nhiều, xem Bảng 6.13.

Vì thuật toán, hàm mất mát và danh sách đặc trưng thống nhất với mô hình cuối, cổng kiểm được đúng thứ nó cần kiểm: bộ đặc trưng có đầy mô hình vào hành vi bám trụ hay không. Nếu lag_1 có mặt thì mô hình nháp cũng sao chép giá trị gần nhất y như mô hình cuối.

Ngưỡng là ± 5 phút và không trạm nào được vượt. Đo trên 288.735 điểm ban ngày, độ trễ là +2,46 phút, trung vị theo trạm +2,79 phút, dao động từ +1,64 đến +3,71, và 0/40 trạm vượt ngưỡng, nên cổng đạt. Cổng này đặt trước bước tinh chỉnh nên chỉ kiểm bộ đặc trưng; sau khi Optuna chọn xong siêu tham số (*hyperparameter*), notebook chạy tiếp một phép quét độ trễ thứ hai trên toàn bộ tập kiểm định, trình bày ở phần đánh giá.

Bảng 6.13: So sánh cấu hình mô hình nháp và mô hình chính thức.

	Mô hình nháp (cỗng)	Mô hình cuối
Thuật toán	LightGBM	LightGBM
Hàm mất mát	11 (MAE)	11 (MAE)
Số đặc trưng	53	53
Trọng số mẫu	có	có
Quy mô tập đầu vào	300.000 lấy ngẫu nhiên	1.550.856
Số cây	200, đặt cố định	Optuna chọn
Tốc độ học	0,08, đặt cố định	Optuna chọn
num_leaves	63, đặt cố định	Optuna chọn
Thời gian huấn luyện	9,3 giây	hàng chục phút

Rào chắn chống rò rỉ và ngữ cảnh lùi

Bước sinh đặc trưng đặt hai rào chắn. Một, mọi đặc trưng suy từ mục tiêu đều được dịch: các cột của sổ trượt tính trên chuỗi mục tiêu đã dịch một bước, nên giá trị tại T không bao giờ chứa sản lượng đo tại chính T . Hai, một mặt nạ lịch sử liên tục kiểm tra toàn bộ số bước của cửa sổ liền trước đều cách nhau đúng 15 phút; cửa sổ vắt qua chỗ đứt gãy thì bị gán khuyết thay vì tính bừa trên hai đoạn không liền nhau.

Ngữ cảnh lùi giải quyết về còn lại: mỗi tập được nối thêm lịch sử của tập liền trước trước khi tính đặc trưng, rồi chỉ xuất phần dòng thuộc chính tập đó. Tập test dùng toàn bộ tập Phát triển làm ngữ cảnh, tập kiểm định dùng tập huấn luyện, và phần kiểm định của mỗi fold dùng phần huấn luyện của chính fold đó. Nhờ vậy dòng đầu tiên của mỗi tập vẫn có đủ lịch sử, mà mỗi fold vẫn là một thí nghiệm khép kín.

Kết quả thực thi. Khối dưới đây trích nguyên văn kết quả kết xuất của notebook 03_1_features_time:

So đặc trưng target sẽ tạo: 2 lag + 8 rolling = 10 cột

Đã sinh đặc trưng thời gian cho development và test (đã ghi file và giải phóng RAM).

- development: 2273970 dòng x 74 cột
- test : 510468 dòng x 75 cột

Đã sinh đặc trưng thời gian cho train/val (đã ghi file và giải phóng RAM).

- train_alias: 1550856 dòng x 75 cột
- val_alias : 723114 dòng x 75 cột

fold_1: train 233244 dòng | val 606105 dòng | 76 cột
fold_2: train 839349 dòng | val 711507 dòng | 76 cột
fold_3: train 1550856 dòng | val 723114 dòng | 76 cột

Số lượng NaN trong các tập:

- Train: 21000 (Đã dropna ở bước 7)
- Val: 0
- Test: 0

0 điểm đứt gãy - lưới thời gian liên tục 100% nhờ Reindex Notebook 01.

(Tổng số dòng: 1550856)

Ô khuyết chỉ xuất hiện ở tập huấn luyện, tại các dòng đầu chuỗi chưa đủ 96 bước lịch sử để tính cửa sổ dài. Tập kiểm định và tập test không còn ô khuyết nào nhờ ngưỡng cảnh lùi.

6.3.2 Solar geometry, bức xạ trời quang và chuẩn hoá theo trạm

Notebook 03_2_features_spatial sinh nhóm đặc trưng suy từ vị trí Mặt Trời, còn 03_3_features_aggregate sinh nhóm tương tác khí tượng và mã hoá biến phân loại. Cả hai nhóm đều là hàm xác định của thời gian và vị trí hoặc là tổ hợp của các biến đã có, nên không mang rủi ro rò rỉ.

Vị trí Mặt Trời theo thuật toán NOAA

Góc cao h và góc phương vị được tính theo thuật toán vị trí Mặt Trời chuẩn của NOAA [34]. Nó dựa trên chuỗi Fourier cho độ xích vĩ, phương trình thời gian và góc giờ. Đây là công cụ tham chiếu chính thức.

Ba chi tiết cài đặt đáng nêu, tóm tắt ở Bảng 6.14.

Chi tiết	Trong mã nguồn	Lý do
Quy đổi về giờ UTC	<code>utc = ts - tz_gio</code> , với <code>tz_gio</code> bằng 11 cho tháng 10–3 và 10 cho tháng 4–9	Mốc trong dữ liệu là giờ địa phương của Úc , còn công thức thiên văn cần giờ UTC. Úc áp dụng giờ mùa hè nên độ lệch đổi theo mùa
Góc phương vị	<code>np.arctan2(...)</code> thay cho <code>arccos</code>	<code>arccos</code> chỉ trả về miền $[0^\circ; 180^\circ]$ nên không phân biệt được buổi sáng với buổi chiều; <code>atan2</code> liên tục trên trọn vòng 360°
Dạng vòng của góc	<code>azimuth_sin, azimuth_cos</code>	Góc đo bằng độ gián đoạn ở mốc 0° và 360° : 359° và 1° kề nhau thực tế nhưng cách xa trên thang số

Bảng 6.14: Chi tiết cài đặt các tham số hình học Mặt Trời.

Cách cắt mùa theo nguyên tháng là một xấp xỉ: giờ mùa hè ở Úc bắt đầu Chủ nhật đầu tiên của tháng 10 và kết thúc Chủ nhật đầu tiên của tháng 4, nên vài ngày đầu hai tháng đó nhận độ lệch chênh một giờ, khoảng 12 ngày mỗi năm.

Bức xạ trời quang theo mô hình Haurwitz

GHI (*Global Horizontal Irradiance*) là tổng bức xạ Mặt Trời chiếu xuống một mặt phẳng nằm ngang, đơn vị W/m^2 . Nó gồm hai thành phần cộng lại: phần trực xạ đi thẳng từ đĩa Mặt Trời và phần khuếch tán do bầu khí quyển và mây tán xạ. Trong dữ liệu của dự án, hai đại lượng này nằm ở hai cột khác nhau và không được lẫn:

- `shortwave_radiation` — GHI đo được thực tế, do Open-Meteo cung cấp.

- **ghi_cs** — GHI_{cs} , giá trị lý thuyết khi trời hoàn toàn quang, do nhóm **tự tính** bằng mô hình Haurwitz từ góc cao Mặt Trời.

Vì GHI_{cs} ứng với điều kiện không mây, nó là mức trần mà bức xạ đo được chỉ có thể tiệm cận chứ không nên vượt qua.

Từ góc cao suy ra bức xạ ngang trời quang:

$$GHI_{cs} = 1098 \times \sin(h) \times \exp\left(-\frac{0,059}{\sin(h)}\right) \quad (\text{W/m}^2) \quad (6.5)$$

Cặp hằng số 1098 và 0,059 lấy đúng bản cài đặt Haurwitz của thư viện **pvlib**, vốn dẫn về hai bài gốc của Haurwitz [11]. Phần tóm tắt của bài báo nguồn phát biểu dạng công thức như sau:

“These relations are of the form $T = (a/m)e^{-bm}$ where $m = \text{air mass (i.e. secant of zenith distance of the sun)}$, $e = \text{base of natural logarithms}$, a and b are constants which depend on the cloudiness and cloud density.”

Mô hình trời quang thuần thiên văn ước lượng thiếu so với bức xạ đo tại các trạm, nên GHI_{cs} được nhân thêm hệ số hiệu chỉnh riêng từng trạm, đặt tên **cs_factor**. Hệ số này tính riêng trên phần huấn luyện của từng fold, xem Bảng 6.15.

Bảng 6.15: Hệ số hiệu chỉnh trời quang **cs_factor** theo từng fold.

Phạm vi tính	Trung vị	Nhỏ nhất	Lớn nhất
Phần huấn luyện fold 1	1,460	1,105	1,827
Phần huấn luyện fold 2	1,538	1,520	1,819
Phần huấn luyện fold 3	1,557	1,541	1,809

Giá trị đổi rõ giữa các fold, trung vị từ 1,460 lên 1,557, nên việc dùng chung một bộ thống kê cho cả ba fold sẽ đưa thông tin của giai đoạn sau vào fold sớm. Notebook ghi thẳng nguyên tắc này ở ô kết quả: *mỗi fold dùng thống kê quy mô tính riêng từ tập train của chính fold đó*.

Thực nghiệm: hạ độ hạt bức xạ từ một giờ về mười lăm phút

Vấn đề. Dữ liệu khí tượng có tần suất một giờ, còn lưới sản lượng có tần suất 15 phút, nên mỗi giá trị bức xạ lặp lại bốn lần liên tiếp: trong một giờ, đặc trưng bức xạ không phân biệt được mốc 12:00 với mốc 12:15.


Nguyên lý. Bailey và cộng sự [12] mô tả thuật toán của Graham và Hollands (1990): tách chỉ số trời quang theo giờ k_t thành mô hình cộng $k_t = k_{tm} + \alpha$ gồm thành phần xu thế và thành phần nhiễu. Điểm cốt lõi là hạ độ hạt của chỉ số trời quang chứ không phải bức xạ, vì bức xạ mang cả biến thiên nhật triều, còn chỉ số trời quang thì không.

Dự án giữ đúng thành phần xu thế k_{tm} , giữ chỉ số trời quang không đổi trong mỗi khối giờ rồi nhân lại với GHI_{cs} tính ở từng mốc 15 phút, và bỏ thành phần nhiễu α , vì α dùng để sinh chuỗi tổng hợp, còn ở đây bức xạ là đặc trưng đầu vào cho mô hình dự báo.

Kết quả đo. Thước đo là tỷ lệ bước có giá trị bức xạ thay đổi so với bước liền trước, tính riêng trên các dòng ban ngày. Khối kết quả của notebook:

--- TY LE BUOC CO GIA TRI BUC XA THAY DOI, TOAN TAP TRAIN (CHI BAN NGAY) ---
 So dong ban ngay: 751,408 / 1,550,856 (48.5%)
 Truoc downscale : 26.7%
 Sau downscale : 76.7%
 Muc tieu la tren 90 phan tram.
 [CANH BAO] Chua dat 90 phan tram,kiem lai buoc downscale.

Tỷ lệ tăng gần ba lần, từ 26,7% lên 76,7%. Hình 6.10 cho thấy hiệu quả trên một cửa sổ sáu giờ.



Hình 6.10: Làm mịn và nội suy dữ liệu bức xạ bước 15 phút tại trạm 1.

Chuẩn hoá quy mô theo trạm

Bốn mươi hai dàn quang điện có quy mô rất khác nhau, nên quy mô được ước lượng từ chính dữ liệu và chỉ từ phần huấn luyện: `site_scale` là phân vị 99 của sản lượng ban ngày, `tran_cong_suat` là phân vị 99,9. Bảng 6.16 trích tám trạm đầu trong bảng notebook in ra.

Một mô hình học thẳng trên sản lượng thô sẽ dành phần lớn sức mô tả để phân biệt trạm lớn với trạm nhỏ, thay vì học quan hệ giữa thời tiết và sản lượng, đó là lý do mục tiêu được chuẩn hoá trước khi huấn luyện.

Tương tác khí tượng và mã hoá biến phân loại

Notebook 03_3_features_aggregate sinh năm đặc trưng tương tác, xem Bảng 6.17.

Tỷ lệ khuyết 47,43% (735.612 dòng) của hai đặc trưng dạng thương đến từ mẫu số: ban đêm bức xạ ngang bằng 0 nên phép chia không xác định. Giá trị khuyết được giữ nguyên thay vì điền 0, để mô hình cây học nhánh riêng cho dữ liệu khuyết. Số giá trị vô cực trên cả năm cột bằng 0.

Bảng 6.16: Quy mô công suất 8 trạm quang điện tiêu biểu.

Trạm	site_scale	tran_cong_suat	cs_factor
27	97,19	99,00	1,55
11	92,05	92,72	1,74
25	79,73	82,42	1,55
19	41,73	42,80	1,55
18	35,04	36,21	1,55
6	27,53	28,51	1,74
8	26,50	26,89	1,74
1	21,50	22,73	1,70

Bảng 6.17: Tương quan của các đặc trưng tương tác với mục tiêu.

Đặc trưng	Định nghĩa	Khuyết	Pearson
temp_x_shortwave	nhiệt độ × bức xạ ngang	0,01%	0,3487
diffuse_ratio	bức xạ khuếch tán / bức xạ ngang	47,43%	-0,2350
dni_ratio	bức xạ trực xạ / bức xạ ngang	47,43%	0,2350
cloud_x_shortwave	mây toàn phần × bức xạ ngang	0,01%	0,1921
cloud_low_x_shortwave	mây tầng thấp × bức xạ ngang	0,01%	0,1650

Mã hoá biến phân loại. Bảng mã được khớp chỉ trên phía huấn luyện rồi áp cho phía kiểm định; notebook khớp được 8 bảng mã, và số ô gặp hạng mục lạ trên tập kiểm định bằng 0.

Kiểm chứng cuối bước sinh đặc trưng. Notebook in ra ba phép kiểm:

```

--- KIEM TRA 1: dac trung target deu duoc shift ---
Cot lag con lai sau khi khu tre pha: ['lag_4', 'lag_96']
lag_96(t) == target(t-96) tren mau: DAT
--- KIEM TRA 2: ty le dong co lich su day du ---
- train      : 99.74% dong co du lich su lien tục
- val        : 100.00% dong co du lich su lien tục
--- KIEM TRA 3: hang muc la (unseen category) ---
Tong so o gap hang muc la trong val: 0

```

Sau ba notebook sinh đặc trưng, tập huấn luyện đi từ 50 cột lên 114 cột, trong đó 46 cột là đặc trưng ứng viên; các fold mang 115 cột do có thêm cột đánh dấu fold.

6.3.3 Định nghĩa các đặc trưng dẫn xuất

Một số cột xuất hiện trong bảng chẩn đoán và bảng chấm điểm ở Mục 6.3.7 là đại lượng dẫn xuất, không đọc thẳng từ dữ liệu nguồn. Bảng 6.18 ghi công thức của chúng.

Về các cột bị loại. Hai cột `con_cach_tran` và `clearsky_proxy` được sinh ra ở bước đặc trưng nhưng không lọt vào bộ được chọn. `clearsky_proxy` tương quan 0,9973 với

Bảng 6.18: Công thức toán học các đặc trưng dẫn xuất.

Đặc trưng	Công thức	Ý nghĩa
ky_vong	$\text{site_scale} \times \max(\sin h, 0)$	Mức sản lượng kỳ vọng của trạm tại góc cao hiện tại, nếu trời hoàn toàn quang
ty_le_bao_hoa	$\text{clip}\left(\frac{\text{ky_vong}}{\text{tran_cong_suat}}, 0, 3\right)$	Mức kỳ vọng đã tiến sát trần công suất tới đâu
con_cach_tran	$\text{tran_cong_suat} - \text{ky_vong}$	Khoảng dư còn lại tới trần, tính bằng kWh
rad_x_sinelev	$\text{shortwave_radiation} \times \sin h$	Bức xạ chiếu hiệu dụng lên mặt phẳng ngang
clearsky_proxy	$(\sin h)^{1,2}$	Dạng đường cong ngày thuần hình học, nhọn hơn $\sin h$ một chút
chi_so_troi_quang	$\text{clip}\left(\frac{\text{shortwave_radiation}}{\text{ghi_cs}}, 0, 1,5\right)$	Tỷ lệ bức xạ đo được trên bức xạ trời quang đã hiệu chỉnh theo trạm
temp_x_shortwave	$\text{temperature_c} \times \text{shortwave_radiation}$	Tương tác nhiệt độ và bức xạ
diffuse_ratio	$\text{clip}\left(\frac{\text{diffuse_solar_rad.}}{\text{shortwave_rad.}}, 0, 10\right)$	Phần khuếch tán chiếm bao nhiêu trong tổng bức xạ
cloud_x_shortwave	$\text{cloud_cover_total} \times \text{shortwave_radiation}$	Tương tác mây toàn phần và bức xạ

$\sin_elevation$ nên mang thông tin trùng lặp, còn con_cach_tran không đạt ngưỡng thông tin tương hỗ.

Một đỉnh chính về tên gọi. Tên chi_so_troi_quang gợi ý rằng giá trị 1,0 tương ứng trời hoàn toàn quang. Phép kiểm chứng cho thấy điều đó không đúng với cột này: sau khi GHI_{cs} đã nhân hệ số hiệu chỉnh theo trạm, tỷ lệ đo được không đạt tới 1,0 ngay cả vào lúc quang nhất giữa trưa, giá trị lớn nhất ở nhóm góc cao 50–90° chỉ đạt 0,760. Vì vậy tài liệu này không mô tả nó như một chỉ số trời quang có ý nghĩa vật lý trực tiếp, mà gọi đúng bản chất là biến tỷ lệ bức xạ đã hiệu chỉnh theo từng trạm. Nó vẫn hữu ích làm đặc trưng đầu vào vì thứ tự giữa các quan sát trong cùng một trạm được bảo toàn, mà cây quyết định chỉ dùng thứ tự để tách nhánh.

Về cột pv_clr_lonij . Dự án có cài đặt chỉ số K của Lonij đúng nguyên bản phân vị 80, cửa sổ trượt 15 ngày theo từng khung giờ, có $\text{shift}(1)$ nên chỉ nhìn quá khứ thành cột pv_clr_lonij . Cột này đạt điểm quan trọng biến 1,959, đứng hạng 6 trong bảng chẩn đoán ở Mục 6.3.7, nhưng không lọt Top 35 theo thông tin tương hỗ và không nằm trong danh sách bảo vệ, nên bị loại ở bước chọn theo đúng quy tắc đã đặt trước.

Cột này nối trực tiếp với lập luận về mức phân vị ở Mục 6.3.5: dự án cài cả phương án phân vị 80 của Lonij lẫn phương án phân vị 99 của mình, rồi để bước chấm điểm quyết định bằng số liệu thay vì chọn trước bằng lập luận.

6.3.4 Thực nghiệm: khử độ trễ cài sẵn bằng đặc trưng tại thời điểm mục tiêu

Vấn đề. Nhãn cần dự báo nằm ở thời điểm $T+h$, nhưng các đặc trưng hình học Mặt Trời và nhãn lịch `sin_elevation`, `ghi_cs`, `hour` vẫn là giá trị tại T . Mô hình do đó dùng vị trí Mặt Trời lúc T để dựng lại sản lượng lúc $T+h$, và đường dự báo sinh ra chính là đường Mặt Trời bị trễ đúng h bước. Đây là hệ quả cấu trúc của bài toán, và tác động của nó lan rộng vì cùng đại lượng đó cũng là mẫu số chuẩn hoá ở Mục 6.3.5.

Cách xử lý. Quy trình khai báo một danh sách 22 cột tất định hình học Mặt Trời cùng các đại lượng suy ra từ nó, và toàn bộ nhãn thời gian theo lịch rồi sinh thêm bản của chúng tại $T+h$ với hậu tố `_mt`, đồng thời giữ nguyên bản tại T . Ở tầm H1 sinh được 14 cột, nâng tổng số đặc trưng vào mô hình từ 39 lên 53.

Ranh giới hợp lệ của phép dịch. Vị trí Mặt Trời và nhãn lịch tại $T+h$ là kết quả tính toán thiên văn và lịch thuần tuý; đứng ở thời điểm T đã biết chính xác chúng bằng bao nhiêu, không cần chờ tới $T+h$ mới đo. Điều này khác hẳn biến khí tượng: bức xạ và mây tại $T+h$ chỉ biết được sau khi đo, nên `shortwave_radiation`, `lag_96` và toàn bộ nhóm `rolling_*` bắt buộc giữ nguyên ở T . Ranh giới đó chính là điều kiện để phép dịch này hợp lệ.

Thêm chứ không thay thế. Phương án thay thế hẳn bản tại T bằng bản tại $T+h$ đã được thử và bị bác bỏ bằng số liệu. Phép đo lấy sai số MAE của đường bao $\hat{y} = \text{site_scale} \times \sin h$ so với sản lượng thật trên tập Phát triển, tính riêng theo khung giờ, cho kết quả ở Bảng 6.19.

Bảng 6.19: So sánh đặc trưng tất định tại T và $T+h$.

Khung giờ	Số dòng	Dùng tại T	Dùng tại $T+h$	Chênh
Toàn bộ ban ngày	999.010	3,1425	3,1296	-0,4%
Sáng 06–09h	246.305	2,1580	2,7258	+26,3%
Chiều 16–18h	189.966	2,9646	2,4136	-18,6%

Hai khung giờ cho hai kết luận ngược nhau, nên không phương án nào thắng tuyệt đối. Trên toàn bộ ban ngày hai bản chênh nhau 0,4%, tức gần như tương đương; chênh lệch chỉ lộ ra khi tách theo khung giờ. Buổi sáng sản lượng thật đi sau Mặt Trời, vì tấm pin còn lạnh và ẩm sương, inverter đang trong giai đoạn khởi động, nên giá trị tại T khớp hơn 26,3%; buổi chiều thì ngược lại, giá trị tại $T+h$ khớp hơn 18,6%. Quy trình vì vậy giữ cả hai bản và để mô hình tự chọn theo khung giờ, thay vì áp một phương án cho cả ngày.

6.3.5 Chuẩn hoá mục tiêu theo vật lý

Bốn mươi trạm có quy mô chênh nhau nhiều lần, và sản lượng trong ngày biến thiên theo góc cao Mặt Trời. Nếu huấn luyện thẳng trên sản lượng thô, mô hình phải dành phần lớn sức mô tả để

phân biệt trạm lớn với trạm nhỏ và để học lại nhip ngày đêm, hai thứ đã biết trước bằng công thức. Mục tiêu vì vậy được đổi sang một tỷ số không thứ nguyên:

$$k_{\text{target}} = \text{clip}\left(\frac{y}{\text{site_scale} \times \max(\sin h, \varepsilon)}, 0, k_{\text{max}}\right) \quad (6.6)$$

Mẫu số gồm hai phần: `site_scale` khử chênh lệch quy mô giữa các trạm, còn $\sin h$ khử nhip ngày đêm. Phép `max` đặt một sàn ε cho mẫu số, vì lúc Mặt Trời sát đường chân trời thì $\sin h \rightarrow 0$ và tỷ số sẽ nổ tung.

Sau khi mô hình dự báo $\hat{k}$, giá trị được nhân ngược về kWh rồi chặn trần:

$$\hat{y} = \min\left(\hat{k} \times \text{site_scale} \times \max(\sin h, \varepsilon), \text{tran_cong_suat} \times 1,02\right) \quad (6.7)$$

Cả `site_scale` và `tran_cong_suat` đều là phân vị của chính chuỗi sản lượng nên mang đơn vị kWh trên mỗi bước 15 phút, cùng đơn vị với y ; phép chặn vì vậy không cần hệ số đổi đơn vị nào.

Cơ sở của cách chuẩn hoá. Việc chia sản lượng đo được cho một mức tham chiếu suy từ chính hệ thống là cách làm đã có trong tài liệu. Engerer và Mills [13] tổng kết các phương pháp trước đó và dẫn lại chỉ số K của Lonij và cộng sự [19], vốn định nghĩa mức tham chiếu bằng một phân vị của chính sản lượng đo được.

Điểm cần đọc kỹ ở tài liệu nguồn là không có một mức phân vị chuẩn. Ngay trên cùng một trang tổng kết, hai công trình tiền lệ chọn hai mức khác hẳn nhau. Golnas lấy phân vị 93:

“After removing days with system outages, the clear-sky BPI (CSBPI) for each system is defined as the 93rd percentile of the set of BPI values in the training set.”

Còn Lonij và cộng sự [19] lấy phân vị 80:

“ PV_{CLR-L} is defined as the 80th percentile of PV_{MEAS-L} at the specified time of day on the previous 15 days for a system.”

Hai mức chênh nhau 13 điểm mà cả hai đều được công bố, vì mỗi bên dựng mẫu số theo một cách. Điều đó có nghĩa mức phân vị là tham số thiết kế đi kèm cách dựng mẫu số, không phải hằng số vật lý mượn được từ tài liệu. Mức của dự án vì vậy phải được biện minh bằng thực nghiệm trên chính dữ liệu của dự án.

Cận cắt suy từ dữ liệu, không đặt tay. Tham số k_{max} không được gán một hằng số trong tệp cấu hình. Notebook huấn luyện đặt `CLIP_K = None` rồi gọi hàm `tinh_clip_tu_train()` để tính nó bằng phân vị 99 của k trên chính tập huấn luyện. Giá trị thu được và ghi vào `model_config.json` là 1,3764, tính trên 681.536 giá trị k . Mức phân vị 99 được chọn bằng phép quét ở Bảng 6.20.

Đường cong WAPE phẳng từ mức 0,99 trở lên, ba mức cuối chỉ chênh nhau 0,0000 điểm phần trăm. Bên dưới mức đó thì sai số xấu dần, tới 25,2239% ở phân vị 0,90 vì cắt mất 10% dữ liệu. Dòng

Bảng 6.20: Quét ngưỡng phân vị cận cắt trên tập kiểm định.

Mức phân vị	Ngưỡng cắt	Tỷ lệ bị cắt (%)	WAPE kiểm định (%)
0,900	1,1412	10,00	25,2239
0,950	1,2200	5,00	25,0739
0,975	1,2916	2,50	25,0267
0,990	1,3782	1,00	25,0141
0,995	1,4508	0,50	25,0135
0,999	1,7266	0,10	25,0135
1,000	7,4245	0,00	25,0135

cuối cùng cho thấy phép cắt vẫn cần thiết: bỏ hẳn nó thì ngưỡng nhảy lên 7,4245, tức đuôi phân bố có những điểm gấp gần mười lần phần thân. Mức 0,99 là điểm mà đường cong bắt đầu phẳng mà vẫn chặn được đuôi đó.

Hai giá trị ngưỡng trong báo cáo. Bảng 6.20 ghi ngưỡng 1,3782 tại mức 0,99, còn tệp cấu hình mô hình ghi 1,3764. Hai con số này không mâu thuẫn: cùng một mức phân vị nhưng tính trên hai tập khác nhau. Phép quét chạy trên tập kiểm định để đo WAPE tương ứng với từng mức, nên ngưỡng của nó là phân vị 99 của k trên tập kiểm định (307.342 giá trị ban ngày đo thật, đọc từ 05e_kiem_chung/con_so_bao_cao.json). Ngưỡng thực sự nạp vào mô hình bắt buộc phải suy từ tập huấn luyện, nên nó là phân vị 99 của k trên tập huấn luyện (681.536 giá trị), bằng 1,3764. Giá trị dùng để huấn luyện và để chấm điểm ở Mục 6.5 là 1,3764.

Hạn chế: ngưỡng cắt dùng chung cho hai tầm dự báo. Ngưỡng 1,3764 được tính ở tầm H1 rồi dùng lại cho tầm H4. Tính riêng cho H4 thì phân vị 99 của k là 2,0156. Nguyên nhân nằm ở cấu tạo của k : mẫu số lấy $\sin h$ tại thời điểm T , còn tử số là sản lượng tại $T + h$. Ở tầm 15 phút Mặt Trời gần như đứng yên nên hai vế khớp nhau; ở tầm 60 phút, buổi sáng Mặt Trời lên nhanh nên mẫu số nhỏ hơn hẳn tử số và k giàu lên.

Hệ quả đo được: dùng ngưỡng của H1 cho H4 thì tỷ lệ nhận bị cắt tăng từ 1,00% lên 8,59%, và phần bị cắt dồn vào sườn lên buổi sáng, xem Bảng 6.21.

Bảng 6.21: Tỷ lệ nhận bị cắt theo khung giờ trong ngày.

Giờ	H1 bị cắt	Tỷ lệ H1	H4 bị cắt	Tỷ lệ H4
6	4	0,05%	3.192	42,98%
7	226	0,61%	13.505	36,17%
8	454	0,75%	18.004	29,92%
9	847	1,41%	13.942	23,17%
10	1.352	2,25%	7.172	11,93%
11	1.079	1,80%	2.113	3,52%
12	822	1,37%	514	0,86%
13–19	2.032	$\approx 0,6\%$	99	$< 0,1\%$
Tổng	6.816	1,00%	58.541	8,59%

Ngưỡng này chặn ở cả hai đầu: lúc huấn luyện nó cắt cụt nhãn, và lúc dự báo nó chặn luôn đầu ra vì đầu ra cũng đi qua cùng phép cắt trước khi nhân ngược. Với tầm H4 vào buổi sáng, mô

hình vừa không được học giá trị thật vừa bị áp trần khi dự báo, nên phần sườn lên bị hụt biên độ. Buổi chiều không có hiện tượng này vì Mặt Trời xuống nên tử số nhỏ hơn mẫu số.

Sửa đúng cách là gọi lại `tinh_clip_tu_train()` trong bước chuẩn bị ma trận của tầm H4. Việc đó kéo theo huấn luyện lại toàn bộ H4 và chạy lại cả dây chuyền đánh giá, nên nằm ngoài phạm vi đợt này và được ghi vào hướng phát triển ở Mục 6.8.3. Mọi con số H4 trong báo cáo đều là số của cấu hình đang dùng ngưỡng 1,3764.

6.3.6 Kiểm chứng các tham số cố định

Bốn tham số được gán giá trị cố định trong tệp cấu hình. Notebook `05b_thuc_nghiem_tham_so_hardcode` quét từng tham số qua nhiều mức, giữ nguyên mọi thứ còn lại, rồi huấn luyện và chấm lại trên tập kiểm định. Kết quả ở Bảng 6.22.

Bảng 6.22: Thực nghiệm quét 4 tham số cố định trên tập kiểm định.

Tham số	Mức	Dòng huấn luyện	WAPE (%)	RMSE	R^2
eps_elev	0,00	604.200	20,7838	3,5100	0,8908
	0,02	602.937	20,6678	3,4990	0,8915
	0,05	599.174	20,7345	3,5098	0,8908
	0,10	582.252	20,6486	3,4967	0,8916
	0,15	557.266	20,7176	3,5049	0,8911
$k_{\max}$	1,0	599.174	23,4990	3,7697	0,8740
	1,2	599.174	20,9647	3,5358	0,8892
	1,5	599.174	20,7345	3,5098	0,8908
	2,0	599.174	20,7344	3,5098	0,8908
	3,0	599.174	20,7344	3,5098	0,8908
Hệ số nói trần	1,00	599.174	20,7358	3,5111	0,8907
	1,02	599.174	20,7345	3,5098	0,8908
	1,05	599.174	20,7332	3,5088	0,8909
	1,10	599.174	20,7327	3,5084	0,8909
Trọng số vùng đỉnh	0,0	599.174	20,6603	3,5129	0,8906
	0,5	599.174	20,6775	3,5019	0,8913
	1,0	599.174	20,7345	3,5098	0,8908
	2,0	599.174	20,8405	3,5193	0,8902

Bảng này phải đọc trung thực, vì không phải tham số nào cũng có tác động như nhau.

Sàn mẫu số ε không quyết định độ chính xác. Toàn dải từ 0,00 tới 0,15 chỉ chênh nhau 0,1352 điểm phần trăm WAPE. Cái mà ε thực sự điều khiển là số dòng còn lại để huấn luyện: từ 604.200 xuống 557.266, mất 7,8%. Hai con số này là hai đầu của dải quét, ứng với $\varepsilon = 0,00$ và $\varepsilon = 0,15$, đọc từ ô kết quả notebook `05b_thuc_nghiem_tham_so_hardcode.ipynb` và cột `so_dong_train` của tệp `05b_thuc_nghiem_tham_so/thuc_nghiem_tham_so_hardcode.csv`. Mức 0,05 ứng với góc nâng $\arcsin(0,05) = 2,87^\circ$. Tỷ lệ dòng giữ lại được so với mức không lọc là

$$\frac{599.174}{604.200} = 0,991682 \rightarrow \mathbf{99,17\%} \quad (6.8)$$

Con số này là tỷ lệ trên các dòng thực sự vào hàm mục tiêu của phép quét ở Bảng 6.22. Tính trên toàn bộ tập huấn luyện trước khi áp trọng số mẫu thì tỷ lệ là $681.536/709.954 = 96,00\%$; hai con số này đọc từ dòng **Bi loai khoi ham muc tieu** ở ô kết quả của cùng notebook trên. Hai con số khác nhau vì hai phạm vi khác nhau; báo cáo dùng 99,17% đúng theo phạm vi của bảng.

Phần bị loại nhỏ như vậy vì vành $0 < \sin h \leq 0,05$ rất hẹp và gần như không phát điện. Notebook `05e_kiem_chung_con_so_bao_cao.ipynb` đo lại trên phạm vi khai báo tường minh: tập huấn luyện, giữ những dòng có nhãn tại $T+15$ phút là số đo thật ban ngày và không bị loại khỏi huấn luyện, còn 635.564 dòng. Trung bình mỗi trạm mỗi ngày có 40,8 bước trong phạm vi đó, trong đó chỉ 0,35 bước rơi vào vành. Sản lượng trung bình một bước trong vành là 0,4238 kWh, so với 6,7349 kWh ở các bước còn lại, kém 16 lần. Cộng lại, phần sản lượng nằm trong vành là

$$\frac{2.279 \text{ kWh}}{4.240.381 \text{ kWh}} = 0,000537 \rightarrow \mathbf{0,054\%} \quad (6.9)$$

Đặt sàn ở 0,05 vì vậy chặn được vùng mẫu số tiến về 0 mà chỉ bỏ đi khoảng năm phần vạn sản lượng ban ngày. Mọi con số trong đoạn này đọc từ tệp kết quả `05e_kiem_chung/con_so_bao_cao.json`.

Cận cắt $k_{\max}$ là tham số có tác động rõ. Hạ xuống 1,0 làm WAPE xấu đi 2,76 điểm, vì cắt mất phần thân của phân bố chứ không chỉ đuôi. Nới lên 2,0 và 3,0 cải thiện thêm 0,0001 điểm ở cả hai mức, nhưng đổi lại thì phép cắt gần như mất tác dụng chặn các điểm đo bất thường. Giá trị dùng thật là 1,3764 suy từ phân vị 99 của tập huấn luyện, nằm giữa hai mức 1,2 và 1,5 của phép quét.

Hệ số nới trần không phải lựa chọn về độ chính xác. Bốn mức từ 1,00 tới 1,10 chênh nhau 0,0031 điểm WAPE, tức nằm trong mức nhiễu. Hệ số 1,02 được chọn theo lý do vật lý: chừa 2% dư địa quanh trần để không cắt oan các dao động ngắn do hiện tượng tăng cường bức xạ ở mép mây, chứ không phải khẳng định công suất lắp đặt thực tế cao hơn 2%.

Trọng số vùng đỉnh làm WAPE tổng thể xấu đi. Tắt hẳn cho 20,6603%, thấp hơn mức đang dùng 0,0742 điểm. Đây là một đánh đổi có chủ đích chứ không phải tham số bị bỏ quên: trọng số này kéo mô hình chú ý vào khung giờ phát điện mạnh, nơi sai số có giá trị vận hành lớn nhất, và trả giá bằng một phần nhỏ sai số trung bình trên toàn tập.

Ngưỡng cắt chỉ số trời quang. Tham số CLIP_CSI chặn tỷ lệ bức xạ đo trên bức xạ trời quang. Bảng 6.23 cho thấy nó ảnh hưởng tới bao nhiêu điểm bị cắt.

Bảng 6.23: Số lượng điểm dữ liệu bị cắt bởi ngưỡng CLIP_CSI.

Ngưỡng	Số điểm bị cắt	Tỷ lệ (%)
1,0	39.265	5,4592
1,1	33.127	4,6058
1,2	28.684	3,9880
1,3	24.393	3,3915
1,5	18.689	2,5984
2,0	11.179	1,5543

Ngưỡng 1,0 ứng với giả định bức xạ đo không bao giờ vượt bức xạ trời quang lý thuyết, giả

định đó cắt 5,46% số điểm, quá nhiều để coi là hợp lý, vì hiện tượng tăng cường bức xạ ở mép mây làm bức xạ đo vượt mức trời quang trong thời gian ngắn là có thật. Ngưỡng 1,5 cắt 2,60%, giữ lại phần vượt trần do vật lý và chỉ loại phần vượt xa.

6.3.7 Chẩn đoán và chọn đặc trưng

Sau ba notebook sinh đặc trưng, tập huấn luyện mang 114 cột. Hai notebook tiếp theo quyết định cột nào thực sự đi vào mô hình, với vai trò tách bạch: `04_vif_diagnostics` đo và xuất bằng chứng, `05_select_features` quyết định. Notebook chẩn đoán không tự loại cột nào — nó ghi bảng chỉ số ra tệp để bước chọn đọc lại.

Cách phân vai này có lý do: hệ số phóng đại phương sai chỉ đo mức một đặc trưng bị các đặc trưng còn lại giải thích, không đo mức đặc trưng đó giải thích được mục tiêu. Một cột có thể vừa cộng tuyến cao vừa mang thông tin vật lý không thay thế được, nên máy không được quyền tự loại.

Chẩn đoán đa cộng tuyến

Trong 114 cột, 86 cột được đưa vào chẩn đoán; 28 cột còn lại nằm ngoài phạm vi vì là mục tiêu, khoá định danh, cột ghi nguồn gốc dữ liệu, cờ ngoại lai hoặc cột thời gian thô. Kết quả phân loại trình bày ở Bảng 6.24.

Bảng 6.24: Phân bố chẩn đoán đa cộng tuyến trên 86 đặc trưng.

Nhãn	Số cột	Nghĩa
HIGH_VIF	41	Hệ số phóng đại phương sai vượt 10
OK	27	Không vướng tiêu chí nào
CONSTANT	9	Chỉ một giá trị duy nhất, phương sai bằng 0
DUPLICATE	8	Trùng lặp gần hoàn hảo với một cột khác
HIGH_MISSING	1	Tỷ lệ khuyết quá cao
Tổng	86	

Cột duy nhất mang nhãn khuyết cao là `source_gap_id` với 97,68% ô trống đúng bản chất của nó, vì nó chỉ nhận giá trị tại các dòng nằm trong một khoảng trống nguồn.

Cột trùng lặp. Ở ngưỡng $|r| \geq 0,95$ notebook đếm được 44 cặp, nhưng chỉ những cặp đạt $|r| \geq 0,9999$ mới bị coi là trùng lặp thực sự, vì cộng tuyến hoàn hảo khiến phép tính hệ số phóng đại phương sai không xác định. Tám cột bị loại ở bước này, xem Bảng 6.25.

Sáu nhóm đầu là các cách mã hoá khác nhau của cùng một đại lượng thời gian, sinh ra ở các bước khác nhau của quy trình rồi cùng tồn tại. Cặp `diffuse_ratio` và `dni_ratio` có $r = -1,0000$ vì hai tỷ lệ này cộng lại bằng 1 theo định nghĩa. Sau bước loại trùng, số đặc trưng còn 78.

Hệ số phóng đại phương sai. Bảng 6.26 lấy tám cột cao nhất.

Ba cột bức xạ đạt mức chặn trên vì GHI bằng tổng của thành phần trực xạ chiếu xuống mặt ngang và thành phần khuếch tán, nên biết hai cột là suy ra được cột còn lại. Cặp `site_scale` và `tran_cong_suat` có $r = 0,9999$ vì cả hai là phân vị 99 và phân vị 99,9 của cùng một chuỗi sản lượng.

Bảng 6.25: Các cặp đặc trưng trùng lặp và cột đại diện giữ lại.

Cột bị bỏ	Đại diện giữ lại	Số giá trị phân biệt
quarter_hour	minute_of_day	96
hour_of_day	hour	24
hour_bucket_raw	hour	24
hour_bucket_model	hour	24
day_of_week_model	day_of_week	7
month_model	month	12
number_of_panels_missing_flag	capacity_kw_missing_flag	2
dni_ratio	diffuse_ratio	37.341

Bảng 6.26: Tám đặc trưng có hệ số phóng đại phương sai (VIF) cao nhất.

Đặc trưng	VIF	Nguồn cộng tuyến
direct_normal_irradiance	9999	Ba cột bức xạ ràng buộc nhau qua quan hệ hình học
diffuse_solar_radiation	9999	
shortwave_radiation	9999	
tran_cong_suat	7.567,53	Cùng suy từ phân vị sản lượng của một trạm
site_scale	7.516,67	
day_of_year	5.228,18	Trùng thông tin với biến tháng
month	5.186,16	
sin_elevation	2.846,97	Hàm xác định của cùng góc cao Mặt Trời

Không cột nào trong Bảng 6.26 bị loại. Cộng tuyến làm hệ số của mô hình tuyến tính mất ổn định, nhưng mô hình dùng ở đây là cây quyết định tăng cường gradient nó chọn điểm cắt theo mức giảm hàm mất mát chứ không giải hệ phương trình chuẩn tắc, nên không chịu ảnh hưởng đó.

Đối chiếu bằng một phương pháp độc lập. Để không quyết định chỉ dựa trên một thước đo, notebook chạy thêm hồi quy bình phương tối thiểu riêng phần và lấy điểm quan trọng biến, đo theo hiệp phương sai với mục tiêu thay vì theo cộng tuyến giữa các đặc trưng. Bảy đặc trưng đứng đầu được ghi ở Bảng 6.27.

Bảng 6.27: Đặc trưng dẫn đầu theo độ quan trọng PLS và hệ số VIF tương ứng.

Đặc trưng	Điểm quan trọng	VIF
rolling_mean_4	2,265	461,18
rolling_min_4	2,251	882,04
rolling_max_4	2,224	1.375,52
lag_4	2,123	27,77
ky_vong	2,039	21,18
pvcclr_loni	1,959	10,80
lag_96	1,883	5,36

Sáu trong bảy đặc trưng dẫn đầu đồng thời mang nhãn cộng tuyến cao. Đây là lý do trực tiếp để bước chọn không dùng hệ số phóng đại phương sai làm tiêu chí loại: nếu cắt theo ngưỡng 10 thì sáu đặc trưng mạnh nhất theo thước đo độc lập sẽ bị loại hết.

Danh sách cấm

Trước khi chấm điểm, notebook 05_select_features khai báo tường minh một danh sách cấm gồm 53 tên cột. Danh sách này chặn bốn loại: chính mục tiêu và các biến thể của nó, cờ ngoại lai và cột loại trừ huấn luyện, cột ghi nguồn gốc dữ liệu, và các khoá định danh cùng cột thời gian thô.

Danh sách được khai báo theo tên chứ không theo tập dữ liệu, nên nó bao cả những tên chỉ xuất hiện ở các bước khác của quy trình. Trong 114 cột của tệp đầu vào, 40 cột trùng tên với danh sách và bị loại; 74 cột còn lại đi tiếp vào bước chấm điểm. Cách khai báo dư này là có chủ đích: thêm một tên không tồn tại thì vô hại, còn sót một tên rõ ràng thì hỏng cả kết quả.

Danh sách cấm được đặt trước phép chấm điểm chứ không sau, vì một cột rõ ràng luôn đạt điểm tương quan cao: nếu để cột đó tham gia đánh giá thì chính thước đo sẽ chọn nhầm đặc trưng rõ ràng thông tin tương lai.

Chấm điểm bằng thông tin tương hỗ

Phép chấm điểm chạy trên thông tin tương hỗ giữa từng đặc trưng và mục tiêu. Thước đo này bắt được cả quan hệ phi tuyến, khác hệ số tương quan Pearson vốn chỉ đo quan hệ tuyến tính điều cần thiết ở đây vì quan hệ giữa bức xạ và sản lượng bão hoà dần khi tới gần trần công suất.

Điểm chỉ tính trên các dòng hợp lệ, tức đã bỏ dòng mang cờ loại trừ huấn luyện:

Tổng số dòng ban đầu: 1550856

Số dòng hợp lệ (exclude_from_training == False): 1514314 (97.64%)

Số dòng bị loại trừ khỏi chấm điểm: 36542

Bảng 6.28 lấy mười đặc trưng đứng đầu trong 74 ứng viên, chấm trên mẫu 100.000 dòng.

Bảng 6.28: Mười đặc trưng có điểm thông tin tương hỗ (MI) cao nhất.

Hạng	Đặc trưng	Điểm
1	rolling_max_4	1,1724
2	rolling_mean_4	1,1251
3	ky_vong	1,0785
4	rolling_min_4	1,0582
5	lag_96	1,0018
6	lag_4	0,8315
7	solar_elevation	0,8258
8	sin_elevation	0,7967
9	ty_le_bao_hoa	0,7949
10	ghi_cs	0,7939

Bốn vị trí đầu đều là đặc trưng của sổ trượt một giờ, và sáu vị trí đầu đều suy từ lịch sử của chính chuỗi sản lượng. Bảng xếp hạng này khớp với kết quả tự tương quan ở Mục 6.2.3: chuỗi mang tự tương quan +0,9033 tại mốc một giờ, nên các thống kê của cửa sổ một giờ gần nhất là nguồn thông tin mạnh nhất về giá trị sắp tới.

Danh sách bảo vệ

Lấy thẳng 35 đặc trưng đứng đầu sẽ loại mất một số biến khí tượng và hình học Mặt Trời có điểm thấp nhưng cần cho mô hình đọc được điều kiện vật lý tại bước hiện tại. Notebook vì vậy khai báo một danh sách bảo vệ gồm 21 đặc trưng, cả 21 đều có mặt trong dữ liệu, và bổ sung lại những đặc trưng nằm ngoài ngưỡng cắt:

```
--- DANH SACH BAO VE ---
Co trong du lieu : 21/21
Bi Top K cat, da bo sung lai (4): ['azimuth_sin', 'temperature_c',
                                   'doy_sin', 'doy_cos']
Tong dac trung duoc chon: 36 (Top K) + 4 (bao ve) = 40
```

Bốn đặc trưng được bổ sung nằm ở hạng 37, 40, 49 và 54 theo điểm thông tin tương hỗ. Hai cột `doy_sin` và `doy_cos` mã hoá vị trí trong năm dưới dạng vòng; điểm của chúng thấp vì trên một mẫu ngẫu nhiên rải khắp 18 tháng, mùa gần như không phân biệt được nhưng mô hình cần chúng để không coi ngày 31/12 và ngày 01/01 là hai thời điểm xa nhau.

Kết quả áp cho mười tập

Bốn mươi đặc trưng cơ bản đã chọn (mở rộng thành 53 đặc trưng khi thêm các biến trễ mục tiêu $T + h$ cho mô hình H1) được áp đồng loạt cho mười tập dữ liệu bốn tập chính và sáu phần của ba fold:

```
--- DA LOC 10 TAP THEO 39 DAC TRUNG DA CHON ---
tap      dong  cot_truoc  cot_sau  feature  cot_phu  \
0      v4_train 1550856      114      49      39      10
1      v4_val   723114      114      49      39      10
2      v4_test   510468      114      49      39      10
3 v4_development 2273970      113      49      39      10
4   fold_1_train 233244      115      49      39      10
5   fold_1_val   606105      115      49      39      10
6   fold_2_train 839349      115      49      39      10
7   fold_2_val   711507      115      49      39      10
8   fold_3_train 1550856      115      49      39      10
9   fold_3_val   723114      115      49      39      10

feature_thieu
0           0
1           0
2           0
3           0
4           0
5           0
6           0
7           0
8           0
9           0
```

Moi tap deu co du dac trung da chon.

Cột `feature_thieu` bằng 0 ở cả mười dòng, tức không tập nào thiếu đặc trưng đã chọn. Mỗi tập giữ 50 cột: 40 đặc trưng cùng 10 cột phụ trợ gồm mục tiêu, mốc thời gian, mã trạm và các cột phục vụ lọc phạm vi chấm điểm. Danh sách 39 tên cột được ghi ra tệp `selected_features.json` để các bước huấn luyện và phục vụ đọc lại đúng một danh sách duy nhất.

6.3.8 Tổng hợp bộ đặc trưng đưa vào mô hình

Bảng 6.29 tổng hợp toàn bộ 40 đặc trưng cơ bản được lựa chọn (mở rộng thành 53 đặc trưng sau khi thêm các biến mục tiêu tương lai $T + h$ cho H1) đưa vào huấn luyện mô hình, phân loại theo 6 nhóm chức năng.

Bảng 6.29: Danh mục 40 đặc trưng cơ bản được lựa chọn vào mô hình.

Nhóm Đặc Trưng	Số Cột	Danh Sách Tên Cột
Thời gian và lịch tuần hoàn	6	minute_of_day, hour, hour_sin, hour_cos, doy_sin, doy_cos
Solar geometry và trời quang	8	solar_elevation, sin_elevation, solar_azimuth, azimuth_sin, azimuth_cos, ghi_cs, cs_factor, chi_so_troi_quang
Khí tượng quan trắc	5	shortwave_radiation, diffuse_solar_radiation, direct_normal_irradiance, temperature_c, cloud_cover_low
Tương tác vật lý và tỷ lệ	5	rad_x_sinelev, temp_x_shortwave, diffuse_ratio, cloud_x_shortwave, cloud_low_x_shortwave
Lịch sử chuỗi thời gian	9	lag_4, lag_96, rolling_mean_4, rolling_std_4, rolling_min_4, rolling_max_4, rolling_mean_96, rolling_std_96, rolling_max_96
Quy mô trạm và mã hoá	6	ky_vong, ty_le_bao_hoa, tran_cong_suat, site_id_enc, weather_condition_enc, weather_description_enc
Tổng số đặc trưng	40	

Mười bốn cột `_mt` sinh thêm ở bước huấn luyện đều thuộc hai nhóm đầu hình học Mặt Trời và nhân lịch đúng theo ranh giới hợp lệ đã nêu ở Mục 3.4:

Thêm 14 đặc trưng tại dinh tại T+15 phút:

```
['solar_elevation_mt', 'solar_azimuth_mt', 'azimuth_sin_mt',
 'azimuth_cos_mt', 'sin_elevation_mt', 'ghi_cs_mt', 'ky_vong_mt',
 'ty_le_bao_hoa_mt', 'minute_of_day_mt', 'hour_mt', 'hour_sin_mt',
 'hour_cos_mt', 'doy_sin_mt', 'doy_cos_mt']
```

Ma tran train : 599,174 dòng x 54 đặc trưng

Mục tiêu chuẩn hoá k: min 0.0028 trung vi 0.6423 max 1.3764

Không cột khí tượng nào có mặt trong danh sách này. Giá trị lớn nhất của mục tiêu chuẩn hoá bằng đúng 1,3764, tức cận sát suy từ phân vị 99 ở Mục 6.3.5 đang hoạt động.

6.4 Huấn luyện và chọn hàm mất mát

Mô hình là LightGBM hồi quy, huấn luyện riêng cho H1 và H4, mỗi tầm nhận 53 đặc trưng. Mục này đi qua năm bước: trọng số cho dòng ngoại lai, tinh chỉnh siêu tham số (*hyperparameter*), sáu cấu hình chọn được, chọn hàm mất mát, và cấu hình tắt định.

6.4.1 Chính sách trọng số cho dòng ngoại lai

Các dòng mang nhãn ngoại lai không bị xoá khỏi lưới. Chúng nhận trọng số bằng 0, tức không đóng góp vào hàm mục tiêu, nhưng vẫn nằm trong bảng để bước báo cáo truy ngược được:

```
--- CHINH SACH OUTLIER, experiment = measured_only_headline ---
Dong co weight = 0 khong tham gia ham muc tieu nhung van giu de bao cao.
Tong dong bi loai khoi ham muc tieu: 82,362 / 681,536 (12.08%)
    trong do physical_over_capacity: 0 dong (luon bi loai o moi experiment)
Khoang thoi gian train: 2020-01-02 06:30:00 -> 2021-06-21 17:00:00
```

Cách gán trọng số 0 được chọn thay vì xoá dòng, vì xoá sẽ làm đứt lưới thời gian và mọi đặc trưng trễ, cửa sổ trượt tính sau đó đều đếm sai khoảng cách, đúng vấn đề mà bước dựng lưới ở Mục 6.2.1 đặt ra để tránh.

6.4.2 Tinh chỉnh siêu tham số (*hyperparameter*)

Mỗi hàm mất mát được Optuna chạy một phiên tìm kiếm riêng với ngân sách 20 trial, chấm bằng WAPE gộp trên ba fold cửa sổ mở rộng của tập Phát triển. Không hàm nào phải dùng lại bộ tham số của hàm khác, và không hàm nào bị cố định mức điều hoà.

Miền tìm kiếm khai báo cố định trong cả ba notebook huấn luyện, ghi ở Bảng 6.30.

Bảng 6.30: Không gian tìm kiếm siêu tham số cho Optuna.

Siêu tham số	Miền	Vai trò
n_estimators	[400; 1200]	Số cây tối đa, early stopping chốt số thật
learning_rate	[0,02; 0,12] thang log	Tốc độ học
num_leaves	[63; 255]	Độ phức tạp mỗi cây
min_child_samples	[20; 120]	Số mẫu tối thiểu mỗi lá
subsample	[0,7; 1,0]	Tỷ lệ mẫu mỗi vòng
colsample_bytree	[0,7; 1,0]	Tỷ lệ cột mỗi cây
reg_alpha	[0; 10]	Điều hoà L_1
reg_lambda	[0; 10]	Điều hoà L_2
alpha	[0,5; 20] thang log	Điểm chuyển của Huber, chỉ Huber có

Vì reg_alpha và reg_lambda được thả độc lập trên cùng một miền, không gian tìm kiếm bao trùm cả ba chế độ điều hoà: L_1 thuần, L_2 thuần và dạng phối hợp. Mỗi hàm mất mát vì vậy được trao cơ hội ngang nhau để tự tìm mức điều hoà phù hợp trước khi đem ra so.

Bảng 6.31: Bộ siêu tham số tối ưu do Optuna lựa chọn theo từng cấu hình.

Cấu hình	Số cây	Tốc độ học	Số lá	Mẫu/lá	Tỷ lệ mẫu	Tỷ lệ cột	L_1	L_2
MAE — H1	800	0,03019	82	88	0,700	0,817	2,58	4,82
Huber — H1	386	0,05781	71	81	0,751	0,720	9,49	9,66
MSE — H1	329	0,05121	146	49	0,884	0,742	2,92	3,66
MAE — H4	400	0,04857	69	111	0,778	0,899	3,12	5,20
Huber — H4	526	0,02849	99	71	0,950	0,770	9,88	4,18
MSE — H4	509	0,03570	134	46	0,869	0,810	9,81	3,99

6.4.3 Sáu cấu hình Optuna chọn được

Điểm chuyển của Huber được Optuna chọn rất khác nhau giữa hai tầm: $\alpha = 9,86$ ở H1 nhưng chỉ 0,73 ở H4. Đọc ngang bảng còn thấy hai xu hướng. Các cấu hình MSE dùng số lá lớn hơn hẳn, 146 và 134 so với 71–99 của Huber, tức cây sâu và chia nhỏ hơn, phù hợp với việc MSE phạt nặng sai số lớn nên có động cơ khớp sát từng vùng dữ liệu. Mức phạt L_1 mà Optuna chọn cho Huber ở cả hai tầm đều gần chạm cận trên của miền (9,49 và 9,88), cho thấy cấu hình này cần ràng buộc mạnh mới ổn định.

Hai chỗ chạm biên miền tìm kiếm. subsample của MAE–H1 bằng 0,7003, tức đúng cận dưới; reg_alpha của Huber đạt 9,49–9,88 trên miền $[0; 10]$. Khi một siêu tham số (*hyperparameter*) dừng ngay tại biên, không thể loại trừ khả năng giá trị tốt hơn nằm ngoài miền đã khai báo. Vì vậy tài liệu này không tuyên bố đây là cấu hình tối ưu toàn cục, mà chỉ là cấu hình tốt nhất tìm được trong miền và ngân sách 20 trial đã khoá từ trước. Mở rộng miền ở hai chỗ đó là việc nên làm ở lần huấn luyện sau.

6.4.4 Chọn hàm mất mát

Ba hàm được chấm trên tập kiểm định, phần dữ liệu mô hình chưa từng nhìn thấy, ở phạm vi đo thật ban ngày. Phạm vi này xét dòng nhãn tại $T+h$ đúng như ở bước đánh giá cuối tại Mục 6.5.2, và loại hai trạm 19, 24 cho khớp với phạm vi huấn luyện. Kết quả đầy đủ của sáu cấu hình ở Bảng 6.32.

Bảng 6.32: Sai số trên tập kiểm định theo các hàm mất mát.

Tầm	Hàm mất mát	WAPE (%)	RMSE	MAE	R^2
<i>H1 — 288.811 quan sát cho cả ba hàm</i>					
H1	MAE	22,0523	3,6737	1,5062	0,8984
H1	MSE	22,6591	3,6373	1,5477	0,9004
H1	Huber	22,7937	3,6608	1,5569	0,8991
<i>H4 — 272.569 quan sát cho cả ba hàm</i>					
H4	MAE	26,9712	4,3598	1,9338	0,8628
H4	MSE	27,3365	4,2850	1,9600	0,8674
H4	Huber	27,4086	4,2896	1,9651	0,8672

MAE cho sai số thấp nhất ở cả hai tầm và được chọn cho cả hai. Trong mỗi tầm, ba hàm được chấm trên đúng cùng số quan sát, điều kiện để phép so sánh có nghĩa, vì nếu một cấu hình

được chấm trên tập sạch hơn thì chênh lệch WAPE phản ánh phạm vi chứ không phản ánh hàm mất mát.

Đáng chú ý là MAE thắng theo WAPE nhưng thua theo RMSE ở cả hai tầm. Điều này đúng với bản chất hai hàm: MSE phạt bình phương sai số nên ép sai số lớn xuống mạnh hơn, cho RMSE tốt hơn; MAE phạt tuyến tính nên bám phần thân phân bố, cho sai số tương đối tổng thể thấp hơn. Dự án lấy WAPE làm tiêu chí chọn vì nó là chỉ số được báo cáo, và vì mục tiêu vận hành là tổng sai số trên tổng sản lượng chứ không phải không chế vài sai số cực trị.

Phép chọn này thực hiện hoàn toàn trên tập kiểm định; tập test không tham gia. Notebook 10_compare_optuna_current có một công kiểm tự động cho đúng điều đó, và nó báo PASS.

6.4.5 Cấu hình tắt định

Toàn bộ sáu lần huấn luyện chạy trên CPU với `deterministic = true`, `force_col_wise = true`, `max_bin = 127`, `random_state = 42` và `n_jobs = 6`. Chế độ GPU bị tắt có chủ đích. Tài liệu tham số của LightGBM ghi rõ *deterministic “used only with cpu device type”*; bật GPU thì cờ này bị bỏ qua. Quy trình đặt tính tái lập lên trước tốc độ nên chọn CPU.

Cấu hình tắt định này là điều kiện để mọi con số trong tài liệu truy được về đúng tệp kết quả đã sinh ra chúng: sáu cấu hình huấn luyện, sáu tệp `metrics_val.json` dưới `06_train/`, và các bảng ở Mục 6.4.4 đọc thẳng từ những tệp đó.

6.5 Đánh giá trên tập test niêm phong

Tập test tách từ đầu và chỉ mở đúng một lần ở đây, sau khi hàm mất mát và siêu tham số (*hyperparameter*) đã khoá. Mục này đi qua sáu bước: thước đo, phạm vi chấm điểm, kết quả, chênh lệch giữa test và kiểm định, đối chứng Prophet, và kiểm chứng độ trễ pha.

6.5.1 Thước đo

Chỉ số chính của toàn bộ tài liệu là WAPE, sai số phần trăm tuyệt đối có trọng số:

$$WAPE = \frac{\sum_i |y_i - \hat{y}_i|}{\sum_i |y_i|} \times 100\% \quad (6.10)$$

Ba điểm về cách áp dụng.

Gộp một lần trên toàn bộ phạm vi. Tử số và mẫu số cộng dồn qua mọi trạm và mọi mốc thời gian trong phạm vi đang xét, rồi mới chia. Đây không phải trung bình của WAPE từng trạm; cách gộp này khiến trạm phát nhiều đóng góp nhiều hơn vào con số cuối, đúng với ý nghĩa vận hành là tổng sai số trên tổng sản lượng.

Mẫu số không bao giờ bằng 0. Phạm vi chấm điểm luôn yêu cầu dòng ban ngày và đo thật, nên trong tập được chấm không có trường hợp tổng sản lượng bằng 0.

Chọn WAPE thay cho MAPE. MAPE chia theo từng điểm nên nổ tung ở các mốc sản lượng gần 0 lúc rạng sáng và chập tối, chính những mốc chiếm phần lớn dữ liệu. WAPE đặt tổng ở mẫu số nên không gặp vấn đề đó.

Chỉ số này do Kolassa và Schütz [25] đưa ra dưới tên tỷ số MAD/Mean.

Trong lĩnh vực dự báo bức xạ mặt trời, Temporal-Neto và cộng sự [15] cũng chọn chỉ số này và giải thích công dụng của phép lấy trọng số:

“The Weighted Absolute Percentage Error (WAPE) is defined as the weighted average of the MAE. The weighing can help distinguish smaller errors from more significant errors when dealing with low-volume data and when a data point can be minimal compared to the rest of the data, like intermittent data. This metric prevents small values from being compared in scale to larger values.”

Đó đúng là tình huống của dữ liệu quang điện: sản lượng lúc rạng sáng và chập tối nhỏ hơn hẳn lúc giữa trưa, và phép lấy trọng số theo sản lượng thật giữ cho những mốc nhỏ đó không bị đem so ngang thang với những mốc lớn.

6.5.2 Phạm vi chấm điểm

Không phải mọi dòng trong tập test đều dùng để tính chỉ số. Bốn điều kiện lọc được áp dụng như ở bước huấn luyện, đưa 510.468 dòng xuống 478.942 dòng.

Phép dịch nhãn lên $T+h$ loại thêm một phần nữa. Sau khi lọc, lưới thời gian không còn liên tục, nên `shift(-h)` theo trạm có thể trở tới dòng hợp lệ kế tiếp chứ không phải mốc $T+h$. Bước chấm điểm vì vậy đối chiếu mốc thời gian của dòng bị dịch tới và chỉ giữ dòng nào lệch đúng 15h phút: H1 loại 3.303 dòng còn 475.599, H4 loại 12.964 dòng còn 465.818. Kiểm lại trên tệp `prediction_audit.parquet` thì không còn dòng nào lệch tầm ở cả hai tầm.

Chỉ số được báo ở ba phạm vi lồng nhau. Điều kiện phạm vi xét dòng nhãn tại $T+h$, không phải dòng đặc trưng tại T : hai cột `energy_source` và `is_daylight` được dịch sang mốc nhãn thành `nhan_energy_source` và `nhan_is_daylight` rồi mới dùng để lọc.

- **Toàn bộ** — mọi dòng còn lại sau bốn điều kiện lọc và phép kiểm tầm.
- **Đo thật** — thêm điều kiện `nhan_energy_source = measured`.
- **Đo thật ban ngày** — thêm điều kiện `nhan_is_daylight = true`. Đây là phạm vi chính thức mà tài liệu dùng để báo chỉ số: 229.548 dòng ở H1 và 229.297 dòng ở H4.

Bản trước lọc theo cột tại T . Vì nhãn là sản lượng tại $T+h$, cách đó để lọt vào phạm vi “đo thật ban ngày” những dòng mà nhãn thực chất do bước điền khuyết của tầng ETL sinh ra hoặc rơi vào ban đêm. Sửa lại cho bám mốc nhãn làm WAPE H1 tăng 0,05 điểm và H4 tăng 0,13 điểm, tức con số cũ dễ hơn thực tế.

6.5.3 Kết quả

Bảng 6.33 là kết quả chính của toàn bộ tài liệu.

Cả hai tầm dùng cấu hình MAE, đúng hai cấu hình thắng trên tập kiểm định ở Mục 6.4.4.

Bảng 6.33: Sai số WAPE trên tập test niêm phong theo ba phạm vi.

Phạm vi	H1 (%)	H4 (%)
Toàn bộ	17,10	21,86
Đo thật	17,76	22,64
Đo thật ban ngày	17,74	22,62

Phạm vi chính thức gồm 229.548 dòng ở H1 và 229.297 dòng ở H4.

Sai số phân bố không đều giữa các trạm. Ở H1, trạm tốt nhất đạt 11,89% còn trạm kém nhất 28,32%, trung vị 18,12%; ở H4 khoảng này là 15,12% đến 35,88%, trung vị 22,72%. Chênh lệch hơn hai lần giữa hai đầu cho thấy một mô hình dùng chung cho cả 40 trạm vẫn để lại phần khác biệt riêng của từng trạm mà đặc trưng hiện có chưa mô tả hết.

6.5.4 Chênh lệch giữa sai số trên test và trên kiểm định

Bảng 6.34 đặt cạnh nhau ba con số của cùng một mô hình ở ba phạm vi đánh giá khác nhau. Chúng không so trực tiếp được với nhau, phải đọc kèm phạm vi.

Bảng 6.34: Đối chiếu sai số WAPE giữa các giai đoạn đánh giá.

Phạm vi đánh giá	H1 (%)	H4 (%)
Optuna, gộp ba fold kiểm định	24,1767	29,4090
Test niêm phong, toàn bộ	17,0963	21,8627
Test niêm phong, đo thật ban ngày	17,7409	22,6181
Cùng phạm vi với Prophet	17,7921	22,3613

Sai số trên test thấp hơn trên ba fold kiểm định tới hơn sáu điểm. Nguyên nhân nằm ở vị trí của hai tập trên trục thời gian, không phải ở việc test dễ hơn. Ba fold kiểm định nằm ở giai đoạn **sớm** của chuỗi, nơi lịch sử dùng để tính lag_{96} và các cửa sổ trượt còn ngắn, nên nhiều mốc dự báo thiếu ngữ cảnh. Tập test nằm ở **cuối** chuỗi, mọi mốc đều đã có đủ lịch sử phía sau. Chênh lệch này đến từ phạm vi dữ liệu và không cho phép kết luận rằng tập test đã tham gia vào việc chọn mô hình, hàm mất mát và siêu tham số (*hyperparameter*) đều khoá trên tập Phát triển trước khi tập test được mở.

6.5.5 Đối chứng với Prophet

Chỉ số dự báo vượt trội

Một con số WAPE đứng một mình không nói lên chất lượng. Nó cần được đặt cạnh một mô hình đối chứng. Chỉ số Forecast Skill Score đo phần sai số cắt giảm được so với đối chứng. Dạng chuẩn của chỉ số, theo Nguyễn và Müsgens [26], là:

$$SS = 1 - \frac{A_f}{A_r} \quad (6.11)$$

với A_f và A_r lần lượt là thước đo sai số của mô hình cần đánh giá và của mô hình đối chứng. Tài liệu này lấy A là WAPE và trình bày kết quả theo phần trăm:

$$SS = \left(1 - \frac{WAPE_{\text{mô hình}}}{WAPE_{\text{đối chứng}}} \right) \times 100\% \quad (6.12)$$

Chỉ số này do Marquez và Coimbra [27] đưa vào lĩnh vực dự báo điện mặt trời: thay vì đọc một con số sai số tuyệt đối, ta đo phần sai số cắt giảm được so với một mô hình đối chứng.

Lợi ích của cách đọc này được nêu rõ ngay trong các nguồn gốc. Sở tay kiểm định dự báo của Nhóm công tác liên hợp WWRP/WGNE [28] chỉ ra rằng sai số thấp chưa chắc do mô hình giỏi:

“Skill refers to the increase in accuracy due purely to the “smarts” of the forecast system. Weather forecasts may be more accurate simply because the weather is easier to forecast – skill takes this into account.”

Điều này đúng với dữ liệu của đề tài: WAPE trên tập test thấp hơn trên ba fold kiểm định tới hơn sáu điểm phần trăm, mà nguyên nhân đã phân tích ở trên là do vị trí hai tập trên trục thời gian chứ không do mô hình khá lên. Chỉ số kỹ năng khử đúng loại chênh lệch đó, vì mô hình và đối chứng cùng chịu một điều kiện dữ liệu. Marquez và Coimbra nêu thêm một lợi ích thứ hai, rằng tỷ số này ổn định qua các tầm dự báo khác nhau:

“The direct use of statistical quantities to assign forecasting quality can be misleading because these metrics do not convey a measure of the variability of the time-series for the solar irradiance data. ...the ratio is preserved for widely different time horizons when the same time averaging periods are used, and therefore provides a robust way to compare solar forecasting skills.”

Nhờ đó hai mô hình chạy ở hai địa điểm hay hai tầm dự báo khác nhau mới so sánh được với nhau.

Nguyễn và Müsgens [26], trong bài phân tích tổng hợp các nghiên cứu dự báo điện mặt trời trên tạp chí *Journal of Renewable and Sustainable Energy*, viết dạng tổng quát của chỉ số như sau:

“ $SS = \frac{A_f - A_r}{A_p - A_r}$, where A_f , A_p , and A_r are the accuracy measurements (e.g., mean squared errors) of the forecasts of interest, the perfect forecasts, and the reference forecasts, respectively. In solar forecasting, it is often assumed that the accuracy measure of a perfect forecast A_p is much smaller than the reference forecast’s A_r and can be approximately 0. Therefore, SS can be reformulated as: $SS = 1 - A_f/A_r$.”

Ký hiệu A ở đây là một thước đo sai số bất kỳ, MSE chỉ được nêu làm ví dụ. Chính bài đó nói tiếp rằng việc chọn thước đo nào là quyết định của người làm, và dẫn ra những lựa chọn khác nhau đã được công bố:

“To calculate SS, scholars need to decide on the accuracy measurement metric and the reference method. There are different suggestions for the accuracy measurement metrics. For example, Perez et al. (2013) used mean squared error (MSE), Morf (2021) recommended using Spearman’s ρ as the skill score, etc.”

Ở đó mô hình đối chứng là dự báo bằng 0 tại mọi thời điểm, nên mẫu số rút gọn mất. Tài liệu này dùng đối chứng là Prophet chứ không phải dự báo 0, nên mẫu số được viết đầy đủ, đúng như dạng tổng quát (6.11).

Công thức (6.12) vì vậy là công thức (6.11) với A là WAPE, khung công thức giữ nguyên không đổi một ký hiệu. WAPE được chọn vì đó là chỉ số chính đã dùng xuyên suốt báo cáo, nhờ vậy chỉ số kỹ năng đọc cùng một thang với mọi bảng phía trước. Cả tử số và mẫu số đều tính trên cùng một tập dòng nên phép chia không bị lệch phạm vi.

Việc đánh giá bằng một bộ nhiều chỉ số thay vì một con số duy nhất theo Zhang và cộng sự [17]; bản tiền ấn phẩm của bài đó viết:

“Conventional measures of solar forecasting accuracy include root mean square error (RMSE), mean bias error (MBE), and mean absolute error (MAE).”

Điều kiện so sánh

Prophet là mô hình chuỗi thời gian cộng tính, chỉ học xu thế và chu kỳ ngày/tuần từ chính lịch sử sản lượng, không dùng bất kỳ biến khí tượng nào. Nó được huấn luyện trong cùng cửa sổ thời gian Phát triển với mô hình chính, rồi dự báo tại đúng các mốc mục tiêu của tập test.

Khi chấm điểm, hai mô hình dùng cùng một tập dòng, cùng tử số và cùng mẫu số. Phạm vi này yêu cầu cả giá trị tại T lẫn nhãn tại $T+h$ đều là số đo thật, đồng thời dòng tại T là ban ngày, chặt hơn phạm vi đo thật ban ngày của mô hình chính, nên số dòng nhỏ hơn: 220.114 ở H1 và 202.677 ở H4. Kết quả ở Bảng 6.35.

Bảng 6.35: So sánh hiệu năng giữa LightGBM và baseline Prophet.

Tầm và mô hình	Số dòng	WAPE (%)	RMSE	MAE	R^2
H1 — LightGBM	220.114	17,7921	3,4443	1,4017	0,9231
H1 — Prophet	220.114	35,2548	5,4683	2,7775	0,8063
<i>Skill Score H1</i>		+49,53%			
H4 — LightGBM	202.677	22,3613	4,3475	1,8504	0,8815
H4 — Prophet	202.677	35,0821	5,6182	2,9031	0,8020
<i>Skill Score H4</i>		+36,26%			

Giới hạn của phép đối chứng

Chênh lệch 17,46 điểm WAPE ở H1 là kết quả cuối cùng của hai phương án, nhưng không tách được thành phần đóng góp của riêng nhóm đặc trưng khí tượng. Lý do là hai mô hình khác nhau đồng thời ở hai điểm: thuật toán (phân rã chuỗi cộng tính so với cây tăng cường gradient) và

tập đầu vào (không có biến khí tượng so với có). Muốn tách thì phải chạy thêm hai cấu hình đối chứng nữa: LightGBM bỏ hết biến khí tượng, và Prophet có biến ngoại sinh. Hai cấu hình đó nằm ở Mục 6.8.3 như hướng phát triển tiếp theo.

Ngoài ra, chỉ số vượt trội đo mức cải thiện so với một mô hình đối chứng cụ thể, không phải so với mọi phương án khả dĩ. Một đường cơ sở yếu hơn sẽ cho chỉ số cao hơn mà không phản ánh năng lực mô hình tốt hơn.

6.5.6 Kiểm chứng độ trễ pha trên mô hình cuối

Nguyên cơ lớn nhất của một mô hình dự báo quang điện là nó học cách lặp lại giá trị vừa đo thay vì thật sự dự báo — khi đó đường dự báo trông rất khớp nhưng thực chất chỉ là đường thực tế bị đẩy sang phải. Notebook 09_kiem_chung_tre pha đo trực tiếp hiện tượng đó trên 475.599 dòng dự báo H1 của tập test, bằng cách so mốc đạt đỉnh của đường dự báo với mốc đạt đỉnh của đường thực tế, cho từng trạm từng ngày:

```
--- LECH DINH LOCAL: 40 site x 5,080 ngày ---
lech_phut duong = du bao den SAU thuc te (dich phai / tre). am = du bao den SOM.

count    5080.00
mean     -1.05
std       78.63
min      -495.00
25%      -45.00
50%       15.00
75%       45.00
max       270.00

So ngay du bao dich PHAI (tre) : 2,791 / 5,080 (54.9%)
So ngay dung khop (lech = 0)  : 384 / 5,080 (7.6%)
So ngay du bao dich TRAI (som) : 1,905 / 5,080 (37.5%)
```

Trung bình lệch $-1,05$ phút, tức gần như không thiên về bên nào; trung vị $+15$ phút, đúng một bước. Nếu mô hình chỉ lặp lại giá trị vừa đo thì độ lệch phải bằng đúng tầm dự báo ở gần như mọi ngày, và tỷ lệ dịch phải sẽ tiến tới 100%. Con số thực tế là 54,9% dịch phải so với 37,5% dịch trái, phân bố hai phía, không phải dấu hiệu của mô hình sao chép.

Độ lệch chuẩn 78,63 phút cho thấy mức phân tán giữa các ngày vẫn lớn, và 32 trên 40 trạm có trung vị nghiêng về phía trễ. Đây là giới hạn còn lại của mô hình, ghi nhận để lần huấn luyện sau xử lý tiếp.

Notebook còn đo một giả thuyết cạnh tranh: nếu độ lệch bắt nguồn từ việc dữ liệu khí tượng chỉ có độ hạt một giờ, thì đỉnh thực tế xảy ra càng gần cuối khối giờ sẽ càng lệch nhiều. Số đo bác bỏ điều đó, cả bốn vị trí trong khối giờ đều cho trung vị đúng 15 phút, xem Bảng 6.36.

Bảng 6.36: Phân tích độ trễ pha và độ lệch đỉnh của dự báo H1.

Phút trong giờ	Số ngày	Độ lệch trung vị (phút)
0–14	1.052	15,0
15–29	1.112	15,0
30–44	1.631	15,0
45–59	1.285	15,0

6.6 Giải thích mô hình bằng SHAP

Cây tăng cường gradient cho sai số thấp nhưng không tự nói được nó dựa vào đâu. Mục này dùng SHAP, đi qua bốn bước: cơ sở phương pháp, tầm quan trọng tổng thể, phân tích chi tiết ba trường hợp dự báo, và giới hạn diễn giải.

6.6.1 Cơ sở phương pháp

SHAP quy phân đóng góp theo giá trị Shapley của lý thuyết trò chơi hợp tác: mỗi đặc trưng được coi là một người chơi, và phần đóng góp của nó là mức thay đổi trung bình của dự báo khi thêm nó vào mọi tổ hợp đặc trưng khác. Cách quy này có tính chất cộng, tổng đóng góp của tất cả đặc trưng cộng với giá trị nền bằng đúng dự báo, nên đọc được ở mức từng dòng dữ liệu. Lundberg và Lee [16] là công trình đề xuất khung thống nhất này.

Phạm vi tính: mô hình thắng ở tầm H1 (cấu hình MAE), chạy trên toàn bộ 475.599 dòng của tập test với 53 đặc trưng. Giá trị SHAP tính trên thang mục tiêu đã chuẩn hoá k , không phải thang kWh.

Ma trận đặc trưng dùng để tính SHAP lấy đúng tệp `X_test_h1.parquet` mà bước đánh giá đã ghi ra, nên phạm vi dòng thống nhất với Phần 5. Giá trị SHAP được tính trên toàn bộ 475.599 dòng của tập test, không lấy mẫu.

6.6.2 Tầm quan trọng tổng thể

Bảng 6.37 xếp hạng đặc trưng theo trung bình trị tuyệt đối giá trị SHAP trên toàn tập test.


Bảng 6.37: Top 10 đặc trưng quan trọng nhất theo giá trị SHAP trung bình.

Hạng	Đặc trưng	SHAP trung bình	Nhóm
1	direct_normal_irradiance	0,0869	Khí tượng đo được
2	ky_vong	0,0860	Quy mô trạm
3	rolling_min_4	0,0805	Lịch sử chuỗi
4	ghi_cs_mt	0,0755	Trời quang tại $T+h$
5	rolling_max_4	0,0678	Lịch sử chuỗi
6	rolling_mean_4	0,0566	Lịch sử chuỗi
7	minute_of_day	0,0475	Thời gian
8	tran_cong_suat	0,0382	Quy mô trạm
9	rolling_std_4	0,0338	Lịch sử chuỗi
10	weather_condition_enc	0,0218	Khí tượng phân loại

Bảng này cho một kết quả đáng chú ý khi đặt cạnh bảng thông tin tương hỗ ở Mục 6.3.7. Ở bước chọn đặc trưng, bốn vị trí đầu đều là thống kê cửa sổ trượt một giờ. Ở đây, đứng đầu lại là `direct_normal_irradiance` — một biến khí tượng đo được — và vị trí thứ tư thuộc về `ghi_cs_mt`, tức bức xạ trời quang tại thời điểm mục tiêu.

Hai điểm rút ra. Thứ nhất, thông tin tương hỗ đo quan hệ của một đặc trưng với mục tiêu khi đứng riêng, còn SHAP đo phần đóng góp của nó trong mô hình đã huấn luyện, nơi các đặc trưng chia nhau thông tin; hai thước đo trả lời hai câu hỏi khác nhau nên không buộc phải trùng thứ hạng. Thứ hai, việc `ghi_cs_mt` lọt vào nhóm bốn đầu là bằng chứng cho thấy nhóm đặc trưng tất định tại $T+h$ ở Mục 3.4 thực sự được mô hình dùng, chứ không phải cột thừa.

Hình 6.11 trình bày phân bố giá trị SHAP của từng đặc trưng trên toàn bộ tập test.



Hình 6.11: Biểu đồ SHAP Beeswarm thể hiện tác động của các đặc trưng.


6.6.3 Giải thích ba dự báo cụ thể

Tính chất cộng gộp của SHAP cho phép phân tích chi tiết từng trường hợp dự báo đơn lẻ. Notebook chọn ba trường hợp tương phản trong tập test, ghi ở Bảng 6.38.

Bảng 6.38: Phân tích 3 trường hợp dự báo bằng SHAP cục bộ.

Trường hợp	Trạm	Thời điểm	Thực tế (kWh)	Tổng SHAP
Đẩy dự báo lên	10	09/03/2022 10:15	5,5312	+0,6684
Kéo dự báo xuống	27	28/01/2022 17:15	2,8750	−0,8110
Gần mức nền	36	31/03/2022 17:15	2,8906	−0,0000

Ba trường hợp này minh họa ba chế độ khác nhau của mô hình. Ở ca đẩy lên, đóng góp lớn nhất đến từ `direct_normal_irradiance` (+0,0923) và `minute_of_day` (+0,0645) — bức xạ trực xạ mạnh vào giữa buổi sáng, đúng nhánh lên của đường sản lượng trong ngày. Ở ca kéo xuống, hai đặc trưng đẩy mạnh nhất theo chiều âm là `ky_vong` (−0,2193) và `tran_cong_suat` (−0,0929), kèm `direct_normal_irradiance` (−0,0812): chiều muộn, Mặt Trời đã xuống thấp nên mức kỳ vọng suy từ quy mô trạm cao hơn sản lượng thực tế. Ở ca gần nền, tổng đóng góp gần triệt tiêu vì các phần dương và âm cân nhau. Hai hình dạng thác tương phản trình bày ở Hình 6.12.



Hình 6.12: Biểu đồ SHAP Waterfall giải thích hai trường hợp dự báo tương phản.

6.6.4 Giới hạn diễn giải


SHAP quy phần đóng góp của đặc trưng vào dự báo của mô hình, không phải vào sản lượng thật. Nó cho biết mô hình đã dựa vào đâu, không cho biết quan hệ nhân quả vật lý. Khi hai đặc trưng tương quan cao, mà Mục 6.3.7 cho thấy có nhiều cặp như vậy, phần đóng góp có thể bị chia giữa chúng theo cách phụ thuộc vào cấu trúc cây đã học, nên không nên đọc thứ hạng như một xếp hạng tầm quan trọng vật lý.

6.7 Ứng dụng trực quan hoá kết quả

Kết quả dự báo được đưa vào một ứng dụng Streamlit gồm ba trang, mã nguồn tại `srcs/07_dashboard/`. Ứng dụng đọc lại đúng các tệp kết quả mà Phần 5 dùng, không tính lại chỉ số. Ba trang lần lượt ở Hình 6.13, Hình 6.14 và Hình 6.15.

6.7.1 Trang giám sát chuỗi thời gian


Trang này đặt đường thực tế cạnh đường dự báo theo từng trạm và từng khoảng thời gian, kèm bảng chỉ số theo trạm và biểu đồ đối chiếu với Prophet.



Hình 6.13: Giao diện Trang 1: Giám sát chuỗi thời gian theo trạm.

6.7.2 Trang giải thích dự báo


Trang này đưa kết quả SHAP ở Mục 6.6 lên giao diện: tỷ trọng đóng góp theo nhóm đặc trưng, xếp hạng đặc trưng, và giải thích một dự báo cụ thể do người dùng chọn.



Hình 6.14: Giao diện Trang 2: Giải thích dự báo bằng SHAP.

6.7.3 Trang dự báo và phân tích giả định

Trang này gọi `forecast_service.py` để sinh dự báo mới. Điểm cần nêu về mặt kỹ thuật: dịch vụ này **đọc lại** `clip_k` và các tham số chuẩn hoá từ `model_config.json` của chính mô hình đang dùng, thay vì khai báo lại trong mã phục vụ. Nhờ vậy phép nhân ngược từ k về kWh ở giai đoạn suy luận sử dụng cùng bộ tham số với giai đoạn huấn luyện; nếu hai bên khai báo riêng thì chỉ cần một lần sửa cấu hình là kết quả trên giao diện lệch khỏi kết quả trong báo cáo mà không ai phát hiện.



Hình 6.15: Giao diện Trang 3: Dự báo và phân tích giả định (What-If).

6.8 Kết luận và hướng phát triển

Mục này tổng kết ba phần: kết quả đạt được, giới hạn của công trình, và hướng phát triển.

6.8.1 Kết quả đạt được

Quy trình dựng được một mô hình LightGBM dùng chung cho 40 trạm quang điện, đạt WAPE 17,74% ở tầm 15 phút và 22,62% ở tầm một giờ trên tập test niêm phong, phạm vi đo thật ban ngày. So với đối chứng Prophet trên cùng tập dòng, chỉ số vượt trội đạt +49,53% và +36,26%.

Điều đáng nói hơn con số là cách các con số đó được bảo vệ. Năm rào chắn ở Mục 6.1.5 được kiểm chứng bằng số liệu chứ không bằng lập luận: phép ghép thời tiết nhân quả đưa số dòng dùng thời tiết tương lai về 0; thống kê quy mô tính riêng theo từng fold; cận cắt suy từ phân vị của tập huấn luyện; tập test mở đúng một lần. Hàm mất mát cho cả hai tầm được chốt trên tập kiểm định trước khi tập test được mở, và mọi chỉ số báo cáo ở Mục 6.5 đều là kết quả của lần mở duy nhất đó.

6.8.2 Hạn chế

- **Bộ dữ liệu độc lập nhỏ hơn con số 42.** Bốn mươi hai vị trí lắp đặt điện mặt trời nằm trên năm khuôn viên, nên dữ liệu khí tượng bị nhân bản giữa các trạm cùng khuôn viên; số mẫu

thời tiết độc lập thực chất là năm.

- **Sai số phân bố không đều giữa các trạm**, từ 11,89% tới 28,32% ở tầm H1, và 15,12% tới 35,88% ở tầm H4. Mô hình dùng chung chưa mô tả hết phần khác biệt riêng của từng trạm.
- **Độ trễ pha còn tồn tại ở mức thấp**: trung vị +15 phút, và 32 trên 40 trạm nghiêng về phía trễ.
- **Phép đối chứng Prophet không tách được đóng góp của biến khí tượng**, vì hai mô hình khác nhau đồng thời ở thuật toán và tập đầu vào.
- **Hai siêu tham số (*hyperparameter*) dừng ngay tại biên miền tìm kiếm**, nên không thể tuyên bố cấu hình hiện tại là tối ưu.
- **Thời tiết chỉ có độ hạt một giờ**, và bước hạ độ hạt mới đưa tỷ lệ bước có giá trị thay đổi lên 76,7%, chưa phủ hết các khối rìa sáng và rìa chiều.

6.8.3 Hướng phát triển

Ba việc cụ thể, xếp theo mức dễ làm:

1. Mở rộng miền tìm kiếm ở hai chỗ chạm biên, hạ cận dưới của `subsample` và nâng cận trên của `reg_alpha`.
2. Chạy hai cấu hình đối chứng còn thiếu để tách phần đóng góp của nhóm đặc trưng khí tượng: một LightGBM bỏ hết biến khí tượng, và một Prophet có biến ngoại sinh.
3. Xử lý phần khác biệt giữa các trạm, hoặc bằng đặc trưng riêng cho trạm, hoặc bằng cách hiệu chỉnh đầu ra theo từng trạm sau khi dự báo.

Kết luận và Hướng phát triển

7.1 Kết luận Tổng quan

Dự án đã hoàn thành toàn diện các mục tiêu nghiên cứu và kỹ thuật đề ra, giải quyết trọn vẹn chuỗi giá trị dữ liệu từ khâu thu thập, tiền xử lý, lưu trữ, phát hiện dị thường cho đến dự báo sản lượng và trực quan hóa phân tích hệ thống điện mặt trời:

- **Kiến trúc kho dữ liệu chuẩn hóa và hiệu năng cao:** Thiết kế và vận hành thành công kho dữ liệu (Data Warehouse) trên nền tảng Supabase PostgreSQL theo mô hình Galaxy Schema kết nối 2 bảng Fact và 4 bảng Dimension. Hệ thống tích hợp cơ chế Connection Pooling qua `pg8000`, quy trình nạp dữ liệu tuần tự an toàn giao dịch (Explicit DB Transaction) và cơ chế kiểm tra đối chiếu vân tay dữ liệu (MD5 Fingerprint), bảo toàn trọn vẹn tính toán vẹn tham chiếu cho hơn 2,73 triệu bản ghi quan trắc từ 42 trạm PV.
- **Quy trình tiền xử lý và kỹ thuật đặc trưng chuyên sâu:** Xây dựng pipeline tự động hóa xử lý triệt để 107.452 ô dữ liệu khuyết thiếu (đạt 100%) thông qua chiến lược nội suy lai kết hợp quy tắc vật lý ban đêm (Night-Zeroing) và nội suy phân cấp (Linear, Cubic Spline, Multivariate Regression). Đồng thời, dự án giải quyết thành công bài toán lệch pha tần suất ghi nhận (đồng bộ chu kỳ 15 phút lên 1 giờ) và trích xuất các đặc trưng thời gian kết hợp lịch trình vận hành học xá (`is_semester`, `is_exam`, `is_holiday`) nhằm loại bỏ triệt để hiện tượng rò rỉ dữ liệu (Data Leakage).
- **Mô hình học máy phát hiện dị thường và dự báo sản lượng:** Triển khai thành công kiến trúc phân lớp lai 3 tầng GMM-IF (Gaussian Mixture Model kết hợp Isolation Forest) trên các phân đoạn cây quyết định, kết hợp bộ 6 mã rào chắn vật lý để gấn cờ chính xác 33.280 bản ghi ngoại lai (tỷ lệ 1,22%) phục vụ chẩn đoán bảo trì. Đồng thời, xây dựng và tối ưu hóa mô hình học máy (LightGBM kết hợp Optuna) dự báo sản lượng điện theo giờ, tích hợp phân tích SHAP nhằm giải thích định lượng mức độ đóng góp của các yếu tố khí tượng và nhiệt độ.
- **Hệ thống trực quan hóa hỗ trợ ra quyết định:** Thiết kế bộ 3 Dashboard quản trị hoàn chỉnh trên Tableau Desktop (Executive Overview, Operational Efficiency & Loss Analysis, Anomaly Detection & Predictive Maintenance) với cấu trúc UI/UX nhất quán, giúp chuyển đổi dữ liệu kỹ thuật thành các chỉ số vận hành trực quan, phục vụ điều độ năng lượng và hỗ trợ bảo trì chủ động dựa trên điều kiện (Condition-Based Maintenance).

7.2 Khuyến nghị

Dựa trên kết quả phân tích thực nghiệm từ kho dữ liệu tập trung, mô hình phân lớp ngoại lai GMM-IF và mô hình học máy dự báo sản lượng, nhóm đề xuất các giải pháp kỹ thuật và vận hành có tính ứng dụng cao cho đơn vị quản lý:

1. **Ứng dụng mã chẩn đoán GMM-IF vào quy trình bảo trì dựa trên điều kiện (Condition-Based Maintenance):** Thay vì thực hiện kiểm tra thủ công định kỳ, bộ phận kỹ thuật nên tích hợp trực tiếp 6 mã phân loại lý do ngoại lai từ Pipeline lên hệ thống giám sát thời gian thực. Cụ thể:
 - Khi xuất hiện mã PHYSICAL_LOW_ENERGY_STRONG_SUN: Lập tức phát lệnh kiểm tra sự cố ngắt mạch biến tần (Inverter trip), hỏng diode bypass hoặc hiện tượng che bóng bất thường tại chuỗi pin.
 - Khi xuất hiện mã PHYSICAL_HIGH_ENERGY_NO_SUN hoặc DISTRIBUTION_JUMP: Khoanh vùng xử lý lỗi cảm biến dòng điện (CT sensor drift), hiện tượng dòng rò ngược ban đêm hoặc xung nhiễu đường truyền viễn thông (telemetry spike) mà không cần rà soát toàn bộ dàn pin.
2. **Tối ưu hóa điều độ năng lượng học xá dựa trên mô hình dự báo và đặc trưng lịch trình (Campus Energy Dispatching):** Kết quả mô hình học máy cho thấy mối tương quan chặt chẽ giữa sản lượng điện tạo ra và lịch trình vận hành thực tế (`is_semester`, `is_exam`, `is_holiday`). Ban quản lý năng lượng khuôn viên có thể sử dụng dự báo sản lượng theo giờ (E_{hour}) để:
 - Chủ động lên kế hoạch vận hành các phụ tải tiêu thụ lớn (hệ thống điều hòa trung tâm HVAC, trạm sạc xe điện, máy chủ tính toán) vào khung giờ năng đạt đỉnh để tối đa hóa tỷ lệ tự tiêu thụ tại chỗ (Self-consumption).
 - Cắt giảm công suất đỉnh (Peak Shaving) mua từ lưới điện vào các khung giờ biểu giá cao trong mùa thi cử hoặc cao điểm học kỳ.
3. **Thiết lập cơ chế giám sát chất lượng dữ liệu tự động (Data Observability Pipeline):** Doanh nghiệp nên chuẩn hóa quy trình kiểm tra vận tay dữ liệu 4 bước (`fingerprint_supabase`) thành một tác vụ định kỳ tự động (Automated Health-check). Cơ chế này giúp phát hiện sớm các hiện tượng lệch pha dữ liệu (Data Shift), thiếu hụt bản ghi telemetry từ các trạm hoặc lỗi kết nối trước khi dữ liệu được nạp vào kho DWH phục vụ báo cáo BI.
4. **Phân bổ nguồn lực vận hành và bảo dưỡng (O&M) theo phân tích đóng góp đặc trưng SHAP:** Từ kết quả phân tích SHAP cho thấy nhiệt độ môi trường và tổn thất nhiệt là rào cản lớn nhất đối với hiệu suất phát điện khi bức xạ cao, ban quản lý nên ưu tiên kinh phí cải thiện giải pháp thông gió tự nhiên/cưỡng bức cho khu vực đặt biến tần tại các trạm có hệ số nhiệt độ suy giảm mạnh nhất trong danh mục 42 trạm, thay vì dàn trải ngân sách bảo dưỡng đồng đều.

7.3 Hạn chế

Mặc dù đã hoàn thiện toàn diện từ kiến trúc kho dữ liệu tập trung đến mô hình học máy và trực quan hóa Dashboard, đề tài vẫn tồn tại một số rào cản kỹ thuật xuất phát từ đặc tính dữ liệu thực tế và hạ tầng triển khai:

- **Lệch pha độ phân giải thời gian giữa hai nguồn dữ liệu (Granularity Mismatch):** Dữ liệu bức xạ và khí tượng viễn thám từ Open-Meteo API chỉ hỗ trợ tần suất ghi nhận theo chu kỳ 1 giờ, trong khi cảm biến sản lượng tại trạm đo đặc ở bước thời gian 15 phút. Việc bắt buộc phải gom cụm (Aggregation) sản lượng lên chu kỳ 1 giờ khiến mô hình mất đi khả năng nhận diện các biến động công suất ngắn hạn do hiện tượng mây che khuất tức thời (Cloud Transient Effects).
- **Thiếu hụt các tham số đo lường vật lý vi mô tại trạm:** Dữ liệu thực nghiệm của 42 trạm chưa bao gồm các cảm biến đo nhiệt độ thực tế bề mặt tấm pin (T_{cell}), thông số góc nghiêng và góc phương vị thực tế của từng chuỗi pin (Tilt/Azimuth), cũng như cảm biến đo độ bám bụi (Soiling Sensor). Do đó, mô hình phải ước lượng các tổn thất quang học và tổn thất nhiệt gián tiếp thông qua nhiệt độ môi trường 2m và các trường bức xạ tổng quát.
- **Hạn chế về tính tổng quát hóa theo vùng địa lý (Geographical Generalizability):** Toàn bộ dữ liệu 42 trạm phát được thu thập trong phạm vi các khuôn viên của Đại học La Trobe thuộc bang Victoria (Úc) với khí hậu ôn đới/bán khô hạn. Do đó, các bộ siêu tham số và trọng số mô hình cần được tái huấn luyện hoặc áp dụng kỹ thuật thích ứng miền (Domain Adaptation) trước khi có thể chuyển giao sang các khu vực có đặc thù khí hậu nhiệt đới gió mùa (như Việt Nam).
- **Kiến trúc vận hành xử lý theo lô (Batch Processing):** Toàn bộ quy trình từ ETL, phân lớp cơ ngoại lai GMM-IF cho đến nạp dữ liệu vào Supabase DWH hiện chạy theo từng đợt (Batch Mode). Hệ thống chưa hỗ trợ xử lý dòng dữ liệu liên tục thời gian thực (Streaming Pipeline) để phát tín hiệu cảnh báo tức thời các sự cố điện lưới (như Voltage Spikes hoặc Telemetry Dropouts) ngay tại thời điểm cảm biến ghi nhận.

7.4 Hướng phát triển trong tương lai

7.4.1 Nâng cấp Mô hình Học máy và Dự báo Đa bước

Nhằm nâng cao năng lực dự báo và tính ứng dụng thực tiễn trong điều độ năng lượng, hệ thống sẽ được mở rộng theo các hướng tiếp cận sau:

- **Mô hình hóa chuỗi thời gian sâu và định lượng độ bất định (Probabilistic Forecasting):** Nghiên cứu triển khai các kiến trúc Deep Learning chuyên biệt cho chuỗi thời gian như Temporal Fusion Transformer (TFT), PatchTST hoặc N-BEATS. Các mô hình này cho phép nắm bắt quan hệ phi tuyến dài hạn, đồng thời cung cấp các khoảng tin cậy (Prediction Intervals: P10, P50, P90) thay vì chỉ dự báo một giá trị điểm (Point Forecast), hỗ trợ quản trị rủi ro biến động phụ tải.
- **Dự báo siêu ngắn hạn (Nowcasting) kết hợp ảnh viễn thám:** Tích hợp luồng dữ liệu dự báo thời tiết số (Numerical Weather Prediction – NWP) có độ phân giải cao và dữ liệu ảnh vệ tinh thời gian thực để xây dựng mô hình Nowcasting trong khung thời gian 15–60 phút, phục vụ bài toán điều khiển biến tần tự động.

7.4.2 Tự động hóa MLOps, DataOps và Hạ tầng Điện toán Đám mây

Chuyển dịch toàn bộ quy trình sang môi trường đám mây nhằm tối ưu hóa khả năng mở rộng quy mô (Scalability):

- **Điều phối luồng dữ liệu tự động (Workflow Orchestration):** Triển khai Apache Airflow hoặc Prefect để tự động hóa toàn bộ các DAGs trích xuất, biến đổi và kiểm tra vân tay dữ liệu (Data Fingerprint). Kết hợp MLflow hoặc Weights & Biases để quản lý vòng đời mô hình (Model Registry) và theo dõi hiện tượng trôi dạt dữ liệu (Data Drift / Concept Drift) khi phân phối bức xạ thay đổi theo mùa.
- **Xây dựng kiến trúc xử lý dòng thời gian thực (Real-time Streaming):** Tích hợp Apache Kafka hoặc Redpanda kết hợp với ClickHouse/Supabase Realtime Engine để tiếp nhận trực tiếp luồng telemetry từ biến tần và đồng hồ thông minh theo chu kỳ giây.

7.4.3 Mở rộng Ứng dụng Thực tiễn và Điều độ Năng lượng Học xá

Khai thác sâu hơn các kết quả phân tích để phục vụ trực tiếp bài toán kinh tế và vận hành kỹ thuật:

- **Tối ưu hóa hệ thống pin lưu trữ (BESS Integration & Energy Arbitrage):** Kết hợp mô hình dự báo sản lượng điện mặt trời với hồ sơ tiêu thụ thực tế tại học xá và biểu giá điện theo giờ (Time-of-Use – TOU) để lập lịch sạc/xả tối ưu cho hệ thống pin lưu trữ năng lượng (Battery Energy Storage System – BESS), tối đa hóa tỷ lệ tự tiêu thụ (Self-consumption) và cắt giảm công suất đỉnh (Peak Shaving).
- **Đóng gói mô hình phát hiện dị thường lên thiết bị biên (Edge AI):** Tối ưu hóa và biên dịch khung phân lớp GMM-IF sang định dạng ONNX Runtime hoặc TensorRT để nhúng trực tiếp vào các bộ điều khiển công nghiệp (Edge Gateways/RTU) tại trạm, giúp cách ly và chẩn đoán sự cố ngay cả khi mất kết nối mạng về máy chủ trung tâm.

Phụ lục A: Kế hoạch Thực hiện và Phân công Nhiệm vụ

A.1. Lộ trình Thực hiện 14 Tuần (Sprint Timeline)

Sprint	Thời Gian	Quy Trình (CLO)	Nội Dung Trọng Tâm	Sản Phẩm Đầu Ra (Deliverables)
Sprint 1	Tuần 1 – 2	Bước 1: Thu thập (CLO1)	Khởi tạo & Thu thập dữ liệu thô	Project Charter, Backlog Jira, GitHub Repo, 2,73 triệu dòng dữ liệu La Trobe University, Open-Meteo API, AEMO VIC RRP.
Sprint 2	Tuần 3 – 4	Bước 1.5: Lưu trữ (CLO2)	Xây dựng Pipeline ETL & Data Warehouse	DDL Supabase PostgreSQL, Lược đồ Galaxy Schema, Staging & Buffer Layer, DVC, S3 Storage, CI/CD GitHub Actions.
Sprint 3	Tuần 5 – 6	Bước 2: Làm sạch (CLO3)	Làm sạch dữ liệu (Data Cleaning)	Thuật toán Hybrid Imputation và dữ liệu khuyết, lọc dị thường Rolling IQR & GMM-IF, cờ phân loại <code>gmm_if_outlier_flag</code> .
Sprint 4	Tuần 7 – 8	Bước 3: Chuyển đổi (CLO4)	Biến đổi & Làm giàu dữ liệu (Transformation)	Materialized Views <code>bi_mart</code> và <code>ml_mart</code> , logic tính toán PR, Temperature Loss, quy đổi tài chính theo giá AEMO Victoria.
Sprint 5	Tuần 9 – 10	Bước 4: Phân tích (CLO5)	Khám phá dữ liệu chuyên sâu (EDA)	Kiểm định tính dừng ADF Test, biểu đồ tự tương quan ACF/PACF, ma trận tương quan thời tiết và phân tích đa biến.
Sprint 6	Tuần 11	Bước 5: Trực quan (CLO6)	Trực quan hóa kết quả phân tích	Bộ 3 Dashboard Tableau hoàn chỉnh (Executive Snapshot, Technical Deep-Dive, Solar Asset & Weather Impact), <code>Preferences.tps</code> .
Sprint 7	Tuần 12 – 13	Bước 6: Dự báo (CLO7)	Mô hình hóa & Dự báo dữ liệu	Pipeline LightGBM/ARIMA, tối ưu Optuna, giải thích mô hình SHAP, Web App Streamlit (Interactive What-If Analysis).
Sprint 8	Tuần 14	Tổng kết (CLO8)	Hoàn thiện tài liệu dự án	Báo cáo tốt nghiệp hoàn chỉnh, tài liệu kiến trúc kỹ thuật DWH, video demo và đóng gói mã nguồn nghiệm thu.

Bảng 7.1: Lộ trình 14 tuần thực hiện dự án theo 8 Sprints chuẩn hóa theo CLO.

A.2. Ma trận Phân công Trách nhiệm Thành viên (RACI Matrix)

Thành Viên	MSSV	Phạm Vi Công Việc Chính	Tỷ Lệ (%)
Nguyễn Vũ Nhựt	PS44442	Trưởng nhóm (Team Leader / PM): Điều phối tiến độ dự án (Sprint/Jira), kiểm soát quy chuẩn kỹ thuật hệ thống, thực hiện Code Review, kiểm duyệt chất lượng dữ liệu và rà soát, hoàn thiện báo cáo tổng thể.	100%
Ngô Tấn Đạt	PS44589	Lead Data Architect / AI: Thiết kế kiến trúc Pipeline ETL/MLOps, quản lý cơ sở dữ liệu và hạ tầng DWH (Supabase/PostgreSQL), phát triển API, nghiên cứu và huấn luyện mô hình (GMM-IF, LightGBM/Optuna/SHAP).	100%
Lê Công Toàn	PS44145	Xây dựng module Tiền xử lý dữ liệu (Transform), nghiên cứu cơ sở toán học và triển khai thuật toán Điền khuyết nhân quả (Causal Cascade Imputation), đồng bộ dữ liệu đa tần số thời gian (15m vs 1h).	100%
Nguyễn Văn Sỹ	PS43671	Phân tích Khám phá Dữ liệu (EDA), khai phá insight từ mẫu hình phát điện, phát triển Hệ thống Dashboard Quản trị trên Tableau Desktop, thiết kế UI/UX theo bảng màu ngũ nghĩa và xây dựng Calculated Fields phức hợp.	100%
Nguyễn Xuân Hùng	PS44527	Quản lý tài liệu nghiệp vụ và đặc tả kỹ thuật, kiểm định và đối soát tính toàn vẹn dữ liệu (Data Quality & Verification), hỗ trợ triển khai cấu trúc kho dữ liệu và tổng hợp kết quả kiểm thử.	100%

Bảng 7.2: Phân công nhiệm vụ và khối lượng hoàn thành của các thành viên.

Phụ lục B: Cấu trúc Gói Mã nguồn

Toàn bộ mã nguồn của dự án được tổ chức theo cấu trúc module hóa hướng đối tượng chuẩn công nghiệp, cho phép tái lập 100% kết quả nghiên cứu:


Listing 7.1: Sơ đồ cấu trúc cây thư mục mã nguồn của dự án The Outliers

```
datn_outlier_hs_nlmt/
|-- data/
|   |-- raw/                                # Du lieu goc UNISOLAR & API
|   |-- staging_buffers/                    # Du lieu dem resample 15 phut
|   |-- mlmart_base/
|       |-- v4_final_cleaned.parquet        # Tap hop nhat 2,73M dong (ML Mart)
|-- docs/
|   |-- scrum_8_project_delivery_defense/# Tai lieu nghien cuu & bao ve
|-- reports/
|   |-- DATN_REPORT_FINAL_01.tex           # Bao cao tong hop chinh thuc
|   |-- Section1.tex -> Section7.tex       # Cac chuong bao cao doc lap
|   |-- figures/                           # So do kien truc & Dashboard
|   |-- images/                            # Bieu do EDA, SHAP & research
|-- srcs/
|   |-- 00_database/                       # DDL tao Supabase DWH (Galaxy)
|   |-- 00_utils/                          # Ket noi CSDL & Object Storage
|   |-- 01_extract/                        # Crawler Kaggle & Weather API
|   |-- 02_transform/
|       |-- 01_run_transform_buffers.py    # Resample 15m & dien khuyet
|       |-- 02_generate_outliers/         # Thuat toan GMM-IF gan 6 ma loi
|   |-- 03_load/                           # Nap vao Supabase Data Warehouse
|   |-- 04_build_data_marts/               # Tao BI Mart & Views cho Tableau
|   |-- 05_machine_learning/
|       |-- pipeline/
|           |-- core/                      # Metric WAPE, Huber, L1 Loss
|           |-- stages/ (s01 -> s10)       # 10 buoc pipeline ML tu dong
|           |-- actions/                   # Optuna 50 trials & Baseline
|   |-- 06_run_pipeline/                   # Orchestrator dieu phoi toan bo
|   |-- 07_dashboard/
|       |-- app.py                         # Ung dung Streamlit tuong tac
|       |-- forecast_service.py            # Dich vu du bao realtime doc lap
|       |-- pages/                        # Cac trang (TimeSeries, SHAP, DuBao)
```

Phụ lục C: Vòng đời học máy

Hình 6.3 ở Mục 6.1.2 sử dụng bản vẽ đã được Việt hóa tiêu đề để phục vụ công tác trình bày báo cáo. Phụ lục này trích dẫn bản vẽ nguyên tác tiếng Anh theo tài liệu đào tạo chuyên ngành MLOps quốc tế để người đọc tiện tra cứu các thuật ngữ kỹ thuật gốc.

◇ ML Life Cycle



Hình 7.1: Vòng đời học máy (MLOps Lifecycle) [24].

Thuật Ngữ Tiếng Anh (Gốc)	Thuật Ngữ Tiếng Việt	Ý Nghĩa Kỹ Thuật trong Dự Án
Data Ingestion & Versioning	Thu nạp & Đánh phiên bản	Lưu vết 2,73 triệu dòng dữ liệu sạch bằng tệp Parquet.
Causal Feature Engineering	Kỹ sư đặc trưng nhân quả	Chỉ dùng dữ liệu quá khứ ($t \leq T$) chống rò rỉ thông tin.
Time-Series Cross Validation	Kiểm tra chéo chuỗi thời gian	Sử dụng 3-Fold Expanding Window bảo toàn tính thứ tự thời gian.
Hyperparameter Optimization	Tối ưu hóa siêu tham số	Sử dụng thuật toán Bayesian TPE qua 50 Trials Optuna.
Explainable AI (XAI)	Trí tuệ nhân tạo giải thích được	Sử dụng SHAP TreeExplainer bóc tách mức độ đóng góp biến số.
Model Serving & Inference	Đóng gói & Dự báo thực thi	Module ForecastService phản hồi dự báo thời gian thực.

Bảng 7.3: Bảng đối chiếu thuật ngữ kỹ thuật MLOps Anh – Việt.

Phụ lục D: Bảng Tra cứu Chi tiết 6 Mã Dị thường Kỹ thuật

Hệ thống phân lớp lại GMM–IF gán nhãn 33.280 bản ghi dị thường thành 6 mã lý do kỹ thuật phục vụ công tác O&M hiện trường:

Mã Kỹ Thuật	Điều Kiện Kích Hoạt	Bản Chất Sự Cố / Vật Lý	Hành Động Khuyến Nghị
zero_drift	$GHI = 0 \text{ W/m}^2$, $h \leq 0^\circ$, $0 < E \leq 0,025 \text{ kWh}$	Biến dòng CT bị trôi điểm cân bằng điện áp 0V ban đêm.	Tăng ETL tự động ép về 0; Lên lịch hiệu chuẩn biến dòng CT.
night_leakage	$GHI = 0 \text{ W/m}^2$, $h \leq 0^\circ$, $E > 0,025 \text{ kWh}$	Dòng rò cảm ứng hoặc vi xử lý Inverter tiêu thụ điện tự dùng.	Kiểm tra an toàn cách điện tủ phân phối AC và chống rò.
underperformance	$GHI \geq 500 \text{ W/m}^2$, $E < 0,5 \times E_{\text{expected}}$	Hỏng diode bypass, đứt cầu chì DC 1 chuỗi, hoặc cell pin bị rạn nứt.	Cử kỹ sư dùng camera nhiệt hồng ngoại quét tìm chuỗi pin lỗi.
inverter_zero_output	$GHI \geq 700 \text{ W/m}^2$, $E = 0 \text{ kWh}$	Biến tần ngắt mạch khẩn cấp do quá áp lưới ($> 253\text{V}$) hoặc quá nhiệt.	Kiểm tra rô-le bảo vệ điện áp lưới và hệ thống quạt tản nhiệt.
thermal_derating	$T_{\text{amb}} \geq 40^\circ\text{C}$, $GHI \geq 800$, $0,6 \leq E/E_{\text{exp}} \leq 0,85$	Biến tần tự động giảm tải để bảo vệ linh kiện bán dẫn công suất IGBT.	Lắp tấm chắn nắng phản quang; vệ sinh lưới tản nhiệt biến tần.
inverter_clipping	$GHI \geq 850 \text{ W/m}^2$, $E \approx P_{\text{AC, max}}$ (đỉnh phẳng)	Công suất DC vượt định mức AC ($ILR = 1,25$).	Tối ưu kinh tế thiết kế theo chuẩn CEC; không cần can thiệp kỹ thuật.

Bảng 7.4: Ma trận tra cứu 6 mã dị thường kỹ thuật GMM–IF và quy trình xử lý.

Tài Liệu Tham Khảo

- [1] S. Wimalaratne, D. Haputhanthri, S. Kahawala, G. Gamage, D. Alahakoon, và A. Jennings, “UNISOLAR: An Open Dataset of Photovoltaic Solar Energy Generation in a Large Multi-Campus University Setting,” *15th International Conference on Human System Interaction (HSI)*, IEEE, 2022. DOI: [10.1109/HSI55341.2022.9869474](https://doi.org/10.1109/HSI55341.2022.9869474).
- [2] Open-Meteo, “Historical Weather API & ERA5/ERA5-Land Reanalysis Climate Dataset,” *Open-Meteo Documentation*, 2023. [Online]. Available: <https://open-meteo.com/>.
- [3] IEA-PVPS Task 13, “Performance, Operation and Reliability of Photovoltaic Systems: Review of Failures and Degradation Mechanisms,” *International Energy Agency Technical Report*, IEA-PVPS T13-15:2023, 2023.
- [4] X. Li, G. Du, Y. Li, Z. Ma, L. Liu, M. Jiang, F. Liu, và T. Mu, “Outlier Detection of Photovoltaic Power Generation System Data Based on GMM-IF Algorithm,” *IEEE Access*, vol. 13, pp. 108823–108837, 2025. DOI: [10.1109/ACCESS.2025.3581641](https://doi.org/10.1109/ACCESS.2025.3581641).
- [5] F. T. Liu, K. M. Ting, và Z.-H. Zhou, “Isolation Forest,” trong *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, 2008, pp. 413–422.
- [6] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, New York, 2006.
- [7] J. W. Tukey, *Exploratory Data Analysis*, Addison-Wesley, Reading, MA, 1977.
- [8] V. Chandola, A. Banerjee, và V. Kumar, “Anomaly Detection: A Survey,” *ACM Computing Surveys*, vol. 41, no. 3, pp. 1–58, 2009.
- [9] T. Kim, W. Ko, và J. Kim, “Analysis and Impact Evaluation of Missing Data Imputation in Day-ahead PV Generation Forecasting,” *Applied Sciences*, vol. 9, no. 1, p. 204, 2019. DOI: [10.3390/app9010204](https://doi.org/10.3390/app9010204).
- [10] M. Roy, V. Pyltsov, và Y. Hu, “IISE PG&E Energy Analytics Challenge 2025: Hourly-Binned Regression Models Beat Transformers in Load Forecasting,” Columbia University, arXiv:2505.11390, 2025. [Online]. Available: <https://arxiv.org/abs/2505.11390>.
- [11] B. Haurwitz, “Insolation in Relation to Cloudiness and Cloud Density,” *Journal of Meteorology*, vol. 2, no. 3, pp. 154–166, 1945.
- [12] M. D. Bailey và cộng sự, “Temporal and Spatial Downscaling for Solar Radiation,” arXiv:2405.11046, 2024. [Online]. Available: <https://arxiv.org/abs/2405.11046>.
- [13] N. A. Engerer và F. P. Mills, “KPV: A clear-sky index for photovoltaics,” *Solar Energy*, vol. 105, pp. 679–693, 2014. DOI: [10.1016/j.solener.2014.04.019](https://doi.org/10.1016/j.solener.2014.04.019).

- [14] S. Dev, T. AlSkaif, M. Hossari, R. Godina, A. Louwen, và W. van Sark, “Solar Irradiance Forecasting Using Triple Exponential Smoothing,” trong *IEEE International Conference on Smart Energy Systems and Technologies (SEST)*, 2018. arXiv:1807.05872.
- [15] A. Temporal-Neto và cộng sự, “PIN: A new metric to evaluate solar irradiance forecast models,” *Energy Reports*, vol. 13, pp. 1–12, 2025. DOI: [10.1016/j.egyr.2025.01.076](https://doi.org/10.1016/j.egyr.2025.01.076).
- [16] S. M. Lundberg và S.-I. Lee, “A Unified Approach to Interpreting Model Predictions,” trong *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017. arXiv:1705.07874.
- [17] J. Zhang, A. Florita, B.-M. Hodge, S. Lu, H. F. Hamann, V. Banunarayanan, và A. M. Brockway, “A suite of metrics for assessing the performance of solar power forecasting,” *Solar Energy*, vol. 111, pp. 157–175, 2015. DOI: [10.1016/j.solener.2014.10.016](https://doi.org/10.1016/j.solener.2014.10.016).
- [18] J. Zhang, B.-M. Hodge, và A. Florita, “Comprehensive Evaluation of Solar Irradiance and Power Forecasting Metrics,” NREL/CP-5500-60142, *3rd International Workshop on Integration of Solar Power into Power Systems*, 2013.
- [19] V. P. Lonij, A. E. Brooks, K. Koch, và A. D. Cronin, “Analysis of 80 Rooftop PV Systems in the Tucson, AZ Area,” trong *38th IEEE Photovoltaic Specialists Conference (PVSC)*, 2012, pp. 549–553. DOI: [10.1109/PVSC.2012.6317674](https://doi.org/10.1109/PVSC.2012.6317674).
- [20] S. J. Taylor và B. Letham, “Forecasting at Scale,” *The American Statistician*, vol. 72, no. 1, pp. 37–45, 2018.
- [21] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, và G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed., John Wiley & Sons, Hoboken, NJ, 2015.
- [22] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, và T.-Y. Liu, “LightGBM: A Highly Efficient Gradient Boosting Decision Tree,” trong *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 3146–3154.
- [23] T. Chen và C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” trong *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.
- [24] Đặng Nhã và Anh Dương, “Data Version Control,” tài liệu bài giảng *AI VIET NAM — All-in-One 2025*, slide 9 (*Theory Perspective — ML Life Cycle*), 2025.
- [25] S. Kolassa và W. Schütz, “Advantages of the MAD/Mean ratio over the MAPE,” *Foresight: The International Journal of Applied Forecasting*, no. 6, pp. 40–43, 2007.
- [26] T. N. Nguyen và F. Müsgens, “A meta-analysis of solar forecasting based on skill score,” *Journal of Renewable and Sustainable Energy*, vol. 18, no. 2, p. 026102, 2026. DOI: [10.1063/5.0300682](https://doi.org/10.1063/5.0300682).

- [27] R. Marquez và C. F. M. Coimbra, “Proposed Metric for Evaluation of Solar Forecasting Models,” *Journal of Solar Energy Engineering* (ASME), vol. 135, no. 1, p. 011016, 2013. DOI: [10.1115/1.4007496](https://doi.org/10.1115/1.4007496).
- [28] WWRP/WGNE Joint Working Group on Forecast Verification Research, “Forecast Verification: Issues, Methods and FAQ,” Bureau of Meteorology, Australia, 2009. [Online]. Available: https://www.cawcr.gov.au/projects/verification/verif_web_page.html.
- [29] R. Kimball và M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed., John Wiley & Sons, Indianapolis, IN, 2013.
- [30] World Meteorological Organization (WMO), *Guide to Instruments and Methods of Observation: Volume I – Measurement of Meteorological Variables*, WMO-No. 8, Geneva, Switzerland, 2021.
- [31] Supabase Inc., “PostgreSQL Database & Row-Level Security for Modern Analytics Architecture,” *Supabase Technical Architecture Documentation*, 2024. [Online]. Available: <https://supabase.com/docs>.
- [32] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [33] Tableau Software (Salesforce), *Visual Analysis Best Practices: A Guide to Creating Meaningful Dashboards*, Seattle, WA, 2023.
- [34] National Oceanic and Atmospheric Administration (NOAA), “Solar Position Calculator,” Earth System Research Laboratories, Global Monitoring Laboratory, [Online]. Available: <https://gml.noaa.gov/grad/solcalc/>.