

Thiết kế, Huấn luyện và Đánh giá Mô hình Dự báo Sản lượng Quang điện

Nhóm The Outliers

Mục lục

1 Tổng quan quy trình học máy	4
1.1 Phạm vi và dữ liệu đầu vào	4
1.2 Bài toán và tầm dự báo	4
1.3 Nhấn ngoại lai kế thừa từ tầng ETL	6
1.3.1 Bốn phép đo thay cho precision và recall	7
1.4 Sơ đồ toàn cảnh	12
1.5 Năm rào chắn chống rò rỉ dữ liệu	12
2 Chuẩn bị dữ liệu và chia tập	14
2.1 Dựng lại lưới thời gian liên tục	14
2.2 Phân tích khám phá dữ liệu và các quyết định sinh đặc trưng	17
2.2.1 Phân bố đơn biến của sản lượng	17
2.2.2 Mẫu hình phát điện và tác động của mây	18
2.2.3 Tự tương quan	19
2.2.4 Tương quan giữa các biến	20
2.3 Chia dữ liệu theo trục thời gian	21
2.4 Ba fold theo cửa sổ mở rộng	22
2.5 Thực nghiệm: đo phần chồng lấn nhãn ở ranh giới fold	23
3 Sinh đặc trưng	24
3.1 Đặc trưng thời gian, trễ và cửa sổ trượt	25
3.1.1 Thực nghiệm: chọn mốc trễ	25
3.1.2 Cổng lệch pha đặt trước bước tính chỉnh	27
3.1.3 Rào chắn chống rò rỉ và ngưỡng cảnh lùi	28
3.2 Hình học Mặt Trời, bức xạ trời quang và chuẩn hoá theo trạm	29

3.2.1	Vị trí Mặt Trời theo thuật toán NOAA	29
3.2.2	Bức xạ trời quang theo mô hình Haurwitz	30
3.2.3	Thực nghiệm: hạ độ phân giải bức xạ từ một giờ về mười lăm phút	32
3.2.4	Chuẩn hoá quy mô theo trạm	32
3.2.5	Tương tác khí tượng và mã hoá biến phân loại	32
3.3	Định nghĩa các đặc trưng dẫn xuất	35
3.4	Thực nghiệm: khử độ trễ cài sẵn bằng đặc trưng tại thời điểm mục tiêu .	37
3.5	Chuẩn hoá mục tiêu theo vật lý	38
3.6	Kiểm chứng các tham số cố định	41
3.7	Chẩn đoán và chọn đặc trưng	43
3.7.1	Chẩn đoán đa cộng tuyến	44
3.7.2	Danh sách cấm	46
3.7.3	Chấm điểm bằng thông tin tương hỗ	46
3.7.4	Danh sách bảo vệ	48
3.7.5	Kết quả áp cho mười tập	49
3.8	Tổng hợp bộ đặc trưng đưa vào mô hình	49
4	Huấn luyện và chọn hàm mất mát	50
4.1	Chính sách trọng số cho dòng ngoại lai	51
4.2	Tinh chỉnh siêu tham số	51
4.3	Sáu cấu hình Optuna chọn được	52
4.4	Chọn hàm mất mát	52
4.5	Cấu hình tắt định	53
5	Đánh giá trên tập test niêm phong	54
5.1	Thước đo	54
5.2	Phạm vi chấm điểm	55
5.3	Kết quả	55
5.4	Chênh lệch giữa sai số trên test và trên kiểm định	56
5.5	Đối chứng với Prophet	57
5.5.1	Chỉ số dự báo vượt trội	57
5.5.2	Điều kiện so sánh	57
5.5.3	Giới hạn của phép đối chứng	57
5.6	Kiểm chứng độ trễ pha trên mô hình cuối	58
6	Giải thích mô hình bằng SHAP	59
6.1	Cơ sở phương pháp	59

6.2	Tầm quan trọng tổng thể	60
6.3	Giải thích ba dự báo cụ thể	61
6.4	Giới hạn diễn giải	64
7	Ứng dụng trực quan hoá kết quả	64
7.1	Trang giám sát chuỗi thời gian	64
7.2	Trang giải thích dự báo	64
7.3	Trang dự báo và phân tích giả định	64
8	Kết luận và hướng phát triển	65
8.1	Kết quả đạt được	65
8.2	Giới hạn	68
8.3	Hướng phát triển	68

1 Tổng quan quy trình học máy

1.1 Phạm vi và dữ liệu đầu vào

Phần này trình bày toàn bộ quy trình học máy của dự án, bắt đầu từ tệp dữ liệu đã làm sạch ở tầng ETL và kết thúc ở ứng dụng dự báo. Các bước trích xuất, biến đổi và nạp dữ liệu vào kho không thuộc phạm vi tài liệu này.

Đầu vào duy nhất của quy trình là tệp `data/mlmart_base/v4_final_cleaned.parquet`, gồm **2.731.946** bản ghi ở độ phân giải 15 phút, thu thập từ **42** dàn quang điện đặt tại **5** khuôn viên của Đại học La Trobe, Úc. Mỗi bản ghi mang giá trị sản lượng của một dàn tại một mốc thời gian, kèm các biến khí tượng tương ứng lấy từ Open-Meteo. Không phải mọi giá trị đều là số đo gốc — cột `energy_source` phân biệt dòng đo thật với dòng do tầng ETL điền khuyết, và Mục 2.1 trình bày tỷ lệ từng loại.

Phần sản lượng bắt nguồn từ bộ dữ liệu mở **UNISOLAR** do Wimalaratne và cộng sự [1] công bố. Bài báo mô tả đúng cấu hình mà dự án đang dùng — 42 dàn quang điện trên năm khuôn viên của Đại học La Trobe, bang Victoria, Úc, đo ở bước 15 phút — kèm vị trí địa lý và thông số kỹ thuật của từng dàn, xem Hình 1.

UNISOLAR đi kèm dữ liệu khí tượng của Cục Khí tượng Úc ở bước một phút. Dự án lấy biến khí tượng từ **Open-Meteo** theo toạ độ của từng khuôn viên, nên mọi kết luận về nhóm đặc trưng khí tượng trong tài liệu này thuộc về nguồn Open-Meteo.

Hai trạm mang số hiệu 19 và 24 có siêu dữ liệu công suất lắp đặt mâu thuẫn với sản lượng đo được, nên bị loại khỏi phạm vi huấn luyện và chấm điểm. Mô hình cuối cùng vì vậy được đánh giá trên 40 trạm; hai trạm còn lại vẫn nằm trong kho dữ liệu và vẫn hiển thị trên ứng dụng, chỉ không tham gia vào các con số được báo cáo.

1.2 Bài toán và tầm dự báo

Mục tiêu dự báo là **sản lượng điện phát ra** của từng dàn quang điện, ký hiệu y , đơn vị kWh trên mỗi khoảng 15 phút. Đây là bài toán dự báo chuỗi thời gian có biến ngoại sinh: ngoài lịch sử sản lượng của chính dàn đó, mô hình còn được cung cấp các biến khí tượng và hình học Mặt Trời tại thời điểm cần dự báo.

Tầm dự báo (*forecast horizon*) là khoảng cách thời gian giữa thời điểm đưa ra dự báo và thời điểm được dự báo. Dự án huấn luyện hai cấu hình ứng với hai tầm:

- **H1** — dự báo sản lượng tại $T + 15$ phút, tức một bước phía trước.
- **H4** — dự báo sản lượng tại $T + 60$ phút, tức bốn bước phía trước.

UNISOLAR: An Open Dataset of Photovoltaic Solar Energy Generation in a Large Multi-Campus University Setting

Shashini Wimalaratne
Centre for Data Analytics and
Cognition (CDAC)
La Trobe University
Melbourne, Australia
shashini.18@cse.mrt.ac.lk

Dilantha Haputhanthri
Centre for Data Analytics and
Cognition (CDAC)
La Trobe University
Melbourne, Australia
d.haputhanthrige@latrobe.edu.au

Sachin Kahawala
Centre for Data Analytics and
Cognition (CDAC)
La Trobe University
Melbourne, Australia
s.kahawala@latrobe.edu.au

Gihan Gamage
Centre for Data Analytics and
Cognition (CDAC)
La Trobe University
Melbourne, Australia
g.gamage@latrobe.edu.au

Daminda Alahakoon
Centre for Data Analytics and
Cognition (CDAC)
La Trobe University
Melbourne, Australia
d.alahakoon@latrobe.edu.au

Andrew Jennings
Centre for Data Analytics and
Cognition (CDAC)
La Trobe University
Melbourne, Australia
andrew.jennings@latrobe.edu.au

Abstract—We introduce an open dataset of high-granularity Photovoltaic (PV) solar energy generation, solar irradiance, and weather data from 42 PV sites deployed across five campuses at La Trobe University, Victoria, Australia. The dataset includes approximately two years of PV solar energy generation data collected at 15-minute intervals. Geographical placement and engineering specifications for each of the sites are also provided to aid researchers in modelling solar energy generation. Weather data is available at 1-minute intervals and is provided by the Australian Bureau of Meteorology (BOM). Apparent temperature, air temperature, dew point temperature, relative humidity, wind speed, and wind direction were provided under the weather data. The paper describes the data collection methods, cleaning, and merging with weather data. This dataset can be used to forecast, benchmark, and enhance operational outcomes in solar sites.

Keywords—renewables, photovoltaic, dataset, solar energy generation, solar irradiance, weather, net-zero carbon emissions

rooftops of all university buildings across its five campuses. The university has installed PV systems on the rooftops at the Bundoora and Mildura campuses and solar carports have been constructed at Bendigo and Albury-Wodonga campuses. The main campus in Bundoora has 7500 solar panels installed across 25 buildings, which translates to a decrease of 4000 tonnes of CO₂ emissions per annum and 50% of daytime demand for electricity.

The La Trobe Energy AI/Analytics Platform (LEAP) is the flagship AI initiative of this commitment towards achieving Net Zero Carbon Emissions by 2029. LEAP draws on diverse datasets related to electricity consumption, renewables generation, energy utilization, as well as water and gas consumption. In this paper, we present UNISOLAR, an open dataset of high-granularity PV energy generation and weather data collected over 2.5 years (2020-2022) from the multi-campus setting of La Trobe University. This dataset contains PV data and weather data from 42 sites across the five campuses in the La Trobe university network: Bundoora.

Hình 1: Trang đầu bài báo công bố bộ dữ liệu UNISOLAR [1], IEEE *International Conference on Human-System Interaction* 2022. Phần tóm tắt xác nhận quy mô 42 dàn quang điện trên năm khuôn viên và bước đo 15 phút.

Hai tầm này phục vụ hai nhu cầu vận hành khác nhau: H1 dùng cho điều độ tức thời, H4 dùng cho lập kế hoạch trong giờ tới. Mỗi tầm có một mô hình riêng, được huấn luyện và chấm điểm độc lập.

Cơ sở chọn họ mô hình. Dự án dùng LightGBM — một mô hình cây tăng cường gradient — thay vì các kiến trúc học sâu dựa trên transformer. Lựa chọn này có tiền lệ định lượng trong tài liệu: Roy, Pyltsov và Hu [2] chấm 12 mô hình dự báo phụ tải điện trên cùng bộ dữ liệu của cuộc thi IISE PG&E Energy Analytics Challenge 2025, trải từ hồi quy tuyến tính từng khúc tới TimeGPT. Kết quả đo được cho thấy mô hình cây tăng cường gradient đạt sai số thấp hơn các kiến trúc học sâu ở cả ba kịch bản kiểm thử, với khoảng cách không nhỏ: RMSE 159,6 so với 239,5 của Transformer, tức thấp hơn 33%.

Bảng kết quả của bài báo ở Hình 2. Bối cảnh của công trình đó gần với bài toán của dự án ở ba điểm: dữ liệu có cấu trúc chu kỳ mạnh theo giờ và theo mùa, kích thước

Table 4: Model Comparison Results

Metric	Test Case	Models											
		Piecewise	Poly	XGBoost	RF	MLP	GP	LSTM	TF	NHITS	TCN	TFT	TimeGPT
R^2	Year 1 $\rightarrow$ Year 2	-3.2	0.6	0.8	0.8	0.8	0.8	0.7	0.7	0.7	0.7	0.3	0.18
	Year 2 $\rightarrow$ Year 1	0.7	0.8	0.9	0.8	0.9	0.9	0.7	0.7	0.6	0.7	0.2	0.32
	Both years	-7054e3	-750e6	0.7	0.6	0.5	0.5	0.5	0.5	0.3	0.4	0.4	$\times$
RMSE	Year 1 $\rightarrow$ Year 2	833.2	263.4	159.6	174.8	160.6	168.9	220.9	239.5	233.6	222.8	329.3	369.03
	Year 2 $\rightarrow$ Year 1	242.0	181.6	178.6	189.6	170.7	177.2	254.8	270.7	294.4	237.7	408.0	383.18
	Both years	1e6	12e6	263.7	286.5	312.5	308.1	311.6	309.9	368.5	334.9	348.7	$\times$

Hình 2: Bảng 4 của Roy, Pyltsov và Hu [2], so sánh 12 mô hình trên cùng bộ dữ liệu. Khung đỏ đánh dấu ba dòng RMSE — chỉ số càng nhỏ càng tốt. Ở kịch bản *Year 1 $\rightarrow$ Year 2*, mô hình cây XGBoost đạt 159,6 trong khi Transformer (cột TF) là 239,5, LSTM là 220,9 và TimeGPT là 369,03.

tập huấn luyện ở mức triệu dòng chứ không phải hàng chục triệu, và yêu cầu vận hành đòi hỏi mô hình chạy lại được trên CPU. Bài báo làm trên bài toán **phụ tải điện**, không phải sản lượng quang điện; nguồn này được dẫn như **tiền lệ về lựa chọn họ mô hình**. Kết quả của dự án được chứng minh bằng phép đối chứng riêng với mô hình Prophet, trình bày ở phần đánh giá.

1.3 Nhãn ngoại lai kế thừa từ tầng ETL

Tập dữ liệu đầu vào mang sẵn hai cột do tầng ETL sinh ra: `gmm_if_outlier_flag` và `gmm_if_outlier_reason`. Quy trình học máy không tự phát hiện ngoại lai mà **kế thừa** kết quả này. Vì các nhãn đó quyết định dòng nào được tham gia huấn luyện và dòng nào bị loại khỏi chỉ số báo cáo, phần dưới đây tóm tắt cách các nhãn này được tạo ra.

Thuật toán mang tên GMM-IF, ghép tên của hai kỹ thuật thành phần:

- **GMM** — *Gaussian Mixture Model*, mô hình hỗn hợp Gauss. Kỹ thuật này giả định dữ liệu sinh ra từ vài phân phối Gauss chồng lên nhau, rồi ước lượng **mật độ xác suất** tại mỗi điểm. Điểm nằm ở vùng mật độ thấp là điểm hiếm. Câu hỏi nó trả lời: *điểm này hiếm tới mức nào so với phân bố chung*.
- **IF** — *Isolation Forest*, rừng cô lập. Kỹ thuật này dựng nhiều cây chia ngẫu nhiên và đếm **số nhát cắt cần thiết để tách riêng** một điểm khỏi phần còn lại. Điểm bất thường nằm tách biệt nên bị cô lập sau rất ít nhát cắt. Câu hỏi nó trả lời: *tách điểm này ra khỏi đám đông dễ hay khó*.

Hai kỹ thuật đo hai thứ khác nhau — một bên là mật độ, một bên là độ tách biệt — nên có thể bổ trợ cho nhau, xem Hình 3. Cách ghép chúng lại thích nghi từ công

trình của Li và cộng sự [4]. Nhóm tác giả đó chỉ ra rằng dữ liệu chuỗi thời gian của hệ quang điện có tính phi tuyến và không dừng cao, nên khó mô tả bằng một phân phối Gauss duy nhất. Công trình đó đề xuất **phân đoạn dữ liệu trước rồi mới áp GMM** trong từng phân đoạn, đồng thời tích hợp Isolation Forest làm cơ chế quyết định ở bước chi tiết. Kết quả thực nghiệm của bài báo cho thấy phương án kết hợp cải thiện trung bình 3,8% về độ chính xác và 9,1% về F-value so với dùng riêng lẻ GMM hoặc Isolation Forest.

Hai nguyên lý này hỏi hai câu hỏi khác nhau về cùng một điểm dữ liệu. Hình 4 minh hoạ bằng chính dữ liệu của dự án.

Hình 4 cho thấy hai thuật toán không thay thế được nhau. Nửa trái, GMM gắn cờ 156 điểm trên 8.176 quan sát, tức $156/8.176 = 1,91\%$, toàn bộ nằm ở đuôi trên của sản lượng và rải đều qua mọi mức bức xạ; đại lượng nó đo là mức hiếm của điểm trong phân bố. Nửa phải, Isolation Forest gắn cờ 246 điểm, tức $246/8.176 = 3,01\%$, theo một đại lượng khác: số nhất cần thiết để tách điểm đó khỏi phần còn lại.

Hai tập cờ **không trùng nhau**: phần giao chỉ còn 144 điểm, tức GMM mất $156 - 144 = 12$ điểm và Isolation Forest mất $246 - 144 = 102$ điểm khi bắt cả hai cùng đồng ý. Có những điểm GMM cho là hiếm nhưng Isolation Forest thấy vẫn dễ giải thích, và ngược lại. Pipeline lấy phép giao để chỉ giữ phần mà cả hai góc nhìn cùng đồng ý, sau đó hợp thêm với các luật rào chắn vật lý.

Trên toàn bộ tệp đầu vào, cột `gmm_if_outlier_flag` gắn cờ **33.280** dòng trên tổng **2.731.946** dòng:

$$\frac{33.280}{2.731.946} = 0,012182 \rightarrow \mathbf{1,22\%} \quad (1)$$

Ba nhóm lý do chiếm phần lớn là vượt trần công suất, đồng thuận GMM-IF, và bước nhảy phân phối cục bộ.

1.3.1 Bốn phép đo thay cho precision và recall

Phát hiện ngoại lai ở đây là bài toán **học không giám sát**, và bộ dữ liệu không đi kèm nhãn sự cố do người vận hành xác nhận. Không có nhãn đối chiếu thì không tính được precision, recall hay F-score — nói cách khác, không có cách nào chấm điểm một ngưỡng là đúng hay sai. Vì vậy chất lượng của nhãn được đo bằng bốn đại lượng khác, mỗi đại lượng trả lời một câu hỏi kiểm chứng được.

Một — chất lượng phân đoạn của cây quyết định. Bước phân đoạn được chấm bằng hệ số xác định R^2 , đo trên toàn bộ 42 trạm: trung bình **0,758**, thấp nhất 0,606 và cao nhất 0,826. Con số này **không phải** độ chính xác của bộ phát hiện ngoại lai; nó chỉ

Received 29 March 2025, accepted 13 June 2025, date of publication 20 June 2025, date of current version 30 June 2025.

Digital Object Identifier 10.1109/ACCESS.2025.3581641



RESEARCH ARTICLE

Outlier Detection of Photovoltaic Power Generation System Data Based on GMM-IF Algorithm

XIN LI^{1,2}, GUOXIN DU^{1,2}, YUMAN LI³, ZENGQIANG MA^{1,2}, LIHU LIU⁴,
MINGLONG JIANG^{1,2}, FEIYU LIU^{1,2}, AND TIANNING MU⁵¹Hebei Provincial Collaborative Innovation Center of Transportation Power Grid Intelligent Integration Technology and Equipment, Shijiazhuang Tiedao University, Shijiazhuang, Hebei 050043, China²School of Electrical and Electronics Engineering, Shijiazhuang Tiedao University, Shijiazhuang, Hebei 050043, China³Department of Quality Inspection and Management, Hebei Chemical & Pharmaceutical College, Shijiazhuang, Hebei 050026, China⁴National Pipeline Network Group Northern Pipeline Company Ltd., Langfang, Hebei 065000, China⁵State Grid Shijiazhuang Electric Power Supply Company, Shijiazhuang 050051, China

Corresponding author: Yuman Li (ssqhx11@163.com)

This work was supported in part by the National Natural Science Foundation of China under Grant 12072207 and Grant 52205571, and in part by the Natural Science Foundation of Hebei Province under Grant E2021210105.

ABSTRACT The Gaussian Mixture Model (GMM) is widely used in anomaly detection due to its flexibility in handling complex data distributions and its soft classification mechanism. However, its modeling process relies on the assumption that data follows a Gaussian distribution. In contrast, time-series data from photovoltaic (PV) systems often exhibit high nonlinearity and non-stationarity, making it difficult to represent with a single Gaussian distribution, which affects detection performance. To address this issue and improve detection accuracy, this paper proposes a segmented GMM-IF outlier detection algorithm. In this method, the decision tree segmentation modeling strategy is used to structure the data to construct a local Gaussian-like distribution dataset to overcome the prior assumptions. Additionally, it integrates an Isolation Forest (IF) as the decision-making mechanism for detailed detection, further enhancing detection accuracy. Under different operating conditions and actual photovoltaic array datasets, comparative experiments were conducted using different evaluation metrics and algorithms to verify the effectiveness and superiority of the GMM-IF algorithm. Experimental results show that compared with the single model of GMM and IF, the GMM-IF algorithm has an average improvement of 3.8% in accuracy and 9.1% in F-value. Compared with other comparison algorithms, GMM-IF has obvious advantages, especially in terms of recall.

INDEX TERMS Photovoltaic power generation system, outlier detection, GMM algorithm, decision tree, IF.

1. INTRODUCTION


In recent years, environmental pollution is serious and energy crisis has arrived. The development and use of new energy have been highly concerned [1], [2]. The solar energy has the characteristics of large reserves, wide distribution and high efficiency. So it is widely used in the new energy field [3]. According to the International Agency (IEA) energy report, the global PV total has reached 760 GW by the end of 2020.

The associate editor coordinating the review of this manuscript and approving it for publication was Elizete Maria Lourenco.

It is expected to reach 1,721 GW by 2030 and to further increase to 4,670 GW by 2050 [4]. With the development of the PV industry and the increase of the total installed capacity of PV globally, it is particularly important to ensure the normal operation and maintenance of PV systems.

Due to the complex external situation of the PV array operation, the output power is susceptible to the influence of the environment such as temperature and irradiance, coupled with the abnormal operation of the PV equipment, which will lead to a large number of outliers in the output power. A large number of outliers will affect the realization of system

Hình 3: Trang 1 bản toàn văn của Li và cộng sự [4], *IEEE Access* tập 13, trang 108823–108837. Khung đỏ đánh dấu đúng hai ý mà dự án lấy làm ngữ cảnh: dùng *chiến lược phân đoạn bằng cây quyết định* để tạo các vùng gần Gauss, và *tích hợp Isolation Forest làm cơ chế quyết định* ở bước chi tiết. Hai con số 3,8% và 9,1% dẫn ở đoạn trên nằm ở cuối phần tóm tắt, do **trên dữ liệu của bài báo** — nơi nhóm tác giả có nhãn đối chiếu.



Hình 4: (Trích xuất từ Notebook 05d_thuc_nghiem_rao_chan_vat_ly.ipynb) Hai nguyên lý chạy trên dữ liệu thật của dự án: trạm 27, dải bức xạ 201–350 W/m², 8.176 quan sát. **Trái:** GMM hai thành phần, điểm đỏ là các quan sát có mật độ tương đối $P_{\text{GMM}} < 0,02$. **Phải:** phân bố điểm cô lập của Isolation Forest (100 cây), phần cam là vùng bị cắt theo contamination = 0,03.

đo mức các phân đoạn do cây tạo ra giữ được cấu trúc hình dạng phát điện của từng trạm, tức mức phân đoạn đủ đồng nhất để chạy GMM bên trong. Hệ số R^2 tính trên phần dư thấp hơn nhiều (0,118–0,346, trung bình 0,187), đúng như kỳ vọng, vì phần dư là phần biến động còn lại sau khi đã trừ ảnh hưởng của bức xạ nên chứa nhiều nhiễu thời tiết và sai số cảm biến.

Hai — mức giám cảnh báo khi bắt hai cơ chế cùng đồng ý. Phép giao giữa GMM và Isolation Forest lọc bỏ phần lớn ứng viên của cả hai phía, xem Bảng 1.

Bản kiểm toán gốc của tầng ETL nằm trong thư mục kết quả cục bộ, không được theo dõi bằng git, nên người đọc báo cáo không dựng lại được. Để bảng dưới đây kiểm chứng được, nhóm viết script 07_local_gmm_if_audit.py trong srcs/02_transform/02_generate_outliers/. Script đọc bản kết xuất ML Mart có sẵn trên máy, tách lại ba tệp đệm mà thuật toán cần, rồi gọi chính 02_gmm_if.py nguyên bản — không viết lại thuật toán, và không mở kết nối tới cơ sở dữ liệu hay kho lưu trữ đám mây nào.

Bảng 1: Số ứng viên của từng cơ chế và phần còn lại sau khi bắt cả hai cùng đồng ý. Ngưỡng dùng cho GMM là $P_{\text{GMM}} < 0,02$; Isolation Forest chạy với contamination = 0,03. Dựng lại trên máy bằng 07_local_gmm_if_audit.py; số liệu ghi ở 07_local_gmm_if_summary.json.

Cơ chế	Số ứng viên	Qua được phép giao	Tỷ lệ sống sót
GMM	28.664	5.650	19,71%
Isolation Forest	36.295	5.650	15,57%

Hai tỷ lệ sống sót trong bảng là thương của cột thứ ba trên cột thứ hai:

$$\text{GMM: } \frac{5.650}{28.664} = 0,1971 \quad \text{và} \quad \text{Isolation Forest: } \frac{5.650}{36.295} = 0,1557 \quad (2)$$

Lớp đồng thuận vì vậy loại đi hơn bốn phần năm số cảnh báo của GMM và gần năm phần sáu số cảnh báo của Isolation Forest. Tỷ lệ này đo **mức giảm cảnh báo đơn lẻ**; nó không tương đương precision, vì phần bị loại chưa có nhãn xác nhận đúng hay sai.

Bản dựng lại cho ra cùng một kết quả. Chạy lại thuật toán trên máy, không kết nối cơ sở dữ liệu, cho 32.616 dòng bị gắn cờ so với 33.280 dòng của lần chạy ETL — chênh 664 dòng trên tổng 2.731.946. Hai lần chạy ra cùng một quyết định trên **99,75%** số dòng:

$$\frac{2.725.126}{2.731.946} = 0,99750 \rightarrow \mathbf{99,75\%} \quad (3)$$

Riêng trong nhóm dòng mà tầng ETL đã gắn cờ, bản dựng lại bắt lại được $29.536/33.280 = 88,75\%$. Hai tỷ lệ này khác nhau vì hai mẫu số khác nhau, không phải hai kết quả khác nhau.

Phần chênh nằm ở đầu vào chứ không ở thuật toán: tầng ETL chạy trên bảng đệm trước khi ghép ML Mart, còn bản dựng lại chạy trên bản kết xuất ML Mart, nên tập dòng hai bên không trùng khít tuyệt đối. Vì vậy các con số trong mục này ghi theo bản dựng lại — đó là bản mà người đọc chạy lại được bằng một lệnh.

Ba — khả năng tách hạng của điểm cô lập. Điểm cô lập trung bình của các dòng bị gắn cờ cuối cùng là **0,5086**, so với **0,2119** ở các dòng bình thường. Khoảng cách giữa hai nhóm là $0,5086 - 0,2119 = \mathbf{0,2967}$, tức nhóm bị gắn cờ có điểm cao gấp $0,5086/0,2119 = 2,40$ lần. Chênh lệch dương và ổn định cho thấy điểm số có xếp hạng được hai nhóm, nhưng đây là bằng chứng về khả năng phân tách chứ không phải chứng nhận độ chính xác.

Bốn — độ tái lập của năm luật rào chắn vật lý. Một quy tắc lọc dữ liệu chỉ đáng tin nếu người khác dựng lại được đúng kết quả của nó. Nhóm viết lại toàn bộ năm luật trong notebook 05d_thuc_nghiem_rao_chan_vat_ly, đọc đúng ba tệp đệm mà tầng ETL đọc — bảng đệm sản lượng, bảng đệm thời tiết và bảng chiều trạm — rồi đối chiếu từng dòng với cờ mà tầng ETL đã ghi. Kết quả ở Bảng 2.

Ba trên năm luật dựng lại bắt trọn 100% số cờ tầng ETL đã ghi; hai luật còn lại đạt 98,6% và 99,7%. Phần dựng lại nhiều hơn vài dòng là do ML Mart mất một ít dòng khi ghép khoá, không phải do khác công thức.

Cách dựng cận trên. Cận trên có dạng $Q_3 + m \cdot \text{safe_IQR}$, trong đó *IQR* được tính riêng cho từng ô (**trạm** × **mùa** × **dải bức xạ**) chứ không tính trên toàn chuỗi, để

Bảng 2: Đối chiếu số cờ do notebook dựng lại với số cờ tầng ETL đã ghi. Đọc từ ô kết quả của notebook 05d_thuc_nghiem_rao_chan_vat_ly.ipynb.

Luật	Tầng ETL ghi	Dựng lại	Trùng	Độ khớp
PHYSICAL_OVER_CAPACITY	26.501	26.819	26.501	100,0%
PHYSICAL_HIGH_ENERGY_NO_SUN	36	37	36	100,0%
PHYSICAL_HIGH_ENERGY_LOW_RAD	140	144	138	98,6%
PHYSICAL_LOW_ENERGY_STRONG_SUN	57	57	57	100,0%
PHYSICAL_DISTRIBUTION_JUMP	1.202	1.317	1.198	99,7%

sản lượng của một điểm được so với đúng những điểm cùng hoàn cảnh nắng.

Chuỗi sản lượng ban đầu có nhiều khoảng trống thời gian, nên sau khi chia theo ba chiều đó, một số ô còn rất ít quan sát. Ô mỏng cho IQR co gần về 0; khi ấy cận $Q_3 + 1,5 \cdot IQR$ nằm sát ngay Q_3 và sẽ gấn cờ hàng loạt điểm hoàn toàn bình thường. Pipeline vì vậy đặt hai lớp bảo vệ:

- **Nhánh dự phòng theo cỡ mẫu.** Ô nào có dưới 50 quan sát thì bỏ chiều mùa, lấy thống kê của ô thô hơn (**trạm $\times$ dải bức xạ**) thay thế.
- **Sàn cho khoảng tứ phân vị.** Thay IQR bằng $\text{safe_IQR} = \max(IQR, 0,03 \cdot p_{95}, 0,1)$, nên dù IQR của ô có về 0 thì cận vẫn còn một biên tối thiểu suy từ quy mô của chính trạm đó.

Hệ số nhân cũng nâng từ 1,5 lên 4 để cận nghiêm hơn, tránh gấn cờ những dao động do mây che vốn hợp lệ.


Độ nhảy của ngưỡng. Cận $Q_3 + m \cdot \text{safe_IQR}$ quyết định bao nhiêu dòng bị loại khỏi tập huấn luyện, nên hệ số m được quét qua sáu mức trên cùng dữ liệu, từ mức Tukey chuẩn 1,5 tới 6. Kết quả ở Bảng 3 và Hình 5.

Nhìn Hình 5 thấy hai điều. Số dòng bị gấn cờ giảm đều khi m tăng, đường giảm liên tục và **không có bậc nhảy nào** cho thấy một mức m đặc biệt tự tách ra khỏi phần còn lại. Phần sản lượng bị ảnh hưởng nằm gọn dưới mốc 0,05% trên toàn dải, cao nhất 0,0344% tại $m = 1,5$ và thấp nhất 0,0040% tại $m = 6$ — chênh nhau vốn vẹn 0,03 điểm phần trăm.

Hai quan sát trên dẫn tới một kết luận: dù chọn hệ số nào trong khoảng 1,5–6, lượng dữ liệu bị loại đều không vượt quá một phần nghìn của bộ dữ liệu, nên **lựa chọn hệ số không đủ sức làm thay đổi kết quả mô hình**. Mức 4 đang dùng là một quyết định nằm trong vùng an toàn, **không phải một mức tối ưu đã được chứng minh**.

Bảng 3: Số dòng và sản lượng bị loại khi đổi hệ số nhân của `safe_IQR`. Tỷ lệ tính trên tổng 9,31 triệu kWh. Đọc từ tệp kết quả `05d_rao_chan_vat_ly/quet_he_so_safe_iqr.csv`.

Hệ số m	Số dòng bị loại	Sản lượng bị loại (kWh)	Tỷ lệ trên tổng
1,5	693	3.202	0,0344%
2	523	2.610	0,0280%
3	245	1.380	0,0148%
4 (đang dùng)	144	873	0,0094%
5	115	649	0,0070%
6	69	373	0,0040%



Hình 5: (Trích xuất từ Notebook `05d_thuc_nghiem_rao_chan_vat_ly.ipynb`) Quét hệ số nhân m của `safe_IQR` qua sáu mức. **Trái:** số dòng bị gán cờ. **Phải:** phần sản lượng bị ảnh hưởng, trực tung dừng ở 0,05%.


1.4 Sơ đồ toàn cảnh

Hình 6 mô tả chín bước của quy trình. Bốn bước đầu lấy, làm sạch, chia và khảo sát dữ liệu; bước 5 sinh rồi chọn đặc trưng; bốn bước cuối huấn luyện, đánh giá, đưa mô hình vào sử dụng và quản lý phiên bản dữ liệu cùng mô hình.

Mỗi bước tương ứng với một notebook trong thư mục `notebooks/forecasting_v4_energy/`. Toàn bộ số liệu và hình ảnh trong các phần sau đều trích từ những tệp kết quả liệt kê ở Bảng 4.

1.5 Năm rào chắn chống rò rỉ dữ liệu

Rò rỉ dữ liệu là rủi ro lớn nhất của một bài toán dự báo chuỗi thời gian: chỉ cần một đặc trưng vô tình mang thông tin của tương lai, mọi chỉ số đánh giá đều trở nên vô nghĩa. Quy trình đặt năm rào chắn, mỗi rào chắn gắn với một bước cụ thể:



Hình 6: Chín bước của quy trình học máy. Đọc theo mũi tên: bước 1 ở ô trên cùng bên trái, sang phải là bước 2, xuống hàng dưới là bước 3 rồi 4, tiếp tục tới bước 9. Dòng cuối mỗi ô ghi tập kết quả mà bước đó sinh ra.

Bảng 4: Ánh xạ giữa bước trong quy trình và notebook thực hiện.

Bước	Notebook	Kết quả ghi ra
Chuẩn bị lưới thời gian	01_reindex_mask_outlier	lưới 15 phút liên tục
Chia dữ liệu	02_split_time_series	3 fold và tập test niêm phong
Khám phá dữ liệu	02_EDA	thống kê mô tả, ACF/PACF, tương quan
Đặc trưng thời gian	03_1_features_time	lag, rolling, chu kỳ lịch
Đặc trưng không gian	03_2_features_spatial	hình học Mặt Trời, site_scale
Đặc trưng tương tác	03_3_features_aggregate	tương tác, mã hoá phân loại
Chẩn đoán đa cộng tuyến	04_vif_diagnostics	bảng hệ số VIF
Chọn đặc trưng	05_select_features	selected_features.json
Huấn luyện	06_1, 06_2, 06_3	model.pkl, model_config.json
Chọn hàm mất mát	06_4_validate_model	bảng đối chiếu ba hàm
Đánh giá cuối	07_final_test	metrics_overall.json
Giải thích mô hình	08_explainable_ai	biểu đồ SHAP
Mô hình đối chứng	06_0b_baseline_prophet	prophet_test_summary.json

1. **Nhân quả trong ghép thời tiết** (bước 2). Mỗi bản ghi tại thời điểm T chỉ được ghép với khối khí tượng của giờ đã kết thúc trước T . Điều kiện này được kiểm tra trên toàn bộ 2,73 triệu bản ghi.
2. **Không chồng lấn khi chia dữ liệu** (bước 3). Dữ liệu được cắt theo trục thời gian, không xáo trộn ngẫu nhiên. Tập test được tách ra trước mọi bước khác và chỉ được mở đúng một lần ở bước 7.
3. **Thống kê tính riêng theo từng fold** (bước 5). Các đại lượng tổng hợp như `site_scale` hay `cs_factor` được ước lượng riêng trong phần huấn luyện của từng fold, không nhìn sang phần kiểm định.
4. **Ngưỡng suy từ dữ liệu huấn luyện** (bước 6). Cận cắt của mục tiêu chuẩn hoá được tính từ phân vị của dữ liệu huấn luyện, rồi ghi vào tệp cấu hình để các bước sau đọc lại đúng giá trị đó thay vì tính lại trên tập khác.
5. **Tái lập được** (bước 6). LightGBM chạy ở chế độ tắt định trên CPU; chạy lại với cùng hạt giống ngẫu nhiên cho ra mô hình trùng khớp.

Bốn rào chắn đầu được kiểm chứng bằng số liệu ở các phần tương ứng phía sau. Rào chắn thứ năm được kiểm chứng bằng hai phép chạy lại độc lập, trình bày ở Mục 4.5.

2 Chuẩn bị dữ liệu và chia tập

2.1 Dựng lại lưới thời gian liên tục

Dữ liệu sản lượng thu từ công tơ không phải lúc nào cũng đủ mốc: mất điện, mất kết nối hoặc lỗi ghi đều để lại lỗ hổng trên trục thời gian. Nếu đưa thẳng dữ liệu khuyết mốc vào bước sinh đặc trưng, các biến trễ và biến cửa sổ trượt sẽ tính sai — `lag_4` lẽ ra phải lùi đúng 60 phút thì lại lùi 75 hay 90 phút, tùy vào chỗ bị khuyết.

Notebook `01_reindex_mask_outlier` dựng lại lưới 15 phút liên tục cho từng trạm bằng `pd.date_range`, rồi đánh dấu những dòng vừa được chèn thêm. Thứ tự hai việc này là điều kiện bắt buộc: **dựng lưới trước, lọc sau**. Nếu lọc bỏ dòng ban đêm hay dòng ngoại lai trước khi dựng lưới, khoảng cách thời gian giữa các dòng còn lại sẽ không đều, và mọi đặc trưng trễ sau đó đều lệch.

Các dòng bị gấn cờ ngoại lai ở tầng ETL không bị xoá khỏi lưới. Chúng được giữ nguyên vị trí để lịch sử không bị đứt quãng, nhưng mang nhãn loại trừ nên không đóng góp vào hàm mất mát khi huấn luyện, cũng không tham gia vào các chỉ số được báo cáo.

Ba ràng buộc thiết kế. Bước dựng lưới tuân thủ ba ràng buộc, cùng hướng tới một mục tiêu: không để thông tin của tương lai, hoặc thông tin không có thật, lọt vào lưới dữ liệu.

1. **Thời tiết chỉ được lấp theo chiều tiến.** Chỉ dùng `ffill()` theo từng trạm, tức kéo giá trị đã quan sát trong quá khứ sang hiện tại. Tuyệt đối không dùng `bfill()`, vì kéo ngược là lấy giá trị của mốc sau đắp cho mốc trước — đúng định nghĩa của rò rỉ dữ liệu.
2. **Siêu dữ liệu tĩnh thiếu thì giữ nguyên khuyết.** Các cột như `capacity_kw`, `number_of_panels`, vĩ độ và kinh độ nếu thiếu thì để nguyên khuyết, không lấp và không bịa giá trị.
3. **Điền mục tiêu theo bậc thang nhân quả.** Slot mới chèn được điền theo đúng thứ tự: `night_zero` → `causal_day_persistence` (cùng giờ hôm qua) → `causal_week_persistence` (cùng giờ tuần trước) → `causal_profile_median` → `fallback_zero`. Mọi bậc đều chỉ nhìn về quá khứ. Riêng khoảng trống từ 24 giờ trở lên được xếp vào `machine_failure_zero` và đánh dấu loại khỏi huấn luyện.

Kết quả thực thi. Khối dưới đây trích nguyên văn kết quả kết xuất của notebook

`01_reindex_mask_outlier:`

Đã reindex lưới 15 phút cho 42 site.

Tổng số dòng sau reindex: 2784438

- Dòng gốc: 2731946

- Dòng inserted: 52492

Forward-fill thời tiết (causal only, per-site):

- Số cột thời tiết: 15

- NaN trước: 812250

- NaN sau: 1890

- Đã lấp: 810360 giá trị

Đã điền target cho 52492 slot inserted.

--- PHÂN BỐ ENERGY_SOURCE SAU CASCADE ---

<code>energy_source</code>	
<code>etl_imputed</code>	1536301
<code>measured</code>	1195645
<code>machine_failure_zero</code>	42055
<code>night_zero</code>	6287
<code>causal_day_persistence</code>	2668
<code>fallback_zero</code>	984
<code>causal_profile_median</code>	283
<code>causal_week_persistence</code>	215

--- GATE CHECK ---

- Target null: 0

- Energy_source rỗng: 0

PASS - Không còn target null hoặc energy_source rỗng.

Phân tích kết quả. Sáu nhãn thuộc bậc thang điền — machine_failure_zero, night_zero, causal_day_persistence, fallback_zero, causal_profile_median và causal_week_persistence — cộng lại bằng đúng 52.492, tức đúng số dòng đã chèn. Không dòng nào rơi ra ngoài bậc thang, cũng không dòng nào bị đếm hai lần. Cổng kiểm ở cuối xác nhận không còn mục tiêu khuyết và không còn energy_source rỗng.

Hạn chế của bước dựng lưới. Trong 52.492 dòng được chèn thì 42.055 dòng rơi vào nhãn machine_failure_zero, tức các khoảng trống từ 24 giờ trở lên, được gán 0 và loại khỏi huấn luyện:

$$\frac{42.055}{52.492} = 0,8012 \rightarrow \mathbf{80,1\%} \quad (4)$$

Bốn phần năm phần chèn thêm vì vậy **không mang thông tin mới**; chúng chỉ giữ chỗ để lưới thời gian không bị đứt. Phần còn lại được điền bằng các bậc suy từ lịch sử thật, gồm $6.287 + 2.668 + 984 + 283 + 215 = 10.437$ dòng, trong đó 6.287 dòng là night_zero — các mốc ban đêm vốn phải bằng 0. Số dòng thực sự được suy từ lịch sử phát điện là $10.437 - 6.287 = \mathbf{4.150}$ dòng.

Một hạn chế nữa: sau khi lấp theo chiều tiến vẫn còn 1.890 ô thời tiết khuyết. Đó là các mốc nằm ở đầu chuỗi của từng trạm, nơi chưa có quan sát quá khứ nào để kéo sang. Chỉ có thể lấp những ô này bằng `bfill()`, tức lấy giá trị của mốc sau đắp cho mốc trước, mà phép đó đưa thông tin tương lai vào dữ liệu huấn luyện. Quy trình vì vậy giữ nguyên trạng thái khuyết ở các mốc đó, đổi lấy việc bảo toàn ràng buộc nhân quả. Theo khối kết xuất ở trên, phép lấp theo chiều tiến xử lý được 810.360 trên 812.250 ô khuyết ban đầu, tức $810.360/812.250 = 99,77\%$; phần còn lại là 1.890 ô. LightGBM nhận trực tiếp giá trị khuyết nên phần này không cần điền.

Cách xử lý này phù hợp với kết quả của Kim, Ko và Kim [3]. Nhóm tác giả đánh giá tác động của dữ liệu khuyết tới bài toán dự báo sản lượng quang điện và chỉ ra rằng cách xử lý phần khuyết ảnh hưởng trực tiếp tới sai số của mô hình dự báo, chứ không phải là một bước tiền xử lý trung tính, xem Hình 7.

Từ đó, dự án tách bạch hai việc: **dựng lại mốc thời gian** để cấu trúc chuỗi không bị đứt, và **đánh dấu nguồn gốc từng dòng** để phần dữ liệu không đáng tin không lọt vào chỉ số báo cáo. Phạm vi của bài báo và của dự án khác nhau ở một điểm: bài báo khảo sát bốn phương pháp điền khuyết cho **dữ liệu khí tượng** và kết luận phương

However, PV power generation widely varies due to environmental factors; thus, the accurate forecasting of PV generation becomes essential. Meanwhile, weather data for environmental factors include many missing values; for example, when we estimated the missing values in the precipitation data of the Korea Meteorological Agency, they amounted to ~16% from 2015–2016, and further, 19% of the weather data were missing for 2017. Such missing values deteriorate the PV power generation prediction performance, and they need to be eliminated by filling in other values. Here, we explore the impact of missing data imputation methods that can be used to replace these missing values. We apply four missing data imputation methods to the training data and test data of the prediction

Hình 7: Trích đoạn abstract của Kim, Ko và Kim [3]. Khung đỏ đánh dấu câu khẳng định dữ liệu khuyết làm suy giảm hiệu năng dự báo sản lượng quang điện và cần được xử lý bằng cách điền giá trị thay thế. Đây là cơ sở để dự án tách bạch hai việc ở bước chuẩn bị dữ liệu.

pháp k láng giềng gần nhất cho kết quả tốt nhất, trong khi dự án chỉ mượn kết luận tổng quát rằng phần khuyết phải được xử lý có chủ đích.

2.2 Phân tích khám phá dữ liệu và các quyết định sinh đặc trưng

Trước khi sinh đặc trưng, dữ liệu được khảo sát ở notebook 02_EDA. Phạm vi khảo sát là **chỉ tập huấn luyện**, sau khi loại hai trạm 19 và 24: còn 1.480.000 dòng của 40 trạm. Đây là điều kiện bắt buộc — các quyết định sinh đặc trưng ở Phần 3 đều rút ra từ bước này, nên nếu khảo sát cả tập test thì tập test đã tham gia vào thiết kế mô hình, trái với nguyên tắc niêm phong nêu ở Mục 1.5.

Ba phạm vi con được tách riêng để mọi con số phía sau đều nói rõ nó thuộc phạm vi nào:

Doc vao : 1,550,856 dong x 12 cot | 42 tram
Sau khi bo tram [19, 24]: 1,480,000 dong | 40 tram

toan bo	1,480,000 dong	(100.00%)
ban ngay	742,116 dong	(50.14%)
do that ban ngay	606,112 dong	(40.95%)

2.2.1 Phân bố đơn biến của sản lượng


Phân bố lệch phải rất mạnh và nhọn: trên toàn bộ tập huấn luyện, độ lệch đạt 6,06 và độ nhọn đạt 47,37, trong khi phân phối chuẩn có cả hai bằng 0. Nguyên nhân trực tiếp là **52,30%** số quan sát bằng 0 — ban đêm và các khung giờ rìa ngày. Trung vị của toàn bộ tập cũng bằng 0, tức quá nửa dữ liệu không mang thông tin phát điện.

Hình 8 trình bày ba cách nhìn cùng một phân bố. Lọc về ban ngày kéo độ lệch xuống 4,51 và tỷ lệ giá trị 0 xuống 6,66%; lọc thêm điều kiện đo thật thì không còn giá trị 0 nào. Ba dòng của Bảng 5 vì vậy là căn cứ trực tiếp cho hai quyết định: **chỉ tính chỉ**

Bảng 5: Thống kê mô tả sản lượng theo ba phạm vi. Đọc từ ô kết quả của notebook 02_EDA.ipynb.

Phạm vi	Số dòng	Trung vị	Độ lệch	Độ nhọn	% bằng 0
Toàn bộ	1.480.000	0,0000	6,0612	47,3723	52,30
Ban ngày	742.116	2,7325	4,5148	25,3908	6,66
Đo thật ban ngày	606.112	3,2188	4,4313	24,5310	0,00

số báo cáo trên phạm vi đo thật ban ngày, và chuẩn hoá mục tiêu để kéo phân bố về dạng đều hơn.



Hình 8: (Trích xuất từ Notebook 02_EDA.ipynb) **Trái:** histogram toàn bộ tập huấn luyện, trục tung thang loga. **Giữa:** chỉ ban ngày. **Phải:** boxplot đối chiếu hai phạm vi.

2.2.2 Mẫu hình phát điện và tác động của mây

Hai dạng ngày cho hai dạng chuỗi khác hẳn nhau. Ngày trời quang cho đường cong trơn dạng parabol; ngày nhiều mây cho chuỗi gãy khúc liên tục. Notebook chọn hai ngày tương phản trên trạm phát mạnh nhất, và chỉ xét những ngày có ít nhất 40 mốc đo thật ban ngày cùng đủ 96 mốc trong ngày, để hình không rơi vào ngày do tầng ETL điền khuyết:


Trạm 27 | 283 ngày đạt điều kiện | 71 ngày nhiều nắng
Ngày trời quang: 2020-10-02 | đo gap 0.0031
Ngày nhiều mây : 2020-12-23 | đo gap 0.0926

Hai ngày này không được chọn bằng mắt mà bằng một đại lượng đo trực tiếp trên chuỗi sản lượng, gọi là **độ gấp**: trung bình trị tuyệt đối của sai phân bậc hai trong ngày, chia cho đỉnh của chính ngày đó. Sai phân bậc hai đo mức đổi hướng giữa ba mốc liên tiếp, nên đường càng trơn thì độ gấp càng nhỏ; phép chia cho đỉnh khiến chỉ số không phụ thuộc quy mô trạm. Phép chọn chỉ xét trong nhóm 71 **ngày nhiều nắng** —

nhóm có tổng sản lượng thuộc phần tư trên — rồi lấy ngày độ gấp nhỏ nhất làm ngày trời quang và ngày độ gấp lớn nhất làm ngày nhiều mây. Ràng buộc nhóm là cần thiết: một ngày âm u kéo dài cũng cho đường phẳng lì và độ gấp rất nhỏ, nếu không lọc trước thì nó sẽ bị chọn nhầm thành ngày trời quang.

Hình 9 đặt hai ngày cạnh nhau trên cùng thang trục tung. Ngày 02/10/2020 cho một đường cong trơn, lên đều rồi hạ gần đối xứng. Ngày 23/12/2020 đạt đỉnh tương đương nhưng chỉ giữ được trong ít bước, phần còn lại là chuỗi răng cưa. Độ gấp của hai ngày chênh nhau gần 30 lần: $0,0926/0,0031 = 29,9$.

Cả hai đều thuộc nhóm ngày nhiều nắng, tức lượng bức xạ khả dụng trong ngày tương đương, nhưng cho hai chuỗi khác hẳn. Phần chênh lệch đó là do mây, và mô hình không thể suy ra nó từ lịch hay từ vị trí Mặt Trời. Đây là căn cứ sinh hai đặc trưng `chi_so_troi_quang` và `rad_x_sinelev`: chúng cấp cho mô hình tín hiệu về mức che phủ **ngay tại bước hiện tại**, thay vì bắt mô hình suy ra gián tiếp từ các mốc trễ.



Hình 9: (Trích xuất từ Notebook 02_EDA.ipynb) Sản lượng theo bước 15 phút tại trạm 27, hai ngày dùng chung thang trục tung. **Trái:** ngày trời quang 02/10/2020, độ gấp 0,0031. **Phải:** ngày nhiều mây 23/12/2020, độ gấp 0,0926. Trục hoành là giờ trong ngày, cắt trong khoảng 5–21 giờ vì ngoài khoảng đó sản lượng bằng 0. Số đo của hai ngày kiểm chứng được bằng `srcs/05_machine_learning/kiem_chung_bao_cao_v4.py`, mục 11.


2.2.3 Tự tương quan

Bảng 6 ghi tự tương quan của chuỗi sản lượng tại các mốc trễ đáng chú ý.

Con số +0,9680 tại mốc 15 phút là điểm cần đọc kỹ. Ở mức tự tương quan đó, giá trị tại t gần như là bản sao của giá trị tại $t + 1$, nên một mô hình được cấp `lag_1` sẽ có lỗi tất hiển nhiên: lặp lại giá trị vừa đo. Mốc 1 giờ vẫn giữ tương quan cao +0,8942 nhưng đã đủ xa để không còn là bản sao, còn mốc 24 giờ ở +0,7923 mang thông tin chu kỳ ngày. Hình 10 là biểu đồ đầy đủ. Ba con số này là căn cứ định lượng cho lựa chọn trình bày ở Mục 3.1.

Bảng 6: Tự tương quan của chuỗi sản lượng tại các mốc trễ đáng chú ý, trạm 27, 51.652 bước liên tục. Đọc từ ô kết quả của notebook 02_EDA.ipynb.

Mốc trễ	Khoảng cách	ACF
lag_1	15 phút	+0,9680
lag_4	1 giờ	+0,8942
lag_96	24 giờ	+0,7923
—	48 giờ	+0,7632
—	72 giờ	+0,7490



Hình 10: (Trích xuất từ Notebook 02_EDA.ipynb) **Trái:** ACF quét 288 bước = 72 giờ. **Phải:** PACF quét 96 bước = 24 giờ. Vạch đỏ chấm là mốc 96 bước.

2.2.4 Tương quan giữa các biến

Tương quan tính trên 606.112 dòng đo thật ban ngày, xem Bảng 7.


Bảng 7: Tương quan với sản lượng, tính trên phạm vi đo thật ban ngày, kèm cột đối chiếu khi gộp cả ban đêm. Đọc từ ô kết quả của notebook 02_EDA.ipynb.

Biến	Spearman ban ngày	Gộp cả đêm	Chênh
shortwave_radiation	+0,6043	+0,9024	+0,2981
direct_normal_irradiance	+0,5513	+0,8755	+0,3243
diffuse_solar_radiation	+0,3808	+0,8750	+0,4942
temperature_c	+0,2628	+0,4349	+0,1721
cloud_cover_total	-0,1591	+0,0330	+0,1921

Cột chênh lệch là kết quả đáng chú ý nhất của cả bước khảo sát. Nếu gộp cả ban đêm, tương quan của shortwave_radiation với sản lượng vọt từ +0,60 lên +0,90, và diffuse_solar_radiation vọt từ +0,38 lên +0,88. Mức tăng đó **không phản ánh quan hệ vật lý**: ban đêm mọi biến bức xạ và sản lượng đều bằng 0 cùng lúc, nên hơn một

nửa số điểm nằm chồng tại gốc toạ độ và tự động đẩy hệ số tương quan lên. Ma trận đầy đủ ở Hình 11.

Cột `cloud_cover_total` cho thấy rõ nhất: ban ngày nó mang dấu **âm** $-0,1591$ — đúng ý nghĩa vật lý là mây che thì sản lượng giảm — nhưng gộp cả đêm thì đổi thành dấu dương $+0,0330$, tức đảo ngược hoàn toàn ý nghĩa. Vì vậy mọi tương quan trong tài liệu này đều tính trên phạm vi đo thật ban ngày.



Hình 11: (Trích xuất từ Notebook 02_EDA.ipynb) Ma trận tương quan Spearman trên 606.112 dòng đo thật ban ngày.

Chẩn đoán đa cộng tuyến không nằm ở bước này. Hệ số phóng đại phương sai cần toàn bộ đặc trưng đã sinh xong, nên nó được tính ở notebook 04_vif_diagnostics và trình bày ở Mục 3.7.

2.3 Chia dữ liệu theo trục thời gian

Với bài toán dự báo, phép chia ngẫu nhiên thông thường là sai về nguyên tắc, vì cách chia đó cho phép mô hình học từ dữ liệu của tháng sau rồi đi dự báo tháng trước. Notebook 02_split_time_series vì vậy cắt dữ liệu **theo thứ tự thời gian**, không xáo trộn.


Trước hết, 15% số mốc thời gian cuối cùng được tách ra làm **tập test niêm phong** và cất đi. Phần còn lại, gọi là tập Phát triển, mới được dùng để sinh đặc trưng, chọn đặc trưng, tinh chỉnh siêu tham số và chọn hàm mất mát. Tập test chỉ được mở đúng một lần ở bước đánh giá cuối, sau khi mọi quyết định đã khoá.

Phép cắt thực hiện trên **trục mốc thời gian**, không phải trên số dòng. Toàn bộ dữ liệu có 81.023 mốc thời gian phân biệt; cắt 15% cuối cho 12.154 mốc thuộc tập test và 68.869 mốc thuộc tập Phát triển. Ranh giới rơi vào 18/12/2021 lúc 09:30:

- **Tập Phát triển** — từ 01/01/2020 00:15 đến 18/12/2021 09:15.
- **Tập test niêm phong** — từ 18/12/2021 09:30 đến 23/04/2022 23:45.

Tỷ lệ 15% tính trên mốc thời gian tương ứng 510.468 dòng trên tổng 2.784.438, tức 18,33% khối lượng dữ liệu. Hai tỷ lệ lệch nhau do **số trạm hoạt động tăng dần theo thời gian**: đầu năm 2020 có 30 trạm phát sinh dữ liệu, tới cuối năm 2021 đủ 42 trạm, nên mỗi mốc thời gian ở giai đoạn sau mang nhiều dòng hơn giai đoạn trước. Hình 12 mô tả cách chia.

Phép cắt theo mốc được chọn thay vì cắt theo số dòng vì nó cho một ranh giới thời gian duy nhất áp dụng chung cho cả 42 trạm. Cắt theo số dòng sẽ khiến mỗi trạm có một mốc cắt riêng và tập test không còn là một giai đoạn liền mạch.



Hình 12: (Trích xuất từ Notebook 02_split_time_series.ipynb) Cách chia dữ liệu theo trục thời gian: tập test niêm phong tách ra từ phần cuối, phần Phát triển còn lại chia thành ba fold theo cửa sổ mở rộng.

2.4 Ba fold theo cửa sổ mở rộng

Tập Phát triển được chia thành ba fold theo kiểu **cửa sổ mở rộng** (*expanding window*): phần huấn luyện của fold sau chứa trọn phần huấn luyện lẫn phần kiểm định của fold trước. Cách này mô phỏng đúng tình huống vận hành thật — càng về sau càng có nhiều lịch sử để học — và bảo đảm phần kiểm định luôn nằm ở tương lai so với phần huấn luyện.

Phép chia fold cũng thực hiện trên trục mốc thời gian, mỗi fold nhận đúng 17.217 mốc cho phần kiểm định, còn phần huấn luyện nở rộng dần qua 17.218, 34.435 rồi 51.652 mốc.

Bảng 8: Ranh giới thời gian, kích thước và số trạm của ba fold, đọc từ các tệp `fold*_train_selected.parquet` và `fold*_val_selected.parquet`.

Fold	Phần huấn luyện			Phần kiểm định		
	đến	số dòng	trạm	đến	số dòng	trạm
1	28/06/2020 08:30	233.244	30	24/12/2020 16:45	606.105	39
2	24/12/2020 16:45	839.349	39	22/06/2021 01:00	711.507	42
3	22/06/2021 01:00	1.550.856	42	18/12/2021 09:15	723.114	42

Nhìn Bảng 8 thấy rõ tính chất mở rộng: mốc kết thúc huấn luyện của fold 2 trùng đúng mốc kết thúc kiểm định của fold 1, và tương tự giữa fold 3 với fold 2. Kích thước tập huấn luyện tăng dần từ 233 nghìn lên 1,55 triệu dòng, trong khi tập kiểm định giữ quy mô tương đương nhau, khoảng 600–720 nghìn dòng.

Hạn chế: fold sớm có trạm chưa từng xuất hiện khi huấn luyện. Cột số trạm trong Bảng 8 cho thấy một hệ quả trực tiếp của việc các trạm lần lượt đi vào vận hành theo thời gian. Ở fold 1, mô hình học trên 30 trạm nhưng bị chấm điểm trên 39 trạm; ở fold 2 là 39 trạm so với 42. Chênh lệch đó nghĩa là một phần dữ liệu kiểm định thuộc về những trạm mà mô hình **chưa từng nhìn thấy một dòng nào** lúc huấn luyện. Tới fold 3 thì cả 42 trạm đều đã có mặt ở phần huấn luyện nên tình huống này không còn.

Ảnh hưởng của nó làm sai số đo trên fold 1 và fold 2 **bi quan hơn thực tế vận hành**, vì trong vận hành thật mô hình luôn đã có lịch sử của trạm mà nó dự báo. Chiều ảnh hưởng là an toàn — sai số bị đánh giá nặng hơn chứ không nhẹ đi — nhưng khi so sánh các cấu hình bằng WAPE gộp ba fold thì phần đóng góp của fold 1 vẫn mang theo thành phần sai lệch này.

2.5 Thực nghiệm: đo phần chồng lấn nhãn ở ranh giới fold

Ba fold được cắt liên tục, không chèn khoảng đệm giữa phần huấn luyện và phần kiểm định. Hai quy tắc chống rò rỉ nêu ở Mục 1.4 chỉ ràng buộc **đặc trưng đầu vào**; riêng **nhãn** cần một phép kiểm riêng. Nhãn của một dòng huấn luyện là sản lượng tại $T + h$, nên với những dòng nằm sát mốc cắt, thời điểm $T + h$ có thể đã rơi sang vùng kiểm định. Nhóm đo trực tiếp phần chồng lấn này.

Cách tiến hành. Với mỗi fold, đọc trực tiếp tệp `fold_i_train_selected.parquet`, lấy mốc thời gian lớn nhất $T_{\max}$ của phần huấn luyện. Một dòng có nhãn rơi sang vùng kiểm định khi và chỉ khi mốc thời gian của dòng đó lớn hơn $T_{\max} - 15h$ phút, với h là số bước của tầm dự báo. Đếm số dòng thoả điều kiện đó cho cả hai tầm H1 và H4. Phép đo chạy trên chính các tệp fold mà bước huấn luyện đọc vào, không dùng dữ liệu trung gian nào khác.

Bảng 9: Số dòng huấn luyện có nhãn rơi sang vùng kiểm định, tính trên từng fold và từng tầm dự báo. Đọc từ ô kết quả của notebook `05b_thuc_nghiem_tham_so_hardcode.ipynb`, Thí nghiệm 9.

Fold	Cỡ tập huấn luyện	Chồng lấn H1	Chồng lấn H4	Tỷ lệ H4
1	233.244	30	120	0,0514%
2	839.349	39	156	0,0186%
3	1.550.856	42	168	0,0108%

Trường hợp xấu nhất là fold 1 ở tầm H4: 120 dòng trên 233.244, tức **0,0514%**. Tỷ lệ nhỏ như vậy là hệ quả cấu trúc của phép cắt — chỉ những dòng nằm trong h bước cuối cùng của tập huấn luyện mới có nhãn vượt sang vùng kiểm định, mà h nhiều nhất là bốn bước.

Bảng 9 tự kiểm chứng được. Ở tầm H1 chỉ **một** bước cuối bị chồng lấn, nên số dòng phải bằng số trạm còn hoạt động tại bước đó: cột chồng lấn H1 cho 30, 39 và 42, trùng khít cột số trạm ở Bảng 8. Cột H4 gấp đúng bốn lần các giá trị đó.

Với mức chồng lấn dưới một phần nghìn ở cả ba fold, phép cắt liên tục được giữ nguyên, không chèn khoảng đệm.

3 Sinh đặc trưng

Ba notebook liên tiếp bổ sung đặc trưng vào cùng một khung dữ liệu, mỗi notebook phụ trách một họ: `03_1_features_time` sinh đặc trưng suy từ trục thời gian và từ lịch sử sản lượng, `03_2_features_spatial` sinh đặc trưng hình học Mặt Trời cùng các đại lượng chuẩn hoá theo trạm, `03_3_features_aggregate` sinh đặc trưng tương tác khí tượng và mã hoá biến phân loại. Hai notebook sau đó thu hẹp lại: `04_vif_diagnostics` chẩn đoán đa cộng tuyến, `05_select_features` chốt danh sách chính thức.

3.1 Đặc trưng thời gian, trễ và cửa sổ trượt

Notebook 03_1_features_time sinh ba nhóm đặc trưng, tóm tắt ở Bảng 10.

Bảng 10: Ba nhóm đặc trưng sinh tại notebook 03_1_features_time.ipynb. Cột cuối ghi tham số thực tế khai báo trong notebook.

Nhóm	Cột sinh ra	Tham số
Lịch và chu kỳ	minute_of_day, month, day_of_week, is_weekend, season, season_code, hour_sin, hour_cos, doy_sin, doy_cos	chu kỳ ngày 1440 phút; chu kỳ năm 365,25 ngày
Trễ	lag_4, lag_96	LAGS = (4, 96), tức $T - 60$ phút và $T - 24$ giờ
Cửa sổ trượt	rolling_mean, rolling_std, rolling_min, rolling_max cho mỗi cửa sổ	ROLLING_WINDOWS = (4, 96), bốn thống kê mỗi cửa sổ

Hai nhóm sau tạo ra 2 cột trễ cộng 8 cột cửa sổ trượt, bằng 10 cột suy từ chuỗi mục tiêu — đúng con số notebook in ra khi khai báo hàm sinh đặc trưng.

Mã hoá lịch bằng sin và cos. Nếu để giờ trong ngày ở dạng số nguyên, mốc 23:45 và mốc 00:00 cách nhau đúng một bước 15 phút trên thực tế nhưng cách nhau 23 đơn vị trên thang số. Cây quyết định chia theo ngưỡng sẽ coi hai mốc liền kề đó là hai vùng xa nhau. Cặp (sin, cos) đưa trục thời gian về một vòng tròn khép kín, nên khoảng cách giữa hai mốc kề nhau qua nửa đêm trở lại đúng bằng khoảng cách thật. Cùng lý do, ngày trong năm được mã hoá bằng doy_sin và doy_cos theo chu kỳ 365,25 ngày.

3.1.1 Thực nghiệm: chọn mốc trễ

Khái niệm nền. *Persistence* là mô hình dự báo cơ sở: lấy giá trị quan sát tại t làm dự báo cho $t + h$. Dev và cộng sự [8] định nghĩa nó là phương pháp *giả định điều kiện tại thời điểm dự báo không thay đổi so với thời điểm quan sát*, và ghi nhận rằng cách này *chạy tốt* ở các tầm dự báo ngắn, khi điều kiện thời tiết biến thiên chậm — xem Hình 13.

Từ định nghĩa trên suy ra một hệ quả đại số mà bài báo không nêu: nếu $\hat{y}(t+h) = y(t)$ thì đường dự báo **chính là đường đo thật dịch phải h bước**, tức lệch pha đúng bằng tầm dự báo. Mặt khác, vì chuỗi biến thiên chậm ở tầm ngắn — đúng điều kiện mà bài báo nói *persistence* chạy tốt — nên hiệu giữa $y(t)$ và $y(t+h)$ nhỏ, và một chỉ số sai số tính theo từng điểm vẫn cho con số đẹp.

using TES with other two common forecasting approaches, viz. persistence forecasting and average forecasting. The persistence forecasting method assumes that the conditions for the forecast do not change (especially for shorter lead times). This method works well in conditions when weather maps change very slowly with time. We also compare our approach

Hình 13: Trích mục *Benchmarking* của Dev và cộng sự [8]. Khung đỏ đánh dấu hai mệnh đề: *persistence* giả định điều kiện không đổi — đặc biệt ở các tầm dự báo ngắn — và phương pháp này chạy tốt khi điều kiện thời tiết biến thiên chậm.

Tầm H1 của dự án đúng bằng 15 phút, nằm trọn trong vùng đó. Một mô hình lặp lại giá trị vừa đo sẽ cho **chỉ số sai số tốt** nhưng **đường dự báo trễ một nhịp** — con số đẹp ở đây không chứng minh năng lực dự báo.

Giả thuyết. Mốc trễ càng gần thời điểm dự báo thì tín hiệu càng mạnh, nhưng cũng càng dễ kéo mô hình về đúng dạng vừa nêu. Thực nghiệm này xác định mốc trễ nào được đưa vào.

Cách tiến hành. Ba cấu hình được đối chiếu trên cùng dữ liệu và cùng quy trình tinh chỉnh: cấu hình nền chỉ có lag_{96} ($T - 24$ giờ), cấu hình thêm lag_1 ($T - 15$ phút), và cấu hình thêm lag_4 ($T - 60$ phút). Mỗi cấu hình được chấm bằng WAPE và một phép đo lệch pha riêng: độ trễ trung bình giữa đường dự báo và đường đo thật trên từng trạm, kèm số trạm vượt ngưỡng cho phép. Ba mốc đã thử ghi ở Bảng 11.

Bảng 11: Ba mốc trễ đã được thử và quyết định tương ứng, ghi tại ô khai báo LAGS của notebook 03_1_features_time.ipynb.

Mốc trễ	Quyết định	Căn cứ ghi trong notebook
lag_{96} ($T - 24$ giờ)	giữ	Chu kỳ ngày; xa thời điểm dự báo nên không tạo lệch pha
lag_1 ($T - 15$ phút)	loại	Gây lệch pha trên gần như toàn bộ đội hình; sai số theo từng điểm giảm nhưng là hệ quả của việc lặp lại giá trị vừa đo
lag_4 ($T - 60$ phút)	giữ	Đủ xa để không lặp lại được giá trị vừa đo, vẫn đủ gần để mang thông tin quán tính; qua được cổng lệch pha ở Mục 3.1.2

Độc kết quả. Quyết định phân biệt lag_1 với lag_4 không dựa vào sai số mà dựa vào **lệch pha**. Nếu chỉ nhìn WAPE thì lag_1 sẽ được chọn, vì nó cho con số thấp nhất

— đúng như hệ quả đại số nêu ở đầu mục. Dự án chốt $\text{LAGS} = (4, 96)$ và loại `lag_1`.

Cần nêu rõ giới hạn của bằng chứng này: notebook ghi lại **quyết định** và **căn cứ định tính**, không lưu một phép đối chứng có kiểm soát giữa ba cấu hình trên cùng một lần chạy. Bằng chứng định lượng cho cấu hình được chọn nằm ở cổng lệch pha trình bày ngay sau đây.

3.1.2 Cổng lệch pha đặt trước bước tinh chỉnh

Phép đo lệch pha không chạy song song với WAPE mà được đặt thành một **cổng chặn** ở đầu notebook huấn luyện: chỉ khi cổng đạt thì quy trình mới được phép chạy Optuna và huấn luyện thật.

Cách đo. Độ trễ suy từ quan hệ giữa sai số và độ dốc của đường đo thật. Nếu đường dự báo bị dịch c bước thì sai số xấp xỉ $-c$ nhân với độ dốc, nên hệ số hồi quy của sai số theo độ dốc chính là c :

$$\text{độ trễ (phút)} = -\frac{\sum_t d_t e_t}{\sum_t d_t^2} \times 15, \quad d_t = \frac{y_{t+1} - y_{t-1}}{2}, \quad e_t = \hat{y}_t - y_t. \quad (5)$$

Cách này **tách sai số biên độ khỏi sai số thời điểm**: dự báo cao hơn hay thấp hơn thực tế đều không làm đổi con số, chỉ việc đến sớm hay đến muộn mới làm đổi.

Ngưỡng và kết quả. Cổng yêu cầu độ trễ nằm trong ± 5 phút và không trạm nào vượt ngưỡng. Kết quả in ra ở notebook `06_1_train_mae`:

```
TRAIN THU NHANH DE DO TRE (truoc khi tune)
Train thu 300,000 dong x 54 dac trung trong 9.3 giay

TREN 288,735 diem ban ngay cua tap test:
Do tre          : +2.46 phut   (duong = du bao di SAU thuc te)
Nguong cho phep: +/- 5.0 phut
WAPE tham khao : 22.47% (model nho, chua tune - chi de doi chieu)

Site vuot nguong: 0/40
Tre theo site: trung vi +2.79 phut | nho nhat +1.64 | lon nhat +3.71

CONG DO TRE: DAT - tre +2.46 phut, khong site nao vuot nguong.
Cho phep chay Optuna va train that.
```

Mô hình dùng ở cổng. Cổng chạy trên một mô hình nháp, cùng thuật toán và cùng hàm mất mát với mô hình cuối nhưng nhỏ hơn nhiều, xem Bảng 12.

Vì thuật toán, hàm mất mát và danh sách đặc trưng giống hệt mô hình cuối, cổng kiểm được đúng thứ nó cần kiểm: **bộ đặc trưng có đẩy mô hình vào hành vi bám**

Bảng 12: Mô hình nháp dùng ở cổng lệch pha so với mô hình cuối. Đọc từ ô cấu hình cổng lệch pha trong notebook 06_1_train_mae.ipynb.

	Mô hình nháp (cổng)	Mô hình cuối
Thuật toán	LightGBM	LightGBM
Hàm mất mát	ℓ_1 (MAE)	ℓ_1 (MAE)
Số đặc trưng	54	54
Trọng số mẫu	có	có
Quy mô tập đầu vào	300.000 lấy ngẫu nhiên	1.550.856
Số cây	200, đặt cố định	Optuna chọn
Tốc độ học	0,08, đặt cố định	Optuna chọn
num_leaves	63, đặt cố định	Optuna chọn
Thời gian huấn luyện	9,3 giây	hàng chục phút

trụ hay không. Nếu lag_1 có mặt thì mô hình nháp cũng sao chép giá trị gần nhất y như mô hình cuối.

Cổng này đặt trước bước tinh chỉnh nên chỉ kiểm bộ đặc trưng. Sau khi Optuna chọn xong siêu tham số và huấn luyện mô hình cuối, notebook chạy tiếp một phép quét độ trễ thứ hai trên toàn bộ tập kiểm định — trình bày ở phần đánh giá.

3.1.3 Rào chắn chống rò rỉ và ngữ cảnh lùi

Bước sinh đặc trưng đặt hai rào chắn. Thứ nhất, mọi đặc trưng suy từ mục tiêu đều được dịch: các cột cửa sổ trượt tính trên chuỗi mục tiêu **đã dịch một bước**, nên giá trị tại T không bao giờ chứa sản lượng đo tại chính T .

Thứ hai, một **mặt nạ lịch sử liên tục** kiểm tra rằng toàn bộ số bước của cửa sổ liền trước đều cách nhau đúng 15 phút; nếu cửa sổ vắt qua một chỗ đứt gãy, giá trị bị gán khuyết thay vì được tính bừa trên hai đoạn không liền nhau.

Ngữ cảnh lùi. Mỗi tập được nối thêm lịch sử của tập liền trước trước khi tính đặc trưng, rồi chỉ xuất phần dòng thuộc chính tập đó. Tập test dùng toàn bộ tập Phát triển làm ngữ cảnh, tập kiểm định dùng tập huấn luyện, và phần kiểm định của mỗi fold dùng phần huấn luyện của chính fold đó. Nhờ vậy dòng đầu tiên của mỗi tập vẫn có đủ lịch sử, mà mỗi fold vẫn là một thí nghiệm khép kín.

Kết quả thực thi. Khối dưới đây trích nguyên văn kết quả kết xuất của notebook 03_1_features_time:

```
So đặc trưng target sẽ tạo: 2 lag + 8 rolling = 10 cột
```

Đã sinh đặc trưng thời gian cho development và test (đã ghi file và giải phóng RAM).

- development: 2273970 dòng x 74 cột
- test : 510468 dòng x 75 cột

Đã sinh đặc trưng thời gian cho train/val (đã ghi file và giải phóng RAM).

- train_alias: 1550856 dòng x 75 cột
- val_alias : 723114 dòng x 75 cột

fold_1: train 233244 dòng | val 606105 dòng | 76 cột

fold_2: train 839349 dòng | val 711507 dòng | 76 cột

fold_3: train 1550856 dòng | val 723114 dòng | 76 cột

Số lượng NaN trong các tập:

- Train: 21000 (Đã dropna ở bước 7)
- Val: 0
- Test: 0

0 điểm đứt gãy - lưới thời gian liên tục 100% nhờ Reindex Notebook 01.
(Tổng số dòng: 1550856)

Ô khuyết chỉ xuất hiện ở tập huấn luyện, tại các dòng đầu chuỗi chưa đủ 96 bước lịch sử để tính cửa sổ dài. Tập kiểm định và tập test không còn ô khuyết nào nhờ ngữ cảnh lùi.

3.2 Hình học Mặt Trời, bức xạ trời quang và chuẩn hoá theo trạm


Notebook 03_2_features_spatial sinh nhóm đặc trưng suy từ vị trí Mặt Trời, còn 03_3_features_aggregate sinh nhóm tương tác khí tượng và mã hoá biến phân loại. Cả hai nhóm đều là **hàm xác định của thời gian và vị trí** hoặc là tổ hợp của các biến đã có, nên không mang rủi ro rò rỉ.

3.2.1 Vị trí Mặt Trời theo thuật toán NOAA

Góc cao h và góc phương vị được tính theo thuật toán vị trí Mặt Trời chuẩn của NOAA — chuỗi Fourier cho độ xích vĩ, phương trình thời gian và góc giờ. Đây là công cụ tham chiếu chính thức, xem Hình 14.

Ba chi tiết cài đặt đáng nêu, tóm tắt ở Bảng 13.

Cách cắt mùa theo **nguyên tháng** là một xấp xỉ: giờ mùa hè ở Úc bắt đầu Chủ nhật đầu tiên của tháng 10 và kết thúc Chủ nhật đầu tiên của tháng 4, nên vài ngày đầu hai tháng đó nhận độ lệch chênh một giờ — khoảng 12 ngày mỗi năm.



Hình 14: NOAA Solar Calculator của Global Monitoring Laboratory — công cụ chính thức tính vị trí Mặt Trời mà hàm `tin_goc_mat_troi` của dự án dựa theo.

Bảng 13: Ba chi tiết cài đặt của bước hình học Mặt Trời.

Chi tiết	Trong mã nguồn	Lý do
Quy đổi về giờ UTC	$utc = ts - tz_gio$, với tz_gio bằng 11 cho tháng 10–3 và 10 cho tháng 4–9	Mốc trong dữ liệu là giờ địa phương của Úc , còn công thức thiên văn cần giờ UTC. Úc áp dụng giờ mùa hè nên độ lệch đổi theo mùa
Góc phương vị	<code>np.arctan2(...)</code> thay cho <code>arccos</code>	<code>arccos</code> chỉ trả về miền $[0^\circ; 180^\circ]$ nên không phân biệt được buổi sáng với buổi chiều; <code>atan2</code> liên tục trên trọn vòng 360°
Dạng vòng của góc	<code>azimuth_sin</code> , <code>azimuth_cos</code>	Góc đo bằng độ gián đoạn ở mốc 0° và 360° : 359° và 1° kề nhau thực tế nhưng cách xa trên thang số

3.2.2 Bức xạ trời quang theo mô hình Haurwitz

GHI (*Global Horizontal Irradiance*) là **tổng bức xạ Mặt Trời chiếu xuống một mặt phẳng nằm ngang**, đơn vị W/m^2 . Nó gồm hai thành phần cộng lại: phần trực xạ đi thẳng từ đĩa Mặt Trời và phần khuếch tán do bầu khí quyển và mây tán xạ. Trong dữ liệu của dự án, hai đại lượng này nằm ở **hai cột khác nhau** và không được lẫn:

- `shortwave_radiation` — **GHI đo được thực tế**, do Open-Meteo cung cấp.

- ghi_cs — GHI_{cs} , giá trị lý thuyết khi trời hoàn toàn quang, do nhóm **tự tính** bằng mô hình Haurwitz từ góc cao Mặt Trời.

Vì GHI_{cs} ứng với điều kiện không mây, nó là mức trần mà bức xạ đo được chỉ có thể tiệm cận chứ không nên vượt qua.

Từ góc cao suy ra bức xạ ngang trời quang:

$$GHI_{cs} = 1098 \times \sin(h) \times \exp\left(-\frac{0,059}{\sin(h)}\right) \quad (\text{W/m}^2) \quad (6)$$

Cặp hằng số 1098 và 0,059 lấy đúng bản cài đặt Haurwitz của thư viện pvlib, vốn dẫn về hai bài gốc của Haurwitz [5]. Hình 15 là đoạn tóm tắt của bài báo nguồn.

ABSTRACT

From records of insolation and from observations of cloudiness and cloud density obtained at Blue Hill Observatory relations have been derived which give the amount of insolation, T , to be expected on the average with a given cloudiness, cloud density and solar air mass. These relations are of the form $T = (a/m)e^{-bm}$ where m = air mass (i.e. secant of zenith distance of the sun), e = base of natural logarithms, a and b are constants which depend on the cloudiness and cloud density. The effect of the cloud density on the insolation is of the same importance as cloudiness if the sky is largely covered.

The following table shows the insolation for different values of cloudiness and density and for air masses 1 and 3 in cal/cm²/hr. It will be seen that, especially with larger values of the cloudiness, the effect of the

Hình 15: Đoạn tóm tắt bài báo Haurwitz [5], *Journal of Meteorology* tập 2, tr. 154–166. Khung đỏ đánh dấu dạng công thức $T = (a/m)e^{-bm}$ với m là khối không khí — nguồn gốc của mô hình trời quang mà dự án dùng.

Mô hình trời quang thuần thiên văn ước lượng thiếu so với bức xạ đo tại các trạm, nên GHI_{cs} được nhân thêm hệ số hiệu chỉnh riêng từng trạm, đặt tên cs_factor. Hệ số này **tính riêng trên phần huấn luyện của từng fold**, xem Bảng 14.

Bảng 14: Hệ số hiệu chỉnh trời quang cs_factor theo từng fold. Đọc từ ô kết quả của notebook 03_2_features_spatial.ipynb.

Phạm vi tính	Trung vị	Nhỏ nhất	Lớn nhất
Phần huấn luyện fold 1	1,460	1,105	1,827
Phần huấn luyện fold 2	1,538	1,520	1,819
Phần huấn luyện fold 3	1,557	1,541	1,809

Giá trị đổi rõ giữa các fold — trung vị từ 1,460 lên 1,557 — nên việc dùng chung một bộ thống kê cho cả ba fold sẽ đưa thông tin của giai đoạn sau vào fold sớm. Notebook ghi thẳng nguyên tắc này ở ô kết quả: *mỗi fold dùng thống kê quy mô tính riêng từ tập train của chính fold đó*.

3.2.3 Thực nghiệm: hạ độ phân giải bức xạ từ một giờ về mười lăm phút

Vấn đề. Dữ liệu khí tượng có tần suất một giờ, còn lưới sản lượng có tần suất 15 phút, nên mỗi giá trị bức xạ lặp lại bốn lần liên tiếp: trong một giờ, đặc trưng bức xạ không phân biệt được mốc 12:00 với mốc 12:15.

Nguyên lý. Bailey và cộng sự [6] mô tả thuật toán của Graham và Hollands (1990): tách chỉ số trời quang theo giờ k_t thành mô hình cộng $k_t = k_{tm} + \alpha$ gồm thành phần xu thế và thành phần nhiễu. Điểm cốt lõi là hạ độ phân giải **chỉ số trời quang** chứ không phải bức xạ — vì bức xạ mang cả biến thiên nhật triều, còn chỉ số trời quang thì không. Đoạn nguồn ở Hình 16.

Dự án giữ đúng thành phần xu thế k_{tm} — giữ chỉ số trời quang không đổi trong mỗi khối giờ rồi nhân lại với GHI_{cs} tính ở từng mốc 15 phút — và bỏ thành phần nhiễu α , vì α dùng để sinh chuỗi tổng hợp, còn ở đây bức xạ là đặc trưng đầu vào cho mô hình dự báo.

Kết quả đo. Thước đo là tỷ lệ bước có giá trị bức xạ thay đổi so với bước liền trước, tính riêng trên các dòng ban ngày. Khối kết quả của notebook:

```
--- TY LE BUOC CO GIA TRI BUC XA THAY DOI, TOAN TAP TRAIN (CHI BAN NGAY) ---
So dong ban ngay: 751,408 / 1,550,856 (48.5%)
Truoc downscale : 26.7%
Sau downscale : 76.7%
Muc tieu la tren 90 phan tram.
[CANH BAO] Chua dat 90 phan tram,kiem lai buoc downscale.
```

Tỷ lệ tăng gần ba lần, từ 26,7% lên 76,7%. Hình 17 cho thấy hiệu quả trên một cửa sổ sáu giờ.

3.2.4 Chuẩn hoá quy mô theo trạm

Bốn mươi hai dàn quang điện có quy mô rất khác nhau, nên quy mô được ước lượng từ chính dữ liệu và **chỉ từ phần huấn luyện**: `site_scale` là phân vị 99 của sản lượng ban ngày, `tran_cong_suat` là phân vị 99,9. Bảng 15 trích tám trạm đầu trong bảng notebook in ra.

Một mô hình học thẳng trên sản lượng thô sẽ dành phần lớn sức mô tả để phân biệt trạm lớn với trạm nhỏ, thay vì học quan hệ giữa thời tiết và sản lượng — đó là lý do mục tiêu được chuẩn hoá trước khi huấn luyện.


3.2.5 Tương tác khí tượng và mã hoá biến phân loại

Notebook `03_3_features_aggregate` sinh năm đặc trưng tương tác, xem Bảng 16.

surements of solar radiation to time series at a minute scale by matching the closest day between the hourly input of observed data and a generated hourly time series. There are many other studies that temporally downscale according to this first definition (Buster et al. (2021), Frimane et al. (2019), Zhang et al. (2018), Grantham et al. (2017), Skartveit & Olseth (1992)).

The second approach is less widely studied but important for future projections. Graham & Hollands (1990) developed a simple algorithm that disaggregates the hourly clear sky index, k_t , into an additive model: $k_t = k_{tm} + \alpha$. Here, the clear sky index is a measure of atmospheric transparency for incoming solar radiation. They identified sets $\{k_{tm}\}$, a trend component, and $\{\alpha\}$, a noise component, for all values of k_t , the daily average clear sky index, and assessed the variability observed in α by conditioning according to k_t . In this way, the method is similar to an analog method, which uses observed data at the desired spatial or time scale as the downscaled data (Zorita & Von Storch (1999)), but only for the errors, α . Aguiar & Collares-Pereira (1992) developed the Time-Dependent, Autoregressive, Gaussian (TAG) Model for hourly time series generation based on the daily clearness index as input. The TAG algorithm claims better consistency compared to Graham & Hollands (1990), which may be due to more locations that were used in its development. Grantham et al. (2016) proposes an additive model to generate hourly synthetic times series of GHI data. The model includes a Fourier series component, autoregressive component, and a stochastic component. The stochastic component bins errors according to solar elevation and zenith angle. Then, synthetic series are created by drawing from these bins to add stochastic error for the given solar angle and elevation at the hour being modeled. This method is similar to an analog method which essentially uses observed data as the final simulation. Finally, the distribution of the synthetic solar radiation is adjusted to match

Hình 16: Trích trang 5 bài tổng quan Bailey và cộng sự [6]. Khung đồ mô tả thuật toán Graham và Hollands (1990): tách chỉ số trời quang theo giờ k_t thành mô hình cộng $k_t = k_{tm} + \alpha$.



Hình 17: (Trích xuất từ Notebook 03_2_features_spatial.ipynb) Bức xạ tại trạm 1, ngày 19/12/2020, từ 11 giờ đến 17 giờ. **Trên:** dữ liệu gốc theo giờ, mỗi giá trị lặp bốn lần nên đường đi thành bậc thang. **Dưới:** sau khi hạ độ phân giải, đường biến thiên theo từng bước 15 phút.

Bảng 15: Quy mô trạm tính trên tập huấn luyện, tám trạm lớn nhất. Đọc từ ô kết quả của notebook 03_2_features_spatial.ipynb.

Trạm	site_scale	tran_cong_suot	cs_factor
27	97,19	99,00	1,55
11	92,05	92,72	1,74
25	79,73	82,42	1,55
19	41,73	42,80	1,55
18	35,04	36,21	1,55
6	27,53	28,51	1,74
8	26,50	26,89	1,74
1	21,50	22,73	1,70

Tỷ lệ khuyết 47,43% (735.612 dòng) của hai đặc trưng dạng thương đến từ mẫu số: ban đêm bức xạ ngang bằng 0 nên phép chia không xác định. Giá trị khuyết được giữ nguyên thay vì điền 0, để mô hình cây học nhánh riêng cho dữ liệu khuyết. Số giá trị vô cực trên cả năm cột bằng 0.

Mã hoá biến phân loại. Bảng mã được khớp **chỉ trên phía huấn luyện** rồi áp cho phía kiểm định; notebook khớp được 8 bảng mã, và số ô gặp hạng mục lạ trên tập kiểm định bằng 0.

Bảng 16: Năm đặc trưng tương tác, tỷ lệ khuyết trên tập huấn luyện và tương quan Pearson với mục tiêu tính trên 763.740 dòng ban ngày. Đọc từ ô kết quả của notebook 03_3_features_aggregate.ipynb.

Đặc trưng	Định nghĩa	Khuyết	Pearson
temp_x_shortwave	nhiệt độ $\times$ bức xạ ngang	0,01%	0,3487
diffuse_ratio	bức xạ khuếch tán / bức xạ ngang	47,43%	-0,2350
dni_ratio	bức xạ trực xạ / bức xạ ngang	47,43%	0,2350
cloud_x_shortwave	mây toàn phần $\times$ bức xạ ngang	0,01%	0,1921
cloud_low_x_shortwave	mây tầng thấp $\times$ bức xạ ngang	0,01%	0,1650

Kiểm chứng cuối bước sinh đặc trưng. Notebook in ra ba phép kiểm:

```

--- KIEM TRA 1: dac trung target deu duoc shift ---
Cot lag con lai sau khi khu tre pha: ['lag_4', 'lag_96']
lag_96(t) = target(t-96) tren mau: DAT
--- KIEM TRA 2: ty le dong co lich su day du ---
- train      : 99.74% dong co du lich su lien tục
- val        : 100.00% dong co du lich su lien tục
--- KIEM TRA 3: hang muc la (unseen category) ---
Tong so o gap hang muc la trong val: 0

```

Sau ba notebook sinh đặc trưng, tập huấn luyện đi từ 50 cột lên 114 cột, trong đó 46 cột là đặc trưng ứng viên; các fold mang 115 cột do có thêm cột đánh dấu fold.

3.3 Định nghĩa các đặc trưng dẫn xuất

Một số cột xuất hiện trong bảng chẩn đoán và bảng chấm điểm ở Mục 3.7 là đại lượng dẫn xuất, không đọc thẳng từ dữ liệu nguồn. Bảng 17 ghi công thức của chúng.

Hai cột `con_cach_tran` và `clearsky_proxy` được sinh ra ở bước đặc trưng nhưng **không lọt vào bộ được chọn**: `clearsky_proxy` tương quan 0,9973 với `sin_elevation` nên mang thông tin trùng lặp, còn `con_cach_tran` không đạt ngưỡng thông tin tương hỗ.

Một đính chính về tên gọi. Tên `chi_so_troi_quang` gợi ý rằng giá trị 1,0 tương ứng trời hoàn toàn quang. Phép kiểm chứng cho thấy điều đó không đúng với cột này: sau khi GHI_{cs} đã nhân hệ số hiệu chỉnh theo trạm, tỷ lệ đo được **không đạt tới** 1,0 **ngay cả vào lúc quang nhất giữa trưa** — giá trị lớn nhất ở nhóm góc cao 50–90° chỉ

Bảng 17: Công thức các đặc trưng dẫn xuất. Đọc từ mã nguồn notebook 03_2_features_spatial.ipynb và 03_3_features_aggregate.ipynb.

Đặc trưng	Công thức	Ý nghĩa
ky_vong	$\text{site_scale} \times \max(\sin h, 0)$	Mức sản lượng kỳ vọng của trạm tại góc cao hiện tại, nếu trời hoàn toàn quang
ty_le_bao_hoa	$\text{clip}\left(\frac{\text{ky_vong}}{\text{tran_cong_suat}}, 0, 3\right)$	Mức kỳ vọng đã tiến sát trần công suất tới đâu
con_cach_tran	$\text{tran_cong_suat} - \text{ky_vong}$	Khoảng dư còn lại tới trần, tính bằng kWh
rad_x_sinelev	$\text{shortwave_radiation} \times \sin h$	Bức xạ chiếu hiệu dụng lên mặt phẳng ngang
clearsky_proxy	$(\sin h)^{1,2}$	Dạng đường cong ngày thuần hình học, nhọn hơn $\sin h$ một chút
chi_so_troi_quang	$\text{clip}\left(\frac{\text{shortwave_radiation}}{\text{ghi_cs}}, 0, 1,5\right)$	Tỷ lệ bức xạ đo được trên bức xạ trời quang đã hiệu chỉnh theo trạm
temp_x_shortwave	$\text{temperature_c} \times \text{shortwave_radiation}$	Tương tác nhiệt độ và bức xạ
diffuse_ratio	$\text{clip}\left(\frac{\text{diffuse_solar_rad.}}{\text{shortwave_rad.}}, 0, 10\right)$	Phần khuếch tán chiếm bao nhiêu trong tổng bức xạ
cloud_x_shortwave	$\text{cloud_cover_total} \times \text{shortwave_radiation}$	Tương tác mây toàn phần và bức xạ

đạt 0,760. Vì vậy tài liệu này không mô tả nó như một chỉ số trời quang có ý nghĩa vật lý trực tiếp, mà gọi đúng bản chất là **biến tỷ lệ bức xạ đã hiệu chỉnh theo từng trạm**. Nó vẫn hữu ích làm đặc trưng đầu vào vì thứ tự giữa các quan sát trong cùng một trạm được bảo toàn, mà cây quyết định chỉ dùng thứ tự để tách nhánh.

Về cột pv_clr_lonij. Dự án có cài đặt chỉ số K của Lonij đúng nguyên bản — phân vị 80, cửa sổ trượt 15 ngày theo từng khung giờ, có `shift(1)` nên chỉ nhìn quá khứ

— thành cột `pv_clr_lonij`. Cột này đạt điểm quan trọng biến 1,959, đứng hạng 6 trong bảng chẩn đoán ở Mục 3.7, nhưng không lọt Top 35 theo thông tin tương hỗ và không nằm trong danh sách bảo vệ, nên bị loại ở bước chọn theo đúng quy tắc đã đặt trước.

Cột này nối trực tiếp với lập luận về mức phân vị ở Mục 3.5: dự án cài cả phương án phân vị 80 của Lonij lẫn phương án phân vị 99 của mình, rồi để bước chấm điểm quyết định bằng số liệu thay vì chọn trước bằng lập luận.

3.4 Thực nghiệm: khử độ trễ cài sẵn bằng đặc trưng tại thời điểm mục tiêu

Vấn đề. Nhãn cần dự báo nằm ở thời điểm $T+h$, nhưng các đặc trưng hình học Mặt Trời và nhãn lịch — `sin_elevation`, `ghi_cs`, `hour` — vẫn là giá trị tại T . Mô hình do đó dùng vị trí Mặt Trời lúc T để dựng lại sản lượng lúc $T+h$, và đường dự báo sinh ra chính là đường Mặt Trời bị trễ đúng h bước. Đây là hệ quả cấu trúc của bài toán, và tác động của nó lan rộng vì cùng đại lượng đó cũng là mẫu số chuẩn hoá ở Mục 3.5.

Cách xử lý. Quy trình khai báo một danh sách 22 cột **tất định** — hình học Mặt Trời cùng các đại lượng suy ra từ nó, và toàn bộ nhãn thời gian theo lịch — rồi sinh thêm bản của chúng tại $T+h$ với hậu tố `_mt`, đồng thời **giữ nguyên** bản tại T . Ở tầm H1 sinh được 14 cột, nâng tổng số đặc trưng vào mô hình từ 40 lên 54.

Ranh giới hợp lệ của phép dịch. Vị trí Mặt Trời và nhãn lịch tại $T+h$ là kết quả tính toán thiên văn và lịch thuần tuý; đứng ở thời điểm T đã biết chính xác chúng bằng bao nhiêu, không cần chờ tới $T+h$ mới đo. Điều này khác hẳn biến khí tượng: bức xạ và mây tại $T+h$ chỉ biết được sau khi đo, nên `shortwave_radiation`, `lag_96` và toàn bộ nhóm `rolling_*` bắt buộc giữ nguyên ở T . Ranh giới đó chính là điều kiện để phép dịch này hợp lệ.

Thêm chữ không thay thế. Phương án thay thế hẳn bản tại T bằng bản tại $T+h$ đã được thử và bị bác bỏ bằng số liệu. Phép đo lấy sai số MAE của đường bao $\hat{y} = \text{site_scale} \times \sin h$ so với sản lượng thật trên tập Phát triển, tính riêng theo khung giờ, cho kết quả ở Bảng 18.

Hai khung giờ cho hai kết luận ngược nhau, nên không phương án nào thắng tuyệt đối. Trên toàn bộ ban ngày hai bản chênh nhau 0,4%, tức gần như tương đương; chênh lệch chỉ lộ ra khi tách theo khung giờ. Buổi sáng sản lượng thật **đi sau** Mặt Trời, vì tấm pin còn lạnh và ẩm sương, inverter đang trong giai đoạn khởi động — nên giá trị tại T khớp hơn 26,3%; buổi chiều thì ngược lại, giá trị tại $T+h$ khớp hơn 18,6%. Quy trình vì vậy giữ cả hai bản và để mô hình tự chọn theo khung giờ, thay vì áp một phương án cho cả ngày.

Bảng 18: So sánh dùng đặc trưng tất định tại T với tại $T+h$, đo bằng MAE của đường bao $\text{site_scale} \times \max(\sin h, \varepsilon)$ so với sản lượng thật tại $T+15$ phút, trên 999.010 dòng ban ngày của tập Phát triển. Kiểm chứng bằng `srcs/05_machine_learning/kiem_chung_bao_cao_v4.py`, mục 10.

Khung giờ	Số dòng	Dùng tại T	Dùng tại $T+h$	Chênh
Toàn bộ ban ngày	999.010	3,1425	3,1296	−0,4%
Sáng 06–09h	246.305	2,1580	2,7258	+26,3%
Chiều 16–18h	189.966	2,9646	2,4136	−18,6%

Bảng này được tính lại từ dữ liệu chứ không chép từ khối ghi chú trong mã nguồn. Khối ghi chú đó ghi ba cặp số khác (3,1873 với 3,1884; 1,5934 với 2,1833; 3,4002 với 2,8574) nhưng không kèm phạm vi dòng nên không dựng lại được. Hai lần đo cùng chiều ở cả ba khung giờ; báo cáo lấy bản dựng lại được.

3.5 Chuẩn hoá mục tiêu theo vật lý

Bốn mươi trạm có quy mô chênh nhau nhiều lần, và sản lượng trong ngày biến thiên theo góc cao Mặt Trời. Nếu huấn luyện thẳng trên sản lượng thô, mô hình phải dành phần lớn sức mô tả để phân biệt trạm lớn với trạm nhỏ và để học lại nhịp ngày đêm — hai thứ đã biết trước bằng công thức. Mục tiêu vì vậy được đổi sang một tỷ số không thứ nguyên:

$$k_{\text{target}} = \text{clip}\left(\frac{y}{\text{site_scale} \times \max(\sin h, \varepsilon)}, 0, k_{\text{max}}\right) \quad (7)$$

Mẫu số gồm hai phần: `site_scale` khử chênh lệch quy mô giữa các trạm, còn $\sin h$ khử nhịp ngày đêm. Phép `max` đặt một sàn ε cho mẫu số, vì lúc Mặt Trời sát đường chân trời thì $\sin h \rightarrow 0$ và tỷ số sẽ nổ tung.

Sau khi mô hình dự báo $\hat{k}$, giá trị được nhân ngược về kWh rồi chặn trần:

$$\hat{y} = \min\left(\hat{k} \times \text{site_scale} \times \max(\sin h, \varepsilon), \text{tran_cong_suat} \times 1,02\right) \quad (8)$$

Cả `site_scale` và `tran_cong_suot` đều là phân vị của chính chuỗi sản lượng nên mang đơn vị kWh trên mỗi bước 15 phút, cùng đơn vị với y ; phép chặn vì vậy không cần hệ số đổi đơn vị nào.

Cơ sở của cách chuẩn hoá. Việc chia sản lượng đo được cho một mức tham chiếu suy từ chính hệ thống là cách làm đã có trong tài liệu. Engerer và Mills [7] tổng

kết các phương pháp trước đó và dẫn lại chỉ số K của Lonij và cộng sự [12], vốn định nghĩa mức tham chiếu bằng một **phân vị của chính sản lượng đo được**.

Điểm cần đọc kỹ ở tài liệu nguồn là **không có một mức phân vị chuẩn**. Ngay trên cùng một trang tổng kết, hai công trình tiền lệ chọn hai mức khác hẳn nhau, xem Hình 18.

where PV_{MEAS-G} is the measured 15-minute energy value for each system, E_{gtc} is the 15-minute clear-sky plane-of-array irradiance estimated using the Bird Clear Sky Model [3], and the factor of 1000 converts the irradiance to suns. After removing days with system outages, the clear-sky BPI (CSBPI) for each system is defined as the 93rd percentile of the set of BPI values in the training set.

The clearness index of Lonij et al. [36] is defined as

where E_{gt} is the plane-of-array irradiance, E_{gtc} is the clear-sky plane-of-array irradiance, PV_{MEAS-L} is the measured power output normalized by a system's peak power, and PV_{CLR-L} is its clear-sky normalized power output. PV_{CLR-L} is defined as the 80th percentile of PV_{MEAS-L} at the specified time of day on the previous 15 days for a system Lonij et al. [36]. System-specific factors, like shading, were then removed by taking the 80th percentile of an ensemble of 80 systems spread across a 50 x 50 km² region Lonij et al. [36].

The numerators in BPI and K are equivalent to that in K_{PV} : PV_{MEAS-G}

Hình 18: Trích trang 21 của Engerer và Mills [7]. Hai đoạn được đánh dấu cho thấy hai công trình tiền lệ dùng hai mức phân vị khác nhau để dựng mẫu số: Golnas lấy phân vị 93, còn Lonij và cộng sự [12] lấy phân vị 80.

Hai mức chênh nhau 13 điểm mà cả hai đều được công bố, vì mỗi bên dựng mẫu số theo một cách. Điều đó có nghĩa mức phân vị là **tham số thiết kế đi kèm cách dựng mẫu số**, không phải hằng số vật lý mượn được từ tài liệu. Mức của dự án vì vậy phải được biện minh bằng thực nghiệm trên chính dữ liệu của dự án.

Cận cắt suy từ dữ liệu, không đặt tay. Tham số $k_{\max}$ không được gán một hằng số trong tệp cấu hình. Notebook huấn luyện đặt `CLIP_K = None` rồi gọi hàm `tinh_clip_tu_train()` để tính nó bằng phân vị 99 của k trên chính tập huấn luyện. Giá trị thu được và ghi vào `model_config.json` là **1,3764**, tính trên 681.536 giá trị k . Mức phân vị 99 được chọn bằng phép quét ở Bảng 19.

Đường cong WAPE phẳng từ mức 0,99 trở lên — ba mức cuối chỉ chênh nhau 0,0001 điểm phần trăm. Bên dưới mức đó thì sai số xấu dần, tới 22,6101% ở phân vị 0,90 vì cắt mất 10% dữ liệu. Dòng cuối cùng cho thấy phép cắt vẫn cần thiết: bỏ hẳn nó thì ngưỡng nhảy lên 13,4137, tức đuôi phân bố có những điểm gấp gần mười lần phần

Bảng 19: Quét mức phân vị dùng làm cận cắt, chạy trên **tập kiểm định**. Đọc từ tệp kết quả 05_selected/quet_muc_phan_vi_nguong_cat.csv.

Mức phân vị	Ngưỡng cắt	Tỷ lệ bị cắt (%)	WAPE kiểm định (%)
0,900	1,1525	10,00	22,6101
0,950	1,2341	5,00	22,5211
0,975	1,3090	2,50	22,4949
0,990	1,4015	1,00	22,4901
0,995	1,4832	0,50	22,4900
0,999	1,9297	0,10	22,4900
1,000	13,4137	0,00	22,4900

thân. Mức 0,99 là điểm mà đường cong bắt đầu phẳng mà vẫn chặn được đuôi đó.

Hai giá trị ngưỡng trong báo cáo. Bảng 19 ghi ngưỡng 1,4015 tại mức 0,99, còn tệp cấu hình mô hình ghi 1,3764. Hai con số này không mâu thuẫn: cùng một mức phân vị nhưng tính trên hai tập khác nhau. Phép quét chạy trên tập kiểm định để đo WAPE tương ứng với từng mức, nên ngưỡng của nó là phân vị 99 của k trên tập kiểm định (≈ 289.000 giá trị). Ngưỡng thực sự nạp vào mô hình bắt buộc phải suy từ tập huấn luyện, nên nó là phân vị 99 của k trên tập huấn luyện (681.536 giá trị), bằng 1,3764. Giá trị dùng để huấn luyện và để chấm điểm ở Phần 5 là 1,3764.

Hạn chế: ngưỡng cắt dùng chung cho hai tầm dự báo. Ngưỡng 1,3764 được tính ở tầm H1 rồi dùng lại cho tầm H4. Tính riêng cho H4 thì phân vị 99 của k là 2,0156. Nguyên nhân nằm ở cấu tạo của k : mẫu số lấy sin h tại thời điểm T , còn tử số là sản lượng tại $T + h$. Ở tầm 15 phút Mặt Trời gần như đứng yên nên hai vế khớp nhau; ở tầm 60 phút, buổi sáng Mặt Trời lên nhanh nên mẫu số nhỏ hơn hẳn tử số và k giàu lên.

Hệ quả đo được: dùng ngưỡng của H1 cho H4 thì tỷ lệ nhãn bị cắt tăng từ 1,00% lên **8,59%**, và phần bị cắt dồn vào sườn lên buổi sáng, xem Bảng 20.

Ngưỡng này chặn ở cả hai đầu: lúc huấn luyện nó cắt cụt nhãn, và lúc dự báo nó chặn luôn đầu ra vì đầu ra cũng đi qua cùng phép cắt trước khi nhân ngược. Với tầm H4 vào buổi sáng, mô hình vừa không được học giá trị thật vừa bị áp trần khi dự báo, nên phần sườn lên bị hụt biên độ. Buổi chiều không có hiện tượng này vì Mặt Trời xuống nên tử số nhỏ hơn mẫu số.

Sửa đúng cách là gọi lại `ting_clip_tu_train()` trong bước chuẩn bị ma trận của tầm H4. Việc đó kéo theo huấn luyện lại toàn bộ H4 và chạy lại cả dây chuyền đánh giá, nên nằm ngoài phạm vi đợt này và được ghi vào hướng phát triển ở Phần 8. Mọi con số H4 trong báo cáo đều là số của cấu hình đang dùng ngưỡng 1,3764.

Bảng 20: Tỷ lệ nhận bị ngưỡng 1,3764 cắt, tách theo giờ trong ngày, tính trên tập huấn luyện. Kiểm chứng bằng `srcs/05_machine_learning/kiem_chung_bao_cao_v4.py`, mục 1.

Giờ	H1 bị cắt	Tỷ lệ H1	H4 bị cắt	Tỷ lệ H4
6	4	0,05%	3.192	42,98%
7	226	0,61%	13.505	36,17%
8	454	0,75%	18.004	29,92%
9	847	1,41%	13.942	23,17%
10	1.352	2,25%	7.172	11,93%
11	1.079	1,80%	2.113	3,52%
12	822	1,37%	514	0,86%
13–19	2.032	$\approx 0,6\%$	99	$< 0,1\%$
Tổng	6.816	1,00%	58.541	8,59%

3.6 Kiểm chứng các tham số cố định

Bốn tham số được gán giá trị cố định trong tệp cấu hình. Notebook `05b_thuc_nghiem_tham_so_hardcode` quét từng tham số qua nhiều mức, giữ nguyên mọi thứ còn lại, rồi huấn luyện và chấm lại trên tập kiểm định. Kết quả ở Bảng 21.

Bảng này phải đọc trung thực, vì không phải tham số nào cũng có tác động như nhau.

Sàn mẫu số ε không quyết định độ chính xác. Toàn dải từ 0,00 tới 0,15 chỉ chênh nhau 0,0717 điểm phần trăm WAPE. Cái mà ε thực sự điều khiển là số dòng còn lại để huấn luyện: từ 604.200 xuống 557.266, mất 7,8%. Mức 0,05 ứng với góc nâng $\arcsin(0,05) = 2,87^\circ$. Tỷ lệ dòng giữ lại được so với mức không lọc là

$$\frac{599.174}{604.200} = 0,991682 \rightarrow \mathbf{99,17\%} \quad (9)$$

Con số này là tỷ lệ trên **các dòng thực sự vào hàm mục tiêu** của phép quét ở Bảng 21. Tính trên toàn bộ tập huấn luyện trước khi áp trọng số mẫu thì tỷ lệ là $681.536/709.954 = 96,00\%$. Hai con số khác nhau vì hai phạm vi khác nhau; báo cáo dùng 99,17% đúng theo phạm vi của bảng.

Phần bị loại nhỏ như vậy vì vành $0 < \sin h \leq 0,05$ rất hẹp và gần như không phát điện. Trung bình mỗi trạm mỗi ngày có 47,1 bước ban ngày, trong đó chỉ 1,89 bước rơi vào vành này. Sản lượng trung bình một bước trong vành là 0,1630 kWh, so với 6,5743 kWh ở các bước còn lại — kém 40 lần. Cộng lại, phần sản lượng nằm trong vành là

Bảng 21: Quét bốn tham số cố định, chấm trên 779.099 dòng của tập kiểm định. Đọc từ tệp kết quả 05b_thuc_nghiem_tham_so/thuc_nghiem_tham_so_hardcode.csv.

Tham số	Mức	Dòng huấn luyện	WAPE (%)	RMSE	R^2
eps_elev	0,00	604.200	20,5872	3,4733	0,8931
	0,02	602.937	20,5657	3,4895	0,8921
	0,05	599.174	20,5692	3,4799	0,8926
	0,10	582.252	20,5810	3,4832	0,8924
	0,15	557.266	20,5155	3,4630	0,8937
$k_{\max}$	1,0	599.174	24,1097	3,8230	0,8704
	1,2	599.174	21,1356	3,5535	0,8881
	1,5	599.174	20,5692	3,4799	0,8926
	2,0	599.174	20,4791	3,4638	0,8936
	3,0	599.174	20,4473	3,4502	0,8945
Hệ số nổi trần	1,00	599.174	20,5710	3,4816	0,8925
	1,02	599.174	20,5692	3,4799	0,8926
	1,05	599.174	20,5669	3,4781	0,8928
	1,10	599.174	20,5650	3,4766	0,8928
Trọng số vùng đỉnh	0,0	599.174	20,4051	3,4623	0,8937
	0,5	599.174	20,5059	3,4650	0,8936
	1,0	599.174	20,5692	3,4799	0,8926
	2,0	599.174	20,6429	3,4928	0,8919

$$\frac{4.631 \text{ kWh}}{4.485.237 \text{ kWh}} = 0,001033 \rightarrow \mathbf{0,103\%} \quad (10)$$

Đặt sàn ở 0,05 vì vậy chặn được vùng mẫu số tiến về 0 mà chỉ bỏ đi một phần nghìn sản lượng ban ngày.

Cận cắt $k_{\max}$ là tham số có tác động rõ. Hạ xuống 1,0 làm WAPE xấu đi 3,54 điểm, vì cắt mất phần thân của phân bố chứ không chỉ đuôi. Nới lên 2,0 và 3,0 cải thiện thêm 0,09 và 0,12 điểm, nhưng đổi lại thì phép cắt gần như mất tác dụng chặn các điểm đo bất thường. Giá trị dùng thật là 1,3764 suy từ phân vị 99 của tập huấn luyện, nằm giữa hai mức 1,2 và 1,5 của phép quét.

Hệ số nổi trần không phải lựa chọn về độ chính xác. Bốn mức từ 1,00 tới 1,10 chênh nhau 0,006 điểm WAPE, tức nằm trong mức nhiễu. Hệ số 1,02 được chọn theo lý do vật lý: chứa 2% dư địa quanh trần để không cắt oan các dao động ngắn do hiện

tượng tăng cường bức xạ ở mép mây, chứ không phải khẳng định công suất lắp đặt thực tế cao hơn 2%.

Trọng số vùng đỉnh làm WAPE tổng thể xấu đi. Tất hẳn cho 20,4051%, thấp hơn mức đang dùng 0,164 điểm. Đây là một đánh đổi có chủ đích chứ không phải tham số bị bỏ quên: trọng số này kéo mô hình chú ý vào khung giờ phát điện mạnh, nơi sai số có giá trị vận hành lớn nhất, và trả giá bằng một phần nhỏ sai số trung bình trên toàn tập.

Ngưỡng cắt chỉ số trời quang. Tham số CLIP_CSI chặn tỷ lệ bức xạ đo trên bức xạ trời quang. Bảng 22 cho thấy nó ảnh hưởng tới bao nhiêu điểm bị cắt.

Bảng 22: Số điểm bị ngưỡng CLIP_CSI cắt. Đọc từ tệp kết quả 05b_thuc_nghiem_tham_so/thuc_nghiem_clip_csi.csv.

Ngưỡng	Số điểm bị cắt	Tỷ lệ (%)
1,0	39.265	5,4592
1,1	33.127	4,6058
1,2	28.684	3,9880
1,3	24.393	3,3915
1,5	18.689	2,5984
2,0	11.179	1,5543

Ngưỡng 1,0 ứng với giả định bức xạ đo không bao giờ vượt bức xạ trời quang lý thuyết — giả định đó cắt 5,46% số điểm, quá nhiều để coi là hợp lý, vì hiện tượng tăng cường bức xạ ở mép mây làm bức xạ đo vượt mức trời quang trong thời gian ngắn là có thật. Ngưỡng 1,5 cắt 2,60%, giữ lại phần vượt trần do vật lý và chỉ loại phần vượt xa.

3.7 Chẩn đoán và chọn đặc trưng

Sau ba notebook sinh đặc trưng, tập huấn luyện mang 114 cột. Hai notebook tiếp theo quyết định cột nào thực sự đi vào mô hình, với vai trò tách bạch: 04_vif_diagnostics **đo** và xuất bằng chứng, 05_select_features **quyết định**. Notebook chẩn đoán không tự loại cột nào — nó ghi bảng chỉ số ra tệp để bước chọn đọc lại.

Cách phân vai này có lý do: hệ số phóng đại phương sai chỉ đo mức một đặc trưng bị các đặc trưng còn lại giải thích, không đo mức đặc trưng đó giải thích được mục tiêu. Một cột có thể vừa cộng tuyến cao vừa mang thông tin vật lý không thay thế được, nên máy không được quyền tự loại.

3.7.1 Chẩn đoán đa cộng tuyến

Trong 114 cột, 86 cột được đưa vào chẩn đoán; 28 cột còn lại nằm ngoài phạm vi vì là mục tiêu, khoá định danh, cột ghi nguồn gốc dữ liệu, cờ ngoại lai hoặc cột thời gian thô. Kết quả phân loại trình bày ở Bảng 23.

Bảng 23: Phân bố nhãn chẩn đoán trên 86 đặc trưng số. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.

Nhãn	Số cột	Nghĩa
HIGH_VIF	41	Hệ số phóng đại phương sai vượt 10
OK	27	Không vướng tiêu chí nào
CONSTANT	9	Chỉ một giá trị duy nhất, phương sai bằng 0
DUPLICATE	8	Trùng lặp gần hoàn hảo với một cột khác
HIGH_MISSING	1	Tỷ lệ khuyết quá cao
Tổng	86	

Cột duy nhất mang nhãn khuyết cao là `source_gap_id` với 97,68% ô trống — đúng bản chất của nó, vì nó chỉ nhận giá trị tại các dòng nằm trong một khoảng trống nguồn.

Cột trùng lặp. Ở ngưỡng $|r| \geq 0,95$ notebook đếm được 44 cặp, nhưng chỉ những cặp đạt $|r| \geq 0,9999$ mới bị coi là trùng lặp thực sự, vì cộng tuyến hoàn hảo khiến phép tính hệ số phóng đại phương sai không xác định. Tám cột bị loại ở bước này, xem Bảng 24.

Bảng 24: Tám cột trùng lặp gần hoàn hảo và cột đại diện được giữ lại. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.

Cột bị bỏ	Đại diện giữ lại	Số giá trị phân biệt
<code>quarter_hour</code>	<code>minute_of_day</code>	96
<code>hour_of_day</code>	<code>hour</code>	24
<code>hour_bucket_raw</code>	<code>hour</code>	24
<code>hour_bucket_model</code>	<code>hour</code>	24
<code>day_of_week_model</code>	<code>day_of_week</code>	7
<code>month_model</code>	<code>month</code>	12
<code>number_of_panels_missing_flag</code>	<code>capacity_kw_missing_flag</code>	2
<code>dni_ratio</code>	<code>diffuse_ratio</code>	37.341

Sáu nhóm đầu là các cách mã hoá khác nhau của cùng một đại lượng thời gian, sinh ra ở các bước khác nhau của quy trình rồi cùng tồn tại. Cặp `diffuse_ratio` và

`dni_ratio` có $r = -1,0000$ vì hai tỷ lệ này cộng lại bằng 1 theo định nghĩa. Sau bước loại trùng, số đặc trưng còn 78.

Hệ số phóng đại phương sai. Bảng 25 lấy tám cột cao nhất.

Bảng 25: Tám đặc trưng có hệ số phóng đại phương sai cao nhất. Giá trị 9999 là mức chặn trên mà notebook đặt cho trường hợp cộng tuyến gần hoàn hảo. Đọc từ ô kết quả của notebook `04_vif_diagnostics.ipynb`.

Đặc trưng	VIF	Nguồn cộng tuyến
<code>direct_normal_irradiance</code>	9999	Ba cột bức xạ ràng buộc nhau qua quan hệ hình học
<code>diffuse_solar_radiation</code>	9999	
<code>shortwave_radiation</code>	9999	
<code>tran_cong_suat</code>	7.567,53	Cùng suy từ phân vị sản lượng của một trạm
<code>site_scale</code>	7.516,67	Trùng thông tin với biến tháng
<code>day_of_year</code>	5.228,18	
<code>month</code>	5.186,16	
<code>sin_elevation</code>	2.846,97	Hàm xác định của cùng góc cao Mặt Trời

Ba cột bức xạ đạt mức chặn trên vì GHI bằng tổng của thành phần trực xạ chiếu xuống mặt ngang và thành phần khuếch tán, nên biết hai cột là suy ra được cột còn lại. Cặp `site_scale` và `tran_cong_suat` có $r = 0,9999$ vì cả hai là phân vị 99 và phân vị 99,9 của cùng một chuỗi sản lượng.

Không cột nào trong Bảng 25 bị loại. Cộng tuyến làm hệ số của mô hình tuyến tính mất ổn định, nhưng mô hình dùng ở đây là cây quyết định tăng cường gradient — nó chọn điểm cắt theo mức giảm hàm mất mát chứ không giải hệ phương trình chuẩn tắc, nên không chịu ảnh hưởng đó.

Đổi chiếu bằng một phương pháp độc lập. Để không quyết định chỉ dựa trên một thước đo, notebook chạy thêm hồi quy bình phương tối thiểu riêng phần và lấy điểm quan trọng biến, đo theo hiệp phương sai với mục tiêu thay vì theo cộng tuyến giữa các đặc trưng. Bảy đặc trưng đứng đầu được ghi ở Bảng 26.

Sáu trong bảy đặc trưng dẫn đầu đồng thời mang nhãn cộng tuyến cao. Đây là lý do trực tiếp để bước chọn không dùng hệ số phóng đại phương sai làm tiêu chí loại: nếu cắt theo ngưỡng 10 thì sáu đặc trưng mạnh nhất theo thước đo độc lập sẽ bị loại hết.

Bảng 26: Bảy đặc trưng dẫn đầu theo điểm quan trọng biến của hồi quy bình phương tối thiểu riêng phần, đặt cạnh hệ số phóng đại phương sai của chính chúng. Đọc từ ô kết quả của notebook 04_vif_diagnostics.ipynb.

Đặc trưng	Điểm quan trọng	VIF
rolling_mean_4	2,265	461,18
rolling_min_4	2,251	882,04
rolling_max_4	2,224	1.375,52
lag_4	2,123	27,77
ky_vong	2,039	21,18
pv_clr_lonij	1,959	10,80
lag_96	1,883	5,36

3.7.2 Danh sách cấm

Trước khi chấm điểm, notebook 05_select_features khai báo tường minh một danh sách cấm gồm 53 tên cột. Danh sách này chặn bốn loại: chính mục tiêu và các biến thể của nó, cờ ngoại lai và cột loại trừ huấn luyện, cột ghi nguồn gốc dữ liệu, và các khoá định danh cùng cột thời gian thô.

Danh sách được khai báo theo tên chứ không theo tập dữ liệu, nên nó bao cả những tên chỉ xuất hiện ở các bước khác của quy trình. Trong 114 cột của tệp đầu vào, 40 cột trùng tên với danh sách và bị loại; 74 cột còn lại đi tiếp vào bước chấm điểm. Cách khai báo dư này là có chủ đích: thêm một tên không tồn tại thì vô hại, còn sót một tên rò rỉ thì hỏng cả kết quả.

Danh sách cấm được đặt trước phép chấm điểm chứ không sau, vì một cột rò rỉ luôn đạt điểm cao: nếu để nó dự thi thì chính thước đo sẽ chọn nó. Hình 19 là đoạn khai báo.

3.7.3 Chấm điểm bằng thông tin tương hỗ

Phép chấm điểm chạy trên **thông tin tương hỗ** giữa từng đặc trưng và mục tiêu. Thước đo này bắt được cả quan hệ phi tuyến, khác hệ số tương quan Pearson vốn chỉ đo quan hệ tuyến tính — điều cần thiết ở đây vì quan hệ giữa bức xạ và sản lượng bão hoà dần khi tới gần trần công suất.

Điểm chỉ tính trên các dòng hợp lệ, tức đã bỏ dòng mang cờ loại trừ huấn luyện:

Tổng số dòng ban đầu: 1550856
Số dòng hợp lệ (exclude_from_training = False): 1514314 (97.64%)

```

"""Stage 07a: danh sách CAM (deny list) - chặn rò rỉ nhân và công tuyền cấu trúc.

Tách từ bước 4 của run_select_features() trong 03_feature_selection.py.

DAY LA HANG RAO CHONG RO RI QUAN TRONG NHAT CUA CA PIPELINE. Bo sot 1 cot o day thi
model dat R2 rat cao tren train/val nhưng HOAN TOAN THAT BAI khi du bao that.
"""
from __future__ import annotations

import pandas as pd

# — 1. Chính biến mục tiêu —
DENY_TARGET = ["energy_generated_kwh"]

# — 2. Provenance / outlier —
# BẢNG CHUNG từ dữ liệu thô:
# - Khi exclude_from_training == True thì sản lượng = 0.0 ở 100.00% trường hợp
#   (36.847 dòng trong tập train, đều là machine_failure zero do gap >= 24h).
# - Nhóm outlier_group == physical_over_capacity có sản lượng trung bình 19,43 kWh,
#   vượt xa nhóm normal (2,75 kWh).
# HAU QUA NEU DUA VAO MODEL: các cột này được tạo SAU KHI đã đo và kiểm tra target.
# Model chỉ cần trả bảng "thay có thì đoán 0" -> điểm cực cao trên train/val nhưng
# THẬT BAI khi du bao tuong lai (lúc đó chưa có dữ liệu đo để gán có).
# VAI TRÒ DUNG của chúng: (1) lọc dòng khỏi train, (2) gán trọng số mau,
# (3) khoanh vùng tính metric theo nhóm. KHÔNG được làm đặc trưng đầu vào.
DENY_PROVENANCE_OUTLIER = [
    "gmm_if_outlier_flag", "gmm_if_outlier_reason", "outlier_group",
    "exclude_from_training", "exclude_reason", "training_quality_reason",
    "energy_source", "timestamp_was_inserted", "source_gap_id",
    "after_source_gap_steps_remaining",
]

# — 3. Có ban ngày / audit —
DENY_DAYLIGHT_AUDIT = [
    "is_daylight", "weather_is_day", "sunshine_duration", "weather_is_observed",
]

# — 4. Khoa ID - tránh model học vệt index thay vì học đặc tính vật lý —
DENY_IDS = [
    "gen_id", "site_id", "geo_id", "date_id", "time_id", "weather_id", "weather_type_id",
]

# — 5. Categorical thô (đã được mã hóa thành *_enc ở stage s05) —
DENY_RAW_CATEGORICAL = [
    "site_id", "campus_name", "location_name", "site_metric", "panel",
    "inverter", "optimizers", "weather_join_method",
    "weather_condition", "weather_description",
]

# — 6. Thời gian thô —
# 'year' bị cấm vì TANG ĐƠN ĐIỆU, không tuần hoàn:
# train year = {2020, 2021} | test year = {2021, 2022}
# -> 455.616 dòng test (89%) có year = 2022 CHƯA TUNG xuất hiện lúc train.
# Cay quyết định tách theo 'year <= 2021' sẽ áp dụng tác học từ giá trị chưa hề thấy.
# Khác hạn month / day of year / day sin / day cos: những cái do TUẦN HOÀN, lặp hàng năm.
DENY_RAW_TIME = ["timestamp", "time_diff", "full_date", "weather_timestamp", "year"]

# — 7. Công tuyền CẤU TRÚC (không phải tương quan ngẫu nhiên) —
# dni_ratio: VIF vô cực trên mẫu ban ngày. Giữ diffuse_ratio (ý nghĩa vật lý rõ: tỷ lệ
# mây mù), bỏ dni_ratio.
# con_cach_tran = tran_cong_suat - ky_vong: to hợp tuyền tính CHINH XÁC của 2 cột con lai,
# không mang thông tin mới.
# site_scale và tran_cong_suat đều là hàng số theo site (phần vì 99 và 99,9 của CÙNG một
# phân phối) nên tương quan gần tuyệt đối; giữ tran_cong_suat (dạng dung trực tiếp trong
# tỷ lệ bao hòa/con_cach_tran), bỏ site_scale khỏi tập đặc trưng train.
DENY_STRUCTURAL_COLLINEAR = ["dni_ratio", "con_cach_tran", "site_scale"]

# — 8. Metadata của bước split (do stage s02 gán) —
# KHÔNG cam cở tiền tố 'v3_' vì các đặc trưng thật cùng dung tiền tố này.
SPLIT_META = [
    "v3_holdout_split", "v3_test_start_timestamp", "v3_split_strategy",
    "v3_n_time_series_splits", "v3_split", "v3_cv_fold", "v3_cv_role",
]

def dung_deny_list(df: pd.DataFrame, df_diag: pd.DataFrame | None = None) -> tuple[set, dict]:
    """Góp toàn bộ deny list. Tra về (tập cam, chi tiết từng nhóm để bao cáo)."""
    cam = set(
        DENY_TARGET + DENY_PROVENANCE_OUTLIER + DENY_DAYLIGHT_AUDIT
        + DENY_IDS + DENY_RAW_TIME + DENY_RAW_CATEGORICAL + DENY_STRUCTURAL_COLLINEAR
    )
    cam.update(c for c in SPLIT_META if c in df.columns)
    # Mỗi cột có chứa 'timestamp' trong tên: thời gian thô tăng đơn điệu, model sẽ học
    # theo độ lớn của timestamp và không ngoài suy được sang tương lai.
    cam.update(c for c in df.columns if "timestamp" in c.lower())

    trung_lap = set()
    if df_diag is not None and "duplicate_of" in df_diag.columns:
        trung_lap = set(df_diag.loc[df_diag["duplicate_of"].notna(), "feature"])
        cam.update(trung_lap)

    chi_tiet = {
        "target": len(DENY_TARGET),
        "provenance_outlier": len(DENY_PROVENANCE_OUTLIER),
        "daylight_audit": len(DENY_DAYLIGHT_AUDIT),
        "ids": len(DENY_IDS),
        "raw_time": len(DENY_RAW_TIME),
        "raw_categorical": len(DENY_RAW_CATEGORICAL),
        "structural_collinear": len(DENY_STRUCTURAL_COLLINEAR),
        "trung_lap_tu_s06": len(trung_lap),
        "tong_cam": len(cam),
    }
    return cam, chi_tiet

def dac_trung_ung_vien(df: pd.DataFrame, cam: set) -> list[str]:
    return [c for c in df.columns if c not in cam]

```

Hình 19: Đoạn khai báo danh sách cấm trong quy trình chọn đặc trưng. Mỗi nhóm cột bị cấm đi kèm lý do ngay tại chỗ khai báo.

Số dòng bị loại trừ khỏi chấm điểm: 36542

Bảng 27 lấy mười đặc trưng đứng đầu trong 74 ứng viên, chấm trên mẫu 100.000 dòng.

Bảng 27: Mười đặc trưng có điểm thông tin tương hỗ cao nhất. Đọc từ ô kết quả của notebook 05_select_features.ipynb.

Hạng	Đặc trưng	Điểm
1	rolling_max_4	1,1724
2	rolling_mean_4	1,1251
3	ky_vong	1,0785
4	rolling_min_4	1,0582
5	lag_96	1,0018
6	lag_4	0,8315
7	solar_elevation	0,8258
8	sin_elevation	0,7967
9	ty_le_bao_hoa	0,7949
10	ghi_cs	0,7939

Bốn vị trí đầu đều là đặc trưng của số trượt một giờ, và sáu vị trí đầu đều suy từ lịch sử của chính chuỗi sản lượng. Bảng xếp hạng này khớp với kết quả tự tương quan ở Mục 2.2: chuỗi mang tự tương quan +0,8942 tại mốc một giờ, nên các thống kê của cửa sổ một giờ gần nhất là nguồn thông tin mạnh nhất về giá trị sắp tới.

3.7.4 Danh sách bảo vệ

Lấy thẳng 35 đặc trưng đứng đầu sẽ loại mất một số biến khí tượng và hình học Mặt Trời có điểm thấp nhưng cần cho mô hình đọc được điều kiện vật lý tại bước hiện tại. Notebook vì vậy khai báo một danh sách bảo vệ gồm 22 đặc trưng, cả 22 đều có mặt trong dữ liệu, và bổ sung lại những đặc trưng nằm ngoài ngưỡng cắt:

```
--- DANH SACH BAO VE ---
Co trong du lieu : 22/22
Bi Top K cat, da bo sung lai (5): ['azimuth_sin', 'temperature_c',
                                   'rolling_min_96', 'doy_sin', 'doy_cos']
Tong dac trung duoc chon: 35 (Top K) + 5 (bao ve) = 40
```

Năm đặc trưng được bổ sung nằm ở hạng 36, 40, 49, 54 và 68 theo điểm thông tin tương hỗ. Hai cột do_y_sin và do_y_cos mã hoá vị trí trong năm dưới dạng vòng; điểm của

chúng thấp vì trên một mẫu ngẫu nhiên rải khắp 18 tháng, mùa gần như không phân biệt được — nhưng mô hình cần chúng để không coi ngày 31/12 và ngày 01/01 là hai thời điểm xa nhau.

3.7.5 Kết quả áp cho mười tập

Bốn mươi đặc trưng đã chọn được áp đồng loạt cho mười tập dữ liệu — bốn tập chính và sáu phần của ba fold:

```
--- DA LOC 10 TAP THEO 40 DAC TRUNG DA CHON ---
      tap      dong  cot_truoc  cot_sau  feature  cot_phu  \
0      v4_train 1550856      114      50      40      10
1      v4_val   723114      114      50      40      10
2      v4_test  510468      114      50      40      10
3 v4_development 2273970      113      50      40      10
4  fold_1_train  233244      115      50      40      10
5  fold_1_val   606105      115      50      40      10
6  fold_2_train  839349      115      50      40      10
7  fold_2_val   711507      115      50      40      10
8  fold_3_train 1550856      115      50      40      10
9  fold_3_val   723114      115      50      40      10

feature_thieu
0          0
1          0
2          0
3          0
4          0
5          0
6          0
7          0
8          0
9          0
```

Mọi tập đều có đủ đặc trưng đã chọn.

Cột `feature_thieu` bằng 0 ở cả mười dòng, tức không tập nào thiếu đặc trưng đã chọn. Mỗi tập giữ 50 cột: 40 đặc trưng cùng 10 cột phụ trợ gồm mục tiêu, mốc thời gian, mã trạm và các cột phục vụ lọc phạm vi chấm điểm. Danh sách 40 tên cột được ghi ra tệp `selected_features.json` để các bước huấn luyện và phục vụ đọc lại đúng một danh sách duy nhất.

3.8 Tổng hợp bộ đặc trưng đưa vào mô hình

Bảng 28 liệt kê trọn 40 đặc trưng đã chọn, xếp theo sáu nhóm.

Mười bốn cột `_mt` sinh thêm ở bước huấn luyện đều thuộc hai nhóm đầu — hình học Mặt Trời và nhãn lịch — đúng theo ranh giới hợp lệ đã nêu ở Mục 3.4:

Bảng 28: Bốn mươi đặc trưng được chọn, xếp theo nhóm. Đọc từ 05_selected/selected_features.json.

Nhóm	Số cột	Tên cột
Thời gian và lịch tuần hoàn	6	minute_of_day, hour, hour_sin, hour_cos, doy_sin, doy_cos
Hình học Mặt Trời và trời quang	8	solar_elevation, sin_elevation, solar_azimuth, azimuth_sin, azimuth_cos, ghi_cs, cs_factor, chi_so_troi_quang
Khí tượng đo được	5	shortwave_radiation, diffuse_solar_radiation, direct_normal_irradiance, temperature_c, cloud_cover_low
Tương tác và tỷ lệ	5	rad_x_sinelev, temp_x_shortwave, diffuse_ratio, cloud_x_shortwave, cloud_low_x_shortwave
Lịch sử chuỗi	10	lag_4, lag_96, rolling_mean_4, rolling_std_4, rolling_min_4, rolling_max_4, rolling_mean_96, rolling_std_96, rolling_min_96, rolling_max_96
Quy mô trạm và mã hoá	6	ky_vong, ty_le_bao_hoa, tran_cong_suat, site_id_enc, weather_condition_enc, weather_description_enc
Tổng	40	

Thêm 14 đặc trưng tất định tại T+15 phút:

```
['solar_elevation_mt', 'solar_azimuth_mt', 'azimuth_sin_mt',
 'azimuth_cos_mt', 'sin_elevation_mt', 'ghi_cs_mt', 'ky_vong_mt',
 'ty_le_bao_hoa_mt', 'minute_of_day_mt', 'hour_mt', 'hour_sin_mt',
 'hour_cos_mt', 'doy_sin_mt', 'doy_cos_mt']
```

Ma tran train : 599,174 dòng x 54 đặc trưng

Mức tiêu chuẩn hoá k: min 0.0028 trung vi 0.6423 max 1.3764

Không cột khí tượng nào có mặt trong danh sách này. Giá trị lớn nhất của mục tiêu chuẩn hoá bằng đúng 1,3764, tức cận cắt suy từ phân vị 99 ở Mục 3.5 đang hoạt động.

4 Huấn luyện và chọn hàm mất mát

Mô hình là LightGBM hồi quy, huấn luyện riêng cho từng tầm dự báo: H1 dự báo mốc T+15 phút, H4 dự báo mốc T+60 phút. Mỗi tầm nhận 54 đặc trưng — 40 cột đã chọn

ở Mục 3.7 cộng 14 cột tắt định tại thời điểm mục tiêu đã trình bày ở Mục 3.4.

4.1 Chính sách trọng số cho dòng ngoại lai

Các dòng mang nhãn ngoại lai không bị xoá khỏi lưới. Chúng nhận trọng số bằng 0, tức không đóng góp vào hàm mục tiêu, nhưng vẫn nằm trong bảng để bước báo cáo truy ngược được:

```
--- CHINH SACH OUTLIER, experiment = measured_only_headline ---
Dong co weight = 0 khong tham gia ham muc tieu nhung van giu de bao cao.
Tong dong bi loai khoi ham muc tieu: 82,362 / 681,536 (12.08%)
    trong do physical_over_capacity: 0 dong (luon bi loai o moi experiment)
Khoang thoi gian train: 2020-01-02 06:30:00 -> 2021-06-21 17:00:00
```

Cách gán trọng số 0 được chọn thay vì xoá dòng, vì xoá sẽ làm đứt lưới thời gian và mọi đặc trưng trễ, cửa sổ trượt tính sau đó đều đếm sai khoảng cách — đúng vấn đề mà bước dựng lưới ở Mục 2.1 đặt ra để tránh.

4.2 Tinh chỉnh siêu tham số

Mỗi hàm mất mát được Optuna chạy **một phiên tìm kiếm riêng** với ngân sách 20 trial, chấm bằng WAPE gộp trên ba fold cửa sổ mở rộng của tập Phát triển. Không hàm nào phải dùng lại bộ tham số của hàm khác, và không hàm nào bị cố định mức điều hoà.

Miền tìm kiếm khai báo cố định trong cả ba notebook huấn luyện, ghi ở Bảng 29.

Bảng 29: Miền tìm kiếm siêu tham số khai báo cho Optuna. Đọc từ hàm `tham_so_co_ban` trong notebook `06_1_train_mae.ipynb`.

Siêu tham số	Miền	Vai trò
<code>n_estimators</code>	[400; 1200]	Số cây tối đa, early stopping chốt số thật
<code>learning_rate</code>	[0,02; 0,12] thang log	Tốc độ học
<code>num_leaves</code>	[63; 255]	Độ phức tạp mỗi cây
<code>min_child_samples</code>	[20; 120]	Số mẫu tối thiểu mỗi lá
<code>subsample</code>	[0,7; 1,0]	Tỷ lệ mẫu mỗi vòng
<code>colsample_bytree</code>	[0,7; 1,0]	Tỷ lệ cột mỗi cây
<code>reg_alpha</code>	[0; 10]	Điều hoà L_1
<code>reg_lambda</code>	[0; 10]	Điều hoà L_2
<code>alpha</code>	[0,5; 20] thang log	Điểm chuyển của Huber, chỉ Huber có

Vì `reg_alpha` và `reg_lambda` được thả độc lập trên cùng một miền, không gian tìm kiếm bao trùm cả ba chế độ điều hoà: L_1 thuần, L_2 thuần và dạng phối hợp. Mỗi hàm mất mát vì vậy được trao cơ hội ngang nhau để tự tìm mức điều hoà phù hợp trước khi đem ra so.

4.3 Sáu cấu hình Optuna chọn được

Bảng 30: Siêu tham số tốt nhất do Optuna chọn, theo từng hàm mất mát và tầm dự báo. Cả sáu cấu hình dùng chung `random_state = 42`, `deterministic = true` và `max_bin = 127` trên CPU. Đọc từ khoá `best_params` trong tệp kết quả của mỗi notebook huấn luyện.

Cấu hình	Số cây	Tốc độ học	Số lá	Mẫu/lá	Tỷ lệ mẫu	Tỷ lệ cột	L_1	L_2
MAE — H1	800	0,03019	82	88	0,700	0,817	2,58	4,82
Huber — H1	386	0,05781	71	81	0,751	0,720	9,49	9,66
MSE — H1	329	0,05121	146	49	0,884	0,742	2,92	3,66
MAE — H4	400	0,04857	69	111	0,778	0,899	3,12	5,20
Huber — H4	526	0,02849	99	71	0,950	0,770	9,88	4,18
MSE — H4	509	0,03570	134	46	0,869	0,810	9,81	3,99

Điểm chuyển của Huber được Optuna chọn rất khác nhau giữa hai tầm: $\alpha = 9,86$ ở H1 nhưng chỉ 0,73 ở H4. Đọc ngang bảng còn thấy hai xu hướng. Các cấu hình MSE dùng số lá lớn hơn hẳn — 146 và 134 so với 71–99 của Huber — tức cây sâu và chia nhỏ hơn, phù hợp với việc MSE phạt nặng sai số lớn nên có động cơ khớp sát từng vùng dữ liệu. Mức phạt L_1 mà Optuna chọn cho Huber ở cả hai tầm đều gần chạm cận trên của miền (9,49 và 9,88), cho thấy cấu hình này cần ràng buộc mạnh mới ổn định.

Hai chỗ chạm biên miền tìm kiếm. `subsample` của MAE–H1 bằng 0,7003, tức đúng cận dưới; `reg_alpha` của Huber đạt 9,49–9,88 trên miền $[0; 10]$. Khi một siêu tham số dừng ngay tại biên, không thể loại trừ khả năng giá trị tốt hơn nằm ngoài miền đã khai báo. Vì vậy tài liệu này không tuyên bố đây là cấu hình tối ưu toàn cục, mà chỉ là cấu hình tốt nhất tìm được trong miền và ngân sách 20 trial đã khoá từ trước. Mở rộng miền ở hai chỗ đó là việc nên làm ở lần huấn luyện sau.

4.4 Chọn hàm mất mát

Ba hàm được chấm trên tập kiểm định — phần dữ liệu mô hình chưa từng nhìn thấy — ở phạm vi đo thật ban ngày. Phạm vi này xét **dòng nhãn tại $T+h$** đúng như ở bước đánh giá cuối tại Mục 5.2, và loại hai trạm 19, 24 cho khớp với phạm vi huấn luyện. Kết quả đầy đủ của sáu cấu hình ở Bảng 31.

Bảng 31: Sai số trên tập kiểm định, phạm vi đo thật ban ngày. Trong mỗi tầm, cả ba hàm được chấm trên đúng cùng số quan sát. Đọc từ `metrics_val.json` của sáu cấu hình dưới `06_train/`.

Tầm	Hàm mất mát	WAPE (%)	RMSE	MAE	R^2
<i>H1 — 288.811 quan sát cho cả ba hàm</i>					
H1	MAE	22,0515	3,6737	1,5062	0,8984
H1	MSE	22,6588	3,6372	1,5477	0,9004
H1	Huber	22,7936	3,6608	1,5569	0,8991
<i>H4 — 272.569 quan sát cho cả ba hàm</i>					
H4	MAE	26,9585	4,3592	1,9329	0,8628
H4	MSE	27,3309	4,2847	1,9596	0,8675
H4	Huber	27,4040	4,2893	1,9648	0,8672

MAE cho sai số thấp nhất ở cả hai tầm và được chọn cho cả hai. Trong mỗi tầm, ba hàm được chấm trên đúng cùng số quan sát — điều kiện để phép so sánh có nghĩa, vì nếu một cấu hình được chấm trên tập sạch hơn thì chênh lệch WAPE phản ánh phạm vi chứ không phản ánh hàm mất mát.

Đáng chú ý là MAE thắng theo WAPE nhưng thua theo RMSE ở cả hai tầm. Điều này đúng với bản chất hai hàm: MSE phạt bình phương sai số nên ép sai số lớn xuống mạnh hơn, cho RMSE tốt hơn; MAE phạt tuyến tính nên bám phần thân phân bố, cho sai số tương đối tổng thể thấp hơn. Dự án lấy WAPE làm tiêu chí chọn vì nó là chỉ số được báo cáo, và vì mục tiêu vận hành là tổng sai số trên tổng sản lượng chứ không phải khống chế vài sai số cực trị.

Phép chọn này thực hiện hoàn toàn trên tập kiểm định; tập test không tham gia. Notebook `10_compare_optuna_current` có một cổng kiểm tự động cho đúng điều đó, và nó báo PASS.

4.5 Cấu hình tất định

Toàn bộ sáu lần huấn luyện chạy trên CPU với `deterministic = true`, `force_col_wise = true`, `max_bin = 127`, `random_state = 42` và `n_jobs = 6`. Chế độ GPU bị tắt có chủ đích. Tài liệu tham số của LightGBM ghi rõ `deterministic` chỉ có tác dụng với thiết bị CPU, xem Hình 20; bật GPU thì cờ này bị bỏ qua. Quy trình đặt tính tái lập lên trước tốc độ nên chọn CPU.

Kiểm chứng bằng hai phép chạy lại. Sau khi cấu hình đã khoá và tập test đã mở, cả sáu cấu hình được huấn luyện lại từ đầu bằng cùng hạt giống. Kết quả trên tập

```
deterministic, default = false, type = bool
  • used only with cpu device type
```

Hình 20: Mục `deterministic` trong tài liệu tham số của LightGBM. Dòng đầu ghi tham số này chỉ dùng được với thiết bị CPU.

kiểm định của lần chạy lại này chính là Bảng 31 ở Mục 4.4, và thứ tự giữa ba hàm mất mát giữ nguyên so với lần khoá cấu hình. Đây là bằng chứng cho rào chắn thứ năm ở Mục 1.5.

Phép chạy lại thứ hai nằm ở bước giải thích mô hình: bước tính SHAP ở Phần 6 được chạy lại trên mô hình vừa huấn luyện lại và cho bảng xếp hạng cùng giá trị trùng khít tới từng chữ số với lần chạy trước.

5 Đánh giá trên tập test niêm phong

Tập test được tách ra từ đầu ở Mục 2.3 và cất đi. Nó chỉ được mở đúng một lần, ở bước này, sau khi hàm mất mát và bộ siêu tham số đã khoá.

5.1 Thước đo

Chỉ số chính của toàn bộ tài liệu là **WAPE** — sai số phần trăm tuyệt đối có trọng số:

$$WAPE = \frac{\sum_i |y_i - \hat{y}_i|}{\sum_i |y_i|} \times 100\% \tag{11}$$

Ba điểm về cách áp dụng.

Gộp một lần trên toàn bộ phạm vi. Tử số và mẫu số cộng dồn qua mọi trạm và mọi mốc thời gian trong phạm vi đang xét, rồi mới chia. Đây không phải trung bình của WAPE từng trạm; cách gộp này khiến trạm phát nhiều đóng góp nhiều hơn vào con số cuối, đúng với ý nghĩa vận hành là tổng sai số trên tổng sản lượng.

Mẫu số không bao giờ bằng 0. Phạm vi chấm điểm luôn yêu cầu dòng ban ngày và đo thật, nên trong tập được chấm không có trường hợp tổng sản lượng bằng 0.

Chọn WAPE thay cho MAPE. MAPE chia theo từng điểm nên nổ tung ở các mốc sản lượng gần 0 lúc rạng sáng và chập tối — chính những mốc chiếm phần lớn dữ liệu. WAPE đặt tổng ở mẫu số nên không gặp vấn đề đó. Dạng công thức trên trùng với định nghĩa WAPE trong bảng chỉ số của Temporal-Neto và cộng sự [9], xem Hình 21.

Weighted Absolute Percentage Error

$$WAPE(y, \hat{y}) = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{\sum_{i=1}^n |y_i|}$$

Hình 21: Dòng *Weighted Absolute Percentage Error* trong Bảng 1 của Temporal-Neto và cộng sự [9], cắt từ bảng chỉ số đánh giá mô hình dự báo. Công thức trùng với dạng dự án dùng. Cách chia tập và cách lọc phạm vi là thiết kế riêng của dự án.

5.2 Phạm vi chấm điểm

Không phải mọi dòng trong tập test đều dùng để tính chỉ số. Bốn điều kiện lọc được áp dụng như ở bước huấn luyện, đưa 510.468 dòng xuống 478.942 dòng.

Phép dịch nhấn lên $T+h$ loại thêm một phần nữa. Sau khi lọc, lưới thời gian không còn liên tục, nên `shift(-h)` theo trạm có thể trở tới dòng hợp lệ kế tiếp chứ không phải mốc $T+h$. Bước chấm điểm vì vậy đối chiếu mốc thời gian của dòng bị dịch tới và chỉ giữ dòng nào lệch đúng 15h phút: H1 loại 3.303 dòng còn **475.599**, H4 loại 12.964 dòng còn **465.818**. Kiểm lại trên tệp `prediction_audit.parquet` thì không còn dòng nào lệch tầm ở cả hai tầm.

Chỉ số được báo ở ba phạm vi lồng nhau. Điều kiện phạm vi xét **dòng nhấn tại $T+h$** , không phải dòng đặc trưng tại T : hai cột `energy_source` và `is_daylight` được dịch sang mốc nhấn thành `nhan_energy_source` và `nhan_is_daylight` rồi mới dùng để lọc.

- **Toàn bộ** — mọi dòng còn lại sau bốn điều kiện lọc và phép kiểm tầm.
- **Đo thật** — thêm điều kiện `nhan_energy_source = measured`.
- **Đo thật ban ngày** — thêm điều kiện `nhan_is_daylight = true`. Đây là phạm vi chính thức mà tài liệu dùng để báo chỉ số: 229.548 dòng ở H1 và 229.297 dòng ở H4.

Bản trước lọc theo cột tại T . Vì nhấn là sản lượng tại $T+h$, cách đó để lọt vào phạm vi "đo thật ban ngày" những dòng mà nhấn thực chất do bước diên khuyết của tầng ETL sinh ra hoặc rơi vào ban đêm. Sửa lại cho bám mốc nhấn làm WAPE H1 tăng 0,05 điểm và H4 tăng 0,13 điểm — tức con số cũ dễ hơn thực tế.

5.3 Kết quả

Bảng 32 là kết quả chính của toàn bộ tài liệu.

Bảng 32: Sai số WAPE trên tập test niêm phong theo ba phạm vi. Đọc từ ô kết quả của notebook 07_final_test.ipynb và tệp metrics_overall.json của từng tầm.

Phạm vi	H1 (%)	H4 (%)
Toàn bộ	17,12	21,94
Đo thật	17,76	22,65
Đo thật ban ngày	17,74	22,62

Cả hai tầm dùng cấu hình MAE — đúng hai cấu hình thắng trên tập kiểm định ở Mục 4.4.

Phạm vi chính thức gồm 229.713 dòng ở H1 và 229.596 dòng ở H4.

Sai số phân bố không đều giữa các trạm. Ở H1, trạm tốt nhất đạt 11,89% còn trạm kém nhất 28,32%, trung vị 18,12%; ở H4 khoảng này là 15,12% đến 35,88%, trung vị 22,72%. Chênh lệch hơn hai lần giữa hai đầu cho thấy một mô hình dùng chung cho cả 40 trạm vẫn để lại phần khác biệt riêng của từng trạm mà đặc trưng hiện có chưa mô tả hết.

5.4 Chênh lệch giữa sai số trên test và trên kiểm định

Bảng 33 đặt cạnh nhau ba con số của cùng một mô hình ở ba phạm vi đánh giá khác nhau. Chúng **không so trực tiếp được** với nhau, phải đọc kèm phạm vi.

Bảng 33: Cùng mô hình, ba phạm vi đánh giá. Đọc từ 08_baseline_prophet_test/optuna_vs_current_wape.csv.

Phạm vi đánh giá	H1 (%)	H4 (%)
Optuna, gộp ba fold kiểm định	24,1767	29,4090
Test niêm phong, toàn bộ	17,0963	21,8627
Test niêm phong, đo thật ban ngày	17,7409	22,6181
Cùng phạm vi với Prophet	17,7934	22,3645

Sai số trên test thấp hơn trên ba fold kiểm định tới hơn sáu điểm. Nguyên nhân nằm ở vị trí của hai tập trên trục thời gian, không phải ở việc test dễ hơn. Ba fold kiểm định nằm ở giai đoạn **sớm** của chuỗi, nơi lịch sử dùng để tính `lag_96` và các cửa sổ trượt còn ngắn, nên nhiều mốc dự báo thiếu ngữ cảnh. Tập test nằm ở **cuối** chuỗi, mọi mốc đều đã có đủ lịch sử phía sau. Chênh lệch này đến từ phạm vi dữ liệu và không cho phép kết luận rằng tập test đã tham gia vào việc chọn mô hình — hàm mất mát và

siêu tham số đều khoá trên tập Phát triển trước khi tập test được mở.

5.5 Đối chứng với Prophet

5.5.1 Chỉ số dự báo vượt trội

Một con số WAPE đứng một mình không nói lên chất lượng. Nó cần được đặt cạnh một mô hình đối chứng. Chỉ số **Forecast Skill Score** đo phần sai số cắt giảm được so với đối chứng:

$$SS = \left(1 - \frac{WAP E_{\text{mô hình}}}{WAP E_{\text{đối chứng}}}\right) \times 100\% \quad (12)$$

Triết lý đánh giá theo nhiều chỉ số so với một đường cơ sở tham chiếu lấy từ Zhang và cộng sự [11]; công thức cụ thể dùng WAPE ở trên là cách áp dụng của dự án, không trích nguyên văn từ bài báo đó. Hình 22 là đoạn nguồn.

of the data. Conventional measures of solar forecasting accuracy include root mean square error (RMSE), mean bias error (MBE), and mean absolute error (MAE) [3, 4].

Hình 22: Đoạn được đánh dấu trong Zhang và cộng sự [11], NREL/CP-5500-60142: các thước đo thông dụng của dự báo quang điện gồm RMSE, MBE và MAE. Dự án lấy tinh thần đánh giá bằng nhiều chỉ số đặt cạnh một mô hình đối chứng, thay vì đọc một giá trị sai số đơn lẻ.

5.5.2 Điều kiện so sánh

Prophet là mô hình chuỗi thời gian cộng tính, chỉ học xu thế và chu kỳ ngày/tuần từ chính lịch sử sản lượng, **không dùng bất kỳ biến khí tượng nào**. Nó được huấn luyện trong cùng cửa sổ thời gian Phát triển với mô hình chính, rồi dự báo tại đúng các mốc mục tiêu của tập test.

Khi chấm điểm, hai mô hình dùng **cùng một tập dòng**, cùng tử số và cùng mẫu số. Phạm vi này yêu cầu cả giá trị tại T lẫn nhân tại $T+h$ đều là số đo thật, đồng thời dòng tại T là ban ngày — chặt hơn phạm vi đo thật ban ngày của mô hình chính, nên số dòng nhỏ hơn: 220.260 ở H1 và 202.955 ở H4. Kết quả ở Bảng 34.

5.5.3 Giới hạn của phép đối chứng

Chênh lệch 17,46 điểm WAPE ở H1 là kết quả cuối cùng của hai phương án, nhưng **không tách được** thành phần đóng góp của riêng nhóm đặc trưng khí tượng. Lý do là

Bảng 34: Đối chứng với Prophet trên cùng tập dòng. Đọc từ 08_baseline_prophet_test/prophet_bang_bao_cao.csv Và prophet_test_summary.json.

Tầm và mô hình	Số dòng	WAPE (%)	RMSE	MAE	R^2
H1 — LightGBM	220.260	17,7934	3,4432	1,4010	0,9232
H1 — Prophet	220.260	35,2563	5,4666	2,7759	0,8063
<i>Skill Score H1</i>		+49,53%			
H4 — LightGBM	202.955	22,3645	4,3447	1,8483	0,8815
H4 — Prophet	202.955	35,0858	5,6147	2,8997	0,8021
<i>Skill Score H4</i>		+36,26%			

hai mô hình khác nhau đồng thời ở **hai điểm**: thuật toán (phân rã chuỗi cộng tính so với cây tăng cường gradient) và tập đầu vào (không có biến khí tượng so với có). Muốn tách thì phải chạy thêm hai cấu hình đối chứng nữa: LightGBM bỏ hết biến khí tượng, và Prophet có biến ngoại sinh. Hai cấu hình đó nằm ở Mục 8.3 như hướng phát triển tiếp theo.

Ngoài ra, chỉ số vượt trội đo mức cải thiện so với **một** mô hình đối chứng cụ thể, không phải so với mọi phương án khả dĩ. Một đường cơ sở yếu hơn sẽ cho chỉ số cao hơn mà không phản ánh năng lực mô hình tốt hơn.

5.6 Kiểm chứng độ trễ pha trên mô hình cuối

Nguy cơ lớn nhất của một mô hình dự báo quang điện là nó học cách lặp lại giá trị vừa đo thay vì thật sự dự báo — khi đó đường dự báo trông rất khớp nhưng thực chất chỉ là đường thực tế bị đẩy sang phải. Notebook 09_kiem_chung_tre pha đo trực tiếp hiện tượng đó trên 478.902 dòng dự báo H1 của tập test, bằng cách so mốc đạt đỉnh của đường dự báo với mốc đạt đỉnh của đường thực tế, cho từng trạm từng ngày:

```
--- LECH DINH LOCAL: 40 site x 5,080 ngày ---
lech_phut duong = du bao den SAU thuc te (dich phai / tre). am = du bao den SOM.
```

```
count    5080.00
mean      -1.05
std       78.63
min      -495.00
25%      -45.00
50%       15.00
75%       45.00
max       270.00
```

So ngày du bao dịch PHAI (tre) : 2,791 / 5,080 (54.9%)
So ngày dung khop (lech = 0) : 384 / 5,080 (7.6%)
So ngày du bao dịch TRAI (som) : 1,905 / 5,080 (37.5%)

Trung bình lệch $-1,05$ phút, tức gần như không thiên về bên nào; trung vị $+15$ phút, đúng một bước. Nếu mô hình chỉ lặp lại giá trị vừa đo thì độ lệch phải bằng đúng tầm dự báo ở gần như mọi ngày, và tỷ lệ dịch phải sẽ tiến tới 100%. Con số thực tế là 54,9% dịch phải so với 37,5% dịch trái — phân bố hai phía, không phải dấu hiệu của mô hình sao chép.

Độ lệch chuẩn 78,63 phút cho thấy mức phân tán giữa các ngày vẫn lớn, và 32 trên 40 trạm có trung vị nghiêng về phía trễ. Đây là giới hạn còn lại của mô hình, ghi nhận để lần huấn luyện sau xử lý tiếp.

Notebook còn đo một giả thuyết cạnh tranh: nếu độ lệch bắt nguồn từ việc dữ liệu khí tượng chỉ có độ phân giải một giờ, thì đỉnh thực tế xảy ra càng gần cuối khối giờ sẽ càng lệch nhiều. Số đo bác bỏ điều đó — cả bốn vị trí trong khối giờ đều cho trung vị đúng 15 phút, xem Bảng 35.

Bảng 35: Độ lệch đỉnh theo vị trí của đỉnh thực tế trong khối giờ. Đọc từ tệp kết quả 09_kiem_chung_tre_pha/lech-theo-vi-tri-trong-gio_h1.csv.

Phút trong giờ	Số ngày	Độ lệch trung vị (phút)
0–14	1.052	15,0
15–29	1.112	15,0
30–44	1.631	15,0
45–59	1.285	15,0

6 Giải thích mô hình bằng SHAP

Cây tăng cường gradient cho sai số thấp nhưng bản thân mô hình không nói được nó dựa vào đâu để ra một con số. Bước này dùng SHAP để quy phần đóng góp của từng đặc trưng vào từng dự báo.

6.1 Cơ sở phương pháp

SHAP quy phần đóng góp theo giá trị Shapley của lý thuyết trò chơi hợp tác: mỗi đặc trưng được coi là một người chơi, và phần đóng góp của nó là mức thay đổi trung bình của dự báo khi thêm nó vào mọi tổ hợp đặc trưng khác. Cách quy này có tính chất cộng

— tổng đóng góp của tất cả đặc trưng cộng với giá trị nền bằng đúng dự báo — nên được ở mức từng dòng dữ liệu. Lundberg và Lee [10] là công trình đề xuất khung thống nhất này, xem Hình 23.

A Unified Approach to Interpreting Model Predictions

Scott M. Lundberg
Paul G. Allen School of Computer Science
University of Washington
Seattle, WA 98105
slund1@cs.washington.edu

Su-In Lee
Paul G. Allen School of Computer Science
Department of Genome Sciences
University of Washington
Seattle, WA 98105
suinlee@cs.washington.edu

Abstract

Understanding why a model makes a certain prediction can be as crucial as the prediction's accuracy in many applications. However, the highest accuracy for large modern datasets is often achieved by complex models that even experts struggle to interpret, such as ensemble or deep learning models, creating a tension between *accuracy* and *interpretability*. In response, various methods have recently been proposed to help users interpret the predictions of complex models, but it is often unclear how these methods are related and when one method is preferable over another. To address this problem, we present a unified framework for interpreting predictions, SHAP (SHapley Additive exPlanations). SHAP assigns each feature an importance value for a particular prediction. Its novel components include: (1) the identification of a new class of additive feature importance measures, and (2) theoretical results showing there is a unique solution in this class with a set of desirable properties. The new class unifies six existing methods, notable because several recent methods in the class lack the proposed desirable properties. Based on insights from this unification, we present new methods that show improved computational performance and/or better consistency with human intuition than previous approaches.

Hình 23: Trang đầu bài báo Lundberg và Lee [10], *A Unified Approach to Interpreting Model Predictions*, NeurIPS 2017 — nguồn của phương pháp quy đóng góp mà bước này sử dụng.

Phạm vi tính: mô hình thắng ở tầm H1 (cấu hình MAE), chạy trên toàn bộ 478.902 dòng của tập test với 54 đặc trưng. Giá trị SHAP tính trên thang mục tiêu đã chuẩn hoá k , không phải thang kWh.

Ma trận đặc trưng dùng để tính SHAP lấy đúng tệp `X_test_h1.parquet` mà bước đánh giá đã ghi ra, nên phạm vi dòng trùng khít với Phần 5. Bước này đã được chạy lại một lần nữa sau khi mô hình được huấn luyện lại: kết quả xếp hạng và giá trị SHAP trùng khít tới từng chữ số với lần chạy trước, phù hợp với chế độ tắt định nêu ở Mục 4.5.

6.2 Tầm quan trọng tổng thể

Bảng 36 xếp hạng đặc trưng theo trung bình trị tuyệt đối giá trị SHAP trên toàn tập test.

Bảng này cho một kết quả đáng chú ý khi đặt cạnh bảng thông tin tương hỗ ở

Bảng 36: Mười đặc trưng có tầm quan trọng tổng thể lớn nhất, đo bằng trung bình trị tuyệt đối giá trị SHAP. Đọc từ 08_explain/shap_importance.csv.

Hạng	Đặc trưng	SHAP trung bình	Nhóm
1	direct_normal_irradiance	0,0872	Khí tượng đo được
2	ky_vong	0,0851	Quy mô trạm
3	rolling_min_4	0,0799	Lịch sử chuỗi
4	ghi_cs_mt	0,0745	Trời quang tại $T+h$
5	rolling_max_4	0,0671	Lịch sử chuỗi
6	rolling_mean_4	0,0565	Lịch sử chuỗi
7	minute_of_day	0,0469	Thời gian
8	tran_cong_suat	0,0391	Quy mô trạm
9	rolling_std_4	0,0334	Lịch sử chuỗi
10	weather_condition_enc	0,0219	Khí tượng phân loại

Mục 3.7. Ở bước chọn đặc trưng, bốn vị trí đầu đều là thống kê cửa sổ trượt một giờ. Ở đây, đứng đầu lại là `direct_normal_irradiance` — một biến khí tượng đo được — và vị trí thứ tư thuộc về `ghi_cs_mt`, tức bức xạ trời quang **tại thời điểm mục tiêu**.

Hai điểm rút ra. Thứ nhất, thông tin tương hỗ đo quan hệ của một đặc trưng với mục tiêu khi đứng riêng, còn SHAP đo phần đóng góp của nó **trong mô hình đã huấn luyện**, nơi các đặc trưng chia nhau thông tin; hai thước đo trả lời hai câu hỏi khác nhau nên không buộc phải trùng thứ hạng. Thứ hai, việc `ghi_cs_mt` lọt vào nhóm bốn đầu là bằng chứng cho thấy nhóm đặc trưng tất định tại $T+h$ ở Mục 3.4 thực sự được mô hình dùng, chứ không phải cột thừa.


Hình 24 trình bày phân bố giá trị SHAP của từng đặc trưng trên toàn bộ tập test.

6.3 Giải thích ba dự báo cụ thể

Tính cộng của SHAP cho phép mở xẻ một dự báo đơn lẻ. Notebook chọn ba trường hợp tương phản trong tập test, ghi ở Bảng 37.

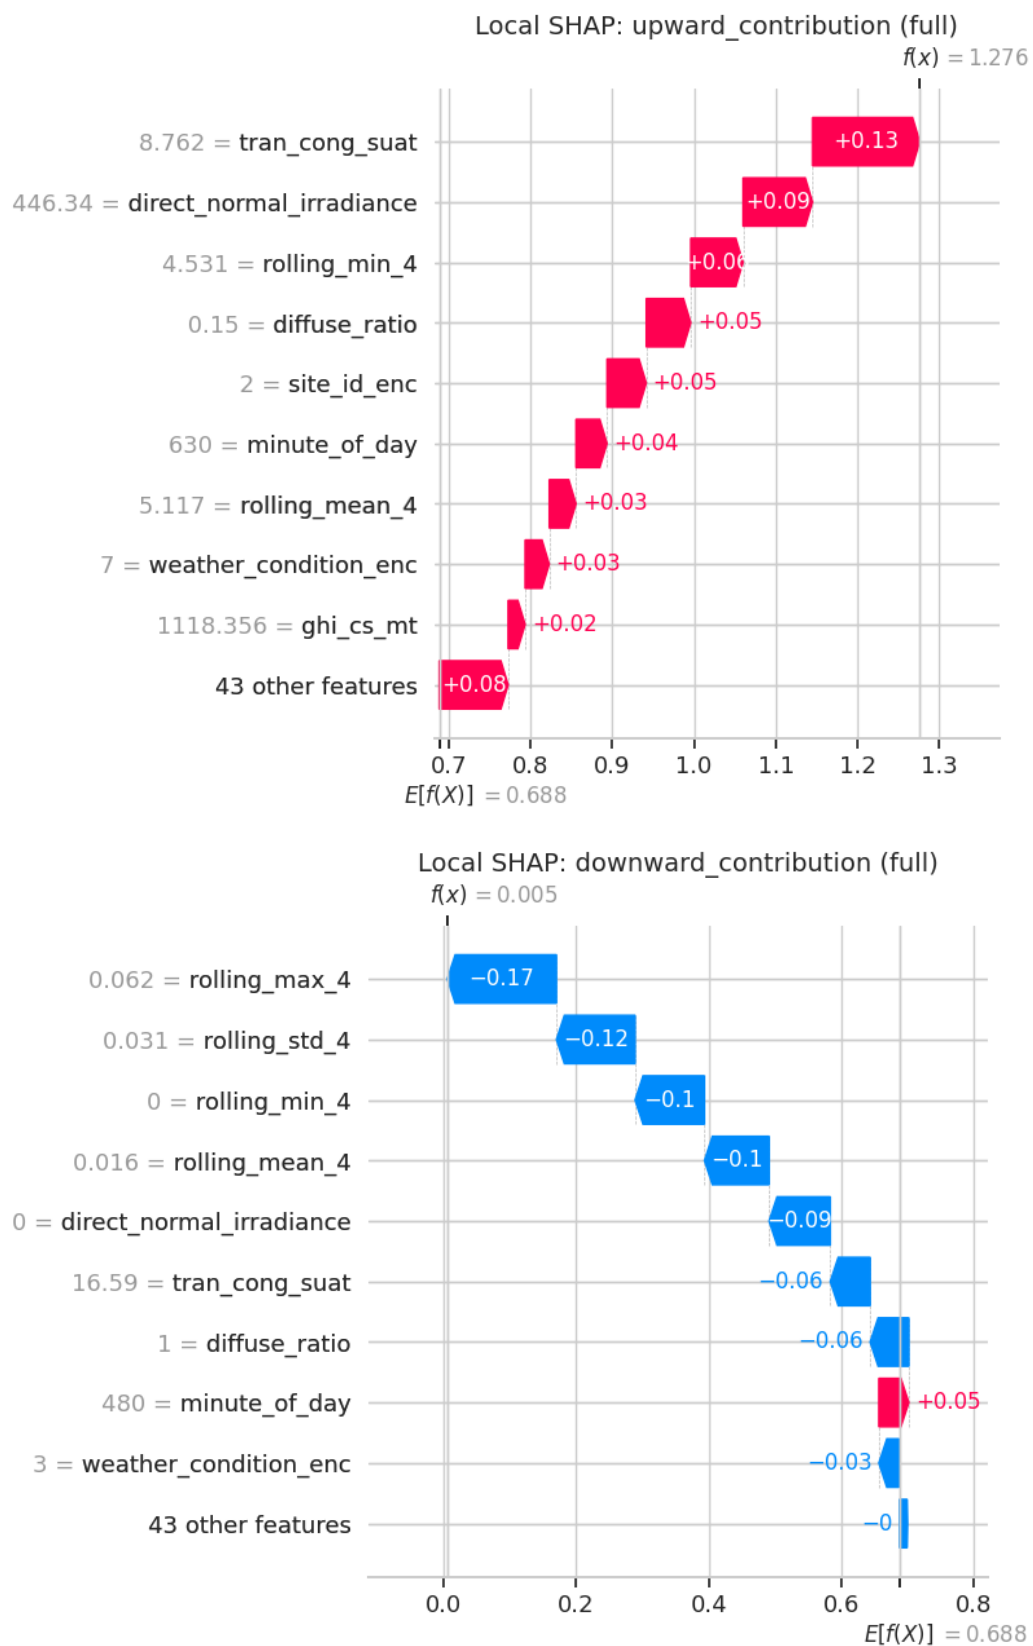
Bảng 37: Ba dự báo được mở xẻ. Đọc từ 08_explain/local_shap_cases.csv.

Trường hợp	Trạm	Thời điểm	Thực tế (kWh)	Tổng SHAP
Đẩy dự báo lên	10	07/04/2022 10:30	5,9688	+0,5972
Kéo dự báo xuống	40	18/04/2022 08:00	0,1250	−0,6860
Gần mức nền	28	21/02/2022 11:15	1,8066	−0,0004



Hình 24: (Trích xuất từ Notebook 08_explainable_ai.ipynb) Biểu đồ beeswarm. Mỗi điểm là một dòng dữ liệu; vị trí ngang là giá trị SHAP, màu là độ lớn của chính đặc trưng đó.

Ba trường hợp này minh họa ba chế độ khác nhau của mô hình. Ở ca đẩy lên, đóng góp lớn nhất đến từ `direct_normal_irradiance` (+0,1047) và `rolling_min_4` (+0,0695) — bức xạ trực xạ mạnh cộng với nền sản lượng giờ trước còn cao. Ở ca kéo xuống, hai đặc trưng đẩy mạnh nhất theo chiều âm là `rolling_max_4` (−0,1953) và `rolling_min_4` (−0,1111), kèm `direct_normal_irradiance` (−0,1019): sáng sớm, sản lượng giờ trước gần như bằng không và bức xạ trực xạ chưa lên. Ở ca gần nền, tổng đóng góp gần triệt tiêu vì các phần dương và âm cân nhau. Ba hình dạng thác trình bày ở Hình 25.



Hình 25: (Trích xuất từ Notebook 08_explainable_ai.ipynb) Biểu đồ thác cho hai dự báo tương phản. **Trên:** trường hợp các đặc trưng cùng đẩy dự báo lên. **Dưới:** trường hợp cùng kéo xuống.

6.4 Giới hạn diễn giải

SHAP quy phần đóng góp của đặc trưng vào **dự báo của mô hình**, không phải vào sản lượng thật. Nó cho biết mô hình đã dựa vào đâu, không cho biết quan hệ nhân quả vật lý. Khi hai đặc trưng tương quan cao — mà Mục 3.7 cho thấy có nhiều cặp như vậy — phần đóng góp có thể bị chia giữa chúng theo cách phụ thuộc vào cấu trúc cây đã học, nên không nên đọc thứ hạng như một xếp hạng tầm quan trọng vật lý.

7 Ứng dụng trực quan hoá kết quả

Kết quả dự báo được đưa vào một ứng dụng Streamlit gồm ba trang, mã nguồn tại `srcs/07_dashboard/`. Ứng dụng đọc lại đúng các tệp kết quả mà Phần 5 dùng, không tính lại chỉ số. Ba trang lần lượt ở Hình 26, Hình 27 và Hình 28.

7.1 Trang giám sát chuỗi thời gian

Trang này đặt đường thực tế cạnh đường dự báo theo từng trạm và từng khoảng thời gian, kèm bảng chỉ số theo trạm và biểu đồ đối chiếu với Prophet.

7.2 Trang giải thích dự báo

Trang này đưa kết quả SHAP ở Phần 6 lên giao diện: tỷ trọng đóng góp theo nhóm đặc trưng, xếp hạng đặc trưng, và giải thích một dự báo cụ thể do người dùng chọn.

7.3 Trang dự báo và phân tích giả định

Trang này gọi `forecast_service.py` để sinh dự báo mới. Điểm cần nêu về mặt kỹ thuật: dịch vụ này **đọc lại** `clip_k` và các tham số chuẩn hoá từ `model_config.json` của chính mô hình đang dùng, thay vì khai báo lại trong mã phục vụ. Nhờ vậy phép nhân ngược từ k về kWh ở lúc suy luận trùng khớp với lúc huấn luyện; nếu hai bên khai báo riêng thì chỉ cần một lần sửa cấu hình là kết quả trên giao diện lệch khỏi kết quả trong báo cáo mà không ai phát hiện.

Time Series & Baseline

Model Explainability (XAI)

Dự báo tới & What-if

Solar Forecast Analytics

The Outliers · Energy Forecasting

Bộ lọc

Horizon

h1 (15 phút)

Artifact đang hiển thị: MAE · H1 — chọn từ validation

Site

1

Chỉ dòng ban ngày

Chỉ dữ liệu đo thật (bỏ outlier/impute)

Hiện đường Prophet (đối chứng)


Khoảng ngày

Cửa sổ 7 ngày

Tự chọn

Cửa sổ

2021-12-30 00:00:00



Time Series & Baseline

Model Explainability (XAI)

Dự báo tới & What-if

Solar Forecast Analytics

The Outliers - Energy Forecasting

Bộ lọc

Horizon

H1 (15 phút)

Mô hình / hàm mất mát

MAE

Đang chạy model MAE - H1; mặc định là model được chọn trên validation.

Trạm

1

Số ngày dự báo

7

Dự báo đệ quy mất khoảng 1 giây mỗi ngày.

FPT Education

FPT POLYTECHNIC

Dự báo sản lượng những ngày tới

Thời tiết lấy trực tiếp từ Open-Meteo theo tọa độ thật của trạm, đưa qua đúng chuỗi đặc trưng của pipeline rồi vào model MAE H1 được chọn từ validation.

DỰ BÁO TRỰC TUYẾN

TỔNG DỰ BÁO

2,524 kWh

7 ngày tới

NGÀY CAO NHẤT

375 kWh

▲ 2026-08-19

NGÀY THẤP NHẤT

327 kWh

▼ 2026-08-20

SỐ BƯỚC ĐỆ QUY

671

mỗi bước 15 phút

KPI WAPE ở trang Time Series KHÔNG phải độ chính xác của dự báo này. Chỉ số đó đo năng lực dự báo một bước (15 phút tới) trên tập test. Dự báo nhiều ngày được thực hiện bằng đệ quy — giá trị vừa dự báo trở thành đầu vào vào `lag_4/rolling_*` cho bước kế tiếp — nên sai số tích lũy dần và độ tin cậy giảm theo khoảng cách. Ngày đầu đáng tin hơn hẳn ngày thứ mười bốn.

Sản lượng dự báo theo bước 15 phút — Trạm 1

Đường cam là sản lượng dự báo, đường chấm chàm là bức xạ Open-Meteo. Bức xạ đã được lùi 1 giờ khi vẽ: giá trị API trả về tại 10:00 là trung bình của khoảng 09:00-10:00, nên vẽ đúng nhãn API sẽ đặt nó muộn 1 giờ so với lúc bức xạ thật sự xảy ra. Sau khi lùi, hai đường đi cùng nhịp — đó là bằng chứng mô hình đang bám thời tiết.

Tổng hợp theo ngày — đối chiếu với thời tiết dự báo

Ngày	Tổng (kWh)	Đỉnh (kWh)	Mây TB (%)	Bức xạ đỉnh (W/m²)	Nhiệt độ TB (°C)
2026-08-15	362.1	16.91	3	644	8.2
2026-08-16	363.7	16.89	15	646	9.3
2026-08-17	362.4	16.87	38	638	9.6
2026-08-18	373.1	17.49	58	639	10.4
2026-08-19	374.8	16.47	50	446	11.9
2026-08-20	327.5	13.48	94	448	12.6
2026-08-21	360.1	15.90	81	491	11.1

Ngày nhiều mây cho tổng thấp, ngày trời quang cho tổng cao — quan hệ này giữ được suốt chân trời dự báo.

What-if — nếu điều kiện khác đi thì sao?

Phần này chạy ở chế độ một bước, không đệ quy. Bốn trong mười đặc trưng quan trọng nhất là `lag_4` và `rolling_*` — sản lượng gần đây. Khi đệ quy, chúng lấy từ chính đầu ra của mô hình, tạo vòng tự neo làm tắt tín hiệu thời tiết: do thực tế trên trạm 1, bức xạ +20% cho +7,33% ở chế độ một bước nhưng chỉ +0,47% khi đệ quy 7 ngày, có ngày còn đối đầu. Dùng số đệ quy ở đây sẽ ra biểu đồ gần như phẳng và người đọc kết luận sai rằng mô hình không quan tâm thời tiết.

Điều chỉnh

Bức xạ mặt trời

1.00

Nhiệt độ

1.00

Độ mây

1.00

Quy mô hệ thống (số tấm pin)

1.00

Không có thanh tốc độ gió: `wind_speed` không nằm trong bộ đặc trưng của mô hình, mọi hệ số nhân đều cho đúng.

Hình 28: Trang 3 của ứng dụng — dự báo và phân tích giả định.

67

vi do thật ban ngày. So với đối chứng Prophet trên cùng tập dòng, chỉ số vượt trội đạt +49,53% và +36,26%.

Điều đáng nói hơn con số là cách các con số đó được bảo vệ. Năm rào chắn ở Mục 1.5 được kiểm chứng bằng số liệu chứ không bằng lập luận: phép ghép thời tiết nhân quả đưa số dòng dùng thời tiết tương lai về 0; thống kê quy mô tính riêng theo từng fold; cận cắt suy từ phân vị của tập huấn luyện; tập test mở đúng một lần. Khi phát hiện tầm H4 có thể cho kết quả tốt hơn với cấu hình MAE huấn luyện sau, nhóm không chấm lại tập test, vì mở tập niêm phong lần thứ hai chính là điều mà toàn bộ quy trình được dựng ra để ngăn.

8.2 Giới hạn

- **Bộ dữ liệu độc lập nhỏ hơn con số 42.** Bốn mươi hai dàn quang điện nằm trên năm khuôn viên, nên dữ liệu khí tượng bị nhân bản giữa các trạm cùng khuôn viên; số mẫu thời tiết độc lập thực chất là năm.
- **Sai số phân bố không đều giữa các trạm,** từ 11,89% tới 28,32% ở tầm H1, và 15,12% tới 35,88% ở tầm H4. Mô hình dùng chung chưa mô tả hết phần khác biệt riêng của từng trạm.
- **Độ trễ pha còn tồn tại ở mức thấp:** trung vị +15 phút, và 32 trên 40 trạm nghiêng về phía trễ.
- **Phép đối chứng Prophet không tách được đóng góp của biến khí tượng,** vì hai mô hình khác nhau đồng thời ở thuật toán và tập đầu vào.
- **Hai siêu tham số dừng ngay tại biên miền tìm kiếm,** nên không thể tuyên bố cấu hình hiện tại là tối ưu.
- **Thời tiết chỉ có độ phân giải một giờ,** và bước hạ độ phân giải mới đưa tỷ lệ bước có giá trị thay đổi lên 76,7%, chưa phủ hết các khối rìa sáng và rìa chiều.

8.3 Hướng phát triển

Bốn việc cụ thể, xếp theo mức dễ làm:

1. Huấn luyện bổ sung cấu hình MAE cho tầm H4 rồi khoá lại trước khi mở một tập test mới, để phép so ở H4 có đủ ba hàm mất mát.

2. Mở rộng miền tìm kiếm ở hai chỗ chạm biên — hạ cận dưới của `subsample` và nâng cận trên của `reg_alpha`.
3. Chạy hai cấu hình đối chứng còn thiếu để tách phần đóng góp của nhóm đặc trưng khí tượng: một `LightGBM` bỏ hết biến khí tượng, và một `Prophet` có biến ngoại sinh.
4. Xử lý phần khác biệt giữa các trạm, hoặc bằng đặc trưng riêng cho trạm, hoặc bằng cách hiệu chỉnh đầu ra theo từng trạm sau khi dự báo.

Tài liệu tham khảo

- [1] S. Wimalaratne, D. Haputhanthri, S. Kahawala, G. Gamage, D. Alahakoon và A. Jennings (2022), “UNISOLAR: An Open Dataset of Photovoltaic Solar Energy Generation in a Large Multi-Campus University Setting”, *15th International Conference on Human System Interaction (HSI)*, IEEE. DOI: [10.1109/HSI55341.2022.9869474](https://doi.org/10.1109/HSI55341.2022.9869474)
- [2] M. Roy, V. Pyltsov và Y. Hu (2025), “IISE PG&E Energy Analytics Challenge 2025: Hourly-Binned Regression Models Beat Transformers in Load Forecasting”, Columbia University, arXiv:2505.11390. <https://arxiv.org/abs/2505.11390>
- [3] T. Kim, W. Ko và J. Kim (2019), “Analysis and Impact Evaluation of Missing Data Imputation in Day-ahead PV Generation Forecasting”, *Applied Sciences*, tập 9, số 1, bài 204. DOI: [10.3390/app9010204](https://doi.org/10.3390/app9010204)
- [4] X. Li, G. Du, Y. Li, Z. Ma, L. Liu, M. Jiang, F. Liu và T. Mu (2025), “Outlier Detection of Photovoltaic Power Generation System Data Based on GMM-IF Algorithm”, *IEEE Access*, tập 13, tr. 108823–108837. DOI: [10.1109/ACCESS.2025.3581641](https://doi.org/10.1109/ACCESS.2025.3581641)
- [5] B. Haurwitz (1945), “Insolation in Relation to Cloudiness and Cloud Density”, *Journal of Meteorology*, tập 2, số 3, tr. 154–166. https://journals.ametsoc.org/view/journals/atsc/2/3/1520-0469_1945_002_0154_iirtca_2_0_co_2.xml
- [6] M. D. Bailey và cộng sự (2024), “Temporal and Spatial Downscaling for Solar Radiation”, arXiv:2405.11046. <https://arxiv.org/abs/2405.11046>
- [7] N. A. Engerer và F. P. Mills (2014), “KPV: A clear-sky index for photovoltaics”, *Solar Energy*, tập 105, tr. 679–693. DOI: [10.1016/j.solener.2014.04.019](https://doi.org/10.1016/j.solener.2014.04.019)
- [8] S. Dev, T. AlSkaif, M. Hossari, R. Godina, A. Louwen và W. van Sark (2018), “Solar Irradiance Forecasting Using Triple Exponential Smoothing”, *IEEE International Conference on Smart Energy Systems and Technologies (SEST)*. arXiv:1807.05872. <https://arxiv.org/abs/1807.05872>
- [9] A. Temporal-Neto và cộng sự (2025), “PIN: A new metric to evaluate solar irradiance forecast models”, *Energy Reports*, tập 13, tr. 1–12. DOI: [10.1016/j.egyr.2025.01.076](https://doi.org/10.1016/j.egyr.2025.01.076)

- [10] S. M. Lundberg và S.-I. Lee (2017), “A Unified Approach to Interpreting Model Predictions”, *Advances in Neural Information Processing Systems (NeurIPS)*, tập 30. arXiv:1705.07874. <https://arxiv.org/abs/1705.07874>
- [11] J. Zhang, B.-M. Hodge, A. Florita, S. Lu, H. F. Hamann và V. Banunarayanan (2013), “Metrics for Evaluating the Accuracy of Solar Power Forecasting”, NREL/CP-5500-60142, *3rd International Workshop on Integration of Solar Power into Power Systems*. OSTI Report No. 1114086. <https://www.nrel.gov/docs/fy14osti/60142.pdf>
- [12] V. P. Lonij, A. E. Brooks, K. Koch và A. D. Cronin (2012), “Analysis of 80 Rooftop PV Systems in the Tucson, AZ Area”, *38th IEEE Photovoltaic Specialists Conference (PVSC)*, tr. 549–553. DOI: [10.1109/PVSC.2012.6317674](https://doi.org/10.1109/PVSC.2012.6317674). Nguồn của chỉ số K dùng phân vị sản lượng đo được của chính hệ thống làm mẫu số.